

YOLO-PEFT: Parameter-Efficient Fine-Tuning on YOLO Family

Paper Reading 是从个人角度进行的一些总结分享，受到个人关注点的侧重和实力所限，可能有理解不到位的地方。具体的细节还需要以原文的内容为准，博客中的图表若未另外说明则均来自原文。

论文概况	详细
标题	《YOLO-PEFT: Parameter-Efficient Fine-Tuning on YOLO Family》
作者	Xu Lin、Wen Jie Nie、Jinlong Peng、Weifu Fu、Yue Xiao Ma、Xiawu Zheng、Yong Liu
发表会议	未获取（arXiv 预印本，编号 arXiv:2608.07051）
会议等级	未获取
发表年份	2026
论文代码	github.com/Tencent/YOLO-Master

作者单位：

- 1. Tencent
- 2. Xiamen University（厦门大学）

研究动机

目标检测模型的规模化部署是对同一套预训练权重的持续再适应过程，新的类别词表、领域、传感器、时延目标和硬件后端都要求反复微调。全量微调需要为每个部署变体复制完整的训练状态与检查点，参数高效微调（PEFT）因此成为降低适配与分发成本的重要手段。但是，为大致同构的 Transformer 栈设计的 PEFT 方法并不能安全迁移到异构的检测器计算图上：现代检测器交错出现稠密卷积、分组卷积与深度可分离卷积，还包含与损失耦合的 DFL 投影、可变形注意力、文本-图像融合与 MoE 路由，不加甄别地插入 LoRA 可能引发优化失败或严重的 mAP 退化。

现有方案在这一问题上留下四个互相独立的缺口：

1. 通用 PEFT 接口按模块名称或类型选择目标，训练前不检查算子契约、检测语义、图接口与放置风险；
2. SpotPatch、LoRA-Det、YOLO-IOD 等检测器专用方法证明了选择性适配的价值，但其放置策略绑定在特定检测器、任务或组件上，缺乏跨越卷积、Transformer、多模态与 MoE 图的统一抽象；
3. 放置本身不提供覆盖训练、adapter-only 检查点、合并与 ONNX/TensorRT 导出的端到端契约，部署兼容性依赖方法特定的集成；
4. 已有接口没有校准机制在高风险的架构-adapter 组合进入完整训练之前识别它们，失败主要依靠代价高昂的试错来发现。

暂未有工作在异构检测器家族上给出一个训练前可审计、可拒绝的 adapter 放置规划框架。

文章贡献

针对上述缺口，本文提出了 YOLO-PEFT，一个结构感知的 PEFT 框架。其核心是把 adapter 放置建模为一个可审计的约束规划问题，而不是再提出一种新的低秩参数化。框架首先把检测器解析为带算子角色与语义角色的类型化图，并用一个有界的十维架构指纹刻画检测器结构；接着按固定顺序施加算子有效性、检测语义、图接口、架构策略与预算可行性约束，在幸存目标上求解预算感知的秩分配，并在校准覆盖内估计失败风险；最终被接受的方案落入统一的训练-保存-合并-导出运行时，当约束无可行交集或校准预测到灾难性退化时返回 Refuse，并把 Full-SFT 作为一等的回退结果。实验表明，在官方 VOC07+12 trainval 到 VOC07 test 协议下，规划器选出的 RS-LoRA 在 YOLO11s 与 YOLO12s 上分别达到 0.7138 与 0.7307 mAP50-95，均超过 Full-SFT 的 0.6428 与 0.6662，而 RT-DETR-L 上七种 LoRA 族配置全部触发校准拒绝，支持了拒绝到全量微调的校准决策。

本文方法

本文方法整体是一条四阶段流水线：解析检测器、求解约束合法的放置、把方案降级到 YOLO 运行时、应用兼容的训练策略，整体流程如下图所示。

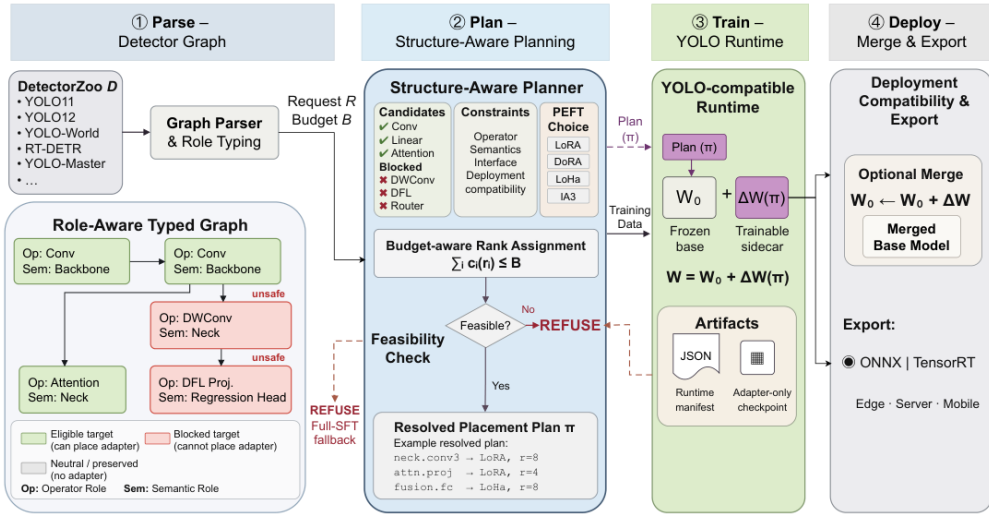


Fig. 1. System overview. The pipeline (1) parses a detector from a supported, evaluated family into a role-aware typed graph, (2) filters unsafe targets, selects the PEFT method, and resolves an adapter placement π via budget-aware rank assignment $\sum_i c_i(r_i) \leq B$, or, within calibrated coverage, returns REFUSE with a Full-SFT fallback, (3) trains sidcar adapters while freezing the base weights ($W=W_0+\Delta W(\pi)$) and saves an adapter-only checkpoint with its runtime manifest, and (4) optionally merges the adapters into an ordinary YOLO model and exports the resulting model through ONNX/TensorRT for edge, server, or mobile deployment.

图中的四列分别对应解析、规划、训练与部署四个阶段，被标记为 **unsafe** 的深度卷积与 DFL 投影在规划阶段即被排除，无法通过适配器进入训练。

问题形式化与放置定义

YOLO-PEFT 把 **adapter** 放置定义为一个带约束的决策问题。检测器 D 表示为有向无环图 $G = (V, E)$ ，PEFT 请求记为 $R = (p, T, L, K)$ ，放置的定义如下：

$$\pi : V_{cand} \rightarrow \{0\} \cup K$$

其中 V_{cand} 是幸存候选模块集合， $\pi(i) = 0$ 表示第 i 层保持冻结， $\pi(i) = r \in K$ 表示给该层分配一个秩为 r 的 **adapter**。直观上，一个合法方案必须同时满足算子有效性、检测头语义安全、图接口兼容、参数预算可行与部署兼容五类约束，规划器的输出定义为：

$$P(G, R, B) = (d, \pi, J), \quad d \in \{Accept, Refuse\}$$

其中 d 是接受或拒绝的决策， B 是 **adapter** 参数预算， J 是有序拒绝日志。这一设计使接受与拒绝都可审计：被接受的方案同样记录被排除的模块，拒绝则至少返回一个终结原因码，从而区分「不支持」与「预测不准」，避免同一个 **Refuse** 掩盖不同成因。

角色感知的图解析与架构指纹

图解析器为每个模块赋予双重角色，是后续全部约束过滤的信息基础。论文强调，同一个 Conv2d 可能属于骨干块、特征金字塔融合、回归头或固定的 DFL 投影，仅凭 Python 类型不足以判定它是否为安全目标。算子角色捕获计算契约：稠密卷积接受普通低秩因子，分组卷积要求组内局部因子，深度卷积不能接受跨通道混合的更新，归一化、激活与未知算子被保守处理；语义角色捕获检测器含义：固定 DFL 投影、几何敏感的回归路径与 MoE 路由被排除，因为微小的更新就可能改变校准好的分箱或专家分配。解析器能识别 YOLO12 的 Area-Attention 块、RT-DETR 的可变形注意力、YOLO-World 的文本融合与 MoE 路由结构，未知模块一律获得 unknown 角色且不被适配。

为了支撑架构级的风险分析，解析器还构造一个有界指纹 $\phi(G) \in \mathbb{R}^{10}$ ，其五个核心维度的定义为：

$$\phi_{core} = (\phi_{attn}, \phi_{text}, \phi_{moe}, \phi_{dw}, \phi_{conv})$$

其中 $\phi_{attn} = |attention|/|V_{role}|$ 度量注意力模块的相对占比， ϕ_{dw} 同理度量深度卷积占比，其余三个维度分别度量文本融合、MoE 专家与稠密/分组卷积的相对占比。另外五个扩展维度编码深度、宽度、头参数比、残差密度与归一化类型。核心维度驱动稳定性分析与变体级 LOVO 评估，指纹随后被架构策略与可靠性校准消费。

符号	含义
$G = (V, E)$	检测器对应的有向无环图
$R = (p, T, L, K)$	PEFT 请求：变体、可选目标集、可选层区间、允许秩集合
B	adapter 参数预算
$z_i = (o_i, s_i, q_i, h_i)$	模块 i 的算子、语义、图接口与部署元数据
$\phi(G)$	检测器的十维架构指纹
J	有序拒绝日志

约束接口与硬约束过滤

规划器按固定顺序施加约束：过滤算子、过滤语义、应用架构策略、分配秩、最后校验可靠性，有效性检查先于效率优化，因为在不安全的层上优化秩分配不可能产出可部署的方案。六类约束的正式接口如下表所示。

Tab. 2. Formal constraint interface. Each row specifies the information consumed, the deterministic acceptance rule, the planner output, and the reason returned when the rule fails. Reliability calibration is evaluated only after the hard constraints.

Constraint	Input	Decision rule	Output if valid	Rejection reason
Operator validity	o_i, p, r : operator type-/shape, groups G , requested variant and rank	Dense conv/linear must be supported by the selected backend. Grouped conv requires group-local factors and $G \mid r$. Depthwise, norm/activation and unknown operators are excluded unless a structure-preserving implementation is registered.	Candidate module with a legal adapter shape	E-OP-UNSUPPORTED, E-GROUP-RANK, E-DEPTHWISE-MIX
Semantic safety	s_i and loss-coupled tags	Exclude fixed DFL bin projections, MoE routers and geometry-sensitive regression subpaths. Classification/regression heads are not treated uniformly: only explicitly whitelisted, loss-compatible subpaths may survive.	Semantically admissible candidate	E-DFL-FIXED, E-HEAD-GEOMETRY, E-ROUTER-ASSIGN
Graph interface	q_i : tensor shapes, fan-in/out, residual and fusion edges	Substitution must preserve input/output shape, number and ordering of tensors, residual identity, and the surrounding execution container.	Interface-preserving host replacement	E-SHAPE, E-MULTIINPUT, E-RESIDUAL
Architecture policy	$\phi(G), p$ and family-scoped guards	Apply only policies calibrated for the recognised family. RT-DETR decoder sampling offsets/attention weights remain frozen; unsupported decoder-wide requests are refused. YOLO12 attention and YOLO-World fusion use their scoped target policies.	Restricted candidate set or documented variant rewrite	E-DECODER-CALIB, E-FAMILY-UNKNOWN
Budget feasibility	Candidate costs $c_p(i, r)$ and budget B	Require $\sum_i c_p(i, \pi(i)) \leq B$ and at least one nonzero-rank target.	Budget-feasible rank assignment	E-BUDGET, E-EMPTY-PLAN
Deployment compatibility	h_i : backend, merge, checkpoint and exporter capabilities	Installed adapters must support adapter-only persistence and either a verified merge or an explicitly supported unmerged export path.	Train-save-merge-export contract	E-NOMERGE, E-EXPORT, E-CHECKPOINT
Reliability calibration	Surviving plan, $\phi(G)$ and variant p	Within calibrated coverage, refuse if predicted Δ mAP is below -0.05 ; outside coverage return unsupported rather than extrapolating a safety guarantee.	ACCEPT with risk score	R-CATASTROPHE, R-OUT-OF-SCOPE

表中每一行约束都消费特定的元信息、执行确定性的接受规则，失败时返回明确的原因码，例如分组卷积秩不可整除返回 E-GROUP-RANK、固定 DFL 返回 E-DFL-FIXED。过滤顺序上，规划器先移除深度卷积、归一化/激活与未知算子；对分组数为 G 的分组卷积，总秩按 $r = \sum_{g=1}^G r_g$ 分配，均衡分配取 $r_g = r/G$ ，因此要求 $G \mid r$ ；随后移除固定 DFL 投影、MoE 路由与几何敏感的回归路径。用户指定的目标集 T 与层区间 L 只在强制过滤之后做交集，显式请求无法重新启用不安全模块。

架构条件策略与端到端示例

家族级策略把经验性安全护栏编码进规划器，但这些策略只对已校准的家族生效。评估过的 RT-DETR-L 画像 ($\phi_{attn} > 0.7$) 拒绝校准阈值以下的全部 LoRA 族配置；注意力占比高的 YOLO12 上 DoRA 被转换为 LoRA 并启用安全注意力训练；YOLO-World 的文本融合请求可以从 LoRA 路由到 LoHa。模块级规则同样保守：YOLO12 排除 `attn.{qkv,proj,pe}` 与 Area-Attention 内部 MLP 卷积，RT-DETR 排除网格初始化的 `sampling_offsets` 与零初始化的 `attention_weights`，`.dfl` 投影永远冻结。

论文以 YOLO12s 上的 rank-16 RS-LoRA 请求演示了完整的规划过程：算子过滤去掉缺乏通道保持适配器的深度卷积宿主，语义过滤去掉 `.dfl` 与几何敏感的回归节点，YOLO12 策略再去掉注意力内部结构，图接口检查保留形状保持的骨干/颈部宿主，预算求解器给幸存的稠密卷积分配 $r = 16$ 直到预算用尽。可见最终目标集完全由图角色与约束生成，而不是一份隐藏的手写列表，改变用户区间或预算只会改变最后的交集与秩分配，强制排除项始终不变。

预算化秩分配与可靠性校准

过滤完成后，规划器在预算约束下求解效用最大化的秩分配，形式化为：

$$\max_{\pi} \sum_{i \in V_{cand}} u(i, \pi(i); p, \phi) \quad s.t. \quad \sum_i c_p(i, \pi(i)) \leq B$$

其中 u 是候选对的效用函数， c_p 是安装成本。对 LoRA 式 adapter，设每个可训练参数占 b 字节，则 $c_{linear} = br(d_{in} + d_{out})$ ， $c_{conv} = br(C_{in}k_hk_w + C_{out})$ ，分组卷积使用 $b \sum_g r_g((C_{in}/G)k_hk_w + C_{out}/G)$ 。rule-only 模式下 $u = u_{op} + u_{sem} + u_{range} + u_{rank} - \lambda c_p$ ，效用非正的候选对被直接丢弃。

给出一个简单的例子，假设一个 $C_{in} = C_{out} = 256$ 、核大小 3×3 的稠密卷积宿主，以 FP16 存储（ $b = 2$ ）、秩 $r = 16$ ，则成本为 $c_{conv} = 2 \times 16 \times (256 \times 9 + 256) = 81920$ 字节。可以看到，单个卷积宿主的秩成本与输入通道数和核面积线性相关，规划器据此在预算内决定把 adapter 装到哪几层；若所有秩都为零或实现成本超出预算，方案被拒绝。

对未被硬约束解决的候选对，校准模式在其覆盖内预测：

$$\Delta mAP \approx \beta_0 + \beta_1 \phi_{attn} + \beta_2 \phi_{text} + \beta_3 \phi_{dw} + \beta_4 \xi_p$$

其中 β_0 是截距， β_1 到 β_3 是注意力、文本融合与深度卷积占比的系数， ξ_p 是在标准矩阵上拟合的变体系数。预测值用于审计，低于 -0.05 灾难阈值时触发拒绝；rule-only 仍是默认模式，LOVO 评估只覆盖已观测架构，不外推到未见家族。

YOLO 兼容运行时与导出契约

契约层负责把数值上有希望的放置降级为真正可训练、可保存、可合并、可导出的执行方案，同时保持四个不变量：I1 基座检查点加载方式不变；I2 adapter 检查点只存 adapter 张量与运行时元数据；I3 合并后恢复普通 YOLO 模块；I4 ONNX 与 TensorRT 导出器看到导出兼容的图。运行时在两套后端之上暴露同一接口：HuggingFace PEFT 处理 LoRA、RS-LoRA、DoRA、LoHa、LoKr、AdaLoRA、IA3、OFT、BOFT 与 HRA 十种变体，一个更窄的仓内后端在 PEFT 不可用时提供纯卷积 LoRA。两条路径共享同一解析出的目标集与生命周期：优化器构建前安装、冻结基座训练、只保存 adapter 状态、加载到兼容的基座检测器、合并、移除包装再导出；adapter 未合并期间卷积融合被禁用，因为过早融合会使宿主模块失效。

对回退的卷积 LoRA，论文给出了合并等价性论证：每个组内更新 $\Delta W_g = B_g A_g^T$ 被重塑到宿主核的对应分区，合并按 $W_0 \leftarrow W_0 + s \Delta W$ 进行。由于更新在每组内独立构造，移除包装后卷积输出与包装模块等价至浮点容差。这保证了规划器输出的方案在部署侧真实可用。

训练策略

方案被接受后，四个可选策略在不改变放置的前提下稳定优化。层级学习率衰减使用 $\eta_\ell = \eta_0 \rho^{d_\ell}$ ，其中 $\rho = 0.85$ ， d_ℓ 是归一化深度，使早期特征提取器收到的更新更小。

Alpha warmup 让 LoRA 缩放 α/r 从零经余弦调度升到目标值，避免满强度的随机 adapter 在训练初期扰动注意力密集的检测器，YOLO12 护栏要求至少三个 warmup epoch。正交正则每隔 N 个 batch 加入：

$$\lambda_{ortho} (\|A^\top A - I\|_F + \|B^\top B - I\|_F)$$

其中 A 与 B 是 LoRA 的两个低秩因子， $\lambda_{ortho} = 0.5$ 为默认值，分块计算限制了多个 adapter 同时激活时的内存开销。动态 dropout 在前 30% 的 epoch 结束后把 adapter dropout 率从 0 线性升至 0.15，早期保留梯度信号、后期施加正则。各策略可通过 LoRAConfig 独立启用，完整的分量消融在补充材料中报告。

实验结果

实验设置

实验遵循官方 Ultralytics VOC 配置：VOC2007 trainval（5,011 图）与 VOC2012 trainval（11,540 图）组成 16,551 图训练集，官方 VOC2007 test 划分含 4,952 图用于测试。核心 s 规模运行采用 600-epoch 上限与 640×640 输入，更宽的 14 变体 $\times 5$ 架构诊断扫描用 300 epoch 与 320×320 。除特别说明外 PEFT 默认 $r = 16$ 、 $\alpha = 32$ 、dropout 0.05 并开启 RS-LoRA 缩放。研究覆盖 CNN 检测器（YOLOv8/YOLO11）、注意力增强的 YOLO12、文本融合的 YOLO-World 与 Transformer 检测器 RT-DETR-L，核心配置在 seeds {0, 28, 42} 上的复跑样本标准差不超过 0.006 mAP50:95 且排序不变。

PEFT 测量矩阵

主对比的完整测量矩阵如下表所示。


Tab. 1. PEFT-on-YOLO measured matrix. W&B export on the official VOC2007 test set (legacy log alias: val2007); anchors are Full-SFT runs of the same backbone. “rs” denotes RS-LoRA scaling; bold values match or exceed Full-SFT. Seed-0 results are shown; selected core reruns at seeds {0, 28, 42} have sample SD ≤ 0.006 mAP_{50:95} and unchanged rankings. The RT-DETR-L refused row records a within-scope planner safeguard: all seven swept LoRA-family configurations fall below $\Delta = -0.05$, so the planner emits REFUSE rather than an adapter; this is not a held-out-architecture test.

Backbone	Variant	r	α	rs	DoRA	OP-TARGETS	mAP ₅₀	mAP _{50:95}	Δ	Total Params	Inference GFLOPs
<i>YOLO11s</i> (DENSE-CONV only, $\phi_{\text{attn}}=0$, anchor 0.6428)											
YOLO11s	Full-SFT (anchor)	—	—	—	—	all	0.8344	0.6428	—	9.44M	21.6
YOLO11s	LoRA	16	32	true	false	conv	0.8865	0.7138	+0.0710	10.44M	25.7
YOLO11s	DoRA	16	32	true	true	conv	0.8865	0.7138	+0.0710	10.44M	25.7
YOLO11s	DoRA (no-rs ablation)	16	32	false	true	conv	0.8350	0.6479	+0.0050	10.46M	25.7
YOLO11s	LoHa	16	32	true	false	conv	0.8620	0.6788	+0.0359	11.45M	21.6
YOLO11s	LoKr	16	32	true	false	conv	0.8750	0.7033	+0.0605	9.51M	21.6
YOLO11s	IA ³	—	—	—	—	conv	0.8717	0.6980	+0.0552	9.45M	21.6
YOLO11s	HRA	16	32	true	false	conv	0.9023	0.7276	+0.0848	10.24M	—
<i>YOLO12s</i> (DENSE-CONV+ATTENTION, $\phi_{\text{attn}}\approx 0.45$, anchor 0.6662)											
YOLO12s	Full-SFT (anchor)	—	—	—	—	all	0.8532	0.6662	—	9.26M	21.6
YOLO12s	LoRA ($r=8$)	8	16	true	false	conv+attn	0.8974	0.7288	+0.0626	9.66M	23.6
YOLO12s	LoRA ($r=16$)	16	32	true	false	conv+attn	0.9007	0.7307	+0.0645	10.06M	25.6
YOLO12s	LoRA ($r=32$)	32	64	true	false	conv+attn	0.9022	0.7363	+0.0701	10.85M	29.6
YOLO12s	LoRA (no-rs ablation)	16	32	false	false	conv+attn	0.8853	0.7094	+0.0432	10.07M	25.6
YOLO12s	LoRA+DoRA, no rs	16	32	false	true	conv+attn	0.8041	0.6112	−0.0550	10.07M	25.6
YOLO12s	LoHa	16	32	true	false	conv+attn	0.8907	0.7222	+0.0560	10.85M	21.6
YOLO12s	IA ³	—	—	—	—	conv+attn	0.8928	0.7210	+0.0548	9.27M	21.6
YOLO12s	HRA	16	32	true	false	conv+attn	0.9111	0.7453	+0.0791	9.91M	—
<i>RT-DETR-l</i> (pure ATTENTION, $\phi_{\text{attn}}\approx 0.85$, anchor 0.6833)											
RT-DETR-l	Full-SFT (anchor)	—	—	—	—	all	0.8614	0.6833	—	32.85M	108.1
RT-DETR-l	LoRA-class refused [‡]	—	—	—	—	—	—	—	(refused)	—	—

表中 YOLO11s 与 YOLO12s 的 Full-SFT 锚点分别为 0.6428 与 0.6662，规划器选出的 RS-LoRA 达到 0.7138 与 0.7307，最强的 HRA 在 YOLO12s 上达到 0.7453。可见适配器方案整体超越全量微调；同时 no-rs 消融让 YOLO12s 掉回 0.7094，LoRA+DoRA 不带 rs 更是崩到 0.6112，表明 RS 缩放是注意力增强架构上防止灾难的关键训练先验。

架构条件行为与校准拒绝

五架构上的诊断扫描热图如下图所示。




图中红色单元表示灾难配置（ $\Delta < -0.05$ ），灾难率随注意力占比 ϕ_{attn} 上升：CNN-only 的 YOLO11n 上标准变体 10 次运行零崩溃，YOLO12n 升至 6/7，RT-DETR-L 达到 7/7。成对 Kendall- τ 分析同样显示变体排序跨家族减弱或反转，表明在评估的家族内不存在通用的 PEFT 排序。机制层面，YOLO-World 的图像与文本分支梯度范数相差数量级，DoRA 的幅度分解放大了这一失配，15 个 epoch 内损失发散并给出 $\Delta = -0.292$ 。RT-DETR-L 的拒绝是覆盖内的规划器护栏：七个配置全部低于阈值，返回最不坏的 adapter 也只是错误接受，拒绝避免了七次完整的训练尝试。

效率审计

受控 YOLO11 系统审计对比如下图所示。

PEFT Methods Performance Detailed Comparison



图中 LoRA 的峰值训练显存从 28.57 GB 降到 16.03 GB（降低 43.9%），但训练时长从 118.2 s 增加到 203.8 s（1.72 倍），其他 PEFT 变体也都慢于 Full-SFT。可见显存的节省以优化时间换来，论文据此把显存、时间与合并/未合并行为作为三个独立资源轴分开报告。

消融与放置对比

规划器各约束组件在 YOLO12s 上的消融如下表所示。

Tab. 11. Ablation A2: planner constraints on YOLO12s, VOC, LoRA $r=16$, $\alpha=32$, RS-LoRA on, core 600-epoch-cap/640-resolution protocol.

Configuration	Targets	Total Params	mAP _{50:95}	Δ
No constraint	all-conv+linear+attn	10.32M	0.6900	+0.0238
+ operator validity	dense+linear+attn	10.07M	0.7094	+0.0432
+ head semantics	dense+linear+attn\reg	10.06M	0.7307	+0.0645
Full planner	dense+attn (planner-pruned)	10.06M	0.7307	+0.0645

表中无约束基线为 0.6900，加入算子有效性过滤升到 0.7094，再加入检测头语义排除跃升到 0.7307，表明语义守卫是稳定性的主要驱动而非单纯的工程护栏。秩敏感性上 $r = 8/16/32$ 对应 0.7288/0.7307/0.7363， $r = 32$ 收益递减且参数与计算开销明显增大， $r = 16$ 是实际的 Pareto 默认点。结构感知放置与语言模型继承默认的对比如下表所示。

Tab. 3. Structure-aware placement versus LM-inherited defaults. The same backbone and evaluation protocol are used in both columns; gains are the structure-aware minus inherited mAP_{50:95}.

Backbone	LM default	mAP	Planner	mAP	Gain
YOLO11s	DoRA (no rs)	0.6479	RS-LoRA	0.7138	+0.0659
YOLO12s	DoRA (no rs)	0.6112	RS-LoRA	0.7307	+0.1195
RT-DETR-L	LoRA sweep	catastrophic	REFUSE	Full-SFT	—

表中同一骨干与协议下，规划器方案在 YOLO11s 与 YOLO12s 上分别带来 +0.0659 与 +0.1195 的增益，RT-DETR-L 上则从灾难性的 LoRA 扫描转为 REFUSE 回退 Full-SFT。补充的 MoE 压力测试中，禁用专家感知规划后 HRA 达到 0.7454 mAP50:95，超过 Full-SFT 的 0.6891，而 BOFT 与 OFT 未能产出指标即失败。

局限与讨论（增补）

此节为偏离语料的增补，仅基于论文原文可查证的内容：

1. 全部核心证据限于官方 VOC07+12 到 VOC07 test 协议，论文明确承认不支持关于 COCO、域移、少样本或方差的任何结论，跨域泛化仍是待验证问题。
2. 拒绝机制在架构层面无法给出误拒/误受率：没有任何检测器家族被留出，原文明言「基于该矩阵无法计算未见架构上的真实误拒率」，variant 级 LOVO（准确率 86.7%、F1 0.850）不等于架构级验证。
3. 可靠性校准是一个在标准矩阵上拟合的线性预测式，覆盖外只能返回 **unsupported** 而非外推安全保证，对全新检测器家族的拒绝验证被列为开放问题。
4. 效率收益是有代价的交换：LoRA 省下 43.9% 峰值显存的同时训练耗时变为 1.72 倍，MoE 压力测试中 BOFT 与 OFT 直接失败且无指标，说明兼容性并不覆盖全部变体。
5. 主矩阵是 seed-0 结果，多种子复跑只作为鲁棒性检查（样本标准差 ≤ 0.006 ），原文自述这「不是配对显著性检验」，结论应理解为受控相对比较。

优点和创新点

个人认为，本文有如下一些优点和创新点可供参考学习：

1. 把 **adapter** 放置从隐藏的手写目标列表改造成可审计的约束规划问题，每次排除都有明确原因码与有序拒绝日志，能够区分「不支持」与「预测不准」两种拒绝，工程上可追溯、可复核。
2. 把 **Refuse** 提升为一等的规划结果并配套可靠性校准，在 RT-DETR-L 七个全部灾难性的配置上避免了七次无效的完整训练，实验覆盖 14 个 PEFT 变体与 5 个异构检测器架构，说服力强。
3. 训练-保存-合并-导出的端到端契约配上分组卷积合并等价性证明，让 **adapter** 方案真正落到边缘部署：合并后计算图恢复基座算子开销，ONNX/TensorRT 导出校验通过，受控审计下峰值训练显存降低 43.9%。