



哈尔滨工业大学学报
Journal of Harbin Institute of Technology
ISSN 0367-6234, CN 23-1235/T

《哈尔滨工业大学学报》网络首发论文

题目: 基于 FMA-YOLOv12 的轨道交通密集行人检测算法
作者: 梁国华, 史祥符, 刘越, 卢剑鸿, 秦孝峰, 贾拴航, 张文韬
收稿日期: 2025-09-21
网络首发日期: 2026-01-14
引用格式: 梁国华, 史祥符, 刘越, 卢剑鸿, 秦孝峰, 贾拴航, 张文韬. 基于 FMA-YOLOv12 的轨道交通密集行人检测算法[J/OL]. 哈尔滨工业大学学报.
<https://link.cnki.net/urlid/23.1235.t.20260114.1112.002>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

DOI:10.11918/202509088

基于 FMA-YOLOv12 的轨道交通密集行人检测算法

梁国华¹, 史祥符¹, 刘越^{1,2}, 卢剑鸿³, 秦孝峰³, 贾拴航³, 张文韬³

(1.长安大学 运输工程学院, 西安 710064; 2.河北水利电力学院, 河北 沧州 061001;

3.西安市轨道交通集团有限公司, 西安 710016)

摘要: 为解决城市轨道交通站在客流高峰时段因行人密度高、光照条件复杂等导致的检测算法精度不足与稳定性下降的问题, 本文构建了一个包含 3,727 张标注图像的轨道交通专用数据集, 覆盖多个站场区域及不同时段场景。以 YOLOv12 为基线模型, 从三方面进行改进: 首先, 采用 Focal-EIOU 损失函数替代原 CIOU 损失函数, 对重叠程度较低的候选框赋予更高优化权重, 从而显著提升小尺度行人的边界框回归精度; 其次, 在浅层特征提取阶段引入 MambaVision 结构, 利用其双分支设计增强模型对行人细节特征的感知能力与抗遮挡性能, 更好地适应站场复杂动态环境中的特征变化; 最后, 将原检测头替换为自适应空间特征融合 (ASFF) 结构, 实现对多尺度特征的自适应加权融合, 在有效过滤背景干扰、减少误检的同时保持较低的推理计算成本。基于上述改进, 构建了适用于轨道交通密集场景的 FMA-YOLOv12 算法。实验结果表明, 改进后模型在自建数据集上的平均精度均值达到 91.8%, 较原模型提升 1.3%; F1 分数为 85.0%, 提升 2.0%, 且 FLOPs 基本保持不变, 表明模型在轨道交通高密度行人场景下提升检测精度的同时保持了良好的计算效率, 为轨道交通智能监控提供了高精度、高效率的解决方案。

关键词: 城市轨道交通; 深度学习; 行人检测; YOLOv12; 目标检测算法; 特征提取; 特征融合

中图分类号: U231.4

文献标志码: A

FMA-YOLOv12 algorithm for dense pedestrian detection in rail transit

LIANG Guohua¹, SHI Xiangfu¹, LIU Yue^{1,2}, LU Jianhong³,
QIN Xiaofeng³, JIA Shuanghang³, ZHANG Wentao³

(1.School of Transportation Engineering, Chang'an University, Xi'an 710064,China;2.Hebei University of Water Resources and Electric Engineering, Cangzhou 061001, Hebei, China;3. Xi'an Metro Group Co., Ltd., Xi'an 710016,China)

Abstract: To address the issues of insufficient accuracy and declining stability of detection algorithms in urban rail transit stations during peak hours, caused by high pedestrian density and complex lighting conditions, this study constructs a dedicated rail transit dataset containing 3,727 annotated images, covering multiple station areas and various time periods. Based on the YOLOv12 baseline model, improvements were made in three key aspects: Firstly, the Focal-EIOU loss function replaced the original CIOU, introducing a focal modulation mechanism that assigns higher optimization weights to candidate boxes with low overlap, thereby significantly improving bounding box regression accuracy for small-scale pedestrians. Secondly, the MambaVision structure was incorporated into the shallow feature extraction stage; its dual-branch design enhances the model's perception of detailed pedestrian features and resistance to occlusion, enabling better adaptation to feature variations within complex and dynamic station environments. Finally, the original detection head was replaced with an Adaptively Spatial Feature Fusion (ASFF) structure, enabling adaptive weighted fusion of multi-scale features, which effectively filters background interference and reduces false detections while maintaining low computational inference costs. Based on the aforementioned improvements, the FMA-YOLOv12 algorithm suitable for dense rail transit scenarios was constructed. Experimental results indicate that the improved model achieves a mean Average Precision (mAP) of 91.8% on the self-built dataset, which is 1.3% higher than the original model; the F1-score reaches 85.0%, an improvement of 2.0%, while the FLOPs remain largely unchanged, demonstrating that the model maintains good computational efficiency while enhancing detection accuracy. This demonstrates that the model not only enhances detection accuracy in high-density rail transit pedestrian scenarios but also maintains excellent computational efficiency, providing a high-precision and efficient solution for intelligent rail transit monitoring.

Keywords: urban rail transit; deep learning; pedestrian detection; YOLOv12; object detection algorithm; feature extraction; feature fusion

收稿日期: 2025-09-21; 录用日期: 2025-11-10

基金项目: 国家自然科学基金项目 (52572332); 河北省高等学校科学技术研究项目 (QN2022118); 长安大学中央高校科研业务费专项资金资助 (300102344201); 西安市科技计划项目 (2024JH-GXFW-0060)

作者简介: 梁国华(1977—), 男, 教授, 博士生导师

通信作者: 刘越, liuyue@chd.edu.cn

行人检测在智能交通、安防监控、无人机监控等多个领域发挥着重要作用^[1],尤其在轨道交通场景中,实现对高密度人群的准确检测与实时分析,对保障乘客安全、提升运营效率具有重要意义。然而,该类场景下存在的严重遮挡、尺度差异大、背景复杂及图像质量波动等问题,对现有检测算法提出了严峻挑战。

为应对上述挑战,本文通过优化目标检测算法来提高行人检测精度和稳定性。基于深度学习的目标检测算法大致可分为两阶段与单阶段两类。其中,以 Faster R-CNN^[2]、Cascade^[3]、R-CNN^[4]等为代表的两阶段方法,其较高的计算复杂度难以满足轨道交通监控的实时性需求。相比之下,以 YOLO 系列^[5-10]、SSD^[11] (Single Shot MultiBox Detector)、ViT(Vision Transformer)^[12]以及 Swin-Transformer^[13]等为代表的单阶段检测器,凭借其端到端的集成设计与极高的处理效率,更契合实时监控与边缘部署的应用要求。

尽管 YOLO 系列算法在实时检测任务中展现出显著的速度优势,但在面对轨道交通站场中行人高度密集、相互遮挡严重、目标尺度差异大等复杂场景时,其检测性能仍存在一定局限。为提升模型在密集行人场景下的表现,近年来研究者从结构优化与损失函数设计等角度进行了多方面探索。例如,高昂等^[14]针对检测头在多尺度行人定位中表达能力不足的问题,设计了动态解耦检测头,增强了对不同尺度行人特征的判别与定位能力;张忠民等^[15]则通过引入改进的 RepVGG 模块替换原始卷积结构,强化了骨干网络在复杂场景下的特征提取能力,并通过增设检测头以缓解小尺度目标的漏检问题;王泽宇等^[16]进一步在注意力机制与损失函数层面进行改进,通过引入 EMA 模块以聚合像素级全局特征,并结合排斥损失(Repulsion Loss)以抑制密集人群中的边界框重叠与误检现象。

尽管上述方法在不同层面提升了密集行人检测的性能,多数研究仍未能从根本上解决多模块协同效率低下、复杂遮挡下细节特征丢失,以及多尺度特征融合机制不够灵活等问题。特别是在高密度轨道交通场景中,行人目标之间的严重遮挡与尺度极端变化导致现有模型在精度与效率的平衡方面仍面临挑战。鉴于此,本文在 YOLOv12 基础上,系统性地融合 Focal-EIOU 损失、MambaVision 结构与自适应空间特征融合模块(adaptively spatial feature fusion, ASFF),从边界框优化、浅层特征增强与多尺度融合三个层面进行联合改进,以期在保持较高推理速度的同时,进一步提升模型对密集、遮挡与小尺度行人的检测能力。

本研究构建了一个包含 3,727 张标注图像的城市轨道交通场景数据集,覆盖多时段、多光照和多种客流密度条件。具体改进包括:1) 采用 Focal-EIOU 损失函数,优化边界框回归精度,缓解高密度定位偏差;2) 在浅层特征提取阶段引入 MambaVision 双分支结构,通过状态空间模型 SSM(State Space Model)路径与卷积分支增强模型对遮挡目标的感知能力;3) 使用 ASFF 模块重构检测头,实现多尺度特征的自适应融合,动态优化 P3~P5 层的特征贡献。上述改进有效解决了高密度行人场景下因目标重叠导致的定位精度问题,显著降低了误检与漏检率。改进后的算法在提升对站场复杂环境感知能力的同时,达成了检测精度与计算效率的平衡^[17-19]。该算法不仅为轨道交通的实时智能监控与安全预警提供了直接解决方案^[20-21],其技术路径所展现的通用性,也为机场、大型活动场馆等同类公共安全场景的智能化升级提供了有价值的参考与技术支持^[22]。

1 数据采集与处理

1.1 数据采集

本研究选取某市两个客流密集的地铁站(A站与B站)作为数据采集点,共采集约 20 小时监控视频,涵盖通道、扶梯、楼梯、付费区、站厅及站台等多个关键区域,具体摄像头布设信息见表 1。图 1 展示了 A 站各区域视频分帧后的行人图像:站厅、站台和付费区作为乘客聚集与疏散的核心区域,人流密度显著较高;而通道、楼梯与扶梯区域受空间结构与光照条件影响,易形成复杂的光影变化,为验证模型在光照干扰下的鲁棒性提供了典型场景^[23-24]。A 站作为多线换乘枢纽,全天客流持续密集;B 站毗邻商业区,高峰时段人流高度集中,二者共同构成多样化的行人行为与密度模式。该数据集天然具备多重挑战,包括扶梯与通道区域的严重遮挡、出入口与站厅的光照剧烈变化,以及由近远景引起的目标尺度极端差异,从而系统支撑算法在真实轨道交通环境中的鲁棒性评估与泛化能力验证。




图 1 A 站分帧后的行人图片

Fig. 1 Pedestrian image after framing at station A

表 1 摄像头的位置及对应的区域名称

Tab. 1 The position of the camera and the corresponding area name

序号	车站区域	名称
1	A 站出入口 (D 口)	D 口楼梯
2	A 站出入口 (D 口)	D 口通道
3	A 站出入口 (D 口)	D 口扶梯
4	A 站站厅 (站厅中部)	厅西付费区
5	A 站站台 (2 号线站台南扶梯口)	站厅
6	B 站出入口 (D 口)	D 口楼梯 1
7	B 站出入口 (D 口)	D 口通道 1
8	B 站出入口 (D 口)	D 口扶梯 1
9	B 站出入口 (D 口)	D 口通道 2
10	B 站出入口 (D 口)	D 口扶梯 2
11	B 站出入口 (D 口)	D 口负一扶梯 1
12	B 站出入口 (D 口)	D 口负一扶梯 2
13	B 站站台 (3 号线站台上行尾)	站台
14	B 站站厅 (2 号线厅西非付费区)	站厅

1.2 数据处理

本研究构建轨道交通场景数据集的流程如下：1）视频分帧处理，基于某市地铁监控视频（总时长 20 h），采用固定间隔采样策略（20 s/帧），通过对分帧后图像的初步统计分析，本研究确认该策略成功捕获了从低密度（每帧少于 10 人）到极高密度（每帧超过 50 人）的连续客流变化，最终，共提取有效图像样本 3,727 张，覆盖早晚高峰及平峰时段的客流特征；2）行人标注，使用 Labelimg 工具进行边界框标注，重点优化标注质量：排除广告牌、行李等非乘客干扰项；针对部分遮挡目标采用最小外接矩形标注法；3）数据格式转换，将 VOC 格式标注文件（XML）转换为 YOLO 标准格式（TXT），实现类别 ID、归一化坐标等参数的标准化表达；4）数据集划分，按时空分布均衡原则，以 7:3 比例随机划分训练集（2 964 张）与验证集（763 张），确保各区域、时段样本均匀分布。

2 YOLOv12 算法原理与改进方法

2.1 YOLOv12 目标检测算法原理

YOLOv12 采用输入端、骨干网络、特征融合网络（Neck）与输出端的经典架构，并集成多项创新设计：输入端通过数据增强提升鲁棒性；骨干网络采用分层递进结构，底层以基础卷积提取初级特征，中段引入 Area Attention 模块（通过区域划分优化注意力计算）与 R-ELAN（基于残差连接强化特征聚合），

平衡计算效率与特征表达；特征融合基于改进 FPN+PAN 架构^[25-26]，复用 R-ELAN 并整合 Flash Attention 等技术，通过精简设计（去除位置编码、卷积替代线性操作等）提升效率；输出端利用多尺度融合特征，经轻量化检测头生成预测。整体架构通过注意力机制与高效特征聚合策略，实现检测精度与实时性的平衡。

2.2 Focal-EIOU 替换 CIOU

YOLOv12 的损失函数体系由边界框回归损失、分类损失与目标置信度损失构成。其中，YOLOv12 模型默认采用 CIOU（Complete-Intersection over Union）作为边界框损失函数。然而，在地铁站客流高峰等高密度场景下由于遮挡、模糊等困难样本占比显著增加，CIOU 损失函数易使模型训练过程被大量简单样本所主导，进而影响检测性能。鉴于此，本文着重围绕边界框损失函数展开针对性改进在本研究中，使用 Focal-EIOU 替换 CIOU，Focal-EIOU 是 Focal-Loss 和 EIOU-Loss 结合的变体，EIOU 旨在改进传统的 IOU 损失，通过考虑边界框的宽高比、角度等因素，更好地度量框与框之间的匹配，尤其是在复杂场景中，地铁站场这种密集人群的情况，它能够提供更精确的目标定位^[27]。它帮助减少容易预测的样本对训练的影响，避免训练时被大量的负样本（即非目标区域）所主导，使得模型更专注于困难样本（如不规则、重叠的人）^[28]。

Focal-EIOU 的公式见下式：

$$L_{\text{Focal-EIOU}} = \text{IOU}^\gamma \cdot L_{\text{EIOU}}$$

$$L_{\text{EIOU}} = 1 - \text{IOU} + \frac{\rho^2(b, b^{gt})}{c^2} + \frac{\rho^2(w, w^{gt})}{C_w^2} + \frac{\rho^2(h, h^{gt})}{C_h^2} \quad (1)$$

式中：IOU 为交并比； γ 为调节因子，用于控制难易样本的权重分配； b 、 b^{gt} 分别表示预测框、真实框的中心坐标； c 为预测框与真实框最小外接矩形的对角线长度； w 、 w^{gt} 分别表示预测框、真实框的宽度； h 、 h^{gt} 分别表示预测框、真实框的高度； w^{gt} 、 h^{gt} 表示真实框的宽度和高度； c_w 、 c_h 分别表示闭包矩形的宽度和高度； ρ 为欧氏距离函数。

Focal-EIOU 通过引入焦点因子，动态调整困难样本（如遮挡目标）的损失权重，结合 EIOU 对宽高比和中心距离的优化，提升模型对复杂场景的适应能力。在城市轨道交通站场中，部分行人会相互遮挡或远离摄像头，使用 Focal-EIOU 可以使模型对这些难检测的行人更加敏感，从而提高检测准确率。在实际应用中，往往存在大量的背景区域（如站台的地面、墙壁等）。Focal-EIOU 能够有效减轻背景区域对损失函数的影响，聚焦于真实目标的检测，避免背景区域对模型训练造成的干扰。城市轨道交通站场中，行人目标的尺寸差异较大，Focal-EIOU 能够帮助模型更好地应对这些尺寸差异，尤其是在检测到较小的行人时，比 CIOU 具有优势。

2.3 骨干网络中引入 MambaVision

MambaVision 构建层级化架构，经四阶段渐进处理实现高效表征：Stem 层通过连续卷积生成 1/2 分辨率特征，依托空间局部性提取基础纹理；Stage1-2 以残差卷积与下采样协同，处理 1/4-1/8 分辨率特征，依托线性计算与残差连接，既强化了高分辨率特征的代表能力，又保障了训练的稳定性；Stage3-4 部署双分支交替结构，MambaVisionLayer 通过 SSM 与卷积分支捕获序列依赖和空间细节，MLP 增强非线性表征，双分支互补以规避信息冗余与特征丢失；构建局部到全局的递进学习闭环。MambaVision 模型体系结构如图 2 所示。




图 2 MambaVision 模型的体系结构

Fig. 2 Architecture of the MambaVision model

YOLOv12 Backbone 结构采用分层递进设计，其中 P2 阶段负责处理 1/4 分辨率特征图，在特征金字塔中承担着小目标检测与细粒度边缘表征的核心功能。轨道交通站场景中，远景行人、肢体部分等小尺度目标在 P2 阶段具有最丰富的空间信息，而传统 Conv 模块在此分辨率下难以有效建模长距离依赖关系，导致对遮挡目标和细节特征的感知能力不足。MambaVisionLayer 的双分支设计（SSM 路径与卷积分支）可高效捕获序列依赖和空间细节，与 P2 阶段的功能需求高度契合，且其线性计算复杂度（ $O(n)$ ）与 YOLOv12 骨干网络的轻量化设计兼容，因此在 P2 阶段将原生 Conv 模块替换为 MambaVisionLayer，如图 3 所示。




图 3 YOLOv12 Backbone 结构

Fig.3 Backbone structure of YOLOv12

MambaVisionLayer 的双分支设计能针对性弥补传统卷积模块的固有局限，具体表现为：SSM 路径以线性计算复杂度（ $O(n)$ ）处理高分辨率特征图，高效捕获目标轮廓拓扑等序列依赖，避免了传统自注意力机制的平方级计算开销；对称卷积分支通过深度卷积保留背景纹理等空间细节，缓解纯 SSM 路径易出现的局部特征流失问题，使 P2 阶段既能高效处理高分辨率特征，又能兼顾细粒度信息保留。MambaVision 通过其独特的双分支架构，同步强化了模型对行人细节特征的感知能力和对全局上下文关系的理解能力，从而显著减少了漏检和误检，最终实现了检测精度和综合性能的显著提升。

2.4 ASFF 模块优化 YOLOv12 检测头

在目标检测中,处理多尺度物体是一个具有挑战性的问题。虽然特征金字塔或多级特征塔是解决多尺度问题的常用方法,但在单阶段检测器中,不同尺度特征之间的不一致性限制了其性能提升。为了解决这个问题,提出了自适应空间特征融合(ASFF)模块。ASFF 模块通过引入可学习的空间自适应权重参数，实现特征金字塔中多尺度特征图的有效融合。该设计核心在于解决不同层级特征间的语义与尺度不一致性问题，其融合机制并非简单的特征相加或拼接，而是通过网络动态生成空间权重图，据此对来自不同层级的特征进行加权融合。ASFF 说明如图 4 所示。




图 4 自适应空间特征融合机制说明

Fig. 4 Illustration of the adaptive spatial feature fusion mechanism

ASFF 机制针对特征金字塔的 3 个层级（Level1、Level2、Level3）分别设计了自适应融合单元（ASFF-1、ASFF-2、ASFF-3），实现跨层级特征的精准整合：

面向特征金字塔第 l 层级（ $l \in \{1,2,3\}$ ），通过特征分辨率统一→空间权重学习→自适应加权融合三阶段，生成优化后的特征图 ASFF 供预测头使用。

输入：特征金字塔 X^1 （步长 32）、 X^2 （步长 16） X^3 （步长 8）

输出：融合特征（分辨率与一致）

阶段 1：特征分辨率统一

将非层级的特征图调整至相同的尺寸：对于上采样操作，采用插值法（如双线性或最近邻）提升分辨率，随后通过 1×1 卷积对齐通道数；对于下采样操作，则采用步长为 2 的 3×3 卷积（或池化与卷积的组合），同时同步调整通道维度，定义 U 为上采样操作， D 为下采样操作。

$$x^{k \rightarrow l} = \begin{cases} U(x^k), & k < l \\ D(x^k), & k > l \\ x^k, & k = l \end{cases} \quad (2)$$

阶段 2：空间权重学习

对每个对齐后的特征图 $x^{k \rightarrow l}$ 学习空间自适应权重生成权重标量图：

$$w^k = F_{1 \times 1}(x^{k \rightarrow l}), \quad w^k \in \mathbf{R}^{H_l \times W_l \times 1} \quad (3)$$

（ $F_{1 \times 1}$ 为 1×1 卷积，后接 ReLU 激活函数以引入非线性变换，增强模型对特征关系的建模能力，同时保持计算效率）

Softmax 归一化（空间位置 (i,j) 独立）：

$$\alpha_{ij}^k = \frac{\exp(w_{ij}^k)}{\sum_{m=1}^3 \exp(w_{ij}^m)}, \quad \sum_{k=1}^3 \alpha_{ij}^k = 1, \quad \alpha^k \in [0,1]^{H_l \times W_l \times 1} \quad (4)$$

阶段 3：自适应加权融合

按空间位置加权求和生成最终特征：

$$ASFF^l = \sum_{k=1}^3 \alpha^k \odot x^{k \rightarrow l} \quad (5)$$

⊙表示逐元素乘法+广播机制

ASFF 的本质是学习一个空间自适应的特征选择器：

$$ASFF^l(i,j) = \sum_{k=1}^3 \alpha_{ij}^k \cdot x^{k \rightarrow l}(i,j) \quad (6)$$

式中 α_{ij}^k 由网络动态生成，决定位置 (i,j) 对第 k 层特征的依赖强度。

该过程能够动态筛选与当前尺度及空间位置最相关的特征信息，同时抑制冲突性或干扰性响应（如复杂背景），从而显著提升特征的尺度不变性。在轨道交通行人检测场景中，该机制能够针对性应对行人尺度差异大、背景干扰多的核心挑战，在提升检测精度的同时，因其仅依赖轻量级的 1×1 卷积操作，保持了较低的推理成本，满足实际部署的实时性要求。

2.5 改进后的 YOLOv12 模型架构

改进后的 YOLOv12 网络在架构如图 5 所示。骨干网络（Backbone）中，Stem 层通过 2 个 3×3 卷积（步幅 2）配合 BN 与 SiLU，实现输入图像的快速下采样与非线性特征增强；Stage 模块则构建混合架构，Stage1 依托 C3k2 模块堆叠 Bottleneck 提取局部特征，Stage2 引入 MambaVisionLayer，融合 Mamba 高效序列建模能力与对称卷积的空间特征提取优势 Stage3/4 以 C3k2 保障基础特征，结合 A2C2f 模块强化特征交互，提升高层语义提取效果。检测环节，ASFF 模块替代原始 Detect 头，对 FPN/PAN 输出的多尺度特征，先经卷积对齐通道与分辨率，再学习空间权重并按权重融合，动态筛选有效特征，适配小目标、重叠目标检测需求；后续分设 ASFF1/2/3 检测头，基于融合特征，通过卷积完成分类与回归任务，分别适配大、中、小目标检测，ASFF 模块通过 1×1 卷积和 ReLU 激活函数动态生成空间权重，实现多尺度特征的自适应融合。整体改进通过 Mamba 增强序列特征表达、ASFF 优化多尺度特征融合，有效提升模型在复杂场景下的特征利用效率与多尺度目标检测精度。




图 5 改进后的 YOLOv12 模型架构

Fig. 5 Improved YOLOv12 model architecture

ASFF 与 MambaVision 通过端到端训练形成深度协同优化机制：一方面，空间权重动态平衡 P2 层细粒度信息（如远景行人轮廓）与 P3-P5 层高级语义特征的融合占比，配合 MambaVisionLayer 对 P2 层细节建模的强化能力，再经 ASFF 对 P3、P4、P5 多尺度特征的高效整合，显著提升了地铁站台小目标与密集遮挡目标的检测精度；另一方面，MambaVision 基于序列长度的线性计算复杂度，与 ASFF 通过轻量级 1×1 卷积实现的权重生成过程形成效率协同，两者共同保障模型在复杂场景下仍能维持 25FPS 的实时性，适配地铁站监控的实战需求。

3 实验设置与结果分析

3.1 实验环境及关键参数

本文研究的软件环境为：深度学习框架为 2.1.2 版本的 Pytorch；GPU 型号为 RTX3080Ti，CPU 型号为 8 核 vCPU（Intel Xeon Silver 4214R，2.40 GHz），CUDA 版本为 11.8，Python 版本为 3.10。训练模型时设置的关键参数如表 2 所示。

表 2 关键参数配置表

Tab. 2 Configuration Table of Key Parameters

参数	值
Lr0（初始学习率）	0.01
Momentum（动量）	0.937
Epochs(训练轮次)	100
Img-Size(输入的图像尺寸)	640×640×3
Batch-Size(批次训练的样本量)	16
weight_decay(权重衰减)	0.0005

在超参数配置文件中，学习率过大可能导致训练不稳定和振荡，学习率过小可能导致训练速度缓慢和陷入局部最优解。研究中学习率被设定为 0.01，而权重衰减系数则为 0.0005。除此之外，其余网络设置参数均采用了官方仓库提供的默认值。在主函数中，其他参数均沿用了默认值。训练轮次设置为 100 轮，以平衡模型性能与计算成本，确保模型充分学习轨道交通场景行人特征的同时避免过拟合。

3.2 改进 YOLOv12 算法实验

本研究采用平均精确度均值（mean average precision, mAP）、F1 分数、参数量（parameters）、FLOPs（floating point operations）作为评价指标。mAP@0.5 是指在 IoU 阈值固定为 0.5 时计算的 mAP。F1 分数是精确率与召回率的调和平均值，高 F1 分数意味着模型在这两个指标上都表现良好，能够减少误分类的情况。参数量表示模型的大小，计算量则反映了模型的计算速度与算力需求。FLOPs 指浮点运算次数，用来衡量算法的总体需要计算量，指标越小意味着模型对硬件的性能要求越低，需要的训练和推理时间越少。上述评价指标的计算公式如下：

$$Precision = \frac{TP}{TP+FP} \quad (7)$$

$$Recall = \frac{TP}{TP+FN} \quad (8)$$

$$mAP@0.5 = \frac{\sum_{m=1}^M \int_0^1 P(R) dR}{M} \quad (9)$$

$$F1 = \frac{2(Precision \times Recall)}{Precision + Recall} \quad (10)$$

式中：TP(True Positives)表示实际为正类且正确预测为正类的样本数；FP(False Positives)表示实际为负类但误判为正类的样本数；FN(False Negative)表示实际为正类但误判为负类的样本数。mAP(mean Average Precision, mAP)指的是精确度（Precision）与召回率（Recall）曲线下，纵轴为精度、横轴为召回率所围成面积的算术平均值；M 是数据集中类别的总数；P(R)是类别 m 在 IoU=0.5 下的精度-召回函数

本研究对比了 mAP@0.5、F1 分数、参数量、FLOPs，如表 3 和图 6 所示，YOLOv12 的 mAP@0.5 达到 90.5%，显著高于两阶段模型 Faster R-CNN。在同为单阶段的模型中，YOLOv12 也比 YOLOv5、YOLOv8 和 YOLOv11 和 SSD 分别高出 3.0、0.9、0.2 和 10 个百分点。在 F1 分数方面，YOLOv12 达到 83.0%，优于 Faster R-CNN、SSD、YOLOv5 和 YOLOv8，与 YOLOv11 性能相当。GFLOPs 为 6.5，检测速度优于 YOLOv8、Faster R-CNN、SSD 虽然检测速度稍逊色于 YOLOv5、YOLOv11，但是也满足实时检测的要求，在保持较小参数量和较低计算量的前提下，实现了较高的检测精度和实时性，更适合轨道交通复杂场景，实现更高的精度和稳定性。

表 3 各种目标检测方法在地铁轨道站场数据集上的对比实验

Tab. 3 Comparison experiments of various object detection methods on subway track station datasets

Models	mAP@0.5/%	F1/%	参数量	GFLOPs
YOLOv5	87.5	80	1.9	4.5
YOLOv8	89.6	82	3.2	8.7
YOLOv11	90.3	83	2.59	6.4
YOLOv12	90.5	83	2.6	6.5
Faster R-CNN	77.6	60	28.27	259.78
SSD	77.5	67	23.75	30.43
FMA-YOLOv12	91.8	85.0	4.2	6.4




图 6 各种目标检测方法的 mAP@0.5 曲线对比

Fig. 6 Comparison of mAP@0.5 curves for various object detection methods

为了评估 Focal-EIOU、MambaVision 和 ASFF 对融合后的模型 FMA-YOLOv12 性能的影响，本文进行了三部分的消融实验，结果如表 4 所示。“√”表示引入该模块。MambaVision 强化细节建模、ASFF 优化多尺度特征融合、Focal-EIOU 聚焦难样本与抑制背景干扰，三者协同提升了地铁站小目标、遮挡行人的检测精度，同时增强对尺寸差异大的行人目标的适应能力。三者协同工作使 mAP@0.5 增加至 91.8%、F1 分数达到 85.0%，计算量仅为 6.4GFLOPs。在保持高精度的同时还能保证检测速度。研究证实了各模块在提高 FMA-YOLOv12 的性能方面发挥作用，组合使用后达到了精度和效率之间的最佳平衡。

表 4 消融实验

Tab. 4 Ablation experiments

Focal-EIOU	MambaVision	ASFF	mAP@0.5/%	F1/%	GFLOPs
			90.5	83.0	6.5
√			91.0	84.0	6.5
	√		90.8	83.0	6.9
		√	91.1	83.0	6.1
√	√		91.3	84.0	6.9
	√	√	91.5	85.0	6.4
√		√	91.3	84.0	6.1
√	√	√	91.8	85.0	6.4

由图 7 可以看出，改进后的模型 mAP@0.5 有了显著提升，训练前几轮模型改进前后的 mAP@0.5 值较为接近，随着训练轮数的增加，改进后的模型在更早的训练轮数就达到了较高的 mAP@0.5 值，改进后的模型能够更准确地识别出行人并定位其位置。




图 7 模型改进前后 mAP@0.5 曲线

Fig. 7 mAP@0.5 Curve Comparison

如图 8 所示的损失曲线表明，训练损失在 20 个 epoch 后基本收敛，验证集损失同步下降并稳定，未见明显背离，表明模型未发生过拟合，同时模型的关键性能指标（如 mAP@0.5）通常需要更长的优化周期才能达到峰值。充足的训练轮次有助于观察模型进入稳定平台期后的表现，确保评估结果的可靠性，因此也验证了训练轮次为 100 的合理性。分析改进前后的边界框损失变化可知，FMA-YOLOv12 模型不仅收敛速度最快，且达到的最终损失值最低，验证了其优化可有效降低训练损失。




图 8 模型改进前后边界框损失对比

Fig. 8 Comparison of bounding box loss before and after model improvement

为验证自建数据集的有效性及其对模型性能改进的支撑作用，本文在公开数据集 CityPersons 上开展了对比实验。实验环境与参数配置均与此前保持一致，以确保结果的可比性。实验结果如表 5 所示。

表 5 模型改进前后在 CityPerson 数据集上的对比实验

Tab. 5 Comparative Experiments of the Model Before and After Improvement on the CityPerson Dataset

模型	mAP@0.5/%	F1/%	GFLOPs
YOLOv12	88.5	83.0	6.4
FMA-YOLOv12	89.6	84.0	6.4

分析表 5 可知：与 YOLOv12 相比改进后的算法 FMA-YOLOv12 的 mAP@0.5 提高了 1.1%，F1 分数提高 1%。实验显示本文算法在自制数据集上各项指标较于其他算法均有明显的优势，同时也证明了本文的算法具有泛化性。

图 9 直观呈现了 YOLOv12 算法改进前后对地铁站内同一视频帧的目标检测效果对比。通过图像分析可知，原始 YOLOv12 算法在地铁站行人检测场景中存在 1 例误检与 1 例漏检问题。具体而言，图 9（b）黄色框标注区域内实际含 2 名行人，而图 9（a）中原算法将其误检为 3 名；对于图 9（c）中的儿童目标，原算法未能实现有效检测。相比之下，图 9（d）所示的 FMA-YOLOv12 算法不仅成功消除了上述误检现象，还准确识别出了此前漏检的儿童目标，验证了改进算法的有效性。




Fig. 9 Object detection results of the YOLOv12 algorithm before and after improvement

为验证改进后 FMA-YOLOv12 网络模型的检测效能，本文构建地铁站场景自制数据集开展测试。同时，引入 Heatmap 技术对检测结果予以可视化呈现（图 10）在行人检测热力图中，颜色越偏向红、橙、黄等暖色系，代表模型对该区域存在行人的置信度越高，行人存在的可能性越大；反之，颜色越偏向蓝、紫等冷色系，行人存在的可能性越小。实验表明，该算法可精准识别并定位图像中的行人目标，在地铁站场景下，漏检、误检情况极少出现，展现出优异的检测性能。




Fig. 10 Detection result of FMA-YOLOv12

4 结 论

1) 针对轨道交通站场行人高密度、相互遮挡及光照干扰导致的目标检测精度低、稳定性差等问题,本文提出将 Focal-EIOU 损失函数、MambaVision 与 ASFF 融合 YOLOv12 算法的改进方案。通过对某市地铁 A 站、B 站行人数据集进行检测与跟踪实验,结果表明,本文行人目标检测算法 mAP@0.5 达到 91.8%, F1 分数达到 85.0%, 其计算成本保持在 6.4 GFLOPs。该方案通过融合后各模块的协同作用,在保证训练速度的情况下有效提高了模型检测精度,降低了漏检、误检率,验证了其在城市轨道交通场景下的可行性。

2) 本文能够充分挖掘轨道交通站场行人目标特征,精准提取行人目标,对高密度场景下行人遮挡、光照变化导致的目标特征模糊性和检测结果波动性进行建模。本研究虽基于特定站点数据集构建,但算法核心框架与优化策略具备普适性,可通过调整模型参数适应不同轨道交通站场布局、客流特征及光照条件。该算法不仅能够实现高精度行人目标检测与稳定跟踪,还可为站场客流疏导策略制定、安全风险预警系统设计提供理论支撑,助力提升轨道交通站场运营的安全性与管理效能。

3) 本研究仍存在一定局限。一方面,数据集虽基于轨道交通站场构建,但场景丰富度和数据多样性有待提升,可能影响算法在复杂多变真实场景下的泛化能力;另一方面,从数据集与效果验证的角度来看,本研究采用的是为适配特定研究目标而自主构建的数据集,这类定制化数据能更好地贴合研究场景的独特需求;在效果呈现上,目前主要聚焦于自身优化前后的性能对比,后续可结合更多开源基准数据集的指标体系,进一步丰富效果验证的维度。

参考文献

- [1] 霍华, 邢晓钰。复杂场景下的轻量化行人检测算法研究[J/OL]. 计算机应用与软件, 1-10 [2025-09-15]. <https://link.cnki.net/urlid/31.1260.tp.20250703.1757.002>
- HUO Hua, XING Xiaoyu. Research on lightweight pedestrian detection algorithm in complex scenes[J/OL]. Computer Applications and Software, 1-10[2025-09-15]. <https://link.cnki.net/urlid/31.1260.tp.20250703.1757.002>
- [2] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149. DOI:10.1109/TPAMI.2016.2577031
- [3] CAI Z W, VASCONCELOS N. Cascade R-CNN: Delving into high quality object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT, USA: IEEE, 2018: 6154-6162. DOI:10.1109/CVPR.2018.00644
- [4] HE K M, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN[C]//Proceedings of the IEEE International Conference on Computer Vision. Venice, Italy: IEEE, 2017: 2961-2969. DOI:10.1109/ICCV.2017.322
- [5] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, NV, USA: IEEE, 2016: 779-788. DOI:10.1109/CVPR.2016.91
- [6] SUN P, ZHANG R, JIANG Y, et al. Sparse R-CNN: End-to-end object detection with learnable proposals[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville, TN, USA: IEEE, 2021: 14454-14463. DOI:10.1109/CVPR46437.2021.01423
- [7] REDMON J, FARHADI A. YOLOv3: An incremental improvement[EB/OL]. (2018-04-08)[2025-09-15]. <https://arxiv.org/abs/1804.02767>
- [8] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: Optimal speed and accuracy of object detection[J/OL]. arXiv preprint, 2020. <https://arxiv.org/abs/2004.10934>
- [9] ZHU X, LYU S, WANG X, et al. TPH-YOLOv5: Improved YOLOv5 based on transformer prediction head for object detection on drone-captured scenarios[J/OL]. arXiv preprint, 2021. DOI:10.48550/arXiv.2108.11539
- [10] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, Canada: IEEE, 2023: 7464-7475. DOI:10.1109/CVPR52729.2023.00721

- [11] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single shot multibox detector[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21–37. DOI:10.1007/978-3-319-46448-0_2
- [12] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[EB/OL]. arXiv preprint, 2020. DOI:10.48550/arXiv.2010.11929
- [13] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Montreal, Canada: IEEE, 2021: 10012-10022. DOI:10.1109/ICCV48922.2021.00986
- [14] 高昂, 梁兴柱, 夏晨星, 等. 一种改进 YOLOv8 的密集行人检测算法[J/OL]. 图学学报, 2023, 44(05): 890-898. DOI:10.11996/JG.j.2095-302X.2023050890
- GAO Ang, LIANG Xingzhu, XIA Chenxing, et al. An improved YOLOv8 algorithm for dense pedestrian detection[J/OL]. Journal of Graphics, 2023, 44(05): 890-898. DOI:10.11996/JG.j.2095-302X.2023050890
- [15] 张忠民, 吴泽. 基于改进 YOLOv5 的密集行人检测方法[J/OL]. 应用科技, 2023, 50(01): 33-39. DOI:10.11991/yykj.202204024
- ZHANG Zhongmin, WU Ze. Dense pedestrian detection method based on improved YOLOv5[J/OL]. Applied Science and Technology, 2023, 50(01): 33-39. DOI:10.11991/yykj.202204024
- [16] 王泽宇, 徐慧英, 朱信忠, 等. 基于 YOLOv8 改进的密集行人检测算法: MER-YOLO[J/OL]. 计算机工程与科学, 2024, 46(06): 1050-1062. DOI:10.3969/j.issn.1007-130X.2024.06.012
- WANG Zeyu, XU Huiying, ZHU Xinzong, et al. MER-YOLO: An improved dense pedestrian detection algorithm based on YOLOv8[J/OL]. Computer Engineering & Science, 2024, 46(06): 1050-1062. DOI:10.3969/j.issn.1007-130X.2024.06.012
- [17] 熊恩杰, 张荣芬, 刘宇红, 等. 面向交通标志的 Ghost-YOLOv8 检测算法[J/OL]. 计算机工程与应用, 2023, 59(20): 200-207. DOI:10.3778/j.issn.1002-8331.2303-0000
- XIONG Enjie, ZHANG Rongfen, LIU Yuhong, et al. Ghost-YOLOv8 detection algorithm for traffic signs[J/OL]. Computer Engineering and Applications, 2023, 59(20): 200-207. DOI:10.3778/j.issn.1002-8331.2303-0000
- [18] 涂育智, 王法翔, 吴春霖. 融合多注意力机制的轻量级无人机航拍小目标检测模型[J/OL]. 计算机工程与应用, 2025, 61(11): 93-104. DOI:10.3778/j.issn.1002-8331.2401-0000
- TU Yuzhi, WANG Faxiang, WU Chunlin. Lightweight UAV aerial small target detection model integrating multi-attention mechanism[J/OL]. Computer Engineering and Applications, 2025, 61(11): 93-104. DOI:10.3778/j.issn.1002-8331.2401-0000
- [19] 朱宇凡, 杨吉凯, 李威. 改进 YOLOv12 的水面垃圾检测方法 [J/OL]. 计算机工程与应用, 1-14 [2025-09-17]. DOI:10.3778/j.issn.1002-8331.2505-0249
- ZHU Yufan, YANG Jikai, LI Wei. Improved YOLOv12-based Water Surface Garbage Detection Method [J/OL]. Computer Engineering and Applications, 1-14 [2025-09-17]. DOI:10.3778/j.issn.1002-8331.2505-0249
- [20] ZHAO H, YANG G, WANG D, et al. Lightweight deep neural network for real-time visual tracking with mutual learning[C]//Proceedings of the 2019 IEEE International Conference on Image Processing (ICIP). Taipei, Taiwan: IEEE, 2019: 3063-3067
- [21] HARDINGHAUS M, NIELAND S, OOSTENDORP R, et al. Developing a multi-method approach to identifying e-scooter hazard hotspots[J/OL]. Journal of Traffic and Transportation Engineering (English Edition), 2024, 11(4): 667-680. DOI:10.1016/j.jtte.2023.03.002
- [22] WANG X, FU C, HE J, et al. StrongFusionMOT: a multi-object tracking method based on LiDAR-camera fusion[J/OL]. IEEE Sensors Journal, 2023, 23(11): 11241-11252. DOI:10.1109/JSEN.2023.3289345
- [23] DHOKE A, CHOUDHARY P. Temporal and spatial compliance behaviour of pedestrians under the influence of time pressure at signalized intersections: A pedestrian simulator study[J/OL]. Journal of Traffic and Transportation Engineering (English Edition), 2024, 11(1): 55-68. DOI:10.1016/j.jtte.2023.04.010
- [24] WANG Y, WANG H, WANG W, et al. Architecture, application, and prospect of digital twin for highway infrastructure[J/OL]. Journal of Traffic and Transportation Engineering (English Edition), 2024, 11(5): 835-852. DOI:10.1016/j.jtte.2024.03.003

- [25] LIN T Y, DOLLAR P, GIRSHICK R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, USA: IEEE, 2017: 2117-2125
- [26] LIU S, QI L, QIN H, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City, USA: IEEE, 2018: 8759-8768
- [27] ZHENG Z, WANG P, LIU W, et al. Distance-IoU loss: faster and better learning for bounding box regression[J/OL]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(7): 12993-13000. DOI:10.1609/aaai.v34i07.6093
- [28] 韩俊, 袁小平, 王淮, 等. 基于 YOLOv5s 的无人机密集小目标检测算法[J/OL]. 浙江大学学报 (工学版), 2023, 57 (6): 1224-1233.DOI: 10.3785/j.issn.1008-973X.2023.06.018
- HAN Jun, YUAN Xiaoping, WANG Zhun, et al. UAV dense small target detection algorithm based on YOLOv5s[J/OL]. Journal of Zhejiang University (Engineering Science), 2023, 57(6): 1224-1233.DOI: 10.3785/j.issn.1008-973X.2023.06.018

