



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331,CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目： 基于 MNBS-YOLOV12 的肾脏肿瘤病变区域检测
作者： 杨丹丹，王霄，吴钦木，何志琴，罗霞
网络首发日期： 2026-06-01
引用格式： 杨丹丹，王霄，吴钦木，何志琴，罗霞. 基于 MNBS-YOLOV12 的肾脏肿瘤病变区域检测[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20260601.1358.016>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于 MNBS-YOLOV12 的肾脏肿瘤病变区域检测

杨丹丹¹, 王霄^{1,2+}, 吴钦木^{1,2}, 何志琴^{1,2}, 罗霞¹

1. 贵州大学电气工程学院, 贵阳 550025

2. 贵州省高等学校新型电力系统及其数字化技术工程研究中心, 贵阳 550025

+ 通信作者 E-mail: xwang9@gzu.edu.cn

摘要: 医学影像中肾脏肿瘤的精准检测对临床诊断与治疗至关重要, 针对现有医学影像检测方法在复杂形态表征、多尺度特征融合以及模糊边界识别等方面存在的局限与不足, 提出一种基于改进 YOLOv12 框架的肾脏肿瘤检测模型 MNBS-YOLOv12。模型改进包括: (1) 在 A2C2f 模块中嵌入十字形窗口自注意力机制 (Cross-Shaped Window Self-Attention Module, CSWin-SA), 通过水平和垂直方向的条纹自注意力学习, 增强模型对不规则形状病变区域的表征能力, 在维持计算效率的前提下扩展有效感受野; (2) 引入高效多尺度注意力模块 (Efficient Multi-Scale Attention, EMA) 并与 C3k2 结构相结合, 采用通道分组与维度重塑策略减少计算开销, 通过多尺度并行分支捕获从微小钙化至弥漫性病变的差异化特征, 利用跨空间学习机制精准区分肿瘤与正常肾实质的纹理差异; (3) 设计双聚合注意力融合模块 (Dual-Aggregation Attention Fusion Module, DAFM) 以替代传统特征拼接操作, 通过自注意力机制保持肿瘤结构完整性, 并借助交叉注意力深度融合多尺度互补信息, 有效提升模型对模糊、小尺寸及部分遮挡病变的检测鲁棒性, 降低复杂背景下的误检与漏检; (4) 采用扩展的 B_CIoU 损失函数, 在 CIoU 基础上增加三项约束, 进一步提升定位精度与训练收敛速度。实验结果表明, MNBS-YOLOv12 在精确率、召回率、mAP50 和 mAP50-95 四项指标上均优于 YOLOv12 模型, 分别达到 95.75%、97.77%、98.35% 和 93.65%, 较基线模型分别提升 2.72、2.06、2.54 和 1.83 个百分点, 验证了所提多模块机制协同作用的有效性与模型优越的检测性能。

关键词: YOLOv12; 肾脏肿瘤检测; 注意力机制; 目标检测; 深度学习

文献标志码: A **中图分类号:** TP391.4 **doi:** 10.3778/j.issn.1002-8331.2601-0193

Detection of renal tumor lesion regions using the MNBS-YOLOV12 approach

YANG Dandan¹, WANG Xiao^{1,2+}, WU Qinmu^{1,2}, HE Zhiqin^{1,2}, LUO Xia¹

1. School of Electrical Engineering, Guizhou University, Guiyang 550025, China

2. Engineering Research Center for New Power Systems and Their Digital Technology in Higher Education Institutions of Guizhou Province, Guiyang 550025, China

Abstract: Accurate detection of kidney tumors in medical imaging is crucial for clinical diagnosis and treatment. To address the limitations of existing medical imaging detection methods in complex morphological representation, multi-scale feature fusion, and fuzzy boundary recognition, a kidney tumor detection model called MNBS-YOLOv12 based on an improved YOLOv12 framework was proposed. The model improvements include: (1) embedding a Cross-Shaped Window Self-Attention Module (Cross-Shaped Window Self-Attention Module ,

基金项目: 国家自然科学基金项目(NO.61861007), 贵州省科技支撑计划项目([2023]096、[2022]264、[2023]412、[2023]409), 贵州省科技计划项目(ZK[2021]303)。

作者简介: 杨丹丹(2001—), 女, 在读硕士研究生, 研究方向为基于深度学习的医疗影像处理; 王霄(1985—), 男, 博士, 教授, 研究方向为自组网信息融合与可信度计算、控制理论与控制工程等; 吴钦木(1976—), 男, 博士, 教授, 研究方向为电动汽车传动控制、电驱动系统效率优化和故障诊断、深度学习等; 何志琴(1974—), 女, 硕士, 教授, 研究方向为先进控制理论在机电系统应用、电力电子技术及电力拖动控制系统等; 罗霞(2002-), 女, 在读硕士研究生, 研究方向为基于深度学习的医疗影像处理。

CSWin-SA) within the A2C2f module, which enhances the model's ability to represent irregularly shaped lesion areas through stripe self-attention learning in horizontal and vertical directions, expanding the effective receptive field while maintaining computational efficiency; (2) introducing an Efficient Multi-Scale Attention (Efficient Multi-Scale Attention, EMA) module in combination with the C3k2 structure, using channel grouping and dimension reshaping strategies to reduce computational overhead, capturing differentiated features from tiny calcifications to diffuse lesions via multi-scale parallel branches, and precisely distinguishing the textural differences between tumors and normal renal parenchyma through a cross-space learning mechanism; (3) designing a Dual-Aggregation Attention Fusion Module (Dual-Aggregation Attention Fusion Module, DAFM) to replace traditional feature concatenation operations, maintaining tumor structure integrity through self-attention mechanisms, and using cross-attention to deeply fuse multi-scale complementary information, effectively improving the model's robustness for detecting fuzzy, small, and partially occluded lesions and reducing false positives and missed detections in complex backgrounds; (4) adopting an extended B_CIoU loss function by adding three additional constraints on top of CIoU, further enhancing localization accuracy and training convergence speed. Results demonstrate that MNBS-YOLOv12 outperforms the original YOLOv12 model in four key metrics: precision, recall, mAP50, and mAP50-95, achieving 95.75%, 97.77%, 98.35%, and 93.65%, respectively, which represent improvements of 2.72%, 2.06%, 2.54%, and 1.83% over the baseline model, validating the effectiveness of the proposed multi-module collaborative design and the superior performance of the model.

Key words: YOLOv12; kidney tumor detection; attention mechanism; object detection; deep learning

肾细胞癌作为肾脏肿瘤发病的主要类型,是全球范围内常见的泌尿系统恶性肿瘤之一,其发病率和死亡率呈逐年上升趋势。计算机断层扫描(CT)成像技术因其高分辨率和高对比度,已成为肾脏肿瘤筛查、诊断和术前规划的首选影像学手段。在CT图像中准确、高效地识别和定位肾脏肿瘤病变区域,对于临床医生的早期诊断、治疗方案制定以及预后评估具有至关重要的价值。医学图像检测是医学图像计算和计算机辅助干预的一个重要研究课题,主要通过处理图像来获取有用的信息,如患病器官或组织的形状、大小和结构,提供更准确和详细的诊断和治疗建议。近年来,基于深度学习的医学图像检测技术取得了显著进展,并已广泛应用于多个医学领域。并且随着深度学习领域中目标检测算法的开发,研究人员开始将这些算法用于病灶检测,尤其是癌症方面。

Chen 等人^[1]提出 YOLO-NeuroBoost 模型,该模型将 YOLOv8 网络与动态卷积 KernelWarehouse,卷积块注意力模块(Convolutional Block Attention Module, CBAM)技术结合,并使用 InnerGIoU 损失函数

取代 CIoU 损失来计算边界框损失。Alamri 等人^[2]提出了一种创新的深度学习和量子熵技术用于脑肿瘤边缘检测和分类模型,应用于 MRI 成像。其核心创新是采用 Wiener 滤波与自适应伽马校正双步骤预处理提升 MRI 图像质量;以增强 UNet+NAdam 分割肿瘤区域、量子熵(QE)界定边界的双分支策略兼顾精度;通过多头注意力融合 EfficientNetV2 与 Swin 变换器来强化特征提取,并结合 GCRNN 分类器及 STO 算法自适应调参提升性能。LI 等人^[3]提出基于多模态信息融合和卷积神经网络(Convolutional Neural Network, CNN)的脑肿瘤检测方法 Multi-CNNs。将 2D-CNN 扩展为多模态 3D-CNN,以获得不同模态特征下的脑病变三维空间,帮助更好提取模态间差异信息。Sargunan 等人^[4]提出了一种名为 SqResF-Net 的新方法,该方法通过结合 SqueezeNet、Deep Residual Network(DRN)和分数微积分(FC)来有效和准确地检测肾脏肿瘤。Sudharson 等人^[5]基于轻量级深度学习模型,开发了一个面向早期肾脏异常的 2D 超声自动诊断系统。通过结构层调整,构建了适用于超声图像的

专用网络 US-Net, 能够从不同质量的超声影像中提取特征, 再由集成分类模块基于多数投票机制做出最终预测。Sun 等人^[6]提出了一种基于图卷积网络 (GCN) 的肺炎检测方法, 包括创新的 k-hop 图构建算法、自适应图卷积网络 (SAGCN)、图注意力机制和节点自适应范围融合 (NARF) 模块, 以改善全局结构信息和病变相关性的提取。ZHI 等人^[7]研究设计并验证了一个人工智能交互网络称为肾脏肿瘤分期网络 (KtSNet), 该网络利用弱监督学习, 通过人类-人工智能交互实现实时、高效地检测高侵袭性透明细胞肾细胞癌。Hisham 等人^[8]提出了一种多阶段分类流程来分类五种类型的肾肿瘤, 并使用一个由三个部分组成的新颖集成系统来区分五种肾肿瘤亚型。

与此同时, 以 YOLO 系列为代表的一阶段目标检测算法, 因其卓越的检测速度与精度, 在自然图像领域获得了广泛应用。其核心思想是将目标检测视为一个回归问题, 直接预测目标的边界框和类别概率, 这种高效的范式为医学图像分析提供了新的思路。将目标检测的快速定位能力与精细分割相结合, 有望实现更高效的病灶分析流程。2025 年发布的 YOLOv12 模型^[9], 在先前版本的基础上进行了改进, 其核心理念是进行一次“以注意力为中心”的深度架构革新。YOLOv12 在实时目标检测技术发展中实现了关键突破。其结合高效骨干网络 (R-ELAN)、FlashAttention 模块与 7×7 可分离卷积, 在检测速度与准确性上均优于前代, 同时具备实例分割能力, 展现出更强的多功能性与应用潜力。

然而, 现有通用目标检测方法在处理肾脏肿瘤这一特定医学任务时存在局限且并无具体方法提出并应用。其核心挑战在于: 肾脏病灶不仅尺寸差异大 (从微小钙化至弥漫性病变), 且形态多数不规则, 加之肿瘤组织与正常肾实质在影像学上常呈现一些相似的纹理特征, 导致现有方法难以有效捕捉跨尺度的差异化表征, 并在模糊边界与复杂背景干扰下易产生误检与漏检。针对上述临床检测局限, 本文首次提出一种面向肾脏肿瘤病变检测的应用型创新框架——

MNBS-YOLOv12。

本文的主要贡献详述如下:

(1) 将 CSWin-SA 加入 A2C2f 模块, 增强其对不规则形状肾脏肿瘤病变区域的检测能力, 加入 CSWin-SA, 实现水平和垂直条纹的自我注意力学习, 在保持计算效率的同时增强了感受野交互能力。

(2) 引入 EMA 与 YOLOv12 的 C3k2 相结合, 特征分组策略通过通道分组与维度重塑, 在保留特征信息完整性的同时, 显著降低了计算开销, 通过多尺度并行分支有效捕捉从微小钙化到弥漫性病变区域的差异化特征, 跨空间学习机制精准区分肿瘤组织与正常肾实质的纹理差异。

(3) 将 DAFM 替换 YOLOv12 中的传统拼接方式 (concat) 用于肾脏肿瘤病变区域检测, 通过自注意力机制强化肿瘤轮廓与内部结构的完整性表达, 避免关键信息在融合中被稀释, 同时利用交叉注意力深度挖掘多尺度特征间的互补信息, 使模型能更全面感知模糊、微小及部分遮挡的肾脏肿瘤病变, 从而在复杂背景中实现更精准的定位, 显著降低漏检与误检概率。

(4) 采用一种 B_CIoU 损失函数, 在 CIoU 损失函数的基础上, 进一步引入了三个附加惩罚项: 重叠区域的大小、预测框与目标框之间的宽高关系, 以及中心点之间的归一化距离。以此提高模型检测精度和收敛速度。

1 方法介绍

MNBS-YOLOV12 网络结构如图 1 所示。本文对基准网络进行了四项关键改进:

第一, 将 CSWin-SA 与骨干网络部分 A2C2f 模块相结合, 该设计通过在其核心引入 CSWin-SA, 使模型能够分别在水平与垂直方向的条形窗口内进行高效的注意力计算, 提供全局空间上下文约束, 从空间分布层面有效抑制特定背景结构的误检。从而在保持较低计算复杂度的前提下, 增强对不规则形态肾脏肿瘤病变区域的特征捕捉与感受野交互能力。


第二, 将 DAFM 替换 Concat 部分, DAFM 通过自注意力机制强化了单一模态内目标特征的完整性和

连贯性, 确保目标的核心结构 (如轮廓、关键部件) 在融合过程中不被破坏, 为目标定位提供稳定支撑; 同时, 交叉注意力机制充分挖掘不同模态中与目标相关的互补信息 (如外观特征与语义特征、全局特征与局部特征), 让检测模型能更全面地感知目标属性, 有效提升对复杂场景下模糊、遮挡、不同尺寸目标的识别能力, 降低漏检和误检概率。

第三, 将 EMA 与 YOLOv12 的 C3k2 相结合, 该

设计通过特征分组实现高效计算, 利用多尺度分支覆盖广泛的病变特征, 并借助跨空间学习精准定位肿瘤区域, 从而在整体上优化了对肾脏肿瘤的特征表征能力。

第四, 采用一种 B_CIoU 损失函数, 其引入的三项附加约束以提升对肾脏肿瘤病灶定位的稳定性与精确性, 同时提高模型检测精度和收敛速度。






图1 MNBS-YOLOV12 网络结构

Fig.1 MNBS-YOLOV12 Network Architecture

综上，四个模块形成了从特征筛选、语义引导、空间约束到几何优化的完整肾脏肿瘤病变检测流程，

层层递进、互为支撑，共同提升模型在复杂背景下的检测鲁棒性与定位精度，如表 1 所示。

表 1 模型改进机制对照

Table 1 Comparison of Model Improvement Mechanisms

核心挑战	对应改进	针对性设计	解决问题
形态不规则与空间上下文缺失	CSWin-SA	采用十字形窗口自注意力，沿水平和垂直方向建模	增强模型对不规则形状病变的几何表征能力，扩展感受野以理解肿瘤与周围器官的空间关系
边界模糊与背景干扰	EMA-C3k2	通过通道分组与跨空间学习，精细化区分纹理差异	精准区分肿瘤组织与正常肾实质的纹理差异，捕捉从微小钙化到弥漫性病变区域的差异化特征
多尺度特征融合与小病变丢失	DAFM	设计双聚合注意力融合模块替代传统特征拼接操作，实现特征的动态重标定与融合	在多尺度融合过程中保留小尺寸病变的细节信息，提升对模糊及部分遮挡病变的鲁棒性
定位精度不足	B_CIoU 损失函数	在 CIoU 基础上增加三项约束，优化边界框回归。	针对不规则肿瘤形态，提升预测框与真实标注的匹配度，加速模型收敛。

1.1 CSWin-SA

肾脏肿瘤的精准检测在临床影像诊断中依赖对病灶全局空间上下文的理解，这源于肾脏独特的解剖学结构与肿瘤生长模式的深层关联。肾脏作为一对实质性器官，其内部结构呈现显著的空间各向异性：肾动脉呈放射状分支深入肾实质，肾锥体与集合系统沿肾乳头至肾盂方向纵向走行，而肾包膜则作为边界结构将肾脏与周围脂肪囊分隔。这种解剖学布局决定了肾脏病变并非孤立存在：肿瘤的生长往往沿特定的解剖

轴线延伸。从特征提取的角度看，这种空间各向异性表现为两个正交方向上的显著模式：水平方向（对应放射状血管分布）与垂直方向（对应集合系统纵向走行）。启发本文对注意力机制的选择—CSWin-SA 通过水平条纹与垂直条纹的并行计算，匹配了肾脏解剖结构的这种正交方向性。然而，现有 CNN 方法受限于方形卷积核的固定感受野，难以有效建模这种长距离、非规则的空间依赖关系，经典的 Transformer 全局

自注意力虽能捕获长程上下文,但其计算量大,且缺乏对肾脏解剖学结构的先验引导,易将解剖学上不相关的远距离区域纳入注意力计算,反而引入噪声。

鉴于这一背景,本文首次将 CSWin-SA 引入肾脏肿瘤病变检测任务,构建了 A2C2f 增强模块,其核心创新在于将其十字形条纹注意力机制与肾脏解剖学轴线进行对齐。具体而言,CSWin-SA 将注意力头均分为两组,分别在水平与垂直条纹上并行执行自注意力计算。这一设计恰好与肾脏的两条解剖学主线相吻合:水平条纹注意力(沿图像高度方向划分)可捕获肿瘤沿人体纵轴的上下位置关系,对应肾脏集合系统的头足走向;垂直条纹注意力(沿图像宽度方向划分)可捕获肿瘤相对于肾门的横向偏移,对应肾血管的放射状分布。

由于肾脏恶性肿瘤的病理特征显现出不规则形态的本质,是对上述两条解剖轴线的非对称性突破与浸润,具体表现为向外凸起的肿瘤伪足,往往优先沿着血管间隙(水平轴向)或肾盂输尿管连接部(垂直轴向)的路径生长。CSWin-SA 的十字形窗口策略通过正交分解,可将不同形状的肿瘤凸起视作水平与垂直两个方向的矢量和,只要该凸起在 X 轴(血管方向)或 Y 轴(集合系统方向)上具有连续性分量,对应的狭长形条纹感受野就能在单一窗口内完整覆盖该凸起的基底部与尖端,从而在特征编码层面保持不规则边界的拓扑连续性。

并且由于肾脏肿瘤(如肾细胞癌)常呈膨胀性生长,同时沿血管轴与集合系统轴两个主要方向延伸,CSWin-SA 的十字交叉并行计算可同步建模这两个解剖轴向上的特征依赖,实现对不规则病变沿解剖主方向的定向理解。通过这种对齐,模型可实现对肾脏肿瘤沿解剖轴线的定向空间建模,同时避免无关噪声的干扰。在维持计算效率的前提下,实现对不规则病变区域的全局建模。

在目标检测任务中,CSWin-SA 的十字形注意力机制能够并行提取水平方向的物体轮廓特征与垂直方向的空间层级信息,从而提升对不同长宽比目标的定位精度。相较于传统窗口注意力机制,其条纹式注意力在维持相近计算负载的同时,更显著扩展其模型的有效感受野^[10]。同时,与传统的自注意和基于移位窗

口的多头注意力机制不同^[11-13],CSWin-SA 通过将注意力计算组织为水平与垂直条纹的并行处理,实现了计算效率与模型能力的平衡。其核心结构如图 2 所示,首先,将全部的 N 个注意力头均分为两组,一组 $\{h_1, h_2, \dots, h_{N/2}\}$ 在水平条纹上执行自注意力计算,另一组 $\{h_{N/2+1}, h_{N/2+2}, \dots, h_N\}$ 在垂直条纹上并行执行,最终将两组的输出进行拼接。这种设计突破了传统窗口注意力的局部限制,在显著扩大有效感受野的同时,降低了整体计算复杂度。

具体而言,该机制通过一个可调节的条带宽度(sw)参数来适应不同分辨率的输入与任务需求:通常对高分辨率输入选用较小的 sw 以保持细节,对低分辨率输入则选用较大的 sw 以捕获更广泛的上下文信息。在操作流程上,输入特征图会被划分为一系列不重叠的水平或垂直条纹。较大的 sw 值意味着每个条纹覆盖更长的像素范围,从而增强模型捕捉条带内长程依赖关系的能力,这对于理解图像中的全局语境至关重要。详细过程如下:

水平条纹划分是将输入特征图 $X \in R^{H \times W \times C}$ 在高度(H)方向上切割,划分为 M 个不重叠的水平条纹。肾脏集合系统(肾盏、肾盂)及输尿管上段沿人体纵轴(头足方向)纵向走行,肿瘤常沿此轴向延伸。水平条纹注意力可沿垂直方向捕获肿瘤与集合系统的空间依赖关系。每个条纹的高度为 sw , 宽度为 W 。因此,总条纹数 $M = H / sw$ 。垂直条纹划分同理在宽度(W)方向上切割,形成多个垂直条纹。在条纹内并行计算自注意力的过程中,各分组注意力头在其指定方向的条纹单元内独立执行计算:对于水平组的第 n 个注意力头,首先将第 i 个水平条纹的特征 $X_h^i \in R^{sw \times W \times C}$ 通过线性变换映射为查询(Q)、键(K)和值(V)向量,随后在该条纹内部执行标准自注意力计算,通过 Softmax 得到局部特征表示 Y_n^i 。具体实现公式如下:

$$Q_n^i = W_n^Q X_h^i \quad K_n^i = W_n^K X_h^i \quad V_n^i = W_n^V X_h^i \quad (1)$$

$$Y_n^i = \text{Softmax}\left(\frac{Q_n^i (K_n^i)^T}{\sqrt{d_n}}\right) V_n^i \quad (2)$$

$$H_Attention_n(X) = [Y_n^1, Y_n^2, \dots, Y_n^M] \quad (3)$$

垂直条纹划分同上,在宽度(W)方向上切割,

形成 S 个垂直条纹。肾动脉自肾门进入后呈近似水平方向的放射状分支, 贯穿肾窦至肾皮质。垂直条纹注意力(沿图像宽度方向划分)可沿水平方向建模肿瘤与肾血管的空间关系。

$$Q_n^i = W_n^Q X_v^i \quad K_n^i = W_n^K X_v^i \quad V_n^i = W_n^V X_v^i \quad (4)$$

$$V_Attention_n(X) = [Y_n^1, Y_n^2, \dots, Y_n^S] \quad (5)$$

完成所有条纹的并行计算后, 系统将各头输出的条纹注意力结果分别沿空间维度拼接, 形成完整的水

平方向注意力与垂直方向注意力, 最终通过拼接所有方向的注意力输出并经过线性融合层, 生成兼具多向全局上下文信息的综合特征表示。

$$h_n = \begin{cases} H_Attention_n(X), n = 1, 2, 3, \dots, N/2 \\ V_Attention_n(X), n = N/2 + 1, \dots, N \end{cases} \quad (6)$$

$$CSWin_Attention(X) = \text{concat}(h_1, h_2, \dots, h_N) W^\circ \quad (7)$$




图2 CSWin 自注意力机制

Fig.2 CSWin Self-Attention Mechanism

1.2 结合 EMA 的 C3k2_EMA

由于肿瘤组织与正常肾实质在影像学上常呈现高度相似的纹理特征。具体而言, 肾实质的皮质、髓质、肾柱等正常结构具有规律的灰度分布和规则的空间排列; 而肾细胞癌等病变则常呈现异质性、不规则灰度模式, 但在部分病例中, 处于早期浸润阶段或属于低级别的肿瘤, 其与正常组织之间的灰度差异较为微弱, 难以区分。这种纹理相似性导致传统检测方法具有一定的局限性。针对现有方法难以区分肿瘤与肾实质细微纹理差异的问题, 本文创新性地将 EMA 与 C3k2 结构融合, 通过通道分组策略实现对模糊边界的精细化特征提取, 这是首次将跨空间学习机制应用于肾脏肿瘤的纹理辨析任务中。

在传统注意力机制中, 如通道注意力 (Squeeze-and-Excitation, SE)、坐标注意力 (Coordinate Attention, CA) 通常将整个通道维度作为一个整体进行全局建模, 这种方式隐含假设所有通道共享相同的语义分布。其中, SE 仅聚焦通道维度建模, 通常忽略空间位置信息,

无法捕捉肾脏结构中肿瘤与正常组织的空间分布差异。

CA 虽引入坐标信息实现空间与通道联合建模, 但其全局建模方式未对特征进行区分, 会将肿瘤纹理、正常肾实质结构等不同语义特征混合编码, 会引发信息干扰, 难以挖掘细微纹理差异。而在肾脏肿瘤检测任务中, 病变区域的表征涉及多种异质信息——包括肿瘤轮廓的几何结构、内部纹理的灰度分布、以及与周围组织的边界关系。若将这些信息压缩到单一的通道注意力权重中, 易导致不同语义模式的相互干扰与信息混淆。针对这一问题, EMA 采用特征分组策略, 将输入特征沿通道维度划分为 G 个子特征 $X = [X_0, X_1, X_2, \dots, X_{G-1}]$, 其中 $X_i \in R^{C/G \times H \times W}$, 让不同分组独立学习肿瘤异质灰度、规则肾实质结构等差异化语义模式, 使各通道组在训练过程中实现自动分化, 避免将轮廓、纹理、背景等异质信息压缩到单一注意力权重中造成的语义混淆。

同时, 为降低计算复杂度, CA 通常采用 1×1 卷积对通道维度进行降维。然而, 这一操作在压缩计算量

的同时,也造成了通道信息的不可逆损失——降维过程会丢失肾脏肿瘤细微纹理与模糊边界的细节信息,这不适用需要精细纹理辨别的肾脏肿瘤检测任务。针对这一问题,EMA 将部分通道维度重塑到批次维度,而非通过卷积进行通道压缩,即将 G 个特征组重塑并排列到批次维度,重新定义形状为 $C//G \times H \times W$ 的张量进行后续处理。该设计依据源于标准 2D 卷积核的参数维度为 $[out_channels, in_channels, k, k]$, 利用卷积核不涉及批次维度的特性,在不减少通道数、不增加参数的前提下实现跨通道信息的高效并行处理,确保肿瘤的细微纹理、模糊边界等关键信息在注意力计算过程中不被压缩或丢失。

最后,特征分组与维度重塑形成协同机制进一步引入跨空间学习,EMA 通过将 1×1 分支和 3×3 分支的输出进行跨维度交互,通过矩阵点积操作聚合像素级全局上下文,帮助模型在肾脏复杂背景中准确聚焦目标病变区域,从而提升检测精度。

简单来说,特征分组策略将输入特征的通道维度划分为多个子特征,并通过重塑部分通道至批处理维度,在保留各通道完整信息的同时降低计算开销,确保模型在高效运行的同时不会过多增加参数总量;多尺度并行分支 (1×1 卷积负责捕捉短程依赖、 3×3 卷积负责捕捉长程依赖)覆盖不同尺度目标的特征;跨空间学习机制通过矩阵点积操作聚合像素级全局上下文,有效抑制正常组织干扰,聚焦病变区域从而提升检测精度。EMA 具体结构如图 3 所示。

(1) 特征分组:将输入特征图(维度为 $C \times H \times W$)按通道划分为 G 个子特征(每个子特征维度为 $C/G \times H \times W$),并将 G 组子特征重塑至批处理维度,形成 $G \times batch_size$ 的新批处理维度,避免通道降维带来的信息损失。

(2) 并行子网络:包含 1×1 分支与 3×3 分支。 1×1 分支借鉴 CA 的 1D 全局平均池化,沿水平和垂直方向编码空间位置信息,通过 1×1 卷积建模局部跨通道

交互,聚焦于肿瘤浸润前沿的毛刺状边界、灰度突变区域等短程依赖关系; 3×3 分支通过 3×3 卷积扩大感受野,捕捉肿瘤整体的空间结构信息,包括肿瘤与肾实质的空间上下文关系、肿瘤内部的坏死/囊变区分布等长程依赖特征,增强对复杂场景的适应能力。

沿水平方向的 1D 全局平均池化:

$$z_c^H(H) = \frac{1}{W} \sum_{0 \leq i \leq W} x_c(H, i) \quad (8)$$

其中, x_c 表示第 c 个通道的输入特征, H 表示高度方向的特定位置, W 表示宽度方向的维度大小。该步骤在固定的高度 H 上,对所有宽度方向的位置进行平均,输出尺寸为 $R^{C \times H \times 1}$ 。

沿垂直方向的 1D 全局平均池化:

$$z_c^W(W) = \frac{1}{H} \sum_{0 \leq j \leq H} x_c(j, W) \quad (9)$$

其中, x_c 表示第 c 个通道的输入特征, H 表示高度方向的维度大小, W 表示宽度方向的特定位置。该步骤在固定的高度 H 上,对所有宽度方向的位置进行平均,输出尺寸为 $R^{C \times 1 \times W}$ 。

(3) 跨空间学习:对两个分支的输出分别进行 2D 全局平均池化,经 Softmax 激活后通过矩阵点积生成两个空间注意力图,聚合后通过 Sigmoid 函数输出最终注意力权重,与原始输入特征图逐元素相乘,得到加权后的特征图(维度仍为 $C \times H \times W$),可直接嵌入深层网络。

2D 全局平均池化:

$$z_c = \frac{1}{H \times W} \sum_j^H \sum_i^W x_c(i, j) \quad (10)$$

其中, x_c 表示第 c 个通道的输入特征, H 和 W 分别表示高度和宽度方向的维度大小。该步骤在所有空间位置进行平均,将整个空间维度压缩为单个数值,输出尺寸为 $R^{C \times 1 \times 1}$ 。




图3 高效多尺度注意力 (EMA)

Fig.3 Efficient Multi-Scale Attention (EMA)

1.3 双聚合注意力融合 DAFM

针对多尺度特征融合过程中小尺寸病变信息易丢失、背景噪声易放大的问题，本文引入一种应用型创新模块——DAFM，将自注意力与交叉注意力机制引入肾脏肿瘤检测的多尺度特征融合任务中。该设计的创新性在于：并非对特征进行被动拼接，而是通过双路注意力机制实现对多尺度信息的主动筛选与语义对齐，从而在融合过程中优先保留小尺寸病变的细节信息，并抑制背景干扰。

具体而言，肾脏肿瘤的小尺寸病变检测，其难点主要体现为微弱信号在深度网络中的双向衰减：一方面，随下采样层级加深，特征响应被逐步削弱；另一方面，在多尺度融合阶段，病变特征易受复杂背景的耦合干扰。DAFM为解决这一问题，一是通过自注意路径（SAB）在跨模态融合前增强浅层特征，提升微小病变响应权重，同时抑制无关背景噪声，提高信噪比。二是依托由 softmin 驱动的差异聚焦策略，结合小病变细节多留存于浅层特征、深层特征对应信息匮乏形成的特征差异，在交叉注意力交互块（CAIB）中以 softmin 替换常规 softmax，实现对特征差异的重点捕捉而非共性提取，促使深层特征主动提取浅层细节信息，进而激活并放大微弱的病变信号。三是引入可学习参数 α 与 β 实现动态权重调节，模型可依据输入特征自适应把控模态内信息与模态间信息的保留程度，在以小病变为主的区域自动提升 α 数值，增强 SAB 作

用，避免病变细节被背景信息掩盖。

结构如图4所示。SAB对每种模态分别执行内部精细化处理，通过特征自我增强与去噪，确保肿瘤轮廓、关键部件等核心结构在融合前不被削弱，从源头上避免信息丢失。CAIB采用 softmin 机制，其核心创新在于聚焦模态间的差异点而非相关性：当浅层细节特征与深层语义特征存在差异时，softmin 赋予该区域更高权重，使小尺寸病变的微弱信号能够被深层特征“唤醒”并保留，避免了因过度依赖共性而导致的细节信息遗漏——这是融合中挖掘互补信息。最后，引入可学习参数 α 和 β 对两类注意力输出进行动态加权融合，使模型能根据输入特征的自适应需求优先保留关键信息，避免固定权重导致的重要信息被掩盖，输出时确保优先级。通过“先增强、再挖掘、后优先”的递进式保护策略，DAFM 从根本上解决了传统特征拼接中小目标信息易丢失、模糊边界结构易破坏的问题。

具体来说，先通过 1×1 卷积层生成两组 QKV（查询，键，值），其中包含 $x_1, x_2 \in R^{H \times W \times C}$ 分别代表两种模态的输入特征。然后，使用依赖性卷积（DWConv）以将 QKV 表示投影到细化的特征空间中，最后，每个 QKV 集合被分成三个部分，分别表示查询、键和相应模态的值：

$$Q_i, K_i, V_i = \text{Conv}_{1 \times 1}(x_i) \quad i \in (1, 2) \quad (11)$$

$$Q_i^1, K_i^1, V_i^1 = \text{DWConv}(Q_i), \text{DWConv}(K_i), \text{DWConv}(V_i) \quad (12)$$

接着，通过引入 CAIB，有效促进多模态信息在

高级语义层面的集成。该机制确保各模态的查询表示能够与来自对应模态的键和值实现精确对齐，从而增强了模态间特征的一致性和相关性。

而 SAB 与 CAIB 协同作用，旨在强调和细化模态内部的特征表达。

$$CAIB_{x1 \rightarrow x2} = \text{Soft max}(-Q_{x1} \cdot K_{x2}^T) \cdot V_{x2} \quad (13)$$

$$CAIB_{x2 \rightarrow x1} = \text{Soft max}(-Q_{x2} \cdot K_{x1}^T) \cdot V_{x1}$$

$$SAB_{x1} = \text{Soft max}(Q_{x1} \cdot K_{x1}^T) \cdot V_{x1} \quad (14)$$

$$SAB_{x2} = \text{Soft max}(Q_{x2} \cdot K_{x2}^T) \cdot V_{x2}$$

在上述基础上，DAFM 通过对上述两类注意力模块的输出进行加权组合，实现对整体特征表示的增强。

$$F_1 = CAIB_{x2 \rightarrow x1} + \alpha SAB_{x1} \quad (15)$$

$$F_2 = CAIB_{x1 \rightarrow x2} + \beta SAB_{x2}$$

$$F_i' = \text{Conv}_{1 \times 1}(F_i) \quad (16)$$

$$F_{final} = \text{Conv}_{3 \times 3}(\text{Concat}(F_1', F_2')) \quad (17)$$

其中， 1×1 卷积用于对经过双重注意力增强的特征进行通道级精炼，而可学习参数 α 和 β （取值范围限定在 $[0,1]$ 之间）则作为平衡因子，动态调节 SAB 与 CAIB 特征在融合过程中的贡献权重。最终，将两种模态的特征沿通道维度拼接，并借助 3×3 卷积实现特征降维与语义压缩，从而生成紧凑且语义丰富的联合表示，为后续的深层特征提取任务提供高质量的输入特征。




图4 双聚合注意力融合 DAFM

Fig.4 Dual-Aggregated Attention Fusion DAFM

1.4 B_CIoU 损失函数

YOLOv12 网络使用 Ciou 作为边界框的损失函数，Ciou 通过结合 IoU 重叠度、中心点距离惩罚和宽高比一致性惩罚，实现了边界框回归的全面优化，显著提升了收敛速度和检测精度^[14]，成为目标检测中的主流选择。但其问题在于宽高比惩罚项存在理论局限性：当预测框与真实框宽高比相同时，该惩罚项失效，Ciou 退化为 DIou；同时，宽高比惩罚项 v 在求导过程中因包含 $1/(w^2 + h^2)$ ，在宽高归一化后易引发梯度

爆炸，为解决此问题而引入的梯度截断或修改操作，又会扭曲原始梯度方向，影响模型的最终收敛精度。

针对上述问题，并结合肾脏肿瘤影像的任务特性——即病灶尺寸跨度大、边界模糊、与肾盂及肾窦等正常组织灰度接近且易发生边界粘连，同时医学影像标注中的真实框存在轻微偏差——这对损失函数的梯度稳定性与回归分支的鲁棒性要求更高。传统 Ciou 难以实现对弱边界、小尺度病灶的精准约束，本文引入一种 B_CIoU 损失函数^[15-16]，在 Ciou 损失函数的

基础上, 进一步引入了三个附加惩罚项: 重叠区域的大小、预测框与目标框之间的宽高关系, 以及中心点之间的归一化距离。该项改进不仅可以有效规避 CIoU 宽高比惩罚失效问题, 提升对肾脏肿瘤病灶定

位的稳定性与精确性, 同时改善模型收敛过程, 更适配肾脏肿瘤病变区域检测的临床需求。提高模型检测精度和收敛速度。CIoU 与 B_CIoU 损失函数对比如图 5 所示。其公式如下所示:

$$L_{B_CIoU} = 1 - IoU + \frac{\rho^2(B^{gt}, B^P)}{c^2} + \alpha v^v + \frac{\rho_1^2(B^{gt}, B^P)}{c_1^2} + \beta v_1^v \quad (18)$$

$$v^v = \frac{8}{\pi^2} \left[(w_{gt}^2 + w^2) \left(\arctan\left(\frac{w}{w_{gt}}\right) - \frac{\pi}{4} \right)^2 + (h_{gt}^2 + h^2) \left(\arctan\left(\frac{h}{h_{gt}}\right) - \frac{\pi}{4} \right)^2 \right] \quad (19)$$

其中 B^{gt} 是目标框, B^P 是预测框, ρ 表示预测框与目标框中心点之间的距离, ρ_1 是重叠区域与目标框中心点的距离, c 表示包围预测框与目标框的最小矩形框的对角线距离, α 是权衡参数, c_1 为目标框的

对角线长度, β 是权衡参数, v_1^v 衡量重叠区域与目标框的宽高一致性。 w_{gt} 、 h_{gt} 是目标框的宽度和高度, w 、 h 是预测框的宽度和高度, w_o 、 h_o 表示重叠区域的宽度和高度。




图5 CIoU 与 B_CIoU

Fig.5 CIoU and B_CIoU

2 实验部分

2.1 数据集

KiTS 数据集是一个公开的肾脏 CT 影像数据集, 旨在促进肾脏肿瘤的自动化分割和检测技术的发展。经过初步筛选和清洗, 最终得到的数据集包含“严重有病变”和“正常无病变”两种样本, 类别分布较为平衡, 图像涵盖了不同类型的肾脏病变。该数据集包含了 300 例接受肾脏部分切除或根治性切除手术的患者的术前增强 CT 影像。该数据集的核心特征包括提供了肾脏 CT 影像及其相关的标注信息, 重点是肾脏及肾

脏肿瘤区域的检测任务。将数据集按一定比例分别划分训练集、验证集以及测试集。其中, 训练集图片 2745 张, 测试集 393 张, 验证集 783 张。

在输入到模型中训练之前, 对切片图像进行以下预处理操作: 1) 调整窗宽、窗位使得肾脏成像清晰; 2) 将图片尺寸统一为 640×640; 3) 数据增强, 将切片图像以 0.5 的概率随机水平翻转、0.5 的概率随机裁剪并放大 (不改变图像尺寸)、以 0.2 的概率旋转 90 度的方式扩充数据集以增加网络泛化性能; 4) 最后对图像进行归一化处理, 以加速深度全卷积网络的收敛。如图 6 所示。




图 6 肾脏 CT 影像处理

Fig.6 Kidney CT Image Processing

2.2 实验环境

本实验的运行环境基于 Windows11 64 位操作系统, 硬件平台搭载了 13 代英特尔酷睿 i5-13400F 处理器、32GB 内存以及 16GB 显存的 NVIDIA GeForce RTX5060Ti 显卡。软件开发环境使用 PyCharm 2022,

并基于 Python3.12 编程语言与 PyTorch12.4 (CUDA 版本) 深度学习框架进行模型构建与计算, 该配置为处理 KiTS 等大型医学影像数据集提供了充足的计算与存储资源。模型的训练参数设置如表 2 所示。

表 2 训练参数配置

Table 2 Training Parameter Configuration

Parameters	Values
Epoch	150
Batch size	4
Learning rate	0.001
Image size	640×640
Optimizer	Adamw

2.3 评价指标

本文采用精确率(Precision)、召回率(Recall)、平均精度均值(mAP50、mAP50-95)、F1 分数(F1_Score)衡量模型精度, 模型权重衡量模型复杂度以及计算量(FLOPS)来衡量模型的检测效能。其中:

精确率(Precision): 表示模型预测为正例的样本中, 实际为正例的比例。

召回率(Recall): 表示所有实际为正例的样本中, 模型成功预测出的比例。

mAP50: 在 IoU 阈值为 0.5 时的平均精度。

mAP50-95: 在 IoU 阈值从 0.5 到 0.95 之间逐步变化时的平均精度, 更全面的精度评估。

F1-Score: 是精确率和召回率的调和平均值, 用于综合评估模型性能。公式如下:

$$P = \frac{TP}{TP + FP} \quad (20)$$

$$R = \frac{TP}{TP + FN} \quad (21)$$

$$mAP50 = \frac{1}{N} \sum_{i=1}^N AP_i \quad (22)$$

$$mAP50_{-95} = \frac{1}{N} \sum_{i=1}^N \frac{1}{10} \sum_{t=50}^{95} AP_t(i) \quad (23)$$

$$F1_Score = 2 \times \frac{precision \times recall}{precision + recall} \quad (24)$$

其中, TP 为正确预测为正例的样本, FP 为错误预测为正例的样本, FN 为错误预测为负例的样本。 AP_i 是第 i 个类别的平均精度, IoU 阈值设定为 0.5。 $AP_t(i)$ 表示在特定 IoU 阈值下, 第 i 个类别的平均精度。

2.4 训练结果分析

在 MNBS-YOLOV12 的训练过程中, 记录了测试集与验证集的边界损失、分类损失、分布损失值以及模型的精确率、召回率、mAP50 和 mAP50-95。训练过程中, 迭代次数与损失值、精确率、召回率和平均精度均值的变化曲线如图 7 和图 8 所示。可知 MNBS-YOLOV12 训练集与验证集的边界损失和分类损失在迭代次数 20 轮以后逐步稳定, 较 YOLOV12 更快收敛, 表明本文所提模型在训练过程中已实现较好的收敛效果。经 150 轮训练, MNBS-YOLOV12 的训练效果在精确率、召回率、mAP50、mAP50-95 方

面均优于 YOLOV12。最终模型达到了 95.75% 的精确率, 97.77% 的召回率, 98.35% 的 mAP50 以及 93.65% 的 mAP50-95。对比基线模型精确率 93.03%, 召回率

95.71%, mAP50 为 95.81%, mAP50-95 为 89.48%, 均有效提升。




图 7 MNBS-YOLOV12 损失值变化曲线

Fig.7 MNBS-YOLOv2 Loss Curves




图 8 MNBS-YOLOV12 训练效果分析

Fig.8 MNBS-YOLOV12 Training Performance Analysis

2.5 消融实验

为量化评估各改进模块的性能贡献,本研究以 YOLOv12 作为基线模型,在相同的训练环境和超参数配置下系统通过控制变量法依次引入 CSWin-SA、EMA、DAFM 以及 B_CIoU 损失函数,进行了 9 组消融实验,观测其对检测精度(Precision)、召回率(Recall)和平均精度(mAP50, mAP50-95)等关键指标的影响变化,具体实验结果见表 3 所示。由表 3 可知,基线模型 YOLOv12 的精确率、召回率和 mAP50 分别为 93.03%、95.71%和 95.81%。单独引入各个模块的精确率、召回率和 mAP50 均有提升相应的百分点。单独引入 CSWin-SA 模块后,模型精确率提升 1.99 个百分点,表明十字形注意力机制有效增强了空间特征感知能力,尤其对精确率改善最为显著。单独使用 EMA, mAP50 提升 1.75 个百分点,该模块在保持通道完整性的同时,表明通过多尺度并行分支实现了对特征表达的显著增强。单独引入 EMA 后,其精确率提升了 1.55 个百分点,召回率提升了 1.35 个百分点,表明在肾脏复杂背景中该注意力之际可准确聚焦目标病变区域,从而提

升检测精度与误检。单独引入 DAFM,精确率提升 1.83 个百分点,召回率提升 1.31 个百分点, mAP50 提升 2 个百分点,表明其双注意力机制在特征融合方面的优势得到充分验证。单独引入 B_CIoU 损失函数,精确率提升 1.73 个百分点,召回率提升 0.73 个百分点, mAP50 提升 2.22 个百分点,表明改进损失函数对提高标准 IoU 阈值下的检测准确率效果更好。当引入多种注意力机制时(CSWin-SA、EMA、DAFM),各项指标均有效提升,表明其抑制背景干扰能力有所提升,可更为精准聚焦肿瘤病变区域。

当 CSWin-SA、EMA、DAFM 模块以及 B_CIoU 损失函数共同集成于基线模型时,模型在保持轻量化(权重 10.9MB)和参数量增加不多的同时实现了最优性能。其精确率达到 95.75%,较基线(93.03%)提升 2.72 个百分点,召回率达到 97.77%,较基线(95.71%)提升 2.06 个百分点, mAP50 达到 98.35%,较基线(95.81%)提升 2.54 个百分点,验证了多模块协同设计的有效性。

表 3 MNBS-YOLOV12 消融实验

Table 3 MNBS-YOLOV12 Ablation Study

CSWin-SA	EMA	DAFM	B_CIoU	Precision (%)	Recall (%)	mAP ₅₀ (%)	mAP ₅₀₋₉₅ (%)	Weight (MB)	FLOPs (G)
				93.03	95.71	95.81	89.48	11.5	6.5
✓				95.02	97.05	97.37	91.06	10.3	6.9
	✓			94.58	97.06	97.56	91.31	11.1	6.1
		✓		94.86	97.02	97.81	91.23	10.6	6.7
			✓	94.76	96.44	98.03	89.55	11.3	6.5
✓	✓			95.25	97.08	97.50	91.63	11.2	7.2
	✓	✓		95.65	97.01	97.70	91.17	10.8	7.1
✓		✓		95.13	97.71	98.03	92.59	10.5	6.8
✓	✓	✓		95.23	97.56	98.15	93.46	10.3	8.3
✓	✓	✓	✓	95.75	97.77	98.35	93.65	10.9	8.3

2.6 对比试验

2.6.1 与主流模型对比

为进一步评估 MNBS-YOLOV12 的综合性能表现, 本文模型与几种主流模型进行了效果对比, 实验数据集和参数设置一致, 结果和分析见表 4 和图 9。由表 4 可知, SSD^[17]作为经典的单阶段目标检测算法, 推理速度较慢, 参数量较高, 其召回率相对 Faster CNN 较高, 说明该算法能够检测到绝大部分的病变区域, 漏检率较低, 但高召回率以牺牲精确率为代价, 说明误检较多。Faster CNN 作为经典的两阶段检测器, 其定位精度优于 SSD, 说明其回归边界框的稳定性较好, 但准确率较低以及其推理速度较慢。相比之下, YOLO 系列模型其精度和召回率均优于前者, YOLOv5n^[18]以及 YOLOv6n^[19]相对于 SSD 和 Faster R-CNN, 在精确率、召回率和 mAP 上取得了较好的平衡。YOLOv8n^[20]在 YOLOv6n 的基础上, 精确率提升较大, 成为了精确率与召回率平衡得非常好的一个模型, 综合性能强。YOLOv9-10^[21-22]相比 YOLOv8n 召回率略


有下降, 说明其性能低于 YOLOv8。YOLO11n^[23]继承了 YOLOv8n 高召回率的特性, 具有最快的推理速度, 但其 mAP₅₀₋₉₅ 比本文模型低 3.87 个百分点。MNBS-YOLOV12 模型在所有四项评估指标上均优于其他模型, 其mAP₅₀₋₉₅分别超出 YOLOv5n、YOLOv6n、YOLOv8n 和 YOLOv9n 约 8.55、7.42、6.08 和 5.72 个百分点。高精确率和召回率意味着该模型在复杂多变的医学影像中, 既能最大限度地避免误诊, 又能极其有效地防止漏诊, 证明本文所提模型在肾脏肿瘤病变区域检测任务上的综合优越性。并且在参数量上相较于 YOLOv12s 减少了 40.1%, 相较 YOLOv8s 减少了 50%。推理延迟速度上, 本文所提模型略慢于 YOLOv12n, 但均快于 YOLOv12s 和 YOLOv12m, 分别提升 8%和 50%, 体现了 MNBS-YOLOV12 在精度与效率之间的美好平衡优势。在维持高精度检测性能的同时, 有效控制模型参数量与计算开销, 达成了轻量化设计目标。

表 4 与主流模型对比试验


Table 4 Comparative Testing with Mainstream Models

Model	Precision(%)	Recall(%)	mAP ₅₀ (%)	mAP ₅₀₋₉₅ (%)	F1-Score	Param(M)	Latency(ms)
SSD	87.29	92.76	93.28	82.94	89.94	26.30	16.70
Faster R-CNN	86.99	90.70	93.37	84.07	88.80	41.40	50.10
YOLOv5n	90.07	92.57	94.74	85.10	91.30	1.76	2.90
YOLOv6n	90.47	91.69	95.17	86.23	91.07	4.70	2.69
YOLOv8n	93.29	93.50	96.33	87.57	93.39	3.20	1.77
YOLOv8s	93.36	94.71	97.41	89.94	94.03	11.20	2.33
YOLOv8m	93.34	95.40	97.30	88.52	94.35	25.90	5.09
YOLOv9n	93.36	92.64	96.14	87.93	92.99	2.30	2.56
YOLOv9s	93.27	92.89	96.35	88.34	93.07	7.10	3.30
YOLOv9m	93.58	92.75	96.38	88.67	93.16	20.00	5.90


Model	Precision(%)	Recall(%)	mAP ₅₀ (%)	mAP ₅₀₋₉₅ (%)	F1-Score	Param(M)	Latency(ms)
YOLOv10n	93.01	92.82	96.59	88.40	92.91	2.30	1.84
YOLOv10s	92.89	92.73	95.97	87.34	92.80	7.20	2.49
YOLOv10m	93.42	93.26	96.59	88.73	93.33	15.40	4.74
YOLO11n	92.43	94.19	96.50	89.78	93.30	2.60	1.50
YOLO11s	92.36	94.73	96.78	89.74	93.52	9.40	2.50
YOLO11m	92.68	94.80	96.80	89.85	93.72	20.10	4.70
YOLOv12n	93.03	95.71	95.81	89.48	94.35	2.81	1.64
YOLOv12s	93.25	95.82	96.45	90.30	94.51	9.30	2.81
YOLOv12m	93.60	95.88	96.57	90.58	94.72	20.20	4.91
MNBS-YOLOV12	95.75	97.77	98.35	93.65	96.74	5.57	2.40




(a)不同模型精确率对比



(b)不同模型召回率对比



(c)不同模型 mAP50 对比



(d)不同模型 mAP50-95 对比

图9 与主流模型对比分析

Fig.9 Comparison with Mainstream Models

2.6.2 损失函数对比

在相同的训练环境和超参数配置下系统开展了不同损失函数的对比实验, 由表 5 可知, GIoU^[24]在精确

率上略有优势, DIoU^[25]在召回率上表现突出, 本文所采用的 B_CLoU 损失函数, 在精确率、召回率和 mAP50 上实现了最佳平衡, 达到了 95.75%, 97.77%, 98.35%, 其性能显著优于其他对比方法。充分说明,

本文通过引入多角度边界框回归约束设计的 B_CIoU 损失函数, 能够更全面、更平衡地优化检测模型的识别与定位能力, 有效提升了模型在复杂医学影像中对肾脏肿瘤病变的检测稳定性与整体精度。

表 5 不同损失函数对比

Table 5 Comparison of Different Loss Functions

Loss function	Precision(%)	Recall(%)	mAP ₅₀ (%)	F1-Score
CIoU	93.03	95.71	95.81	94.35
GIoU	93.28	95.40	97.30	94.32
DIoU	93.10	96.17	97.69	94.61
WIoU	93.15	95.87	95.68	94.49
B_CIoU	95.75	97.77	98.35	96.74

2.6.3 注意力机制对比

在相同的训练环境和超参数配置下系统开展了不同注意力机制的对比实验, 分别加入不同注意力机制, 包括 CBAM^[26]、双路径坐标注意力机制 (Dual Coordinate Attention Feature Extraction, DCAFE)^[27]、通道与空间注意力机制 (Channel and Spatial Attention Block, CASA)^[28]、层次化双路径注意力机制 (HierarchicalDual-PathAttention, HDPA)。由表 6 可知, 在 YOLOV12 基线上, 加入不同注意力机制后,

多数模型在 mAP50、精确率、召回率上均有提升, DAFM 在召回率 (97.06%) 和 mAP50 (97.81%) 上表现最优, CSWin-SA 则在精确率 (95.02%) 和模型轻量化 (10.3MB) 上领先, 说明二者有效提升目标检测能力和整体检测性能。增强了对不规则形态肾脏肿瘤病变区域的特征捕捉与感受野交互能力, 可有效提升对肾脏 CT 在复杂场景下模糊、遮挡、不同尺寸目标的识别能力。

表 6 不同注意力机制对比

Table 6 Comparison of Different Attention Mechanisms

Network	Precision(%)	Recall(%)	mAP ₅₀ (%)	Weight (MB)	F1-Score
YOLOV12	93.03	95.71	95.81	11.5	94.35
YOLOV12+CBAM	93.79	96.95	97.97	10.7	95.34
YOLOV12+DCAFE	94.93	93.59	97.19	11.7	94.25
YOLOV12+CASAB	93.75	94.87	97.54	11.4	94.30
YOLOV12+HDPA	94.01	95.88	97.77	10.8	94.93
YOLOV12+DAFM	94.86	97.06	97.81	10.6	95.94
YOLOV12+CSWin-SA	95.02	97.05	97.37	10.3	96.02
YOLOV12+EMA	94.58	97.06	97.56	11.1	95.80

2.6.4 DAFM 对不同尺寸病变检测性能对比

为分析 DAFM 对不同尺寸病变检测性能的影响。本文将数据验证集划分为不同尺寸的病变样本, 根据病变区域像素面积将样本分为小 ($<32^2$)、中 ($32^2 - 96^2$)、大 ($\geq 96^2$) 三类, 验证集共 783 张图像, 其中标注病变区域 1050 个, 小尺寸、中尺寸、大尺寸病变数量分别为 567 个, 252 个, 231 个, 占比分别为 54%, 24%, 22%。分别统计其在 IoU 阈值为 0.5 时的

平均精度, mAP50_s, mAP50_m, mAP50_l 分别表示小、中、大尺寸病变的 mAP50。由表 7 可知, DAFM 对小尺寸病变的检测精度提升最大 (+4.1%), 对大尺寸的提升较中尺寸病变的提升略小, 说明 DAFM 在融合过程中小尺寸病变的细节信息被有效保留, 同时有效抑制背景干扰, 在检测精度上的提升也较为明显, 证明所提模块的创新对肿瘤病变区域检测的有效性。

表 7 DAFM 对不同尺寸病变检测性能影响

Table 7 The impact of DAFM on lesion detection performance of different sizes

Model	mAP50_s(%)	mAP50_m(%)	mAP50_l(%)	FLOPs (G)
YOLOV12	93.56	95.37	95.81	6.5
YOLOV12+DAFM	97.66	97.47	97.56	6.7
提升百分比	+4.1	+2.1	+1.75	+0.2

2.6.5 不同多尺度融合方法性能对比

为分析 DAFM 的有效性, 在相同的训练环境和超参数配置下, 在 KiTS 数据集上将其与现有医学影像多尺度融合方法进行对比。分别与特征金字塔融合 (Feature Pyramid Network, FPN)、调制融合模块 (Modulation Fusion Module, MFM)、动态特征融合模块 (Dynamic Feature Fusion, DFF) 进行对比试验,

均替换 YOLOV12 的 Neck 部分进行比较。由表 8 可知, DAFM 在精确率、召回率以及 mAP50 指标上优于其他三种方法, 其 mAP50 较基线模型提升了 2 个百分点, 并且在不显著增加模型复杂度的前提下 (DAFM 的参数量为 2.96M, 较基线仅增加 0.15M, 计算量为 6.7G, 与基线 6.5G 基本持平), 验证了其在医学影像多尺度融合任务中的先进性与有效性。

表 8 不同多尺度融合方法性能对比


Table 8 Performance Comparison of Different Multi-Scale Fusion Methods

Model	Precision(%)	Recall(%)	mAP ₅₀ (%)	FLOPs (G)	Param(M)
YOLOV12	93.03	95.71	95.81	6.5	2.81
YOLOV12+FPN	94.30	94.07	97.41	8.7	3.12
YOLOV12+MFM	93.51	95.00	96.56	8.1	3.01
YOLOV12+DFF	94.23	96.01	97.29	6.9	3.06
YOLOV12+DAFM	94.86	97.02	97.81	6.7	2.96

2.7 可视化结果及分析

根据 MNBS-YOLOV12 模型的实验结果, 进行肾脏肿瘤病变区域可视化效果分析, 绿色框代表肿瘤病变区, 蓝色框代表正常肾脏, 如图 10 所示。对比了原始 CT 图像 (Original)、标注真值 (Ground Truth) 与五个不同目标检测模型在肾脏肿瘤病变区域检测任务上的检测结果。由图可知, YOLOV5、YOLOV8、YOLO11n、YOLOV12 能完整框出肿瘤区域, 但其准确率低于 MNBS-YOLOV12 模型, 对于 MNBS-YOLOV12 模型, 不仅准确标定了肾脏肿瘤病变区域的位置, 预测框与真实肿瘤边界的贴合程度较

高, 而且提高了置信度分数, 表明改进模型在肾脏肿瘤病变区域检测上的性能得到了显著提升。并且在正常肾脏组织与肿瘤病变的二分类任务中, MNBS-YOLOV12 在两类目标上均表现出优异的识别稳定性与分类准确性, 提升了整体检测任务的精确率与召回率。综合可视化效果与定量指标可知, 本文提出的改进策略有效增强了模型对肾脏肿瘤的敏感性与定位精度, 为后续临床辅助诊断应用提供了可靠的技术基础。






图 10 正常肾脏与肿瘤可视化检测结果

Fig.10 Visual Detection Results of Normal Kidneys and Tumors

2.8 复杂背景下检测性能可视化分析

在肾脏 CT 影像中, 复杂背景主要来源于肾实质的复杂纹理、血管断面 (增强扫描中的高信号)、肾窦脂肪与集合系统的混杂信号, 以及部分容积效应导致的边界模糊。这些背景结构与肿瘤在影像上可能存在相似的灰度分布或纹理特征。而 YOLOV12 并不能解决医学影像中该复杂背景对病变区域检测的干扰问题。因此, 本文通过引入多种注意力机制, 包括 EMA, DAFM, 以及 CSWin-SA 解决医学影像中复杂背景对病变区域检测的问题。

首先, 由于肿瘤与正常组织纹理相似, EMA 在底层特征提取阶段引入特征分组与跨空间学习机制, 使模型区分出肿瘤与背景的专属特征表征, 从纹理层面初步抑制干扰; 其次, DAFM 在特征融合阶段引入双聚合注意力, 通过自我增强强化肿瘤细节, 并使用 softmax 机制聚焦深浅层特征的差异点, 利用深层语义引导模型过滤背景噪声; 最后, A2C2f 模块通过十字形窗口自注意力施加全局解剖约束, 排除局部背景干扰, 并对模糊边界进行上下文推理与重建。三个注意力机制共同协作, 实现了从纹理区分、特征筛选到空间约束的全面背景抑制。

为直观展示引入多种注意力机制以抑制模糊边界

与复杂背景干扰的效果, 本文采用 Grad-CAM 生成反映模型关注区域的热力图, 选取模型中的 5 个关键特征层作为目标检测层, 计算肿瘤类别对目标层特征图的梯度, 经全局平均池化获得各通道权重, 加权求和后上采样至原图尺寸。热力图与原始 CT 图像叠加后, 红色高亮区域表示模型重点关注的位置, 蓝色区域表示模型忽略的位置, 并在相关热力图标注其置信度分数。选取典型病例, 分别用 Baseline、+EMA、+EMA+DAFM、+EMA+DAFM+CSWin-SA 生成热力图。不同模型在复杂背景区域的热力图对比如图 11 所示。可知 YOLOV12 模型热力图中, 肾实质背景区域以及周围存在大量高激活值, 表明误将背景识别为病变。+EMA 模型的热力图, 背景区域的激活值显著降低, 置信度分数提高, 说明 EMA 模块通过纹理辨析有效抑制了背景干扰。+EMA+DAFM 模型的热力图, 模型更精准地聚焦于肿瘤区域, 背景噪声进一步减少。+EMA+DAFM+CSWin-SA 的热力图, 模型不仅精准聚焦肿瘤, 且在边界模糊处仍保持完整激活, 证明 A2C2f 的边界补全机制有效。

2.9 EMA 不同通道组特征解耦可视化

为直观验证通道分组策略的语义解耦效果, 本文补充特征图可视化与通道响应热力图分析: 选取典型

肾脏肿瘤样本，对 EMA 不同通道组输出特征进行可视化分析。通道组 1 特征响应热力图的高亮区域专注于肿瘤内部异质纹理与灰度不均区域，可捕捉肿瘤与正常肾实质的细微灰度差异；通道组 2 特征响应热力图的高亮区域聚焦肿瘤模糊边界、浸润轮廓与不规则形态；其余通道组 3 特征响应热力图的高亮区域主要

激活正常肾皮质、肾柱等背景结构，并抑制肿瘤区域，实现检测目标与背景的有效区分。

如图 12 所示，可见不同通道组在训练后分化出差异化的语义模式，分别专注于肿瘤内部纹理、肿瘤边界、正常背景组织等不同特征，从而避免了将多种异质信息压缩到单一注意力权重中导致的语义混淆。




图 11 不同注意力机制热力图可视化对比

Fig.11 Visualization comparison of heatmaps for different attention mechanisms




图 12 EMA 不同通道组特征解耦可视化

Fig.12 Visualization of Feature Decoupling for Different EMA Channel Groups

3 结束语

本文从特征表征、多尺度信息融合、注意力机制

设计以及损失函数优化四个维度进行了系统性改进，在保证实时推理效率的同时显著提升了模型的检测性

能与临床应用潜力。具体所做工作如下:

(1) 提出融合 CSWin-SA 的 A2C2f 增强模块。通过引入 CSWin-SA, 设计水平与垂直条纹的窗口划分策略, 在有限计算复杂度下实现了长距离特征依赖的有效建模。该模块显著提升了网络对形态不规则、边界模糊的肾脏肿瘤病变区域的特征表征能力, 增强了模型在复杂解剖背景下的检测鲁棒性。

(2) 构建基于 EMA 的特征提取机制。将 EMA 与 YOLOv12 的 C3k2 结构相结合, 通过分组特征重组与跨尺度并行学习, 实现了多层级语义信息的有效融合。该方法在保持特征完整性的同时降低了计算负担, 并能自适应捕捉从微小钙化灶到弥漫性病变的差异化视觉模式, 提升了模型对病变异质性的感知能力。

(3) 引入 DAfM 以替代传统的拼接操作。该模块通过自注意力强化关键特征表达, 结合交叉注意力促进多尺度特征间的语义互补, 有效抑制了特征融合过程中的信息稀释现象。实验表明, 该设计显著增强

了模型对模糊、小尺寸及部分遮挡肿瘤的认识与定位能力, 在复杂影像背景中实现了更高的检测精度与更低的假阳性率。

(4) 采用边界优化损失函数 B_CIoU 。在 $CIoU$ 的基础上, 通过系统引入重叠区域度量、宽高一致性约束及归一化中心距离三个惩罚项, 构建了更精细的边界框回归优化目标。该损失函数不仅提高了检测框的定位精度, 还加速了模型训练收敛过程。

尽管当前模型性能优越, 但其计算复杂度在临床实时部署中仍需关注, 未来可引入多模态数据(如增强 CT、DWI、PET)及时间序列影像(如动态增强 MRI), 通过跨模态注意力机制或 3D+时序网络, 融合结构与功能信息, 提升对肿瘤良恶性鉴别、分级及疗效评估的辅助决策能力。探索小样本学习、半监督/自监督预训练, 或利用弱监督标注(如仅提供病变存在性标签)进行模型训练, 减少对精细标注的依赖, 提高模型在数据稀缺场景下的泛化性能。

参考文献

- [1] CHEN A, LIN D, GAO Q Q. Enhancing brain tumor detection in MRI images using YOLO-NeuroBoost model[J]. Frontiers in Neurology, 2024, 15(1): 1445882.
- [2] ALAMRI A, ABDEL-KHAKEK S, BAHADDAD A A, et al. Innovative Deep Learning and Quantum Entropy Techniques for Brain Tumor MRI Image Edge Detection and Classification Model[J]. Alexandria Engineering Journal, 2025, 122(5): 588-604.
- [3] LI M, KUANG L, XU S, et al. Brain tumordetection based on multimodal information fusionand convolutional neural network[J]. IEEEaccess, 2019, 7(12): 180134-180146.
- [4] SARGUNAN I, KRISHNAMOORTHY S K, GOVINDHARAJU K, et al. TopK-KiU-Net and squeeze residual fraction network for kidney tumor segmentation and detection[J]. Biomedical Signal Processing and Control, 2026, 113: 109116.
- [5] SUDHARSON S, KOKIL P. Automated diagnosis tool for clinical ultrasound image analysis in kidney disease identification[J]. Biomedical Signal Processing and Control, 2026, 111: 108345.
- [6] SUN J, XUE J, XU Z, et al. SAGCN: Self-adaptive Graph Convolutional Network for pneumonia detection[J]. Biomedical Signal Processing and Control, 2025, 106: 107634.
- [7] RUI Z, QIAO L, SHUAI S, et al. Weakly Human-Supervised Deep Learning for Real-Time Detection of High-Grade Aggressive Clear CellRenal Cell Carcinoma on Contrast-Enhanced CT.[J], Medical Physics, 2026, 53(2): e70348.
- [8] HISHAM A, AHMED A, MOHAMED G, et al. A Deep Learning Ensemble Framework for Multi-Subtype Renal Tumor ClassificationUsing Contrast-Enhanced CT[J]. Scientific Reports, 2026, 16(1): 1-10.
- [9] TIAN Y J, YE Q X, DOERMANN D. YOLOv12: Attention-Centric Real-Time Object Detectors.[J]. Computing Research Repository, 2025.
- [10] LIN C W, LIN Y, CHEN Z S. Multi-modal and Unified-Scale Multi-Window Fusion Attention Mechanisms for Brain Tumor Segmentation[J]. Multimedia Systems, 2026, 32(3): 1-12.
- [11] 孙帮勇,赵兴运,吴思远,等.基于移位窗口多头自注意力 U 型网络的低照度图像增强方法[J].电子与信息学报, 2022, 44(10):

- 3399-3408.
- SUN B Y, ZHAO X Y, WU S Y, et al. Low-light Image Enhancement Method Based on Shifted Window Multi-head Self-attention U-shaped Network. *Journal of Electronics & Information Technology*, 2022, 44(10): 3399-3408.
- [12] 李潇鹏,赵明航,钟诗胜,等.基于全局自注意力机制和局部多尺度特征通道融合的锂电池健康状态预测[J].*电气工程学报*,2025,20(05):91-99.
- LI X P, ZHAO M H, ZHONG S S, et al. State-of-health Estimation for Lithium-ion Batteries Based on Global Self-attention Mechanism and Local Multi-scale Feature Channel Fusion [J].*JOURNOF ELECTRICAL ENGINEERING*, 2025, 20(05): 91-99.
- [13] 史浩进,邱吉尔,陶洪峰,等.自注意力机制下多尺度特征融合的轴承故障诊断[J].*控制工程*,2025,32(09):1603-1610.
- SHI H J, QIU J L, TAO H F, et al. Bearing Fault Diagnosis with Multi-scale Feature Fusion Under Self-attention Mechanism[J]. *Control Engineering of China*, 2025, 32(09): 1603-1610.
- [14] ZHENG Z H, WANG P, LEI W, et al. Distance-IoU Loss: Faster and Better Learning for Bounding Box Regression[C]// *Proceedings of the AAAI Conference on Artificial Intelligence(AAAI-20)*. New York, USA: AAAI Press, 2020: 12993-13000.
- [15] ZHENG Z H, WANG P, REN D W, et al. Enhancing Geometric Factors in Model Learning and Inference for Object Detection and Instance Segmentation[J], *IEEE Transactions on Cybernetics*, 2022, 52(8): 8574-8586.
- [16] 刘雄彪,杨贤昭,陈洋,等.基于 CIoU 改进边界框损失函数的目标检测方法[J].*液晶与显示*,2023,38(05):656-665.
- LIU X B, YANG X Z, CHEN Y, et al. Object detection method based on CIoU improved bounding box loss function[J]. *Chinese Journal of Liquid Crystals and Displays*, 2023, 38(05): 656-665.
- [17] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single shot MultiBox detector[C]//*Proceedings of the 14th European Conference on Computer Vision(ECCV 2016)*. Amsterdam, Netherlands: Springer, 2016: 21-37.
- [18] VIDHYA N P, PRIYA R. Automated diagnosis of the severity of TMB infestation in cashew plants using YOLOv5[J]. *Journal of Image and Graphics*, 2024, 12(3): 276-282.
- [19] Li C Y, Li L L, Jiang H L, et al. YOLOv6: A Single-Stage Object Detection Framework for Industrial Applications[J], *Computing Research Repository*, 2022.
- [20] VARGHESE R, SAMBATH M. YOLOv8: A novel object detection algorithm with enhanced performance and robustness[C]// *Proceedings of the 2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS)*. Piscataway, NJ, USA: IEEE, 2024: 1-6.
- [21] WANG C Y, YE H I, LIAO H Y M. YOLOv9: Learning what you want to learn using programmable gradient information[C]// *Proceedings of the European Conference on Computer Vision(ECCV 2024)*. Cham, Switzerland: Springer Nature Switzerland, 2024: 1-21.
- [22] LIU R. Enhanced Motorbike Helmet Detection Using YOLOv10 with Attention-Based Modifications[C]//*Proceedings of the 2024 4th International Conference on Computer Science and Blockchain (CCSB)*. Piscataway, NJ, USA: IEEE, 2024: 114-118.
- [23] Khanam R, Hussain M. YOLOv11: an Overview of the Key Architectural Enhancements[J].*Computing Research Repository*, 2024.
- [24] 侯志强,刘晓义,余旺盛,等.使用 GIoU 改进非极大值抑制的目标检测算法[J].*电子学报*,2021,49(04):696-705.
- HOU Z Q, LIU X Y, YU W S, et al. Object Detection Algorithm for Improving Non-Maximum Suppression Using GIoU[J].*ACTA ELECTRONICA SINICA*, 2021, 49(04): 696-705.
- [25] 孙子文,袁广林,李从利,等.基于 DIoU 损失与平滑约束的结构化 SVM 目标跟踪方法[J].*计算机科学*,2024,51(S1):401-408.
- SUN Z W, YUAN G L, LI C L, et al. Object Tracking of Structured SVM Based on DIoU Loss and Smoothness Constraints[J].*Computer Science*, 2024, 51(S1): 401-408.
- [26] 朱强军,刘趁心,汪慧兰,等.融合 CBAM 和 DCNv3 的 YOLOv7 模型果蔬检测分类研究[J].*中国农机化学报*,2026,47(02): 292-298+305.

- ZHU Q J, LIU C X, WANG H L, et al. Research on fruit and vegetable detection and classification based on the YOLOv7 model combined with CBAM and DCNv3 [J]. *Journal of Chinese Agricultural Mechanization*, 2026, 47(02): 292-298+305.
- [27] GUPTA S, TRIPATHI A K. Flora-NET: Integrating dual coordinate attention with adaptive kernel based convolution network for medicinal flower identification[J]. *Computers and Electronics in Agriculture*, 2025, 230: 109834.
- [28] WAZIR S, KIM D. Rethinking decoder design: Improving biomarker segmentation using depth-to-space restoration and residual linear attention[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2025)*. New Orleans, LA, USA: IEEE/CVF, 2025: 30861-3087.
- 