

改进YOLOv12的水面垃圾检测方法

朱宇凡¹, 杨吉凯², 李威²⁺

1. 华中科技大学 电气与电子工程学院, 武汉 430074

2. 华中科技大学 船舶与海洋工程学院, 武汉 430074

+ 通信作者 E-mail: hustliw@hust.edu.cn

摘要:针对现有水面垃圾检测方法模型较老、易漏检错检、无法满足高效的水面环境治理的问题,提出了改进YOLOv12的水面垃圾检测方法WDW-YOLO。该方法引入基于小波变换的WTConv改进颈部网络的C3k2模块,设计C3k2_WTConv模块,在保证模型参数可控性的同时实现了模型感受野的有效扩大;对于骨干网络中的C3k2模块,引入DynamicConv进行创新得到C3k2_DynamicConv模块,增加更多可学习参数的同时限制计算量的增长,增强模型对特征信息的捕捉能力,进而提高检测精度;将CIoU替换为WiseIoUv3并探究最佳的超参数组合,平衡检测难度不同的样本,增强模型的小目标检测能力。在FloW_IMG数据集上进行对比实验和消融实验,实验结果表明,提出的WDW-YOLO模型较基线YOLOv12n模型mAP50和mAP50-95分别提高2.7和1.8个百分点,达到90.7%和50.6%,在降低模型复杂度的同时实现了更高的检测准确率,在自动化的水面清理和水体保护中具有高可靠性与高实用性。

关键词:水面垃圾检测;YOLOv12;WTConv;DynamicConv;WiseIoUv3

文献标志码:A **中图分类号:**TP391.4 **doi:**10.3778/j.issn.1002-8331.2505-0249

Improving Water Debris Detection Method of YOLOv12

ZHU Yufan¹, YANG Jikai², LI Wei²⁺

1.School of Electrical & Electronic Engineering, Huazhong University of Science and Technology, Wuhan 430074, China

2.School of Naval Architecture & Ocean Engineering, Huazhong University of Science and Technology, Wuhan 430074, China

Abstract: To address the issue of outdated models, high rates of missed and false detections, and the inability of existing water surface debris detection methods to meet the requirements of efficient water surface environmental management, this paper proposes an improved water debris detection method, WDW-YOLO, based on YOLOv12. This method introduces WTConv based on wavelet transform to improve the C3k2 module in the neck network, designing the C3k2_WTConv module. This design effectively expands the model's receptive field while maintaining controllable model parameters. For the C3k2 module in the backbone network, it introduces DynamicConv to innovate and obtain the C3k2_DynamicConv module. This approach increases the number of learnable parameters while limiting the growth of computational load, thereby enhancing the model's ability to capture feature information and improving detection accuracy. Additionally, it replaces CIoU with WiseIoUv3 and explore the optimal combination of hyperparameters to balance samples with different detection difficulties and enhance the model's ability to detect small objects. Experiments are conducted on the FloW_IMG dataset, including comparative and ablation studies. The results show that the proposed WDW-YOLO model achieves a 2.7 and 1.8 percentage points increase in mAP50 and mAP50-95, respectively, compared to the baseline YOLOv12n model, reaching 90.7% and 50.6%. This improvement is achieved while reducing model complexity and enhancing detection accuracy. The WDW-YOLO model demonstrates high reliability and practicality for automated water surface cleaning and water body protection.

Key words: water debris detection; YOLOv12; WTConv; DynamicConv; WiseIoUv3

随着全球工业化和城市化的加速发展,水体污染问题日益严重,其中水面垃圾污染成为制约水生态环境可

持续发展的重要因素之一。水面垃圾不仅破坏水体的自然景观,还对水生生物的生存环境造成威胁,甚至可

基金项目:国家自然科学基金(52171336)。

作者简介:朱宇凡(2003—),男,研究方向为深度学习、机器视觉;杨吉凯(2000—),男,硕士,研究方向为目标识别、深度学习;李威(1975—),男,博士,教授,研究方向为水下声学、振动与噪声。

收稿日期:2025-05-21 **修回日期:**2025-07-08 **文章编号:**1002-8331(2026)01-0101-11

能通过食物链传递对人类健康产生潜在危害。因此,及时、高效地检测和清理水面垃圾,对于保护水生态环境、维护生态平衡具有重要意义^[1]。

传统的水上垃圾清理工作主要依赖人工打捞,这种方法效率低下、难以清理所有水面垃圾,且存在诸多安全隐患,亟待更加高效和安全的自动化清理方式,而识别准确率高且易于部署的水面垃圾检测方法是实现这一目标的核心所在^[2]。

近年来,计算机视觉技术在目标检测领域取得了显著进展,尤其是基于深度学习的目标检测算法^[3],为水面垃圾检测方法提供了新的思路。当前基于深度学习的目标检测算法主要包括一阶段算法和二阶段算法。典型的二阶段算法有 R-CNN^[4]、Fast R-CNN^[5]和 Faster R-CNN^[6]等,由于依赖预先生成的候选区域进行分类和定位,二阶段算法需要更多的计算资源且检测速度较慢,不适合部署在计算资源有限和检测实时性要求高的水面垃圾检测场景中。典型的一阶段算法有 YOLO 系列^[7-9]和 SSD^[10],一阶段算法直接在图像上预测类别和边界框,具有更快的检测速度和较高的检测准确率,更适合部署在水面垃圾检测场景中。

针对水面垃圾和泛目标检测问题,Wang 等^[11]提出了一种改进 YOLOv8n 的水面目标检测方法,增加 4 倍下采样的小目标检测头,引入混合局部通道注意力(mixed local channel attention, MLCA)和 SENetV2 分别改进骨干网络和颈部网络的 C2f 模块,并采用 SiOU 替换 CiOU,实现了较好的检测效果,但小目标检测头可能会引入更多噪声,且改进后的模型计算量增加过多,限制了算法的部署。袁和平等^[12]提出了一种改进 YOLOv5s 的漂浮垃圾追踪算法,通过平衡因子调节归一化距离度量和 CiOU 对损失函数的贡献,并在数据关联模型中引入可调节超参数,提高了模型的追踪准确率,但引入过多参数的手动调节使得模型的泛化能力大幅下降,无法满足水面垃圾检测的场景需求。Li 等^[13]提出了一种改进 YOLOv8n 的轻量级水面目标检测算法,通过优化梯度路径和 ELAN(efficient layer aggregated network)结构设计了 C2f-E 模块,并引入双向特征金字塔(bidirectional feature pyramid network, BiFPN)和 WIoU 损失函数,获得了较好的检测效果。但是,上述研究的基线模型相对陈旧,检测精度与实时性均弱于最新的 YOLOv12 模型,不适用于水面垃圾检测场景。

针对 YOLOv12 改进,目前暂无相关研究。本文综合考虑 YOLOv12 模型特点以及水面垃圾检测场景所面对的问题,选取 YOLOv12n 作为基线模型进行改进优化,提出了精度更高、更易于部署的 WDW-YOLO 模型,具体贡献如下:

(1)提出 WDW-YOLO 小目标检测模型,在 YOLOv12 框架基础上引入三项改进,提高了水面场景下的小目标

检测精度。

(2)提出 C3k2_WTConv 和 C3k2_Dyanmicconv 模块。C3k2_WTConv 通过 WTConv^[14]小波变换扩大感受野,提升检测精度。C3k2_Dyanmicconv 模块通过 Dyanmicconv^[15]动态生成卷积核权重获取更多网络参数,增强模型特征提取能力。

(3)采用基于动态非单调聚焦机制的 WiseIoUv3^[16]作为边界框损失函数,在 Flow_IMG 数据集进行实验,提出更精细的场景适用超参数,并验证了本文改进模型的有效性和先进性。

1 YOLOv12 模型

YOLOv12 是由 Tian 等^[17]提出的最新一代 YOLO 系列算法,延续了单阶段检测的核心架构,能够在单次前向传播中直接预测图像中所有目标的类别和边界框。模型架构可分为 Backbone、Neck 和 Head 三部分。Backbone 由一系列卷积层和池化层构成,通过卷积和下采样等操作生成具有丰富信息的特征图,为后续的特征提取提供基础。Neck 用于连接 Backbone 和 Head,并进一步融合、增强和调整特征信息,生成多尺度的、更具判别性的特征表示。Head 是模型的最终输出部分,通过卷积层和全连接层对特征进行非线性变换,输出识别目标的类别概率和边界框坐标。

在此基础上,YOLOv12 的创新在于提出区域注意力(area attention),通过将特征图划分为多个区域(默认为 4 个区域),避免了复杂的窗口划分操作,同时保持较大的感受野,巧妙地将注意力机制引入 YOLO 框架以替换传统的卷积神经网络(convolutional neural network, CNN),利用注意力机制的性能优势实现了更高的检测精度。为了应对注意力机制引入的优化挑战,YOLOv12 还引入了残差高效层聚合网络(R-ELAN),在 ELAN 架构基础上从输入到输出增加了一个具有缩放因子(默认为 0.01)的残差捷径。通过新的聚合方法,使用一个过渡层调整通道通道维度,并生成一个单一的特征图,通过后续处理与连接形成瓶颈结构,实现了网络稳定高效和计算成本的平衡性。

通过创新的注意力机制引入和优化的网络结构,YOLOv12 实现了检测精度与实时性的较好平衡,但是,YOLOv12 基线模型仍存在以下不足需要改进:(1)感受野有限。YOLO 系列采用标准卷积层来提取特征,难以捕捉更大范围的图像信息。(2)特征信息捕捉能力不足。YOLO 系列的参数量相对固定,在处理复杂的图像特征尤其是大规模数据集上的预训练任务时无法捕捉足够的特征信息,进而限制了模型的表达能力。(3)小目标检测能力弱。YOLO 系列的 CiOU 损失函数强调距离与长宽比等几何因素,会加剧对低质量样本的惩罚,没有充分考虑检测样本的难易平衡,这导致在处理小目标

检测任务时其性能仍有较大提升空间。

综上所述,基于YOLOv12的优缺点,本文采用YOLOv12作为改进的基线模型,其网络结构如图1所示。

2 改进YOLOv12模型

本文针对YOLOv12基线模型感受野有限、特征信息捕捉能力不足和小目标检测能力弱的缺点做出如下改进。

2.1 C3k2_WTConv模块

在卷积神经网络中,特征图上的每一个单元所“观察”到的输入图像范围被称为感受野。当感受野增大时,模型能够捕捉到更大范围的图像信息,从而在处理复杂场景的任务时表现出更强的性能。YOLO网络采用标准卷积层提取特征信息,在结构上局限于特征信息的局部融合,无法实现较大的感受野。以往研究通过增加卷积核大小以模拟ViTs(vision transformer)自注意力模块的全局感受野,但是效果不尽人意。本文引入基于小波变换的WTConv改进YOLO骨干网络中的C3k2模块,实现了YOLO网络感受野的有效扩大。

WTConv通过小波变换将输入信号分解到不同的频率带,在不同的频率带中分别进行卷积操作后利用逆小波变换重新组合结果,在保持网络参数可控性的前提下大幅扩大了卷积层的感受野。

具体来说,WTConv采用Haar小波变换,将输入图像分解为低频和高频部分,一维Haar小波变换可以用公式表示为:

$$X_{LL}, X_{LH}, X_{HL}, X_{HH} = WT(X) \quad (1)$$

式中, X_{LL} 为低频部分, X_{LH} 、 X_{HL} 和 X_{HH} 为高频部

分, X 为输入信号,WT为小波变换操作。

对于二维输入信号如图像,一维小波变换可以分别作用于行和列实现二维小波变换,可以用公式表示为:

$$[X_{LL}, X_{LH}, X_{HL}, X_{HH}] = \text{Conv}([f_{LL}, f_{LH}, f_{HL}, f_{HH}], X) \quad (2)$$

式中, f_{LL} 为低频滤波器, f_{LH} 、 f_{HL} 和 f_{HH} 为一组高频滤波器, X 为输入图像, X_{LL} 为低频分量, X_{LH} 、 X_{HL} 和 X_{HH} 为水平、垂直和对角的高频分量,Conv为卷积操作。

在二维情况下,通过低频和高频滤波器组合,将图像分解为低频分量(LL)和高频分量(LH、HL、HH),分别对应图像的轮廓、水平边缘、垂直边缘和对角线信息。这种分解方式使得模型能够同时捕捉图像的全局结构和局部细节特征,增强模型的检测性能。并且边缘信息对于目标的定位和识别非常重要,WTConv能够更好地提取这些信息,从而提高模型的检测性能。

对应的卷积核可以用公式表示为:

$$\begin{cases} f_{LL} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, f_{LH} = \frac{1}{2} \begin{bmatrix} 1 & -1 \\ 1 & -1 \end{bmatrix} \\ f_{HL} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ -1 & -1 \end{bmatrix}, f_{HH} = \frac{1}{2} \begin{bmatrix} 1 & -1 \\ -1 & -1 \end{bmatrix} \end{cases} \quad (3)$$

四种滤波器形成一组正交基,可以用转置卷积实现逆小波变换(inverse wavelet transform, IWT),将分解后的频率带重新组合为原始空间域的信号,其过程为WT操作的逆操作,可以用公式表示为:

$$X = \text{Conv-transposed}([f_{LL}, f_{LH}, f_{HL}, f_{HH}], [X_{LL}, X_{LH}, X_{HL}, X_{HH}]) \quad (4)$$

式中,transposed为转置操作。

感受野的大小并不是越大越好,WTConv通过递归分解低频分量实现级联小波分解,扩大感受野的同时




图1 YOLOv12网络结构图

Fig.1 Architecture of YOLOv12

保持网络参数的可控性,分解的每一层可以用公式表示为:

$$X_{LL}^{(i)}, X_{LH}^{(i)}, X_{HL}^{(i)}, X_{HH}^{(i)} = WT(X_{LL}^{(i-1)}) \quad (5)$$

式中, i 表示当前层级,故 $X_{LL}^{(0)} = X$ 。

在每一层分解中,感受野都会随着分解的进行而扩大,从而使得模型能够捕捉到更大范围的图像信息。这种感受野的扩大,有助于模型更好地理解图像的全局信息,提高对复杂场景的适应能力。

为了缓解网络参数量的二次方增加,WTConv使用WT对输入的低频和低频内容进行滤波和下采样。然后,在不同频率图上执行小卷积核的深度卷积,最后使用IWT构建输出 Y ,该过程用公式表示为:

$$Y = IWT(Conv(W, WT(X))) \quad (6)$$

式中, X 为输入张量, W 为一个 $k \times k$ 的深度卷积核权重张量,其输入通道数为 X 的4倍。

通过小波变换和逆小波变换的组合,WTConv在每一层分解后,参数量的增长是可控的。这种参数可控性,使得模型在扩大感受野的同时,不会因为参数量的大幅增加而导致模型复杂度过高,从而保证了模型的训练效率和推理速度。

通过公式(5)的级联操作进行扩展,可以用公式表示为:

$$\begin{cases} X_{LL}^{(i)}, X_H^{(i)} = WT(X_{LL}^{(i-1)}) \\ Y_{LL}^{(i)}, Y_H^{(i)} = Conv(W^{(i)}, (X_{LL}^{(i)}, X_H^{(i)})) \end{cases} \quad (7)$$

式中, $X_{LL}^{(0)}$ 为该层输入, $X_H^{(i)}$ 为第 i 层描述的两个高频图。

因为WT和IWT为线性操作,采用IWT将所有频率带的结果组合,用公式表示为:

$$Z^{(i)} = IWT(Y_{LL}^{(i)} + Z^{(i-1)}, Y_H^{(i)}) \quad (8)$$

式中, $Z^{(i)}$ 为从第 i 层开始的累计输出。

WTConv通过将卷积操作与频率分量分离,能够处理不同频率带的信息,实现对图像多尺度信息的提取,在网络参数量仅对数级增长的前提下,实现了感受野的指数级增长。并且由于其对频率信息的分解和重构,引入WTConv后模型对目标形状更加敏感,能够过滤复杂环境中的高频噪声信息,增强了模型对水面纹理等干扰的鲁棒性。本文引入WTConv改进YOLOv12颈部网络中C3k2模块的Bottleneck,改进后的C3k2_WTConv模块如图2所示。

2.2 C3k2_DynamicConv 模块

在卷积神经网络中,参数量和浮点运算次数高度相关,通常具有更大参数的网络结构能够更好地学习从简单边缘到复杂形状的多层次特征,进而捕捉更丰富的特征信息。但在增加网络参数量的同时,大幅增加的参数量通常会限制模型的部署。本文引入DynamicConv改进YOLO颈部网络的C3k2模块,在保持低计算量的同时获得更多网络参数。




图2 C3k2_WTConv 结构图

Fig.2 Architecture of C3k2_WTConv

不同于固定的卷积核,DynamicConv根据输入数据的特性自适应地调整卷积核,为每个输入样本动态生成卷积核权重,从而更好地捕捉特征信息。

对于输入特征 $X \in \mathbb{R}^{C_{in} \times H \times W}$ 和标准卷积层的卷积核权重 $W \in \mathbb{R}^{C_{out} \times C_{in} \times K \times K}$,其中 C_{in} 和 C_{out} 为输入和输出通道数, H 和 W 为输入特征图的高和宽, K 为卷积核的大小。则标准卷积操作公式表示为:

$$Y = X * W \quad (9)$$

式中, $Y \in \mathbb{R}^{C_{out} \times H' \times W'}$ 为标准卷积层输出。

而在DynamicConv中,卷积核权重通过多个动态专家(dynamic experts)对卷积核权重进行动态生成,每个动态专家对应一个卷积核权重 $W_i \in \mathbb{R}^{C_{out} \times C_{in} \times K \times K}$,对于每个输入样本生成一组动态系数 α_i ,对专家权重根据动态系数进行加权融合生成最终的动态卷积核 W' ,用公式表示为:

$$W' = \sum_{i=1}^M \alpha_i W_i \quad (10)$$

式中, M 为动态专家数量, α_i 为第 i 个动态专家的权重系数,且满足 $\sum_{i=1}^M \alpha_i = 1$ 。

权重系数 α_i 根据输入样本 X 动态生成,DynamicConv使用一个两层的多层感知机(multi-layer perceptron, MLP)来实现这一步骤:对输入样本 X 进行全局平均池化,将其压缩为一个向量 $Pool(X) \in \mathbb{R}^{C_{in}}$,使用一个两层的MLP对池化后的向量进行处理得到权重系数,并通过softmax函数归一化,用公式表示为:

$$\alpha = softmax(MLP(Pool(X))) \quad (11)$$

式中, $\alpha \in \mathbb{R}^M$ 为生成的系数,softmax为归一化函数,Pool为全局平均池化操作。

对于标准卷积层,参数量和计算量为:

$$\begin{cases} Params = C_{out} \times C_{in} \times K \times K \\ FLOPs = W' \times H' \times C_{out} \times C_{in} \times K \times K \end{cases} \quad (12)$$

式中, $Params$ 为参数量, $FLOPs$ 为计算量。

对于 DynamicConv, 其包含系数生成模块、动态权重融合和卷积过程, 对应的参数量和计算量为:

$$\begin{cases} Params' = M \times C_{out} \times C_{in} \times K \times K + C_{in}^2 + M \times C_{in} \\ FLOPs' = M \times C_{out} \times C_{in} \times K \times K + W' \times H' \times C_{out} \times C_{in} \times K \times K + C_{in}^2 + C_{in} \times M \end{cases} \quad (13)$$

式中, $Params'$ 为参数量, $FLOPs'$ 为计算量, $C_{in}^2 + C_{in} \times M$ 和 $C_{in}^2 + C_{in} \times M$ 为系数生成模块的参数量和计算量, $M \times C_{out} \times C_{in} \times K \times K$ 为动态权重融合计算量, $M \times C_{out} \times C_{in} \times K \times K$ 和 $W' \times H' \times C_{out} \times C_{in} \times K \times K$ 为卷积过程的参数量和计算量。

DynamicConv 和标准卷积的参数量和计算量之比分别为:

$$\begin{aligned} Ratio_{param} &= \frac{M \times C_{out} \times C_{in} \times K \times K + C_{in}^2 + M \times C_{in}}{C_{out} \times C_{in} \times K \times K} = \\ &= \frac{C_{in}}{C_{out} \times K \times K} + \frac{M}{C_{out} \times K \times K} + M \approx \frac{1}{K \times K} + M \\ & (M \ll C_{out} \times K \times K, C_{in} \approx C_{out}) \end{aligned} \quad (14)$$

$$\begin{aligned} Ratio_{FLOS} &= \frac{C_{in}}{W' \times H' \times C_{out} \times K \times K} + \\ &= \frac{M}{W' \times H' \times C_{out} \times K \times K} + \frac{M}{W' \times H'} + 1 \approx 1 \\ & (1 \ll M \ll W' \times H', C_{in} \approx C_{out}) \end{aligned} \quad (15)$$

由公式(14)(15)可知, 通常情况下, DynamicConv 的计算量相比标准卷积层几乎没有增加, 而参数量则扩大至约 M 倍, 能够有效提升模型对更丰富特征信息的捕捉能力。

综上所述, DynamicConv 的输出用公式表示为:

$$Y = X * W' = X * \sum_{i=1}^M \alpha_i W_i \quad (16)$$

本文引入 DynamicConv 改进 YOLOv12 骨干网络中 C3k2 模块的 Bottleneck, 改进后的 C3k2_DynamicConv 模块如图3所示。

2.3 WiseIoUv3 损失函数

边界框损失函数用于衡量预测边界框和真实边界框之间的差异, 精确的边界框损失函数有助于提升模型的小目标检测能力。YOLOv12 的默认损失函数为 CIoU, 公式为:

$$\begin{cases} \alpha = \frac{v}{(1 - IoU) + v} \\ v = \frac{4}{\pi^2} (\arctan \frac{w_{gt}}{h_{gt}} - \arctan \frac{w}{h})^2 \\ CIoU = IoU - (\frac{\rho^2(b, b^{gt})}{c^2}) + \alpha v \\ L_{CIoU} = 1 - CIoU \end{cases} \quad (17)$$




图3 C3k2_DynamicConv 结构图

Fig.3 Architecture of C3k2_DynamicConv

式中, α 为权重因子, v 为预测边界框和真实边界框的宽高比一致性, w 和 h 为预测框的宽和高, w_{gt} 和 h_{gt} 为实际框宽和高, IoU 为预测边界框 b 和真实边界框 b^{gt} 交并比, $\rho^2(b, b^{gt})$ 为预测框中心点和真实框中心点的欧几里得距离的平方, c 为预测框和真实框的最小外接矩形的对角线长度, L_{CIoU} 为最终计算得到的损失函数。

CIoU 同时考虑交并比、长宽比和中心点距离的策略能够较好地衡量预测框与真实框的相似性, 但会放大对低质量锚框的惩罚, 导致不同检测难度样本的平衡问题, 降低模型对小目标的检测能力。

本文采用基于动态非单调聚焦机制的 WiseIoUv3 作为边界框损失函数。相比 CIoU 对距离与长宽比等几何因素的强调, WiseIoUv3 使用“离群度”作为锚框质量评估的指标, 通过锚框之间的比较评估不同锚框的质量, 减少了在几何属性上不必要的惩罚。并通过梯度增益分配策略: 对离群度小的锚框分配较小的梯度增益, 使边界框回归聚焦到普通质量锚框; 对离群度大的锚框同样分配较小的梯度增益, 防止低质量锚框产生更大的有害梯度, 平衡了难易检测样本, 实现模型对数量最多的普通质量锚框的关注, 进而提升模型的小目标检测和泛化能力。WiseIoUv3 的计算公式为:

$$\begin{cases} L_{WIoUv3} = (\frac{\beta}{\delta \epsilon^{\beta-\delta}}) L_{WIoUv1} \\ \beta = \frac{L_{IoU}^\gamma}{L_{IoU}} \in [0, +\infty) \\ L_{WIoUv1} = R_{WIoU} (1 - IoU) \\ R_{WIoU} = \exp(\frac{(x - x_{gt})^2 + (y - y_{gt})^2}{W_g^2 + H_g^2}) \end{cases} \quad (18)$$

式中, (x, y) 是预测框的中心坐标, (x_{gt}, y_{gt}) 是真实框的中心坐标; W_g 和 H_g 分别为同时包含预测框和真实框

的最小外围框宽高。 β 为离群度,它表示的是一个目标 IoU 损失 L_{IoU}^y 与当前 IoU 损失 L_{IoU} 的比值; α 和 δ 是超参数,用于调节比例因子; R_{IoU} 是距离损失; L_{WIoUv1} 是具有距离注意力的 1 代 WiseIoU。

WiseIoUv3 作者在 MS-COCO 数据集实验得出最佳超参数组合为 $\alpha=1.9$ 和 $\delta=3$,但不同场景下锚框的不同需要对超参数进行更细致的实验探究,本文使用 WiseIoUv3 替换 CIOU,并基于水面纹理影响严重和小目标多的水面垃圾数据集探究超参数的最佳组合。

2.4 WDW-YOLO 模型

本文提出基于 YOLOv12 的改进模型:WDW-YOLO 模型,模型结构如图 4 所示。WDW-YOLO 模型架构与基线模型改进点如下:

(1) 引入 WTConv 对 YOLOv12 颈部网络中的 C3k2 模块进行创新改进,通过小波变换扩大网络的感受野和频率响应以提高检测精度。

(2) 引入 DynamicConv 对 YOLOv12 骨干网络中的 C3k2 模块进行创新改进,通过动态生成卷积核权重,在不引入过多计算量的前提下引入更多网络参数来提高检测精度。

(3) 采用基于动态非单调聚焦机制的 WiseIoUv3 作为边界框损失函数,提高模型对数量最多的普通质量锚框的关注来提升小目标检测能力,并分析超参数在小目标检测场景的贡献。

3 实验结果与分析

3.1 实验环境

本文实验全部基于 Linux20.04 操作系统,使用基于

Python3.8.0 的 Pytorch2.0.0 搭建深度学习模型,使用 NVIDIA GeForce RTX 4090D GPU 作为模型训练平台,并采用 CUDA11.7 对 GPU 进行加速。本文深度学习模型参数设置如表 1 所示。

表 1 模型参数

Table 1 Model parameters

参数	设置	参数	设置
类别数量	1	学习阈值	0.01
输入宽	640	优化器	SGD
输入高	640	批大小	64
学习率	0.001 25	训练轮数	300

3.2 实验数据集

本文实验采用 FloW_IMG 数据集^[18]。该数据集由欧卡智船公司发布,是全球第一个无人船视角的水面漂浮垃圾检测数据集。数据集共 2 000 张图像和 5 271 个标注对象,其中尺寸小于 32×32 的小目标占比较高。数据集中典型的场景如图 5 所示,包含丰富的环境挑战,具体挑战包括但不限于复杂光影场景、水面倒影和光照干扰,这些挑战充分反映了水面垃圾识别面临的困难,要求模型不仅能够准确识别目标,还需具备优秀的鲁棒性,可以全面地验证改进模型的先进性和有效性。

3.3 评价指标

本文改进模型的目的是优化水面垃圾检测方法,需要在保持模型易部署的前提下获得更高的检测精度。为了全面评估改进模型的先进性和有效性,设置以下实验评估指标:准确率(precision, P)、召回率(recall, R)、IoU 为 0.5 时的平均精度均值(mean average precision, mAP)mAP50 和 IoU 从 0.5 到 0.95(每隔 0.05 为一个步




图 4 WDW-YOLO 网络结构图

Fig.4 Architecture of WDW-YOLO




图5 FloW_IMG数据集的典型场景

Fig.5 Typical scenarios of FloW_IMG dataset

长)范围内计算的mAP值的平均值mAP50-95作为模型对水面垃圾检测准确率的评估指标,P、R、mAP越接近1说明模型检测准确率越高;模型中可训练参数的总数参数量与模型在推理过程中所需的浮点运算次数计算量作为模型效率的评估指标。指标的计算公式如下:

$$TP = \frac{TP}{TP + FP} \tag{19}$$

$$R = \frac{TP}{TP + FN} \tag{20}$$

$$mAP = \frac{1}{n} \sum_{i=1}^N AP_i = \frac{1}{n} \sum_{i=1}^N \int PdR \tag{21}$$

式中,TP为检测垃圾正确的目标数量;FP为检测错误垃圾的目标数量;FN为漏检垃圾的目标数量;AP为平均精度,即PR曲线下的面积;N为目标检测类别的数量。

3.4 WiseIoUv3实验

李岩超等^[19]在遥感场景中测试出的WiseIoUv3的最佳范围 $\alpha \in [1.25, 1.75]$ 和 $\beta \in [4, 5]$,由于遥感场景与水面垃圾场景同为小目标场景,本文在该基础上扩大范围进行实验,在添加前两项改进的前提下测试出符合本实验场景的最佳超参数组合,实验以mAP50作为评价指标,实验结果如表2所示。

由表2可知, $\alpha = 1.5$ 和 $\beta = 4.0$ 时mAP50达到最大值90.7%,相比不替换CIoU损失函数仅采用前两个改进时mAP50为89.9%,提升0.8个百分点,证明了WiseIoUv3改进的有效性。并且,当 $\alpha = 1.5$ 和 $\beta \in [3.75, 4.5]$ 时,mAP50 $\in [0.9, 0.907]$ 达到极大值区间,而其他不佳超参数组合对mAP50作用不大甚至起到负作用,说明在水面垃圾与类似小目标场景中,WiseIoUv3超参数的最佳组合为 $\alpha = 1.5$ 和 $\beta \in [3.75, 4.5]$ 。

3.5 消融实验

为了验证本文提出的改进水面垃圾检测方法所做

表2 WiseIoU实验

Table 1 WiseIoU experiment

α	δ	mAP50	α	δ	mAP50
1.00	3.75	0.887	1.50	3.75	0.901
1.00	4.00	0.906	1.50	4.00	0.907
1.00	4.25	0.891	1.50	4.25	0.901
1.00	4.50	0.898	1.50	4.50	0.900
1.00	4.75	0.894	1.50	4.75	0.897
1.00	5.00	0.898	1.50	5.00	0.899
1.00	5.25	0.901	1.50	5.25	0.902
1.25	3.75	0.893	1.75	3.75	0.902
1.25	4.00	0.891	1.75	4.25	0.885
1.25	4.25	0.893	1.75	4.50	0.884
1.25	4.50	0.901	1.75	4.75	0.887
1.25	4.75	0.899	1.75	5.00	0.886
1.25	5.00	0.898	1.75	5.25	0.884
1.25	5.25	0.886	2.00	3.75	0.879
2.00	4.00	0.889	2.00	4.25	0.893
2.00	4.50	0.890	2.00	5.25	0.870

的各项改进的有效性,对各项改进进行消融实验。实验之间严格控制模型参数一致,消融实验结果如表3所示,表中“+A”为添加C3k2_WTConv改进,“+B”为添加C3k2_Dyanmicconv改进,“+C”为添加3.4节中最佳超参数组合的WiseIoUv3改进。

表3 消融实验结果

Table 3 Results of ablation experimen

模型	Params/10 ⁶	GFLOPs	mAP50/%	mAP50-95/%	P/%	R/%
baseline	2.56	6.3	88.0	49.5	88.9	80.9
+A	2.50	6.3	88.5	49.2	92.5	78.1
+B	2.60	6.3	88.6	49.8	88.6	81.3
+C	2.56	6.3	88.8	50.0	86.6	84.3
+A+B	2.55	6.3	89.9	49.7	91.0	82.8
+A+C	2.50	6.3	89.0	50.1	91.2	81.0
+B+C	2.60	6.3	89.8	49.8	88.4	84.8
+A+B+C	2.55	6.3	90.7	50.6	91.7	80.7

表3中证明了各个改进的有效性,引入WTConv后,模型获取到更大的感受野,并保持网络参数的可控性,mAP50增长0.5个百分点,准确率增长3.6个百分点,验证了其对检测性能提升的有效性;引入DynamicConv使得模型的特征信息捕捉能力增强,并且网络参数量增长的同时计算量不变,mAP50和mAP50-95都有明显提升;最后添加最佳超参数组合的WiseIoUv3,平衡难易样本,进一步加强小目标检测能力,获得最高的检测精度。

3.6 对比实验

为了证明本文提出的WDW-YOLO模型的先进性,将WDW-YOLO与主流一阶段目标检测算法进行对比分析,实验之间严格控制参数一致,实验结果如表4所示。

由表4可知,本文提出的改进模型与8种YOLO系列经典模型相比,参数量仅略高于YOLOv5n、YOLOv9-tiny和YOLOv10n,计算量仅高于YOLOv5n,保持低计

表4 不同模型实验结果对比

Table 4 Comparison of experimental results of different models

模型	Params/ 10^6	GFLOPs	mAP50/%	mAP50-95/%	P/%	R/%
YOLOv3-tiny	9.52	14.3	76.7	42.1	87.8	65.4
YOLOv5n	2.18	5.8	88.1	48.9	89.6	80.1
YOLOv6n	4.16	11.5	88.0	48.5	90.9	80.7
YOLOv8n	2.68	6.8	89.9	50.7	91.8	80.7
YOLOv9-tiny	1.73	6.4	88.5	50.4	89.4	83.7
YOLOv10n	2.27	6.5	90.1	51.2	90.7	82.4
YOLO11n	2.58	6.3	88.8	50.4	91.4	81.7
YOLOv12n	2.56	6.3	88.0	49.5	88.9	80.9
ASF-YOLO ^[20]	2.24	6.3	89.3	48.8	89.3	82.8
Hyper-YOLO-t ^[21]	2.68	7.6	89.7	50.0	89.8	83.9
Hyper-YOLO-n ^[21]	3.62	9.5	90.3	50.6	90.9	83.4
WDW-YOLO(ours)	2.55	6.3	90.7	50.6	91.7	80.7

算量的同时获得更多网络参数,而mAP50为最高,达到90.7%的检测精度;与基于YOLOv5改进的ASF-YOLO相比,参数量略高,计算量持平,而mAP50和mAP50-95分别提升1.4和1.8个百分点;对于引入超图计算的同等量级的Hyper-YOLO系列,相比Hyper-YOLO-t参数量和计算量分别下降4.85%和17.10%,mAP50和mAP50-95分别提升1.0和0.6个百分点,相比Hyper-YOLO-n参数量和计算量分别下降29.6%和33.7%,mAP50提升0.4个百分点,mAP50-95持平。但是,改进模型还存在以下缺陷:检测精度依赖 WiseIoUv3 超参数的调整,召回率不足。

实验结果表明,本文改进模型在模型效率和检测精度之间取得了较好的平衡,综合性能优于现有模型,更适合部署在水面垃圾检测场景中。

3.7 实验结果可视化

为了直观地对比本文改进模型与基线模型的检测

效果,本文从测试集中选取具有挑战性的图像进行对比测试,并通过检测效果和检测热力图两种可视化方法说明改进模型的先进性。

(1) 检测效果可视化

检测效果可视化结果如图6、图7和图8所示。图6面对远距离小目标挑战时,WDW-YOLO凭借更强的小目标检测能力,对图像中部偏右的小目标识别准确率提高7个百分点;图7面对视角不足和光照影响的双重挑战,基线模型未能准确地识别图像左下角影响较大区域中的水面垃圾,而WDW-YOLO成功识别到该目标,并且对图像中其他水面垃圾的识别准确率也有一定提升,充分证明了改进模型特征信息捕捉能力的增强,但是改进模型对该类难识别目标的检测准确率较低,也反映了改进模型亟待改进的缺陷;图8面对水面纹理变化及干扰物体时,YOLOv12n错误的识别会导致水面垃圾清洁效率的降低,得益于对图像频率信息的分解和重构,




图6 远距离小目标检测对比图

Fig.6 Comparison of remote small target detection




图7 视角不足和光照影响检测对比图

Fig.7 Comparison of detection impacted by insufficient viewing angle and lighting



图8 水面纹理变化和干扰物体检测对比图

Fig.8 Comparison of detection of surface texture variation and interference objects

WDW-YOLO 能够更好地捕捉图像低频部分的全局结构信息,抑制图像高频部分的水面纹理变化和干扰等信息,这不仅提升了对正确目标的检测准确率,并且没有错判非水面垃圾物体,验证了改进模型面对水面纹理等干扰场景的鲁棒性。实验结果表明,在YOLOv12n出现漏检错检时,改进的WDW-YOLO能更好地识别漏检目标,回避错检目标,助力水面垃圾及时清理。

(2) 热力图可视化

为了验证改进模型对特征信息捕捉能力的增强,本文采用 Grad-CAM++^[22]方法生成热力图来可视化模型关注的特征区域,基线模型与改进模型对测试集中具有挑战的图像热力图可视化如图9所示,热力图中颜色越

深说明模型对此区域的特征信息关注度越高。

图9第1列中,基线模型对远距离的楼房和树木等给予过多关注,缺乏对水面的关注,而改进模型则将聚焦于可能出现垃圾的水面,有助于及时且准确地发现水面垃圾;图9第2列中,基线模型对水面纹理干扰部分的关注度不足,容易导致漏检,而改进模型则有效地对水面投入更均衡的关注度,避免了漏检错检的问题;图9第3列中,由于岸边楼房倒影与波纹,基线模型的关注策略无法有效地覆盖水面,而改进模型虽然错误地分配一部分关注度至天空,但是对水面仍有优于基线模型的更高关注。

实验结果说明,改进模型的关注策略能更好地覆盖




图9 YOLOv12n 与 WDW-YOLO 检测结果对比

Fig.9 Comparison of detection results between YOLOv12n and WDW-YOLO

更可能出现垃圾的水面,并减少对如岸边设施、水面纹理和楼房倒影等干扰的关注,有助于准确地捕捉特征信息,进而增强模型在复杂环境下的检测准确性和鲁棒性。

4 结语

针对现有水面垃圾检测方法模型较老、易漏检错检、无法满足高效的水面环境治理的问题,提出了一种改进YOLOv12的水面垃圾检测方法WDW-YOLO。主要结论为:引入WTConv改进YOLOv12颈部网络中的C3k2模块,扩大模型的感受野;引入DynamicConv改进YOLOv12骨干网络的C3k2模块,增强模型对特征信息的捕捉能力;使用WiseIoUv3替换CIoU并提出最佳的超参数组合,提升模型的小目标检测能力。实验结果表明,WDW-YOLO的综合性能优于当前主流算法,但也存在检测精度依赖超参数、面对不同环境的鲁棒性有待验证等缺陷,具有高可靠性和高实用性,适合部署在无人船等设备上进行自动化的水面垃圾检测和清理,有助于保护水体的生态环境和平衡,促进高质量、可持续发展的绿色发展。下一步计划将改进模型部署至武汉华航清舟智能科技有限公司无人船,在湖北省武汉市后官湖和黄冈市遗爱湖进行水面垃圾清洁工作,结合实际效果探索轻量化与检测精度的进一步平衡。

参考文献:

- [1] 安立会,李欢,王菲菲,等.海洋塑料垃圾污染国际治理进程与对策[J].环境科学研究,2022,35(6):1334-1340.
AN L H, LI H, WANG F F, et al. International governance progress in marine plastic litter pollution and policy recom-

mendations[J]. Research of Environmental Sciences, 2022, 35(6):1334-1340.

- [2] 曾志超,徐玥,王景玉,等.基于SOE-YOLO轻量化的水面目标检测算法[J].图学学报,2024,45(4):736-744.
ZENG Z C, XU Y, WANG J Y, et al. A water surface target detection algorithm based on SOE-YOLO lightweight network[J]. Journal of Graphics, 2024, 45(4):736-744.
- [3] 张智,易华挥,郑锦.语言引导视觉的小样本航拍图像目标检测[J].北京航空航天大学学报,2025,51(7):2338-2348.
ZHANG Z, YI H H, ZHENG J. Few-shot object detection of aerial image based on language guidance vision[J]. Journal of Beijing University of Aeronautics and Astronautics, 2025, 51(7):2338-2348.
- [4] YASIR M, LIU S W, XU M M, et al. ShipGeoNet: SAR image-based geometric feature extraction of ships using convolutional neural networks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62:5202613.
- [5] GIRSHICK R. Fast R-CNN[C]//Proceedings of the 2015 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2015:1440-1448.
- [6] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6):1137-1149.
- [7] WANG J X, LIU M, DU Y R, et al. PG-YOLO: an efficient detection algorithm for pomegranate before fruit thinning[J]. Engineering Applications of Artificial Intelligence, 2024, 134:108700.
- [8] 杨思念,曹立佳,杨洋,等.基于机器视觉的PCB缺陷检测算法研究综述[J].计算机科学与探索,2025,19(4):901-915.
YANG S N, CAO L J, YANG Y, et al. Review of PCB defect

- detection algorithm based on machine vision[J].Journal of Frontiers of Computer Science and Technology, 2025, 19(4): 901-915.
- [9] 王宁,智敏.深度学习下的单阶段通用目标检测算法研究综述[J].计算机科学与探索,2025,19(5):1115-1140.
WANG N, ZHI M. Review of one-stage universal object detection algorithms in deep learning[J].Journal of Frontiers of Computer Science and Technology, 2025, 19(5): 1115-1140.
- [10] LI X S, WANG C L, ZENG Z. WS-SSD: achieving faster 3D object detection for autonomous driving via weighted point cloud sampling[J].Expert Systems with Applications, 2024, 249: 123805.
- [11] WANG J, ZHAO H. Improved YOLOv8 algorithm for water surface object detection[J].Sensors, 2024, 24(15): 5059.
- [12] 袁和平,周波,刘必劲.基于YOLOv5-Byte面向清洁船的多目标漂浮垃圾追踪算法[J].中国舰船研究,2025,20(3): 327-338.
YUAN H P, ZHOU B, LIU B J. A multi-object tracking algorithm for cleaning vessels to track floating debris based on YOLOv5-Byte[J].Chinese Journal of Ship Research, 2025, 20(3): 327-338.
- [13] LI C L, WANG L, LIU Y T, et al. Lightweight water surface object detection network for unmanned surface vehicles[J].Electronics, 2024, 13(15): 3089.
- [14] FINDER S E, AMOYAL R, TREISTER E, et al. Wavelet convolutions for large receptive fields[C]//Proceedings of the 18th European Conference on Computer Vision. Cham: Springer, 2025: 363-380.
- [15] HAN K, WANG Y H, GUO J Y, et al. ParameterNet: parameters are all you need for large-scale visual pretraining of mobile networks[C]//Proceedings of the 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2024: 15751-15761.
- [16] TONG Z J, CHEN Y H, XU Z W, et al. Wise-IoU: bounding box regression loss with dynamic focusing mechanism [EB/OL]. [2025-05-10]. <https://arxiv.org/abs/2301.10051>.
- [17] TIAN Y J, YE Q X, DOERMANN D. YOLOv12: attention-centric real-time object detectors[EB/OL]. [2025-05-10]. <https://arxiv.org/abs/2502.12524>.
- [18] CHENG Y W, ZHU J N, JIANG M X, et al. FloW: a dataset and benchmark for floating waste detection in inland waters [C]//Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 10933-10942.
- [19] 李岩超,史卫亚,冯灿.面向无人机航拍小目标检测的轻量级YOLOv8检测算法[J].计算机工程与应用,2024,60(17): 167-178.
LI Y C, SHI W Y, FENG C. Lightweight YOLOv8 detection algorithm for small object detection in UAV aerial photography[J].Computer Engineering and Applications, 2024, 60(17): 167-178.
- [20] KANG M, TING C M, TING F F, et al. ASF-YOLO: a novel YOLO model with attentional scale sequence fusion for cell instance segmentation[J].Image and Vision Computing, 2024, 147: 105057.
- [21] FENG Y F, HUANG J G, DU S Y, et al. Hyper-YOLO: when visual object detection meets hypergraph computation [J].IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025, 47(4): 2388-2401.
- [22] CHATTOPADHAY A, SARKAR A, HOWLADER P, et al. Grad-CAM: generalized gradient-based visual explanations for deep convolutional networks[C]//Proceedings of the 2018 IEEE Winter Conference on Applications of Computer Vision. Piscataway: IEEE, 2018: 839-847.