



湖南大学学报(自然科学版)
Journal of Hunan University(Natural Sciences)
ISSN 1674-2974,CN 43-1061/N

《湖南大学学报(自然科学版)》网络首发论文

题目: 融合 SFAR-Net 图像增强与 YOLOv12-DMFA 的高铁接触网支持装置故障检测方法

作者: 顾桂梅, 蹇靖宇, 赵克进

收稿日期: 2026-03-04

网络首发日期: 2026-05-22

引用格式: 顾桂梅, 蹇靖宇, 赵克进. 融合 SFAR-Net 图像增强与 YOLOv12-DMFA 的高铁接触网支持装置故障检测方法[J/OL]. 湖南大学学报(自然科学版).
<https://link.cnki.net/urlid/43.1061.N.20260521.2008.002>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

融合 SFAR-Net 图像增强与 YOLOv12-DMFA 的高铁接触网支持装置故障检测方法

顾桂梅¹, 蹇靖宇^{1†}, 赵克进²

(1. 兰州交通大学 自动化与电气工程学院, 甘肃 兰州 730070;
2. 中国铁路兰州局集团有限公司 银川供电段, 宁夏 银川 750000)

摘要: 接触网支持装置作为高速铁路牵引供电系统的核心单元, 其完好性直接影响受电弓受流安全. 但在4C (接触网悬挂状态检测监测装置) 巡检场景中, 由于成像设备噪声、运动模糊及压缩伪影干扰, 图像对比度低且细节缺失, 导致现有算法在螺母缺失、绝缘子脏污等缺陷识别中存在定位精度差及漏检率高等问题. 为此, 本文提出一种“图像增强—目标检测”协同的两阶段框架. 首先, 构建空频联合注意力增强网络 (spatial-frequency joint attention network, SFAR-Net) 对低质量图像进行细节增强, 提升目标的可辨识度; 随后, 将增强图像输入改进的YOLOv12 (you only look once version 12, YOLOv12) 网络完成检测. 针对多尺度小目标与复杂背景下的特征表达不足的问题, 在检测网络中引入动态多尺度频域自适应模块 (dynamic multi-scale frequency-domain adaptation module, DMFA), 增强模型对关键区域的表征能力. 实验结果表明, SFAR-Net在峰值信噪比 (peak signal-to-noise ratio, PSNR)、结构相似性指标 (structural similarity index measure, SSIM) 与学习感知图像块相似度 (learned perceptual image patch similarity, LPIPS) 分别达到39.08 dB、0.9747和0.1014, 说明该方法在图像保真度、结构保持能力及感知质量方面均取得了较好的综合表现. 在下游任务中, SFAR-Net预处理使YOLOv12的全类平均精度 (mean average precision, mAP) mAP@0.5从71.4%提升至73.6%; 结合DMFA模块后, 最终框架的mAP@0.5提升至74.9%, mAP@0.5:0.95达到65.9%. 该研究为高铁接触网的智能巡检提供了可靠的技术支撑.

关键词: 高速铁路接触网支持装置; 缺陷检测; 图像增强; YOLOv12; 空频联合注意力; 动态多尺度频域自适应模块

中图分类号: U293.2; TP391.9 文献标志码: A

Fault detection for high-speed railway catenary support devices via SFAR-Net image enhancement and YOLOv12-DMFA

GU Guimei¹, JIAN Jingyu^{1†}, ZHAO Kejin²

(1. School of Automation and Electrical Engineering, Lanzhou Jiaotong University, Lanzhou 730070, China;
2. Yinchuan Power Supply Section, China Railway Lanzhou Group Co., Ltd, Yinchuan 750000, China)

Abstract: The integrity of high-speed railway catenary support devices is critical for pantograph

收稿日期: 2026-03-04

基金项目: 中国国家铁路集团有限公司基金资助项目(N2022G012), Funded by the China State Railway Group Co., Ltd. (N2022G012);

国家自然科学基金资助项目(61661027), National Natural Science Foundation of China (61661027)

作者简介: 顾桂梅(1970-), 女, 辽宁兴城人, 兰州交通大学教授

[†]通信联系人, E-mail: 812711926@qq.com

current collection safety. In 4C (Catenary Condition Monitoring and Analysis System) inspections, image quality is often degraded by noise, motion blur, and compression artifacts, leading to low contrast and missing details. This results in suboptimal localization accuracy and high miss rates in detecting fine-grained defects such as missing nuts and contaminated insulators. To address this, we propose a two-stage framework combining image enhancement and object detection. A Spatial-Frequency Joint Attention network (SFAR-Net) enhances fine details in low-quality images, improving target visibility. Enhanced images are then processed by an improved YOLOv12 detector. To tackle insufficient feature representation for small, multi-scale targets in complex backgrounds, a Dynamic Multi-Scale Frequency-Domain Adaptation Module (DMFA) is incorporated, enhancing attention to critical regions. SFAR-Net achieves a PSNR of 39.08 dB, an SSIM of 0.9747, and an LPIPS of 0.1014, demonstrating excellent comprehensive performance in image fidelity, structural preservation, and perceptual quality. In downstream detection, SFAR-Net improves the mAP@0.5 of YOLOv12 from 71.4% to 73.6%; with the DMFA module, the final framework achieves an mAP@0.5 of 74.9% and an mAP@0.5:0.95 of 65.9%. This method offers a robust technical solution for intelligent defect detection of high-speed railway catenary support devices.

Key words: high-speed railway catenary support device; defect detection; image enhancement; YOLOv12; spatial-frequency joint attention (SFAR-Net); dynamic multi-scale frequency-domain adaptation module (DMFA)

高速铁路的发展对牵引供电系统的稳定运行提出了极高要求。作为系统的核心单元，接触网支持装置承担着支撑、定位与绝缘等关键功能，其状态直接影响受流安全^[1]。然而，支持装置在长期服役中易出现螺母缺失、绝缘子脏污等缺陷，若识别不及时，将严重危害行车安全。因此，开展高精度、智能化的故障检测研究具有重要的工程意义。目前，基于 4C 检测系统的自动巡检图像分析已成为主流手段。但在实际场景中，受列车震颤、成像距离及户外光照等因素干扰，采集到的图像部分存在对比度低、运动模糊及压缩伪影严重等问题。这导致现有检测算法面临特征提取困难与定位准度差等挑战。

针对低质量图像，相比于成本高昂的硬件优化，基于算法的图像增强方案因其灵活性成为提升识别性能的关键。现有增强方法多聚焦于空间域特征建模^[2-3]，但在应对复杂复合退化时，单纯的空域建模难以充分表征全局频率分布。频域信息在描述纹理增强与边缘重建方面具有独特优势。已有研究表明，联合空频域特征能有效提升图像感知质量，但面向高铁巡检场景的耦合增强研究仍较为有限。另一方面，目标检测已在工业检测等任务中取得显著进展。

现有基于深度学习的目标检测方法大致分为一阶段和两阶段两类。一阶段检测算法如 YOLO 系列^[4-6]，通过单次前向传播实现目标定位与分类，具有较高检测效率；两阶段检测算法通常先生成候选区域，再完成分类与边界框回归，具有较高检测精度，但计算开销大。尽管已有研究针对接触网相关故障检测开展了探索，并取得了一定成果，如顾桂梅等^[7]基于改进的 SSD 算法实现了吊弦线夹螺栓检测，但现有方法大多侧重于检测网络结构改进，对低质量巡检图像带来的特征退化问题关注不足。

针对现有级联方案在任务逻辑与特征流转上的局限性，本文提出一种任务驱动的 SFAR-Net 与 YOLOv12-DMFA 深度协同方案。该方案首先通过空频联合注意力机制实现视觉修复与语义增强的有机融合，有效弥补了不利成像条件下细粒度缺陷因表征能力受限而导致的语义信息损失。在此基础上，引入 DMFA 模块，利用多尺度局部适配实现特征层级的动态对齐与补偿，显著强化了模型对螺母及绝缘子等关键语义区域的特征聚焦能力与定位精度，从而实现了底层图像增强与高层目标检测任务的高效协同。

1 方法构想与实现流程

高铁接触网部分图像存在运动模糊、对比度低及目标重叠等退化问题，制约了螺母与绝缘子等中小目标的识别准度。为此，本文提出一种“视觉增强-特征自适应”深度耦合的两阶段架构。整体思路与处理流程如图 1 所示。

第一阶段 SFAR-Net 采用空频双分支并行结构，利用频域提取分支重构全局结构信息，同步结合空

域提取分支还原局部纹理细节；两路双分支的特征汇合后进入频域自注意力（fast fourier transform self-attention, FFTSA）模块，通过对融合特征进行频域全局建模与加权，为后续检测任务提供高质量的视觉表征。在第二阶段，本研究将 DMFA 模块集成于 YOLOv12 中，构建 A2C2f-DMFA 耦合架构，显著强化了模型对螺母、绝缘子等目标的判别性特征捕获精度，有效提升了在复杂背景下的目标定位准确性。




图 1 SFAR-Net+YOLOv12-DMFA 两阶段框架

Fig.1 Two-stage framework with SFAR-Net and YOLOv12-DMFA

2 空频联合注意力图像增强网络

在 4C 接触网检测任务中，震动、姿态变化及复杂照度诱发的非各向同性模糊与压缩伪影，导致螺母、绝缘子等目标的边缘与纹理发生严重语义衰减。鉴于频域表征对模糊与退化具有高度敏感性，但存在空间定位信息缺失的局限，本文构建了空频并行特征提取模块：频域分支旨在强化高频细节与纹理重构，空域分支则负责保持空间结构与长程依赖。通过双域特征互补，有效提升了模型在复合退化环境下的特征表达与后续检测的可靠性。

2.1 频域分支

在双分支架构中，频域分支首先将输入图像映射至频域以解耦高低频成分。为兼顾局部建模与全局频率交互，该分支同步利用常规卷积提取细粒度局部特征，并结合基于快速傅里叶变换（fast fourier transform, FFT）的卷积实现大感受野频率聚合。提取后的特征经逆离散余弦变换（inverse discrete cosine transform, IDCT）重返空间域，确保与空域分支在统一表征空间内实现高效融合。该过程的形式化表示如下：

$$\mathbf{F} = T_{\text{DCT}}(\mathbf{I})$$

$$\hat{\mathbf{F}} = \phi_c(\phi_{\text{FFT}}(\mathbf{F}))$$

$$\mathbf{X}_f = T_{\text{DCT}}^{-1}(\hat{\mathbf{F}}) \quad (1)$$

其中， $\mathbf{I}$ 为输入图像； $\mathbf{F}$ 与 $\hat{\mathbf{F}}$ 分别为变换后与增强后的频域特征； $\mathbf{X}_f$ 为该分支的输出特征； T_{DCT} 与 T_{DCT}^{-1} 分别为 DCT/IDCT 算子； ϕ_{FFT} 表示基于 FFT 的卷积模块； ϕ_c 表示常规卷积堆叠。

2.2 空域分支

为弥补频域分支在结构稳定性上的不足，空域分支通过建模长程依赖与保持结构一致性，提升了复杂背景及遮挡下的定位鲁棒性。该分支引入非局部稀疏注意力（non-local sparse attention, NLSA），利用球面局部敏感哈希将特征进行分桶计算，在保留非局部全局上下文聚合能力的同时显著降低了计算复杂度。设空间特征序列为 $\{\mathbf{x}_i\}_{i=1}^N$ ，桶映射为 $B(i)$ ，则桶内注意力可表示为：

$$\mathbf{y}_i = \sum_{j \in B(i)} \alpha_{ij} g(\mathbf{x}_j)$$

$$\alpha_{ij} = \text{softmax}_{j \in B(i)}(f(\mathbf{x}_i, \mathbf{x}_j)) \quad (2)$$

其中， $\mathbf{y}_i$ 为位置聚合特征； α_{ij} 为注意力权重； f 与 g 分别为相似度函数与线性嵌入。利用 softmax 归一化相似度，实现稀疏约束下的长程依赖建模。

2.3 空频特征融合策略

在完成频域分支对高频纹理的初步强化与空域分支对全局结构及长程依赖的建模后，针对其属性

迥异的空频异构特征，深度整合是实现高质量图像增强的关键。

为消除两域特征间的语义鸿沟，本文首先通过通道对齐平抑量级分布差异，随后利用FFTSA模块实现全图尺度的“结构引导细节”动态交互。该机制利用宏观拓扑约束微观纹理重建（如螺纹细节），并有效抑制冗余噪声与特征冲突，从而为后续检测任务构建高保真、强判别性的特征表征空间。

2.3.1 跨域特征级联与通道对齐




图2 空频双分支特征提取模块

Fig.2 Spatial-frequency dual-branch feature extraction module

其能够在全图尺度下建立长程依赖关系。

2.3.2 频域自注意力模块

虽然初步融合实现了特征叠加，但线性映射难以表征跨频带间的非线性依赖，易导致关键故障特征被背景噪声淹没。为此，本文引入FFTSA^[8]模块，通过在频域执行自注意力计算实现特征权重的自适应重标定。相较于传统的空间域矩阵乘法，FFTSA能够实现更高效的全局依赖建模，精准捕捉不同频带间的相关性，从而强化低频结构与高频细节的协同表达。其结构如图3所示。

首先，通过FFT将输入特征映射到频域表示 F ，从而获得包含局部信息与全局结构的频域特征。接着，频域特征通过线性映射生成查询（ Q ）、键（ K ）

和值（ V ），这些值用于计算自注意力权重并在频域内进行交互。具体来说，注意力权重 α_{ij} 是通过查询与键的内积计算得到的：

$$\alpha_{ij} = \text{softmax} \left(\frac{Q_i \cdot K_j^T}{\sqrt{d_k}} \right) \quad (3)$$

其中， d_k 是键的维度， α_{ij} 表示查询 Q_i 与 K_j 键之间的相似度。通过此权重系数，将其作用于 V_j 值上，进一步增强了频带间的信息融合能力：

$$\text{Attn}(F) = \sum_j \alpha_{ij} \cdot V_j \quad (4)$$

其中， $\text{Attn}(F)$ 是FFTSA模块的核心加权算子，代表自注意力机制对频域特征 F 的加权合并操作，

如图2所示，SFAR-Net提取的空域局部细节与频域全局拓扑特征首先通过通道级联实现初步汇聚。为确保异构特征在融合过程中的语义一致性并抑制潜在的特征冗余，本节利用轻量级卷积层执行特征维度的自适应映射与通道对齐。该卷积层通过特征动态重加权，在压缩冗余特征的同时强化了跨域特征间的非线性交互，从而构建起统一的联合表征空间。为后续的高阶空频特征融合奠定了数据基础。




图3 FFTSA 模块

Fig.3. FFTSA module

3 YOLOv12 目标检测算法

针对高铁4C巡检中细粒度目标易受成像退化干扰的挑战，本文采用兼顾实时性与精度的YOLOv12^[9]作为基线检测器（图4）。其结构由用于多尺度语义提取的Backbone、强化跨尺度特征聚合的Neck以及执行状态感知的Head组成。相比传统YOLO架构，YOLOv12的核心优势在于引入了区域注意力（Area Attention）机制，通过高效的区域级信息交互扩大有效感受野，增强了对关键目标的建模能力。




图 4 YOLOv12 结构图

Fig.4. YOLOv12 architecture

3.1 YOLOv12-DMFA

总体而言, YOLOv12 在检测任务中实现了精度与速度的平衡. 然而, 针对接触网支持装置故障检测这一极具挑战性的任务, YOLOv12 仍面临着局限性. 接触网缺陷 (如螺母缺失) 多表现为极细粒度的小目标, 且常处于隧道暗纹、密集承力索与支柱等复杂背景中. 首先, YOLOv12 采用的标准卷积算子受限于固定的局部感受野, 在深层下采样过程中

难以有效捕获跨区域的长程上下文信息. 其次, 高铁巡检场景中普遍存在的冗余信息会引入大量背景响应, 干扰了检测网络对关键缺陷特征的精准提取.

为了克服这些瓶颈, 本文在 YOLOv12 的骨干网络与特征融合网络关键节点处引入了 DMFA 模块, 其整体架构如图 5 所示.




图 5 YOLOv12-DMFA 结构图

Fig.5. YOLOv12-DMFA architecture

如图 6 所示, DMFA 模块通过整合动态特征融合网络^[10](Dynamic Feature Fusion Network, DFFN)、动态调优模块^[11](Dynamic Tuning, DyT)和多认知视觉适配器^[12] (Multi-cognitive Visual Adapter, Mona) 三大组件显著提高了 YOLOv12 在细粒度缺陷检测中的能力. 其中, DFFN 模块利用多维特征自适应对齐机制, 有效补偿了运动模糊等因素造成的边缘纹理损失; DyT 模块借鉴 Transformer 标准化层设计,

实现了不同退化环境下特征表示的全局一致性增强; Mona 模块则通过集成多尺度卷积滤波器的多认知设计, 利用深度可分离卷积对不同层级的语义特征进行精炼与精确对齐, 增强了对复杂背景下细粒度目标的捕获能力. DMFA 模块通过这三大组件的协同工作, 显著改善了图像在低照度、复杂背景等严苛条件下的表征能力.




图 6 DMFA 模块结构示意图
Fig.6 Architecture of the DMFA module

3.1.1 DFFN 模块

DFFN 模块作为 YOLOv12-DMFA 的组件之一，其结构如图 7 所示，通过逐通道卷积（depthwise convolution, DWConv）与线性变换的高效耦合优化了多尺度特征融合。其核心引入了多维特征自适应对齐机制，通过动态滤波算子根据图像退化程度（如运动模糊）在空间、频域及数值维度上动态重构频率拓扑并调节融合策略。




图 7 DFFN 结构图
Fig.7 DFFN architecture

3.1.2 DyT 模块

DyT 模块（图 8）作为 YOLOv12-DMFA 的关键组件，旨在提升复杂环境下的特征鲁棒性。该模块受 Transformer 归一化层启发，通过动态调制逐层特征的动态范围来优化特征表达。区别于传统静态归一化，DyT 引入了内容自适应调节机制，能够基于输入图像特征实时优化特征分布，显著增强了模型的环境适应能力。其核心操作定义如下：

$$\text{DyT}(\mathbf{x}) = \gamma \tanh(\alpha \cdot \mathbf{x}) + m \quad (5)$$

其中， $\mathbf{x}$ 为输入特征； α 是一个可学习的标量； $\tanh$ 是双曲正切函数； γ 和 m 是可学习的参数，分别对应特征的缩放和偏移，使得每一层的特征表达更具灵活性。




图 8 DyT 结构图
Fig.8 DyT architecture

3.1.3 Monalayer 模块

Monalayer 模块（图 9）通过引入多认知视觉滤波器设计，显著增强了网络对多维度视觉特征的感知能力。不同于依赖线性滤波器的传统适配器，Monalayer 利用多尺度的 DWConv 提取多样化特征，在保持参数高效性的同时提升了视觉信息的传递效率。结合上/下投影结构，该模块实现了特征空间的动态优化与表达增强，有效提升了网络处理复杂巡检任务的鲁棒性。其计算过程可以通过以下公式表达：

$$\mathbf{x}_{\text{norm}} = s_1 \cdot |\mathbf{x}_0|_{\text{LN}} + s_2 \cdot \mathbf{x}_0 \quad (6)$$

其中， $\mathbf{x}_0$ 是输入特征； $\mathbf{x}_{\text{norm}}$ 表示经过多认知视阈加权后的输出特征；LN 代表层归一化算子； s_1 和 s_2 是可学习的权重，用于调节输入特征的分布。接下来，特征经级联的 DWConv 与 1×1 卷积实现多尺度融合，并结合 GeLU 激活与上投影完成输出重构，辅以残差连接优化信息流转。




图 9 Monalayer 结构图

Fig.9 Mona architecture

4 实验分析

4.1 数据集介绍

本文数据集依托高铁 4C 装置自动采集构建, 覆盖多运行速度及复杂气象工况, 有效弥补了领域内缺乏多类型、跨场景共用缺陷数据集的不足.




图 10 典型的故障识别图像与正常图像
Fig.10 Typical Fault Identification Image and Normal Image

针对真实工况中配对样本匮乏的问题, 本文在 2500 张高清图像基础上, 借鉴 BSRGAN^[13]的退化流水线设计思想 (图 11), 通过随机退化算子序列生成合成配对数据. 该策略确保了合成样本与现场采集的 668 张真实低质图像分布趋同, 使 SFAR-Net 能够学习稳健的图像增强映射, 从而为后续 YOLOv12-DMFA 检测网络构建统一的高质量特征表征空间.

4.2 实验环境配置

本文实验基于 PyTorch 2.7.1 框架与 Python 开发, 运行于配备双路 Montage Jintide C5218R CPU 及 NVIDIA RTX A40 (24GB) GPU 的工作站 (软件环境包含 CUDA 11.8 与 CuDNN9.7). 所有样本通过 X-AnyLabeling 工具标注, 具体训练超参数详见表 1. 为确保对比评估的严谨性与公平性, 所有基准模型均在相同的硬件平台与数据集划分下, 遵循

实验涵盖四类典型目标: nut_normal (382 张)、nut_missing (1400 张)、Insulator_normal (1000 张) 与 Insulator_pollution (386 张), 典型样本如图 10 所示. 为确保评估严谨性, 本文按约 7:1:2 的比例将数据集划分为训练集 (2199 张)、验证集 (631 张) 与测试集 (338 张), 并严格执行“场景、ID 隔离”原则以防止数据泄露.

其官方推荐的最优配置进行训练.




图 11 借鉴 BSRGAN 的实用退化模型示意图
Fig.11 Schematic of the BSRGAN-inspired practical degradation model

表 1 训练超参数设置

Tab.1 Training hyperparameter settings

超参数项目	批量	初始学习率	学习率衰减系数	终止学习率	学习率动量	训练轮次	IoU
数值	16	0.01	0.01	0.001	0.937	250	50

4.3 SFAR-Net 图像增强实验分析

为验证 SFAR-Net 在复杂工况下的增强性能及其对下游检测任务的增益, 本文选取 U-Net、NAFNet^[14]、Uformer-B^[15]及 Restormer^[16]作为对比基准. 评估体系涵盖像素级保真度 (PSNR)、结构相似性 (SSIM^[17]) 及感知质量 (LPIPS^[18]) 三个维度, 旨在全面衡量模型对低质量巡检图像的增强效

果. 各指标定义如下:

$$\text{PSNR} = 10 \times \log_{10} \left(\frac{\text{MAX}^2}{\text{MSE}} \right)$$

$$\text{SSIM}(\mathbf{x}, \mathbf{y}) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_2)(\sigma_x^2 + \sigma_y^2 + C_2)}$$

$$\text{LPIPS}(x, y) = \frac{1}{N} \sum_i \|\phi(x) - \phi(y)\| \quad (7)$$

其中, MAX 为图像的最大像素值; MSE 为均方误差; μ_x 和 μ_y 分别为两幅图像的均值; σ_x 和 σ_y 为方差; σ_{xy} 为协方差; C_1 和 C_2 为稳定化常数; ϕ 为预训练网络提取的特征; N 为网络层数.

相应定量结果如表 2 所示, SFAR-Net 在 PSNR (39.08 dB)、SSIM (0.9747) 与 LPIPS (0.1014) 指标上均表现最优. 优异的 PSNR 与 SSIM 印证了其卓越的像素保真度与结构保持能力, 而最低的 LPIPS 值则反映出增强图像在感知层面最契合真实分布. 在此基础上, 本文进一步从微观像素(图 12)与宏观结构(图 13)两个维度展开定性对比. 视觉评估结果有力佐证了上述定量分析.

针对 U-Net 算法, 该经典架构虽能捕捉部分低级特征, 但在处理低照度及模糊图像时表现乏力, 尤其在高频细节增强上严重欠缺, 导致图像整体模糊. 定量结果显示, U-Net 的各项指标均为最低 (PSNR 37.03 dB, SSIM 0.9710, LPIPS 0.1078). 由图 13(b)可见, 其对绝缘子等部件的边缘增强极度模糊, 细节丢失严重. 相比之下, SFAR-Net 在处理螺母缺失等小目标缺陷时, 能够实现更精细的纹理还原.

NAFNet 虽提升了全局依赖建模能力, 但对小目标缺陷的增强效果欠佳. 如图 12(c)和图 13(c)所示, 其在像素边缘锐度与结构完整性方面均有所欠

缺. 尽管其 PSNR (37.28 dB) 优于 UNet, 但 LPIPS 指标 (0.1069) 依然偏高, 表明其生成的图像在视觉感知质量上仍未达到理想标准, 难以满足复杂工况下的巡检需求.

Uformer-B 凭借 Transformer 架构在全局信息建模上具有优势, 但在细粒度特征与高频细节增强方面仍显不足. 定量数据显示, 其 PSNR (37.42 dB) 与 SSIM (0.9728) 虽处于中等水平, 但在不利光照条件下对微小语义信息的提取能力受限, 其增强后的图像细节丰富度不及 SFAR-Net.

Restormer 融合了残差模块与 Transformer 架构, 在处理大尺度图像退化时表现良好, 但是其在复杂背景下的纹理增强方面仍存在瓶颈. 定量分析中, Restormer 虽获得较高的 PSNR (38.72 dB), 但 LPIPS (0.1048) 仍高于本文方法. 视觉对比显示, Restormer 生成的纹理存在轻微模糊感, 且在结构级部件的边缘锐度上仍逊色于 SFAR-Net.

综上所述, SFAR-Net 在低照度与模糊等复杂环境下展现出显著优越性. 通过空频双分支特征提取和频域自注意力机制的协同设计, 实现了深度空间-频率特征融合. 实验一致证明, SFAR-Net 无论在宏观结构还是微观像素层面, 均能实现对真实场景的高保真还原, 体现了卓越的视觉重建能力与语义保持效果.

表 2 不同图像增强方法的定量对比

Tab.2 Quantitative comparison of different image enhancement methods

	PSNR/dB	SSIM	LPIPS
U-Net	37.03	0.9710	0.1078
NAFNet	37.28	0.9713	0.1069
Uformer-B	37.42	0.9728	0.1075
Restormer	38.72	0.9737	0.1048
SFAR-Net	39.08	0.9747	0.1014




图 12 不同算法的图像增强效果对比（像素级细节）

Fig.12 Comparison of image enhancement effects at the pixel-level micro-details




图 13 不同算法的图像增强效果对比（结构级部件）

Fig.13 Comparison of image enhancement effects at the structural-level macro-components

4.4 目标检测实验分析

为全面评估 YOLOv12-DMFA 的检测性能，本文设计了两组实验：

1) 消融实验：通过依次引入 DFFN、DyT 及 Mona 模块（即完整的 DMFA），定量分析各核心组件对检测增益的贡献；

2) 对比实验：通过选取主流算法 Faster R-CNN、DEIM-D-FINE、RT-DETR 及 UAV-DETR 作为对比基准。评估指标涵盖 $mAP@0.5$ 、参数量（Params）及推理速度（fps）等，旨在从精度、复杂度和实时性三个维度确保评价的全面性与公平性。

$$\begin{aligned}
 P &= \frac{TP}{TP+FP} \\
 R &= \frac{TP}{TP+FN} \\
 AP &= \int_0^1 P(R) dR \\
 mAP@0.5 &= \frac{1}{N} \sum_{i=1}^N AP_i \\
 mAP@0.5:0.95 &= \frac{1}{10} \sum_{k=0}^9 \left(\frac{1}{N} \sum_{i=1}^N AP_i \right) \\
 F_1 &= 2 \times \frac{P \times R}{P + R} \\
 fps &= \frac{N}{T}
 \end{aligned} \tag{8}$$

其中：TP、FP、FN 分别表示真正例、假正例与假负例数量； P 和 R 分别为精确率与召回率； AP 为平均精度； mAP 为所有类别的平均精度； N 为类别总数； T 为推理总耗时； F_1 是 P 和 R 的调和

平均数，用于衡量模型的综合表现；fps 为每秒推理帧数。

4.4.1 消融实验

为验证各模块贡献，表 3 与图 14 展示了逐步引入 SFAR-Net 及 DMFA 组件后的性能增益与可视化结果。基线模型在低质图像中受模糊与噪声干扰严重，边缘特征退化导致置信度较低且漏检明显（图 14(a)）。

引入 SFAR-Net 后， $mAP@0.5$ 与 $mAP@0.5:0.95$ 分别提升至 73.6% 和 64.1%。如图 14(b) 所示，图像清晰度的显著改善使目标置信度从 0.59 优化至 0.67，为检测阶段提供了高质量底层特征输入。

加入 DFFN 后， $mAP@0.5$ 增至 73.8%，有效找回了原本因模糊而漏检的目标（图 14(c)），显著增强了模型对弱纹理特征的判别稳定性。

随后引入 DyT 模块，虽 $mAP@0.5$ 出现小幅波动，但 $mAP@0.5:0.95$ 回升至 64.2%。该现象源于 DyT 的自适应特征缩放机制：通过抑制特征图离群值产生“特征挤压”效应，虽在低阈值下限制了部分极弱特征表达，但显著精细化了边界框回归过程，提升了高精度区间的定位性能（图 14(d)）。

最终集成 Mona 后，该模型达到最优性能（ $mAP@0.5$ 为 74.9%、 $mAP@0.5:0.95$ 为 65.9%）。如图 14(e) 所示，该模块通过强化关键区域表征并抑制背景干扰，使目标置信度提升至 0.76，显著优化了密集目标的检出率。这验证了 Mona 在增强语义表达及确保复杂巡检场景下检测完备性方面的核心价值。

表 3 消融实验结果

Tab.3 Results of ablation experiments

方案	SFAR-Net	DFFN	DyT	Mona	平均精度 AP/%				mAP@0.5/%	mAP@0.5:0.95/%	F ₁ -score/%
					螺母正常	螺母缺失	绝缘子正常	绝缘子脏污			
1	×	×	×	×	95.6	69.9	49.4	70.5	71.4	59.8	70.7
2	✓				98.5	73.0	49.8	73.9	73.6	64.1	73.6
3	✓	✓			98.0	71.8	52.3	73.1	73.8	62.8	74.1
4	✓	✓	✓		98.5	71.2	49.9	74.9	73.4	64.2	73.7
5	✓	✓	✓	✓	98.7	75.3	49.8	75.7	74.9	65.9	74.2




图 14 消融实验中各模块对检测性能增益的视觉对比 ((a)-(e)依次为各阶段累加效果)

Fig.14 Visual comparison of detection performance gain in the ablation study (stages (a)-(e) correspond to the sequential addition of each module).

4.4.2 不同算法性能比较

为全面验证算法优越性, 选取 Faster R-CNN、DEIM-D-FINE、RT-DETR 及 UAV-DETR 为对比模型. 实验结果如表 4 所示, 可见, 经典算法 Faster R-CNN 在复杂背景下精度 (mAP@0.5 为 59.9%) 与推理速度 (17.1 fps) 均受限. DEIM-D-FINE 在小目标检测 (螺母缺失 AP 达 69.6%) 及低延迟场景下表现优异 (204.8 fps), mAP@0.5 提升至 70.4%. 相比之下, RT-DETR 与 UAV-DETR 虽然提升了定位精度 (mAP@0.5 分别为 68.3%与 67.7%), 但受

限于较大的模型体积 (最高 77.0 MB) 与相对较低的推理速度 (均低于 75 fps), 难以满足边缘设备的高效部署.

本文算法通过集成 SFAR-Net 增强网络与 DMFA 模块, 在性能与效率上实现了显著平衡: mAP@0.5 提升至 74.9%, mAP@0.5:0.95 达 65.9%, 推理速度高达 230.1 fps 且模型仅 6 MB. 结果表明, 该方法满足了高铁 4C 巡检车的需求, 且显示出极高的性能与效率比.

表 4 不同算法检测性能对比

Tab.4 Comparison of detection performance of different algorithms

模型	平均精度 AP/%				mAP@0.5/%	mAP@0.5:0.95/%	Parameters/M	Size/MB	fps
	螺母正常	螺母缺失	绝缘子正常	绝缘子脏污					
Faster R-CNN	90.3	58.3	37.9	52.9	59.9	47.4	41.36	493.0	17.1
DEIM-D-FINE	90.6	69.6	49.8	71.6	70.4	51.7	3.72	14.5	204.8
RT-DETR	97.5	74.0	48.0	53.5	68.3	56.2	19.88	77.0	65.9
UAV-DETR	98.1	68.9	41.6	61.7	67.7	56.5	21.25	41.3	74.2
本文算法	98.7	75.3	49.8	75.7	74.9	65.9	2.82	6.0	230.1

5 结论

1) 针对 4C 巡检图像的低照度与模糊问题, 提出 SFAR-Net 架构. 通过空频双分支提取与频域自注意力机制, 实现了显著的亮度提升与纹理重构.

指标均优于主流算法,从源头增强了细粒度缺陷的可辨性。

2) 在检测阶段,构建以 YOLOv12 为基准的 DMFA 模块,集成 DFFN 局部融合、DyT 分布优化及 Mona 关键区域强化技术,显著提升了多尺度表征与背景抑制能力。

3) 从工程应用角度看,本文方法在实现精度增益的同时,兼顾了计算效率与轻量化指标。模型推理速度快、稳定性高,能够满足 4C 检测车快速响应的需求,具备优异的精度-效率平衡及广阔的工程应用前景。

4) 尽管模型整体性能提升显著,但“绝缘子正常”类别由于弱纹理特征及复杂背景干扰,导致其判别边界仍存在不稳定性,识别难度相对较大。为此,后续研究将聚焦于难例扩充和目标对齐增强策略,旨在进一步提升模型在复杂表观变化下的泛化能力与识别精度。

参考文献:

- [1] 张毅,甄云飞.重载铁路接触网 4C 缺陷识别方法研究[J].设备管理与维修,2023(22): 100-101.
ZHANG Y, ZHEN Y F. Research on defect identification method of catenary 4C in heavy-haul railway[J]. Plant Maintenance Engineering, 2023(22): 100-101. (in Chinese)
- [2] 巩固.矿井环境下机器人目标识别算法研究[D].徐州:中国矿业大学,2020.
GONG G. Study on robot target recognition algorithm in coal mine environment[D]. Xuzhou: China University of Mining and Technology, 2020. (in Chinese)
- [3] 牟琦,魏妍妍,李姣,等.改进的 Retinex 低照度图像增强算法研究[J].哈尔滨工程大学学报,2018,39(12): 2001-2010.
MU Q, WEI Y Y, LI J, et al. Research on the improved Retinex algorithm for low-illumination image enhancement [J]. Journal of Harbin Engineering University, 2018, 39(12): 2001-2010. (in Chinese)
- [4] 仲元昌,陈宇,杨子楚,等.面向小型无人机检测应用的改进 YOLOv8 算法[J].湖南大学学报(自然科学版),2025,52(4):57-67.
ZHONG Y C, CHEN Y, YANG Z C, et al. Improved YOLOv8 algorithm for small UAV detection applications[J]. Journal of Hunan University (Natural Sciences), 2025, 52(4):57-67. (in Chinese)
- [5] WANG C Y, BOCHKOVSKIY A, LIAO H M. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 17-24, 2023, Vancouver, BC, Canada. IEEE, 2023: 7464-7475.
- [6] REDMON J, FARHADI A. YOLOv3: an incremental improvement[EB/OL]. 2018: arXiv: 1804.02767. <https://arxiv.org/abs/1804.02767>.
- [7] 顾桂梅,王小亮.深度学习的接触网小目标缺陷识别研究[J].电子测量与仪器学报,2024,38(4): 151-160.
GU G M, WANG X L. Identification of the catenary small target defects in deep learning[J]. Journal of Electronic Measurement and Instrumentation, 2024, 38(4): 151-160. (in Chinese)
- [8] KONG L S, DONG J X, GE J J, et al. Efficient frequency domain-based transformers for high-quality image deblurring[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 17-24, 2023, Vancouver, BC, Canada. IEEE, 2023: 5886-5895.
- [9] TIAN Y J, YE Q X, DOERMANN D. YOLOv12: attention-centric real-time object detectors[EB/OL]. 2025 : arXiv : 2502.12524. <https://arxiv.org/abs/2502.12524>.
- [10] DAI T, WANG J P, GUO H, et al. FreqFormer: frequency-aware transformer for lightweight image super-resolution[C]//International Joint Conference on Artificial Intelligence. 2024.
- [11] ZHU J C, CHEN X L, HE K M, et al. Transformers without Normalization [J/OL]. arXiv preprint arXiv:2505.02530v2, 2025 [2026-05-10]. <https://arxiv.org/abs/2503.10622>.
- [12] YIN D S, HU L Y, LI B, et al. 5%>100%: breaking performance shackles of full fine-tuning on visual recognition tasks[C]//2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 10-17, 2025. Nashville, TN, USA. IEEE, 2025: 20071-20081.
- [13] ZHANG K, LIANG J Y, VAN GOOL L, et al. Designing a practical degradation model for deep blind image super-resolution[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). October 10-17, 2021, Montreal, QC, Canada. IEEE, 2022: 4771-4780.
- [14] CHEN L Y, CHU X J, ZHANG X Y, et al. Simple baselines for Image restoration[C]//Computer Vision - ECCV 2022. Cham: Springer, 2022: 17-33.
- [15] WANG Z D, CUN X D, BAO J M, et al. Uformer: a general U-shaped transformer for image restoration[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 18-24, 2022, New Orleans, LA, USA. IEEE, 2022: 17662-17672.
- [16] ZAMIR S W, ARORA A, KHAN S, et al. Restormer: efficient transformer for high-resolution image restoration[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). June 18-24, 2022, New Orleans, LA, USA. IEEE, 2022: 5718-5729.
- [17] HORÉ A, ZIOU D. Image quality metrics: PSNR vs. SSIM[C]//2010 20th International Conference on Pattern Recognition. August 23-26, 2010, Istanbul, Turkey. IEEE, 2010: 2366-2369.
- [18] ZHANG R, ISOLA P, EFROS A A, et al. The unreasonable effectiveness of deep features as a perceptual metric[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. June 18-23, 2018, Salt Lake City, UT, USA. IEEE, 2018: 586-595.