

基于 DFR-SN-YOLO 的棉花顶芽识别方法

方会敏^{1,2}, 徐全旺¹, 陈学庚^{1,3}, 张庆怡^{1,2*}, 鲁佳录¹

(1. 江苏大学农业工程学院, 镇江 212013; 2. 现代农业装备与技术教育部重点实验室(江苏大学), 镇江 212013;

3. 石河子大学机械电气工程学院, 石河子 832003)

摘要: 针对密植环境下棉花顶芽漏检率高、检测精度低等问题, 该研究提出了一种 DFR-SN-YOLO 的棉花顶芽检测模型。首先, 使用 DWConv 和改进后的 C3_Faster 重设轻量高效的主干, 进行有效卷积提取顶芽特征; 其次针对顶芯漏检问题, 基于棉田顶叶和顶芯位置相对的结构关联性, 通过在主干引入具有识别位置信息的 CA (coord attention) 注意力获取更多顶芯信息特征, 结合颈部网络改进的 C3_RFCBAMConv 模块, 融入感受野注意力的卷积, 提高模型在全局特征识别到顶芯的能力; 最后, 提出一种针对顶芽识别的 SN (Shape-NWD-IoU) 损失函数, 考虑顶芽自身形状同时注重小目标的提取, 提高对顶芽的识别能力。试验结果表明, DFR-SN-YOLO 相较于原模型, 平均检测精度 mAP@50 为 97.5%, 提高了 3 个百分点; 顶芯准确率为 92.4%, 提高了 3.9 个百分点; 召回率达到 95.0%, 有效解决了顶芯漏检的问题, 同时模型参数量为 3.9M 下降 44%; 部署在边缘计算设备上, 推理速度为 37 帧/s, 研究结果为后续棉花智能机械打顶提供了技术支持。

关键词: 棉花顶芽; 图像识别; 边缘部署; YOLOv5s; 小目标; 结构关联性

doi: 10.11975/j.issn.1002-6819.202503208

中图分类号: S24

文献标志码: A

文章编号: 1002-6819(2025)-17-0162-13

方会敏, 徐全旺, 陈学庚, 等. 基于 DFR-SN-YOLO 的棉花顶芽识别方法[J]. 农业工程学报, 2025, 41(17): 162-174.

doi: 10.11975/j.issn.1002-6819.202503208 <http://www.tcsae.org>

FANG Huimin, XU Quanwang, CHEN Xuegeng, et al. Cotton top bud recognition method based on DFR-SN-YOLO[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(17): 162-174. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202503208 <http://www.tcsae.org>

0 引言

棉花作为中国重要的经济作物之一, 产量和出口量均位于世界前列^[1]。打顶是棉花种植过程中的重要一环, 通过抑制顶端生长优势控制主茎生长, 减少无效果枝对水肥的徒耗, 具有显著的增产增收效果^[2]。目前, 棉花打顶主要通过人工、化控和机械方式。人工打顶强度大、成本高、效率低, 无法保证打顶工作的及时完成; 化控打顶易引发药害和土壤残留, 且过量化控极易减产; 机械打顶通过物理摘除顶芽, 无药剂依赖, 减少环境危害的同时效率高, 适合规模化种植。因此, 越来越多的学者开始了棉花机械打顶技术与装备的研究^[3]。如何在田间密植环境下精准识别顶芽, 是实现棉花精准机械打顶的基本前提^[4]。

计算机视觉技术在农业领域的广泛应用, 推动农业生产不断向高效率、高质量方向发展^[5]。在棉花种植领域, 计算机视觉可以识别棉花、杂草等, 检测棉花病虫害及预测棉花产量等, 这些技术为棉花智能化种植提供

了重要保障。FAN 等^[6]通过采用 ShuffleNet v2、三级 BiFPN 和混合注意力机制 PHAM 重构了特征提取模块, 提出了一种基于 YOLOv5 的棉花和杂草轻量检测模型。陈柯屹等^[7]针对棉花顶芽小不易识别的问题, 提出了一种融合动态机制的 Faster R-CNN 识别方法, 识别单一顶芽速度为 10.3 帧/s。亚森江·白克力等^[8]提出了一种改进 YOLOv4-tiny 的轻量化棉花顶芽识别方法, 识别单一顶芽的推理时间为 71 ms。彭炫等^[9]为提高复杂情况下棉花顶芽的识别率, 以顶芯为研究对象, 通过增加更小尺度检测层融合 CBAM 注意力机制提出了一种改进 YOLOv5 顶芽识别模型, 顶芯识别准确率达到 92.8%。XIE 等^[10]为获得精准顶芽定位, 提出一种 CBLN-YOLO 顶芽分割算法, 使用 LDConv 代替传统卷积降低参数量, 同时使用 CA (coord attention) 注意力提取更多顶芽细节特征, 使用 Inner Clou 损失函数计算回归损失, 并在自建数据集取得不错效果。赵露强等^[11]针对边缘设备算力差、运动模糊等问题, 采用 ShuffleNetv2 轻量化主干和 DySample 动态上采用模块提出 CottonBud-YOLOv5s 轻量型顶芽检测模型, 具有较高检测精度, 检测速度达 27 帧/s。韩鑫等^[12]设计了基于顶芽识别的化学打顶系统, 其中识别系统采用 YOLOv5 对顶芽进行识别, 由 32 单片机控制喷药系统对顶芽变量喷洒化学打顶药剂。刘润飞^[13]针对棉花病虫害检测问题, 提出了一种基于改进 YOLOv8 的棉花虫害检测算法, 通过使用 DCNv3 替换主干网络中的普通卷积, 并加入通道注意力机制, 在提升精度同时实现了对病虫害的实时检测。刘祥等^[14]以脱

收稿日期: 2025-03-26 修订日期: 2025-06-17

基金项目: 中国博士后科学基金项目 (2023M741433 和 2025M772490); 江苏大学高级人才基金项目 (22JDG041); 山东省重点研发计划项目 (乡村振兴科技创新提振行动计划) (2024TZXD058)

作者简介: 方会敏, 副教授, 研究方向为高效田间管理技术与装备。

Email: fanghuimin@ujs.edu.cn

*通信作者: 张庆怡, 讲师, 研究方向为智能农机装备。

Email: zhangqingyi@ujs.edu.cn

叶期密植棉为研究对象,结合无人机提出了一种 RCH-UNet 模型,将网络中的 CBR 下采样模块替换为 ResNet50,同时引入 CA 注意力和 Hardwish 激活函数,增强了复杂环境下棉花的分割效果。

同一棉田里不同棉花植株之间生长状况不同^[15],上述研究通常将单一特征(顶芯或顶叶)作为识别目标。但是,由于顶芯尺寸较小,容易被遮挡,直接识别的效果较差。而顶叶的形态、颜色和尺寸受到棉株个体生长差异影响,识别效果不稳定,易被棉株的其余展开叶影响。本研究同时将顶芯和顶叶作为识别目标,实现当顶芯未被完全遮挡时直接识别出顶芯;当顶芯被完全遮挡时可通过识别顶叶间接确定打顶位置,降低漏打顶或过打顶率。为提高机械打顶准确度,本文以田间密植环境下棉花顶芽(包括顶叶和顶芯)为检测对象,提出了一种棉花顶芽检测模型(DFR-SN-YOLO)。该模型以 YOLOv5 模型为基础,通过采用 DWConv 和 C3_Faster 重构轻量化主干网络,同时在主干网络添加注意力机制,颈部网络融入新型感受野注意力的 C3 模块及提出针对小目标识别新型损失函数 SN-IoU (Shape-NWD-IoU) 的方式,提高模型对顶芯的召回率和准确率,以期智能化打顶提供技术支持。


1 材料与方法

1.1 顶芽数据集的采集


为了建立自然环境下的棉花顶芽数据集,于 2024 年 7 月在新疆石河子市(44.3°N, 86.0°E)和沙湾市(44.2°N, 85.6°E)进行棉田图像采集。本研究模拟棉花打顶设备的作业场景,在距离顶芽 20~40 cm 处和 50~80 cm 处分别使用相机和无人机设备,在单株顶芽、多株遮挡顶芽、多株未遮挡等不同自然状态以及光照较弱、正常光照、强光照等不同光照条件下采集图像,部分数据集样本如图 1 a 所示。

对无人机采集的视频进行抽帧,结合相机拍摄的图片集得到棉花顶芽图像,并进行相同尺寸裁剪后作为数据采集来源,共 1 023 张,为了提高模型的泛化能力,防止训练时因数据集过少造成过拟合现象,采用数据增强方法对数据集进行扩充。考虑到打顶作业中可能遇到晴阴天、灰尘及设备不同角度等情况,本文采取对应随机调整饱和度、添加噪声、角度反转等方式对数据集进行扩充,共得到棉花顶芽图像 5 115 张,并按照 7:2:1 的比例划分为训练集、验证集和测试集。

传统人工打顶为摘除棉花顶部“一叶一芯”^[16],即先确认顶芯位置,然后以此为基准进行顶芯和一片顶叶的掐除。综合考虑棉花植株生长特性和棉花种植户经验,现结合实际拍摄图定义顶芯与顶叶。顶叶指棉花植株主茎顶端的叶子,从上方看位于植株的中间位置,顶叶一般颜色更为嫩绿,反映在图像上为有光泽,其梗结的相对位置一般为顶芯,如图 1 b 所示,顶叶是一片嫩叶,用深色矩形框标记;顶芯是一个嫩芽,用浅色矩形框标记。使用 Labelimg 软件对其进行标注,分为顶芯和顶叶 2 类。



a. 部分数据集的示例
a. Examples of partial datasets



b. Labelimg 标注顶芽示例图
b. Labeling labels the apical bud example image

注:(I) 单株未遮挡,(II) 单株遮挡,(III) 单株未遮挡强光照,(IV) 单株遮挡强光照,(V) 多株未遮挡,(VI) 多株未遮挡强光照,(VII) 多株遮挡,(VIII) 多株遮挡强光照。

Note: (I) Single strain unobscured, (II) Single strain occlusion, (III) Single strain unobscured strong light, (IV) Single strains block strong light, (V) Multiple strains unobscured, (VI) Multiple strains unobscured strong light, (VII) Multiple strains occlusion, (VIII) Multiple strains block strong light.

图 1 棉花顶芽数据集样本

Fig.1 Cotton top bud dataset sample

1.2 识别方法

近年来,YOLO 系列模型在目标检测领域取得了重大进展,凭借高精度和快速的推理速度在工业领域发展迅速。为了找到适合棉花顶芽检测的算法模型,本文利用已建立的数据集评估现有常用的 YOLO 模型在顶芯和顶叶识别的推理精度、速度及计算成本等方面的性能,所得结果见表 1,其中本文检测对象有两类:顶芯(小目标)和顶叶(大目标),其准确率、召回率分别用 SP、SR 和 BP、BR 表示。

表 1 YOLO 系列模型的检测结果

Table 1 Detection results of models of YOLO series

模型 Model	准确率 P/%		召回率 R/%		平均精度 mAP@50/ %	参数 Parameter/ M	计算成本 GFLOPs/ G	权重大小 Weight/ MB
	顶芯 SP	顶叶 BP	顶芯 SR	顶叶 BR				
YOLOv3s	89.5	96.3	85.5	95.5	93.8	15.3	43.8	30.9
YOLOv5n	86.7	92.9	81.5	97.7	92.2	1.8	4.1	3.7
YOLOv5s	88.5	96.5	87.0	96.5	94.5	7.0	15.8	14.5
YOLOv8n	85.1	93.8	78.1	96.3	92.7	3.0	8.1	6.1
YOLOv8s	91.9	97.1	85.2	96.5	95.1	11.1	28.4	22.5
YOLOv10n	87.4	92.7	81.0	96.0	92.9	2.7	8.2	5.8
YOLOv10s	91.5	96.4	81.1	94.3	95.2	8.0	24.4	16.5
YOLO 11n	87.9	95.8	79.4	95.9	93.9	2.6	6.3	5.5
YOLO 11s	92.1	95.4	83.8	96.3	96.0	9.4	21.3	19.2

通过表 1 发现在所有模型中顶叶的识别精度(BP)和召回率(BR)值均比较高,对于顶芯召回率(SR)普遍偏低;对顶芯检测效果较好的几个模型分别为

YOLOv5s、YOLOv3s、YOLOv8s 及 YOLO11s, 尽管 YOLOv3、YOLOv8 和 YOLOv11 的顶芯检测准确率 (SP) 高于 v5, 但他们对顶芯的召回率 (SR) 偏低及增加的计算成本可能对处理能力有限的设备带来挑战。同时考虑到模型部署, YOLOv5 具有广泛优化、成熟的工具链以及模型转换和部署的强大支持, 使其更可靠、高效地适用不同硬件设备。综合各种因素后, 最终选择了 YOLOv5s 作为本研究的基准模型。

YOLOv5 网络结构主要包括 4 个部分: 输入、主干网络、颈部网络和检测头。输入是待检测的图像, 通过归一化将图像统一尺寸为 (640×640) 像素后输入检测网络。主干网络是模型的主要特征提取器, 将输入图像经过卷积分割成不同尺寸的特征级提取特征。颈部网络的主要作用则是将主干网络提取到的特征进行整合, 从而提高检测精度, 并传给第 4 部分检测头, 有小、中和大 3 种尺度检测头对目标进行预测。

针对密植环境下棉花顶芽漏检率高、检测精度低问题, 本文提出一种 DFR-SN-YOLO 的网络结构模型, 如图 2 所示。首先设计了一种轻量化的主干结构 DWConv 和 C3_Faster, 将主干中 Conv 模块替换为 DWConv, 通过逐点有效卷积, 减少通道数和参数精简模型的同时更易移植, 并在 C3 模块中融入 Faster 网络, 形成 C3_Faster, 解决了计算复杂度和实际计算速度 (FPS) 问题, 且在主干网络 P5 特征层提取前加入 CA 注意力, 提高小目标检测精度; 在颈部网络中设计了 C3_RFCBAMConv 模块, 将 RFCBAM 感受野注意力融入 C3 中, 提高对顶芽空间位置信息获取的能力, 并通过试验确定了添加位置; 最后, 提出一种 SN-IoU 损失函数, 将最新的 Shape-IoU 与 NWD-IoU 结合在一起使用, Shape 考虑顶芽边界框形状和尺度计算损失, 使边界框更加准确, NWD 则注重小目标的检测, 两者结合提高对顶芯的检测能力。




图 2 DFR-SN-YOLO 网络结构图


Fig.2 Structure diagram of the DFR-SN-YOLO network

1.2.1 DWConv、C3_Faster 及 CA 重构轻量化主干


1) DWConv

深度可分离卷积主要由两部分组成: 深度卷积和逐点卷积。其主要优势是减少参数量, 同时提高模型的效


率和速度。传统卷积如图 3a 所示, 每个通道都需要与所有滤波器进行卷积, 这大大增加了模型计算量; 而 DWConv 中, 深度卷积每个通道仅需与一个滤波器进行卷积^[17], 逐点卷积进一步减少了参数量。通过降低输入通道的维度, 可以在保持相对高性能的同时, 减少模型的大小和计算需求, 尤其是在移动设备受限的环境下。



a. 卷积模块
a. Convolutional module



b. C3_Faster模块
b. The C3_Faster module



c. CA注意力机制
c. CA attention mechanism

注: $n \times n$ 为卷积核的尺寸, C 、 H 、 W 分别为特征图的通道数、高度和宽度, C_p 为受部分卷积影响的通道数, r 为缩减率。

Note: $n \times n$ is the size of the convolution kernel, C , H and W are the number of channels, height and width of the feature map respectively, C_p is the number of channels affected by partial convolution, and r is the reduction rate.

图 3 轻量化主干创新模块示意图

Fig.3 Schematic diagram of the lightweight backbone innovation module

用数学式表达标准卷积，假设卷积核大小为 $D_K \times D_K$ ，输入通道为 M ，输出通道为 N ，输出的特征图尺寸为 $D_F \times D_F$ ，则

参数量对比：

$$\frac{\text{深度可分离卷积}}{\text{标准卷积}} = \frac{D_K \cdot D_K \cdot M + M \cdot N}{D_K \cdot D_K \cdot M \cdot N} = \frac{1}{N} + \frac{1}{D_K^2} \quad (1)$$

计算量对比：

$$\frac{\text{深度可分离卷积}}{\text{标准卷积}} = \frac{D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F}{D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F} = \frac{1}{N} + \frac{1}{D_K^2} \quad (2)$$

一般地， N 较大，可忽略不计； $D_K=3$ ， D_K 表示卷积核的大小。如果使用常见的 3×3 的卷积核，深度可分离卷积的参数量和计算量可下降到原来的 $1/9$ 左右^[18]。

2) C3_Faster

由上述得知 DWConv 减少了参数量和计算量，但是单独使用 DWConv 不一定带来计算速度和准确度的提高。DWConv 中的 PWConv 为了提高准确度遵循 Conv，但会使通道数从 C 增加到 C' ，从而导致更多的内存访问、更高的延迟和更低的计算速度^[19]。Conv 和 DWConv 的内存访问量为

$$H \cdot W \cdot 2C' + n^2 \cdot C' \approx H \cdot W \cdot 2C' \quad (3)$$

因此，为了解决上述问题，本文采用 FasterNet，引入部分卷积 (PConv)，通过利用特征的卷积网络冗余来缓解内存访问和计算冗余。其具体操作流程如图 3 b 所示，PConv 的内存访问量为

$$H \cdot W \cdot 2C_p + n^2 \cdot C_p^2 \approx H \cdot W \cdot 2C_p \quad (4)$$

式中 H 和 W 分别表示特征图的高度和宽度， n 表示卷积核的大小， C_p 表示受部分卷积影响的通道数。与传统卷积相比，PConv 显著减少了计算成本，只需要 $1/16$ 的计算操作，提高了计算速度。同样，PConv 中的内存访问减少到传统卷积的 $1/4$ ，且 PConv 采用 T 型感受野卷积，更强调中心位置^[20]。

如图 3b 所示，在 FasterNetBlock 模块中，PConv 层选择性地将传统卷积应用于输入通道的子集，以进行空间特征提取，同时保留其余通道。对于连续或常规的内存访问，第一个或最后一个连续的 C_p 通道被视为整个特征图的代表，用于计算^[21]。因此，将 FasterNetBlock 集成到 C3 中不仅可优化设备计算能力，而且在空间特征提取中起着至关重要的作用，选择用于空间特征提取的输入通道，同时保持其他通道不变。

3) CA

上文提到 DWConv 卷积的替换实现了模型计算量的轻量化，C3_Faster 提高了模型的推理速度，为提高模型准确度，还需要在主干网络引入应用于轻量化网络的注意力机制。注意力机制常用来告诉模型需要关注的内容和位置，因此被广泛使用在深度神经网络中来加强模型的性能。在轻量化网络结构中，SE Attention 应用最多，如图 3 c 所示，其通过 2D 全局池化计算通道注意力，在很低的成本下做到性能提升。但是，SE 模块仅考虑通道间信息编码而忽视了位置信息。对于棉株顶芽来说，顶叶一般位于植株中心，顶芯一般处于顶叶相对位置，可

见位置信息对于顶芽识别起到重要作用，因此，本文引入轻量化网络中具有位置信息的注意力机制 CA，通过 1D 池化操作将输入特征图分别在水平方向和垂直方向上进行池化 (X Avg Pool 和 Y Avg Pool)，生成两个方向上的特征图 ($C \times 1 \times W$ 和 $C \times H \times 1$)，保留了空间位置信息^[22]。然后，这两个特征图被连接后，通过卷积操作提取特征，进一步生成 2 个方向上的注意力权重。最终，CA 将这 2 个权重分别应用在输入特征图的水平方向和垂直方向，实现方向感知和位置敏感的注意力增强。根据顶芽的位置特性，引入轻量化关注位置信息的 CA 可以有效提升模型对顶芽的检测能力。

1.2.2 颈部网络融入基于感受野的 C3_RFCBAMConv 模块

在卷积操作中感受野内的空间特征直接决定了每一步卷积操作的感知。现有空间注意力机制仅通过对输入特征图的空间特征认知来确定权重，无法关注到感受野的空间特征。对于不同区域和尺寸的感受野仅作相同的处理，限制了模型捕捉和利用图像中信息的能力；其次还存在现有空间注意力无法有效共享大尺度卷积核的参数问题。RFA (reception-filed attention) 感受野注意力机制弥补了现有空间注意力的局限，其将视线转移到了感受野的空间特征上，强调了感受野中各个特征的重要性，并且基于感受野的空间特征能够更灵活地调整卷积核的参数，彻底解决了卷积核参数共享的问题^[23]。

RFAConv 生成的注意力图还是会增加较多参数量，本文采用 RFAConv 引入 CBAM (convolutional block attention module) 注意力机制^[24]的 RFCBAMConv 作为本方法的基本卷积模块 (图 4)。CBAM 由通道注意力模块 CAM 和空间注意力模块 SAM 组成，通过将感受野空间特征引入到 CBAM 中，可以在更少的参数和计算量上升的条件下获得 RFA 带来的性能提升，同时，为减少计算量，将原始的通道注意力机制 CAM 改为了 SE (squeeze-and-excitation) 模块^[25]，并且将通道注意力和空间注意力并行进行运算，分别产生注意力特征图。




图 4 融入感受野注意力 C3_RFCBAMConv 模块示意图
Fig.4 Schematic diagram of the attention C3_RFCBAMConv module for integrating into the receptive field

SE 的计算如式 (5) 和式 (6) 所示，SAM 的计算如式 (7) 所示，其中 F_{sq} 表示使用全局平均池化的压缩操作， u_c 和 z_c 表示变换前后每个通道的特征图， F_{ex} 表示

通过两次全连接层学习通道权重矩阵的过程, σ 和 δ 表示不同的非线性激活函数, Y 表示全连接层计算中压缩的通道, M_s 表示经池化、卷积和激活运算后得到的空间注意力权重, $f^{7 \times 7}$ 表示 7×7 的卷积操作^[26]。

$$z_C = F_{sq}(u_C) = \frac{1}{W \cdot H} \sum_{i=1}^W \sum_{j=1}^H u_C(i, j) \quad (5)$$

$$F_{ex}(z, W) = \sigma(g(z, Y)) = \sigma(Y_2 \delta(Y_1 z)) \quad (6)$$

$$M_s(F) = \sigma(f^{7 \times 7}([\text{AvgPool}(F); \text{MaxPool}(F)])) \quad (7)$$

RFCBAMConv 模块整体结构如图 4 所示, 首先通过分组卷积并调整形状快速生成感受野空间特征图, 然后经过 SAM 空间注意力模块压缩通道维度, 在这里进行 SAM 运算可以充分获取基于感受野的空间信息, 并使每个感受野内部不再共享注意力权重。同时原始的输入特征图经过 SE 通道注意力模块压缩空间维度获得通道信息的向量表示, 最后将获得的两部分注意力图分别与感受野空间特征图进行加权计算, 并通过步长为卷积核大小的卷积运算获得输出特征图。通过引入 RFCBAMConv 替代 YOLOv5s 的传统卷积运算, 使网络基于感受野空间特征能以更高效的方式来提取和处理顶芽特征, 更好处理复杂场景的顶芽检测。

1.2.3 SN-IoU

边界框损失函数用于衡量预测边界框与真实边界框之间的差异, 改进方案为在 IoU 上添加新的几何约束, 如 GT 框和 Anchor 框的距离、形状和角度等, 有效的损失函数决定模型训练效果和最终性能。

1) Shape-IoU

通常的边界框回归方法是考虑 GT 框和 Anchor 框之间的几何关系, 利用边界框的相对位置和形状计算损失, 但却忽略了边界框自身形状和尺度等固有属性对边框回归的影响。新提出的 Shape 函数, 如图 5a 所示, 该方法通过关注边界框本身形状和尺度来计算损失, 从而使得边界框回归更为准确尤其是对顶芯的检测^[27]。

$$\text{IoU} = \frac{|b^p \cap b^{gt}|}{|b^p \cup b^{gt}|} \quad (8)$$

$$ww = \frac{2(w^{gt})^{scale}}{(w^{gt})^{scale} + (h^{gt})^{scale}} \quad (9)$$

$$hh = \frac{2(h^{gt})^{scale}}{(w^{gt})^{scale} + (h^{gt})^{scale}} \quad (10)$$

$$\text{distance}^{shape} = hh \cdot \frac{(x_c - x_c^{gt})^2}{c^2} + ww \cdot \frac{(y_c - y_c^{gt})^2}{c^2} \quad (11)$$

$$\Omega^{shape} = \sum_{t=w,h} (1 - e^{-w_t})^\theta, \theta = 4 \quad (12)$$


$$\begin{cases} w_w = hh \cdot \frac{|w^p - w^{gt}|}{\max(w^p, w^{gt})} \\ w_h = ww \cdot \frac{|h^p - h^{gt}|}{\max(h^p, h^{gt})} \end{cases} \quad (13)$$

式中 IoU 为两框间的交互比, b^p 为预测框, b^{gt} 为真实框, w^p 、 h^p 为预测框的宽度和高度, w^{gt} 、 h^{gt} 为真实框的宽度和高度, $scale$ 为尺度因子, 与数据集中顶芽的尺度有关,

ww 、 hh 和 w_w 、 w_h 分别为水平、垂直方向的权重系数和交叠框尺度, 其取值与框的形状有关。 (x_c^p, y_c^p) 为预测框 b^p 矩心坐标, (x_c^{gt}, y_c^{gt}) 为真实框 b^{gt} 矩心坐标, c 为两框最小外接框对角线长度。最后对应的边框回归损失计算如下:

$$L_{Shape} = 1 - \text{IoU} + \text{distance}^{shape} + 0.5\Omega^{shape} \quad (14)$$


式中 distance^{shape} 和 Ω^{shape} 为最终根据边界框本身形状尺度计算的形状修正系数和形状修正系数。



真实框GT 预测框Anchor

a. 形状损失函数

a. Shape-IoU



$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} = 0.53 \quad \rightarrow \quad \text{IoU} = \frac{|A \cap C|}{|A \cup C|} = 0.06$$

b. 小目标损失函数

b. Small target loss function

注: 矩形框 A 为实际框, B 和 C 为预测框。

Note: Rectangular box A is the actual box, B and C are the prediction boxes.

图 5 SN-IoU 损失函数示意图

Fig.5 Schematic representation of the SN-IoU loss function

2) NWD-IoU

如图 5b 所示, 当矩形框 B 平移 3 个像素得到 C 时, 预测框和真实框的 IoU 值从 0.53 减至 0.06。说明传统损失函数不适于小目标的检测, 因为 IoU 对小尺度更敏感。NWD-IoU 是一种提高小目标检测的损失函数^[28], 采用一种度量方法计算框和框间的相似度, 即把框建模成高斯分布, 然后用 Wasserstein 距离来度量 2 个分布间的相似度, 来代替 IoU。使用此方法的优势在于其对目标的尺度不敏感, 对于小目标检测更加稳定。

对于两个 2D 高斯分布 $\mu_1 = N(m_1, \Sigma_1)$ 和 $\mu_2 = N(m_2, \Sigma_2)$, 他们之间的二阶 Wasserstein 距离可以定义为:

$$W_2^2(\mu_1, \mu_2) = \|m_1 - m_2\|_2^2 + \text{Tr}(\Sigma_1 + \Sigma_2 - 2(\Sigma_2^{1/2} \Sigma_1 \Sigma_2^{1/2})^{1/2}) \quad (15)$$

式中 W_2 为两分布间 Wasserstein 距离, μ_1 、 μ_2 为两个二维高斯分布, m_1 、 m_2 和 Σ_1 、 Σ_2 分别为两分布的均值向量

和协方差矩阵, Tr 表示矩阵迹运算。此外, 对于高斯分布 N_a 和 N_b 从边界框建模

$A = (cx_a, cy_a, w_a, h_a)$ 和 $B = (cx_b, cy_b, w_b, h_b)$, 代入得:

$$W_2^2(N_a, N_b) = \left\| \left[\left[cx_a, cy_a, \frac{w_a}{2}, \frac{h_a}{2} \right]^T, \left[cx_b, cy_b, \frac{w_b}{2}, \frac{h_b}{2} \right]^T \right] \right\|_2^2 \quad (16)$$

式中 N_a 和 N_b 分为由边界框 A、B 建模的高斯分布, (cx_a, cy_a, w_a, h_a) 和 (cx_b, cy_b, w_b, h_b) 分别为边框 A 和 B 中心 x 坐标、中心 y 坐标、宽度和高度, T 为矩阵转置。最后, 通过指数归一化, 可以获得一个新的度量, 称为归一化 Wasserstein 距离 (NWD):

$$NWD(N_a, N_b) = \exp \left(-\frac{\sqrt{W_2^2(N_a, N_b)}}{Q} \right) \quad (17)$$

式中 Q 为与数据集有关的常数。基于 NWD 的边框损失函数如下:

$$L_{NWD} = 1 - NWD(N_a, N_b) \quad (18)$$

综合考虑二者优势, 提出采用 SN 损失函数, 考虑顶芽形状和尺寸计算损失, 同时注重顶芽小目标, 将 Shape-IoU 的计算方法和归一化 NWD-IoU 的计算方法结合, 即将两者按照一定权重比 (本文 iou_ratio 为 0.8) 融合使用得到 SN-IoU。具体定义如下:

$$Loss = iou_ratio \cdot (1.0 - L_{NWD})_{mean} + (1 - iou_ratio) \cdot (1.0 - L_{Shape})_{mean} \quad (19)$$

1.3 系统环境配置和网络参数设置

本试验的操作系统为 Windows 11, 软件在 PyCharm 2023.2.1 上运行。使用框架是 Python 3.8 和 Pytorch 1.11.0 的 CUDA 11.3。计算硬件包括一个具有 24 GBVRAM 的 NVIDIA RTX 4090 和一个 Intel (R) Xeon (R) Platinum 8352 V CPU @ 2.10 GHz。超参数设置如表 2 所示。

1.4 模型评估指标

为了评估模型的有效性, 本文选择以下几个指标^[29], 包括精度 (P)、召回率 (R) 和平均检测精度 ($mAP@50$ 、

$mAP@[50-95]$) 来衡量检测的准确度, 及参数数量 (Parameter) 和浮点运算量 (GFLOPs) 来评估模型性能和复杂性。

表 2 模型训练的参数设置

Table 2 Parameter settings for the model training

超参数 Hyper-parameter	数值或类型 Value or type
训练轮数 Epoch	200
批量大小 Batch size	32
学习率 Learning rate	0.01
动量值 Momentum	0.937
权重衰减 Weight decay	0.000 6
优化器 Optimizer	SGD

2 结果与分析

2.1 主干中添加 CA 注意力效果对比

主干网络作为模型特征提取器, 获取有效信息是模型检测的重点环节。所以针对模型对顶芯检测精度低的问题, 本文拟采用在主干第 7 层引入 CA 注意力, 增加顶芯的位置信息, 并与原模型 YOLOv5s 及其他层 (3、9、13、17、20) 引入注意力 CA, 在测试集进行对比试验。试验结果如表 3 所示, 从 SR、mAP 来看, 相较于基础模型, CA 的引入提高了模型对顶芯的检测效果, 其中在模型第 7 层加入 CA 注意力, 较比插入到 3、9、13、17、20 层平均检测精度 $mAP@[50-95]$ 更高, 较基线顶芯的准确、召回率分别提升 2.4、2.4 个百分点; 因为第 7 层处于中层, 空间信息和语义信息较为平衡; 随着网络加深, 特征图分辨率降低, 空间信息较少。CA 模块需要利用精确的位置信息, 因此在第 7 层更有效。这一理论预期与试验结果一致, 同时第 7 层也能保持较低的参数量和计算成本。

表 3 不同层加入 CA 注意力的效果及不同的注意力机制对比

Table 3 The effect of adding CA attention at different layers and the comparison of different attention mechanisms

模型 Model	准确率 $P\%$		召回率 $R\%$		平均精度 $mAP@50\%$	平均精度 $mAP@[50-95]\%$	参数 Parameter/M	计算成本 GFLOPs/G
	顶芯 SP	顶叶 BP	顶芯 SR	顶叶 BR				
YOLOv5s	88.5	96.5	87.0	96.5	94.5	67.8	7.0	15.8
不同层加入 CA 注意力 CA attention effect in different layers	CA(3)	87.9	94.2	90.8	97.7	68.3	7.2	15.8
	CA(7)	90.9	96.0	89.4	96.6	69.4	7.0	14.8
	CA(9)	89.4	94.2	90.3	97.1	68.9	7.0	14.8
	CA(13)	91.3	96.2	86.3	96.8	68.6	7.0	15.8
	CA(17)	93.3	95.7	87.4	96.2	68.2	7.0	15.8
	CA(20)	90.3	95.6	85.0	96.8	68.0	7.0	15.8
第 7 层引入不同注意力机制 Different attention mechanism models on the 7 th layer	-GAM	86.1	91.6	85.7	96.3	66.7	8.8	17.2
	-EMA	89.1	96.1	85.6	96.4	67.2	7.2	16.0
	-ECA	88.9	94.7	88.4	96.9	68.0	7.2	16.0
	-NAM	88.3	95.4	86.9	96.7	67.5	7.2	16.0
	-SE	89.6	95.2	88.5	97.0	68.4	7.2	16.0
	-CBAM	90.2	95.8	89.1	96.2	68.5	7.0	15.8

为验证 CA 注意力机制对模型的影响, 本文还通过在第 7 层将 CA 与其他高效注意力机制模块, 如 GAM、EMA、ECA、NAM、SE、CBAM, 进行对比试验, 结果见表 3, 相较于基础模型 YOLOv5s 的顶芽平均检测精度 $mAP@50$, GAM、EMA、NAM 的引入抑制了模型对

顶芽的识别能力, 提升效果最好的注意力模块分别是 CA、CBAM、SE、ECA, 分别提升 1.4、0.9、0.6、0.3 个百分点。其中对顶芯识别准确率、召回率提升最高的是 CA 模块。CA 模块注重顶芯的方向和位置信息, 因顶芯和顶叶的相对位置关系, 所以 CA 模块相较于其他注

意力机制,更能显著提高模型对顶芯的识别能力。因此,本文最终选择在模型第7层位置加入CA注意力机制。

2.2 颈部中改进感受野模块的有效性

首先,为验证C3中融入RFCBAMConv的有效性,将其与使用C3模块融入RFAConv、RFCACConv及原始C3模块的不同模型在测试集进行性能试验对比,试验结果见表4,使用C3_RFCBAMConv得到顶芽的平均精度更高,且模型参数较少,这也验证了CBAM中替换SE可在更少参数条件下提升RFA的性能;其次,为了探究C3_RFCBAMConv的性能,还进行了模型在不同层替换感受野卷积的试验,试验结果如表4所示,在模型第13层替换C3_RFCBAMConv较4、6、8、17、20、23层,顶芽平均检测精度 $mAP@50$ 和 $mAP@[50-95]$ 的值更高,

从颈部网络13~23层结果上看,随着层数加深,信息的丢失再使用感受野卷积强调空间特征,对顶芽的提升效果越来越不明显了,因此可推断出第13层将C3替换C3_RFCBAMConv效果更佳。

最后,为验证C3_RFCBAMConv是否使模型将视线转移到了感受野的空间特征上,从而有利于模型捕捉和提取顶芽特征,本文采用了2种模型,包括未使用(Base)和使用(C3_RFCBAMConv)生成顶芽特征提取热力图来验证感受野的有效性。效果图如图6所示,以图6a为例,基础模型没有识别到顶芯,加入感受野模块后明显识别到顶芯特征(其中热力图的颜色越红说明对此部分特征越敏感)。同理,从其他图片也可得出加入感受野模块后模型对顶芯特征部分更加敏感。

表4 C3中融入不同感受野卷积模块测试结果及不同层替换C3_RFCBAMConv效果对比

Table 4 C3 integrated into the convolution module of different receptive fields and comparison of the effects of different layers of substitution C3_RFCBAMConv

模型 Model		准确率 P/%		召回率 R/%		平均精度 $mAP@50$ /%	平均精度 $mAP@[50-95]$ /%	参数 Parameter/M	计算成本 GFLOPs/G
		顶芯 SP	顶叶 BP	顶芯 SR	顶叶 BR				
C3中融入不同感受野模块 Effects of integrating different receptive field modules in C3	Base (C3)	88.5	96.5	87.0	96.5	94.5	67.8	7.0	15.8
	_RFAConv	91.3	95.8	85.6	96.4	94.9	67.9	7.4	15.8
	_RFCACConv	89.3	95.3	88.6	96.7	95.0	68.3	7.2	15.8
	_RFCBAMConv	92.7	95.5	87.4	96.3	95.8	69.0	7.2	15.8
不同层替换感受野模块 Effects of different layers replacing receptive field modules	_RFCBAMConv (4)	90.8	96.2	86.2	96.0	95.2	68.4	7.1	15.9
	_RFCBAMConv (6)	90.6	95.9	87.9	96.8	95.1	68.2	7.1	15.9
	_RFCBAMConv (8)	91.1	95.8	87.2	96.3	95.2	68.1	7.1	15.9
	_RFCBAMConv (13)	92.7	96.5	87.4	96.8	95.8	69.0	7.2	15.8
	_RFCBAMConv (17)	90.8	94.6	88.1	97.0	95.3	68.6	7.0	15.9
	_RFCBAMConv (20)	89.8	94.0	87.4	97.2	95.0	67.9	7.0	15.8
	_RFCBAMConv (23)	88.7	94.3	88.2	96.8	94.4	67.5	7.0	15.8




图6 融入感受野注意力C3_RFCBAMConv的热力图可视化

Fig.6 Heatmap visualization incorporating receptive field attention C3_RFCBAMConv

2.3 轻量化主干比较

采用目前常用的轻量化模块对模型主干做轻量化处理,包括Ghost^[30]、ShuffleNetv2^[31]、MobileNetv3^[32]、DSConv^[33]、DWConv^[34]及C3_Faster^[34]等,其余部分依

旧采用前文验证过的高效模块,轻量化模块引入主干对比试验结果如表5所示,在主干网络引入ShuffleNetv2、MobileNetv3模型轻量效果最显著,计算成本、权重文件大小下降到1.7 G、1.9 M和1.9 G、2.1 M,但是2个轻

量化的加入导致对顶芯特性的提取识别能力降低，召回率低至 70% 以下；Ghost 的加入使模型稍微轻量了一些，但也造成了顶芯目标提取能力的下降。本文还对比了单独 DSConv 卷积、DWConv 以及两者结合 C3_Faster 的试验效果，试验结果可知 DWConv 结合 C3_Faster 组成的新主干，在结合 CA 等模块后，在模型轻量化的同时也提升了顶芯的召回率，即模型计算成本、权重大小降到 9.0 G、8.3 M，同时顶芯召回率提升到了 95.0%。

2.4 边界框损失函数的对比试验

为解决小顶芽漏检问题，本文提出采用 SN-IoU，将注重顶芽小目标损失函数 NWD-IoU 和考虑顶芽形状尺寸的损失函数 Shape-IoU 按照一定权重比融合。为确定最优融合权重，首先分析了不同融合权重比下的模型性能，如表 6 所示。从表中可以看出，增加 iou_ratio 会带来顶芯召回率（SR）的升高，但 iou_ratio 为 1 时又带来

抑制效果，取 iou_ratio=0.8 时，顶芯召回率 SR、顶芽平均精度 mAP@50 和 mAP@[50-95] 为最高，分别为 95.0%、97.5% 和 70.3%。

表 5 不同轻量化模块试验效果对比

Table 5 Comparison of experimental effects of different lightweight modules

主干 Backbone	准确率 P/%		召回率 R/%		平均精度 mAP@50/ %	参数 Para- meter/ M	计算成本 GFLOPs/ G	权重大小 Weight/ MB
	顶芯 SP	顶芽 BP	顶芯 SR	顶芽 BR				
YOLOv5s	88.5	96.5	87.0	96.5	94.5	7.0	15.8	14.5
Ghost	88.5	96.5	82.5	96.1	94.4	7.8	17.7	16.1
ShuffleNet2	81.0	91.4	68.8	95.1	89.8	7.5	1.7	1.9
MobileNetv3	84.7	92.9	65.8	92.9	86.7	1.2	1.9	2.1
DSConv	89.7	95.0	90.6	96.8	96.2	7.0	10.9	24.7
DWConv	90.5	95.1	89.1	97.2	94.8	4.6	11.0	9.6
DSConv+ C3_Faster	91.1	96.2	88.7	96.4	96.1	6.4	10.9	19.7
DWConv+ C3_Faster	92.4	95.1	95.0	98.4	97.5	3.9	9.0	8.3

表 6 SN 不同融合权重比下模型性能及使用不同损失函数试验结果对比

Table 6 Comparison of model performance under different SN fusion weight ratios and experimental results using different loss functions

损失函数 IoU		准确率 P/%		召回率 R/%		平均精度 mAP@50/%	平均精度 mAP@[50-95]/%
		顶芯 SP	顶芽 BP	顶芯 SR	顶芽 BR		
SN 不同融合权重比下 SN model performance under different fusion weight ratios	iou_ratio=0	91.9	95.5	87.5	96.8	96.6	69.9
	iou_ratio=0.2	93.2	95.2	91.9	98.1	97.2	69.7
	iou_ratio=0.5	93.7	95.2	92.2	98.5	97.4	70.1
	iou_ratio=0.8	92.4	95.1	95.0	98.4	97.5	70.3
	iou_ratio=1.0	93.6	96.7	89.4	97.1	97.1	70.0
不同损失函数 Different loss functions	CIoU	94.0	95.6	87.4	97.6	96.4	69.2
	SIoU	93.3	95.6	88.7	97.4	97.0	69.7
	EIoU	93.2	96.1	86.3	94.5	94.5	67.5
	MPD	93.3	96.9	83.5	96.0	95.9	68.5
	Shape	91.9	95.5	87.5	96.8	96.6	69.9
	NWD	93.6	96.7	89.4	97.1	97.1	70.0
	SN	92.4	95.1	95.0	98.4	97.5	70.3

基础模型采用的边界框损失函数策略是 CIoU，为进一步验证本文提出的 SN（Shape-NWD）损失函数的实际性能，本文将其与常用的典型边界框损失函数（SIoU、EIoU、MPD、Shape、NWD）进行比较。其中 SIoU、EIoU 为顶芽识别文献 [11]、文献 [15] 中使用的损失函数，MPD 为文献 [35] 针对遮挡提出的损失函数以及针对小目标单独采用 Shape 和 NWD 损失函数。如表 6 所示的结果，相比于基线 CIoU 的顶芯召回率 SR 和平均检测精度 mAP，EIoU 和 MPD 没有对顶芯的识别带来提升，其余 4 种 SIoU、Shape、NWD 和本文提出的 SN 损失函数均提高了模型对小目标的检测能力。不同损失函数的平均检测精度在训练中变化情况见图 7，模型在 200 轮训练后收敛，使用 Shape、SIoU 及 NWD 损失函数均提高了顶芽识别平均精度，而本文提出的 SN 损失函数，既考虑顶芽的自身形状，同时注重小目标顶芽，超过了上述损失函数单独使用时的平均精度。结合本文添加的注意力机制 CA 后显著提高了模型对小目标顶芽的识别能力，提升顶芯召回率（SR）至 95.0%。

2.5 消融试验

为了评估 DFR-SN-YOLO 中实施的改进是否能达到预期效果，本文对改进的几个模块进行了一系列验证测试。包括 A-CA、B-C3_RFCBAMConv、C-SN（Shape-NWD-IoU）、D-DF（DWConv 结合 C3_Faster）。




图 7 不同损失函数平均检测精度 mAP@50 对比图
Fig.7 Comparison chart of mAP@50 average detection accuracy of different loss functions

消融试验具体结果如表 7 所示。首先讨论单独使用各个模块的效果。相较于基础模型的检测结果，单独使用 A 模块，一种注重提取位置信息的注意力，可以看到其加入后，顶芯准确率（SP）、召回率（SR）分别提高了 2.4 个百分点；B 模块在 C3 中引入感受野注意力，能更好地感知顶芽目标在整体空间中的分布，引入后显著提高了顶芯的识别准确率（SP）4.2 个百分点；C 模块是针对顶芽小目标设计的损失函数，考虑顶芽自身形状及注重小目标的提取，引入后提高了顶芯的准确率（SP）

和顶叶召回率 (BR); D 是轻量化模块, 可见引入后虽然顶芽检测的平均精度 $mAP@50$ 和 $mAP@[50-95]$ 下降了一些, 但实现模型参数 44% 的下降, 计算成本 37%

的下降, 同时顶芯的检测准确率 (SP) 和召回率 (SR) 有所提升, 说明了 D 模块采用高效卷积代替传统卷积, 能够有效减少模型参数的同时提高小目标检测效果。

表 7 消融试验结果对比

Table 7 Comparison of the results of the ablation experiments

模型 Model	CA	C3_RFCBAMConv	SN	DF	准确率 P/%		召回率 R/%		平均精度		参数 Parameter/M	计算成本 GFLOPs/G
					顶芯 SP	顶叶 BP	顶芯 SR	顶叶 BR	$mAP@50/\%$	$mAP@[50-95]/\%$		
Base					88.5	96.5	87.0	96.5	94.5	67.8	7.0	15.8
A	√				90.9	96.0	89.4	96.6	95.9	69.4	7.0	14.8
B		√			92.7	95.5	87.4	96.3	95.8	69.0	7.2	15.8
C			√		91.4	94.6	87.0	97.4	96.1	69.1	7.0	15.8
D				√	90.3	92.5	87.6	95.1	94.1	67.3	3.9	9.8
A+B	√	√			92.9	95.3	90.0	97.4	96.1	69.5	8.1	20.0
A+C	√		√		91.2	96.0	87.0	96.7	95.1	68.3	7.2	16.0
B+C		√	√		91.1	96.3	91.6	97.2	96.3	69.1	7.2	15.8
A+B+D	√	√		√	94.0	95.6	87.4	97.6	96.4	69.7	4.0	9.8
A+C+D	√		√	√	92.9	96.9	89.5	97.3	97.0	69.6	3.9	8.9
B+C+D		√	√	√	93.1	95.5	87.5	97.9	95.6	68.3	3.9	9.0
A+B+C	√	√	√		91.6	96.2	92.9	97.7	97.0	69.9	7.0	16.0
A+B+C+D	√	√	√	√	92.4	95.1	95.0	98.4	97.5	70.3	3.9	9.0

接着将单个模块混合使用。模块 AB 混合使用较于单独使用有明显的增强效果, 其中顶芯准确率 (SP)、召回率 (SR) 较原模型分别提高了 4.4、3.0 个百分点, 两者优势相结合; 模块 AC 混合使用虽较基线有所提升, 却在顶芯召回率 (SR)、平均精度方面 mAP 较 A 单独使用时有所下降, 两者有所抑制; 模块 BC 也起到相互促进的效果, 明显突出的是顶芯召回率 (SR) 较基线提高了 4.6 个百分点, 但上述 3 种混合都带来了参数量的增加及更高的运算成本。因此, 将轻量化主干模块 D 加入上述模块中, 模块 AB 融入 D 后, 较于原 AB 混合模型检测结果, 参数量减少了 50%, 运算成本减少了 51%, 但是顶芯的召回率 (SR) 下降了 2.6 个百分点; 模块 BC 在之前的试验中显著提高了顶芯的召回率, 将模块 C 引入 ABD 后有效解决了顶芯召回率低的问题, ABCD 4 个模块相互补偿, 做到整体性能提升。

将模块 A+B+C 混合使用时, 顶芯召回率 (SR)、平均精度 $mAP@50$ 和 $mAP@[50-95]$ 分别为 92.9%、97.0% 和 69.9%。引入轻量化主干模块 D 后, 模型在显著降低参数量的同时, 顶芯召回率 (SR) 进一步提升至 95.0%。这种情况可能是由密植棉田环境下顶芯生长特点 (目标小、易遮挡、位置相对固定) 导致的。采集的图像信息中目标顶芯的信息少、容易被叶片信息干扰, 生长期相近的叶片也带来大量的冗余信息。D 模块优化了顶芯特征流, 过滤掉了部分顶芽背景噪声和不相关的细节。DWConv 抑制噪声传播^[17, 19]能避免 A 位置信息被稀释, C3_Faster 中的 PConv 选择关键通道^[20-21]可提升 B 对感受野内空间特征的敏感性, 使得后续 A (CA) 能更精准地定位顶芯位置, B (RFCBAMConv) 能更有效地在关键感受野内捕获顶芯结构, C (SN-IoU) 计算损失时依赖的边界框预测也更准确 (因为特征更聚焦于目标本身), 因此提升了对顶芯的召回率。

2.6 不同目标检测网络的比较

为了进一步证实算法改进的有效性, 与目前广泛使用的主要目标检测算法和现有顶芽研究方法进行了比较, 包括一阶段网络 YOLO 系列、二阶段网络 (Faster_

RCNN^[36]、Mask_RCNN^[37]、Cacsda_RCNN^[38])、DETR-R50^[39] 和现有的顶芽识别研究文献 YOLOv5-cpp^[9] 和 Bud-YOLO^[40] 模型, 对比结果如表 8 所示。Faster_RCNN、Mask_RCNN 等二阶网络结构所需参数量是 YOLO 系列的 4~7 倍, 生成权重文件偏大, 但检测效果如顶芯召回率只有 50% 左右, 同时检测速率也相对较低。与其相比, DETR 网络在顶芽识别准确率及检测速度有所提升, 但模型对顶芽召回率上依旧很低, 同时大量参数也使模型的权重文件偏大。可以看到 YOLO 系列相较于以上 2 种系列模型相对轻量, 检测速度和精度更接近顶芽检测的应用。但模型对顶芯的召回率偏低及模型轻量实时检测速度方面还未达到要求。

为解决上述问题, 本文提出 DFR-SN-YOLO 模型, 对比 YOLOv3、YOLOv5s、YOLOv8s、YOLOv10s、YOLO11s 以及现有的 2 种对顶芽识别的模型, 本文的改进模型 $mAP@50$ 值比上述模型分别提高了 3.7、3.0、2.4、2.3、1.5 个百分点, 其中对顶芯的准确率 (SP) 分别提高 2.9、3.9、0.5、0.9、0.3 个百分点, 召回率 (SR) 分别提高 9.5、8.0、9.8、13.9、11.2 个百分点, 同时模型的权重文件分别减少了 22.6、6.2、14.2、8.2、10.2 MB。与 YOLOv5s、YOLOv8s 等通用型模型相比, DFR-SN-YOLO 模型在 $mAP@50$ 指标上达到 97.5%, 且其参数量仅为 3.9 M。模型在参数量大幅压缩的情况下, 仍可以在检测精度上实现领先。这意味着在顶芽识别方面, 参数量与精度并未呈现正相关性。这与文献 [9, 15, 40] 的结论一致。导致这种情况的原因可能是密植棉田环境下顶芯具有的目标小、易遮挡、位置相对固定的特点, 目标信息少、干扰和冗余信息多, 本文用于对比的 YOLOv5s、v8s 等通用模型并未针对顶芯漏检问题做任何针对性的优化, 其参数量和计算量部分消耗在处理与顶芯检测无关或低效的信息上, 因此在顶芯检测方面召回率较低。而本文改进的 DFR-SN-YOLO 模型通过采用 DWConv 和 C3_Faster 重构轻量化主干网络, 同时在主干网络添加注意力机制, 颈部网络融入新型感受野注意力的 C3 模块及提出针对小目标识别新型损失函数 SN-IoU 的方式,

实现在去除冗余和干扰信息的同时聚焦目标特征信息，较好的适应了密植棉田环境下顶芯的生长特点。在各模块协同作用下，提高了顶芯检测率（SR），因此使平均检测 mAP@50 也较通用型模块有所提升。另较现有的 2 个顶芽识别模型 YOLOv5-cpp^[9] 和 Bud-YOLO^[40]，虽然模型轻量化方面不如两者，但在顶芯识别准确率、召回率及平均精度均高于两者，本文模型在实现部分轻量化同时保持较高的检测精度。

2.7 不同模型检测顶芽的可视化效果对比

为了更准确测试 DFR-SN-YOLO 模型实时检测棉花顶芽的能力，将 DFR-SN-YOLO 与 Faster_RCNN、

YOLOv5s、YOLOv8s、YOLO11s 这 4 种模型进行对比分析，对于简单背景下（无遮挡、单株顶芽）模型的识别效果都很好，因此本文选择 5 种模型检测在自然棉田复杂环境下的顶芽，其中样本 1、2 为随机截取的多株顶芽样本图片，如图 8 所示，通过顶芽检测图可以发现，Faster_RCNN、YOLOv5s、YOLOv8s、YOLO11s 识别顶芽时分别漏检顶叶个数为 4、0、3、3，漏检顶芯个数为 1、2、2、1，同时 YOLOv5s 错检了 2 个顶芽，而改进后的 DFR-SN-YOLO 模型在遮挡的情况下，识别到视野内所有的棉花顶芽，并对顶叶与顶芯很好的进行了区分，两者的检测精度和召回率也较高。

表 8 不同检测网络的检测结果对比

Table 8 Comparison of the detection results for the different detection networks

模型 Model	类型 Type	准确率 P/%		召回率 R/%		平均精度	平均精度	参数	计算成本	文件大小	帧率
		顶芯 SP	顶叶 BP	顶芯 SR	顶叶 BR	mAP@50/%	mAP@[50-95]/%	Parameter/M	GFLOPs/G	Weight/MB	Frame rate/(帧·s ⁻¹)
Faster_RCNN	Two-Stage	80.7	95.8	57.3	81.6	88.3	43.7	41.4	134.1	323.2	38.2
Mask_RCNN	Two-Stage	80.2	95.5	55.9	81.7	87.8	43.2	43.9	187.4	344.3	35.4
Cacsdn_RCNN	Two-Stage	81.6	95.4	55.4	81.9	88.5	44.1	77.1	175.2	603.8	25.4
DETR-R50	DETR	88.7	97.2	56.4	85.2	93.0	66.5	41.5	60.5	507.1	50.2
YOLOv3	One-Stage	89.5	96.3	85.5	95.5	93.8	67.3	1.5	43.8	30.9	35.7
YOLOv5s	One-Stage	88.5	96.5	87.0	96.5	94.5	67.8	7.0	15.8	14.5	49.3
YOLOv8s	One-Stage	91.9	97.1	85.2	96.5	95.1	68.2	11.1	28.4	22.5	42.4
YOLOv10s	One-Stage	91.5	96.4	81.1	94.3	95.2	68.1	8.0	24.4	16.5	43.1
YOLO 11s	One-Stage	92.1	95.4	83.8	96.3	96.0	68.5	9.4	21.3	19.2	45.7
YOLOv5-cpp ^[9]	One-Stage	91.4	95.2	89.1	96.0	95.8	68.8	3.7	8.1	7.7	46.0
Bud-YOLO ^[40]	One-Stage	92.2	94.3	87.1	96.6	95.1	68.0	2.4	6.3	5.7	43.1
Our	One-Stage	92.4	95.1	95.0	98.4	97.5	70.3	3.9	9.0	8.3	53.5




图 8 不同模型检测结果对比

Fig.8 Comparison of different experimental models

2.8 边缘设备部署试验

为验证改进算法模型在边缘设备端的检测性能，选择将模型部署到 NVIDIA Jetson Orin Nano 4GB，同时利用 TensorRT 推理进行模型加速实现最大推理吞吐量和低延迟速度。首先，将 Pytorch 训练好的模型导出为静态 ONNX 模型，将权重文件从 Pytorch 格式（.pt）转化为 ONNX 格式（.onnx），通过 onnxsim 工具优化网络结构，使用 trtexec 工具构建推理引擎，将模型转化为 TensorRT 推理格式（.engine），使用 TensorRT 引擎实现高性能推理。

通过将 DFR-SN-YOLO 与 YOLOv5n、YOLOv5s 进行部署检测对比，3 种模型检测同一区域被遮挡的顶芽，不同模型检测中的效果图如图 9 所示。统计各模型正确检测到顶叶、顶芯个数作为评估模型检测精度指标，检测时间作为评估模型速度指标，试验结果如表 9 所示。

由试验结果分析，YOLOv5n、YOLOv5s 和 DFR-SN-YOLO 模型检测到顶芯和顶叶总个数分别是 16、19、26，其中相对于改进模型，YOLOv5n、5s 分别漏检顶芯个数为 6、4，说明了本文模型在解决顶芯漏检上的有效性；从检测速度的角度，YOLOv5n 及 YOLOv5s 改进前后的模型部署在 Jetson Orin Nano 4GB 上的帧率（FPS）分别是 29、24、37 帧/s，本文的改进模型 FPS 相对于 YOLOv5n、YOLOv5s 分别提高 27%、54%，高于一般视频帧率 25 或 30 帧/s，因此能满足实时检测要求。综上所述，DFR-SN-YOLO 模型推理速度优于基线模型及其轻量模型，在计算能力有限的边缘计算设备上，检测效果与推理速度方面均有优势。




图9 检测中不同模型对比图
Fig.9 Comparison of different models in detection

表9 不同模型的检测试验结果

Table 9 Detection results for the different detection models

模型 Model	检测到目标个数 Number of targets detected		帧率 Frame rate/ (帧·s ⁻¹)
	顶芯 Top hearts	顶叶 Top leaves	
	Top hearts	Top leaves	
YOLO v5n	3	13	29
YOLO v5s	5	14	24
DFR-SN-YOLO	9	17	37

3 结 论

针对密植环境下棉花顶芽漏检率高、检测精度低问题,利用棉田顶芽顶叶和顶芯位置相对的结构关联性,提出了一种 DFR-SN-YOLO 棉花顶芽轻量化检测模型。主要结论如下:

1) 针对顶芯易漏检问题,在主干引入识别顶芽位置信息的 CA 注意力获取更多顶芯信息,通过与原模型 YOLOv5s 及其他层引入 CA 做对比,试验表明,CA 模块通过精准获取空间位置信息,显著增强了模型对顶芯的敏感性,且在第 7 层效果最优,相较于其他注意力机制 (GAM、EMA、ECA、NAM、SE、CBAM),CA 在提升顶芯召回率方面表现较优 (89.4%)。结合颈部网络第 13 层替换的 C3_RFCBAMConv 模块,模型进一步强化了对顶芽在全局特征的识别能力,特别是提升了在复杂背景中对顶芯的判别力,如特征热力图可视化等有效印证了 C3_RFCBAMConv 模块的有效性,显示改进后的模型对顶芽区域特征响应更为集中和强烈。这表明位置注意力与感受野优化组合的策略有效解决密植环境下小目标特征模糊问题。

2) 采用轻量化主干和形状感知损失函数有效减少了模型参数量、计算成本,同时提高顶芽检测精度。使用 DWConv 和改进后的 C3_Faster 重构主干网络,相较其他轻量化主干,不仅显著降低模型参数量 (3.9M) 及计算复杂度 (下降到 9.0 G),使其更易于部署到资源受限的设备,同时保证了有效卷积提取特征。接着针对顶芽识别提出了一种 SN 损失函数,既考虑顶芽自身形状同时注重对小目标的提取,与常用的典型边界框损失函数相比, mAP@50 提升。

3) DFR-SN-YOLO 的顶芽检测平均精度优于目前广泛使用的模型,且与基线模型相比, mAP@50、mAP@[50-95] 分别提高了 3 个百分点、2.5 个百分点,顶芯的准确率 (SP) 提高了 3.9 个百分点,召回率提高了 8 个百分点,解决了顶芯漏检的问题。同时模型的参数量为 3.9M,计算成本为 9.0 G。选择边缘设备 Jetson

Orin Nano 4 GB 进行部署,利用 TensorRT 推理库进行模型加速,经试验验证,DFR-SN-YOLO 模型漏检率更低,同时推理速度为 37 帧/s,推理速度优于 YOLOv5s 及 YOLOv5n 模型,可满足实时检测顶芽的要求,为棉花智能化机械打顶奠定了基础。

[参 考 文 献]

- [1] 赵岩, 陈学庚. 我国棉花产业高质量生产面临的问题与展望[J]. 塔里木大学学报, 2023, 35(1): 1-8.
ZHAO Yan, CHEN Xuegeng. Problems and prospects of high quality cotton production in China[J]. Journal of Tarim University, 2023, 35(1): 1-8. (in Chinese with English abstract)
- [2] 张晋国, 郑超, 赵金, 等. 棉花打顶机自动对行装置设计与试验[J]. 农业机械学报, 2021, 52(7): 93-101.
ZHANG Jinguo, ZHENG Chao, ZHAO Jin, et al. Design and experiment of auto-follow row device for cotton topping machine[J]. Transactions of the Chinese Society for Agricultural Machinery, 2021, 52(7): 93-101. (in Chinese with English abstract)
- [3] 赵广杰. 棉花打顶机械研究现状及发展趋势[J]. 当代农机, 2024, 53(11): 38-39.
ZHAO Guangjie. Current research status and development trends of cotton topping machinery[J]. Contemporary Farm Machinery, 2024, 53(11): 38-39. (in Chinese with English abstract)
- [4] 刘海涛, 伊丽丽, 兰玉彬, 等. 机器视觉在棉花智能打顶领域的应用研究进展[J]. 中国农机化学报, 2021, 42(6): 159-165.
LIU Haitao, YI Lili, LAN Yubin, et al. Research progress in the application of machine vision in the field of cotton intelligent topping[J]. Journal of Chinese Agricultural Mechanization, 2021, 42(6): 159-165. (in Chinese with English abstract)
- [5] 陈学庚, 温浩军, 张伟荣, 等. 农业机械与信息技术融合发展现状与方向[J]. 智慧农业, 2020, 2(4): 1-16.
CHEN Xuegeng, WEN Haojun, ZHANG Weirong, et al. Advances and progress of agricultural machinery and sensing technology fusion[J]. Smart Agriculture, 2020, 2(4): 1-16. (in Chinese with English abstract)
- [6] FAN X, SUN T, CHAI X, et al. YOLO-WDNet: A lightweight and accurate model for weeds detection in cotton field[J]. Computers and Electronics in Agriculture, 2024, 225: 109317.
- [7] 陈柯屹, 朱龙付, 宋鹏, 等. 融合动态机制的改进型 Faster R-CNN 识别田间棉花顶芽[J]. 农业工程学报, 2021, 37(16): 161-168.
CHEN Keqi, ZHU Longfu, SONG Peng, et al. Recognition of cotton terminal bud in field using Faster R-CNN by integrating dynamic mechanism[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(16): 161-168. (in Chinese with English abstract)
- [8] 亚森江·白克力, 周显镭, 刘锋, 等. 基于改进 Tiny-YOLOv4 的棉花顶芽轻量化识别方法[J]. 新疆农业大学学报, 2023, 46(5): 414-420.

- YASENJIANG Baikeli, ZHOU Xianke, LIU Feng, et al. Research on cotton terminal bud recognition based on improved Tiny-YOLOv4 algorithm[J]. Journal of Xinjiang Agricultural University, 2023, 46(5): 414-420. (in Chinese with English abstract)
- [9] 彭炫, 周建平, 许燕, 等. 改进 YOLOv5 识别复杂环境下棉花顶芽[J]. 农业工程学报, 2023, 39(16): 191-197.
PENG Xuan, ZHOU Jianping, XU Yan, et al. Cotton top bud recognition method based on YOLOv5-CPP in complex environment[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2023, 39(16): 191-197. (in Chinese with English abstract)
- [10] XIE Y, CHEN L. CBLN-YOLO: An improved YOLO11n-Seg network for cotton topping in fields[J]. Agronomy, 2025, 15(4): 996.
- [11] 赵露强, 彭强吉, 兰玉彬, 等. CottonBud-YOLOv5s 轻量化棉花顶芽检测算法[J]. 农业工程学报, 2025, 41(4): 175-184.
ZHAO Luqiang, PENG Qiangji, LAN Yubin, et al. CottonBud-YOLOv5s lightweight cotton bud detection algorithm[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(4): 175-184. (in Chinese with English abstract)
- [12] 韩鑫, 韩金鸽, 陈允琳, 等. 基于顶芽智能识别的棉花化学打顶系统研究[J]. 农业机械学报, 2024, 55(3): 145-152.
HAN Xin, HAN Jing, CHEN Yunlin, et al. Research on cotton chemical topping system based on apical bud intelligent recognition[J]. Transactions of the Chinese Society for Agricultural Machinery, 2024, 55(3): 145-152. (in Chinese with English abstract)
- [13] 刘润飞. 基于改进 YOLOv8 的棉花虫害检测算法[J]. 农业工程, 2024, 14(7): 42-47.
LIU Runfei. Cotton pest detection algorithm based on improved YOLOv8[J]. Agricultural Engineering, 2024, 14(7): 42-47. (in Chinese with English abstract)
- [14] 刘祥, 田敏, 梁金艳. 基于 RCH-UNet 的新疆密植棉花图像快速分割及产量预测[J]. 农业工程学报, 2024, 40(7): 230-239.
LIU Xiang, TIAN Min, LIANG Jinyan. Prediction of cotton yield densely planted in Xinjiang of China using RCH-UNet model[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(7): 230-239. (in Chinese with English abstract)
- [15] 席光泽, 周建平, 许燕, 等. 基于改进 YOLOv5s 的复杂环境下棉花顶芽识别[J]. 中国农机化学报, 2024, 45(12): 275-280.
XI Guangze, ZHOU Jianping, XU Yan, et al. Cotton top bud recognition in complex environment based on improved YOLOv5s[J]. Journal of Chinese Agricultural Mechanization, 2024, 45(12): 275-280. (in Chinese with English abstract)
- [16] 易孟华. 基于深度学习的棉花顶芽识别方法研究[D]. 阿拉尔: 塔里木大学, 2023.
YI Menghua. Research on Cotton Terminal Bud Recognition Method Based on Deep Learning[D]. Alar: Tarim University, 2023. (in Chinese with English abstract)
- [17] YANG S, CAO Z, LIU N, et al. Maritime electro-optical image object matching based on improved YOLOv9[J]. Electronics, 2024, 13(14): 2774.
- [18] 杨祥, 王华彬, 董明刚. 改进 YOLOv5 的交通标志检测算法[J]. 计算机工程与应用, 2023, 59(13): 194-204.
YANG Xiang, WANG Huabin, DONG Minggang. Improved YOLOv5's traffic sign detection algorithm[J]. Computer Engineering and Application, 2023, 59(13): 194-204. (in Chinese with English abstract)
- [19] QIN C, ZHOU Z. YOLO-FGD: A fast lightweight PCB defect method based on FasterNet and the gather-and-distribute mechanism[J]. Journal of Real-Time Image Processing, 2024, 21(4): 122.
- [20] CAI Y, HE M, TAO Q, et al. Fast rail fastener screw detection for vision-based fastener screw maintenance robot using deep learning[J]. Applied Sciences, 2024, 14(9): 3716.
- [21] 李洋, 侯文慧, 杨辉煌, 等. 密植环境下基于域自适应学习的番茄检测方法[J]. 农业工程学报, 2024, 40(13): 134-145.
LI Yang, HOU Wenhui, YANG Huihuang, et al. Tomato detection method using domain adaptive learning for dense planting environments[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(13): 134-145. (in Chinese with English abstract)
- [22] SHAO Y, YANG Z, LI Z. Aero-YOLO: An efficient vehicle and pedestrian detection algorithm based on unmanned aerial imagery[J]. Electronics, 2024, 13(7): 1190.
- [23] 马跃, 黄周睿, 周雯, 等. 基于感受野注意力的轻量化林火检测算法[J]. 计算机工程, 2024, 53(43): 143-153.
MA Yue, HUANG Zhouhui, ZHOU Wen, et al. Lightweight forest fire detection algorithm based on receptive field attention[J]. Computer Engineering, 2024, 53(43): 143-153. (in Chinese with English abstract)
- [24] ZHANG D, BU Y, CHEN Q, et al. TW-YOLO: An innovative blood cell detection model based on multi-scale feature fusion[J]. Sensors, 2024, 24(19): 6168.
- [25] 毛清华, 翟姣, 胡鑫, 等. 煤矿综采工作面人员入侵危险区域智能识别方法研究[J]. 煤炭学报, 2024, 13(36): 160-168.
MAO Qinghua, ZHAI Jiao, HU Xin, et al. Research on intelligent recognition method for personnel intrusion hazardous area in fully mechanized mining face[J]. Journal of China Coal Society, 2024, 13(36): 160-168. (in Chinese with English abstract)
- [26] 姚凌云, 周俊峰, 李丽. 改进 YOLOv5su 模型检测桃树缩叶病[J]. 农业工程学报, 2024, 40(14): 109-117.
YAO Lingyun, ZHOU Junfeng, LI Li. Improving the YOLOv5su model for detecting peach tree leaf curl disease[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(14): 109-117. (in Chinese with English abstract)
- [27] ZHANG H, ZHANG S. Shape-IoU: More accurate metric considering bounding box shape and scale[EB/OL]. Arxiv: [2024-12-29]. <https://doi.org/10.48550/arXiv.2312.17663>.
- [28] HE Y, WAN L. YOLOv7-PD: Incorporating DE-ELAN and NWD-CIoU for advanced pedestrian detection method[J]. Information Technology and Control, 2024, 53(2): 390-407.
- [29] 靳红杰, 马顾戡, 唐梦圆, 等. 复杂环境下黄花菜识别的 YOLOv7-MOCA 模型[J]. 农业工程学报, 2023, 39(15): 182-189.
JIN Hongjie, MA Guyu, TANG Mengyuan, et al. Identifying daylily in complex environment using YOLOv7-MOCA model[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2023, 39(15): 182-189. (in Chinese with English abstract)
- [30] HAN K, WANG Y, XU C, et al. GhostNets on heterogeneous devices via cheap operations[J]. International Journal of Computer Vision, 2022, 130(4): 1050-1069.
- [31] 彭红星, 徐慧明, 刘华鼎. 基于改进 ShuffleNet V2 的轻量化农作物害虫识别模型[J]. 农业工程学报, 2022, 38(11): 161-170.
PENG Hongxing, XU Huiming, LIU Huanai. Lightweight agricultural crops pest identification model using improved ShuffleNet V2[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(11): 161-170. (in Chinese with English abstract)
- [32] EMMANUEL P, IOANNIS E, VASILIS T, et al. MobileNet-HeX: Heterogeneous ensemble of MobileNet experts for efficient and scalable vision model optimization[J]. Big Data and Cognitive Computing, 2025, 9(1): 2.
- [33] 杨大勇, 黄正栋, 郑昌贤, 等. 基于改进 YOLOv8n 的茶叶

- 嫩梢检测方法[J]. *农业工程学报*, 2024, 40(12): 165-173.
YANG Dayong, HUANG Zhengli, ZHENG Changxian, et al. Detecting tea shoots using improved YOLOv8n[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2024, 40(12): 165-173. (in Chinese with English abstract)
- [34] 刘忠, 卢安舸, 崔浩, 等. 基于改进 YOLOv8 的轻量化荷叶病虫害检测模型[J]. *农业工程学报*, 2024, 40(19): 168-176.
LIU Zhong, LU Ange, CUI Hao, et al. Lightweight model for detecting lotus leaf diseases and pests using improved YOLOv8[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2024, 40(19): 168-176. (in Chinese with English abstract)
- [35] XIONG C, JIANG X. A novel model for instance segmentation and quantification of bridge surface cracks the YOLOv8-AFPN-MPD-IoU[J]. *Sensor*, 2024, 24(13): 4288.
- [36] 王伟辉, 信泽阳, 车清论, 等. 基于改进 Faster RCNN 模型的冬枣缺陷检测方法[J]. *农业工程学报*, 2024, 40(22): 283-289.
WANG Weihui, XIN Zeyang, CHE Qinglun, et al. Detecting winter jujube defects using improved Faster RCNN model[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2024, 40(22): 283-289. (in Chinese with English abstract)
- [37] 章永龙, 解亚玲, 徐向英, 等. 基于改进 Mask R-CNN 的黄瓜叶面积测量模型[J]. *农业工程学报*, 2023, 39(17): 182-189.
ZHANG Yonglong, XIE Yaling, XU Xiangying, et al. Measuring the cucumber leaf area using improved Mask R-CNN[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2023, 39(17): 182-189. (in Chinese with English abstract)
- [38] SONG P, CHEN K, ZHU L, et al. An improved cascade R-CNN and RGB-D camera-based method for dynamic cotton top bud recognition and localization in the field[J]. *Computers and Electronics in Agriculture*, 2022, 202: 107442.
- [39] LI T, WANG J, ZHANG T. L-DETR: A light-weight detector for end-to-end object detection with transformers[J]. *IEEE Access*, 2022, 10: 105685-105692.
- [40] ZHANG X, CHEN L. Bud-YOLO: A real-time accurate detection method of cotton top buds in cotton fields[J]. *Agriculture*, 2024, 14(9): 1651.

Cotton top bud recognition method based on DFR-SN-YOLO

FANG Huimin^{1,2}, XU Quanwang¹, CHEN Xuegeng^{1,3}, ZHANG Qingyi^{1,2*}, LU Jialu¹

(1. School of Agricultural Engineering, Jiangsu University, Zhenjiang 212013, China; 2. Key Laboratory of Modern Agricultural Equipment and Technology (Jiangsu University), Ministry of Education, Zhenjiang 212013, China; 3. College of Mechanical and Electrical Engineering, Shihezi University, Shihezi 832003, China)

Abstract: Mechanical topping has been one of the most critical procedures in cotton cultivation. The precise identification of apical top buds is often required to avoid missing immature buds for high yield. However, existing topping can fail to distinguish between mature and immature cotton top buds in the densely planted fields, leading to inefficient detection under varying maturity levels and complex environmental conditions. In this study, a YOLOv5s-based model (DFR-SN-YOLO) was proposed for the lightweight and accurate detection of the cotton top bud. A lightweight backbone was integrated with the position-aware attention, receptive-field-aware feature fusion, and a Shape-NWD-IoU loss function. The backbone network was redesigned using depthwise separable convolution (DWConv). An optimized C3_Faster module was employed to reduce the computational complexity for the high efficiency of the feature extraction. The standard convolution was replaced with the efficient DWConv convolution to reduce the number of model parameters. The C3_Faster module was incorporated with the Partial Convolution (PConv) to minimize the memory access and computational redundancy. Furthermore, CoordAttention (CA) was embedded into the backbone to capture the spatial positional relationships between mature and immature top buds. The CA was retained on the location-specific features using 1D average pooling in a horizontal and vertical manner, in order to detect the small top buds. A C3_RFCBAMConv module was introduced into the neck network. Receptive Field Attention (RFA) was combined with a modified convolutional block attention module (CBAM). The spatial feature perception was enhanced to dynamically adjust the convolutional kernel parameters according to the spatial patterns of the receptive field. A squeeze-and-excitation (SE) module was integrated for the channel attention, and a spatial attention module (SAM) for the spatial feature weighting. The robust recognition of immature top buds was observed under the cluttered environments. A hybrid loss function, Shape-NWD-IoU (SN-IoU), was proposed to detect the small and irregularly shaped cotton top buds. The SN-IoU was combined with the Shape-IoU. The geometric constraints (e.g., aspect ratio and scale) of bounding boxes were incorporated with the normalized wasserstein distance (NWD), indicating the similarity between Gaussian-modeled bounding boxes. The localization accuracy was improved on the immature top buds after fusion, particularly under low intersection-over-union (IoU) scenarios. A series of experiments was conducted on a dataset of 5,115 images (expanded by saturation adjustment, noise injection, and angle flipping). The images under diverse lighting and occlusion conditions were collected from the cotton fields in Xinjiang. The improved model was trained on an NVIDIA RTX 4090 GPU with a batch size of 32 and a learning rate of 0.01. Evaluation metrics included the precision (*P*), recall (*R*), mAP, parameters, GFLOPs, and inference speed (FPS). DFR-SN-YOLO was compared with several widely-used object detection models, including the YOLO series (v3-v11) for one-stage networks; Faster RCNN, Mask RCNN, and Cascade R-CNN for two-stage networks; DETR; and existing bud recognition models, such as YOLO-cpp and Bud-YOLO. The results show that the DFR-SN-YOLO outperformed the rest in terms of the average detection accuracy (mAP). Compared with the baseline, the meanaverage precision (mAP@50) increased by 3 percentage points to 97.5%, the accuracy of top buds rose by 3.9 percentagepoints to 92.4%, and the recall rate reached 95.0%. This effectively addresses the issue of missed detection of small top buds. In addition, the model parameters are only 3.9M. Furthermore, the inference speed reached 37 frames/s when deployed on the edge computing device, Jetson Nano 4GB. The cotton apical buds were accurately identified in the different growth states, and then the number of computation parameters was determined for the high accuracy of the apical bud identification. This work can provide the technical support to the subsequent intelligent mechanical topping of cotton.

Keywords: cotton top bud; image recognition; edge deployment; YOLOv5s; small target; structural relevance