

自然光环境下番茄穴盘苗缺苗检测的 YOLO-SFEP 模型

张聪华，任玲^{*}，崔建谱，杨苗，张玉泉，
朱祥建，刘军平

(1. 石河子大学机械电气工程学院，石河子 832003；2. 农业农村部西北农业装备重点实验室，石河子 832003；
3. 现代农业机械兵团重点实验室，石河子 832003)

摘要：番茄穴盘苗缺苗信息的精确检测对智能温室移栽至关重要。该研究以提高对密集性番茄穴盘苗缺苗信息的小目标检测能力、提高模型的光照鲁棒性、减少模型的计算规模和提升模型的训练性能为目标，提出了一种基于改进 YOLOv8n 的温室环境下的番茄穴盘苗缺苗检测模型 YOLO-SFEP。首先，通过结合空间到深度卷积 SPDCConv (space-to-depth convolution) 和 Omni-Kernel 模块优化 YOLOv8n 模型的 P3 检测层以提高模型的小目标检测能力，提高模型的检测精度；其次，在 YOLOv8n 颈部网络中添加高效多尺度注意力机制 EMA (efficient multi-scale attention) 模块，提升模型对番茄穴盘苗缺苗信息的关注，减少复杂光照条件的干扰；然后，采用 FasterNet 网络中的 FasterNet Block 模块替换 YOLOv8n 网络结构里 C2f (cross-stage partial bottleneck with two convolutions) 模块中的 Bottleneck 模块，使模型在保持较高识别准确性的基础上降低模型大小和计算复杂度，实现模型的轻量化；最后，将损失函数 CIoU (complete intersection over union) 替换为 PIoU (powerful-IoU)，通过使用惩罚因子来适应目标大小，优化模型的收敛效果。试验结果表明，建立的 YOLO-SFEP 番茄穴盘苗缺苗检测模型的精确率为 96.7%，较基准模型 YOLOv8n 提高了 2.4 个百分点；模型的参数量和计算量分别为 2.62 M 和 7.6 G，较 YOLOv8n 分别降低了 0.39 M 和 0.5 G；模型大小仅为 5.5 MB，较基准模型减少了 0.8 MB；该模型对光照变化表现出强适应性，在弱光、中光与强光下的平均精度均值分别达 96.7%、98.9% 和 98.1%，具有高鲁棒性；将此模型部署至边缘计算设备树莓派 5 上，可实现的检测帧率为 13.8 帧/s，具有良好的边缘端部署前景。该模型实现了对番茄穴盘苗缺苗信息的精准识别，可为后续移栽机的自动补苗提供缺苗穴孔位置信息。

关键词：缺苗检测；番茄穴盘苗；YOLO-SFEP；注意力机制；光照鲁棒性；边缘端部署

doi: 10.11975/j.issn.1002-6819.202504135

中图分类号: S24; TP391.4

文献标志码: A

文章编号: 1002-6819(2025)-22-0215-11

张聪华，任玲，崔建谱，等. 自然光环境下番茄穴盘苗缺苗检测的 YOLO-SFEP 模型[J]. 农业工程学报, 2025, 41(22): 215-225. doi: 10.11975/j.issn.1002-6819.202504135 <http://www.tcsae.org>

ZHANG Conghua, REN Ling, CUI Jianpu, et al. YOLO-SFEP: A lightweight model for missing tomato plug seedling detection in natural light environments[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(22): 215-225. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202504135 <http://www.tcsae.org>

0 引言

番茄是新疆主要经济作物，2024 年产量已占全国 85%，出口量更是长期稳占全国总出口量的 90% 以上^[1]。新疆番茄种植主要采用温室育苗移栽方式，该方式能够避免番茄苗在播种时受到倒春寒等恶劣气候影响，保证幼苗成活率，以提高作物产量和保证作物品质^[2]。然而，在大规模温室穴盘育苗时，常因种子发芽率不高、播种不均匀或环境因素不适，造成某些穴孔缺苗^[3-5]。因此，为确保穴盘内幼苗生长的一致性，减少大田移栽时漏栽的可能性，需要在育苗早期（2 叶 1 心期）检测番茄穴盘中的缺苗情况，为后续穴盘苗的补栽提供位置信息^[6]。

番茄穴盘苗的缺苗检测是移栽前的重要工序，目前主要依赖人工目检。该方法不仅效率低下、耗费人力，且其准确性易受个人经验等主观因素影响，导致漏检或误检，难以满足大规模番茄种植的需求^[7-8]。因此，针对新疆番茄种植规模大的特点，研究适应温室环境的番茄穴盘苗缺苗检测方法，对于保障后续移栽作业质量、降低生产成本和促进新疆番茄产业的持续健康发展具有重要意义。

在缺苗检测问题研究的早期阶段，国内外学者探索利用基于传统图像处理方法的机器视觉技术，以实现缺苗的自动化识别。张丽娜等^[9]通过深度相机获取黄瓜穴盘幼苗的点云数据，以叶面积和株高的乘积作为分级系数，以整盘穴盘幼苗分级系数的均值与标准差差值作为该穴盘的晚出苗分级阈值，实现对穴盘晚出苗的自动检测。FU 等^[10]利用机器视觉技术检测叶菜苗生长参数，通过对图像进行灰度化和阈值分割处理得到幼苗叶面积的像素值，并与预定标准值进行比较，对不合格苗和合格苗的检测准确率分别为 62.50% 和 88.16%。JIN 等^[11]采用深度相机获取单行幼苗的侧面图像，通过基于 OpenCV 的图像分析以及深度图像的对齐，精确获取幼苗的形态信息，提高了移栽的成功率。LIU 等^[12]通过图

收稿日期: 2025-04-15 修订日期: 2025-09-23

基金项目: 国家自然科学基金资助项目 (52165036); 石河子大学高层次人才项目 (RCZK2021B17); 石河子大学自主资助支持科研项目 (ZZZC202105)

作者简介: 张聪华，研究方向为机器视觉在农业工程中的应用。

Email: zhjob126@126.com

※通信作者: 任玲，博士，教授，研究方向为农业自动化与信息化。

Email: 2542958572@qq.com

像预处理的方式,从穴盘苗图像中提取特征点,并进行定位计算,确定穴盘苗的生长姿态。以上文献均基于传统的图像处理方法进行图像预处理和特征提取,该方法通常采用颜色空间转换和阈值分割,而温室光照强度的变化会导致幼苗叶片颜色特征的改变,固定阈值无法自适应调整,容易导致误检和漏检对检测精度有很大影响,检测稳定性不高。

近年来,深度学习相关算法也被广泛应用于农业领域的图像分类、分割和目标检测等任务。王璨等^[13]通过引入双注意力机制改进语义分割模型,有效区分了形态边界高度相似的幼苗期玉米与杂草。宋磊等^[14]利用深度学习中的单目图像深度估计技术,以 ResNeXt 101 网络为深度估计网络主体,通过深度估计网络获取图像的深度信息,计算拍摄点到植株的真实距离,实现了对多种幼苗在不同距离和一定光照强度变化下的精确测量。张秀花等^[15]提出了 YOLOv3-Tiny 目标检测改进模型,通过添加空间金字塔池化 SPP (spatial pyramid pooling) 和路径聚合网络 PANet (path aggregation network) 等方法,提高了番茄苗分选移栽分级检测精度。JIN 等^[16]提出了 EBG_YOLOv5 模型,通过在主干网络中集成高效的通道注意力机制 ECA (efficient channel attention),在颈部引入双向特征金字塔和分组混洗卷积 GSConv (group shuffle convolution),提高了水培生菜残次叶片的检测精度和效率。然而,尽管基于深度学习的检测模型精度较高,其计算复杂度也相应提升,通常依赖高性能 GPU (graphics processing unit) 或 CPU (central processing unit) 进行推理,对硬件资源要求较高^[17]。而实际农业生产场景中,受成本与部署条件限制,主要采用计算资源有限的边缘计算设备^[18-19]。因此,面向农业边缘计算环境,研究兼具轻量化与高精度的检测模型具有重要的现实意义。

本文以 YOLOv8n 目标检测模型为基础,构建一种模型 YOLO-SFEP 以实现温室环境中番茄穴盘苗的缺苗检测,通过优化原始 YOLOv8n 网络的 P3 小目标检测层来融合 P2 极小目标检测层的特征信息,以提高模型的小目标检测能力;通过引入 EMA 注意力机制,使模型聚焦于缺苗区域,抑制光照变化干扰背景;采用 FasterNet Block 替换 C2f 模块中的 Bottleneck,以降低模型大小和计算复杂度,方便后续将模型部署到资源受限的边缘设备上;替换损失函数 CIoU 为 PIoU,加快模型的收敛速度,降低模型训练的成本;最终,将模型部署于树莓派 5 边缘计算设备,进行番茄穴盘苗缺苗检测的性能测试与验证,为实现该模型的边缘端实际应用提供技术依据。

1 材料与方法

1.1 图像采集与数据集制作

本研究选取新疆苗龄 20 d 的新红 49 号番茄穴盘苗作为研究对象。图像采集时间为 2024 年 4 月上旬和 2025 年 3 月下旬,采集地点位于石河子大学农场培育基地的温室大棚,试验区域如图 1a 所示。采用的图像采集设备为 Canon Eos 600D 相机,图像分辨率为 5 184×3 456 像素。由于温室大棚内的光照条件存在显著的时段性变化,本研究为获取具有光照多样性的数据集,特选择在早上、中午及下午等不同时段采集番茄穴盘苗图像,采

集示例如图 1 所示。最终,共筛选并构建出包含较弱光照图像 360 张、正常光照图像 380 张及较强光照图像 360 张的数据集。




图 1 试验区域及番茄穴盘苗样例

Fig.1 Experimental area and tomato plug seedling samples

以便于模型训练,本研究对图像进行裁剪以统一尺寸,降低计算复杂度。同时,为应对缺苗样本不足的问题,裁剪策略保证了每张图像至少包含一个缺苗穴孔,以此提升其比例。最终图像均包含 24 个穴孔,具体示例如图 2a 所示。

本研究采用单类别检测方法,仅标注缺苗穴孔,以简化模型结构,提高推理速度,从而满足实时性要求。本文将满足以下条件的穴孔判定为缺苗:穴孔内基质表面无任何绿色幼苗组织,且无新生子叶和真叶。在此基础上,使用 Labellmg 工具对缺苗穴孔进行边界框标注,标注时确保边界框完整覆盖穴孔边缘,同时避免与相邻穴孔重叠。缺苗目标统一标记为“none”类别,并生成对应的*.txt 标注文件。为提升模型在真实场景下的泛化能力,使其能够适应番茄穴盘苗在不同形态与环境下的变化,本研究采用图像增强技术对数据集进行扩充^[20]。通过对原始图像进行随机翻转、裁剪、高斯模糊以及亮度与色彩调整等变换,生成具有多尺度、多视角和不同光照条件的增强样本^[21]。最终构建的数据集共包含 7 700 张图像,增强示例如图 2 所示。最后,为了确保模型训练的有效性和评估的可靠性,将数据集按 8:1:1 的比例随机分割成训练集、验证集和测试集。

1.2 基准模型 YOLOv8 网络结构

YOLOv8 继承了 YOLO 系列的设计理念,并提供了 n、s、m、l、x 共 5 种尺度不同的模型^[22]。YOLOv8 网络模型结构主要由三部分组成:主干网络 (Backbone)、颈部网络 (Neck) 和头部网络 (Head)。主干网络主要采用 C2f 模块作为基本构成单元负责从输入图像中高效提取多层次缺苗特征;颈部网络位于主干网络和头部网络之间,负责多尺度特征融合,通过将来自 Backbone 不同阶段的特征图进行融合,增强特征表示能力;头部网络通过无锚框 (Anchor-free) 的方式,直接预测目标边界框的四个角点和中心点,以简化模型结构,并减少锚

框设置的超参数,降低漏检和误检的概率^[23]。

针对番茄穴盘苗缺苗检测任务及边缘设备的算力限制,本研究需兼顾检测精度与模型轻量化。由于 YOLOv8 系列中较大模型因计算复杂而无法满足实时性要求,故最终选择尺度最小的 YOLOv8n 作为基准模型。

1.3 番茄穴盘苗缺苗检测模型的构建

本文提出了一种改进的 YOLOv8n 模型 YOLO-SFEP,分别进行了 P3 小目标检测层的优化、引入注意力机制、模型轻量化设计和损失函数的优化,改进后的模型网络结构如图 3 所示。





图 2 数据增强效果示意图

Fig.2 Schematic of data augmentation effect



注: P1~P5 分别为输入图像经过 2 倍、4 倍、8 倍、16 倍和 32 倍下采样后的特征图; Conv2d 为卷积; BatchNorm2d 为批量归一化; Concat 为拼接操作; SiLU 为激活函数; MaxPool2d 表示最大池化; CFNB 表示使用 FasterNet 模型中的 FasterNet Block 替换原 YOLOv8n 模型的 C2f 中的 Bottleneck; SION 表示对 P3 小目标检测层进行优化; EMA 表示引入 EMA 注意力机制; PLoU 表示损失函数的优化; DFL 为分布焦点损失; BCE 为二元交叉熵损失函数。
Note: P1 to P5 are the feature maps of the input image after downsampling by factors of 2, 4, 8, 16, and 32 respectively. Conv2d denotes convolution; BatchNorm2d denotes batch normalization; Concat denotes concatenation operation; SiLU denotes activation function; MaxPool2d denotes max pooling; CFNB denotes replacing the Bottleneck in the C2f module of the original YOLOv8n model with the FasterNet Block from the FasterNet model; SION denotes optimization of the P3 small-target detection layer; EMA denotes introducing the EMA attention mechanism; PLoU denotes optimization of the loss function; DFL denotes distribution focal loss; BCE denotes binary cross-entropy loss function.


图 3 YOLO-SFEP 模型的整体网络结构

Fig.3 Overall network structure of the YOLO-SFEP model

1.3.1 小目标检测层的优化

原始 YOLOv8n 模型采用 P3、P4、P5 三个检测头，其对应特征图的下采样倍数分别为 8、16 和 32，适用于中等及以上尺寸的目标检测。然而，番茄穴盘苗图像中的缺苗穴孔呈现为小目标，其特征（如颜色与纹理）在经深层网络多次下采样后细节丢失严重，导致模型难以捕获有效的判别性特征。

为提升小目标检测性能，常规解决方案是增加 P2 检测层，但这会显著增加计算复杂度与后续处理难度。为此，本研究在颈部网络进行改进，提出一种小目标改进网络 SION (small object improve net)。该网络并非直接添加 P2 检测层，而是通过空间到深度卷积 SPDCConv (space-to-depth convolution) [24] 对富含细节的 P2 层特征进行压缩与编码，再将所得特征融合至 P3 层。随后，采用 Omni-Kernel 模块对融合后的多尺度特征进行高效整合。如图 4 所示，Omni-Kernel 模块通过其全局、大核与局部分支，能够协同学习从全局上下文到局部细节的特征表征，从而显著增强模型对微小缺苗目标的检测能力 [25]。



注：Dconv 为深度可分离卷积；FCA 为频率通道注意力；SCA 为空间通道注意力；FFT 和 IFFT 分别表示快速傅里叶变换及其逆运算。
Note: Dconv denotes depth-wise convolution; FCA denotes frequency channel attention; SCA denotes spatial channel attention; FFT and IFFT denote fast Fourier transform and its inverse operation, respectively.

图 4 Omni-Kernel 模块结构

Fig.4 Omni-Kernel module structure diagram

1.3.2 引入 EMA 高效多尺度注意力机制

温室环境中的光照变化易对缺苗检测造成干扰。为提升模型的光照鲁棒性，使其能准确聚焦于缺苗区域并抑制背景噪声，本研究在颈部网络中引入高效多尺度注意力 (EMA) 机制 [26]。该机制通过双路径优化提升模型光照鲁棒性：一方面增强全局上下文建模能力，精准区分缺苗区域与背景噪声，减少无效特征干扰；另一方面动态调整通道权重，优先强化含缺苗关键信息的通道响应，弱化光照变化引发的冗余特征影响。EMA 注意力机制模块网络结构如图 5 所示。具体实现流程如下：

首先，将输入特征图 $X \in \mathbb{R}^{C \times H \times W}$ 按通道维度划分为 G 个独立分组，每组包含 $C' = C//G$ 个通道，即：

$$X = [X_0, X_1, \dots, X_{G-1}] \quad (1)$$


其中 $X_i \in \mathbb{R}^{C' \times H \times W}$ 为分组后的子特征图。此操作可降低计算开销，同时使模型聚焦不同分组的特征差异，提升多尺度特征表征能力。

其次，对每个子特征图 X_i 分别执行水平 (X 方向) 和垂直 (Y 方向) 全局平均池化： X 方向池化通过式 (2) 提取每行全局信息，输出维度为 $C' \times H \times 1$ 。

$$X_{i,X-avg} = \frac{1}{W} \sum_{i=1}^W X_i \quad (2)$$

Y 方向池化同理，提取每列全局信息，输出维度为 $C' \times 1 \times W$ ；随后，将双向池化结果融合，形成包含空间全维度信息的特征向量，经卷积层生成注意力权重。

最后，通过权重对原始子特征图加权增强，融合所有分组特征输出最终增强特征图。该过程既保留原始特征细节，又通过多尺度注意力校准强化缺苗特征辨识度，可提升模型在复杂光照条件下的检测稳定性。



注： H 和 W 分别表示图像的高度和宽度； C 为通道数； G 表示通道分组；“//”表示分组操作； X Avg Pool 和 Y Avg Pool 分别表示在水平和垂直方向进行全局平均池化。
Note: H and W represent the height and width of the image, respectively; C is the number of channels; G means the divided groups; “//” denotes the grouping operation; X Avg Pool represents the 1D horizontal global pooling and Y Avg Pool indicates the 1D vertical global pooling, respectively.

图 5 EMA 注意力机制模块网络结构图

Fig.5 EMA attention mechanism module network structure diagram

1.3.3 模型轻量化设计

为适配温室场景下边缘计算设备（如树莓派、嵌入

式工控机)的资源约束,在保障检测精度的前提下降低模型部署门槛,需通过轻量化设计精简参数量与计算量,实现模型在有限算力、存储资源下的高效运行。由于原始 YOLOv8n 中 C2f 模块的 Bottleneck 组件存在计算冗余,本研究提出以 FasterNet 网络^[27]的 FasterNet Block 模块替换 C2f 模块中的 Bottleneck,构建新型 CFNB 模块,并将原始网络中所有 C2f 模块全量替换为该模块,实现模型轻量化。


FasterNet Block 由部分卷积 PConv (partial convolution)、逐点卷积 PWConv (pointwise convolution) 以及标准化层与激活层构成,如图 6a 所示。其核心是 PConv,如图 6b 所示,它仅对输入通道的一部分应用常规卷积,而保持其余通道不变。PConv 的计算量为

$$\text{FLOPs}_{\text{PConv}} = H \cdot W \cdot K^2 \cdot C_p^2 \quad (3)$$


当 $C_p = \frac{1}{4}C$ 时, $\text{FLOPs}_{\text{PConv}}$ 只有常规卷积的 1/16。另外, PConv 有更少的内存访问次数,其计算式为

$$H \cdot W \cdot 2C_p + K^2 \cdot C_p^2 \approx H \cdot W \cdot 2C_p \quad (4)$$

当 $C_p = \frac{1}{4}C$ 时,内存访问次数只有常规卷积的 1/4。该设计巧妙利用了特征图间的冗余性,通过显著减少冗余的计算与内存访问,在仅牺牲极少精度的前提下,大幅降低了计算负载。随后附加的 PWConv 则用于融合所有通道的信息。PConv 与 PWConv 的组合形成了类似 T 型卷积的高效感受野,能更专注于中心位置的特征聚合。



a. FasterNet Block 模块结构图
a. FasterNet Block module structure diagram



b. PConv 原理图
b. PConv schematic

注: H 和 W 分别表示特征图的高度和宽度; C_p 为参与 PConv 计算的通道数; “*”表示常规卷积操作; K 表示卷积核的大小。
Note: H and W represent the height and width of the feature map respectively; C_p represents the number of channels involved in the PConv calculation; “*” indicates the conventional convolution operation; K represents the size of the convolution kernel.

图 6 FasterNet Block 模块结构及 PConv 原理图

Fig.6 FasterNet Block module structure diagram and PConv principle diagram

通过上述替换,模型在保持特征提取能力的同时,参数量与计算复杂度得到有效控制,为后续在边缘设备上的实时检测奠定了基础。

1.3.4 损失函数的优化

在目标检测任务中,边界框回归的精度直接影响模

型的定位性能与训练效率。YOLOv8n 原采用的 CIoU 损失函数虽考虑了中心点距离与宽高比,但难以准确反映预测框与真实框之间的整体形状差异,易导致训练过程中收敛不稳定,限制模型检测精度的进一步提升。

为克服上述缺陷并提升模型训练性能,本研究引入 PIoU 损失函数^[28]以优化回归过程。PIoU 在 IoU 基础上引入形状惩罚因子 P_F ,其核心原理如图 7 所示。该因子通过计算预测框与目标框四边绝对距离之和与其对应目标框宽高的比值,来衡量二者的形状差异,具体计算方式如下:


$$P_F = \left(\frac{dw_1}{w_{gt}} + \frac{dw_2}{w_{gt}} + \frac{dh_1}{h_{gt}} + \frac{dh_2}{h_{gt}} \right) / 4 \quad (5)$$

同时,PIoU 通过梯度调整函数 $f(x) = 1 - e^{-x^2}$,依据预测框质量进行动态梯度分配:对低质量预测框抑制有害梯度,对中等质量预测框加速回归,对高质量预测框则稳定优化过程。PIoU 值及其损失函数定义如下:

$$\text{PIoU} = \text{IoU} - f(P_F), -1 \leq \text{PIoU} \leq 1 \quad (6)$$

$$L_{\text{PIoU}} = 1 - \text{PIoU} = L_{\text{IoU}} + f(P_F), 0 \leq L_{\text{PIoU}} \leq 2 \quad (7)$$

该损失函数通过自适应梯度机制,有效缓解了预测框扩大问题,不仅能加快模型收敛速度,也能增强训练过程的稳定性,从而整体提升定位精度与训练效率。



注: dw_1 , dw_2 , dh_1 和 dh_2 分别为预测框和目标框对应边之间距离的绝对值, w_{gt} 和 h_{gt} 分别表示目标框的宽度和高度。

Note: dw_1 , dw_2 , dh_1 , and dh_2 are the absolute values of the distances between the corresponding sides of the predicted box and the ground truth box, respectively; w_{gt} and h_{gt} denote the width and height of the ground truth box, respectively.

图 7 PIoU 示意图

Fig.7 Schematic diagram of PIoU

1.4 评价指标

为准确评估模型性能,本研究主要采用精确率 P 、召回率 R 和平均精度均值 (mean average precision, mAP) 来评估目标检测模型对缺苗情况的检测精度;采用模型参数量、浮点计算量 (floating point operations, FLOPs) 以及模型大小等指标来评估目标检测模型复杂度;采用推理时间评估模型的检测速度^[29]。

精确率是指检测到的正样本被正确分类的比例,而召回率是指实际为正的样本中被正确预测为正的样本,其计算式如下:

$$P = \frac{T_p}{T_p + F_p} \times 100\% \quad (8)$$

$$R = \frac{T_p}{T_p + F_n} \times 100\% \quad (9)$$

式中 T_p 为将正样本中正确检测出来缺苗类别的样本数量; F_p 为错误预测的负样本数量; F_n 为错误预测的正样本

数量。

本文提出的缺苗检测方法是一种二分类方法，主要用于检测番茄穴盘苗图像中存在的缺苗目标，因此 mAP 等于平均精度（average precision, AP），mAP50 是 IoU 阈值设置为 0.5 时测得的平均 AP 值，mAP 的计算式如下：

$$\text{mAP} = \int_0^1 P(R) dR \quad (10)$$

模型参数量是用于衡量模型复杂度的重要指标，其数值越小，代表模型越轻量化。对于卷积层来说，参数的计算式如下：

$$\text{Parameters} = C_{in} \cdot K^2 \cdot C_{out} + C_{out} \quad (11)$$

式中 C_{in} 代表输入的通道数； C_{out} 代表输出的通道数。

FLOPs 代表浮点运算次数，用于衡量模型的计算复杂度，并间接反映其运行速度。对于卷积层来说，FLOPs 的计算式如下：

$$\text{FLOPs} = 2H \cdot W \cdot C_{in} \cdot K^2 \cdot C_{out} \quad (12)$$

模型推理就是在利用大量数据训练好模型的结构和参数后，使用小批量数据进行一次前向传播，从而得到模型输出的过程，模型推理时间的长短决定了实际部署环境下检测速度的快慢，因此将推理时间作为评估模型性能优劣的指标之一。

1.5 模型训练与部署环境

本试验模型训练和评估均在同一试验环境下运行，所使用的软硬件环境详细信息如表 1 所示。

表 1 试验环境配置

Table 1 Experimental environment configuration

软硬件环境 Software and hardware environment	详情 Details
显卡 GPU	NVIDIA GeForce RTX 3060 Laptop GPU
处理器 CPU	AMD Ryzen 75800H with Radeon Graphics @ 3.20 GHz
CPU 核数 CPU core	12
显存 Display memory	6 GB
内存 Memory	16 GB
操作系统 Operating system	Windows 11
统一计算设备架构 CUDA	Cudnn-8.0
编程语言 Programming language	Python3.8
深度学习框架 Deep Learning Framework	PyTorch

网络模型训练的参数设置如表 2 所示，其中批量大小是根据训练模型硬件设备的算力和显卡的显存决定每批次处理图像的数量；迭代轮数是根据训练过程中损失函数的收敛情况确定的，其余各项参数的设定参照了官方在 COCO 公共数据集上训练 YOLOv8n 模型时的最佳配置^[30]。

模型部署在基于树莓派 5 的边缘计算环境中，该环境的硬件配置包括一个运行频率为 2.4 GHz 的四核 Cortex-A76 处理器和 4 GB 的运行内存，足以支撑模型的本地推理计算。软件环境则包括 Raspberry Pi OS 操作系统，以及用于模型加载和推理的 PyTorch 2.1.0 深度学习框架和 Python 3.8 编程语言环境。

表 2 模型训练参数设置

Table 2 Model training parameter settings

设置 Settings	参数 Parameters	值 Values
训练设置 Training settings	输入大小	640×640 像素
	批量大小	8
	训练轮数	200
	优化器	AdamW
超参数 Hyperparameters	初始学习率	0.01
	权重衰减	0.000 5
	暂退法	0.2
	动量法	0.9
	混合精度训练	True

2 结果与分析

2.1 模型训练结果分析

为验证损失函数优化的效果，在自制的番茄穴盘苗数据集上对 YOLOv8n 与 YOLO-SFEP 进行训练，并从类别损失与位置损失两方面进行对比。如图 8 所示，随着迭代轮次增加，两模型的损失值均持续下降，表明其拟合能力与性能逐步提升。YOLOv8n 的损失曲线约在 160 轮后开始收敛，而 YOLO-SFEP 则在 150 轮后即趋于稳定，证明改进后的模型具有更快的收敛速度。




图 8 模型改进前后损失函数变化曲线

Fig.8 Loss function change curve before and after model improvement

由图 8a 的模型训练过程中类别损失函数的变化趋势可知，YOLO-SFEP 相较于 YOLOv8n 的类别损失函数值在收敛时表现出更小的损失值，反映了模型对检测目标所属类别的预测准确性更高，能够更准确地区别复杂背景和缺苗目标；图 8b 展示了模型训练过程中位置损失函数的变化趋势，YOLO-SFEP 相较于 YOLOv8n 的位置损失函数值在收敛时表现出更小的损失值，表明模型生成的预测框与真实框的位置误差较小，能够更加准确的定位到缺苗目标。因此，YOLO-SFEP 模型相比 YOLOv8n 具有更好的分类性能和定位能力。

2.2 多模块消融试验结果

为评估各改进模块对番茄穴盘苗缺苗检测模型性能的贡献，本文对 YOLO-SFEP 模型进行消融试验，分别引入了 4 项关键改进：首先，采用 Omni-Kernel 模块融合 P2 层特征，以增强小目标检测能力；其次，使用 FasterNet Block 替换所有 C2f 模块中的 Bottleneck 结构，降低模型复杂度；再次，在 Neck 部分引入 EMA 注意力机制，使模型聚焦于缺苗区域并抑制背景干扰；最后，将检测头中的 CIoU 损失函数替换为 PIoU，以加快模型

收敛速度。各模块组合对应的试验结果表 3 所示。

表 3 YOLO-SFEP 模型消融试验结果
Table 3 Results of the YOLO-SFEP model ablation experiments

试验 编号 Test No.	SION	CFNB	EMA	PloU	精确率 Precision/%	mAP50/%	参数量 Parameters/ M	计算量 FLOPs/ G
1	O	O	O	O	94.3	96.2	3.01	8.1
2	II	O	O	O	97.8	98.6	3.31	11.8
3	II	II	O	O	95.5	97.3	2.61	8.6
4	II	II	II	O	96.3	97.7	2.62	8.7
5	II	II	II	II	96.7	97.9	2.62	8.7

注：“II”表示添加，“O”表示未进行变动。
Note: The symbol "II" signifies implementation, while "O" denotes no modification.

根据表 3 第 1 组试验和第 2 组试验的结果对比可得，在第 2 组试验中对模型的小目标检测层进行优化后，模型的精确率比第 1 组的基准模型提升了 3.5 个百分点，平均精度均值提升了 2.4 个百分点，原因是融合 P2 检测层的特征后，模型能更多地捕获到缺苗区域的细微特征（如颜色和穴孔边缘的纹理特征），从而提高模型的检测精度；第 3 组试验是采用 CFNB 模块替换原始模型网络中全部的 C2f 模块，虽然模型的精确率有所下降，但模型的参数量比第 2 组减少了 0.7 M，计算量减少了 3.2 G，实现了模型的轻量化；第 4 组试验则是引入 EMA 注意机制后，使模型聚焦于缺苗区域，抑制光照干扰背景，相比第 3 组试验，在模型的参数量和计算量基本保持不变的同时具有更高的检测精度；第 5 组试验将模型的 CIoU 损失函数替换为 PloU 损失函数后，模型的精确率和平均精确率得到了略微的提升，原因在于 PloU 使用惩罚因子来适应目标大小，解决了预测框的扩大问题，使模型能够更好收敛。综上所述，改进后的模型可以在保持较高检测精度性能的同时，减少模型的复杂性和计算成本，适合在边缘设备上部署与实时运行。

2.3 不同目标检测模型性能对比

为研究 YOLO-SFEP 模型与其他目标检测模型对于番茄穴盘苗缺苗检测性能的差异，选取常见的目标检测模型：SSD（single shot multibox detector）^[31]、Faster R-CNN^[32]、YOLOv5n、YOLOv6n、YOLOv8n、YOLOv9n、YOLOv10n 和 YOLOv11n 开展了性能对比试验，试验结果如表 4 所示。

表 4 不同目标检测模型性能
Table 4 Performance of different object detection models

模型 Model	参数量 Parameters/ M	计算量 FLOPs/ G	模型 大小 Model size/ MB	精确率 Precision/ %	召回率 Recall/ %	mAP50/ %	帧率 FPS/ (帧·s ⁻¹)
SSD	23.60	30.4	92.3	94.7	90.3	94.6	5.9
Faster R-CNN	41.70	72.6	108.2	93.6	91.7	94.2	4.1
YOLOv5n	2.50	7.1	5.3	93.9	94.6	95.8	126.0
YOLOv6n	4.23	11.8	8.7	94.8	95.7	96.6	67.5
YOLOv8n	3.01	8.1	6.3	94.3	96.7	96.2	117.0
YOLOv10n	2.69	8.2	5.8	89.6	88.0	95.1	70.6
YOLOv11n	2.58	6.3	5.5	94.5	96.3	95.7	114.0
YOLO-SFEP	2.62	7.6	5.5	96.7	98.8	97.9	128.0

由表 4 可知，YOLO-SFEP 在整体性能上优于大多数主流目标检测模型。在模型的参数量和计算量方面，

YOLO-SFEP 明显低于 SSD 和 Faster R-CNN 模型，较基准模型分别减少了 0.39 M 和 0.5 G；在模型大小方面，YOLO-SFEP 较基准模型减少了 0.8 MB，仅为 5.5 MB；在精确率、召回率和 mAP50 方面，YOLO-SFEP 模型分别达到了最高的 96.7%、98.8% 和 97.9%，较基准模型分别提升了 2.4、2.1 和 1.7 个百分点；在帧率方面，YOLO-SFEP 模型高于其他模型，达到了 128 帧/s。基于上述结果，YOLO-SFEP 模型性能较其他主流目标检测模型具有明显优势，检测精度和速度均有明显提高，实现了模型轻量化，可以满足番茄穴盘苗缺苗检测的精度和实时性要求。

2.4 不同光照强度下模型的缺苗检测结果

为了验证 YOLO-SFEP 模型对光照强度的适应性，在几组不同的光照强度水平下进行了对比试验。由于使用照度计测量温室内自然光的光照强度范围为 500~80 000 lx，本研究将光照强度分为弱光（500~5 000 lx）、中光（5 000~50 000 lx）、强光（5 000~80 000 lx），表 5 展示了 YOLO-SFEP 模型在番茄穴盘苗缺苗检测任务中，弱光、中光和强光条件下的检测结果差异。

表 5 YOLO-SFEP 在不同光照强度下的缺苗检测结果
Table 5 Detection results of YOLO-SFEP on missing seedlings under different light intensities


光照强度 Light intensity	精确率 Precision/%	召回率 Recall/%	mAP50/%
弱光 Low-light	95.4	98.7	96.7
中光 Medium-light	97.8	99.2	98.9
强光 High-light	96.9	98.5	98.1
平均值 Average value	96.7	98.8	97.9

在中光条件下，模型取得了最优性能，精确率、召回率与 mAP50 分别达到 97.8%、99.2% 与 98.9%，表明该光照强度为模型特征提取提供了最佳的图像质量与对比度。在强光条件下，模型性能略有下降，尤其是召回率降低至 98.5%，原因是过曝现象掩盖了部分缺苗区域的边缘细节，导致少量漏检。在弱光条件下，模型仍保持了 98.7% 的高召回率，但精确率降至 95.4%，说明低对比度环境使模型更易将部分背景误判为缺苗目标，从而引入了误检。

总体而言，YOLO-SFEP 模型在不同光照强度下均表现出稳定的检测性能，各指标平均值分别达到 96.7%（精确率）、98.8%（召回率）与 97.9%（mAP50）。试验结果验证了模型对自然光环境变化的良好适应性，其中弱光条件下的精确率仍有提升空间，未来可通过增强对应环境下的训练样本或引入动态光照归一化方法进一步提高其鲁棒性。

图 9 对比了不同目标检测模型对 3 种光照强度下的番茄穴盘苗图像进行缺苗检测的可视化结果。在弱光条件下，部分对比模型因叶片与基质区域特征相似而易将正常穴孔误判为缺苗，而 YOLO-SFEP 未出现此类误检，表明其在低照度环境下具有较强的抗干扰能力。在正常光照条件下，各模型均未出现明显误检与漏检，但 YOLO-SFEP 对缺苗目标的检测置信度普遍高于其他模型，反映出其更优的识别稳定性与准确度。在强光条件

下，过曝现象导致部分模型对缺苗区域特征提取不足，出现漏检情况，而 YOLO-SFEP 仍能以较高置信度完成检测，验证了其在强光条件下的鲁棒性及所引入注意力机制的有效性。



注：图中红色矩形表示误检，橙色三角形表示漏检。
Note: The red rectangles in the figure indicate false detections, and the orange triangles indicate missed detections.

图 9 不同模型的番茄穴盘苗缺苗检测可视化结果对比
Fig.9 Comparison of visualization results of missing seedling detection for tomato plug seedlings of different models

2.5 YOLOv8n 模型改进前后可视化分析

为探究引入改进机制后 YOLOv8-SFEP 模型关注区域的变化，本研究采用 HiResCAM 算法^[33]对模型决策过程进行可视化分析。该算法通过生成热力图以直观反映模型对图像中不同区域的关注程度，其中红黄色区域表示高度关注，蓝色区域则表示关注度较低。改进前后模型在番茄穴盘苗图像上的热力图可视化结果对比如图 10 所示。




图 10 热力图可视化分析

Fig.10 Visualization analysis of thermodynamic diagram

如图 10 所示，YOLOv8n 模型热力图显示其注意力过度集中于穴孔中心区域，并明显受到穴孔边缘干扰。该现象表明模型在识别过程中易受穴孔结构影响，当穴盘苗存在倾斜时易导致误判，同时相邻穴孔中的幼苗也会对检测产生干扰，从而降低了模型的可靠性与鲁棒性。相比之下，YOLO-SFEP 模型所生成的热力图能够更精准地聚焦于实际缺苗区域，有效抑制了非关键背景特征的干扰，表明其能够学习到更具判别力的特征信息，进

一步验证了本文改进方法在番茄穴盘苗缺苗检测任务中的有效性与优越性。

2.6 边缘端部署与验证

为评估本文提出的 YOLO-SFEP 模型在树莓派 5 嵌入式平台上的检测性能，首先将训练完毕的 PyTorch 权重转换为 ONNX (open neural network exchange) 格式，进而转化为适用于边缘设备的 NCNN (neural computing network) 格式，最终基于 NCNN 推理引擎测试单张图像的平均推理时间。本文将 YOLOv8n 与 YOLO-SFEP 模型分别部署于树莓派 5 平台，使用自制数据集中番茄穴盘苗测试图像进行性能比较，详细检测结果如表 6 所示。

表 6 基于树莓派 5 平台的模型检测性能对比			
Table 6 Comparison of detection performance of models on Raspberry Pi 5 platform			
模型 Models	精确率 Precision/%	模型大小 Model size/MB	推理时间 Inference time/ms
YOLOv8n	93.6	11.9	86.5
YOLO-SFEP	96.1	9.2	74.3

注：模型大小为转换后的 NCNN 格式模型的大小。
Note: The model size refers to the converted NCNN-format model.

本文提出的 YOLO-SFEP 模型在树莓派 5 平台上的综合检测性能显著优于 YOLOv8n：该模型的检测精确率达到 96.1%，提升了 2.5 个百分点；单张图像平均推理时间仅为 74.3 ms，缩短了 12.2 ms；检测帧率提升至 13.8 帧/s，满足实时性的要求。此外，模型体积减少 2.7 MB，进一步降低了边缘设备的运行负载。

YOLOv8n 和 YOLO-SFEP 模型在树莓派 5 上进行番茄穴盘苗的缺苗检测的可视化结果如图 11 示。由图 11 可知，在进行缺苗检测时，YOLOv8n 模型有小概率将穴盘孔中存在倾斜的穴盘苗误判为缺苗，而 YOLO-SFEP 模型可以正确判断缺苗情况，并且实际缺苗位置的预测框置信度由 0.80 提高到了 0.87，表明该模型平衡了在树莓派 5 设备的检测精度与速度，更适用于实时缺苗检测任务。




图 11 模型在树莓派 5 平台上的性能验证

Fig.11 Performance verification of the models on the Raspberry Pi 5 platform

3 结 论

本文将 YOLOv8n 目标检测模型应用在番茄穴盘苗缺苗检测上,提出了一种基于改进 YOLOv8n 的温室环境下番茄穴盘苗缺苗检测模型 YOLO-SFEP,通过结合 SPDCConv 和 Omni-Kernel 模块优化 YOLOv8n 的 P3 检测层以提升模型的小目标检测能力;引入 EMA 注意力机制减少复杂光照条件的影响;使用 CFNB 模块替换 YOLOv8n 网络模型中的 C2f 模块降低模型复杂度;将 CIoU 损失函数替换为 PIoU 损失函数加快模型收敛速度。通过对改进后 YOLOv8n 模型进行消融试验和边缘端部署试验,探究改进前后模型检测性能的变化及边缘部署的实际效果,主要结论如下:

1) YOLO-SFEP 模型在番茄穴盘苗缺苗检测任务中实现了 96.7% 的精确率、98.8% 的召回率与 97.9% 的 mAP50,其中精确率较基准模型提升 2.4 个百分点。模型轻量化方面,其参数量为 2.62 M,计算量为 7.6 G,模型体积为 5.5 MB,其中参数量与计算量分别较基准模型降低 0.39 M 与 0.5 G。

2) YOLO-SFEP 模型的 mAP50 在弱光、中光和强光条件下分别为 96.7%、98.9% 和 98.1%,表明在不同光照条件下该模型性能稳定,能够满足温室自然光环境下番茄穴盘苗的缺苗检测,但弱光条件下的表现稍弱于中光和强光,模型具有进一步的改进空间。

3) YOLO-SFEP 模型在边缘计算设备树莓派 5 上完成了部署和验证,其缺苗检测精确率达到 96.1%,较基准模型提升 2.5 个百分点;单张图像平均推理时间为 74.3 ms,较基准模型缩短 12.2 ms。该模型在精度与速度方面的综合表现能够满足番茄穴盘苗缺苗检测的要求。

本研究基于 YOLOv8n 目标检测模型改进的 YOLO-SFEP 模型实现了对番茄穴盘苗缺苗信息的精准识别,具有良好的边缘端部署前景,可为新疆温室番茄穴盘苗的缺苗检测和智能补苗装备研发提供技术支撑。

【参 考 文 献】

[1] 常持银,汪晶晶,丁莉茹.新疆番茄制品出口市场集中度变化分析[J].中国瓜菜,2024,37(11):183-191.
CHANG Chiyin, WANG Jingjing, DING Liru. Analysis of changes in the market concentration of Xinjiang's tomato

product exports[J]. China Cucurbits and Vegetables, 2024, 37(11): 183-191. (in Chinese with English abstract)

[2] 马晓晓,李华,余思遥,等.番茄穴盘苗自动送取苗试验台的设计与试验[J].机械设计与研究,2020,36(3):214-219.
MA Xiaoxiao, LI Hua, YU Siyao, et al. Design and experiment of tomato seedling automatic picking-up and transporting test-bed[J]. Machine Design and Research, 2020, 36(3): 214-219. (in Chinese with English abstract)

[3] 王永维,肖玺泽,梁喜凤,等.蔬菜穴盘苗自动补苗试验台穴孔定位与缺苗检测系统[J].农业工程学报,2018,34(12):35-41.
WANG Yongwei, XIAO Xize, LIANG Xifeng, et al. Plug hole positioning and seedling shortage detecting system on automatic seedling supplementing test-bed for vegetable plug seedlings[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2018, 34(12): 35-41. (in Chinese with English abstract)

[4] 王小琴,俞高红,刘霓红,等.温室劣苗基质离散元仿真参数标定[J].农业机械学报,2023,54(12):359-366.
WANG Xiaoqin, YU Gaohong, LIU Nihong, et al. Calibration of discrete element simulation parameters for greenhouse poor seedling substrate[J]. Transactions of the Chinese Society for Agricultural Machinery, 2023, 54(12): 359-366. (in Chinese with English abstract)

[5] 王小琴,俞高红,刘霓红,等.劣质钵苗气吸式剔除装置参数优化及试验验证[J].农业工程学报,2023,39(16):36-43.
WANG Xiaoqin, YU Gaohong, LIU Nihong, et al. Parameter optimization and experimental verification of the air suction removal device for inferior bowl seedlings[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2023, 39(16): 36-43. (in Chinese with English abstract)

[6] 李韬,任玲,胡斌,等.改进 YOLOv5s 和迁移学习对番茄穴盘苗的分级检测[J].农业工程学报,2023,39(23):174-184.
LI Tao, REN Ling, HU Bin, et al. Grading detection of tomato hole-pan seedlings using improved YOLOv5s and transfer learning[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2023, 39(23): 174-184. (in Chinese with English abstract)

[7] 田志伟,马伟,杨其长,等.温室穴盘苗移栽机械研究现状及问题分析[J].中国农业大学学报,2022,27(5):22-38.
TIAN Zhiwei, MA Wei, YANG Qichang, et al. Research status and problem analysis of plug seedling transplanter in greenhouse[J]. Journal of China Agricultural University, 2022, 27(5): 22-38. (in Chinese with English abstract)

[8] 李小军.基于视觉检测的穴盘苗移栽路径规划研究[D].石河子:石河子大学,2023.
LI Xiaojun. Vision Detection-Based Path Planning for Plug Tray Seedling Transplanting[D]. Shihezi: Shihezi University, 2023. (in Chinese with English abstract)

[9] 张丽娜,谭戡,蒋易宇,等.基于点云处理的穴盘晚出苗自动检测方法[J].农业机械学报,2022,53(9):261-269.
ZHANG Lina, TAN Yu, JIANG Yiyu, et al. Automatic detection method for late emergence seedlings in plug tray based on point cloud processing[J]. Transactions of the

- Chinese Society for Agricultural Machinery, 2022, 53(9): 261-269. (in Chinese with English abstract)
- [10] FU W, GAO J, ZHAO C, et al. Detection method and experimental research of leafy vegetable seedlings transplanting based on a machine vision[J]. *Agronomy*, 2022, 12(11): 2899.
- [11] JIN X, LI R, TANG Q, et al. Low-damage transplanting method for leafy vegetable seedlings based on machine vision[J]. *Biosystems Engineering*, 2022, 220: 159-171.
- [12] LIU J, XIAO Z, TAN Y, et al. A study on the optimal grasping angle algorithm for plug seedlings based on machine vision[J]. *Agronomy*, 2023, 13(9): 2253.
- [13] 王璨, 武新慧, 张燕青, 等. 基于双注意力语义分割网络的田间苗期玉米识别与分割[J]. 农业工程学报, 2021, 37(9): 211-221.
WANG Can, WU Xinhui, ZHANG Yanqing, et al. Recognition and segmentation of maize seedlings in field based on dual attention semantic segmentation network[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(9): 211-221. (in Chinese with English abstract)
- [14] 宋磊, 李嵘, 焦义涛, 等. 基于 ResNeXt 单目深度估计的幼苗植株高度测量方法[J]. 农业工程学报, 2022, 38(3): 155-163.
SONG Lei, LI Rong, JIAO Yitao, et al. Method for measuring seedling height based on ResNeXt monocular depth estimation[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(3): 155-163. (in Chinese with English abstract)
- [15] 张秀花, 静茂凯, 袁永伟, 等. 基于改进 YOLOv3-Tiny 的番茄苗分级检测[J]. 农业工程学报, 2022, 38(1): 221-229.
ZHANG Xiuhua, JING Maokai, YUAN Yongwei, et al. Tomato seedling classification detection using improved YOLOv3-Tiny[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(1): 221-229. (in Chinese with English abstract)
- [16] JIN X, JIAO H, ZHANG C, et al. Hydroponic lettuce defective leaves identification based on improved YOLOv5s. *Frontiers in Plant Science*, 2023, 14: 1242337.
- [17] 陈沛沛, 戴建国, 张国顺, 等. 基于模型剪枝的棉花氮素营养水平诊断[J]. 农业工程学报, 2024, 40(6): 277-284.
CHEN Peipei, DAI Jianguo, ZHANG Guoshun, et al. Diagnosing the nitrogen content of cotton using model pruning[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(6): 277-284. (in Chinese with English abstract)
- [18] 黄成龙, 柯宇曦, 华向东, 等. 边缘计算在智慧农业中的应用现状与展望[J]. 农业工程学报, 2022, 38(16): 224-234.
HUANG Chenglong, KE Yuxi, HUA Xiangdong, et al. Application status and prospect of edge computing in smart agriculture[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(16): 224-234. (in Chinese with English abstract)
- [19] JIAO Z, HUANG K, JIA G, et al. An effective litchi detection method based on edge devices in a complex scene[J]. *Biosystems Engineering*, 2022, 222: 15-28.
- [20] 郑文轩, 杨璞. 基于频域数据增强与轻量化 YOLO v7 模型的成熟期香梨目标检测方法[J]. 农业机械学报, 2024, 55(5): 244-253.
ZHENG Wenxuan, YANG Ying. Mature stage pear detection method based on frequency domain data augmentation and lightweight YOLOv7 Model[J]. Transactions of the Chinese Society for Agricultural Machinery, 2024, 55(5): 244-253. (in Chinese with English abstract)
- [21] NANNI L, PACI M, BRAHNAM S, et al. Feature transforms for image data augmentation[J]. *Neural Computing & Applications*, 2022, 34(12): 22345-22356.
- [22] HE Y, XU W, LIU D, et al. Real-time tilapia fillet defect segmentation on edge device for robotic trimming[J]. *Computers and Electronics in Agriculture*, 2024, 225: 109337.
- [23] WANG P, LUO Y, ZHU Z. FDI-YOLO: Feature disentanglement and interaction network based on YOLO for SAR object detection[J]. *Expert Systems with Applications*, 2025, 260: 125442.
- [24] SUNKARA R, LUO T. No more strided convolutions or pooling: A new CNN building block for low-resolution images and small objects[C]//AMINI M R, CANU S, FISCHER A, et al. Machine Learning and Knowledge Discovery in Databases: European Conference, ECML PKDD 2022. Grenoble, France, September 19-23, 2022. Proceedings, Part II. Cham: Springer, 2023: 450-465.
- [25] CUI Y, REN W, KNOLL A. Omni-kernel network for image restoration[J]. *Proceedings of the AAAI Conference on Artificial Intelligence*, 2024, 38(2): 1426-1434.
- [26] OUYANG D L, HE S, ZHAN G Z, et al. Efficient multi-scale attention module with cross-spatial learning[C]//2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Rhodes Island, Greece: IEEE, 2023: 1-5.
- [27] CHEN J, LIU Y, ZHANG K, et al. Run, don't walk: Chasing higher FLOPS for faster neural networks[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC, Canada: IEEE, 2023: 12021-12031.
- [28] LIU C, WANG K G, LI Q, et al. Powerful-IoU: More straightforward and faster bounding box regression loss with a nonmonotonic focusing mechanism[J]. *Neural Networks*, 2024, 170: 276-284.
- [29] 杨佳昊, 左昊轩, 黄祺成, 等. 基于 YOLOv5s 的作物叶片病害检测模型轻量化方法[J]. 农业机械学报, 2023, 54(S1): 222-229.
YANG Jiahao, ZUO Haoxuan, HUANG Qicheng, et al. Lightweight method for crop leaf disease detection model based on YOLOv5s[J]. Transactions of the Chinese Society for Agricultural Machinery, 2023, 54(S1): 222-229. (in Chinese with English abstract)
- [30] 吕强, 林刚, 蒋杰, 等. 基于改进 YOLOv5s 模型的自然场景中绿色柑橘果实检测[J]. 农业工程学报, 2024, 40(18): 147-154.
LYU Qiang, LIN Gang, JIANG Jie, et al. Detecting green citrus fruit in natural scenes using improved YOLOv5s model[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(18): 147-154.

(in Chinese with English abstract)

- [31] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single shot multibox detector[C]. LEIBE B, MATAS J, SEBE N, et al. Cham: Springer, 2016: 21-37.
- [32] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. *IEEE*

Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.

- [33] LAMPROU V, KALLIPOLITIS A, MAGLOGIANNIS I. On the evaluation of deep learning interpretability methods for medical images under the scope of faithfulness[J]. *Computer Methods and Programs in Biomedicine*, 2024, 253: 108238.

YOLO-SFEP: A lightweight model for missing tomato plug seedling detection in natural light environments

ZHANG Conghua , REN Ling^{*} , CUI Jianpu , YANG Miao , ZHANG Yuquan ,
ZHU Xiangjian , LIU Junping

(1. College of Mechanical and Electrical Engineering, Shihezi University, Shihezi 832003, China; 2. Key Laboratory of Northwest Agricultural Equipment, Ministry of Agriculture and Rural Affairs, Shihezi 832003, China; 3. Xinjiang Production and Construction Corps Key Laboratory of Modern Agricultural Machinery, Shihezi 832003, China)

Abstract: Intelligent transplantation is often required to accurately detect the missing seedlings in the densely arranged tomato plug seedlings in the greenhouse. In this study, an improved YOLOv8n-based model (named YOLO-SFEP) was proposed to detect the missing-seedlings in greenhouse environments. Small-target detection was also improved by the illumination robustness. Computational complexity was also reduced to optimize the training efficiency. Four innovations were integrated into the framework: feature extraction refinement, attention-driven interference suppression, network lightweighting, and adaptive optimization of the loss function. Extensive experiments were carried out to validate the practical deployment. Firstly, the P3 detection layer of YOLOv8n was reconstructed to integrate the SPDCov (space-to-depth convolution) into an Omni-Kernel module. Dual enhancement strengthened the feature extraction for small targets, effectively improving the detection accuracy in dense seedling arrangements. Secondly, an EMA (efficient multi-scale attention) mechanism was embedded into the neck network, in order to amplify the critical features of missing seedlings, while suppressing interference from uneven lighting conditions in greenhouses. Thirdly, the lightweight deployment was achieved to replace the Bottleneck modules in C2f (cross-stage partial bottleneck with two convolutions) layers with FasterNet Block modules from FasterNet. Redundant parameters were then reduced without compromising recognition accuracy, indicating compatibility with the resource-constrained devices. Finally, the CIoU (complete intersection over union) loss function was replaced by PIoU (powerful-IoU). The adaptive penalty factors were introduced into the target scales. Thereby, the convergence stability was optimized under the varying seedling sizes. Experimental results revealed that the YOLO-SFEP model attained a precision of 96.7%, a recall of 98.8%, and a mean average precision at an intersection over union threshold of 0.5 (mAP50) of 97.9%, in order to detect the missing seedlings in tomato plug trays. There was an improvement over the baseline YOLOv8n model, where the precision was enhanced by 2.4 percentage points. The parameter count and computational load of the proposed model are 2.62 million(M) and 7.6 Gigafllops(G), respectively, representing a reduction of 0.39 M and 0.5 G compared with YOLOv8n. The model size was compacted to 5.5 megabytes(MB), decreasing by 0.8 MB relative to the baseline. Importantly, the model showed high robustness across a spectrum of natural light intensities (low, medium, and high), attaining mAP50 values of 96.7%, 98.9%, and 98.1%, respectively, which underscores its superior performance in challenging illumination environments. The improved model was also deployed on an edge computing device, the Raspberry Pi 5. A detection speed of 13.8 frames per second was achieved, equal to an inference time of 72 milliseconds(ms) per image. This speed was 12.2 ms faster than that of the baseline YOLOv8n model on the same platform. These outcomes highlighted the model's aptitude for real-time greenhouse applications, enabling it to deliver precise and prompt positional data on missing seedlings to support automated replenishment by transplantation equipment. In conclusion, the YOLO-SFEP model markedly improves the detection of missing seedlings in tomato plug trays within greenhouse environments. By integrating advanced modules for small target detection, attention mechanisms for feature enhancement, and efficient components for model lightweighting, it achieves elevated detection accuracy alongside reduced computational complexity. Its successful deployment on an edge device underscores its viability for on-site use. This research offers a solid technical foundation for intelligent missing seedling detection and automated seedling replenishment in greenhouse tomato cultivation. For further research, techniques such as knowledge distillation, quantization and pruning can be considered in the future to lighten the YOLO-SFEP model, and at the same time, analyze the resource consumption of the model in actual deployment, including memory occupation and power consumption, in order to comprehensively evaluate its applicability on edge devices, and eventually build an inspection system to realize the integration of image acquisition and processing by using edge devices.

Keywords: missing seedling detection; tomato plug seedlings; YOLO-SFEP; attention mechanism; lighting robustness; edge-end deployment