

基于 GCMD-YOLO 的轻量化多尺度中药材检测方法

孙 鹏¹, 唐永菁², 孙传聪^{1*}

(山东药品食品职业学院医疗器械系, 威海 264200; 威海市妇幼保健院心内科, 威海 264200)

摘 要: 针对现有中药材智能检测算法在边缘端部署时难以兼顾高精度与实时性的瓶颈, 以及传统模型对药材断面纹理、细微根须等特征提取能力不足导致的小目标漏检与混淆问题, 该文提出 GCMD-YOLO 轻量化多尺度检测方法。该方法在 YOLOv11s 基准模型上进行结构重构与特征增强: 首先, 构建涵盖 100 种中药材的多源数据集; 然后, 利用 GhostConv 与 Dysample 模块重构主干与颈部网络, 设计 Conv-SPPF 模块, 在大幅降低参数冗余的同时优化特征重构效率; 其次, 设计 C3K2-GL 模块, 引入双路径动态卷积机制, 显著增强了对药材细粒度纹理特征的捕捉能力; 再次, 设计 MG-CA 多尺度全局注意力机制, 集成在特征融合层, 通过抑制复杂背景干扰, 提升相似品类的辨识度。结果表明, GCMD-YOLO 在自建的 100 种中药材数据集上, 精确率、召回率和 F1 分数分别达到 93%、91% 和 92%, mAP@0.5 为 92.8%, mAP@0.5:0.95 为 78.6%, 相较于基线模型分别提升 7.0、8.0、7.5、7.3、7.4 个百分点; 参数量降低 16%, 推理速度提升 27%; 混淆试验与可视化分析表明该模块有效解决分类混淆问题, 特征关注精准度也显著提升; 泛化试验表明该模块良好的鲁棒性; 在 JetsonNano 边缘设备上的推理速度达到 39 FPS, 验证了模型的轻量化优势和边缘部署可行性。

关键词: 深度学习; 图像处理; YOLOv11 网络; 网络轻量化; 多尺度识别

doi: 10.11975/j.issn.1002-6819.202508227

中图分类号: TP391.41;S97

文献标志码: A

文章编号: 1002-6819(2026)-05-0001-10

孙鹏, 唐永菁, 孙传聪. 基于 GCMD-YOLO 的轻量化多尺度中药材检测方法[J]. 农业工程学报, 2026, 42(5): 1-10. doi:

10.11975/j.issn.1002-6819.202508227 <http://www.tcsae.org>

SUN Peng, TANG Yongjing, SUN Chuancong. Lightweight multi-scale Chinese herbal medicine detection method based on GCMD-YOLO[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2026, 42(5): 1-10. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202508227 <http://www.tcsae.org>

0 引 言

中医作为中华民族传统文化的瑰宝, 历经数千年传承发展, 在疾病防治和健康保障中发挥着不可替代的作用。中药材作为中医临床诊疗与药物研发的核心物质基础, 种类繁多、形态各异, 且部分品类存在特征相似性高的特点, 其品类辨识与精准检测直接关系到临床疗效与用药安全。

当下的中药材辨识与检测主要依赖人工经验, 存在工作量大、主观性强等问题^[1]; 显微观察与化学检测手段受限于检验周期长、样品破坏性和操作复杂性; 智能检测方法难以突破小目标漏检、类间区分不足、实时响应差等技术难点^[2]。在药房和集散市场等中药材流通、现场快检及移动巡检等应用场景, 普遍存在算力资源受限、但实时性和准确性要求高的需求。

随着深度学习技术的迅猛发展, 为中药材智能化检测提供了技术路径。学者们开展了一系列探索, 在国内, 郭丛等^[3]采用 YOLOv4 算法对 108 种中药饮片建立目标

检测模型, 在算法的颈部网络引入 RFB 感受野模块, 改进后模型的 mAP 达到 88.7%。董苗苗等^[4]在 YOLOv5 算法的主干网络上设计轻量级的 GhostBottleneck 模块, 在模型结构中加入注意力机制, 将原有的卷积层替换为深度可分离卷积, 改进后算法的 mAP@0.5 可以达到 98.37%。赵哲等^[5]在 YOLOv8 模型的基础上引入了 DSConv 和 Biformer 注意力机制, 关注细长和曲折的局部特征, 并通过双层路由机制, 实现了内容感知的稀疏模式, 模型精确率、召回率和平均精度分别达到了 96.4%、98.0% 和 97.7%。孙兴等^[6]在 YOLOv8n 网络中引入 GhostC2f 模块以降低模型参数量, 采用 DySnakeC2f 模块以增强对纤细结构的灵敏度, 替换主干网络的池化层为 SimSPPF 模块以加快推理速度, 并加入坐标注意力, 平均精度达到 84.16%, 模型参数量减少了约 15%。华畅等^[7]基于 YOLOv8n 模型用 SCConv 代替部分 C2f 模块, 添加 DilateBlock 模块, 并引入 Inception 板块扩大特征感受视野, 提高平均精度 2.9%, 参数量降低 1.9%。李玥辰等^[8]对 AlexNet 模型缩减卷积核个数和卷积核大小, 使用全局平均池化, 引入批量归一化层, 采用通道注意力机制 SENet, 平均识别率提高 6.1%, 参数缩减至 1M。王青青等^[9]引入新型注意力机制等模块设计出 Attention-TCM-Net, 改进移动倒置瓶颈卷积模块, 模型的 top-1 准确率和宏准确率分别是 98.15% 和 98.62%。在国外, LAPKOVSKIS^[10]等提出了多模态植物识别的深度学习网络, 通过整合图像、环境参数等多种数据源, 能够更全面地表征植物特

收稿日期:

基金项目: 山东省卫生健康委员会研究项目 (2024183); 山东省威海市中医药科技项目 (2024N-23)

作者简介: 孙鹏, 研究生, 工程师, 研究方向机器视觉应用。

Email: sunpeng4711@163.com

※通信作者: 孙传聪, 研究生, 副教授, 研究方向智能技术应用。

Email: 654335080@qq.com

征; TANG^[11] 等提出基于双分支注意力融合的 MPR 新型药用植物识别网络, 增强了模型对植物图像关键特征的聚焦能力, 提升易混淆品类的识别准确率。这些研究为中药材智能检测奠定基础, 但仍存在局限: 一方面, 多数研究仅聚焦于模型精度提升, 对轻量化优化与推理速度提升重视不足, 巨大的计算开销限制移动设备的应用; 另一方面, 特征融合策略单一, 对根须、叶脉等关键纤细特征与微小目标的检测灵敏度较低。因此, 如何在保持轻量级架构的同时引入细粒度特征提取能力, 成为当前边缘端检测研究的焦点。

针对上述问题, 本研究以轻量化目标检测模型 YOLOv11S 为基础, 结合中药材检测的实际需求开展系统性研究, 提出改进模型 GCMD-YOLO, 核心工作聚焦网络轻量化设计和提升纹理等细微特征的检测能力, 提供兼具精度与实时性的移动端智能解决方案, 满足上述应用场景对精准、快速和易部署的综合要求。

1 数据集构建

中药材检测的准确性高度依赖高质量数据集的支撑, 鉴于目前中药材领域缺乏覆盖广、标注规范的公开权威数据集^[12], 本研究通过多源融合方式构建包含 100 种常见中药材的检测数据集, 其中, 人参、当归等根茎类占 40%、枸杞、五味子等果实种子类占 30%、薄荷、蒲公英等全草类占 20%、叶类、花类、皮类等占 10%, 兼顾数据多样性、代表性和专业标注质量。

数据来源包括: 甘肃中医药大学、南京中医药大学的中药标本专业数据库, 图像背景纯净, 标注信息规范; 爬虫技术的抓取网络图片, 补充自然场景和复杂背景, 提升样本多样性; Kaggle 的药用植物 MedLeaves 开源数据集, 完善类别覆盖, 标注精确, 适合轻量级模型训练。数据集中图像尺度差异大、类间相似性高和细微鉴别性纹理丰富, 原始样本量为 8 642 张。

为提升模型对复杂场景的泛化能力, 进行数据增强如下: 物理仿真增强, 随机调整亮度、对比度、饱和度、进行图像旋转、平移、缩放, 添加高斯噪声以模拟低质量拍摄场景^[13]; 所有图像统一缩放至 640×640, 并经人工审核, 数据增强后数据集扩充至 30 480 张, 按 7:2:1 划分训练、验证和测试集。同种药材原图及增强图如下:

2 模型网络改进设计

2.1 网络整体设计

YOLOv11S 作为该系列的新型轻量级版本, 在推理速度上具备天然优势, 在 COCO 数据集上实现 41.2% 的 mAP@0.5:0.95, 同时模型体积仅 9.4MB, 推理速度达 47FPS (RTX3090)^[14], 精度与速度达到优异平衡, 是理想的基线模型。

本文针对中药材的实时检测任务, 以 YOLOv11S 为基线, 改进思路如下: 骨干网络在减少计算量的同时, 增强对药材全局形态与局部细节的提取能力, 实现轻量化与特征提取优化; 颈部网络高效融合多尺度特征, 并抑制背景干扰, 突出药材鉴别性区域, 实现自适应特征融合与关键信息聚焦。改进后模型的结构如图 2 所示。





图 1 同种药材原图及其增强图

Fig.1 Original Images of the Same Medicinal Herb and Their Augmentation Images



注: GhostConv 为轻量化特征提取模块; Conv 为卷积; C3K2-GL 为改进的 C3K2 模块; C3K2 为特征提取组件; Conv-SPPF 为改进的 SPPF 模块; MG-CA 为改进的 CA 注意力机制; Concat 为特征连接模块; Dysample 为轻量化特征采样模块; HEAD 为检测头。

Note: GhostConv is a lightweight feature extraction module; Conv is convolution; C3K2-GL is an improved C3K2 module; C3K2 is a feature extraction component; Conv-SPPF is an improved SPPF module; MG-CA is an improved CA attention mechanism; Concat is a feature concatenation module; Dysample is a lightweight feature sampling module; HEAD is the detection head.

图 2 改进后的模型结构图


Fig.2 The improved model structure is shown in the figure

改进措施主要如下: 在主干网络中, 将传统卷积层替换为 GhostConv 模块, 在轻量化基础上保留关键形态特征; 将 C3K2 升级为 C3K2-GL 模块, 融合双路径动态卷积机制提升对中药材细微纹理的分辨效率; 将 SPPF 模块原有 maxpool 操作替换为卷积操作, 通过密集特征提取保留边缘与纹理特征; 在颈部网络中, 将浅层卷积层替换为 GhostConv 模块, 缩减冗余参数的同时保证特征流通性; 引入 MG-CA 多尺度全局注意力模块, 通过

聚焦关键形态与纹理特征增强相似品类的区分度；将 upsample 模块替换为 Dysample 动态上采样模块，自适应调整特征融合尺度。

2.2 GhostConv 模块

GhostConv 模块是一种轻量化特征提取模块，其核心理念是通过低成本操作生成冗余特征以减少计算开销与参数规模^[15]。结构如图 3 所示。



注：Input 为输入特征图，W 为该特征图列数，H 为该特征图行数，C 为该特征图通道数；Conv 为卷积；K 为卷积核；m 为输出通道数；n 为输入通道数；s 为幻影特征图数；Output 为输出特征图；W' 为该特征图列数；H' 为该特征图行数。

Note: Input represents the input feature map, W denotes the number of columns in this feature map, H indicates the number of rows in this feature map, and C signifies the number of channels in this feature map. Conv stands for convolution, K represents the convolution kernel, m is the number of output channels, n is the number of input channels, s is the number of ghost feature maps, Output is the output feature map, W' is the number of columns in this feature map, and H' is the number of rows in this feature map.

图 3 GhostConv 模块结构图

Fig.3 GhostConv module structure diagram

GhostConv 模块采用标准卷积和廉价变换组成双路径结构，输入特征图 $H \times W \times c$ ，先经标准卷积 Conv，输出通道为 m 的特征图 $H' \times W' \times n$ ，对此进行线性变换， m 个通道的特征图分别得到 s 个幻影特征图，总计得到 $m \cdot s$ 个幻影特征图；然后，拼接之前标准卷积的输出，得到最终的特征图^[16]。与 YOLOv11 网络中传统的标准卷积相比，GhostConv 既保留了传统卷积的特征提取能力，也减少约 50% 的参数量与计算量^[17]，尤其适用对轻量化要求较高的边缘计算场景。

本文中，线性运算卷积核为 b^2 ，运算 $s-1$ 次，计算量 FLOPs 在标准卷积和在 GhostConv 中分别计算如下：


$$F_1 = H' \times W' \times n \times K^2 \times c \quad (1)$$

$$F_2 = H' \times W' \times n \times K^2 \times c + (s-1) \times H' \times W' \times \left(\frac{n}{s}\right) \times b^2 \quad (2)$$

主干网络的标准卷积核 K 为 3 或 5，而线性变换使用 3×3 深度卷积，即 b 值为 3，存在 $b \leq K$ ；网络层通道数 C 值为 64、128、256 等较大数值，参数压缩比 $\frac{F_1}{F_2}$ 近似为 s ，即 GhostConv 模块比传统卷积，大约节省 s 倍训练时间，并减少约 s 倍参数量，即可获取相同数量特征图。

2.3 C3K2-GL 模块

本文提出全局-局部双通路动态卷积 GL-ODConv 模块（GL-DualPathODConv）。输入特征图进行双路并行特征提取，一路经全局平均池化压缩提取通道维度全局信息，一路经 1×1 Conv 提取局部信息，然后，两路并行特征进行拼接，通过全连接层调整维度，生成动态权重矩，有效扩展感受野。网络结构如下。



注：GAP 为全局平均池化；FC 为全连接层；ReLU 为线性激活函数；concat 为特征融合；Sigmoid 为激活函数；w 为多个独立动态卷积分支； α 为各分支动态权重， α_s 为空间注意力权重； α_c 为通道注意力权重； α_f 为特征调制权重； α_w 为卷积核自身权重。

Note: GAP stands for global average pooling; FC denotes a fully connected layer; ReLU is a rectified linear unit activation function; concat signifies feature concatenation; Sigmoid is an activation function; w represents multiple independent dynamic convolution branches; α represents the weight of each branch, where α_s is the spatial attention weight; α_c is the channel attention weight; α_f is the feature modulation weight; α_w is the weight of the convolution kernel itself.

图 4 GL-ODConv 模块结构图

Fig.4 GL-ODConv module structure diagram

首先，输入经全局特征通路和经局部特征通路：

$$z_g = \text{ReLU}(\text{FC}(\text{GAP}(X))) (z_g \in \mathbb{R}^{C/16}); \quad (3)$$

$$z_l = \text{GAP}(\text{ReLU}(\text{Conv}_{1 \times 1}(X))) (z_l \in \mathbb{R}^C); \quad (4)$$

式中， z_g 表示输出全局特征； z_l 表示输出局部特征；ReLU 表示线性整流激活函数；FC 表示全连接层；GAP 表示全局平均池化； $\text{Conv}_{1 \times 1}(X)$ 表示用 1×1 大小的卷积核输入特征进行卷积。

在两路卷积核并行计算后，按动态权重逐通道加权融合：

$$[z_g; z_l] = \text{ReLU}(W_g \cdot \text{GAP}(X)) \delta \text{GAP}(\text{ReLU}(W_l \odot X)) \quad (5)$$

式中， z_g 和 z_l 分别表示全局、局部特征， $[z_g; z_l]$ 表示对全局和局部通路进行拼接。 W_g 和 W_l 分别表示全局、局部通路的线性变换权重矩阵； $\odot$ 表示用卷积核 W_l 对输入特征 X 进行局部卷积； δ 表示将全局通路和局部通路的输出按通道逐元素相加，融合两者的特征。

进行多尺度特征融合。

$$z_{fused} = \sigma(\text{FC}([z_g; z_l])) \odot X + X (z_{fused} \in \mathbb{R}^{C \times H \times W}) \quad (6)$$

式中， σ 表示使用 Sigmoid 激活函数将全连接输出的权重映射为通道注意力权重。 $\odot$ 表示通道注意力权重与输入特征 X 逐通道、逐像素的相乘。 $+X$ 表示残差连接，即加权后的输入特征 X 与原始特征 X 进行逐元素的相加，最后输出的增强特征图 z_{fused} 与输入特征 X 在维度上一致。

各尺度权重由轻量级注意力模块计算。

$$\alpha_s = \text{Softmax}(\text{MLP}(\text{GAP}(\text{Conv}_s(z_{fused})))) \quad (7)$$

式中，MLP 表示分支权重提取，通过对维度先压缩后扩

张的方式,提取不同分支特征间的非线性关联。*Softmax*表示对*MLP*的结果进行归一化处理,避免权重爆炸,提升稳定性。

基于融合特征生成动态卷积权重,计算如式(8)所示。

$$W_d = \text{Sigmoid}(FC_2(\text{ReLU}(FC_1(z_{fused})))) (W_d \in R^{S \times K \times K}) \quad (8)$$

式中, z_{fused} 表示输出的增强特征图; FC_1 与 FC_2 为第一层和第二层的全连接网络, FC_1 将增强特征图 z_{fused} 展平为一维向量,降低计算量,获取高层抽象特征; FC_2 通过全连接映射到 $S \times K \times K$ 维,得到 S 个 $K \times K$ 的矩阵,生成动态权重参数。 S 表示动态分支的数量。最后, *Sigmoid*激活函数对权重归一化处理。

完成多尺度特征融合。计算如式(9)所示。

$$Y = \sum_{s=1}^S \alpha_s \cdot \text{Conv}_s(X, W_d^{(s)}) \quad (9)$$


式中, α_s 表示分支权重,即表示第 S 个分支对中药材识别的贡献度。 Conv_s 表示第 S 个分支的动态卷积,多分支可分别适配整体形态、纹理和细节的多尺度特征提取需求。 Y 表示多分支特征的加权融合结果,特征维度与增强特征图 z_{fused} 一致。

通过动态生成的 S 个卷积核,对增强特征图 z_{fused} 并行执行多尺度卷积,自适应提取中药材的多尺度特征,并通过 α_s 分支权重平衡各分支的贡献,最后,对 S 个分支加权求和。*GL-ODConv*模块可自适应调整卷积核形状与感受野;多分支机制实现特征的多维度动态加权,强化关键局部特征的表达能力。

*C3K2*模块是YOLO11基于传统*C3*模块的改进设计,它通过结合可变卷积核和通道分离策略,提供了更强大的特征提取能力,适应复杂的场景和深层次的特征提取任务^[18]。主要特点如下: *C3K2*引入多尺度的卷积核*C3K*,可扩展感受野,使模型能够捕捉更广泛的上下文信息,适应大物体检测或背景复杂的场景; *C3K2*模块将输入特征分为两部分,一部分通过普通卷积直接传递,一部分通过多个*C3K*或*Bottleneck*模块进行深度特征提取,最终拼接两部分特征,再经过 1×1 卷积融合,保持轻量化也有效提取深层次特征。但*C3K2*模块卷积核是定值,难以适应微小种子类目标与大尺寸根茎类目标共存的中药材检测任务^[19]。

本文在*C3K2*模块基础上,用*GL-ODConv*模块替换其中残差分支的标准卷积,形成*C3K-GL*模块,替换*C3K2*的浅层*C3K*模块得到*C3K2-GL*模块, *C3K2*的深层*C3K*模块不变。网络结构如下。

首先通过 1×1 卷积对输入特征图进行维度调整,生成中间特征;随后将中间特征分流至两条并行路径:主路径先经过*C3K-GL*模块自适应调整卷积核形态,对叶脉、纹理等深层特征进行细致的捕捉,再经*C3K*模块对捕捉整体特征并融合得到深层特征;辅路径保留浅层特征直接传递,双路径做特征拼接形成输出特征图,本文中*C3K*取值为True。



注: Conv 1×1 为 1×1 的卷积; Split为特征拆分; Bottleneck为轻量化瓶颈结构; *GL-ODConv*为改进的双路径动态卷积; *C3K-GL*为改进的*C3K*模块; concat为特征拼接。

Note: Conv 1×1 is a 1×1 convolution; Split is feature splitting; Bottleneck stands for a lightweight bottleneck structure; *GL-ODConv* represents an improved dual-path dynamic convolution; *C3K-GL* signifies an enhanced *C3K* module; concat indicates feature concatenation.


图5 *C3K-GL*模块结构图

Fig.5 *C3K-GL* module structure diagram

2.4 Conv-SPPF 模块

*SPPF*模块是YOLO11网络中用于增强多尺度特征融合的关键组件,通过并行的多尺度池化操作实现特征聚合^[20]。该模块设计如下:先通过 1×1 卷积将输入特征图通道数压缩至原尺寸的 $1/2$,减少后续计算量;随后设置3个并行分支,分别采用 5×5 、 9×9 、 13×13 的最大池化核对特征图进行处理,捕捉不同尺度的空间特征;最后将原始特征图与各池化分支输出特征拼接,通过 1×1 卷积恢复通道数。虽然有效提升网络对目标尺度变化的适应性,但浅层最大池化操作易导致中药材细微纹理关键特征的丢失^[21]。

针对此问题,本文提出*Conv-SPPF*模块,将其浅层MaxPool模块替换为*GhostConv*模块,提取核心特征,保留原*SPPF*的深层池化框架。网络结构如下。



注: Pooling~Max为最大池化层; concat为特征拼接。

Note: Pooling Max is the max pooling layer; concat refers to feature concatenation.

图6 *Conv-SPPF*模块结构图

Fig.6 *Conv-SPPF* module structure diagram

2.5 MG-CA 模块


*MG-CA*模块在CA注意力机制的架构下,采用多尺度特征感知结合全局通道校准的设计,网络结构如下。

特征图 $X \in \mathbb{R}^{C \times H \times W}$,沿宽度 W 和高度 H 方向,并行进行三分支的平均池化。输出特征可表示为:

$$z_h^{(s)} \in \mathbb{R}^{C \times H \times 1}, z_w^{(s)} \in \mathbb{R}^{C \times 1 \times W} \quad (10)$$

式中, z_h 和 z_w 分别是沿高度和宽度方向的池化输出; $s \in \{1, 2, 4\}$; $s \in \{1, 2, 4\}$ 表示粒度级别: $s=1$ 表示 1×1 网络,

对应全局粒度，捕获整株药材形态特征，针对人参、黄芪等大尺度目标； $s=2$ 表示 2×2 网格，对应中尺度粒度，提取切片纹理特征，针对当归、白术等纹理目标； $s=4$ 表示 4×4 网格，对应局部粒度，定位颗粒细节，针对枸杞、虫草等小目标。



注： 1×1 Avg Pooling 为 1×1 平均池化； 2×2 Avg Pooling 为 2×2 平均池化； 4×4 Avg Pooling 为 4×4 平均池化；ReLU 为线性整流激活函数；Sigmoid 为激活函数；Re-weight 为特征重加权。

Note: 1×1 Avg Pooling is 1×1 average pooling; 2×2 Avg Pooling is 2×2 average pooling; 4×4 Avg Pooling is 4×4 average pooling; ReLU stands for rectified linear unit; Sigmoid is an activation function; Re-weight refers to feature re-weighting.

图 7 MG-CA 模块结构图

Fig.7 MG-CA module structure diagram

将三级特征拼接，再由 1×1 卷积压缩通道，经 ReLU 非线性激活，增强模型的非线性拟合和表达的能力。计算如式 (11) 所示。

$$f = \delta(\text{Conv}_{1 \times 1}(\text{Concot}(z_h, z_w))), f \in \mathbb{R}^{C/r \times (H+W)} \quad (11)$$

式中， f 为中间融合特征向量； $\text{Concot}(z_h, z_w)$ 表示对行、列做特征拼接，拼接后空间维度合并为 $(H+W)$ 。 $\text{Conv}_{1 \times 1}$ 表示用 1×1 卷积核处理拼接后的特征，将通道数从 C 压缩到 C/r ，完成通道降维， r 为压缩比，本文设置为 16。 δ 为 ReLU 激活函数，抑制负值，增强非线性特征表达。

再次分开为两并行支路，按照宽高分为： $[C, 1, H]$ 和 $[C, 1, W]$ ，再转置得到两个特征层 $[C, H, 1]$ 和 $[C, 1, W]$ 。计算如式 (12) 所示。

$$f_h, f_w = \text{Split}(f, [H, W], \text{dim} = 2) \quad (12)$$

式中， f_h 和 f_w 分别是融合特征 f 沿高度和宽度方向拆分的特征；利用 1×1 卷积调整通道数后，经 Sigmoid 获得宽、高维度上的注意力情况； σ 为 Sigmoid 函数，用于生成空间注意力权重。

$$g_h = \sigma(\text{Conv}_{1 \times 1}(f_h)), g_w = \sigma(\text{Conv}_{1 \times 1}(f_w)) \quad (13)$$

最后，通过逐元素相乘，将行注意力权重 g_h 和列注意力权重 g_w 联合作用于输入特征图 F ，得到输出特征图 F' ，实现空间关键区域增强和无关背景抑制。


$$F' = F \otimes g_h \otimes g_w \quad (14)$$

式中， $\otimes$ 表示逐元素相乘，将注意力权重与输入特征图进行逐元素相乘，实现对空间关键区域的协同增强；MG-

CA 通过三级多粒度池化 (1×1 、 2×2 、 4×4) 扩展传统坐标注意力机制的特征感知能力，对不同尺度的空间信息分别进行捕获。

2.6 DySample 模块

YOLOv11 网络的 upsample 采用固定插值规则，易导致关键细节信息丢失，特别是在复杂背景下的小目标检测中表现尤为明显^[22]。而 DySample 通过动态权重生成和自适应特征插值，实现精准的尺度转换，解决传统采样对语义特征关注不足的问题；同时，由于采用点采样替代卷积操作，大幅降低参数量与计算。结构如图 8 所示。



注：X 为尺寸 $H \times W$ ，有 C 个通道的特征图；Sampling point generator 为采样点生成器；Sampling set S 为生成器输出的采样点坐标集合； s 为上采样缩放因子； sH 为目标上采样后的特征图高度； sW 为目标上采样后的特征图宽度； g 为分组数；Grid sample 为网格采样函数； X' 为经过动态上采样后输出的特征图。

Note: X represents a feature map with dimensions $H \times W$ and C channels; Sampling point generator is a sampling point generator; Sampling set S is the set of sampling point coordinates output by the generator; s is the upsampling scaling factor; sH is the height of the feature map after target upsampling; sW is the width of the feature map after target upsampling; g is the number of groups; Grid sample is a grid sampling function; X' is the feature map output after dynamic upsampling.

图 8 DySample 模块结构图

Fig.8 DySample module structure diagram

图中，输入特征图 X 经采样点生成器得到采样集 S ，利用 Grid_sample 函数使采样集 S 中的位置对假设的双线性插值输入特征进行重新采样，生成上采样特征集 X' 。本文中采用动态范围因子的 LP 模式，经线性投影生成偏移集合，匹配目标空间尺寸，由动态权重引导采样过程中的加权融合。

2.7 模型训练参数

本研究中训练模型的硬件配置与参数设置均经过针对性优化，硬件方面，训练平台采用高性能 Intel (R) Core (TM) i7-12700H 处理器，配备 16GBDDR4 运行内存和 NVIDIA GeForce RTX4060 GPU。软件环境基于 Windows11 操作系；编程语言 Python3.8.20；配置 CUDA12.1 搭配 PyTorch1.11.0 深度学习框架。为确定最佳的训练参数组合，本研究对初始学习率、批处理大小和迭代次数三要素进行试验和分析，学习率为 0.01，训练损失震荡无法收敛；设 0.0001 时，收敛速度过慢且精度较低；设 0.001 时，模型在第 40 轮左右达到高性能区间。当批处理为 32，显存需求远超硬件条件；设 8 时训练时长显著增加；设 16 时显存占用和训练速度达到平衡。迭代次数为 100 轮时模型欠拟合；设 200 轮时精度微弱提升但训练时间显著增加；模型在 150 轮后已充分饱和。本文设置学习率 0.001、批处理 16、迭代次数 150。

模型训练过程评价的核心指标包括损失函数

(Loss)、Top-1 准确率 (Top-1 Accuracy)、Top-5 准确率 (Top-5 Accuracy)，Loss 反映模型训练过程中预测值与真实标签的差异程度，其收敛趋势可直观判断训练稳定性与过拟合风险^[24]；Top-1 准确率衡量模型最可能预测类别与真实类别一致的比例；Top-5 准确率则评估真实类别出现在前 5 个预测结果中的概率，适配中药材部分品类形态相似的特点^[25]。训练情况如图 9 所示。




图 9 损失函数和准确率图
Fig.9 Loss function and accuracy graph

从准确率曲线来看，模型在训练前期 0~40 轮展现快速特征学习能力，Top-1 准确率从接近 0 提升至 0.85，Top-5 准确率从 0.1 提升至 0.93，说明其能迅速捕捉中药材的整体形态、颜色差异等基础鉴别特征。40 轮后，准确率进入缓慢提升的平台期，最终 Top-1 稳定在 0.92 以上，Top-5 接近 0.97，且两条曲线均无明显震荡，表明模型对中药材的特征提取充分且稳定，不仅能精准识别差异显著的类别，对形态相似的细粒度类别也具备较强的区分能力。

表 1 消融试验
Table 1 Ablation experiment

序号 NO.	GhostConv	C3K2-GL	Conv-SPPF	MG-CA	Dysample	精准率 Precision %	召回率 Recall %	F1 Score %	mAP@0.5 %	mAP@0.5:0.95%	参数量 Parameters/M	运算量 FLOPs/G
1	×	×	×	×	×	86	83	84.5	85.5	71.2	9.4	21.5
2	√	×	×	×	×	88	85	86.5	87.4	73	7.7	18.3
3	×	√	×	×	×	89	86	87.5	88.6	75	9.6	20.2
4	×	×	√	×	×	88	84	86	87.3	74	9.3	20.8
5	×	×	×	√	×	90	87	88.5	89	76	9.5	21.2
6	×	×	×	×	√	87	85	86	86.9	75.5	9.2	19.7
7	√	√	√	√	√	93	91	92	92.8	78.6	7.9	15.6

从试验 1 与 2 对比可知，在参数量降低 18%、运算量减少 15% 的同时，试验 2 在精准率、召回率和 mAP@0.5 三项关键指标上均获得提升，验证 GhostConv 模块不仅实现网络轻量化，也有效保留并优化基础特征表达能力。

试验 3 在未显著增加运算量的情况下，精准率与 mAP@0.5 提升显著，分别达到 89% 和 88.6%，证明其双路径动态卷积机制对细粒度纹理特征的自适应捕捉能力。

试验 4 通过将池化替换为卷积，mAP@0.5:0.95 提升至 74%，试验 6 则通过动态上采样优化了特征融合过程，取得 FLOPs 为 19.7G 的最佳运算效率。

试验 5 精准率和召回率分别提升至 90% 与 87%，是

损失曲线的变化进一步验证模型的有效性：训练损失快速下降并稳定在 0.2 以下，说明模型通过迭代持续优化参数，对训练集中的中药材特征拟合充分，预测结果与真实标签的差异不断缩小；验证损失虽略高于训练损失，但整体趋势同步且最终稳定在 0.4 以下，表明模型在学习训练数据模式的同时，未出现严重过拟合，预测稳定性强。

2.8 性能评估

改进后模型在测试集上进行性能评估，采用以下指标评估：精确率 (Precision,P) 反映模型对易混淆中药材的误判情况；召回率 (Recall,R) 评估模型对小样本或低辨识度中药材的捕捉能力^[26]；F1 Score 可全面评价模型分类稳定性^[27]。mAP@0.5 综合考量模型在不同类别上的检测精度；mAP@0.5:0.95 则进一步体现模型的鲁棒性；参数量 (Parameters) 反映模型文件大小，浮点运算量 (FLOPs) 评估模型计算效率与硬件适配性^[28]。主要指标计算公式如下：

$$P = \frac{T_p}{T_p + F_p}$$
$$R = \frac{T_p}{T_p + F_N}$$
$$F1Score = \frac{2P * R}{P + R}$$
$$mAP = \frac{\sum_{i=1}^N \int_0^1 P(R) dR}{N} \tag{15}$$

式中， T_p 表示预测对的正样本数量； F_p 表示预测错的正样本数量； F_N 表示应被预测为正却预测为负的样本； N 表示类别总数； $\int_0^1 P(R) dR$ 表示该类别的平均精度。试验结果如表 1 所示。

单模块改进的最优数值，证明多尺度全局注意力机制在聚焦鉴别性关键区域、抑制背景干扰方面的重要作用。

试验 7 集成全部改进模块，在参数量与运算量分别较基线降低 16% 与 27% 的轻量化基础上，精准率、召回率与 mAP@0.5 分别大幅提升至 93%、91% 和 92.8%。

2.9 对比试验

为验证本文模型的优势，本研究在测试集上将其与多种代表性模型进行对比试验，结果如表 2 所示。

相较于其他对比模型：两阶段检测器 Faster R-CNN 虽取得较高的精确率与 mAP@0.5，但其召回率相对较低，且模型参数量与计算量远超其他模型，难以满足边缘部署需求；单阶段多尺度检测器 SSD 的各项精度指标

与效率指标均已显著落后；YOLOv8S 精度与效率表现均衡，但各项指标不及基线模型 YOLOv11S。GCMD-YOLO 在精度与轻量化等方面相较基线和对标模型均有提升。


表 2 对比试验

Table 2 Comparative experiment

模型 Model	精准率 Precision %	召回率 Recall %	F1 分数 F1 Score %	mAP @0.5 %	mAP @0.5: 0.95 %	参数量 Parameters/ M	运算量 FLOPs/ G
Faster R-CNN	82	80.5	81.5	82.1	60.5	28.5	180.6
SSD	78	75.2	76.8	76.8	52.4	26.3	61.2
YOLOv8S	84	81.2	82.8	83.8	68.5	11.1	28.7
YOLOv11S	86	83	84.5	85.5	71.2	9.4	21.5
GCMD-YOLO	93	91	92	92.8	78.6	7.9	15.6

2.10 混淆试验

通过混淆矩阵可直观定位易混淆品类的错误模式，为数据增强和模型优化提供方向^[29]。在测试集上对本文模型进行识别性能验证，结果如下：



注：坐标数字 0-99 为数据集 100 种药材编号

Note: Coordinate numbers 0-99 are the numbers of 100 kinds of medicinal materials in the data set.

图 10 混淆矩阵图

Fig.10 Confusion matrix diagram

从整体来看，主对角线呈现连续高亮分布，表明模型整体识别准确率与训练曲线及消融实验结论一致；非对角线区域则整体颜色暗淡，错误预测样本分布稀疏，未出现明显的类别混淆聚集现象，说明本文模型可有效缓解类间相似性导致的误判问题。

对“当归”与“川芎”、“党参”与“西洋参”易混淆品类对进行分析，本文模型将平均误判率从基线模型的 12.5% 显著降低至 4.2%，表明该模型能有效降低相似药材之间的识别混淆。

2.11 模型可视化

类激活映射图（Class Activation Mapping, CAM）通过梯度加权计算模型关注区域，计算公式如下：

$$\text{CAM}(x, y) = \sum_{k=1}^K w_k^c \cdot A_k(x, y) \quad (16)$$

式中，K 为卷积通道数，C 为目标类别， w_k^c 为 K 通道对类别 c 的权重，(x,y) 为图中位置坐标， $A_k(x, y)$ 为 K 通道

在 (x,y) 处的特征响应^[30]。

通过热力图可视化模型关注区域，验证模型是否学习到中药材标志性特征，而非背景干扰。分别选择根茎类的黄芪、叶类的薄荷叶和果实种子类的枸杞进行可视化分析，结果如下。

由图 11 可见，GCMD-YOLO 的热力图中，对于黄芪，高亮区域集中于菊花心与环纹，纹理特征被清晰激活；对于薄荷叶，热力图沿叶脉走向分布，叶片轮廓与锯齿边缘被显著强化；对于枸杞，热力图为堆叠的果实生成独立的激活中心，并有效抑制背景阴影。基线模型的热力图中：对黄芪，响应弥散至整体轮廓甚至背景，对核心环纹关注微弱；对薄荷叶，仅能识别大致叶片区域，叶脉与边缘细节丢失；对枸杞，则未清晰区分出个体，易将阴影误判为目标。结果表明，GCMD-YOLO 增强对细粒度纹理与形态特征的提取与聚焦能力，优化对关键鉴别区域的精准感知。




图 11 CAM 对比图

Fig.11 CAM comparison diagram

以川木香和土木香这组易混淆样本进行进一步的效果分析，如图 12 所示。




图 12 失败案例 CAM 图

Fig.12 Failure case CAM analysis diagram

由图 12 可见，基线模型将川木香误判为土木香，其激活区域显示出对样本切片边缘和外部残余的模糊关注，相比之下，GCMD-YOLO 成功将该样本识别为川木香，热力图精准地高亮了药材内部放射状韧皮部束的结构，说明该模型在细粒度相似性混淆问题的提升。

2.12 泛化能力验证

为验证训练所得模型能否直接应用于其他来源的数据,即评估其泛化能力,选用百度飞桨 ChinesMedicine-163 中草药数据集开展试验,该数据集涵盖 163 类中草药样本,图像包含不同产地、加工状态的药材形态^[31],且该数据集与本文的自建数据集数据无交集。训练完成的 GCMD-YOLO 模型不经任何微调,在该数据集直接进行测试,结果如表 3 所示:

表 3 泛化试验
Table 3 Generalization test

模型 Model	精确率 Precision %	召回率 Recall %	F1 分数 F1 Score %	mAP @0.5 %	mAP @0.5: 0.95 %	参数量 Parameters/ M	运算量 FLOPs/ G
YOLOV11-S	82	79	81	78.5	63.5	9.4	21.5
GCMD-YOLO	89	87	88	84.5	70.2	7.9	15.6

在跨数据集泛化测试中,相较基线模型,精确率提升 8.5%,召回率提升 10.1%,F1 分数同步提升 8.6%,mAP@0.5 提升 7.6%,mAP@0.5:0.95 提升 10.5%,结果证明,GCMD-YOLO 学习到的特征具有强泛化能力,验证了模型应用的鲁棒性。

3 边缘部署

为验证改进模型在边缘设备的适配性,基于 Jetson-Nano 进行部署。利用 Infer 推理库搭配 TensorRT 加速器。首先,将改进模型及基线模型的 PyTorch 权重(.pt),经 ONNX 工具链导出为 ONNX 格式,借助 ONNX-Simplifier 优化结构,删减冗余层、合并算子以减少推理冗余。接着,依托 JetsonNano 的 CUDA 环境,把优化后的 ONNX 模型转换为 TensorRT 推理引擎(.engine),利用其层融合、FP16 量化等特性适配边缘设备算力。最后,通过 Infer 推理库加载 TensorRT 引擎,在 ChinesMedicine-163 数据集试验,对比两款模型部署效果,结果如表 4 所示:

表 4 部署性能对比
Table 4 Deployment performance comparison

模型 Model	参数量 Parameters/M	运算量 FLOPs/G	mAP @0.5 %	mAP @0.5:0.95 %	FPS(帧·s ⁻¹)
YOLOV11-S	9.4	21.5	85	70.5	25
GCMD-YOLO	7.9	15.6	92	78	39

结果显示,本文模型的 FPS 从 25 提升至 39 帧·s⁻¹,计算效率大幅提升;mAP@0.5 达 92%,mAP@0.5:0.95 达 78%,均优于基准模型,表明模型核心识别精度未受明显影响。

4 结论

本研究针对中药材智能检测中存在的细微特征提取困难、相似品类易混淆及边缘设备部署效率低的问题,基于 YOLOv11s 提出改进模型 GCMD-YOLO,引入 GhostConv、C3K2-GL、MG-CA 等模块进行结构重构与特征增强,显著提升检测精度与模型轻量化能力。研究成果如下:

1) 构建涵盖 100 类中药材的多源数据集,通过物理仿真与多尺度数据增强,扩充至 30,480 张图像,为模型训练与评估提供了高质量数据基础。

2) 在自建数据集上,GCMD-YOLO 实现了精度与轻量化的协同提升:精确率、召回率与 mAP@0.5 分别达到 93%、91% 与 92.8%,较基线模型显著提高;参数量降低 16%,计算量减少 27%,在 Jetson Nano 边缘设备上推理速度达 39 FPS,满足实时检测需求。

3) 通过与 Faster R-CNN、SSD 及 YOLO 系列模型对比,验证了 GCMD-YOLO 在细微纹理区分与多尺度目标检测上的优势。

4) 消融实验与可视化分析进一步表明,各改进模块有效增强了对药材鉴别性特征的提取与聚焦能力,显著降低了相似品类的混淆率。

本研究为中药材的智能化检测提供了一种高精度、轻量化的解决方案,但数据集中药材品类与场景覆盖仍有扩展空间。未来将探索在更复杂实际场景中的模型适配与优化。

[参 考 文 献]

- [1] 王超超,张先超,谷正昌,等.中药材及饮片检测中人工智能应用探讨[J].中国工程科学,2024,26(2):245-254. WANG Chaochao, ZHANG Xianchao, GU Zhengchang, et al. Exploration of artificial intelligence application in the detection of chinese medicinal materials and herbal pieces[J]. China Engineering Science, 2024, 26(2): 245-254. (in Chinese with English abstract)
- [2] 薛晓娟,刘彩,王益民,等.新时代中医药发展现状与思考[J].中国工程科学,2023,25(5):11-20. XUE Xiaojuan, LIU Cai, WANG Yimin, et al. Current status and thoughts on the development of traditional chinese medicine in the new era[J]. China Engineering Science, 2023, 25(5): 11-20 (in Chinese with English abstract)
- [3] 郭丛,田钰嘉,李杨,等.基于 YOLOv4 算法的中药饮片识别[J].中国实验方剂学杂志,2023,29(14):133-140. GUO Cong, TIAN Yujia, LI Yang, et al. Recognition of traditional chinese medicine herbal pieces based on YOLOv4 algorithm[J]. Journal of Experimental Formulae and Pharmacology, 2023, 29(14): 133-140 (in Chinese with English abstract)
- [4] 董苗苗,梁允泉,刘羿璇,等.基于改进的 YOLOv5 实现中药饮片的检测识别[J].现代计算机,2022,28(22):9-16. DONG Miaomiao, LIANG Yunquan, LIU Yixuan, et al. Detection and recognition of traditional chinese medicine herbal pieces based on improved YOLOv5[J]. Modern Computer, 2022, 28(22): 9-16 (in Chinese with English abstract)
- [5] 赵哲,燕振刚,陈蕾.基于改进 YOLOv8 的中药材图像识别[J].软件工程,2024,27(11):38-43. Zhao Zhe, YAN Zhengang, CHEN Lei. Image recognition of traditional chinese medicine materials based on improved YOLOv8[J]. Software Engineering, 2024, 27(11): 38-43 (in Chinese with English abstract)
- [6] 孙兴,李杨,毛天驰,等.改进 YOLOv8 在中药饮片自动识别标注中的研究与应用[J].中草药,2025,56(1):216-226. SUN Xing, LI Yang, MAO Tianchi, et al. Research and application of improved YOLOv8 in automatic identification and annotation of traditional chinese medicine herbal pieces[J]. Chinese Herbal Medicine, 2025, 56(1): 216-226 (in Chinese with English abstract)

- [7] 华畅, 郑豪. 面向中药饮片识别的 MSDA-YOLOv8 检测算法[J]. 时珍国医国药, 2024, 35(12): 2898-2904.
HUA Chang, ZHENG Hao. MSDA-YOLOv8 detection algorithm for traditional chinese medicine herbal pieces recognition[J]. Journal of Traditional Chinese Medicine and Pharmacy, 2024, 35(12): 2898-2904 (in Chinese with English abstract)
- [8] 李明辰, 赵晓, 王若男, 等. 基于改进卷积神经网络的中药饮片图像识别[J]. 科学技术与工程, 2024, 24(9): 3596-3604.
LI Yuechen, ZHAO Xiao, WANG Ruonan, et al. Image recognition of traditional chinese medicine herbal pieces based on improved convolutional neural network[J]. Science, Technology and Engineering, 2024, 24(9): 3596-3604 (in Chinese with English abstract)
- [9] 王青青, 董能峰, 杨怡, 等. 基于图像处理和深度学习的中药材鉴别关键技术[J]. 自动化与仪器仪表, 2023(1): 30-35.
WANG Qingqing, DONG Nengfeng, YANG Yi, et al. Key technologies for identifying traditional chinese medicinal materials based on image processing and deep learning[J]. Automation and Instrumentation, 2023(1): 30-35 (in Chinese with English abstract)
- [10] LAPKOVSKIS A, NEFEDOVA N, BEIKMOHAMMADI A. Automatic fused multimodal deep learning for plant identification[J]. Frontiers in Plant Science, 2025, 161616020-1616020.
- [11] ZHAO L, WU S, FU J, et al. Panoptic plant recognition in 3D point clouds: a dual-representation learning approach with the PP3D dataset[J]. Remote Sensing, 2025, 17(15): 2673-2673.
- [12] 谷瑞, 宋翠玲, 李元昊. 基于 BIM-Res2Net-ICA 的中药饮片图像识别模型[J]. 时珍国医国药, 2025, 36(6): 1192-1200.
GU Rui, SONG Cuiling, LI Yuanhao. Image recognition model of traditional chinese medicine herbal pieces based on BIM-Res2Net-ICA[J]. Journal of Traditional Chinese Medicine and Pharmacy, 2025, 36(6): 1192-1200 (in Chinese with English abstract)
- [13] 李志成. 基于深度学习的中药饮片图像识别研究[D]. 江西中医药大学, 2024.
LI Zhicheng. Research on image recognition of traditional chinese medicine herbal pieces based on deep learning [D]. Jiangxi University of Traditional Chinese Medicine, 2024 (in Chinese with English abstract)
- [14] 陈晨, 卢筱磊, 陈柚青, 等. 基于改进 YOLO11s-Broiler 的复杂环境下笼养鸡全生长周期行为识别模型[J]. 云南农业大学学报(自然科学), 2025, 40(3): 44-56.
CHEN Chen, LU Xiaolei, CHEN Youqing, et al. Behavior recognition model for cage-raised chickens throughout their entire growth cycle based on improved YOLO11s-Broiler in complex environments[J]. Journal of Yunnan Agricultural University (Natural Sciences), 2025, 40(3): 44-56. (in Chinese with English abstract)
- [15] 朱铭敏, 张国平, 谭建军, 等. 基于 YOLOv5s 的轻量级茶叶嫩芽终端检测模型[J]. 浙江农业学报, 2024, 36(6): 1413-1424.
ZHU Mingmin, ZHANG Guoping, TAN Jianjun, et al. A lightweight terminal detection model for tea buds based on YOLOv5s[J]. Acta Agriculturae Zhejiangensis, 2024, 36(6): 1413-1424 (in Chinese with English abstract)
- [16] 周苏娟, 李嘉涛, 何啟森, 等. 基于通道注意力机制的中药饮片图像识别方法[J]. 自动化与信息工程, 2023, 44(5): 63-67+73.
ZHOU Sujuan, LI Jiatao, HE Qisen, et al. Image recognition method for traditional chinese medicine herbal pieces based on channel attention mechanism[J]. Automation and Information Engineering, 2023, 44(5): 63-67+73 (in Chinese with English abstract)
- [17] 叶青, 冯振乾, 朱彦陈, 等. 基于深度学习的中药饮片智能甄别[J]. 现代信息科技, 2023, 7(14): 1-6+11.
YE Qing, FENG Zhenqian, ZHU Yanchen, et al. Intelligent identification of traditional chinese medicine decoction pieces based on deep learning[J]. Modern Information Technology, 2023, 7(14): 1-6+11 (in Chinese with English abstract)
- [18] 韩勇, 兰杰, 郭瑞瑶, 等. 基于深度学习的中药材饮片识别[J]. 西北农业学报, 2023, 32(11): 1859-1867.
HAN Yong, LAN Jie, GUO Ruiyao, et al. Identification of chinese herbal medicine slices based on deep learning[J]. Acta Agriculturae et Agroforestry Sinica, 2023, 32(11): 1859-1867 (in Chinese with English abstract)
- [19] 刘侦龙, 王骥, 麦仁贵. 基于改进 YOLOv10s 的海洋牧场水下海参检测方法[J]. 农业工程学报, 2025, 41(10): 186-194.
LIU Zhenlong, WANG Ji, MAI Rengui. Underwater sea cucumber detection method for marine ranching based on improved YOLOv10s[J]. Journal of the Chinese Society of Agricultural Engineering, 2025, 41(10): 186-194 (in Chinese with English abstract)
- [20] 熊干, 陈慈发, 张上. QMDF-YOLO11: 复杂场景下水稻害虫检测算法[J]. 计算机工程与应用, 2025, 61(13): 113-123.
XIONG Gan, CHEN Cifa, ZHANG Shang. QMDF-YOLO11: A rice pest detection algorithm in complex scenarios[J]. Computer Engineering and Applications, 2025, 61(13): 113-123 (in Chinese with English abstract)
- [21] GHNEMAT RAWN;ALODIBAT SAWSAN. Explainable artificial intelligence (XAI) for deep learning based medical imaging classification. [J]. Abu AlHajja Qasem. Journal of imaging. 2023.155-162.
- [22] ATHALYE CHINMAYEE. Domain-guided data augmentation for deep learning on medical imaging. [J]. Arnaout Rima. PloS one. 2023.77-83.
- [23] 孙剑明, 毕振宇, 牛连丁. 基于特征融合 Transformer 的 EfficientNet v2 网络对马铃薯叶片病害的识别[J]. 江苏农业科学, 2024, 52(8): 166-176.
SUN Jianming, BI Zhenyu, NIU Lianding. Recognition of potato leaf diseases using the EfficientNet v2 network based on feature fusion transformer[J]. Jiangsu Agricultural Sciences, 2024, 52(8): 166-176 (in Chinese with English abstract)
- [24] 李茂, 肖洋轶, 宗望远. 基于改进 YOLO11 的多尺度板栗果实识别方法[J]. 农业机械学报, 2025, 56(5): 443-454.
LI Mao, XIAO Yangyi, ZONG Wangyuan. Multi-scale chestnut fruit recognition method based on improved YOLO11[J]. Transactions of the Chinese Society of Agricultural Machinery, 2025, 56(5): 443-454 (in Chinese with English abstract)
- [25] 蒋永新, 曲衡, 刘旋峰, 等. 残膜回收机铲齿式起膜装置设计与试验[J]. 农业机械学报, 2025, 56(1): 282-289.
JIANG Yongxin, QU Heng, LIU Xuanfeng, et al. Design and experiment of shovel-type film lifting device for residual film recycling machine[J]. Journal of Agricultural Machinery, 2025, 56(1): 282-289 (in Chinese with English abstract)
- [26] PENG ZHANG;DING FAN ZHANG;WAI ZZHOU;LAN WANG;BOYANG WANG;TINGYU ZHANG;SHAO LI. Network pharmacology: towards the artificial intelligence-based precision traditional chinese medicine. [J]. Briefings in bioinformatics. 2023.98-105.
- [27] 丁永军, 杨文涛, 赵一龙. 基于一致性半监督学习的苹果叶片病斑分割模型研究[J]. 农业机械学报, 2024, 55(12): 314-321.
DING Yongjun, YANG Wentao, ZHAO Yilong. Research on apple leaf disease spot segmentation model based on consistent semi-supervised learning[J]. Transactions of the Chinese

- Society of Agricultural Machinery, 2024, 55(12): 314-321 (in Chinese with English abstract)
- [28] 郑文轩, 杨瑛. 基于频域数据增强与轻量化 YOLO v7 模型的成熟期香梨目标检测方法[J]. *农业机械学报*, 2024, 55(5): 244-253.
ZHENG Wenxuan, YANG Ying. Target detection method for mature fragrant pears based on frequency domain data augmentation and lightweight YOLO v7 model[J]. *Journal of Agricultural Machinery*, 2024, 55(5): 244-253 (in Chinese with English abstract)
- [29] 赵毓, 任艺平, 朴欣茹, 等. 基于改进 ShuffleNet V2 的轻量级防风药材道地性智能识别[J]. *智慧农业 (中英文)*, 2023, 5(2): 104-114.
ZHAO Yu, REN Yiping, PU Xinru, et al. Lightweight intelligent identification of genuine wind-resistant medicinal materials based on improved ShuffleNet V2[J]. *Smart Agriculture (Chinese and English)*, 2023, 5(2): 104-114 (in Chinese with English abstract)
- [30] 黄铭杰, 蔡伟强, 张子健, 等. 基于改进 YOLO11 的荔枝果实品种实时精准识别算法[J]. *农业工程学报*, 2025, 41(11): 156-164.
HUANG Mingjie, CAI Weiqiang, ZHANG Zijian, et al. Real-time precise recognition algorithm for litchi fruit varieties based on improved YOLO11[J]. *Journal of the Chinese Society of Agricultural Engineering*, 2025, 41(11): 156-164 (in Chinese with English abstract)
- [31] 谭代庆, 肖志鸿, 吴浩忠, 等. 融合改进残差网络和 Transformer 的易混淆中药饮片识别研究[J]. *中国数字医学*, 2023, 18(6): 42-50.
TAN Daiqing, XIAO Zhihong, WU Haozhong, et al. Research on identifying confusable traditional chinese medicine herbal pieces by integrating improved residual networks and transformers[J]. *China Digital Medicine*, 2023, 18(6): 42-50 (in Chinese with English abstract)

Lightweight multi-scale Chinese herbal medicine detection method based on GCMD-YOLO

SUN Peng¹, TANG Yongjing², SUN Chuancong^{1*}

(Department of Medical Equipment, Shandong College of Pharmaceutical and Food Sciences, Weihai 264200, China; Department of Cardiology and Neurology, Weihai Maternity and Child Healthcare Hospital, Weihai 264200, China)

Abstract: Aiming at the technical bottleneck that existing intelligent detection algorithms for traditional Chinese medicinal materials (TCMMs) struggle to balance high detection accuracy and real-time performance during edge-end deployment, as well as the problems of small-target missed detection and category confusion caused by the significant morphological differences among medicinal materials and the high similarity of their cross-sectional textures, this paper proposes a lightweight multi-scale detection method based on GCMD-YOLO. Taking YOLOv11s as the benchmark architecture, this method achieves the comprehensive improvement of model accuracy and efficiency through the innovative design of feature extraction mechanisms and attention mechanisms. Firstly, by adopting multi-source data fusion and data augmentation technologies, a high-quality dataset covering 100 common varieties of TCMMs with a total of 30,480 images is constructed, which effectively addresses the issues of unbalanced data distribution and single background existing in traditional datasets. Secondly, in terms of model lightweight design, the GhostConv module is utilized to reconstruct the backbone and neck networks, and the Dysample dynamic upsampling module is introduced. This not only drastically reduces parameter redundancy but also optimizes the efficiency of feature reconstruction. To tackle the problem that the traditional SPPF (Spatial Pyramid Pooling Fast) module tends to cause the loss of shallow texture information, the Conv-SPPF module is designed. By replacing pooling operations with convolution operations, this improved module effectively preserves the key edge and texture details of TCMM images. Furthermore, to overcome the challenge of fine-grained feature extraction, the C3K2-GL module is proposed, which incorporates a global-local dual-path dynamic convolution mechanism. By adaptively adjusting the weights of convolution kernels, this module significantly enhances the capability of capturing fine textures of rhizome-type medicinal materials and small targets of seed-type medicinal materials. Meanwhile, the MG-CA multi-scale global attention mechanism is designed and integrated into the feature fusion layer. Leveraging a multi-granularity pooling strategy, this mechanism accurately focuses on the key discriminative regions, suppresses the interference from complex backgrounds, and thus effectively improves the distinguishability of similar TCMM categories. The results show that the GCMD-YOLO model exhibits outstanding performance on the self-built dataset. Specifically, the precision, recall, and F1-score reach 93%, 91%, and 92% respectively; the mean average precision at the intersection over union (IoU) threshold of 0.5 (mAP@0.5) attains 92.8%, and the mAP@0.5:0.95 (mean average precision across IoU thresholds from 0.5 to 0.95 with an interval of 0.05) reaches 78.6%. These metrics represent improvements of 7.0, 8.0, 7.5, 7.3, and 7.4 percentage points over the baseline model, respectively. In terms of model efficiency, the number of parameters is reduced by 16% and the inference speed is increased by 27%. Cross-dataset generalization experiments show that without any fine-tuning, the mAP@0.5 of the proposed model on external datasets is still 7.6 percentage points higher than that of the baseline, demonstrating extremely strong robustness. Analyses of the confusion matrix and Class Activation Mapping (CAM) heatmaps further confirm that this method can effectively resolve the inter-category confusion problem and achieve accurate target localization. Finally, deployment tests on the Jetson Nano edge device indicate that the inference speed of the model reaches 39 frames per second (FPS), which successfully verifies its feasibility and engineering application value for achieving high-precision and real-time detection in resource-constrained scenarios.

Keywords: deep learning; image processing; YOLOv11 network; network lightweight; multi-scale recognition