

基于 PSMF-YOLO 的无人机遥感图像枇杷花蕾小目标检测方法

徐常塑, 柳鑫智, 朱瑜琳, 陈 晨, 凤柳燕, 李云伍*

(西南大学工程技术学院, 重庆 400715)

摘 要: 为解决枇杷花蕾因呈簇状生长、体积小且与背景叶片颜色相近难以被准确识别的问题, 该研究提出了一种基于无人机遥感图像与深度学习结合的目标检测算法 PSMF-YOLO。首先, 利用无人机采集图像并构建了枇杷花蕾数据集; 在此基础上, 基于 YOLOv11n 模型引入 P2 小目标检测层, 以保留更多空间细节, 提升对花蕾的检测能力; 其次, 在网络中加入 SPD-Conv 的模块, 使空间到深度变换的细节保留, 有助于提高低分辨率图像和小目标的检测精度; 将 C2PSA 与 MSDA 多尺度扩张注意力机制结合, 通过多尺度扩张卷积与动态特征融合, 实现全局场景理解的跨层次感知; 最后, 引入 Focaler-DIoU 损失函数解决小目标样本不平衡和边界框回归不精准问题, 提升模型在复杂场景下的检测鲁棒性。试验结果表明, PSMF-YOLO 模型在平均精度均值、准确率、召回率指标上比基础模型分别高 4.9、2.3、4.2 个百分点, 较表现最好的 YOLOv5s 基础模型分别高 0.8、0.1、0.6 个百分点。该研究为农业遥感小目标检测提供有效方法, 为果蔬智能精准管理提供技术支持。

关键词: 枇杷; 花蕾; 无人机; 深度学习; 目标检测; PSMF-YOLO

doi: 10.11975/j.issn.1002-6819.202511124

中图分类号: TP391.4; S24

文献标志码: A

文章编号: 1002-6819(2026)-11-0001-10

徐常塑, 柳鑫智, 朱瑜琳, 等. 基于 PSMF-YOLO 的无人机遥感图像枇杷花蕾小目标检测方法[J]. 农业工程学报, 2026, 42(11): 1-10. doi: 10.11975/j.issn.1002-6819.202511124 <http://www.tcsae.org>

XU Changsu, LIU Xinzhi, ZHU Yulin, et al. A small object detection method for loquat flower buds in UAV remote sensing imagery based on PSMF-YOLO[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2026, 42(11): 1-10. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202511124 <http://www.tcsae.org>

0 引 言

枇杷树成花量大且密集, 若不及时疏花将严重影响果实产量与商品性。因此, 实现早期花蕾的精准检测对智能化疏花作业和提升果实品质具有重要意义。自然环境中枇杷花蕾与叶片颜色十分相近, 且花蕾体积小, 在视觉检测过程中, 难以与背景中密集的绿叶区分。传统方法主要依靠人工目测, 不仅效率低, 而且易受主观因素的影响, 难以满足现代精准农业的需求。

近年来, 无人机遥感技术在农业信息获取中的应用不断深化, 其在多尺度成像、快速覆盖与非接触式观测方面具有显著优势, 为作物器官级表型监测提供了有效手段。万亮等^[1]通过融合无人机获取的多源图谱信息, 实现了水稻稻穗表型参数的高效提取, 验证了无人机平台在复杂田间环境下进行精细化作物表型监测的可行性。多数研究逐步将深度学习方法引入无人机遥感影像分析中, 用于不同作物及其关键器官的自动识别与定位。晏琳等^[2]改进了 YOLOv8 算法, 对苹果进行无人机动态监测, 为田间管理提供了一种高效便捷的工具; 赵建国等^[3]提出了一种改进 YOLOv10 算法检测遥感

图像中的玉米杂草; 范翔宇等^[4]将无人机图像和深度学习结合, 提出用分割精度为 95.96% 的高精度改进模型 DeepLabV3+ 为胡麻大规模倒伏监测提供技术支持。上述研究已证实无人机遥感与深度学习结合在农业目标检测任务中的可行性与有效性, 但针对目标尺度小、密集簇生且与背景视觉特征高度相似的枇杷花蕾, 极易发生漏检与误检。

针对目标检测的性能优化, 已涌现出多种算法框架。陈柯屹等^[5]在 Faster R-CNN 中将主干网络替换为 RegNetX-6.4GF, 有效避免小目标细节丢失, 识别精度提高 3.1 个百分点。Yang 等^[6]将 Swin Transformer^[7] 作为 Mask R-CNN 的主干网络, 并结合 K-means++ 算法^[8] 优化锚框以提升精度。Faster R-CNN^[9] 和 Mask R-CNN^[10] 作为典型的两阶段检测模型, 能够有效检测目标, 但极大的参数量导致检测速度缓慢, 难以满足实时检测的要求。相比之下, 单阶段检测方法在检测速度、计算资源消耗及端到端训练上更具优势, 其中具有代表性的是通过直接回归实现检测的 YOLO 系列和依托多尺度锚框的 SSD 算法^[11]。马中杰等^[12]引入 VanillaBlock 模块替换 SPPCSPC 的两个 CBL 模块, 提出一种基于 YOLOv7-tiny 的无人机视角小目标检测方法。李川红等^[13]提出改进的 YOLOv8 模型以应对无人机航拍中的复杂环境和微小目标。宁娜等^[14]提出的 IM-SSD 通过跨层特征图融合, 使小目标检测率较传统 SSD 算法提升了 7.79 个百分点。YOLOv11^[15] 通过结构优化、引入注意力机制及精简参数, 实现精度的进一步突破。在此基础上, 李成轩等^[16]引进轻量化下采样模块和倒置残差块注意力机制等模块

收稿日期: 2025-11-17 修订日期: 2026-05-21

基金项目: 中央高校基本科研业务费项目 (SWU-KQ24001); 贵州省科技计划项目 (黔科合支撑 [2022] 一般 168)

作者简介: 徐常塑, 博士, 研究方向为智慧农业技术与装备。

Email: xuchangsu@swu.edu.cn

*通信作者: 李云伍, 教授, 博士生导师, 研究方向为农业信息感知与自主导航技术。Email: liywu@swu.edu.cn

实现对梨表面缺陷的高效检测。曾昆峰等^[17]则设计小波变换动态卷积架构,在减少参数量的同时增强特征信息,以提升对目标的识别能力。目标检测算法进展显著,但现有改进多聚焦于单一结构或机制,对无人机遥感条件下低分辨率输入、小目标密集分布与背景高度相似等因素的协同影响关注不足,难以在精度、鲁棒性与轻量化之间取得稳定平衡。

基于此,本文采用 YOLOv11n 作为基础模型,引入 P2 小目标检测层、SPD-Conv 模块、多尺度扩张注意力 (MSDA) 及 Focaler-DIoU 损失函数,构建了 PSMF-YOLO 模型,对无人机遥感图像的枇杷花蕾进行检测。该模型可有效解决花蕾目标尺度小、呈簇生分布且与自然背景纹理相似等特征问题。

1 材料与方法

1.1 数据集制作

1.1.1 数据采集

枇杷花蕾图像采集于中国重庆市北碚区秀峰枇杷园 (东经 29.801°和北纬 106.412°,海拔 304 m)。图像采集设备为 DJI mini3 无人机,该无人机配备 1/1.3 英寸 CMOS 影像传感器,分辨率为 1920×1 080 像素,镜头光圈设置为 f/1.7,飞行高度区间设置在 5~8 m,确保足够清晰地拍摄到枇杷花蕾的图像。共获得 850 张分辨率为 1920×1 080 像素的 RGB 图像数据。

1.1.2 数据集标注与增强

对采集到的 850 张图像进行人工筛选,去除目标数量较少以及图像质量过于模糊的样本,以保证数据集的有效性和标注质量。筛选后得到 600 张图像。使用 Labelimg 图像标注软件,对花蕾进行人工精准标注。枇杷植株顶端的花蕾器官表现出多样化的形态学特征,其发育过程受遗传因素和环境条件的双重影响。花序表现出较为紧凑的簇生形态,个体花蕾呈球形或椭球形分布,整体外观受外围萼片及绒毛覆盖影响。所以在标注过程中,基于几何标注规范,采用数字图像处理技术中的最小外接矩形方法,将花蕾完整地框定在以该几何特征为基础设置的标记范围内,确保对发育初期枇杷花蕾进行准确完整的定位标记,并且生成 TXT 文件。

为了让模型学习到更多特征,在完成标注后,先将数据集按照 7:2:1 的比例划分为训练集、验证集和测试集。利用 OpenCV^[18] 工具包对训练集图像数据进行增强处理,增强方式包括图像翻转、旋转以及亮度和对比度调整等操作 (图 1),最终使训练集图像数量扩充至 3 000 张。

1.2 PSMF-YOLO 模型架构

YOLOv11 相比前代版本 (YOLOv8、YOLOv9、YOLOv10),采用增强型特征金字塔,能够更好地捕捉全局和局部特征,提高对小目标的检测能力,且因其高效的卷积模块,减少计算量的同时提升了检测精度。YOLOv11 包含 n、s、x、m、l 五个版本,随着模型复杂度的非线性增长,其检测精度虽有提升,但训练周期与推理延迟也大幅增加,极难满足实际应用需求。因此,为严格控制模型参数量与内存开销,选用参数量与计算

量最小的 YOLOv11n 作为基础网络,该版本具备优异的轻量化特性与较为稳定的检测精度。在此基础上,本文的改进目标并非追求参数量的绝对最小,而是在保持整体模型规模可控的前提下,通过结构优化提升其对复杂果园环境中小目标的检测能力,实现检测精度与计算开销的合理权衡。




图 1 枇杷花蕾数据增强


Fig.1 Data augmentation for loquat flower-bud Images

PSMF-YOLO 模型 (图 2) 的具体改进有以下几点:

1) 增加 P2 小目标检测层。2) 将整个网络中的 7 个非步幅卷积 (Conv) 层替换成由一个空间至深度 (SPD) 层和一个非步幅卷积 (Conv) 层组成的 SPD-Conv^[19] 层。3) 优化 C2PSA 注意力机制,与多尺度扩张注意力模块 (MSDA)^[20] 结合形成新的 C2PSA-MSDA 模块。4) 将边界框损失函数 CIoU^[21] 替换成 Focaler-IoU^[22] 与 DIoU^[23] 结合形成的 Focaler-DIoU 损失函数。

1.2.1 P2 检测层

为提高 PSMF-YOLO 模型对枇杷花蕾的检测性能,本文在原有网络结构基础上引入 P2 检测层。P2 检测层对应于较低下采样倍率的高分辨率特征层,其构建并非通过额外下采样获得,而是通过特征融合方式形成。具体而言,首先对高层特征图进行上采样操作,使其空间分辨率提升至原来的两倍;随后,将上采样后的特征图与主干网络中相应尺度的浅层特征图在通道维度上进行拼接,并通过带残差连接的 C3k2 模块完成特征融合与特征增强,最终生成 P2 检测层输出。模型的输入图像尺寸统一设定为 640×640 像素,最终输出的多尺度特征图尺寸分别为 160×160、80×80、40×40 和 20×20 像素,可以有效检测输入图像中的小目标,提升检测精度。P2 检测层融合了更多浅层特征,保留了更丰富的位置信息和纹理信息,减少了信息丢失,适用于无人机遥感图像中小目标的精细化检测任务。



注：Conv 代表卷积操作；SPD 代表空间到通道变换；C3k2 代表残差特征提取模块；C2PSA-MSDA 代表跨阶段注意力模块与多尺度扩张注意力机制结合；Upsample 代表上采样模块；Concat 代表特征连接模块；PSABlock-MSDA 代表金字塔压缩注意力模块与多尺度扩张注意力机制结合；SPPF 代表空间金字塔池化模块；MaxPool2 d 代表 2D 最大池化层；Bottleneck 代表基础残差单元；Detect 代表检测头。

Note: Conv represents the convolution operation; SPD denotes the space-to-depth transformation; C3k2 refers to the residual feature extraction module; C2PSA-MSDA represents the combination of the cross-stage attention module and the multi-scale dilated attention mechanism; Upsample denotes the upsampling module; Concat represents the feature concatenation module; PSABlock-MSDA refers to the combination of the pyramid squeeze attention module and the multi-scale dilated attention mechanism; SPPF denotes the spatial pyramid pooling fast module; MaxPool2 d represents the 2D max-pooling layer; Bottleneck denotes the basic residual unit; Detect represents the detection head.


图 2 PSMF-YOLO 的网络结构
Fig.2 Network structure of PSMF-YOLO

1.2.2 SPD-Conv 模块

由于枇杷花蕾在复杂背景下容易受到干扰，且传统目标检测网络中的步幅卷积和池化层在进行特征提取时，会不可避免地丢失关键信息，导致网络在检测小目标时性能下降，因此，本文引入 SPD-Conv (space-to-depth convolution) 模块 (图 3)。SPD-Conv 通过 SPD 变换，将空间信息重新排列至通道维度，在进行下采样的同时保持原始特征图的完整信息，从根本上避免了步幅卷积和池化层带来的信息丢失。此外，SPD-Conv 后续的非步幅卷积不仅增强特征提取能力，还能优化通道信息的分配，使得网络能够更精确地学习枇杷花蕾的边缘细节和纹理特征。

相比于传统的降采样方式，SPD-Conv 在保证感受野扩展的同时有效避免了冗余信息的损失，使得模型在低分辨率小目标检测任务中展现出更优的性能。通过在 YOLOv11n 的多个特征层级应用上 SPD-Conv，构建了一种更加适应小目标检测的网络架构，提升对不同尺度目

标的学习能力，使枇杷花蕾即便在复杂环境中仍然能够被高精度识别。



注：X 表示输入特征图；S 表示空间尺寸；C₁ 和 C₂ 分别表示输入特征图与最终输出特征图的通道数；X' 和 X'' 分别表示中间过渡特征图与最终输出特征图；Convolution 表示应用一个标准卷积。

Note: X denotes the input feature map; S represents the spatial size; C₁ and C₂ respectively indicate the numbers of channels for the input feature map and the final output feature map; X' and X'' respectively denote the intermediate transitional feature map and the final output feature map; Convolution refers to the application of a standard convolution operation.


图 3 SPD-Conv 模块结构及转变过程
Fig.3 SPD-Conv module structure and transformation process

当进行 SPD 变换时 (图中 scale (即缩放因子) = 2), 原始特征图 X 被划分为 4 (scale^2) 个子特征图 $f_{i,j}$, 可以通过式 (1) 计算, 即被划分为 $f_{0,0}$ 、 $f_{1,0}$ 、 $f_{0,1}$ 、 $f_{1,1}$ 。每个子特征图的大小为 $S/2 \times S/2 \times C_1$ 。SPD 变换后, 子特征图在通道维度上进行拼接, 形成新的特征图 X' , 空间尺寸缩小至 $S/2 \times S/2$ ($S/\text{scale} \times S/\text{scale}$), 但通道数变为 $4C_1$ ($\text{scale}^2 C_1$)。这保证了在降采样过程中信息不丢失, 而是被重新编码到通道维度。在 X' 之后, SPD-Conv 应用一个标准卷积 ($\text{stride}=1$), 得到大小为 $S/2 \times S/2 \times C_2$ 的输出特征图 X'' 。

$$f_{i,j} = X[i:S:\text{scale}, j:S:\text{scale}] \quad (1)$$

1.2.3 多尺度扩张注意力机制 MSDA

在 YOLOv11 模型中, C2PSA 模块能够结合空间注意力和通道注意力机制, 更有效地捕捉图像中的关键特征。具体而言, 它通过对不同空间位置 and 不同通道的特征加权, 来提升模型对重要区域的敏感度。但针对枇杷花蕾这种小目标的检测, C2PSA 模块并不具备足够的能力来捕捉全局上下信息。小目标通常需要更大的感受野来识别其细节, 尤其是当目标的尺寸相对较小时, 单独的空间和通道注意力可能无法有效提取这些信息。另外, C2PSA 模块虽然能够在局部区域内提升注意力, 但它缺乏通过扩张卷积来捕捉远距离依赖的能力, 所以引入 MSDA 与 C2PSA 模块融合 (图 4)。



注: Q 、 K 和 V 分别表示查询、键和价值矩阵, 矩阵中的每一行表示一个查询/键/值特征向量; Head 表示头部; Concat 表示特征连接模块。现在设置扩张率为 $r=1, 2, 3$ 和 4 的 3×3 卷积核, 不同头部中注意力感受野的大小分别为 3×3 、 5×5 、 7×7 和 9×9 。

Note: Q , K , and V denote the query, key, and value matrices, respectively, where each row of the matrix represents a query/key/value feature vector. Head refers to an attention head, and Concat represents the feature concatenation module. By setting the dilation rates to $r=1, 2, 3$, and 4 for the 3×3 convolution kernels, the sizes of the attention receptive fields in different heads are 3×3 , 5×5 , 7×7 , and 9×9 , respectively.

图 4 MSDA 结构

Fig.4 MSDA structure is illustrated schematically

多尺度扩张注意力机制 MSDA 的输入为来自上一层的特征图, 其空间维度为 $H \times W$, 通道维度为 C 。首先, 输入特征通过线性映射得到查询特征、键特征和价值特征, 并在通道维度上划分为多个注意力头, 使各注意力头仅处理部分通道信息。随后, 在特征图上以滑动窗口方式逐步遍历各空间位置, 并在每个窗口内部按照预设扩张率对邻域特征进行采样, 从而将全局注意力转化为局部注意力计算, 在有效控制计算复杂度的同时扩大有效感

受野。在上述注意力计算过程中, 不同注意力头采用不同的扩张率设置, 使得在相同窗口大小下能够覆盖不同尺度的邻域范围。当扩张率较小时, 注意力主要聚焦于目标周围的细粒度纹理与边缘信息; 当扩张率较大时, 窗口内被采样的位置间隔增大, 注意力能够在更大的有效感受野范围内建立特征依赖, 从而引入更丰富的上下文信息。对于每个注意力头, 在其对应的扩张采样网格上计算查询与键的相似度, 并对相似度进行归一化, 进而对值特征进行加权汇聚, 得到该头的注意力输出。最后, 将各头输出在通道维度上进行拼接并映射回原通道空间, 作为 MSDA 的输出特征, 并与主干特征进行融合, 从而实现跨尺度上下文信息的动态建模与聚合。通过在多个注意力头中并行引入不同扩张率的局部注意力学习, MSDA 能够同时刻画局部细节信息与较大范围的上下文语义, 有助于在复杂背景下提升小目标的可分辨性与定位稳定性。

1.2.4 Focaler-DIoU 损失函数

在 YOLOv11 中, 边界框回归使用的是基于 CIoU 的损失函数。尽管该损失函数在大目标检测中表现优异, 但在小目标检测中存在显著不足。本文将 YOLOv11 的原边界框损失函数替换成 Focaler-DIoU 损失函数。Focaler-DIoU 结合了 Focaler-IoU 和 DIoU 两种损失的优势, 能够有效改进 YOLOv11 在小目标检测中的表现。首先, 通过动态调整损失权重, Focaler-IoU 能有效缓解数据分布不均衡的问题, 提高小目标的定位精度, 同时加快模型对样本的收敛速度。其次, DIoU 损失主要关注预测框和真实框中心点之间的距离, 从而直接针对位置偏差进行优化。相较于 CIoU 同时引入宽高比约束, DIoU 的简单性降低了不必要的干扰, 使得梯度更新更为稳定, 有利于小目标的快速收敛。Focaler-DIoU 通过综合考虑样本难度和边界框的中心点位置, 从而在回归过程中重点关注困难样本并优化目标定位, 使得 YOLOv11 在处理小目标检测任务中能更精确地校正预测框的位置误差, 大大提升了检测精度。Focaler-DIoU 可通过方程 (2) 计算。

$$\begin{cases} \text{IoU}^{\text{focaler}} = \begin{cases} 0, \text{IoU} < d \\ \frac{\text{IoU}-d}{u-d}, d \ll \text{IoU} \ll u \\ 1, \text{IoU} > u \end{cases} \\ L_{\text{Focaler-IoU}} = 1 - \text{IoU}^{\text{focaler}} \\ L_{\text{DIoU}} = 1 - \text{DIoU} \\ \text{DIoU} = \text{IoU} - \frac{\rho^2(b, b^{\text{gt}})}{c^2} \\ L_{\text{Focaler-DIoU}} = L_{\text{DIoU}} + \text{IoU} - \text{IoU}^{\text{focaler}} \end{cases} \quad (2)$$

式中 $\text{IoU}^{\text{focaler}}$ 表示经过重构后的 Focaler-IoU, IoU 和 DIoU 都为各自原始数值, L_{DIoU} 和 $L_{\text{Focaler-DIoU}}$ 都为针对 DIoU 和 Focaler-DIoU 指标所设计的损失函数的定义。 d 表示下限阈值, 表示 IoU 值低于 d 时, Focaler-IoU 的值为 0。意味着当 IoU 值非常低时, 对应的回归样本不被重视。 u 是上限阈值, 表示 IoU 值高于 u 时, Focaler-IoU 的值为 1, 表示该样本被完全关注。 $\rho^2(b, b^{\text{gt}})$ 表示预测框与真实框中心点之间的欧几里得距离, c 是包含预测框和真实框的最小矩形的对角线距离。

1.3 试验平台与参数设置

本研究由一台配备 Intel Xeon Platinum 8481C CPU、NVIDIA GeForce RTX 4090D GPU、80G 内存的 ubuntu22.04 (64 位) 专业计算机作为实验平台。实验代码基于 CUDA 12.1、Python 3.12、PyTorch 2.3.0 的实验环境。提出模型的输入尺寸为 640×640 ，模型训练设定的 epoch 为 300，每批次训练样本数为 32，学习率初始值设定为 0.01，权重衰减设置为 0.0005。

1.4 模型性能评价指标

用多个评估指标来检测和对比模型的性能，包括精确率 (P)、召回率 (R)、F1 score、平均精度 (AP) 以及平均精度均值 (mAP)。其中，mAP 采用的是 IoU 阈值为 0.5 的平均精度均值 $mAP_{0.5}$ 。F1 分数是精确率和召回率的调和平均值，用于综合考虑分类器的性能。F1 分数越高，表示性能越好。

浮点运算次数 (FLOPs) 及其衍生单位 GFLOPs (表示每秒进行的十亿次浮点运算数量) 用于衡量算法的计算复杂度；参数量 (parameters) 主要由卷积层等决定，代表模型可训练参数的总数，单位是兆 (M)；每秒帧数 (frames per second, FPS) 代表模型处理图像的速度；模型大小 (size) 则是指训练后模型文件占用的存储空间，单位 MB。这四项指标不影响最终的检测精度，却直接决定推理速度与显存占用，是平衡模型检测性能与计算效率的重要评估依据。

2 结果和分析

2.1 消融试验

为了理解模型的不同组成部分对整体性能的贡献，进行消融试验并得到相应结果 (表 1)。

表 1 PSMF-YOLO 模型的消融试验结果

Table 1 Ablation experiment results of the PSMF-YOLO model%

模型 Model	P2	SPDConv	MSDA	Focaler-DIoU	mAP _{0.5}	P	R	F1 score
YOLOv11n	×	×	×	×	80.0	77.0	76.4	76.7
YOLOv11-P2	√	×	×	×	82.1	78.6	77.3	77.9
YOLOv11-SPDConv	×	√	×	×	80.9	77.1	77.8	77.4
YOLOv11-MSDA	×	×	√	×	80.4	76.8	76.5	76.6
YOLOv11-Focaler-DIoU	×	×	×	√	80.6	77.6	76.5	76.6
YOLOv11-P2+SPDConv	√	√	×	×	83.0	79.5	78.6	79.3
YOLOv11-P2+SPDConv+MSDA	√	√	√	×	83.5	79.1	78.9	79.0
PSMF-YOLO	√	√	√	√	84.9	79.3	80.6	80.0

注：“√”表示添加此模块，“×”表示未添加此模块。

Note: “√” indicates that the module is added, “×” indicates that the module is not added.

单独引入 P2 小目标检测层， $mAP_{0.5}$ 、 P 和 R 分别提高 2.1、1.6、0.9 个百分点，说明 P2 能更精准地捕捉到小目标的细节信息。单独采用 SPDConv 轻量级卷积来替代部分标准卷积， $mAP_{0.5}$ 、 P 和 R 分别提高 0.9、0.1 和 1.4 个百分点，说明 SPDConv 在 YOLOv11n 上能够增强特征提取能力。两者结合后 $mAP_{0.5}$ 进一步提升至 83.0%， P 、 R 和 F1 score 也分别提高到 79.5%、78.6% 和 79.3%。仅加入 MSDA $mAP_{0.5}$ 和 R 分别提高 0.4 和 0.1 个百分点。虽然 P 和 F1 score 略有下降，但并不影响整体性能。而

Focaler-DIoU 损失函数则通过减少目标框抖动，将 $mAP_{0.5}$ 由 80.0% 提升至 80.6%。最终，结合全部模块的 PSMF-YOLO 模型整体性能相比 YOLOv11n 取得大幅提升。 $mAP_{0.5}$ 提高至 84.9%，精确率提升至 79.3%，召回率上升到 80.6%，F1 score 提升至 80.0%。具体而言， $mAP_{0.5}$ 、 P 、 R 和 F1 score 分别提高 4.9、2.3、4.2 和 3.3 个百分点。这一改进组合使模型在复杂环境下的枇杷花蕾小目标检测中表现出更高的精度、更强的召回能力和更优的整体检测表现。

将表 1 每个模型的 P-R 曲线放入同一图中 (图 5)。PSMF-YOLO 相比于其他改进模型的线下面积更大，尤其是比基线 YOLOv11n 模型的线下面积大，证明 PSMF-YOLO 比 YOLOv11n 有更好的性能。




图 5 不同模型的 P-R 曲线

Fig.5 P-R Curve for different models

2.2 YOLO 系列模型比较分析

从图 6 看出，随着训练轮数的增加，两种模型的训练损失整体呈快速下降并逐步趋于较低水平，在训练后期仍存在缓慢下降现象；相比之下，验证集上的损失曲线在训练中后期已基本趋于稳定。进一步地，在模型训练过程中同步监控了验证集上的精确率、召回率以及 $mAP_{0.5}$ 等检测性能指标，结果表明上述指标在训练后期波动幅度较小，未再出现明显提升，说明模型在验证集上的泛化性能已达到稳定状态，整体已实现有效收敛。在此基础上可以观察到，PSMF-YOLO 的损失下降速度明显快于 YOLOv11n，且在较早训练阶段即可达到稳定水平，表明所提出模型具有更快的收敛速度和更优的整体检测性能，同时有更好的泛化能力。

将提出的 PSMF-YOLO 模型与 YOLO 系列不同模型在自建数据集上进行比较并得出结果 (表 2)。针对枇杷花蕾小目标的精细化检测，选择 YOLOv11n 作为基础模型进行改进，其原始版本在轻量化与性能平衡上具备显著优势：参数量为 2 582 347 M、模型大小为 5.2 MB、GFLOPs 为 6.3、FPS 达到 233.9，较其他轻量级模型如 YOLOv5n 和 YOLOv10n 展现出更优性能， $mAP_{0.5}$ 值分别比 YOLOv5n 和 YOLOv10n 高出 0.5 和 1.9 个百分点，虽然一些复杂模型在检测精度方面更高，但是 YOLOv11n 在检测性能、计算效率和模型大小之间取得了平衡，所以把 YOLOv11n 作为基线模型更适合本次对花蕾小目标的研究。

提出模型以 84.9% 的 $mAP_{0.5}$ 值显著优于主流模型，

最高比传统轻量级模型 YOLOv3-tiny 高出 19.5 个百分点。同时在 P 、 R 、 $F1$ score 上均达到最优,表明其在密集分布、低对比度的田间场景中有效减少了漏检与误检。此外,PSMF-YOLO 的 GFLOPs、参数量、FPS、模型大小分别为 15.6、4 708 380 M、189.4、9.5 MB,较中大型模型 YOLOv5s 和 YOLOv10s 的参数量分别减少 48.3% 和 41.5%,GFLOPs 和模型大小也显著低于 YOLOv5s 和 YOLOv10s。尽管基线模型以及一些轻量级模型如 YOLOv5n 和 YOLOv10n 在推理速度上更具优势,YOLOv5n 和 YOLOv10n 的 FPS 分别快出提出模型 1.43 倍和 1.07 倍,但它们的 $mAP_{0.5}$ 值明显低于 PSMF-YOLO,验证了所提方法在精度与效率协同优化上的有效性。




图 6 YOLOv11n 和 PSMF-YOLO 的损失曲线
Fig.6 Loss curve of YOLOv11n and PSMF-YOLO

表 2 不同 YOLO 检测模型实验结果								
Table 2 Experimental results of different YOLO detection models								
模型 Model	$mAP_{0.5}$ /%	P / %	R / %	$F1$ 分数 $F1$ score	计算量 Float point operations GFLOPs	参数量 Parameters/M	帧率 FPS/ f/s	模型大小 Model size/M
PSMF-YOLO	84.9	79.380	6	80.0	15.6	4 708 380	189.4	9.5
YOLOv5s	84.1	79.280	0	79.5	23.6	9 111 923	285.9	17.7
YOLOv10s	83.3	78.578	9	78.7	24.4	8 035 734	201.5	15.8
YOLOv8n-p2	82.1	78.079	0	78.5	12.2	2 921 172	261.6	6.0
YOLOv11n	80.0	77.076	4	76.7	6.3	2 582 347	233.9	5.2
YOLOv5n	79.5	76.376	5	76.4	7.1	2 503 139	270.0	5.1
YOLOv10n	78.1	75.574	4	74.9	8.2	2 694 806	202.4	5.5
YOLOv3-tiny	65.4	67.560	0	63.5	18.9	12 128 178	307.3	23.3

为进一步说明模型的轻量化特性,本文对 YOLOv11 系列不同规模模型的参数量进行了统计对比(表 3)。结果表明,PSMF-YOLO 的参数量虽高于 YOLOv11n,但仍明显低于 YOLOv11s、YOLOv11 m 和 YOLOv11l 等中大型模型,说明所提方法在检测精度显著提升的同时,模型规模仍保持在轻量化部署的可接受范围内。

表 3 YOLOv11 不同规模模型的对比		
Table 3 Comparison of different-sized models of YOLOv11		
模型 Model	参数量 Parameters/M	计算量 Float point operations GFLOPs
YOLOv11n	2 582 347	6.3
YOLOv11s	9 458 752	21.7
YOLOv11 m	20 114 688	68.5
YOLOv11l	25 372 160	87.6
YOLOv11x	56 966 176	196.0
PSMF-YOLO	4 708 380	15.6

为了更直观地比较 YOLO 系列模型在枇杷花蕾检测任务中的性能差异,研究中选取具有目标密集分布和背景复杂特征的典型测试图像,对各模型的检测结果进行可视化展示(图 7)。图中采用不同颜色的检测框对检测结果进行区分,其中红色框表示正确检测到的枇杷花蕾,青色框表示漏检的枇杷花蕾,蓝色框表示未能正确检测的区域。为看到模型差异,对每个模型结果的相同区域进行了放大。通过对比看出,不同模型在小目标漏检和误检情况上存在差异。在该场景下,PSMF-YOLO 正确检测到 51 个目标,漏检 2 个,误检 1 个。YOLOv3-tiny 这三方面效率最低,漏检 8 个,误检 7 个。PSMF-YOLO 检测率达到最高,同时漏检率和误检率也为最低,整体检测结果更为稳定。尽管 YOLOv5s 和 YOLOv10s 模型的正确检测数量与 PSMF-YOLO 接近,但是 YOLOv5s 的误检区域增多,其误检率比 PSMF-YOLO 高 1.78 个百分点,而 YOLOv10s 在目标密集区域仍存在一定漏检,其漏检率比 PSMF-YOLO 高 1.75 个百分点。综合可视化结果可以看出,PSMF-YOLO 检测性能较优。PSMF-YOLO 提升了小目标的特征表达鲁棒性,而参数量的适度增加未显著影响部署成本,为农业田间环境下的实时枇杷花蕾监测提供了高精度、低资源依赖的解决方案。


2.3 其他检测模型比较分析

为全面评估 PSMF-YOLO 模型在枇杷花蕾小目标检测任务中的性能表现,现选取多种具有代表性的经典目标检测模型进行对比实验:两阶段高精度网络 Faster R-CNN、单阶段多尺度模型 SSD、轻量级实时应用框架 YOLO 系列,以及基于 Transformer 全局建模的 RT-DETR。通过涵盖不同架构特征的基线对比,能够从检测精度、模型复杂度及实际应用适应性等多个角度,对所提 PSMF-YOLO 模型的性能进行更加全面和客观的评价。

在上述对比设置下,表 4 为各种经典检测模型的实验结果。相较于传统两阶段检测框架 Faster R-CNN 与单阶段模型 SSD、RT-DETR,PSMF-YOLO 以 84.9% 的 $mAP_{0.5}$ 值优于其他模型,充分证实了模型结构优化的有效性。与 YOLOv11n 相比,Faster R-CNN 的精确率虽然比其略高 1.3 个百分点,但是在平均精度、模型参数量以及 FPS 等方面全逊色于 YOLOv11n。同时 RE-DETR 的 $mAP_{0.5}$ 、 P 、 R 虽然也略高于 YOLOv11n,但是在模型参数上,Faster R-CNN 和 RTDETR 分别是 YOLOv11n 的 10.9 倍和 12.4 倍,分别是 PSMF-YOLO 的 6.0 倍和 6.8 倍。尽管提出模型参数量较基础模型增加 82.3%,但相比传统模型的千万级参数量,仍保持轻量化优势。从推理效率角度来看,不同模型在 FPS 指标上虽存在一定

差异，但当推理速度达到较高水平后，其在实际农业场景中的实时性差别已相对有限。相比之下，模型在复杂

背景下对小目标的检测精度与稳定性对实际应用效果具有更为直接的影响。



注：选用复杂场景图像对模型进行可视化。

Note: Images of complex scenes were selected for model visualization.

图 7 YOLO 系列模型检测结果的可视化

Fig.7 Visualization of YOLO series model detection the result

表 4 不同检测模型实验结果

Table 4 Experimental results of different detection models

模型 Model	mAP _{0.5} /%	P/%	R/%	F1 分数 F1 score/%	计算量 Float point Operations/ GFLOPs	参数量 Parameters /M	帧率 FPS/ f/s
SSD	55.5	55.0	51.1	53.0	30.45	23 745 908	263.84
Faster R-CNN	72.9	78.3	66.8	72.1	37.52	28 273 881	104.82
YOLOv11n	80.0	77.0	76.4	76.7	6.3	2 582 347	233.9
RT-DETR	80.7	77.3	77.9	77.6	103.4	31 985 795	78.9
PSMF-YOLO	84.9	79.3	80.6	80.0	15.6	4 708 380	189.4

图 8 展示了不同检测模型结果的可视化。图中 Faster R-CNN、SSD 和 RT-DETR 检测性能均低于 YOLOv11n 和 PSMF-YOLO。YOLOv11n 在图像上正确检测到了 74

个目标，漏检 7 个，误检到 5 个。而 PSMF-YOLO 在同一张图像上比 YOLOv11n 正确检测的目标多了 4 个，漏检的少了 4 个，误检的少了 2 个，表现出更优的小目标检测效果。

前文消融实验结果表明，引入 P2 小目标检测层、SPD-Conv 模块、MSDA 机制以及 Focaler-DIoU 损失函数后，提出模型相比于基线模型在 mAP_{0.5}、精确率和召回率等指标上均获得了显著提升；同时，YOLO 系列模型的对比实验结果进一步验证了 PSMF-YOLO 在检测精度上的整体优势。图 8 的可视化结果作为对上述性能提升在复杂果园场景中的具体表现进行了直观展示。由此可见，PSMF-YOLO 的检测性能优于改进前的 YOLOv11n。




图 8 不同检测模型结果的可视化

Fig.8 Visualization of the results of the different detection models

在农业场景中，硬件资源有限且需实时监测，PSMF-YOLO 通过精准的结构改进，在计算成本可控的前提下实现精度突破，为同类小目标检测任务提供了可复用的优化范式。

2.4 讨论

本研究提出的 PSMF-YOLO 模型在真实复杂场景下的枇杷花蕾发育阶段实时检测花蕾具有巨大潜力，能够识别低对比度的枇杷花蕾小目标，并展现出较高的稳定性。

消融试验表明，各模块增益存在差异：P2 小目标检测层对 mAP_{0.5} 的提升最为显著，较基线模型高 2.1 个百

分点，因其浅层高空间分辨率能有效保留小目标的纹理细节^[24]，增强了模型对小目标的敏感性；而 MSDA 引入后 mAP_{0.5} 小幅提升但 P 值略有下降，这可能与多尺度特征的权重分配失调有关^[25]。

从模型对比结果来看，PSMF-YOLO 的 mAP_{0.5} 优于主流轻量级模型，且在参数量与计算成本上仍保持轻量化优势。尽管 FPS 低于一些模型，但精度提升幅度远超速度损失，体现了精度与效率的协同优化。与两阶段模型 Faster R-CNN 相比，PSMF-YOLO 在 mAP_{0.5} 上领先 12.0 个百分点，参数量仅为 16.6%，这得益于单阶段检测框架的高效性与模块化改进的叠加效应^[26]。

尽管 PSMF-YOLO 模型表现优异,但在复杂应用场景中仍有待进一步突破。针对当前数据集局限于固定航高与空间分辨率的局限,未来拟开展多维度数据采集策略,系统构建涵盖不同飞行高度与多分辨率的影像数据集,以此量化空间分辨率变化对小目标特征提取能力的影响规律,同时更好地分析航高波动导致的尺度变异对检测精度的影响。面对模型对动态光照变化、天气变化及复杂果园背景噪声等非稳态环境泛化性不足的问题,未来研究可以构建环境泛化增强策略。同时,模型的检测准确率牺牲了模型的内存成本,未来的研究中,在保证检测精度的情况下进一步使模型拥有更加轻量化的架构。

依托 PSMF-YOLO 模型的高效能力,未来可将其部署于搭载相机的自主巡检无人机,结合边缘计算设备实现田间实时监测,动态获取花蕾分布密度与发育阶段的数据,为疏花疏蕾决策提供科学依据,同时也是为特色水果产业的可持续发展注入创新动能。

3 结 论

针对枇杷花蕾检测中目标尺度小、背景复杂的问题,本文提出了一种基于无人机遥感图像的目标检测模型 PSMF-YOLO,主要结论如下:

1) 消融试验结果表明,改进后的模型 PSMF-YOLO 相较于 YOLOv11n 模型,精确率、召回率和 mAP0.5 分别提高 2.3、4.2 和 4.9 个百分点。P-R 曲线的结果进一步表明,由于多维特征的有效保留与全局语义融合,PSMF-YOLO 对复杂背景下微小花蕾特征的捕捉能力更强、检测鲁棒性更优。

2) 在枇杷花蕾检测任务中,与 YOLO 系列及其他主流目标检测模型的对比实验结果表明,所提出的 PSMF-YOLO 模型精确率、召回率和 mAP0.5 分别达到 79.3%、80.6% 和 84.9%,相比 SSD、Faster R-CNN、RT-DETR、YOLOv3、YOLOv5、YOLOv8 和 YOLOv10 等网络模型,其精确率、召回率和 mAP0.5 分别提升 0.1~24.3、0.6~29.5 和 0.8~29.4 个百分点,在模型规模保持可控的前提下,实现了检测精度的提升,体现了较高精度与复杂度平衡的特性。

未来的工作将致力于把 PSMF-YOLO 模型推广到其他农作物及生态环境监测领域,以验证其在多场景、多目标检测中的普适性和实时性。同时,已计划进一步优化模型结构和算法细节,探索与前沿人工智能技术的深度融合,提升整体检测精度和模型的稳定性。

【参 考 文 献】

- [1] 万亮,杜晓月,陈硕博,等.基于无人机多源图谱融合的水稻稻穗表型监测[J].农业工程学报,2022,38(9): 162-170.
WAN Liang, DU Xiaoyue, CHEN Shuobo, et al. Rice panicle phenotyping using UAV-based multi-source spectral image data fusion[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(9): 162-170. (in Chinese with English abstract)
- [2] 晏琳,冀汶莉,邢琪琪.果园环境下改进 YOLOv8 的无人机图像多目标苹果识别[J].农业工程学报,2025,41(22): 183-193.
YAN Lin, JI Wenli, XING Qiqi. Multi-target apple recognition from UAV images under orchard environments using improved YOLOv8[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(22): 183-193. (in Chinese with English abstract)
- [3] 赵建国,安美林,赵学观,等.基于 WEED-YOLOv10 的玉米杂草检测方法对靶喷药系统设计[J].农业工程学报,2026,42(01): 48-57.
ZHAO Jianguo, AN Meilin, ZHAO Xueguan, et al. Design of target spraying control system based on detecting maize and weed using WEED-YOLOv10[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2026, 42(01): 48-57. (in Chinese with English abstract)
- [4] 范翔宇,李玥,魏霖静,等.面向收割机影像的轻量化 DeepLabV3+胡麻倒伏识别方法[J].农业工程学报,2025,41(18): 212-219.
FAN Xiangyu, LI Yue, WEI Linjing, et al. Detecting flax lodging from harvester images using lightweight DeepLabV3+[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(18): 212-219. (in Chinese with English abstract)
- [5] 陈柯屹,朱龙付,宋鹏,等.融合动态机制的改进型 Faster R-CNN 识别田间棉花顶芽[J].农业工程学报,2021,37(16): 161-168.
CHEN Keyi, ZHU Longfu, SONG Peng, et al. Recognition of cotton terminal bud in field using improved Faster R-CNN by integrating dynamic mechanism[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(16): 161-168. (in Chinese with English abstract)
- [6] YANG J, WANG F, PANG Y, et al. Research on Pavement Disease Detection Method Based on Improved Mask R-CNN[C]//2024 IEEE 2nd International Conference on Sensors, Electronics and Computer Engineering (ICSECE). Jinzhou, China: IEEE, 2024: 1670-1676.
- [7] 罗雨薇,霍冠英,成振.样本生成与 Swin Transformer-YOLO 网络结合的声呐图像目标检测[J].声学学报,2026,51(1): 201-215.
LUO Yuwei, HUO Guanying, CHENG Zhen. Sonar image target detection using sample generation and Swin Transformer-YOLO network[J/OL]. Acta Acustica, 2026, 51(1): 201-215. (in Chinese with English abstract)
- [8] 苏保玉,李忠,朱婷,等.K-means++算法优化及其在震前兆分析中的应用研究[J].智能计算机与应用,2021,11(5): 205-208.
SU Daiyu, LI Zhong, ZHU Ting, et al. Optimization of K-means++ algorithm and its application in the seismic-geomagnetic analysis[J]. Intelligent Computer and Applications,

- 2021, 11(5): 205-208. (in Chinese with English abstract)
- [9] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. *IEEE transactions on pattern analysis and machine intelligence*, 2016, 39(6): 1137-1149.
- [10] HE K, GKIOXARI G, DOLLAR P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. Venice, Italy: IEEE, 2017: 2961-2969.
- [11] 朱锐, 张家瑜, 黄继超, 等. 基于卷积神经网络的农作物叶片病害检测研究进展[J]. *农业工程学报*, 2025, 41(17): 15-28.
- ZHU Rui, ZHANG Jiayu, HUANG Jichao, et al. Research progress of crop leaf disease detection based on convolutional neural network[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(17): 15-28. (in Chinese with English abstract)
- [12] 马中杰, 罗晨, 骆巍, 等. 基于改进 YOLO v7-tiny 的玉米种质资源雄穗检测方法[J]. *农业机械学报*, 2024, 55(7): 290-297.
- MA Zhongjie, LUO Chen, LUO Wei, et al. Tassel detection method of maize germplasm resources based on improved YOLO v7-tiny[J]. *Transactions of the Chinese Society for Agricultural Machinery*, 2024, 55(7): 290-297. (in Chinese with English abstract)
- [13] 李川红, 付兴兰, 傅晗文, 等. 基于无人机影像的丘陵山地柑橘果实实时检测与计数[J]. *农业工程学报*, 2025, 41(17): 153-161.
- LI Chuanhong, FU Xinglan, FU Hanwen, et al. Real-time detecting and counting of citrus fruits in hilly and mountainous areas using UAV imagery[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(17): 153-161. (in Chinese with English abstract)
- [14] 宁姗, 陈海涛, 赵秋多, 等. 基于 IM-SSD+ACO 算法的整株大豆表型信息提取[J]. *农业机械学报*, 2021, 52(12): 182-190.
- NING Shan, CHEN Haitao, ZHAO Qiuduo, et al. Detection of pods and stems in soybean based on IM-SSD+ACO algorithm[J]. *Transactions of the Chinese Society for Agricultural Machinery*, 2021, 52(12): 182-190. (in Chinese with English abstract)
- [15] KHANAM R, HUSSAIN M. Yolov11: An overview of the key architectural enhancements[EB/OL]. (2024-10-23) [2026-05-11]. <https://arxiv.org/abs/2410.17725>.
- [16] 李成轩, 赵春江, 张驰, 等. 基于 AIC-YOLOv11n 模型的砀山梨多表面缺陷检测方法[J]. *农业工程学报*, 2025, 41(14): 320-328.
- LI Chengxuan, ZHAO Chunjiang, ZHANG Chi, et al. Multi-surface defect detection method for Dangshan pears based on AIC-YOLOv11n model[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(14): 320-328. (in Chinese with English abstract)
- [17] 曾昆峰, 张鹏超, 王磊, 等. 基于改进 YOLOv11n 的轻量化茶叶病虫害识别方法[J]. *农业工程学报*, 2025, 41(24): 220-229.
- ZENG Kunfeng, ZHANG Pengchao, WANG Lei, et al. Lightweight method for identifying tea pests and diseases based on an improved YOLOv11n[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(24): 220-229. (in Chinese with English abstract)
- [18] Culjak I, Abram D, Pribanic T, et al. A brief introduction to OpenCV[C]//2012 Proceedings of the 35th International Convention MIPRO. Opatija, Croatia: IEEE, 2012: 1725-1730.
- [19] SUNKARA R, LUO T. No more strided convolutions or pooling: A new CNN building block for low-resolution images and small objects[C]//Joint European Conference on Machine Learning and Knowledge Discovery in Databases. Cham: Springer Nature Switzerland, 2022: 443-459.
- [20] JIAO J, TANG Y M, LIN K Y, et al. Dilateformer: Multi-scale dilated transformer for visual recognition[J]. *IEEE Transactions on Multimedia*, 2023, 25: 8906-8919.
- [21] ZHENG Z, WANG P, REN D, et al. Enhancing geometric factors in model learning and inference for object detection and instance segmentation[J]. *IEEE transactions on cybernetics*, 2021, 52(8): 8574-8586.
- [22] ZHANG H, ZHANG S. Focaler-iou: More focused intersection over union loss[EB/OL]. (2024-01-19) [2026-05-11]. <https://arxiv.org/abs/2401.10525>.
- [23] ZHENG Z, WANG P, LIU W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]//Proceedings of the AAAI Conference on Artificial Intelligence. New York, USA: AAAI Press, 2020: 12993-13000.
- [24] 江凯伦, 杨扬, 黄文江, 等. 基于 CSE-YOLOXs 的复杂田间环境油菜与杂草实时检测[J]. *农业工程学报*, 2025, 41(13): 195-206.
- JIANG Kailun, YANG Yang, HUANG Wenjiang, et al. Real-time detecting rapeseed and weed in field environments using CES-YOLOXs model[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(13): 195-206. (in Chinese with English abstract)
- [25] 刘玉珍, 刘美怡, 林森, 等. 多尺度特征融合注意力网络的水下图像增强[J]. *计算机辅助设计与图形学学报*, 2023, 35(5): 685-695.
- LIU Yuzhen, LIU Meiyi, LIN Sen, et al. Underwater Image Enhancement Based on Multi-Scale Feature Fusion and Attention Network[J]. *Journal of Computer-Aided Design & Computer Graphics*, 2023, 35(5): 685-695. (in Chinese with English abstract)
- [26] 于乃功, 李奥, 杨弈. 基于 Depth-YOLO 的半导体键合引线缺陷检测算法[J]. *工程科学学报*, 2025, 47(11): 2281-2295.

YU Naigong, LI Ao, YANG Yi. Depth-YOLO-based defect detection algorithm for semiconductor bonding leads[J].

Journal of Engineering Science, 2025, 47(11): 2281-2295. (in Chinese with English abstract)

A small object detection method for loquat flower buds in UAV remote sensing imagery based on PSMF-YOLO

XU Changsu, LIU Xinzhi, ZHU Yulin, CHEN Chen, FENG Liuyan, LI Yunwu^{*}

(College of Engineering and Technology, Southwest University, Chongqing 400715)

Abstract: Loquat flower buds are typically observed to develop in dense and clustered distributions during their natural growth cycle. To ensure optimal nutrient allocation, prevent fruit size disparities, and guarantee the final commercial quality of the fruits, timely and precise thinning operations during the early bud stage are fundamentally required. However, accurate identification and spatial localization of these targets remain significantly challenging in practical agricultural scenarios. This difficulty primarily stems from the inherently small volumetric size of the buds, their clustered growth patterns, and their severe visual similarity in color to the complex surrounding background foliage. To comprehensively address these critical issues and facilitate automated agricultural operations, this study proposes a novel target detection algorithm, termed PSMF-YOLO, which integrates unmanned aerial vehicle (UAV) remote sensing imagery with advanced deep learning techniques. Initially, a specialized loquat flower bud dataset was constructed using high-resolution images acquired by UAVs operating in real-world orchard environments. Building upon this empirical data, an improved detection model was developed using the YOLOv11n architecture as the baseline to effectively balance computational efficiency and detection accuracy. To systematically optimize the network for these microscopic targets, several crucial structural modifications were sequentially implemented. First, a dedicated P2 small-object detection layer was introduced into the architecture. This layer leverages shallower network layers to preserve high-resolution spatial details, thereby fundamentally enhancing the model's intrinsic capability to accurately detect minute and densely packed targets. Second, an advanced Space-to-Depth Convolution (SPD-Conv) module was incorporated into the feature extraction network. By retaining detailed information during the space-to-depth transformation and avoiding the redundant information loss typically caused by traditional stride convolutions, this module significantly improves detection accuracy, particularly for low-resolution images and small objects. Third, the C2PSA module was combined with a multi-scale dilated attention (MSDA) mechanism. This integration achieves comprehensive cross-level perception through multi-scale dilated convolutions and dynamic feature fusion strategies, enabling the network to establish a more effective global context modeling capability. Finally, a Focaler-DIoU bounding box regression loss function was employed. This targeted loss function effectively alleviates the inherent sample imbalance commonly encountered in small-object detection tasks and improves the precise localization of bounding box regression, thereby substantially enhancing the overall robustness of the model when deployed under highly complex orchard conditions. Comprehensive experimental results demonstrate the superior performance of the proposed PSMF-YOLO model. Specifically, the enhanced model achieves remarkable improvements of 4.9, 2.3, and 4.2 percentage points in mean average precision ($mAP_{0.5}$), precision (P), and recall (R) metrics, respectively, when directly compared with the baseline YOLOv11n model. Furthermore, when evaluated against various mainstream object detection frameworks, the PSMF-YOLO model outperforms the best-performing alternative baseline, the YOLOv5s model, by margins of 0.8, 0.1, and 0.6 percentage points across the aforementioned core evaluation metrics. In conclusion, these quantitative results clearly indicate that the proposed PSMF-YOLO method provides a highly effective and accurate algorithmic solution for UAV-based small-target detection tasks in agricultural remote sensing. Consequently, this study offers robust technical support for the broader implementation of intelligent and precise orchard management systems.

Keywords: loquat; bud; unmanned aerial vehicle; deep learning; target detection; PSMF-YOLO