

基于改进 YOLOv10n 的复杂田间小麦幼苗检测和计数方法

李慎可¹, 朱俊科^{1,2,3*}, 黄傲群¹, 唐志成¹, 杨 宁²,
杜常亮², 朱雨昕⁵, 兰玉彬^{1,3,4*}

(1. 山东理工大学农业工程与食品科学学院, 淄博 255000; 2. 齐鲁师范学院生命科学学院, 济南 250200;
3. 山东理工大学生态无人农场研究院, 淄博 255000; 4. 山东省农业航空智能装备工程技术研究中心, 淄博 255000;
5. 山东农业大学农学院, 泰安 271000)

摘 要: 为实现田间复杂环境下小麦幼苗的精确识别, 该研究提出一种基于 YOLOv10n 的改进算法 DSM-YOLOv10 (dualconv-sdi-msda YOLOv10)。首先, 引入双卷积结构 (dual convolution, DualConv) 构建 DCC2f 模块, 替代原骨干网络中的 C2f 结构, 以减少冗余计算并增强特征融合能力; 其次, 针对小麦幼苗分布密集、相互遮挡等检测难点, 采用语义细节融合模块 (semantics and detail infusion, SDI) 替换 Concat 操作, 实现语义指导下的细节增强, 以提升模型对小麦幼苗重叠区域特征的解耦与复用能力; 最后, 引入多尺度空洞注意力机制 (multi-scale dilated attention, MSDA) 强化多尺度特征表达, 以提升模型对小麦幼苗交叉重叠的理解能力。试验结果表明, DSM-YOLOv10 算法能够针对多种复杂场景下的小麦幼苗实现精准检测, 平均精度均值、精确率、召回率和 F1 分数分别达到 91.4%、85.2%、81.7% 和 83.4%, 较原 YOLOv10n 模型分别提高 5.0、2.6、5.4 和 4.1 个百分点, 模型参数数量和浮点运算量分别减少 4.7% 和 10.7%, 推理时间降至 13.2 ms。在幼苗计数任务中, 模型检测结果与实测数据相比, 决定系数、均方根误差和平均绝对误差分别为 0.92、5.68 株和 4.33 株, 性能均优于 YOLOv10n 等主流模型。本研究有效提升了复杂场景下小麦幼苗的检测与计数能力, 为农业实践中的田间数据获取提供了有力支撑。

关键词: YOLOv10n; 目标检测; 小麦幼苗; 双卷积; 语义细节融合; 多尺度空洞注意力机制

doi: 10.11975/j.issn.1002-6819.202511204

中图分类号: TP391.41; S24

文献标志码: A

文章编号: 1002-6819(2026)-14-0263-10

李慎可, 朱俊科, 黄傲群, 等. 基于改进 YOLOv10n 的复杂田间小麦幼苗检测和计数方法[J]. 农业工程学报, 2026, 42(14): 263-272. doi: 10.11975/j.issn.1002-6819.202511204 <http://www.tcsae.org>

Li Shenke, Zhu Junke, Huang Aoqun, et al. Detecting and counting wheat seedlings under complex field conditions using improved YOLOv10n[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2026, 42(14): 263-272. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202511204 <http://www.tcsae.org>

0 引 言

小麦作为世界三大作物之一, 在全球粮食供应与安全保障中发挥着关键作用^[1]。小麦苗期的出苗数量和生长状态直接关系到分蘖能力、光合效率及最终产量, 是农业管理中需进行精准监测的关键阶段^[2-3]。此外, 在小麦育种过程中, 出苗数量是计算出苗率的重要指标, 更是用作衡量种子活力、土壤环境、播种技术、施肥方法以及产量预测的重要依据^[4]。因此, 对小麦幼苗的检测和计数尤为重要。

传统检测方法依赖人工田间调查, 存在效率低、主观性强、难以规模化等弊端^[5]。随着人工智能技术的快

速发展, 基于深度学习的目标检测算法在农业领域展现出显著优势^[6-7]。以深度卷积神经网络 (convolutional neural network, CNN) 为核心的目标检测模型能够通过端到端学习自主捕获多层次特征, 大幅提升了复杂农田场景下的检测精度与鲁棒性^[8-9], 已在作物果实识别^[10]、病虫害检测^[11]、杂草检测^[12] 等方面取得良好效果。用于目标检测的卷积神经网络算法主要包括以 Faster-RCNN 为代表的双阶段检测算法和以 YOLO 系列为代表的单阶段检测算法^[13]。前者通过区域建议网络 (regional proposal network, RPN) 在特征图上筛选可能包含目标的候选区域, 再对这些候选区域进行精确处理, 输出每个目标的最终类别和边界框^[14]。这种算法在检测精度上表现出色, 但计算复杂度相对较高, 推理速度较慢^[15]。后者可以直接在特征图的每个预设位置上预测目标类别和边界框, 实时检测能力和较低的计算资源需求使其成为当前农业实践应用中的主流选择^[16-17]。近年来, 针对小麦幼苗检测已有众多研究, 例如, Liu 等^[18] 提出一种改进的 ConvNeXt 网络, 采用预训练微调模型解决迁移学习中的过拟合问题, 有效提升了小麦幼苗识别分类精度, 但试验采取破坏性采样, 对复杂大田环境不适用。Dong 等^[19] 针对田间复杂光照条件提出 DHS-YOLO 深度

收稿日期: 2025-11-26 修订日期: 2026-01-18

基金项目: 国家重点研发计划项目 (2023YFD2000200); 山东省重点研发计划 (农业良种工程) 项目 (2022 LZGCQY002)

作者简介: 李慎可, 研究方向为精准农业航空技术与装备。

Email: lishenke2023@163.com

*通信作者: 朱俊科, 正高级农艺师, 教授, 研究方向为小麦智慧育种。

Email: zhujunke@126.com; 兰玉彬, 博士, 教授, 博士生导师, 研究方向

为精准农业航空应用技术, 现代农业装备等。

Email: ylan@sdu.edu.cn

学习框架,采用可变形卷积技术捕捉小麦形态特征,并整合动态范围空间注意力,抑制光照引起的图像劣化,对不同光照条件下小麦幼苗影像的检测精确率达到 94.1%。Ma 等^[20-21]通过获取小麦幼苗根茎部特征实现检测计数,前者利用简化的 MobileNetv3 网络替代 CSPDarkne53 特征提取网络,并通过 coyote 优化算法调整网络学习率和卷积核尺寸,提出的改进 YOLOv4 模型检测平均精度均值为 95.15%;后者使用外设的激光设备标记小麦幼苗根茎部并采集图像数据,利用两阶段卷积神经网络进行幼苗和激光点分割,通过统计激光点数量实现计数。侯依廷等^[22-23]采用叶尖标注方法,通过对 YOLOv8 模型添加不同注意力机制和损失函数实现对小麦叶片数的检测,平均精度均值分别达到 85.1% 和 82.9%。Wang 等^[24]提出了一种基于局部标注的小麦幼苗检测方法,利用空间深度卷积和微尺度检测层改进 YOLOv5,有效提升了对小尺寸标注框的特征提取能力,实现了 90.1% 的检测精确率。

上述研究多通过局部特征实现对小麦幼苗的检测,存在一定的局限性,如幼苗重叠导致局部信息丢失,增加错检、漏检风险^[25]。小麦幼苗检测任务的核心难点在于:幼苗叶片尺寸微小且形态相似,易于混淆与漏检;农田环境背景复杂,光照变化、阴影遮挡及植株重叠导致特征提取困难^[26-27];实时监测需求对模型参数与计算复杂度提出更高要求。针对上述问题,本研究提出一种基于 YOLOv10n 的冬小麦幼苗检测方法。在数据标记阶段采取整体标注而非仅限于局部特征信息,以提高网络算法对小麦幼苗整体特征的学习与提取能力,避免因重叠遮挡导致的特征丢失问题,通过构建 DCC2f 模块减少冗余计算并增强特征融合能力,采用 SDI (semantics and detail infusion) 模块提升语义与空间细节的提取能力,引入 MSDA (multi-scale dilated attention) 模块强化多尺度特征表达能力。多个模块协同优化,以解决复杂农田环境下的幼苗目标漏检与错检问题,为冬小麦幼苗的精准检测提供高效可靠的技术手段。

1 材料与方法

1.1 图像数据采集

冬小麦试验田位于山东省淄博市山东理工大学生态无人农场 (36°57'20"N, 118°13'0"E),该地区属暖温带大陆性季风气候,光热充足,年平均气温约 13.2℃,年平均降水量约 650~800 mm,主要种植冬小麦和夏玉米等北方作物。小麦幼苗图像采集时间为 2024 年 10 月 24 日,距离播种日期约 13 d,此时田间已经齐苗,是调查出苗情况的最佳时期。使用 DJI MAVIC 3M 无人机搭载可见光相机进行图像采集,飞行高度设为 0.8 m,云台倾斜 45°拍摄,获取小麦整体特征图像。

1.2 数据预处理

使用无人机拍摄的图像分辨率为 5 280×3 956 像素,综合考虑硬件条件和试验参数的需要,利用 Python 语言编写的随机裁剪代码将原始图像裁剪为 640×640 像素。对裁剪的图像手动筛选,剔除质量差的图像,最终共选取 1 760 张图片作为初始数据集,并利用 LabelImg 软件

对小麦幼苗图像进行边界框标注。

将图像数据按照 8:1:1 的比例划分为训练集、验证集和测试集。另外,为增强数据集的多样性,提高模型泛化能力,本研究采取了多种方式对数据进行增强,包括:(1)缩放,缩放范围为 70%~100%;(2)旋转,逆时针旋转 90°;(3)翻转,水平翻转 180°;(4)添加高斯噪声,方差范围为 10.0~50.0;(5)调整亮度,调整幅度为±15%;(6)添加阴影,阴影数量为 1~3 个。迫使模型学习不同尺度、角度和质量下的目标特征,避免数据过拟合。数据增强效果如图 1 所示。最终,通过上述增强方法将图像样本扩展到 12 320 张,共 166 558 个小麦幼苗标注信息,其中小目标(占图像总面积 1% 以下)占比约 35%,中等目标(占图像总面积 1%~5%)占比约 57%。形成的最终数据集如表 1 所示。




图 1 数据增强

Fig.1 Data augmentation

表 1 数据集划分

Table 1 Partitioning of the dataset

数据集 Dataset	图像高度 Image height/像素	图像宽度 Image width/像素	图像数量 Number of images/张	标注数量 Number of labels/个
训练集 Training set	640	640	9 856	126 098
验证集 Validation set	640	640	1 232	20 650
测试集 Test set	640	640	1 232	19 810
总计 Total	-	-	12 320	166 558

2 模型改进与训练

2.1 YOLOv10 网络模型

YOLOv10 是一种实时端对端的单阶段目标检测算法,通过双重标签分配策略消除对非极大值抑制 (non-maximum suppression, NMS) 的后处理依赖,大幅降低了推理延迟^[28-29]。模型架构引入空间-通道解耦下采样 (spatial-channel decoupled downsampling, SCDown) 模块,有效减少了特征图尺寸变换过程中的信息丢失。同时,在主干网络中融合了大核卷积和部分自注意力 (partial self-attention, PSA) 模块,在保证计算效率的前提下,显著增强了模型的感受野与特征表达能力^[30]。YOLOv10 包括多个版本以满足不同的计算要求,考虑到

算法的参数量和计算量,以及后续部署在终端的可能性,本研究选用 YOLOv10n 作为基线模型,针对小麦幼苗的检测难点对模型进行改进优化。

2.2 改进的小麦幼苗检测模型

基于 YOLOv10n 模型,本研究提出了 DSM-YOLOv10 小麦幼苗检测模型,总体结构如图 2 所示。具体改进如下:


1) 在骨干网络中用 DCC2f 替换传统 C2f,通过双卷积结构减少特征冗余,提高计算效率,便于后续在移动边缘设备上的实时部署,同时增强网络梯度流,为后续处理提供高效和清晰的基础特征。

2) 在骨干网络与颈部网络之间引入 3 个步长与卷积核尺寸均为 1 的 CBS 模块用来存储骨干网络的特征信

息,既能聚合分辨率高但语义信息弱的浅层特征图,也能整合分辨率低但语义信息丰富的深层特征图。并将这些特征信息作为后续 SDI 模块的输入,SDI 模块通过跨层级的注意力引导与哈达玛积操作,将高层语义信息显式注入底层细节特征,实现语义指导下的细节增强,提升模型对小麦幼苗重叠区域特征的解耦与复用能力。

3) 从骨干网络早期(第二层)抽取浅层特征,经过下采样后,引入一条额外的特征融合路径,以增强模型针对细小幼苗的检测性能。

4) 采用 MSDA 注意力机制模块,通过引入多尺度膨胀率,并行捕获局部细节与上下文信息,进一步提升模型对小麦幼苗交叉重叠的理解能力。



注: CBS 为卷积层+批归一化层+SiLU 激活函数, C2f 为跨阶段部分特征融合模块, DCC2f 为融合双卷积 DualConv 的 C2f 模块, SCDwn 为下采样模块, SPPF 为空间金字塔池化层, PSA 为局部自注意力模块, Upsample 为上采样层, Concat 为特征拼接模块, SDI 为语义细节融合模块, CIB 为紧凑倒置块, C2fCIB 为融合了紧凑倒置块 CIB 的 C2f 模块, MSDA 为多尺度空洞注意力机制, Detect 为检测头, Conv 为卷积层, BN 为批归一化层, CB 为卷积层+批归一化层, MaxPool 为最大池化, Split 为特征通道拆分, Add 为特征相加, MHSA 为多头自注意力机制, FFN 为前馈网络, Bottleneck 为包含残差连接的卷积模块。下同。

Note: CBS is composed of the convolutional layer, batch normalization layer, and SiLU (sigmoid linear unit) activation function, C2f is the cross-stage partial feature fusion module, DCC2f is the C2f module that integrates the dual convolution, SCDwn is the spatial-channel decoupled downsampling module, SPPF is the spatial pyramid pooling fast layer, PSA is the partial self-attention module, Upsample is the upsampling layer, Concat is the feature concatenation module, SDI is the semantics and detail infusion module, CIB is the compact inverted block, C2fCIB is the C2f module that integrates the compact inverted block, MSDA is the multi-scale dilated attention, Detect is the detection head, Conv is the convolutional layer, BN is the batch normalization layer, CB is composed of the convolutional layer, and batch normalization layer, MaxPool is the max pooling layer, Split is the feature channel splitting operation, Add is the feature addition operation, MHSA is the multi-head self-attention, FFN is the feed-forward network, Bottleneck is the convolutional block that includes a residual connection. The same below.

图 2 DSM-YOLOv10 模型结构图

Fig.2 DSM-YOLOv10 (dualconv-sdi-msda YOLOv10) model structure diagram

2.2.1 DCC2f 模块


C2f 模块通过多分支、全连接结构提升了梯度流和特征融合能力,从而增强了模型的表征能力和检测精度。然而,多个 Bottleneck 的堆叠以及将所有中间特征图进行 Concat 操作,不可避免地增加了计算复杂度和内存访问开

销,还造成大量的信息冗余^[31]。为了解决这些问题,本文引入 DualConv^[32] (dual convolution) 对 C2f 结构进行优化。

DualConv 是一种结合分组卷积与异构卷积优势的双重卷积方法,包括 3×3 和 1×1 两种卷积核,操作时一部分对输入特征图同时执行 3×3 分组卷积和 1×1 逐点卷积,

另一部分则仅进行 1×1 逐点卷积。分组卷积捕捉空间局部特征，逐点卷积连续在所有输入通道上执行，能够保留原始信息，实现最大程度的跨通道特征融合。不仅解决了分组卷积通信不畅的问题，相比异构卷积还提升了

网络性能。并通过将输入特征图通道和卷积核数量划分为组，每组卷积核仅作用于对应的输入通道，减少了原始骨干网络的参数量，从而降低计算成本。DualConv 模块具体结构如图 3 所示。



注：M 为输入通道数，N 为卷积滤波器数量， 3×3 和 1×1 为卷积核尺寸，G 为分组数量。

Note: M is the number of input channels, N is the number of convolutional filters, 3×3 and 1×1 are the convolutional kernel sizes, and G is the number of groups.

图 3 DualConv 模块结构图

Fig.3 DualConv (dual convolution) module structure diagram


在 C2f 的基础上引入 DualConv 并进行相关优化，得到 DCC2f 模块，如图 4 所示。利用双卷积结构改进的 DCBottleneck 替代原 Bottleneck 模块，通过并行部署分组卷积与逐点卷积，结合残差连接技术，既能缓解深层训练的梯度消失问题，完整传递跨层特征，又能最大限度减少冗余卷积操作，提高计算效率。

特征的语义信息注入低级特征，并通过元素级哈达玛积从高级特征中提取更丰富的细节。

SDI 模块的具体结构如图 5 所示。根据编码器输出的分层特征图，首先对各层级 i 的初始特征 f_i^0 同时应用空间注意力和通道注意力机制，以融合局部空间信息和全局通道信息。具体计算式为

$$f_i^1 = \phi_i^c(\phi_i^s(f_i^0)) \quad (1)$$

式中 f_i^1 代表第 i 层经处理后的特征图， ϕ_i^s 和 ϕ_i^c 分别代表第 i 层级的空间注意力与通道注意力参数。



注：DCBottleneck 为融合了双卷积 DualConv 的 Bottleneck 模块，shortcut 为残差连接，n 为 DCBottleneck 模块的堆叠数量。


Note: DCBottleneck is the Bottleneck block that integrates the dual convolution, shortcut is the residual connection, n is the number of stacked DCBottleneck blocks.

图 4 DCC2f 模块结构图

Fig.4 DCC2f module structure diagram

2.2.2 SDI 模块

原 YOLOv10n 颈部采用路径聚合网络 (path aggregation network, PANet) 实现双向跨尺度连接融合特征，但面对像素级目标时仍存在根本性局限：深层特征的空间分辨率衰减导致目标位置信息耗散，而堆叠式融合机制难以建立跨层级的语义与细节协同优化，致使关键特征复用率很低。针对模型在幼苗细小、密集、重叠等情况检测中的性能瓶颈，本研究引入语义细节融合模块 SDI^[33] 以重构其颈部网络。SDI 模块的核心在于将高级



注：l 代表特征层级。

Note: l represents the feature level.

图 5 SDI 模块结构图

Fig.5 SDI (semantics and detail infusion) module structure diagram

其次，使用 1×1 卷积将 f_i^1 的通道数缩减至超参数 c ，经此处理得到特征图 f_i^2 ， $f_i^2 \in R^{H_i \times W_i \times c}$ ，其中 H_i 、 W_i 和 c 分别代表 f_i^2 的高度、宽度与通道数。

将优化后的特征图输入解码器，在解码器的每一层级 i ，将 f_i^2 作为目标参考特征，调整每一层级 j 的特征尺寸，使其分辨率与 f_i^2 保持一致，调整后的特征图 f_{ij}^3 为

$$f_{ij}^3 = \begin{cases} D(f_j^2, (H_i, W_i)), & j < i \\ I(f_j^2), & j = i \\ U(f_j^2, (H_i, W_i)), & j > i \end{cases} \quad (2)$$

式中 D 、 I 和 U 分别代表自适应平均池化、恒等映射和双线性插值。

再对每个调整后的特征图 f_{ij}^3 应用 3×3 卷积进行平滑处理，计算式为

$$f_{ij}^4 = \theta_{ij}(f_{ij}^3) \quad (3)$$

式中 θ_{ij} 代表平滑卷积的参数， f_{ij}^4 代表第 i 层的第 j 个平滑后特征图。

将所有第 i 层特征图调整至相同分辨率后，对其执行逐元素哈达玛积运算，输出特征图 f_i^5 为


$$f_i^5 = H([f_{i1}^4, f_{i2}^4, \dots, f_{iM}^4]) \quad (4)$$

式中 $H(\cdot)$ 代表哈达玛积， M 代表特征图的总层数。

随后，将 f_i^5 送入第 i 层解码器，进行进一步的分辨率重建与分割操作。该处理可增强目标层级特征的表达能力，使其同时兼具更丰富的语义信息与更精细的空间细节信息。通过此模块可针对幼苗细小、密集、重叠等情况，获取更多特征信息，提高检测精度。

2.2.3 MSDA 模块

MSDA^[34] 模块是一种面向视觉任务的注意力机制创新设计，其核心目标是通过多尺度膨胀策略优化计算效率与特征表达能力。具体结构如图 6 所示。



注：Q、K、V 分别代表查询矩阵、键矩阵和值矩阵，Heads 代表注意力头，Linear 代表线性层， r 代表膨胀率。使用 3×3 的卷积核尺寸，膨胀率 r 取值为 1、2 和 3，各头的注意力感受野尺寸分别为 3×3 、 5×5 和 7×7 。
Note: Q, K and V represent the query, key and value matrices, respectively. Heads represents attention heads, Linear represents the linear layer, and r represents the dilation rate. This study adopts a 3×3 kernel size with dilation rates r set to 1, 2 and 3, and the sizes of the attended receptive fields in different heads are 3×3 , 5×5 and 7×7 .

图 6 MSDA 模块结构图

Fig.6 MSDA (multi-scale dilated attention) module structure diagram

针对输入特征图，通过线性投影获取对应矩阵 Q 、 K 和 V 值，随后将特征图的通道划分为多个不同的注意力头，对其采用不同的膨胀率执行多尺度滑动窗口空洞注意力 (sliding window dilated attention, SWDA) 操作，该操作以查询块为中心，在其周围窗口内稀疏选择键和值，进而对这些代表性块进行自注意力运算。通过多注意力头并行计算不同尺度的局部依赖关系，从而在单层内实现多尺度语义特征的协同学习。随后，将各头的特征进行拼接，输入线性层完成特征聚合。MSDA 模块的计算式为

$$h_i = \text{SWDA}(Q_i, K_i, V_i, r_i), \quad 1 \leq i \leq n \quad (5)$$

$$X = \text{Linear}(\text{Concat}[h_1, \dots, h_n]) \quad (6)$$

式中 r_i 代表第 i 个注意力头的膨胀率， Q_i 、 K_i 和 V_i 代表第 i 个注意力头的输入特征图切片， h_i 代表第 i 个注意力头的输出特征图， X 代表经拼接和线性聚合后的特征图。

相较于传统全局注意力，MSDA 通过为不同注意力头设置不同膨胀率，能够在注意力感受野内有效聚合多尺度语义信息，增强网络对局部细节与上下文信息的融合能力，且无需复杂操作与额外计算成本，即可高效降低自注意力机制的冗余性，为小麦幼苗检测任务在复杂场景下的高效特征学习提供了新的技术路径。

2.3 试验设置与评价指标

2.3.1 试验环境配置

本研究采用 64 位 Windows 10 操作系统，CPU 为 AMD EPYC 7 713 64 核处理器，GPU 为 NVIDIA GeForce RTX 3 090 24 GB，深度学习框架使用 PyTorch 搭建，CUDA 版本为 12.1，PyTorch 版本为 2.0.1，Python 版本为 3.9。训练参数如下：输入图像大小为 640×640 像素，训练批次大小为 32，训练轮数为 100，初始学习率为 0.01。

2.3.2 评价指标

为了全面评估小麦幼苗检测模型的性能，采用精确率 (precision, P)、召回率 (recall, R)、平均精度均值 (mean average precision, mAP)、F1 分数 (F1 score)、浮点运算量 (floating point operations, FLOPs) 和参数量 (parameters) 作为评价指标。另外，本文采用决定系数 (coefficient of determination, R^2)、均方根误差 (root mean square error, RMSE) 和平均绝对误差 (mean absolute error, MAE) 作为模型计数性能的评价指标。

3 结果与分析

3.1 消融试验

为评估提出的各项改进对模型性能的影响，本文在保持训练条件和超参数一致的情况下进行消融试验，具体结果如表 2 所示，以 YOLOv10n 作为基线模型进行对比验证。

表 2 消融试验结果

Table 2 Results of ablation experiment

DCC2fSDIMSDA	Precision	Recall	平均精度		F1 分数	浮点运算量	参数量
			均值	精度		FLOPs/	Parameters/
	P/%	R/%	Mean average precision	F1 score/%		G	M
-	-	-	82.6	76.3	86.4	8.4	2.76
√	-	-	82.9	77.7	87.9	6.9	2.58
-	√	-	83.4	78.6	89.8	9.1	2.90
-	-	√	83.1	78.1	88.2	8.0	2.66
√	√	-	84.5	81.2	90.3	7.8	2.70
√	-	√	83.8	79.5	89.7	6.5	2.49
-	√	√	84.2	80.3	90.1	8.3	2.81
√	√	√	85.2	81.7	91.4	7.5	2.63

注：“-”表示未使用该改进项，“√”表示使用该改进项。

Note: “-” denotes that the corresponding improvement is not applied, while “√” denotes that the corresponding improvement is applied.

由表 2 可知，YOLOv10n 主干的 C2f 模块替换为 DCC2f 模块后，提高了模型的性能。DCC2f 通过并行部署分组卷积与逐点卷积，结合残差连接技术，最大限度减少冗余卷积操作，提高特征融合能力和计算效率。此

改进使模型的参数量和浮点运算量分别减少 6.5% 和 17.9%，平均精度均值和 F1 分数分别提高 1.5 和 0.9 个百分点。加入 SDI 并替换原有 Concat 后，模型能够获取更详细的语义信息和空间细节，精确的检测到复杂场景下的目标。平均精度均值和 F1 分数分别提升 3.4 和 1.6 个百分点。MSDA 的多尺度注意力机制能进一步提升网络的特征提取能力，加入后使模型的平均精度均值和 F1 分数分别提升 1.8 和 1.2 个百分点。当任意两个改进点同时引入时，模型的整体性能仍明显优于基线模型，证明了各项改进的有效性。3 项改进同时引入时，模型性能达到最佳，平均精度均值、精确率、召回率和 F1 分数分别达到了 91.4%、85.2%、81.7% 和 83.4%。相较于基线模型，这些指标分别提升了 5.0、2.6、5.4 和 4.1 个百分点。参数量和浮点运算量分别减少 4.7% 和 10.7%。结果表明 3 个改进模块协同作用，使本文的改进算法在降低复杂度的同时提升了检测精度，可以有效完成小麦幼苗检测任务。

为了更加直观的呈现各改进模块与基线模型的特征响应差异，本研究以热力图的形式进行可视化分析。结果如图 7 所示，基线模型 YOLOv10n 对幼苗特征的关注度欠佳，通过引入 DCC2f、SDI、MSDA 模块后，关注度有了不同程度的提高。整合 3 个模块的 DSM-YOLOv10 模型对幼苗的特征响应强度最高、覆盖最完整，表明多

模块协同增强了模型对目标的特征提取与定位能力。




图 7 不同改进模块的可视化热力图
Fig.7 Visualization heatmaps of different improved modules

3.2 对比试验

为了评估改进后的网络模型效果，本研究将其与 RetinaNet、Faster-RCNN、SSD、YOLOv8n、YOLOv10n 等当前主流目标检测算法在同一数据集上进行对比试验，结果如表 3 所示。

表 3 不同模型检测性能对比
Table 3 Comparison of detection performance of different models

模型 Model	P/%	R/%	mAP/%	F1/%	FLOPs/G	参数量 Parameters/M	推理时间 Inference time/ms
RetinaNet	54.2	51.0	55.6	52.6	54.7	20.80	27.4
Faster-RCNN	62.3	68.1	66.9	65.1	185.1	68.55	72.1
SSD	68.6	57.3	60.7	62.4	62.8	26.29	31.8
YOLOv8n	79.2	68.5	82.8	73.5	8.1	3.10	15.3
YOLOv10n	82.6	76.3	86.4	79.3	8.4	2.76	15.6
DSM-YOLOv10	85.2	81.7	91.4	83.4	7.5	2.63	13.2

表 3 数据显示，改进后的算法在精确率、召回率、平均精度均值、F1 分数以及模型参数和浮点运算量等方面均优于其他模型。平均精度均值相较于 RetinaNet、Faster-RCNN、SSD 和 YOLOv8n 分别提高 35.8、24.5、30.7 和 8.6 个百分点；参数量分别降低 87.4%、96.2%、90.0% 和 15.2%；浮点运算量分别降低 86.3%、96.0%、88.1% 和 7.4%。相较于 YOLOv10n 算法，精确率、召回率、平均精度均值、F1 分数分别增长 2.6、5.4、5.0 和 4.1 个百分点，模型参数量和浮点运算量分别降低 4.7% 和 10.7%，推理时间降至 13.2 ms，检测速度约 76 帧/s，具有实时性，表现出最佳综合性能。图 8 展示了各算法对小麦幼苗检测的效果对比，其中 RetinaNet 和 SSD 漏检与错检情况最为严重，YOLOv8n 和 YOLOv10n 漏检情况较少，但对复杂特征的辨别能力仍较差。综合各指标和检测效果，DSM-YOLOv10 算法能实现对尺寸较小或被部分遮挡幼苗的精准检测，展现出高效性能与鲁棒性。

3.3 复杂场景检测性能


农田情况复杂，土壤背景、环境光照以及幼苗密度都会对检测造成影响，为了进一步评估 DSM-YOLOv10 在各种复杂场景下的检测性能，本研究分别选取阴天

（图像平均像素强度小于 112）、幼苗密集重叠（平均密度 300 株/m² 以上）以及幼苗生长杂乱（目标尺寸变异系数 70% 以上）三种情况下采集的图像进行检测试验，以 YOLOv10n 作为对比模型进行可视化分析。如图 9 所示。在阴天环境下因为光线不足导致噪点增多，图片质量随之下降，幼苗密集重叠会使局部特征丢失，分布杂乱会导致目标大小不一、形态多样，这些均对模型的学习和推理能力提出更高的要求。YOLOv10n 在检测过程中存在一定程度的漏检、单个目标错检为多个目标以及多个目标错检为单个目标的情况。相比之下，DSM-YOLOv10 凭借 SDI 模块对细节特征和边缘信息的提取能力以及 MSDA 多尺度特征融合机制协同工作，实现多种场景下的精准检测，有效降低了漏检和错检率，充分彰显其在复杂农业环境中的优越性能。

3.4 小目标检测效果

为了进一步评估改进型模型在实际应用过程中对于小麦幼苗小目标的检测性能，本研究选取了 350 张小目标占比 90% 以上的图像进行了补充试验。试验结果如表 4 和图 10 所示，YOLOv10n 在识别小型目标时表现欠佳，特别是在幼苗重叠场景中，存在较多的漏检和错检。而 DSM-YOLOv10 模型则展现出优异的小目标检测能力，

平均精度均值达到 86.3%，漏检率和错检率均保持在较低水平，分别为 9.1% 和 3.8%。上述结果表明，DSM-YOLOv10 模型对小麦幼苗目标具有更强的特征提取能力，能够满足农业实际应用的需求。



注：红色边框代表模型的检测结果，黄色边框代表漏检，蓝色边框代表错检。下同。
Note: Red bounding boxes represent the model's detection results, yellow bounding boxes represent missed detections, and blue bounding boxes represent false detections. The same below.

图 8 不同模型检测效果对比

Fig.8 Comparison of detection performance of different models




图 9 复杂场景下的检测效果对比

Fig.9 Comparison of detection performance in complex scenarios

表 4 小目标检测性能对比

Table 4 Comparison of small target detection performance			
模型 Model	mAP/%	漏检率 Missed detection rate/%	错检率 False detection rate/%
YOLOv10n	79.6	15.3	6.5
DSM-YOLOv10	86.3	9.1	3.8

3.5 计数结果分析

为了进一步分析改进模型在复杂实际应用场景下的检测能力，本研究选取 30 幅图像，分别利用不同模型进行检测计数，与实测数据的对比分析结果如表 5 和图 11 所示。DSM-YOLOv10 检测模型的 R^2 、RMSE、MAE 分别为 0.92、5.68 株、4.33 株，与前 5 个模型中表现最好的 YOLOv10n 相比， R^2 提升了 6.98%，RMSE、MAE 分

别降低了 35.23% 和 40.44%。 R^2 的提升说明改进模型的检测结果与实测结果之间有更强的相关性，RMSE、MAE 的降低说明改进模型的检测误差更小、精度更高。RetinaNet、Faster-RCNN、SSD、YOLOv8n 的检测值明显低于实测值，YOLOv10n 虽更接近实测结果，但仍有较多漏检与错检。上述结果表明，DSM-YOLOv10 检测模型具有更高的计数准确率和鲁棒性，能对复杂场景下小麦幼苗实现精准检测。




图 10 小目标检测效果对比

Fig.10 Comparison of small target detection performance

表 5 不同模型计数性能对比

Table 5 Comparison of counting performance of different models			
模型 Model	R^2	RMSE/株	MAE/株
RetinaNet	0.55	28.48	27.03
Faster-RCNN	0.72	17.20	15.67
SSD	0.64	24.75	23.40
YOLOv8n	0.79	11.46	9.47
YOLOv10n	0.86	8.77	7.27
DSM-YOLOv10	0.92	5.68	4.33




图 11 小麦幼苗的模型检测值与实测值拟合结果

Fig.11 Fitting results of model-detected values and measured values for wheat seedlings

4 结 论

针对小麦幼苗目标小、分布密集、互相遮挡等问题,本研究基于 YOLOv10n 提出一种改进算法 DSM-YOLOv10,主要结论如下:

1) 将 DualConv 引入 C2f 构建 DCC2f 模块,用以替换骨干网络中的 C2f 模块,以减少冗余卷积操作,提高特征融合能力和计算效率;引入 SDI 模块更替 Concat,增强网络对语义信息和空间细节的获取能力;引入 MSDA 模块有效聚合多尺度信息,进一步提升网络的特征提取能力,提高检测性能。

2) 试验结果表明,DSM-YOLOv10 检测模型平均精度均值、精确率、召回率和 F1 分数分别达到了 91.4%、85.2%、81.7%和 83.4%,与 YOLOv10n 相比分别提高了 5.0、2.6、5.4 和 4.1 个百分点,并且模型参数数量和浮点运算量分别降低 4.7%和 10.7%,同时推理时间降至 13.2 ms。能在小麦幼苗微小、密集重叠、杂乱的复杂场景下实现实时精准检测,展现出优越性能与鲁棒性。

3) 在小麦幼苗检测计数方面,DSM-YOLOv10 的检测结果与实测结果相比,决定系数、均方根误差、平均绝对误差分别为 0.92、5.68 株、4.33 株,明显优于 RetinaNet、Faster-RCNN、SSD、YOLOv8n 和 YOLOv10n 模型,具有更高的计数准确率和鲁棒性,能对复杂场景下小麦幼苗实现精准计数。

综上,本研究通过多方面改进,提升了模型对复杂场景下小麦幼苗的检测精度和计数性能,为农业实践中的数据调查提供了有效支持,也为其他作物的幼苗检测提供了思路和方法。但需要指出的是,本研究仍存在需进一步探索的问题:首先,模型泛化能力有待提升。未来研究将扩展数据集覆盖更多场景,降低模型对特定数

据的过拟合,增强其适应复杂农业环境的能力,提高检测精度。其次,本模型在水稻、玉米等作物幼苗检测任务中的迁移学习能力以及改进模块在其他 YOLO 版本上的适配性有待进一步考究;最后,本研究主要采用 RGB 图像进行检测,但热红外成像与三维点云技术在农业目标识别中具有独特优势。热红外图像对比度更佳,可在低能见度环境中更清晰区分幼苗与背景;三维点云数据可提供空间深度信息,有助于解决二维图像无法处理的遮挡问题。因此,后续可聚焦于探索高效的多源数据融合策略,提升小麦幼苗检测在更极端场景下的鲁棒性。并进一步探索在移动边缘设备上的实时部署,实现小麦幼苗检测的实时性,为苗期动态监测提供高效可行的技术支撑。

[参 考 文 献]

- [1] Zhu J, Li Y, Wang C, et al. Method for monitoring wheat growth status and estimating yield based on UAV multispectral remote sensing[J]. *Agronomy*, 2024, 14(5): 991.
- [2] Chen P, Li Y, Liu X, et al. Improving yield prediction based on spatio-temporal deep learning approaches for winter wheat: a case study in Jiangsu Province, China[J]. *Computers and Electronics in Agriculture*, 2023, 213: 108201.
- [3] Feng W, Lan Y, Zhao H, et al. Identification of high-photosynthetic-efficiency wheat varieties based on multi-source remote sensing from UAVs[J]. *Agronomy*, 2024, 14(10): 2389.
- [4] 申雪懿, 李东升, 陈琛, 等. 小麦分蘖数目遗传研究进展与展望[J]. *麦类作物学报*, 2023, 43(10): 1344-1350.
Shen Xueyi, Li Dongsheng, Chen Chen, et al. Progress and prospect of genetic research on tiller number in wheat[J]. *Journal of Triticeae Crops*, 2023, 43(10): 1344-1350. (in Chinese with English abstract)
- [5] Qi K, Wu X, Gu C, et al. BreedingEIS: an efficient evaluation information system for crop breeding[J]. *Plant Phenomics*, 2023,

- 5: 0029.
- [6] Wang L, Zhao Y, Liu S, et al. Precision detection of dense plums in orchards using the improved YOLOv4 model[J]. *Frontiers in Plant Science*, 2022, 13: 839269.
 - [7] 李东升, 胡文泽, 兰玉彬, 等. 深度学习在杂草识别领域的研究现状与展望[J]. *中国农机化学报*, 2022, 43(9): 137-144.
Li Dongsheng, Hu Wenzhe, Lan Yubin, et al. Research status and prospect of deep learning in weed recognition[J]. *Journal of Chinese Agricultural Mechanization*, 2022, 43(9): 137-144. (in Chinese with English abstract)
 - [8] 朱周华, 周怡纳, 王斌. 基于卷积神经网络的水稻叶片病害检测与识别研究进展[J]. *中国农机化学报*, 2025, 46(10): 176-182, 191.
Zhu Zhouhua, Zhou Yina, Wang Bin. Research progress on rice leaf disease detection and identification based on convolutional neural network[J]. *Journal of Chinese Agricultural Mechanization*, 2025, 46(10): 176-182, 191. (in Chinese with English abstract)
 - [9] 朱锐, 张家瑜, 黄继超, 等. 基于卷积神经网络的农作物叶片病害检测研究进展[J]. *农业工程学报*, 2025, 41(17): 15-28.
Zhu Rui, Zhang Jiayu, Huang Jichao, et al. Research progress of crop leaf disease detection based on convolutional neural network[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(17): 15-28. (in Chinese with English abstract)
 - [10] 李新龙, 兰玉彬, 王会征. 基于改进 YOLOv10n 的自然场景下芒果果实与果梗检测方法[J]. *农业工程学报*, 2025, 41(19): 167-175.
Li Xinlong, Lan Yubin, Wang Huizheng. Detecting mango fruits and peduncles in natural scenes using improved YOLOv10n[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(19): 167-175. (in Chinese with English abstract)
 - [11] 兰玉彬, 孙斌书, 张乐春, 等. 基于改进 YOLOv5s 的自然场景下生姜叶片病虫害识别[J]. *农业工程学报*, 2024, 40(1): 210-216.
Lan Yubin, Sun Binshu, Zhang Lechun, et al. Identifying diseases and pests in ginger leaf under natural scenes using improved YOLOv5s[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2024, 40(1): 210-216. (in Chinese with English abstract)
 - [12] 王会征, 刘海藤, 李新龙, 等. 基于改进 YOLOv8n 的轻量化草坪异质杂草检测算法[J]. *农业工程学报*, 2025, 41(10): 157-165.
Wang Huizheng, Liu Haiteng, Li Xinlong, et al. Detecting lawn heterogeneous weed using lightweight improved YOLOv8n[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(10): 157-165. (in Chinese with English abstract)
 - [13] Liu L, Ouyang W, Wang X, et al. Deep learning for generic object detection: A survey[J]. *International Journal of Computer Vision*, 2020, 128(2): 261-318.
 - [14] 胡文泽, 王宝聚, 耿丽杰, 等. 基于 Cascade R-CNN 的玉米幼苗检测[J]. *农机化研究*, 2023, 45(5): 26-31.
Hu Wenzhe, Wang Baoju, Geng Lijie, et al. Detection method of corn seedling based on Cascade R-CNN[J]. *Journal of Agricultural Mechanization Research*, 2023, 45(5): 26-31. (in Chinese with English abstract)
 - [15] Xiao Y, Zhang X, Chen Z, et al. Comparative analysis of attentional mechanisms in rice pest identification[J]. *Scientific Reports*, 2025, 15(1): 21397.
 - [16] 翟肇裕, 张梓涵, 徐焕良, 等. YOLO 算法在动植物表型研究中应用综述[J]. *农业机械学报*, 2024, 55(11): 1-20.
Zhai Zhaoyu, Zhang Zihan, Xu Huanliang, et al. Review of applying YOLO family algorithms to analyze animal and plant phenotype[J]. *Transactions of the Chinese Society for Agricultural Machinery*, 2024, 55(11): 1-20. (in Chinese with English abstract)
 - [17] Diwan T, Anirudh G, Tembhurne J. Object detection using YOLO: challenges, architectural successors, datasets and applications[J]. *Multimedia Tools and Applications*, 2022, 82(6): 9243-9275.
 - [18] Liu C, Yin Y, Qian R, et al. Enhanced winter wheat seedling classification and identification using the SETFL-ConvNeXt model: addressing overfitting and optimizing training strategies[J]. *Agronomy*, 2024, 14(9): 1914.
 - [19] Dong X, Pan J. DHS-YOLO: Enhanced detection of slender wheat seedlings under dynamic illumination conditions[J]. *Agriculture*, 2025, 15(5): 510.
 - [20] Ma H, Zhao W, Ji J, et al. A quick counting method for winter wheat at the seedling stage in fields based on an improved YOLOv4 model[J]. *Journal of Animal and Plant Sciences*, 2022, 32(6): 1666-1681.
 - [21] Li M, Zhang L, Wang C, et al. A wheat seedling counting method based on two-stage convolutional neural network[J]. *Smart Agricultural Technology*, 2025, 12: 101332.
 - [22] 侯依廷, 饶元, 宋贺, 等. 复杂大田场景下基于改进 YOLOv8 的小麦幼苗期叶片数快速检测方法[J]. *智慧农业 (中英文)*, 2024, 6(4): 128-137.
Hou Yiting, Rao Yuan, Song He, et al. A rapid detection method for wheat seedling leaf number in complex field scenarios based on improved YOLOv8[J]. *Smart Agriculture*, 2024, 6(4): 128-137. (in Chinese with English abstract)
 - [23] 何豪旭, 高祥, 饶元, 等. 基于改进 YOLOv8s 的小麦苗期叶尖检测方法[J]. *中国农业科学*, 2025, 58(18): 3598-3615.
He Haoxu, Gao Xiang, Rao Yuan, et al. Detection method of leaf tip in wheat seedling stage based on improved YOLOv8s[J]. *Scientia Agricultura Sinica*, 2025, 58(18): 3598-3615. (in Chinese with English abstract)
 - [24] Wang S, Zhao J, Cai Y, et al. A method for small-sized wheat seedlings detection: from annotation mode to model construction[J]. *Plant Methods*, 2024, 20(1): 1-13.
 - [25] Zhou C, Zhou C, Yao L, et al. An improved YOLOv5s-based method for detecting rice leaves in the field[J]. *Frontiers in Plant Science*, 2025, 16: 1561018.
 - [26] Yan C, Yang K. FSM-YOLO: Apple leaf disease detection network based on adaptive feature capture and spatial context awareness[J]. *Digital Signal Processing*, 2024, 155: 104770.
 - [27] 王会征, 李新龙, 薄萍, 等. 基于改进 YOLOv8n 的自然场景下苹果外观品质检测方法[J]. *农业工程学报*, 2025, 41(11): 173-182.
Wang Huizheng, Li Xinlong, Bo Ping, et al. Detecting apple appearance quality under natural scenes using improved YOLOv8n[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(11): 173-182. (in Chinese with English abstract)
 - [28] Wang A, Chen H, Liu L, et al. YOLOv10: real-time end-to-end object detection[J]. *Advances in Neural Information Processing Systems*, 2025, 37: 107984-108011.
 - [29] 刘侦龙, 王骥, 麦仁贵. 基于改进 YOLOv10s 的海洋牧场水下海参检测方法[J]. *农业工程学报*, 2025, 41(10): 186-194.
Liu Zhenlong, Wang Ji, Mai Rengui. Detecting underwater sea cucumber in marine ranching using improved YOLOv10s[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(10): 186-194. (in Chinese with English abstract)
 - [30] 刘畅, 孙雨, 杨远礼, 等. 改进 YOLOv10n 算法在番茄叶片病害检测上的应用[J]. *光电工程*, 2025, 52(8): 27-43.
Liu Chang, Sun Yu, Yang Yuanli, et al. Application of

- improved YOLOv10n algorithm in tomato leaf disease detection[J]. *Opto-Electronic Engineering*, 2025, 52(8): 27-43. (in Chinese with English abstract)
- [31] Gong Y, Ding W, Huang N, Improved YOLOv10n model for enhanced cotton recognition in complex environments[J]. *Smart Agricultural Technology*, 2025, 12: 101209.
- [32] Zhong J, Chen J, Mian A. DualConv: Dual convolutional kernels for lightweight deep neural networks[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2023, 34(11): 9528-9535.
- [33] Peng Y, Chen D, Sonka M. U-Net V2: Rethinking the skip connections of U-Net for medical image segmentation[C]// *Proceedings of the IEEE Conference on International Symposium on Biomedical Imaging*. Houston, USA: IEEE, 2025: 1-5.
- [34] Jiao J, Tang Y, Lin K, et al. DilateFormer: multi-scale dilated transformer for visual recognition[J]. *IEEE Transactions on Multimedia*, 2023, 25: 8906-8919.

Detecting and counting wheat seedlings under complex field conditions using improved YOLOv10n

Li Shenke¹, Zhu Junke^{1,2,3*}, Huang Aoqun¹, Tang Zhicheng¹, Yang Ning²,
Du Changliang², Zhu Yuxin⁵, Lan Yubin^{1,3,4*}

(1. College of Agricultural Engineering and Food Science, Shandong University of Technology, Zibo 255000, China; 2. School of Life and Science, Qilu Normal University, Jinan 250200, China; 3. Academy of Ecological Unmanned Farm, Shandong University of Technology, Zibo 255000, China; 4. Shandong Provincial Engineering Technology Research Center for Agricultural Aviation Intelligent Equipment, Zibo 255000, China; 5. College of Agriculture, Shandong Agricultural University, Tai'an 271017, China)

Abstract: Wheat seedling counting is one of the most crucial field surveys at the emergence stage. However, the challenges remain, such as small size, dense distribution, and mutual occlusion of wheat seedlings. This study aims to accurately detect and count the wheat seedlings in complex field environments. An improved algorithm (named DSM-YOLOv10) was proposed using YOLOv10n. Firstly, global annotation was adopted rather than only local features during data labeling. The overall features of wheat seedlings were learned and extracted to effectively avoid the feature loss caused by overlapping and occlusion. Secondly, a DCC2f module was constructed to replace the C2f module with the dual convolution (DualConv) in the backbone network. Grouped and pointwise convolutions were concurrently deployed to combine with the residual connections. The gradient vanishing was alleviated in deep-layer training. A more complete transmission of cross-layer features was realized to minimize the redundant convolution. Computational efficiency was improved to facilitate subsequent real-time deployment on mobile edge devices. More efficient features were provided for the subsequent processing. Furthermore, a semantics and detail infusion (SDI) module was introduced to explicitly inject the high-level semantic information into low-level detail features using cross-layer attention and Hadamard products. Detail enhancement was obtained under semantic guidance to avoid simple feature stacking without deep information interaction in the conventional concatenation modules. Consequently, the performance was improved to decouple and reuse features in the overlapping regions of wheat seedlings. Finally, a multi-scale dilated attention (MSDA) mechanism was adopted to incorporate the multiple dilation rates. Multi-scale semantic information was effectively aggregated to integrate the local details with contextual information. Furthermore, the intersecting and overlapping wheat seedlings were enhanced after extraction. Moreover, the complex redundancy or additional computational cost was efficiently reduced in the self-attention mechanism. Experimental results demonstrate that the DSM-YOLOv10 model achieved precise detection of wheat seedlings under multiple complex scenarios. The mean average precision (mAP), precision (P), recall (R), and F1 score were 91.4%, 85.2%, 81.7%, and 83.4%, respectively, which was improved by 5.0, 2.6, 5.4, and 4.1 percentage points, respectively, compared with the original YOLOv10n model. Furthermore, the parameter count and floating point operations (FLOPs) were reduced by 4.7% and 10.7%, respectively. The real-time detection was also realized with an inference time of 13.2 ms (approximately 76 frames per second). Compared with the RetinaNet, Faster-RCNN, SSD, and YOLOv8n models, the DSM-YOLOv10 model exhibited the best performance in detection. The mAP values were 35.8, 24.5, 30.7, and 8.6 percentage points higher, respectively; whereas, the number of parameters was reduced by 87.4%, 96.2%, 90.0%, and 15.2%, respectively; and the FLOPs were decreased by 86.3%, 96.0%, 88.1%, and 7.4%, respectively. The DSM-YOLOv10 model also demonstrated excellent recognition of the small objects, with a mAP of 86.3%, particularly in overlapping seedling scenarios. Both its missed detection rate and false detection rate remained at the low levels, at 9.1% and 3.8%, respectively. The coefficient of determination (R^2), root mean square error (RMSE), and mean absolute error (MAE) were 0.92, 5.68 plants, and 4.33 plants, respectively, in the seedling counting task using the DSM-YOLOv10 model. Compared with the YOLOv10n, the R^2 increased by 6.98%, while the RMSE and MAE decreased by 35.23% and 40.44%, respectively, indicating the higher counting accuracy and robustness. This finding can effectively improve the detection and counting performance of wheat seedlings in complex scenarios. The improved model was also featured by fewer parameters and lower FLOPs. The finding can provide support for field data acquisition in smart agriculture.

Keywords: YOLOv10n; target detection; wheat seedling; dual convolution; semantics and detail infusion; multi-scale dilated attention