

基于 YOLO-GESCW 的盛花期红花轻量化检测方法

程义锋^{1,2}, 王超^{1,2*}, 董广翔^{1,2}, 李晓娟^{1,2}, 黄腾龙³, 苏君红⁴

(1. 新疆大学机械工程学院, 乌鲁木齐 830017; 2. 新疆农牧机器人及智能装备工程研究中心, 乌鲁木齐 830017;
3. 西北农林科技大学机械与电子工程学院, 杨凌 712100; 4. 裕民县农业技术推广站, 塔城 834800)

摘要: 为提高盛花期红花检测精度和检测实时性, 该研究基于 YOLOv8n 提出一种 YOLO-GESCW 盛花期红花轻量化检测方法。通过引入幽灵卷积 (Ghost Conv) 降低卷积深度计算开销; 采用高效通道注意力模块 (efficient channel attention, ECA) 替换主干网络及颈部网络部分 C2f 模块, 减少模型参数量和计算量; 引入空间金字塔池化高效层聚合网络 (spatial pyramid pooling with efficient layer aggregation network, SPPELAN) 模块增强多尺度特征提取能力; 在颈部网络加入 C3k2 模块, 提升轮廓与细节捕捉能力; 使用 Wise-IoUv3 函数优化边界框损失。结果表明, 改进后模型参数量约 0.98 M、模型大小为 2.09 MB、浮点计算量为 3.4 G, 较原 YOLOv8n 分别降低 67.44%、65.10% 和 58.02%; 测试集精确率为 93.6%、召回率为 93.0%、平均精度均值 (mAP_{0.5}) 为 98.1%, 平均检测速度为 106.79 帧/s; 在 NVIDIA Jetson Xavier NX 边缘设备部署测试, 目标模型 best.engine 大小为 3.48 MB、平均帧率 52.36 帧/s、单图平均推理耗时 0.007 2 s。该研究实现了检测模型轻量化与检测精度平衡, 可为盛花期红花采收作业检测模型边缘设备部署提供解决方案。

关键词: 深度学习; YOLOv8n; 目标检测; 红花; 轻量化

doi: 10.11975/j.issn.1002-6819.202509289

中图分类号: S225; TP391; S24

文献标志码: A

文章编号: 1002-6819(2026)-04-0033-10

程义锋, 王超, 董广翔, 等. 基于 YOLO-GESCW 的盛花期红花轻量化检测方法[J]. 农业工程学报, 2026, 42(4): 33-42.

doi: 10.11975/j.issn.1002-6819.202509289 <http://www.tcsae.org>

CHENG Yifeng, WANG Chao, DONG Guangxiang, et al. Detecting safflower at the full bloom stage using lightweight YOLO-GESCW[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2026, 42(4): 33-42. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202509289 <http://www.tcsae.org>

0 引言

红花是一种集药用、油料、天然色素等功能于一体的重要经济作物^[1-2], 其盛花期花丝直立, 含水率高, 颜色呈橘红色、形态饱满, 是最佳采收期^[3-4], 及时采收且不损伤花蕾情况下, 2~3 d 可再生长下一茬花丝, 累计可采收 2~3 茬^[5-6]。目前盛花期红花花丝采收仍依赖人工, 采收技术要求高、人工需求量大、劳动强度高, 人工采收成本比例占种植收益 50% 以上^[7-8]。为缓解人工采收劳动强度, 降低采收成本, 研制红花智能化采收装备成为突破红花采收难题的关键方向, 而田间盛花期红花的精准快速识别是装备研发的一个关键环节。

深度学习目标检测算法中, 传统的两阶段检测算法虽在农业领域有一定应用, 但在检测精度和实时性的平衡上, 单阶段的 YOLO 系列算法更具竞争力^[9-11]。随着农业机器人技术发展, 机器视觉与深度学习融合已成为果实等收获物快速精准识别的主流技术路径^[12-14]。现有相关研究中, 张振国等^[15]基于 YOLOv3 采用轻量级网络

幻影结构融合卷积块注意力模块, 提出 GSC-YOLOv3 红花丝检测算法, mAP 达 91.89%, 但是未进行边缘设备部署, 训练设备测试帧率仅 51.1 帧/s。GUO 等^[16]基于 YOLOv5 采用幽灵卷积和卷积块注意力模块结合损失函数优化提出 SF-YOLO 红花检测模型, 但计算开销较大, 参数量达 5.34 M、浮点计算量达 13.2 G。陈金荣等^[17]针对红花尺度变化大、遮挡情况等复杂问题, 基于 YOLOv5s 提出 YOLO-SSAR 红花检测模型, 精确率为 90.1%, 模型大小为 9.7 MB, 但是未进行边缘设备部署测试。张新月等^[18]针对田间复杂环境和边缘设备计算资源受限问题, 基于 YOLOv8n 采用 Vanillanet 轻量化网络和优化损失函数等策略提出 YOLOv8n-VLWS 轻量化红花识别方法, 模型大小仅 3.00 MB, 轻量化改进取得一定成效, 但是边缘设备部署测试单图检测耗时较长, 单图推理需要 0.27 s。CHEN 等^[19]基于 YOLOv8n 改进的 YOLO-SaFi 非结构环境下红花花丝检测算法, 边缘设备部署测试检测速度为 29.1 帧/s, 检测速度仍可进一步提升。王小荣等^[20]针对田间复杂环境造成红花机械化采摘识别不准问题, 基于 YOLOv7 提出 Improved YOLOv7 模型, 在不均衡样本检测方面取得了一定效果, 但是参数量达 40.9 M, 精确率仅 81.8%, 模型检测精度和轻量化平衡仍有提升空间。师翊等^[21]使用高效多尺度通道注意力模块改进 YOLOv8n 模型结合迁移学习方法对自建苹果幼果数据集训练, 该模型在保持轻量化的同时, 精确率达 99.6%。

收稿日期: 2025-09-30 修订日期: 2025-12-02

基金项目: 国家自然科学基金项目 (32301717); 新疆维吾尔自治区天池英才项目 (51052300546)

作者简介: 程义锋, 研究方向为智能采摘机器人。

Email: chengyifeng@stu.xju.edu.cn

※通信作者: 王超, 博士, 副教授, 研究方向为智能农业装备、农业机器人关键技术。Email: wangchao@xju.edu.cn

范天浩等^[22]提出一种基于改进 YOLOv5s 的轻量化金银花识别方法,模型大小为 7.8 MB,精确率达 90.7%,帧率达 135 帧/s,但难以直接适配盛花期红花场景。上述研究在红花等目标检测精度和轻量化网络模型构建方面取得了较好的效果。

但是针对盛花期红花检测,现有研究仍存在以下三方面核心问题:一是红花果球位姿各异且易晃动,花丝尺度变化大且属于小目标,增加检测难度;二是复杂自然环境下光照变化、枝叶遮挡、花丝重叠,模型检测精度不足;三是模型体积大、计算资源占用高,无法满足边缘设备高效部署需求。为此,本研究以 YOLOv8n 为基线模型,从卷积结构、注意力机制、多尺度特征融合、细节捕捉模块和损失函数 5 个方面进行轻量化改进,构建 YOLO-GESCW 模型,旨在保证检测精度的同时,显著降低模型复杂度与计算量,提升边缘设备部署性能,为盛花期红花采收作业检测模型边缘设备部署提供解决方案。

1 材料与方法

1.1 试验数据获取

盛花期红花数据图像采集地点为新疆维吾尔自治区塔城市裕民县哈拉布拉乡南哈拉不拉村,红花品种为“裕红 1 号”。裕民县是“中国无刺红花之乡”,红花种植面积约 $1.33 \times 10^5 \text{ hm}^2$,约占全疆一半。采集时间为 2025 年 7 月 10 日至 15 日,拍摄时间段为 7:00-10:00、12:00-14:00、20:00-22:00,采集设备为 iPhone 13、Vivo S15 Pro 智能手机,图像分辨率 4 032×3 024、3 072×3 072 像素,图像保存为“JPG”格式,所有数据图像均采集于自然环境中的盛花期红花。选择光照较强的晴天、光照较弱的阴天等天气状况下以顺光、侧光、逆光拍摄,俯视拍摄时摄像头光轴与竖直方向夹角 $0^\circ \sim 45^\circ$,摄像头距离样本间距离 150~420 mm。最终,经过人工筛选剔除,采集到包含不同光照、不同位姿、不同尺度、不同遮挡以及重叠的盛花期红花数据图像 2 521 张。不同场景下盛花期红花图像如图 1 所示。

1.2 数据处理

为使模型充分训练,丰富盛花期红花样本数据集,进一步防止过拟合,本研究采用调整亮度、调节饱和度、引入高斯噪声等图像增强手段对原始图像进行处理,其中,亮度调整旨在模拟自然光照强度的动态变化,以还原不同时段(清晨、正午、傍晚)的实际光照效果;饱和度调节用于复现强光环境下设备摄像头因反射效应产生的图像偏差;而高斯噪声的引入则是为了模拟红花在风力作用下发生晃动,进而导致图像出现的模糊现象,使处理后的图像更贴合实际检测场景。原始数据集(2 521 张)叠加增强数据集共包含图片 7 563 张,利用脚本对所有数据图片尺寸调整为 640×640 像素尺寸。

考虑到红花采收主要针对盛花期红花,该花期花丝形态饱满、颜色鲜艳呈现橘红色、具有很高的经济价值,为此仅对盛花期红花进行标注,标注标签为

“Blooming”,采用标注软件 Labelimg 进行人工标注,标注过程精细化要求矩形框尽可能贴合花丝边缘,标注格式为 YOLO 格式的 txt 文件,且保证每张图片至少有一朵盛花期红花位置标注,最后,本研究利用脚本按照 7:2:1 比例将增强后的红花数据集划分为训练集(5 294 张)、验证集(1 512 张)、测试集(757 张)。




图 1 不同场景下盛花期红花图像

Fig.1 Images of safflower in full bloom across different scenes

2 网络模型及轻量化模型构建


2.1 YOLOv8n 模型

YOLOv8^[23]作为 YOLO 系列^[24-27]目标检测算法的代表,在检测精度、推理速度与模型轻量化的平衡上较优,但在应用复杂环境检测、移动设备部署等计算资源受限的场景中,检测性能仍有提升空间^[28]。本研究选用 YOLOv8 系列中参数量最小、推理效率最高的 YOLOv8n 版本作为基线模型^[29]。其结构分为三部分,Backbone(主干网络)以 C2f 模块作为基础单元,承担核心特征提取任务;Neck(颈部网络)采用路径聚合网络(PANet)结构,负责多尺度特征融合;Head(检测头)采用解耦头结构与无锚框策略,在大、中、小三种尺度上完成目标分类与检测框定位。

2.2 轻量化模型构建

盛花期红花检测模型需部署在算力资源有限的边缘设备上,因此在满足检测精度的前提下,需最大限度降低模型参数量与计算量。

本研究以 YOLOv8n 为基线模型，通过以下 5 个模块改进构建轻量化 YOLO-GESCW 模型，改进后模型结构如图 2 所示。首先，为减少卷积核计算开销，引入幽灵卷积（Ghost Conv）^[30] 替换模型标准卷积；其次，为解决模型参数量大和权重文件大问题，采用轻量级高效通道注意力机制（ECA）^[31] 改进原模型主干和颈部网络；进一步，为使空间金字塔池化层更好捕捉多尺度特征信息，引入 YOLOv9 空间金字塔池化高效层聚合网络模块（SPPELAN）^[32]；更进一步，为提高复杂场景下对检测目标轮廓和细节特征快速精准捕捉，在颈部引入 YOLOv11 优化后的瓶颈模块 C3k2^[33]；最后，为降低盛花期红花枝叶遮挡与重叠导致的边界框定位误差，提升盛花期红花检测的边界框定位精度与目标识别准确率，对原 CIoU^[34] 损失函数采用动态非单调聚焦机制损失函数 Wise-IoUv3^[35] 替换。



注：Ghost Conv 为幽灵卷积；ECA 为高效通道注意力模块；SPPELAN 为空间金字塔池化高效特征聚合网络；C3k2 为 C3k2 模块；Up sample 为上采样；Concat 为特征连接模块；Detect 为检测头。
Note: Ghost Conv is ghost convolution; ECA is the efficient channel attention module; SPPELAN is the spatial pyramid pooling with efficient feature aggregation network; C3k2 is the C3k2 module; Up sample is up-sampling; Concat is the feature concatenation module; Detect is the detection head.

图 2 YOLO-GESCW 模型结构
Fig.2 YOLO-GESCW model structure

2.2.1 幽灵卷积（Ghost Conv）

原 YOLOv8n 采用标准卷积（如图 3a），其卷积核数量多、计算开销大。幽灵卷积（Ghost Conv）^[30]（如图 3b）通过“基础特征提取-廉价特征衍生”两步法，在保证特征表达能力的同时，初步减少参数量与计算量。具体流程如下：第一步，输入特征经 1×1 标准卷积压缩输入通道数，降低后续计算基数，同时融合跨通道信息，生成通道数更少的多层次核心基础特征；第二步，对每个基础特征分别执行低成本线性操作，生成“幽灵特征”，大幅减少卷积核计算与参数存储开销；最后，将第一步生成的基础特征与第二步生成的幽灵特征在通道维度拼接，得到与原标准卷积输出通道数、空间尺寸一致的特征图，完成同等特征表达能力下的计算开销降低。





图 3 标准卷积与幽灵卷积
Fig.3 Standard convolution and ghost convolution

2.2.2 轻量级注意力机制 ECA

为增强特征筛选能力，进一步降低模型参数量与计算量，本研究使用 ECA 注意力机制^[31]（如图 4）替换主干网络全部 C2f 模块及颈部网络第 12、21 层 C2f 模块。ECA 注意力机制通过一维卷积自适应捕捉通道间依赖关系，避免全连接层导致的参数膨胀，首先对输入特征图执行全局平均池化，将每个通道的空间信息压缩为单个特征向量，获取全局上下文信息；其次将该特征向量送入 1D 卷积层，卷积核大小根据通道数自适应确定（计算方式如式（1））实现通道依赖精准建模，最后通过 Sigmoid 激活函数对 1D 卷积输出归一化，得到各通道注意力权重，与原始输入特征图逐通道相乘，增强重要通道特征，抑制次要通道特征。ECA 注意力机制卷积核 k 与通道 C 关系如式（1）所示。

$$k = \psi(C) = \left\lfloor \frac{\log_2(C)}{\gamma} + \frac{b}{\gamma} \right\rfloor_{\text{odd}} \quad (1)$$

式中 γ 和 b 是超参数，分别设为 2 和 1； $\lfloor \cdot \rfloor_{\text{odd}}$ 表示取最近奇数。



注： χ 为输入特征图， H 为特征图高度， W 为特征图宽度， C 为特征图通道数，GAP 为全局平均池化， σ 为 Sigmoid 激活函数， $\tilde{\chi}$ 为输出特征图。
Note: χ is the input feature map, H is the height of the feature map, W is the width of the feature map, C is the number of feature map channels, GAP is global average pooling, σ is the Sigmoid activation function, and $\tilde{\chi}$ is the output feature map.

图 4 ECA 模块网络结构
Fig.4 ECA module network structure

2.2.3 空间金字塔池化高效层聚合网络 (SPPELAN)

盛花期红花图像中目标尺度变化大, 原 YOLOv8n 的 SPPF 模块对小目标红花局部簇状结构特征易丢失细节, 导致检测精度不足。本研究引入 SPPELAN 模块^[32] (如图 5) 替换原 SPPF 模块, 强化多尺度特征均衡提取能力, 具体流程为: 首先, 输入特征通过 1×1 卷积统一通道维度, 生成基础特征; 其次, 采用 3 个不同池化卷积核大小的最大池化层并行处理基础特征, 既保留小目标局部细节, 又兼顾大目标全局上下文; 进一步, 将原始基础特征与 3 个池化后的特征拼接, 整合多尺度信息, 避免单一尺度特征损耗; 最后, 经 1×1 卷积完成特征聚合, 调整通道数至与后续网络匹配的维度, 确保特征传递连贯性。




图 5 SPPELAN 模块结构
Fig.5 SPPELAN module structure

SPPELAN 模块融合空间金字塔池化 (SPP) 的多尺度覆盖能力与高效特征聚合网络 (ELAN) 的特征整合能力, 通过多尺度池化核并行提取特征, 增强对小尺度红花的感知能力, 提升复杂场景下模型鲁棒性。

2.2.4 C3k2 模块

为增强对盛花期红花精细轮廓和局部细节特征的快速精准捕捉能力, 本研究将 YOLOv8n 颈部网络第 15、18 层的 C2f 模块替换为 C3k2 模块^[33] (如图 6)。首先, 输入特征经 1×1 卷积调整通道数后, 分为两个并行分支, 主分支直接传递基础特征, 确保红花原始轮廓等低层级信息不丢失, 残差分支进入由 N 个计算单元组成的残差序列, 进行深层细节特征提取; 其次, 计算单元通过 “C3k” 参数选择类型, 本研究设 “C3k=False”, 启用轻量化标准 Bottleneck 单元, 在控制参数量的同时保证细节提取能力, 每个计算单元采用 “卷积-归一化-激活” 标准配置, 并通过 “shortcut” 参数启用跳跃连接, 将输入与输出特征直接相加, 缓解深层训练梯度消失问题, 确保红花边缘、纹理等细节特征无损传递; 最后, 主分支原始特征与残差分支增强特征通过通道维度拼接融合, 再经 1×1 卷积统一通道数后输出。该模块通过双分支结构与拼接融合策略, 强化模型对红花轮廓与纹理的提取能力。

2.2.5 损失函数 Wise-IoUv3

盛花期红花场景中存在类间枝叶遮挡红花和类中红花重叠遮挡, 导致目标边界框易出现 “定位偏移” 或 “形状偏差”。原 YOLOv8n 采用的 CIoU 损失函数^[34], 虽兼顾重叠度、中心点距离与宽高比, 但存在两点缺陷: 一是对宽高比的约束刚性过强; 二是对高重叠遮挡目标的

定位误差惩罚不足, 导致边界框回归精度低。




图 6 C3k2 模块结构
Fig.6 C3k2 module structure

本研究将边界框损失函数替换为 Wise-IoUv3^[35], 通过精细化误差惩罚机制解决遮挡场景定位问题, 该损失函数, 将边界框回归误差拆解为 “位置偏差” 与 “形状偏差”, 独立优化路径, 位置偏差强化中心点微调, 形状偏差采用柔性权重约束; 训练初期对小误差宽松惩罚, 避免收敛缓慢, 后期对大误差增强惩罚, 强制修正框选偏移, 将遮挡红花的边界框从枝叶区域调整至实际花体; 通过 “动态非单调频率调制” 机制, 降低低质量样本干扰, 增强 “中度遮挡、主体可见” 有效红花样本的训练权重, 减少无效样本导致的边界框损失, 聚焦核心检测目标。CIoU 的计算如式 (2) 所示, Wise-IoUv3 的计算如式 (3) ~ (5) 所示。

$$L_{\text{CIoU}} = 1 - \text{IoU} + \frac{\rho^2(b_{\text{pt}}, b_{\text{gt}})}{d^2} + \alpha v \quad (2)$$

式中 L_{CIoU} 为 CIoU 损失; IoU 为预测框与真实框交并比; b_{pt} 为预测框中心点; b_{gt} 为真实框中心点; ρ 为两个中心点欧氏距离; d 为两个矩形框最小外接矩形对角线长度; α 为平衡参数; v 为高宽比一致性度量。

$$L_{\text{WIoU}} = r \cdot \exp\left(\frac{(x - x_{\text{gt}})^2 + (y - y_{\text{gt}})^2}{(H_g^2 + W_g^2)^*}\right) \cdot (1 - \text{IoU}) \quad (3)$$

$$r = \frac{\beta}{\delta \alpha^{\beta-\delta}} \quad (4)$$

$$\beta = \frac{(1 - \text{IoU})^*}{1 - \text{IoU}} \in [0, +\infty] \quad (5)$$

式中 L_{WIoU} 为 Wise-IoUv3 损失; (x, y) 、 $(x_{\text{gt}}, y_{\text{gt}})$ 分别为预测框与真实框中心点坐标; H_g 和 W_g 分别为预测框与真实框最小外接矩形的高和宽; $*$ 为分离操作, r 为非单调聚焦系数; δ 为学习参数; β 为离群值; IoU 为预测框与真实框交并比的平均值。

2.3 试验环境与评价指标

2.3.1 试验环境

为确保试验条件一致性, 本研究模型训练、验证和测试均在同一平台, 该平台硬件配置为: Intel (R) Core (TM) i5-14600KF 14 核 3.50 GHz 处理器, 主板为华硕 PRIME B760M-A WIFI D4, 机带 RAM 32.0 GB、速度 3 600 MHz, 显卡 NVIDIA GeForce RTX 4060TI 8GB。软件配置为: Windows 11 (64 位专业工作站版) 操作系

统, Pytorch 2.6.0 深度学习框架, 使用 12.6 版本 CUDA 加速 GPU, 使用 Anaconda 24.11.3 部署 Ultralytics 8.3.162 资源库, 编程使用 Python 3.12.9, 编译器使用 PyCharm Community Edition 2024.1.4。

部分训练参数设置为: 输入图片尺寸为 640×640 像素, 优化器为 Auto, 优化器动量因子为 0.937, 衰减系数设置为 0.000 5, 初始学习率为 0.005, 训练批次大小设置为 16, 训练轮次设置为 300, 其余参数为默认值。

2.3.2 评价指标

本研究主要采用精确率 (precision, P)、召回率 (recall, R)、平均精度均值 (mean average precision, mAP) 评价模型检测精度, 其中 mAP 阈值设置为 0.5; 采用模型参数量 (parameters), 浮点计算量 (floating

point of operation, FLOPs) 评价模型计算规模; 选取模型大小 (model size) 作为可部署性评价指标; 选取帧率 (frames per second, FPS) 评价模型的实时检测性能。帧率的计算如式 (6) 所示。

$$\text{FPS} = \frac{1/(T_{\text{pre}} + T_{\text{in}} + T_{\text{post}})}{1000} \quad (6)$$

式中 T_{pre} 、 T_{in} 、 T_{post} 分别表示预处理、推理、后处理耗时, 单位 ms。

3 结果与分析

3.1 消融试验

为验证各改进模块在盛花期红花检测中的有效性, 以 YOLOv8n 为基准模型开展消融试验, 结果如表 1 所示。

表 1 盛花期红花数据集的 YOLOv8n 消融试验结果
Table 1 YOLOv8n ablation test results for the safflower data set during full blooming period

Ghost Conv	ECA	SPPELAN	C3k2	Wise-IoUv3	平均精度均值 Mean average precision mAP _{0.5} /%	精确率 Precision/%	召回率 Recall/%	参数量 Parameters /M	浮点计算量 Floating point operations FLOPs/G	帧率 Frames per second FPS/ (帧·s ⁻¹)	模型大小 Model size/MB
×	×	×	×	×	98.8	94.7	96.4	3.01	8.1	104.39	5.99
√	×	×	×	×	98.7	94.6	96.1	2.73	7.5	100.96	5.47
×	√	×	×	×	98.5	94.9	95.0	1.85	5.7	114.95	3.72
×	×	√	×	×	98.5	94.3	96.0	2.85	8.0	108.36	5.69
×	×	×	√	×	98.7	95.1	95.3	2.64	6.6	105.46	5.31
×	×	×	×	√	98.6	94.4	96.1	3.01	8.1	103.67	5.99
×	×	√	×	√	98.6	94.6	95.1	2.85	8.0	105.15	5.69
×	×	√	√	√	98.5	94.4	94.3	2.48	6.5	104.04	5.00
√	√	×	×	×	98.4	93.8	94.1	1.57	5.1	111.98	3.20
√	√	√	×	×	98.1	92.3	94.3	1.40	5.0	90.34	3.00
√	√	√	√	×	98.1	93.2	92.8	0.98	3.4	104.00	2.09
×	√	√	√	√	98.3	93.6	93.1	1.26	4.0	113.29	2.61
√	√	√	√	√	98.1	93.6	93.0	0.98	3.4	106.79	2.09

注: “√” 代表使用该模块, “×” 代表不使用该模块。

Note: “√” indicates that the module was used, “×” indicates that the module was not used.

由表 1 可知, 与基线模型 YOLOv8n 相比, 单独引入 Ghost Conv 替换标准卷积后, 参数量、浮点计算量均出现小幅度下降, 说明先进行部分基础特征生成, 再进行简单线性操作可减少计算开销。在引入 Ghost conv 基础上, 引入 ECA 注意力模块替换 C2f 模块, 模型参数量、浮点计算量均大幅度下降, 说明该模块通过通道自适应卷积操作可有效降低模型的参数量和计算量。单独引入 SPPELAN 模块替换 SPPF 后, 参数量、浮点计算量波动较小, 平均精度均值维持 98.5%, 说明其在不增加计算负担的前提下, 维持多尺度特征融合能力。单独引入 C3k2 模块后精确率为所有单模块改进中最优达 95.1%, 说明该模块有助于增强模型细节特征提取能力。同时进行 5 个模块改进的模型与仅不使用 Wise-IoUv3 的模型对比表明, 引入 Wise-IoUv3 可以有效提高精确率和召回率, 说明采用动态非单调聚焦机制强化了对低冗余、多尺度、细节特征的聚焦, 从而提高了检测性能。

引入 5 个模块改进的 YOLO-GESCW 模型参数量仅为 0.98 M、模型大小仅为 2.09 MB、浮点计算量仅为 3.4 G, 较原模型 YOLOv8n 分别下降约 67.44%、65.10%、58.02%, 精确率为 93.6%、召回率为 93.0%、平均精度均值为 98.1%, 较原模型分别下降 1.1、3.4、0.7 个百分

点, 帧率为 106.79 帧/s, 较原模型表现出更好的综合性, 在轻量化和检测精度平衡上较优。

3.2 不同模型对比试验分析

选取目前主流检测模型 YOLOv9t、YOLOv10n、YOLOv11n、YOLOv12n, 在相同试验条件下训练模型与 YOLO-GESCW 进行性能对比, 同时为客观评价改进的 YOLO-GESCW 模型, 选择本领域 9 种相关模型进行对比分析, 不同模型性能对比结果如表 2 所示。

模型计算规模指标评价, YOLO-GESCW 模型参数量, 较 YOLOv9t、YOLOv10n、YOLOv11n、YOLOv12n 分别降低约 50.25%、56.83%、62.02%、61.72%, 浮点计算量较上述 4 种主流模型分别降低 55.3%、47.7%、46.0%、46.0%, 同时参数量和计算量均低于本领域 9 种模型; 可部署性指标评价, YOLO-GESCW 模型大小仅为 2.09 MB; 模型实时检测性能指标评价, YOLO-GESCW 模型检测帧率为 106.79 帧/s, 均比 4 种主流模型高, 但较 YOLO-SARR^[17] 低 8.21 帧/s、较 YOLOv8n-VLWS^[18] 低 16.67 帧/s、较 YOLO-SaFi^[19] 低 238.01 帧/s; YOLO-GESCW 模型精确率为 93.6%、召回率为 93.0%、平均精度均值为 98.1%, 较上述 4 种主流和 SF-YOLO^[16] 模型低 1~3 个百分点, 除此之外, 均高于其他对比模型。

表 2 不同模型性能对比结果
Table 2 Comparison results of the performance of different models

模型 Model	平均精度均值 Mean average precision mAP _{0.5} /%	精确率 Precision/%	召回率 Recall/%	参数量 Parameters/M	浮点计算量 Floating point operations FLOPs/G	帧率 Frames per second FPS/(帧·s ⁻¹)	模型大小 Model size/MB
YOLO-GESCW	98.1	93.6	93.0	0.98	3.4	106.79	2.09
YOLOv9t	98.7	94.8	95.7	1.97	7.6	63.28	4.45
YOLOv10n	98.7	95.5	95.0	2.27	6.5	103.48	5.51
YOLOv11n	98.7	94.7	95.9	2.58	6.3	93.80	5.25
YOLOv12n	98.5	94.8	93.8	2.56	6.3	83.02	5.29
YOLOv5s-GCE ^[11]	95.9	90.6	91.0	3.52	-	16.67	-
GSC-YOLOv3 ^[15]	91.9	92.9	80.7	-	-	51.10	5 898.24
SF-YOLO ^[16]	95.3	94.1	92.3	5.34	13.2	-	-
YOLO-SSAR ^[17]	93.4	90.1	88.5	-	-	115.00	9.70
YOLOv8n-VLWS ^[18]	96.4	93.1	91.0	-	-	123.46	3.00
YOLO-SaFi ^[19]	93.9	92.2	88.6	1.50	4.8	344.80	3.09
Improved YOLOv7 ^[20]	88.5	81.8	83.9	40.90	-	42.10	-
YOLO-DFL ^[36]	93.4	-	-	29.80	43.2	98.60	-
YOLOv8-WED ^[37]	95.0	93.2	86.7	-	-	72.00	6.40

注：“-”表示原文未提及相关指标。
Note: “-” represents that no reference to relevant indicators in the original text.

综合而言，改进后的模型计算资源消耗更少、模型更小、可部署性更优、检测速度更有优势，满足盛花期红花检测的精度需求和边缘设备部署要求。

3.3 特征可视化

采用 Grad-CAM(gradient-weighted class activation mapping) 技术^[38]，选取盛花期红花图片分别对 YOLOv8n 与 YOLO-GESCW 的主干网络第 7、8、9 层进行特征图像可视化（如图 7 所示）。

通过对比图 7 可知，YOLOv8n 模型第 7 层网络对盛花期红花目标区域关注度不高，并且存在对非花朵区域的关注，相比之下 YOLO-GESCW 模型更关注目标花朵区域；YOLOv8n 模型第 8 层网络关注区域是背景特征信息，YOLO-GESCW 模型仍然关注目标盛花期红花区域特征；YOLOv8n 模型第 9 层网络只关注到部分目标边缘区域，然而 YOLO-GESCW 模型更关注全局目标区域。相比之下 YOLO-GESCW 模型能够准确地聚焦于图像中检测目标的区域，对非目标区域关注较少，这一表现更符合网络模型改进设计的预期目标。

3.4 模型部署验证

3.4.1 特殊场景部署测试

为验证 YOLO-GESCW 的边缘部署性能，基于 NVIDIA Jetson Xavier NX 平台开展试验，边缘计算平台部分配置为：Ultralytics 为 8.3.162 版本，TensorRT 为 8.5.2.2 版本，Python 为 3.8.20 版本，Jetpack 为 5.1.1 版本，CUDA 为 11.4.315 版本，cuDNN 采用 8.6.0.166 版本，启用 20W-6core 模式。输入数据为实地拍摄的照片与视频（iPhone13 拍摄，视频 1080P/60FPS，MP4 格式）。

分别使用改进前后未依赖 Pytorch 框架运行的 best.pt 文件，通过 ONNX Runtime 框架调用 GPU 的 CUDA 计算跨框架中间格式 best.onnx 文件，以及使用 TensorRT 加速，启用 FP16 半精度量化 best.engine 文件进行部署测试。YOLO-GESCW 模型的 best.pt、best.onnx、best.engine 三个部署文件大小分别是 2.09、3.95、3.48 MB，较原 YOLOv8n 模型三个部署文件 best.pt（5.99 MB）、

best.onnx(11.6 MB)、best.engine(7.39 MB)，分别降低约 65.1%、66.0%、52.9%。




图 7 改进前后模型热力图可视化对比
Fig.7 Visual comparison of model heatmaps before and after improvement

4 种典型场景下的检测性能如表 3 所示，其中帧率计算方法如式（6），YOLO-GESCW 模型导出的 best.engine 文件在测试中检测速度、推理速度最优。小尺度-强光-重叠遮挡场景下，best.engine 模型帧率 43.48 帧/s、推理耗时 0.007 1 s；弱光-无遮挡场景下，帧率 32.15 帧/s，推理耗时 0.007 1 s；多株连片红花场景下，平均帧率


51.81 帧/s，平均推理耗时 0.007 2 s；单株红花晃动场景下，平均帧率 52.36 帧/s，平均推理耗时 0.007 2 s。

表 3 模型部署性能对比结果
Table 3 Comparison results of model deployment performance

模型 Model	文件类型 Files type	小尺度-强光-重叠遮挡 Small-scale high-light and overlapping obstruction		弱光-无遮挡 Low-light and unobstructed		多株连片 Scenario with multiple contiguous		单株红花晃动 Single swaying safflower plant	
		帧率 FPS/ (帧·s ⁻¹)	推理耗时 Inference/s	帧率 FPS/ (帧·s ⁻¹)	推理耗时 Inference/s	平均帧率 Everage FPS/ (帧·s ⁻¹)	平均推理耗时 Everage inference/s	平均帧率 Everage FPS/ (帧·s ⁻¹)	平均推理耗时 Everage inference/s
YOLO-GESCW	.pt	24.94	0.024 3	20.24	0.024 2	32.05	0.020 0	31.55	0.020 4
	.onnx	26.18	0.017 0	16.61	0.028 3	33.56	0.016 7	33.11	0.017 2
	.engine	43.48	0.007 1	32.15	0.007 1	51.81	0.007 2	52.36	0.007 2
YOLOv8n	.pt	24.63	0.024 7	18.66	0.027 2	28.33	0.023 7	28.12	0.023 1
	.onnx	21.23	0.021 9	15.02	0.022 5	30.03	0.020 7	22.47	0.028 6
	.engine	40.98	0.007 7	29.94	0.007 7	49.26	0.007 8	48.08	0.007 7

由图 8 可知，YOLO-GESCW 模型在复杂场景下表现出高可靠性。强光重叠场景下（如图 8a）准确检测 17 朵盛花期红花，漏检 3 朵，①目标属虚化遮挡造成漏检，②目标属开放度不符合盛花期红花标准，③和④目标属远景且虚化造成漏检，错检 0 朵，边界框贴合盛花

期红花目标边缘；弱光无遮挡场景下（如图 8b）成功识别 4 朵盛花期红花，置信度均高于 0.65；多株连片场景下（如图 8c）视频流中红花识别稳定，无帧间目标丢失；单株晃动场景下（如图 8d）检测框实时跟踪晃动红花，无定位偏移。



注：蓝色矩形框是检测框标记；红色圆形是漏检标记；白色圆形是非盛花期红花标记。下同。
Note: The blue rectangular boxes mark detection boxes; the red circles mark missed detection; the white circles mark non-blooming. The same below.


图 8 改进模型不同场景下检测效果
Fig.8 Detection results of the improved model under different scenarios

部署试验表明，YOLO-GESCW 模型的 best.engine 文件在边缘设备上具备“小体积、高速度、高精度”的综合优势。

3.4.2 改进前后模型部署检测测试

为验证改进前后模型的实际检测性能差异，将未参

与模型训练过程的自建盛花期红花数据测试集（757 张）图像输入到 NVIDIA Jetson Xavier NX 平台进行测试，选择改进前后启用半精度量化、TensorRT 加速的 best.engine 文件进行测试。改进前后模型部署检测对比结果如图 9 所示。



注：红色矩形是检测框重复标记；红色圆形是漏检标记；黄色矩形是误检标记。
Note: The red rectangles boxes mark detection boxes repeat; the red circles mark missed detection; the yellow rectangles boxes mark false detected instances.

图 9 改进前后模型部署检测对比
Fig.9 Original and improved model comparison of deployment detection

对比两者测试结果发现:

1) YOLO-GESCW 模型检测实时性更占优势。原 YOLOv8n 模型在 757 张测试图片中, 平均单张图片推理速度 0.007 8 s, YOLO-GESCW 模型在测试中, 平均单张图片推理速度 0.007 2 s。

2) YOLO-GESCW 模型检测框整体质量更贴合盛花期红花目标边缘, 原 YOLOv8n 模型存在检测框偏移和重复标注现象。

3) 原 YOLOv8n 模型检测出的盛花期样本置信度大部分高于 YOLO-GESCW 模型, 检测出的同一盛花期红花目标置信度波动范围在 0.1~36 个百分点。

4) 改进前后模型均存在盛花期红花漏检现象, YOLO-GESCW 模型漏检现象主要为图像中盛花期红花目标虚化造成漏检, 原 YOLOv8n 模型漏检现象主要为图像中盛花期红花目标位姿倾斜造成漏检, 此外原 YOLOv8n 模型存在对衰败期红花误检为盛花期红花现象。

在实际部署检测过程中, 由于轻量化改进造成 YOLO-GESCW 模型较原基线模型盛花期红花检测精度略有降低, 从部署试验检测对比结果来看, 劣势体现在, 一是检测出的盛花期红花目标置信度有所降低, 二是虚化的盛花期红花目标检测效果低于基线模型, 优势体现在, 单幅图像推理速度更快, 检测框定位性能更优秀, 对盛花期红花图像没有造成误检, 综合检测性能更优。

4 结 论

针对田间盛花期红花检测精度和实时性要求高, 边缘设备计算资源有限的问题, 本研究以 YOLOv8n 为基线, 通过 5 个方面改进构建 YOLO-GESCW 轻量化模型, 主要结论如下:

1) 模型轻量化与精度平衡效果显著: YOLO-GESCW 参数量为 0.98 M、模型大小为 2.09 MB、浮点计算量为 3.4 G, 较原 YOLOv8n 分别降低了 67.44%、65.10%、58.02%; 在测试集上进行测试精确率为 93.6%、召回率为 93.0%、平均精度均值为 98.1%, 帧率为 106.79 帧/s, 较主流模型 YOLOv9t、YOLOv11n、YOLOv12n 在轻量化与实时性上优势显著。

2) 边缘部署性能满足实际需求: 在 NVIDIA Jetson Xavier NX 平台上, 目标模型 best.engine 大小为 3.48 MB, 单株红花晃动场景下平均帧率为 52.36 帧/s、平均单图推理耗时 0.007 2 s, 可适配采收机器人等边缘设备。

后续研究将结合采收机器人的定位-运动控制需求, 实现“检测-定位-采收”的一体化集成。

【参 考 文 献】

- [1] 周远航, 郭建富, 马小龙, 等. 新疆红花生产现状及发展对策研究[J]. 安徽农业科学, 2021, 49(19): 199-201, 217. ZHOU Yuanhang, GUO Jianfu, MA Xiaolong, et al. Research on current situation and development countermeasures of Xinjiang safflower production[J]. Journal of Anhui Agricultural Sciences, 2021, 49(19): 199-201, 217. (in Chinese with English abstract)
- [2] 梁慧珍, 董薇, 余永亮, 等. 国内外红花种质资源研究进展[J]. 安徽农业科学, 2015, 43(16): 71-74. LIANG Huizhen, DONG Wei, YU Yongliang, et al. Advances in studies on safflower (*Carthamus Tinctorius* L.) at home and abroad[J]. Journal of Anhui Agricultural Sciences, 2015, 43(16): 71-74. (in Chinese with English abstract)
- [3] 李彤彤. 红花质量评价和不同花期成分变化研究[D]. 北京: 北京中医药大学, 2019. LI Tongtong. Study on the Evaluation of Safflower Quality and Compositional Changes at Different Flowering Stages[D]. Beijing: Beijing University of Chinese Medicine, 2019. (in Chinese with English abstract)
- [4] ZHANG H, GE Y, XIA H, et al. Safflower picking points localization method during the full harvest period based on SBP-YOLOv8s-seg network[J]. Computers and Electronics in Agriculture, 2024, 227: 109646.
- [5] XING Z Y, ZHANG Z G, SHI R M, et al. Filament-necking localization method via combining improved PSO with rotated rectangle algorithm for safflower-picking robots[J]. Computers and Electronics in Agriculture, 2023, 215: 108464.
- [6] ZHANG Z G, ZENG C, XU P, et al. Clamping root-cutting end-effector for harvesting fresh safflower[J]. International Journal of Agricultural and Biological Engineering, 2025, 18(2): 146-154.
- [7] WANG X R, ZHOU J P, XU Y, et al. Location of safflower filaments picking points in complex environment based on improved Yolov5 algorithm[J]. Computers and Electronics in Agriculture, 2024, 227: 109463.
- [8] 杨会锋. 新疆红花丝机械化采收研究现状[J]. 新疆农机化, 2020(5): 34-37. YANG Huifeng. Research status of mechanized harvesting of safflower silk in Xinjiang[J]. Xinjiang Agricultural Mechanization, 2020(5): 34-37. (in Chinese with English abstract)
- [9] 王会征, 刘海藤, 李新龙, 等. 基于改进 YOLOv8n 的轻量化草坪异质杂草检测算法[J]. 农业工程学报, 2025, 41(10): 157-165. WANG Huizheng, LIU Haiteng, LI Xinlong, et al. Detecting lawn heterogeneous weed using lightweight improved YOLOv8n[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(10): 157-165. (in Chinese with English abstract)
- [10] 匡敏球, 李旭, 陈嫡, 等. 基于改进 YOLOv8n 的轻量化辣椒花目标检测方法[J]. 农业工程学报, 2025, 41(12): 198-207. KUANG Minqiu, LI Xu, CHEN Shang, et al. Lightweight chili flower target detection method based on improved YOLOv8n[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(12): 198-207. (in Chinese with English abstract)
- [11] 陈金荣, 许燕, 周建平, 等. 深度学习方法在红花采摘机器人中的应用[J]. 农机化研究, 2025, 47(4): 186-191. CHEN Jinrong, XU Yan, ZHOU Jianping, et al. Application of deep learning method in safflower picking robot[J]. Journal of Agricultural Mechanization Research, 2025, 47(4): 186-191. (in Chinese with English abstract)
- [12] 李欣, 徐博, 张雷, 等. 基于改进轻量化 YOLOv5s 的万寿

- 菊识别方法[J]. 计算机测量与控制, 2025, 33(6): 185-192, 199.
- LI Xin, XU Bo, ZHANG Lei, et al. Marigold recognition method based on improved lightweight YOLOv5s[J]. *Computer Measurement and Control*, 2025, 33(6): 185-192, 199. (in Chinese with English abstract)
- [13] 朱军, 陈钢, 蒋丽花, 等. 轻量化改进 YOLOv8n 的荔枝病虫害检测方法[J]. 农业工程学报, 2025, 41(13): 207-215.
- ZHU Jun, CHEN Gang, JIANG Lihua, et al. Detecting litchi pests and disease using lightweight improved YOLOv8n[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(13): 207-215. (in Chinese with English abstract)
- [14] 施国英, 纪嘉鹏, 李天华, 等. 基于改进 YOLOv8s 的杭白菊检测与花期分类[J]. 农业工程学报, 2025, 41(7): 192-199.
- SHI Guoying, JI Jiapeng, LI Tianhua, et al. Detecting chrysanthemum to classify flowering stages using improved YOLOv8s[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(7): 192-199. (in Chinese with English abstract)
- [15] 张振国, 邢振宇, 赵敏义, 等. 改进 YOLOv3 的复杂环境下红花丝检测方法[J]. 农业工程学报, 2023, 39(3): 162-170.
- ZHANG Zhenguo, XING Zhenyu, ZHAO Minyi, et al. Detecting safflower filaments using an improved YOLOv3 under complex environments[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2023, 39(3): 162-170. (in Chinese with English abstract)
- [16] GUO H, WU T L, GAO G M, et al. Lightweight safflower cluster detection based on YOLOv5[J]. *Scientific Reports*, 2024, 14(1): 18579.
- [17] 陈金荣, 许燕, 周建平, 等. 基于 YOLO-SSAR 的自然环境下红花检测算法[J]. 农业工程学报, 2025, 41(2): 215-223.
- CHEN Jinrong, XU Yan, ZHOU Jianping, et al. Detecting safflower in the natural environment using YOLO-SSAR[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(2): 215-223. (in Chinese with English abstract)
- [18] 张新月, 胡广锐, 李浦航, 等. 基于改进 YOLOv8n 的轻量化红花识别方法[J]. 农业工程学报, 2024, 40(13): 163-170.
- ZHANG Xinyue, HU Guangrui, LI Puhang, et al. Recognizing safflower using improved lightweight YOLOv8n[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2024, 40(13): 163-170. (in Chinese with English abstract)
- [19] CHEN B B, DING H F, MA B J, et al. A method for real-time recognition of safflower filaments in unstructured environments using the YOLO-SaFi model[J]. *Sensors*, 2024, 24(13): 4410.
- [20] 王小荣, 许燕, 周建平, 等. 基于改进 YOLOv7 的复杂环境下红花采摘识别[J]. 农业工程学报, 2023, 39(6): 169-176.
- WANG Xiaorong, XU Yan, ZHOU Jianping, et al. Safflower picking recognition in complex environments based on an improved YOLOv7[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2023, 39(6): 169-176. (in Chinese with English abstract)
- [21] 师翊, 王应宽, 王菲, 等. 基于改进 YOLOv8n 的苹果幼果识别[J]. 农业工程学报, 2025, 41(8): 204-210.
- SHI Yi, WANG Yingkuan, WANG Fei, et al. Recognizing young apples using improved YOLOv8n[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(8): 204-210. (in Chinese with English abstract)
- [22] 范天浩, 顾寄南, 王文波, 等. 基于改进 YOLOv5s 的轻量化金银花识别方法[J]. 农业工程学报, 2023, 39(11): 192-200.
- FAN Tianhao, GU Jinan, WANG Wenbo, et al. Lightweight honeysuckle recognition method based on improved YOLOv5s[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2023, 39(11): 192-200. (in Chinese with English abstract)
- [23] YASEEN M. What is YOLOv8: An in-depth exploration of the internal features of the next-generation object detector [EB/OL]. (2024-08-28)[2025-08-05]. <https://doi.org/10.48550/arXiv.2408.15857>.
- [24] LEI M, LI S, WU Y, et al. YOLOv13: Real-time object detection with hypergraph-enhanced adaptive visual perception[EB/OL]. (2025-06-21)[2025-08-05]. <https://doi.org/10.48550/arXiv.2506.17733>.
- [25] TIAN Y, YE Q, Doermann D. YOLOv12: Attention-centric real-time object detectors[EB/OL]. (2025-02-18)[2025-08-09]. <https://doi.org/10.48550/arXiv.2502.12524>.
- [26] GE Z, LIU S, WANG F, et al. YOLOx: Exceeding yolo series in 2021[EB/OL]. (2021-07-18)[2025-08-13]. <https://doi.org/10.48550/arXiv.2107.08430>.
- [27] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, BC, Canada: IEEE, 2023: 7464-7475.
- [28] 刘建江, 李书琴. 基于改进 YOLOv8n 的密集分布猕猴桃花期检测方法[J]. 农业工程学报, 2025, 41(12): 172-181.
- LIU Jianjiang, LI Shuqin. Method for detecting densely distributed kiwifruit flowering period based on improved YOLOv8n[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(12): 172-181. (in Chinese with English abstract)
- [29] VARGHESE R, SAMBATH M. Yolov8: A novel object detection algorithm with enhanced performance and robustness[C]//2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS). Chennai, India: IEEE, 2024: 1-6.
- [30] HAN K, WANG Y, TIAN Q, et al. Ghostnet: More features from cheap operations [C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2020: 1577-1586.
- [31] WANG Q, WU B, ZHU P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2020: 11531-11539.
- [32] YASEEN M. What is YOLOv9: An in-depth exploration of the internal features of the next-generation object detector [EB/OL]. (2024-09-12)[2025-08-05]. <https://doi.org/10.48550/arXiv.2409.07813>.
- [33] KHANAM R, HUSSAIN M. YOLOv11: An overview of the key architectural enhancements[EB/OL]. (2024-10-23)[2025-08-04]. <https://doi.org/10.48550/arXiv.2410.17725>.
- [34] ZHENG, Z H, WANG P, LI W et al. Distance-IoU loss: Faster

- and better learning for bounding box regression[EB/OL]. (2019-11-19)[2025-07-20]. <https://doi.org/10.48550/arXiv.1911.08287>.
- [35] TONG Z, CHEN Y, XU Z, et al. Wise-IoU: Bounding box regression loss with dynamic focusing mechanism[EB/OL]. (2023-01-24)[2025-07-20]. <https://doi.org/10.48550/arXiv.2301.10051>.
- [36] 郭翔羽, 南新元, 石天怡, 等. 基于改进 YOLOv7 的轻量级红花检测方法[J]. 东北师大学报 (自然科学版), 2025, 57(3): 67-76.
- GUO Xiangyu, NAN Xinyuan, SHI Tianyi, et al. A lightweight safflower detection method based on improved YOLOv7[J]. Journal of Northeast Normal University(Natural Science Edition) 2025, 57(3): 67-76. (in Chinese with English abstract)
- [37] ZHANG Z G, WANG Y Z, XU P, et al. WED-YOLO: A detection model for safflower under complex unstructured environment[J]. Agriculture. 2025, 15(2): 205.
- [38] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-cam: Visual explanations from deep networks via gradient-based localization[C]//2017 IEEE International Conference on Computer Vision (ICCV). Venice, Italy: IEEE, 2017: 618-626.

Detecting safflower at the full bloom stage using lightweight YOLO-GESCW

CHENG Yifeng^{1,2}, WANG Chao^{1,2✉}, DONG Guangxiang^{1,2}, LI Xiaojuan^{1,2}, HUANG Tenglong³, SU Junhong⁴

(1. College of Mechanical Engineering, Xinjiang University, Urumqi 830017, China; 2. Agriculture and Animal Husbandry Robot and Intelligent Equipment Engineering Research Centre of Xinjiang Uygur Autonomous Region, Urumqi 830017, China; 3. College of Mechanical and Electronic Engineering, Northwest A & F University, Yangling 712100, China; 4. Yumin County Agricultural Technology Extension Station, Tacheng 834800, China)

Abstract: High accuracy and real-time performance are often required to detect the safflower at the full bloom stage in complex field environments. However, the conventional models are constrained by the high computational complexity and low edge deployment adaptability. In this study, a lightweight detection (named YOLO-GESCW) was proposed for the safflower at the full bloom stage using YOLOv8n. The self-built dataset of the safflower at full bloom was constructed to cover the scenarios with different lighting, weather, target scales, and occlusion levels. Five improvements were systematically implemented: Firstly, Ghost Convolution (Ghost Conv) was used to replace all standard convolutions in the backbone network and the 16th and 19th layer standard convolutions in the neck network, in order to reduce the computational overhead of the convolution depth. Secondly, the Efficient Channel Attention (ECA) module was used to substitute all C2f modules in the backbone network and the 12th and 21st layer C2f modules in the neck network. Model parameters and computational cost were reduced for better lightweight performance. Thirdly, the Spatial Pyramid Pooling with Efficient Layer Aggregation Network (SPPELAN) module replaced the original SPPF (Spatial Pyramid Pooling - Fast) to fuse the multi-scale features, thus enhancing the detection for the irregular small-scale targets. Fourthly, the C3k2 module was added to the neck network to capture the object contours and fine details. Finally, the Wise-IoUv3 loss function replaced the original one to reduce the error between predicted and ground-truth boxes. A comparative analysis was conducted with nine models in the field, including mainstream models YOLOv9t, YOLOv10n, YOLOv11n, YOLOv12n, and Gradient-weighted Class Activation Mapping (Grad-CAM) visualization for the 7th–9th layers of the backbone networks of YOLOv8n and YOLO-GESCW. Deployment verification was performed on the NVIDIA Jetson Xavier NX edge device. Results showed that the YOLO-GESCW was achieved in a parameter count of 0.98 M, model size of 2.09 MB, and FLOPs of 3.4 G, which were 67.44%, 65.10%, and 58.02% lower than YOLOv8n, respectively. On the test set, it reached 93.6% precision, 93.0% recall, and 98.1% mean average precision (mAP@0.5), with an average detection speed of 106.79 frames per second. Compared with the four mainstream models, its parameters were reduced by 50.25%, 56.83%, 62.02%, and 61.72%, while the FLOPs were reduced by 55.3%, 47.7%, 46.0%, and 46.0%, respectively. Among the nine comparative models, the YOLO-GESCW achieved the highest mAP@0.5 (98.15%), its precision was 0.5 percentage points lower than SF-YOLO, but higher than the rest, and its recall was the highest among the nine models. Notably, it was the model with the parameters less than one million (0.98 M), thus consuming fewer computational resources to better meet the lightweight requirements of the edge deployment. The Grad-CAM results confirmed the improved model focused more on the targets, which was consistent with the expected optimizations. The 3.48 MB best was deployed on the edge device. The engine model achieved 52.36 frames per second and 0.0072 s single-image inference time on the 757 unseen images from the self-built dataset. The YOLO-GESCW model effectively balanced the lightweight performance, high detection accuracy, and real-time responsiveness, thereby overcoming the key limitations of conventional models in complex field scenarios. The finding can provide a reliable technical reference for the real-time detection of the safflower at the full bloom stage and its practical deployment on the resource-constrained edge devices. A solid foundation can help develop intelligent safflower harvesting.

Keywords: deep learning; YOLOv8n; target detection; safflower; lightweight