

基于无人机影像与 YOLOv12n-RCL 的向日葵成熟期盘腐病危害程度检测

李京谦^{1,2}，韩国涛^{1,2}，赵 静^{1,2,3*}，张帅领^{1,2}，谢欣妤⁴，
付姗姗⁴，鲁力群⁴，兰玉彬^{1,2}

(1. 山东理工大学农业工程与食品科学学院，淄博 255000；2. 山东省农业航空智能装备工程技术研究中心，淄博 255000；
3. 山东理工大学现代农业装备研究院，淄博 255000；4. 山东理工大学交通与车辆工程学院，淄博 255000)

摘 要：高效、精准地评估向日葵盘腐病危害程度对早期防治、精准施药和产量损失估测至关重要。针对传统病害分级方法效率低、主观性强的问题，该研究提出一种基于改进 YOLOv12n 的向日葵成熟期盘腐病危害程度检测模型。首先，将主干和颈部网络的 C3K2 模块替换为融合感受野注意力卷积（receptive-field attention convolution, RFACConv）与坐标注意力机制（coordinate attention, CA）的 C3K2-RC 模块，以增强模型在复杂环境中对不同等级盘腐病的特征提取能力；其次，在颈部网络集成轻量级的上采样算子 CARFAE 提升特征重构效果；最后，引入一种分离批量归一化的轻量级共享卷积检测头 LSCSBD（lightweight shared convolutional separable batch normalization detection），以提高模型对小尺度病斑的检测精度与速度。试验结果表明，YOLOv12n-RCL 模型的精确率、召回率、mAP_{0.5} 和 mAP_{0.5-0.95} 分别达到了 83.4%、81.2%、84.8% 和 50.2%，较基准模型 YOLOv12n 分别提高了 3.8、3.2、3.4 和 4.0 个百分点；参数量、计算量和模型大小分别压缩至 2.11 M、5.7 G 和 4.5 MB，较原模型 YOLOv12n 分别降低了 17.9%、12.3% 和 19.6%。基于混淆矩阵的病害等级误检结果表明，改进模型对不同等级盘腐病的错误预测比例均在 10% 以下。边缘设备部署测试显示，在包含 1 298 个不同等级盘腐病样本的 70 幅测试图像中，YOLOv12n-RCL 仅出现 10 例漏检和 8 例误检，与基准模型 YOLOv12n 相比，检测效果更优，且帧率更高，达到了 27.5 帧/s。综上，YOLOv12n-RCL 模型在提升检测精度的同时，实现了轻量化设计与部署效率的有效平衡，可为向日葵成熟期盘腐病智能防治装备的研发提供算法参考。

关键词：无人机；向日葵；遥感影像；成熟期盘腐病；YOLOv12n；病害程度分级

doi: 10.11975/j.issn.1002-6819.202512131

中图分类号：S126；S435.655

文献标志码：A

文章编号：1002-6819(2026)-09-0609-13

李京谦，韩国涛，赵静，等. 基于无人机影像与 YOLOv12n-RCL 的向日葵成熟期盘腐病危害程度检测[J]. 农业工程学报，2026，42(9)：609-621. doi: 10.11975/j.issn.1002-6819.202512131 <http://www.tcsae.org>

LI Jingqian, HAN Guotao, ZHAO Jing, et al. Detection of sunflower disk rot severity at the mature stage based on UAV imagery and YOLOv12n-RCL[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2026, 42(9): 609-621. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202512131 <http://www.tcsae.org>

0 引 言

向日葵是重要的油料作物之一，具有较强的耐瘠薄和抗旱性，是中轻度盐碱地改良的首选作物^[1]。由核盘菌（*Sclerotinia Sclerotiorum*）侵染引起的向日葵盘腐病会导致向日葵空籽率上升、产量降低、籽仁蛋白质及含油量等营养物质含量下降，影响籽粒的食用价值和商品价值^[2-3]。因此，盘腐病早期分级检测，对减少农药的使用、提高向日葵的产量和减少农户经济损失具有重要意义。

目前，向日葵盘腐病监测工作依赖人工田间调查，该方法效率低、主观性强、时效性差，难以适应日渐复杂的田间病害发展形势^[4]。近年来，随着人工智能技术

的不断发展，基于深度学习的目标检测技术已广泛应用于病害检测领域^[5-7]。相关算法主要包括以 Faster R-CNN (faster region-based convolutional neural networks)^[8] 为代表的双阶段目标检测算法和以 YOLO^[9] 系列 (you only look once) 为代表的单阶段目标检测算法。GONG 等^[10] 为了解决苹果叶部病害问题，将 Faster R-CNN 特征提取网络替换为 Res2Net 网络，用 Soft-NMS 算法替代非极大值抑制法，并将 RoIPool 替代为 RoIAlign 算法实现了苹果叶部病害的高效识别。吴世琛等^[11] 提出了一种轻量级的葡萄果叶病害检测模型 RLSSL-YOLO11，该模型通过引入轻量化的颈部结构，融合改进型的 RHGNetv2 (repconv-hgnetv2) 主干网络并结合大核注意力机制与批量归一化检测头，实现了复杂环境下对葡萄果叶病害的实时精准检测。CHEN 等^[12] 提出了一种基于 YOLOv4 改进的向日葵叶部病害检测算法，通过 K-means 优化锚框尺寸，并采用轻量级 MobileNet 架构重构主干特征提取网络，在提升病害特征提取效率的同时实现了模型的轻量化部署。上述研究在构建叶部病害数据集时多采用

收稿日期：2025-12-17 修订日期：2026-02-04

基金项目：山东省自然科学基金项目（ZR2021MD091）

作者简介：李京谦，研究方向为计算机技术在农业工程中的应用。

Email: 19811715026@163.com

*通信作者：赵静，博士，副教授，研究方向为农业遥感技术与智能检测。

Email: zbceozj@163.com

地面手持相机采集图像,但在面向植株较高的向日葵花盘病斑检测时,该方法存在数据采集困难、图像覆盖不全、细节捕捉不足等问题,限制了模型在真实田间场景下的适用性与鲁棒性。

无人机具有灵活性强、受地面环境约束较小的优势,能够在大范围内高效获取大量影像数据,已逐渐成为智慧农业中重要的数据采集方式之一^[13]。基于无人机遥感与深度学习相结合的方法,为作物病害检测提供了新的技术途径。胡根生等^[14]研究了基于 M-Backbone 主干网络与注意机制改进的 LiTLBNet 算法,实现了对无人机影像中茶叶叶枯病的精准判别。PAN 等^[15]提出了一种面向无人机可见光图像的水稻白叶枯病检测模型 Xoo-YOLO,该模型以 LSKNet 作为主干网络,引入 GSConv 混合卷积,在降低计算量与参数量的同时,将水稻病害检测精度提升至 94.95%。陈自立等^[16]为解决无人机遥感影像中的烟草病害问题,对 YOLOv10 模型进行了改进,通过优化主干和颈部网络、引入动态上采样算子及更换损失函数等操作,将模型的平均精度均值提高到 97.5%。以上研究通过无人机搭载高分辨率设备,为病害识别提供了高质量的数据基础,同时在模型精度提高及轻量化等方面提供了有效的改进方案,但对向日葵盘腐病等级检测任务中存在以下难点:1)不同等级的病斑形态多变,导致特征提取困难;2)叶片遮挡等复杂的背景因素,增加了漏检风险;3)部分病斑特征差异细微及边界模糊,易导致误检。

针对上述问题,本文提出一种基于改进 YOLOv12n^[17]的向日葵成熟期盘腐病分级检测方法 YOLO12n-RCL。通过重构主干和颈部网络的 C3K2 模块,优化上采样算子并引入轻量化检测头,以提升模型在复杂环境下对病斑区域的识别效果,增强模型特征提取能力并提高检测精度,以期为自然环境下盘腐病不同等级的检测及智能防治作业提供技术支持。

1 材料与方法

1.1 数据采集

试验数据采集于山东省东营市农科院基地,采集时间为 2024 年 7 月 8 日,此时向日葵处于成熟期,花盘盘面朝下。数据采集平台选用大疆 M300 多旋翼无人机,搭载禅思 P1 可见光相机;获取的影像分辨率为 8 192×5 460 像素,以 JPG 格式存储。飞行任务参数设置如下:飞行高度 30 m,飞行速度 2.5 m/s,航向及旁向重叠率均为 80%。相机镜头等效焦距为 35 mm,采取垂直地面方式拍摄,共获取原始影像 700 幅。

1.2 盘腐病危害程度分级标准

在模型训练前,需对采集到的向日葵盘腐病影像进行危害程度分级。参照已有研究方法^[18],将盘腐病害严重程度划分为 5 类:无病斑为 0 级;病斑占花盘面积 25% 以下为 1 级;病斑占花盘面积 26%~50% 为 2 级;病斑占花盘面积 51%~75% 为 3 级;病斑占花盘面积 76% 以上为 4 级。病斑比例的计算方法如下:

$$P_b = \frac{P_t}{P_h} \quad (1)$$

式中 P_b 代表病斑占花盘面积的比例; P_t 表示图像中病斑区域像素数量; P_h 表示图像中花盘区域的总像素数量。基于人工标注的图像,利用 Python 脚本分别统计病斑与花盘区域的像素数量,计算得到 P_b 值,从而对采集的向日葵样本进行病害等级判定。不同等级的盘腐病样本实例如图 1 所示。



图 1 不同等级盘腐病样本实例

Fig.1 Examples of disk rot samples at different grades

1.3 数据集构建

本研究通过无人机平台获取高分辨率的向日葵田间图像。鉴于无人机较高的拍摄视角,影像中通常包含土壤、杂草及其他非目标作物等复杂的背景区域。为减少背景信息干扰并满足模型的输入要求,需要对采集到的无人机影像进行裁剪分幅,并剔除不清晰、不含目标作物的无效样本,筛选出 1 300 幅影像,再按照危害程度对其进行分类和标注,并将标记后的结果统一保存为 YOLO 格式。为确保训练集与测试集样本的相互独立并提高模型的泛化能力,采用“先划分”、“后增强”的处理方式,首先将标注好的向日葵盘腐病图像按照 8:1:1 的比例随机划分为训练集(1 040 幅),验证集(130 幅)和测试集(130 幅),并对训练集中的样本数据进行平移、旋转、色彩变换和亮度调整 4 种方式将图像扩充至 4 160 幅,由于每幅图像包含多个病害等级,经试验统计,各等级数据增强前后的标签数量如表 1 所示。

表 1 向日葵盘腐病数据集的样本信息

病害等级 Disease grade	训练集 Training set	测试集 Test set	验证集 Validation set	数据增强训练集 Augmented training set
0	7 108	900	1 012	28 432
1	6 517	872	855	26 068
2	6 633	767	881	26 532
3	6 400	847	860	25 600
4	6 817	873	810	27 364

2 模型选择

2.1 YOLOv12 目标检测网络


YOLOv12 是 TIAN 等提出的单阶段目标检测方法,其核心架构由输入端(Input)、特征提取网络(Backbone)、特征融合网络(Neck)、检测头(Head)和输出端(Output) 5 个关键部分组成。相较于 YOLOv11^[19]模型,YOLOv12 通过一系列的协同创新,解决了高实时性和低计算能力的应用场景问题。YOLOv12 采用区域注意力模块 A2 (area attention),通过空间分组卷积与通道重标定联合优化策略进行区域划分,在维持较大感受野的同时提升了检测精度^[20]。为缓解深层网络中的梯度

阻塞问题, YOLOv12 引入了残差高效聚合网络 (residual-elan), 通过重构特征聚合路径形成瓶颈结构, 降低了计算开销。在架构层面, YOLOv12 去除了位置编码, 优化了 MLP 比例, 并引入了大型可分离卷积, 以增强对空间信息的建模能力; 在优化内存访问方面, YOLOv12 通过减少堆叠块的数量, 提高了模型的推理速度。基于以上优势, 并综合考虑实际应用中实时性与精准性的需求, 本研究选用 YOLOv12 系列中综合性能最优的 YOLOv12n 作为基础模型。

2.2 改进后的 YOLOv12n 目标检测网络

针对向日葵盘腐病检测任务中存在的病斑形态多变、特征差异细微、边界模糊及目标遮挡等问题, 本研究从

以下 3 个方面对 YOLOv12n 模型进行改进: 首先, 引入扩展感受野卷积 (receptive-field attention convolution, RFA-Conv) 与坐标注意力机制 (coordinate Attention, CA), 对原有 C3K2 结构进行优化, 通过扩大感受野并建立空间坐标依赖, 有效增强了模型在复杂环境下对不规则病斑区域的定位与特征提取能力。其次, 在颈部网络集成轻量级的上采样算子 CARAFE, 利用内容感知的特征重组机制增强特征图重构质量, 提高模型对病斑边缘信息和纹理特征的恢复能力。最后, 提出一种轻量化检测头 LSCSBD (lightweight shared convolutional separable batch normalization detection), 在减少参数数量的同时提升检测精度。图 2 为改进后的 YOLOv12n 网络结构图。



注: Conv 为卷积块, Conv 2d 为二维卷积块, BatchNorm (BN) 为批量归一化层, SiLU 为激活函数, C3K 为自定义卷积核大小的特征提取模块, C3K2 为残差连接特征提取模块, C3K2-RC 为融合了感受野卷积和坐标注意力机制的 C3K2 模块, Split 为特征分割操作, n 为模块出现的次数, Concat 为特征拼接层, A2 为区域注意力机制, A2C2f 为结合了区域注意力机制和残差连接的特征提取模块, Scaling 为特征缩放操作, ABlock 为区域注意力多层感知机模块, CARAFE 为上采样算子, LSCSBD 为批量归一化的轻量化共享卷积检测头。下同。

Note: Conv refers to the convolutional block, Conv 2d refers to the 2D convolutional block, BatchNorm (BN) refers to the batch normalization layer, SiLU is the activation function, C3K is the custom convolution kernel size feature extraction module, C3K2 is the residual connection feature extraction module, C3K2-RC is the C3K2 module that integrates receptive field convolution and coordinate attention mechanism, Split refers to the feature splitting operation, n is the number of times the module appears, Concat is the feature concatenation layer, A2 is the region attention mechanism, A2C2f is the feature extraction module combining region attention mechanism and residual connections, Scaling refers to the feature scaling operation, ABlock is the region attention multilayer perceptron module, CARAFE is the upsampling operator, and LSCSBD refers to the lightweight shared convolutional detection head with batch normalization. The same below.

图 2 YOLOv12n-RCL (YOLOv12n-RFAConv-CA-CARAFE-LSCSBD) 模型结构图

Fig.2 Structure diagram of the YOLOv12n-RCL (YOLOv12n-RFAConv-CA-CARAFE-LSCSBD) model

2.2.1 引入 RFAConv 模块

在自然生长环境下, 不同等级的盘腐病呈现多尺度特性。常规卷积在特征提取过程中因卷积核尺寸固定且感受野单一, 难以适应病害区域在形态、尺度和空间位置上的多样性变化, 导致模型对目标关键特征的提取与定位能力受限。针对上述问题, 本文引入感受野注意力卷积 RFAConv^[21], 其工作过程如图 3 所示。

在 RFAConv 的工作流程中, 模型通过双分支结构实现特征图的融合。上分支首先采用平均池化对输入特征图 X 进行处理, 以聚合每个感受野内的全局特征信息; 随后通过 1×1 分组卷积进行信息交互, 有效提取局部空间上下文特征, 经过维度重组和 Softmax 处理后生成注意力图 f_w 。该注意力图能够为 3×3 感受野内的每个位置分配归一化权重, 使得模型能够自主评估各区域信息的

重要性。

在下分支处理中, 原始特征图 X 通过步长为 1 的 3×3 分组卷积, 生成与注意力图尺寸和通道相同的感受野空间特征 f_e , 该特征随后依次通过归一化和激活函数来增强非线性表达能力。最终, 通过将上分支生成的注意力图与下分支的感受野空间特征进行逐元素相乘, 得

到增强后的输出特征 f_x , 计算式如下:

$$\begin{cases} f_w = \text{Softmax}(g_{\text{Conv}}^{1 \times 1}(\text{Avgpool}(X))) \\ f_e = \text{ReLU}(\text{BatchNorm}(g_{\text{Conv}}^{3 \times 3}(X))) \\ f_x = f_w \times f_e \end{cases} \quad (2)$$

式中 X 表示输入特征图, $g_{\text{Conv}}^{1 \times 1}$, $g_{\text{Conv}}^{3 \times 3}$ 分别表示尺寸为 1×1 和 3×3 的分组卷积运算。





图3 RFAConv 模块结构图

Fig.3 Structure diagram of the RFAConv module

2.2.2 CA 注意力机制

注意力机制能够在训练过程中根据特征的重要性动态调整权重, 从而提高模型对重要特征的关注度, 抑制

无关特征。为了进一步提高模型在复杂环境下对向日葵盘腐病关键特征的提取能力, 并减少背景因素的干扰, 本文引入CA^[22]注意力机制, 工作流程如图4所示。



注: Residual 为残差连接, X Avg Pool 为宽度方向的平均池化, Y Avg Pool 为高度方向的平均池化, r 为通道缩减比例系数, BatchNorm + Non-linear 为标准化和非线性处理单元, S 为 Sigmoid 激活函数, 下同。

Note: Residual refers to the residual connection, X Avg Pool refers to average pooling along the width dimension, Y Avg Pool refers to average pooling along the height dimension, r denotes the channel reduction ratio coefficient, BatchNorm + Non-linear refers to the batch normalization and non-linear processing unit, and S refers to the Sigmoid activation function. The same below.

图4 CA 注意力机制工作流程图

Fig.4 Workflow diagram of CA attention mechanism

CA 注意力机制首先对输入特征图在宽度和高度方向分别进行全局平均池化,生成两个方向的特征图并进行融合。融合后的特征通过 1×1 卷积进行降维,并经过标准化、非线性转换函数将完整特征重新分解为宽度与高度两个方向的特征图。最后利用 1×1 卷积重新调整特征图的通道维度,并结合 Sigmoid 激活函数生成包含空间位置信息的双向注意力权重^[23]。与空间注意力机制相比,CA 注意力机制能够将位置信息嵌入通道注意力中,实现通道信息与位置信息的协同建模,从而帮助模型精准聚焦于病斑关键特征,提升检测的准确性。

2.2.3 C3K2-RC 结构


本文采用 RFACnv 模块替换 Bottleneck 结构中的 3×3 卷积层,构建全新的 RFACnv-Bottleneck 模块,其结构如图 5 所示。在此基础上,将 CA 注意力机制嵌入重构的 RFA-Bottleneck 模块之后,形成改进的 C3K-RC 模块,该模块在初始阶段通过 RFACnv-Bottleneck 增强全局感知能力,保障后续特征提取过程更加稳定,随后通过 CA 注意力机制进一步优化特征选择,使模型更加聚焦于关键目标区域。改进后的 C3K2 模块能够抑制无关背景干扰,对多尺度病害特征进行更加准确的识别和定位。

2.2.4 CARAFE 上采样算子

在向日葵盘腐病分级检测任务中,上采样算子对多尺度病理特征的重建质量影响较大。YOLOv12n 模型采用的最近邻插值法虽提高了计算效率,但其作为无参数运算,在特征重建过程中缺乏对病斑边缘、纹理等关键

细节的语义感知与增强能力,导致病斑轮廓模糊,且对特征差异细微的病斑区分度不足,从而影响模型对病害等级的精准判别。

针对上述问题,本文引入轻量级上采样算子 CARAFE^[24],该模块由上采样核预测与特征重组两部分组成,其工作机制是通过内容编码的方式动态生成上采样核,并与输入特征图的局部区域进行重新组合,实现特征信息重建与传递。CARAFE 能够根据输入特征生成大感受野的内容感知核,在重建过程中自适应增强病斑边缘细节区域的特征表达,同时有效抑制背景噪声,提升模型对不同等级盘腐病的精准检测。CARAFE 上采样算子的工作流程如图 6 所示。




注: RFAConv 为感受野注意力卷积, RFAConv-Bottleneck 为添加感受野注意力卷积的瓶颈层, CA 为坐标注意力机制,下同。

Note: RFAConv refers to the receptive field attention convolution, RFAConv-Bottleneck refers to the bottleneck layer incorporating receptive field attention convolution, and CA indicates the coordinate attention mechanism. The same below.

图 5 C3K2-RC 网络结构图

Fig.5 C3k2-RC network structure diagram



注: X 表示输入特征图, C_m 为通道压缩后的特征图通道数, $N(\chi_l, k_{up})$ 表示以 χ_l 为中心、 k_{up} 为大小的局部邻域, σ 为上采样倍数, W'_l 表示上采样核预测模块生成的权重, X' 表示输出特征图。

Note: X refers to the input feature map, C_m is the number of channels of the feature map after channel compression, $N(\chi_l, k_{up})$ indicates the local neighborhood centered at χ_l with a size of k_{up} , σ is the upsampling factor, W'_l refers to the weights generated by the upsampling kernel prediction module, and X' refers to the output feature map.


图 6 CARAFE 上采样网络结构图

Fig.6 Network structure diagram of CARAFE upsampling

2.2.5 LSCSBD 检测头

YOLOv12n 模型沿用了 YOLOv11 的解耦头设计, 通过独立分支处理目标分类与回归任务, 虽有效提升了模型的学习能力和检测性能, 但并行的分支结构和卷积块堆叠会导致计算量和内存占用增加, 限制了模型的部署与应用。同时, 由于深度卷积的引入会导致感受野

的扩大, 从而削弱了输出端对小尺度目标的检测能力。为此, 本文采用了一种分离批量归一化的轻量级共享卷积检测头 LSCSBD^[25], 核心思想是使用共享卷积降低计算成本, 利用批量归一化激活模块提升模型在复杂场景下对小目标的检测性能。LSCSBD 检测头的结构如图 7 所示。



注: P3、P4、P5 为第 3、4 和 5 层输入特征图, Conv_BN 1×1 为批量归一化卷积层, Conv_GN 3×3 为组归一化共享卷积层, BnAct 为批量归一化和激活函数的组合模块, Conv-Reg 为回归卷积层, Conv-Cls 为分类卷积层, Scale 为缩放因子。

Note: P3, P4, and P5 refer to the feature maps at the 3rd, 4th, and 5th layers. Conv_BN 1×1 is the batch normalization convolutional layer, Conv_GN 3×3 is the group normalization shared convolutional layer, BnAct is the combination module of batch normalization and activation function, Conv-Reg is the regression convolutional layer, Conv-Cls is the classification convolutional layer, Scale is the scaling factor.

图 7 LSCSBD 检测头网络结构图

Fig.7 LSCSBD detection head network structure diagram

LSCSBD 接收颈部网络输入的不同尺度特征图后, 各分支首先通过批量归一化卷积调整通道维度, 整合来自颈部的特征信息。随后采用 3×3 共享卷积实现跨层级特征融合, 在减少参数量的同时增强语义特征; 融合后的特征经批量归一化激活模块完成分布校准与非线性变换。最后, 通过并行的 Conv-Reg 与 Conv-Cls 分支处理边界框回归与类别预测任务, 实现任务解耦。输出层通过 Scale 模块对特征进行缩放, 以适配不同层级的检测头对应的目标尺度分布。

2.3 试验环境与参数配置

2.3.1 试验运行环境

试验模型的运行环境如表 2 所示。为保证结果的可靠性, 后续对比试验均在同一软硬件环境下完成。

表 2 试验的软硬件配置参数

Table 2 Hardware and software configuration parameters for experiments

软硬件配置	参数
中央处理器	Intel(R)Core(TM)i7-11700k
图形处理器	NVIDIA GeForce RTX 3060 Ti
优化算法	SGD
操作系统	Ubuntu 18.04
配置环境	Pytorch 2.6.0+Python 3.10.16
训练轮次	200
批次大小	16
输入图像尺寸	1024×1024
初始学习率	0.01
动量系数	0.935
权重衰减次数	0.0005

2.3.2 模型评价指标

本研究通过精确率 (precision, P)、召回率 (recall,

R)、平均精度均值 (mean average precision, mAP)、检测速度 (frames per second, FPS)、参数量 (parameters)、浮点数运算量 (floating-point operations per second, FLOPs) 和权重文件大小 (model size) 对模型的性能进行评估。

3 结果与分析


3.1 YOLOv12n-RCL 与 YOLOv12n 性能对比

为验证模型改进前后的性能效果, 将 YOLOv12n 和 YOLOv12n-RCL 在本文自制的向日葵盘腐病数据集上进行训练, 从精确率、召回率、IoU=0.5 的平均精度均值和 IoU=0.5-0.95 的平均精度均值 4 个指标进行分析, 模型在 200 轮的训练变化趋势如图 8 所示。结合训练曲线和结果文件 (results.csv) 可知, 在精确率方面, YOLOv12n-RCL 虽在训练期间伴随一定的震荡波动, 但整体呈现出更快的上升趋势与更高的精度上限, 且在模型收敛后稳定性更强, 波动范围较基准模型明显缩小; 在召回率方面, YOLOv12n-RCL 模型在整个训练过程中始终优于 YOLOv12n, 且在 180 轮左右趋于稳定; 在检测精度方面, YOLOv12n-RCL 在 mAP_{0.5} 与 mAP_{0.5-0.95} 指标上均明显优于基础模型, 反映出其在不同交并比阈值下均具备更优的检测性能与边界框定位精度。综上所述, YOLOv12n-RCL 在训练稳定性、目标定位能力与多阈值检测精度方面均优于原模型, 验证了改进模块的有效性。

3.2 RFACConv 与 CA 重构不同位置 C3K2 的试验结果

本文将集成感受野卷积与坐标注意力机制的 C3K2-RC 替换 YOLOv12n 不同位置的 C3K2 模块, 分析其对

模型检测性能的影响。由表3可以看出,与单独替换主干或颈部网络的C3K2模块相比,同时替换取得了最优性能,其精确率 P 、召回率 R 及两种阈值下的平均精度均值 $mAP_{0.5}$ 和 $mAP_{0.5-0.95}$ 均达到最高值,分别为81.1%、77.8%、82.2%和48.3%,因此,将C3K2-RC模块协同作用于特征提取与特征融合两个阶段,能更有效地提升模型对盘腐病的检测能力。



注: $mAP_{0.5}$ 表示 IoU 阈值为 0.5 时的平均精度均值, $mAP_{0.5-0.95}$ 表示 IoU 阈值为 0.95 时的平均精度均值, 下同。
Note: $mAP_{0.5}$ represents the mean average precision at an IoU threshold of 0.5, and $mAP_{0.5-0.95}$ represents the mean average precision across IoU thresholds from 0.5 to 0.95. The same below.

图8 模型优化前后的性能评估结果

Fig.8 Performance comparison between the baseline and the optimized model

表3 C3K2-RC 模块不同引入位置的对比试验

Table 3 Comparative experiment on different positions for the introduction of the C3K2-RC module

替换位置 Replace position	$P/\%$	$R/\%$	$mAP_{0.5}/\%$	$mAP_{0.5-0.95}/\%$
主干	80.0	76.9	81.9	48.1
颈部	78.0	75.8	81.7	47.0
主干+颈部	81.1	77.8	82.2	48.3

3.3 C3K2-RC 模块的有效感受野对比试验

为验证 C3K2-RC 模块在扩展感受野方面的效果,并评估其对病斑特征提取方面的影响,本文设计了感受野对比试验。感受野表征卷积核对输入特征信息的感知范围,较小的感受野仅能覆盖有限的局部特征,而扩大感受野有助于整合更丰富的上下文信息,从而提升模型在复杂场景中对多尺度目标的判别能力^[26]。图9展示了原C3K2模块与引入 RFACnv、CA 及其组合模块的有效感受野对比结果。可以看出,与原始模型及引入单一模块相比,集成 RFACnv 与 CA 的 C3K2 感受野特征由高度集中的中心点,转变为更广泛且结构化的空间分布,在垂直与水平方向上均明显增强。这一变化表明 C3K2-RC 通过 RFACnv 卷积与 CA 注意力的协同作用,实现了感受野的系统性扩展,使模型能够融合更丰富的空间上下文信息,从而更准确地感知和捕捉多尺度病斑的形态与细节特征。





图9 C3K2 引入不同模块后的输出感受野

Fig.9 Output receptive field of C3K2 with the integration of different modules

3.4 CARAFE 特征层可视化结果

为验证 CARAFE 上采样算子在改善局部模糊、纹理细节弱化及背景噪声方面的效果,选取一张包含土壤和杂草干扰的样本图像进行特征图可视化分析,如图10所示。

模型特征响应强度通过区域的明暗程度体现,响应值越高,表明该区域信息对检测任务越关键。由图10可知,相较于基准模型 YOLOv12n,改进模型对向日葵目标的关注度明显提升,背景噪声减少,纹理特征也更为清晰。这得益于 CARAFE 上采样提升了特征图重构质量,使得高亮区域更集中于真实目标,从而有效降低了土壤、杂草等干扰区域的影响。



注: 图中红色框代表向日葵目标。

Note: The red frame in the image represents the sunflower target.

图10 添加 CARAFE 模块前后输入输出特征对比图

Fig.10 Comparison of input and output features before and after adding the CARAFE module

3.5 不同模块消融试验结果

为探究不同模块在所建立的向日葵盘腐病检测模型中的作用与贡献,本研究设置了多组消融试验,将不同改进模块集成至原 YOLOv12n 目标检测模型中进行训练,结果如表 4 所示。

由表 4 可知,从单模块改进效果来看,在 YOLOv12n 基础上引入 C3K2-RC 模块后,模型的精确率、mAP_{0.5} 和 mAP_{0.5-0.95} 分别增加了 1.5、1.2 和 2.1 百分点,召回率略微下降,参数量、计算量和模型大小略微增加。该结果表明,C3K2-RC 模块通过扩大感受野并引入坐标注意力机制,强化了模型对病害特征的提取能力,从而提升

了分类与定位精度;引入 CARAFE 模块替换原有的上采样模块后,模型在召回率、mAP_{0.5} 和 mAP_{0.5-0.95} 指标上分别增加了 0.4、0.2 和 0.8 个百分点,同时参数量、计算量和权重大小分别下降 13.2%、10.8% 和 12.5%,说明 CARAFE 上采样算子通过内容感知与特征重组机制,有效提升了特征图在重建过程中的信息完整性,减少了细节信息的丢失。使用轻量化 LSCSBD 模块替代原检测头后,模型在所有精度指标上均获得提升,其中精确率、召回率、mAP_{0.5} 和 mAP_{0.5-0.95} 分别提升 0.6、0.7、1.3 和 2.2 个百分点,同时模型参数量、计算量和权重大小略微下降。

表 4 消融试验结果

Table 4 Ablation test results

C3K2-RC	CARAFE	LSCSBD	P/%	R/%	mAP _{0.5} /%	mAP _{0.5-0.95} /%	参数量 Parameters/M	计算量 FLOPs/G	模型大小 Model size/MB
□	□	□	79.6	78.0	81.4	46.2	2.57	6.5	5.6
■	□	□	81.1	77.8	82.2	48.3	2.59	6.6	5.7
□	■	□	79.6	78.4	81.6	47.0	2.23	5.8	4.9
□	□	■	80.2	78.7	82.7	48.4	2.44	6.4	5.3
■	■	□	82.7	80.1	83.6	49.7	2.33	6.3	5.1
■	□	■	83.7	81.2	84.5	50.1	2.46	6.5	5.4
□	■	■	79.9	78.0	82.1	48.4	2.09	5.6	4.5
■	■	■	83.4	81.2	84.8	50.2	2.11	5.7	4.5

注:“■”表示采用了该模块,“□”表示未采用该模块,FLOPs 为浮点数运算次数。下同。

Note: “■” indicates that the module is adopted, “□” indicates that the module is not adopted, and FLOPs stands for the number of floating-point operations. The same below.

上述单一模块虽提升了模型的检测性能,但各模块改进效果有限。在多模块组合试验中,结合 C3K2-RC 与 LSCSBD 的 YOLOv12n 模型的精确率和召回率最高,分别达到了 83.7% 和 81.2%;融合 CARAFE 与 LSCSBD 的 YOLOv12n 模型轻量化性能最好,参数量、计算量和模型大小较基线模型分别下降 18.7%、13.8% 和 19.6%。最终,同时引入三个模块后,构建的 YOLOv12n-RCL 模型在精度 (mAP_{0.5} 为 84.8%, mAP_{0.5-0.95} 为 50.2%) 和效率 (参数量为 2.11M, 计算量为 5.7 G, 模型大小为 4.5 MB) 之间达到了最优平衡,证明了各模块在计算效率和特征提取方面的有效性和协同优势。上述过程可进一步依据热力图可视化结果^[27]印证:由图 11 可知,YOLOv12n-RCL 在向日葵花盘的高响应区域更为集中,漏检和误检激活明显减少,模型表现出更强的判别性区域聚焦能力。

3.6 不同模型对比试验

为探究不同主流模型在相同任务下的表现,将改进模型与 Faster R-CNN、SSD^[28]、RT-DETR^[29]、CenterNet^[30]、

YOLOv5s、YOLOv7-tiny、YOLOv8n、YOLOv9 t、YOLOv10n、YOLOv11n 和 YOLOv12n 进行对比试验,结果如表 5 所示。Faster R-CNN 二阶段网络结构参数量、计算量和权重文件较大,但检测性能较单阶段网络表现较差。与其相比,SSD、CenterNet 和 RT-DETR 网络的精确率和检测精度有较大提升,但模型对盘腐病检测的召回率依旧表现不佳,漏检率较高。从表中可以看出单阶段的 YOLO 系列相较于以上 4 种模型相对轻量,检测精度和模型大小更满足轻量化的部署需求,但模型的性能表现仍有进一步提升空间。




图 11 消融试验的可视化效果

Fig. 11 Visualization effect of the ablation study

表 5 不同检测网络的综合性能对比


Table 5 Comparative analysis of the overall performance of different detection networks

模型 Model	类型 Type	P/%	R/%	mAP _{0.5} /%	mAP _{0.5-0.95} /%	参数量 Parameters/M	计算量 FLOPs/G	模型大小 Model size/MB
Faster R-CNN	Two-Stage	70.1	65.6	68.8	40.2	137.1	370.2	114.2
SSD	One-Stage	73.1	66.4	72.1	42.3	24.0	61.1	105.2
CenterNet	One-Stage	72.1	67.1	75.6	43.7	32.7	70.2	90.6
RT-DETR(resnet50)	DETR	71.9	68.2	78.7	44.1	42.8	130.5	96.7
YOLOv5s	One-Stage	78.9	77.3	81.2	46.4	7.26	16.4	13.7
YOLOv7-tiny	One-Stage	80.1	81.0	80.5	45.5	6.02	13.2	11.7
YOLOv8n	One-Stage	79.1	78.0	81.4	46.7	3.01	8.2	6.3
YOLOv9 t	One-Stage	76.5	74.2	79.5	44.7	1.73	6.4	4.3
YOLOv10n	One-Stage	79.2	78.7	80.4	45.1	2.69	8.2	5.8
YOLOv11n	One-Stage	78.3	78.8	80.6	46.0	2.61	6.6	5.7
YOLOv12n	One-Stage	79.6	78.0	81.4	46.2	2.57	6.5	5.6
YOLOv12n-RCL	One-Stage	83.4	81.2	84.8	50.2	2.11	5.7	4.5

为兼顾向日葵盘腐病检测中的轻量化部署与高精度需求，本文提出 YOLOv12n-RCL 模型。与 YOLOv5s、YOLOv7-tiny、YOLOv8n、YOLOv9t、YOLOv10n、YOLOv11n 和 YOLOv12n 相比，本文改进模型在 $mAP_{0.5}$ 指标上分别比上述 7 种模型提升了 3.6、4.3、3.4、5.3、4.4、4.2 和 3.4 个百分点；在 $mAP_{0.5-0.95}$ 上分别增加了 3.8、4.7、3.5、5.5、5.1、4.2 和 4.0 个百分点。在精确率和召回率方面，改进模型的 P 、 R 也较于其他 7 种模型显著提升，比原模型 YOLOv12n 分别提高了 3.8 和 3.2 个百分点，达到了 83.4% 和 81.2%。此外，测试结果表明，YOLOv12n-RCL 模型的参数量、计算量和模型大小较基线模型分别降低了 17.9%、12.3% 和 19.6%，其复杂度低于除 YOLOv9t 以外的其他模型。综上所述，本研究所提出的 YOLOv12n-

RCL 模型在精准率、召回率、 $mAP_{0.5}$ 等核心检测指标上均实现最优，同时兼具较低的计算开销与模型大小，能够为向日葵盘腐病实时检测任务提供更加高效的解决方案。

为了直观地呈现 YOLOv12n-RCL 的实际检测效果，选取测试集图像进行检测验证，检测效果如图 12 所示。可以看出，主流的 YOLO 系列模型（图 12a~图 12g）在向日葵盘腐病图像数据集上检测性能低下，尤其在边缘目标检测和叶片遮挡情况下漏检和误检严重。相比之下，YOLOv12n-RCL 在 3 种场景下均有良好的表现，在处理边缘目标检测、叶片遮挡以及病斑特征差异细微等复杂场景时表现出更优异的检测性能与分类效果。试验结果验证了改进模块对于提升模型性能的有效性，从而获得了更高的检测置信度与更强的稳定性。



注：图中蓝色圆表示漏检，红色三角表示错检。
Note: In the figure, The blue circle indicates missed detections, while the red triangle indicates false detections.

图 12 不同目标检测模型识别效果对比
Fig.12 Performance comparison of different object detection models

3.7 基于混淆矩阵的模型性能评估与误检分析

为分析改进模型对向日葵盘腐病不同危害程度的误检情况，引入 YOLOv12n-RCL 的混淆矩阵进行评估，结果如图 13 所示。




图 13 不同等级病害的混淆矩阵
Fig.13 Confusion matrix for different disease severity grades

YOLOv12n-RCL 在 0 级（无病）、1 级、2 级、3 级和 4 级的召回率分别为 83.0%、81.2%、79.1%、80.7% 和 82.0%，模型对 5 个等级的识别能力较为均衡。此外，真实标签为 2 级的样本中有 8.2% 被误判为 3 级，真实标签为 3 级的样本中有 9.3% 被误判为 2 级。因此，YOLOv12n-RCL 对不同等级病害的混淆主要发生在 2 级和 3 级，而在其余等级的判定上，该模型的误判率均在 10% 以内，体现出其对不同危害程度的盘腐病具备良好的区分性能。该归一化混淆矩阵为后续针对性地优化中等程度的病害等级检测模型提供了依据。

3.8 盘腐病害检测模型边缘部署与结果分析

为检验 YOLOv12n-RCL 在移动端的实际性能，分别将其与基线模型部署于 Jetson Orin Nano 开发板进行对比试验。首先将训练得到的权重文件转换为 onnx 格式文件，通过 onnx-simplifier 工具优化节点；其次，使用 TensorRT 提供 trtexec 工具将 onnx 模型文件转换为 engine 引擎文件，并采用 INT8 量化以提升计算效率。测试结果显示，

YOLOv12n-RCL 的检测速度达到 27.5 帧/s, 较基准模型 YOLOv12n (18.7 帧/s) 提升了 47.1%, 已基本满足盘腐病的实时检测需求。最后, 通过 PyQt5 开发的盘腐病检测系统进一步验证模型的性能, 如图 14 所示。该系统由两个模块组成: 系统功能模块和病害可视化检测模块。系统功能模块包括导入模型、单张图像检测、多图像检测、视频检测、保存检测图像以及退出系统; 病害可视化检测模块能够同时显示原始图像和病害检测结果, 并实现对图像中盘腐病等级和数量的统计, 可用于辅助评估病害密度。在包含 1 298 个不同等级盘腐病样本的 70 幅测试图像中, YOLOv12n 模型漏检、错检数量分别为 35 和 30, 而 YOLOv12n-RCL 仅 10 例漏检、8 例错检。综合评价, 本研究提出的 YOLOv12n-RCL 模型在 Jetson Orin Nano 嵌入式平台表现出更优的检测性能、更快的推理速度, 拥有更好的部署前景。





图 14 向日葵盘腐病检测系统界面

Fig.14 Sunflower disk rot detection system interface

3.9 基于特征图像拼接的向日葵盘腐病区域可视化及分析


为进一步验证 YOLOv12n-RCL 模型在无人机原始影像中的应用性能与可靠性, 设计了一套基于分块检测与拼接重组策略的盘腐病监测流程, 其工作原理如下: 首先, 从航拍数据中随机选取研究区域, 利用 ArcGIS 软件将其裁剪为符合模型输入尺寸的图像序列; 随后, 将图像序列导入盘腐病检测系统, 采用本文改进模型依次完成病害目标检测与危害程度分级; 最后, 基于 Pix4D 软件, 依据坐标信息对检测后的图像块进行特征匹配与拼接, 重构出包含不同危害程度盘腐病的空间分布影像如图 15a 所示。从局部放大图可看出, 在目标分布密集、叶片遮挡等复杂场景下, 改进模型仍保持稳定的检测性能, 未出现明显漏检或误检。此外, 图 15b 展示的大田与局部特征响应可视化结果, 进一步验证了模型对病斑关键特征的提取能力。

基于无人机拼接影像的监测方法能够直观、定量地呈现病害在田间的空间分布特征。模型输出的病害等级分布矢量数据可进一步转换为田间作业处方图, 为植保无人机的精准变量施药提供准确的地理坐标与决策依据, 有助于降低农药使用量, 提升防治效率。



a: 大田病害检测与分级结果

a: Field-scale disease detection and grading results



b: 大田识别效果可视化

b: Visualization of field-scale recognition performance

图 15 向日葵盘腐病区域监测与分级结果可视化

Fig.15 Visualization of monitoring and grading results for sunflower disk rot regions

4 讨论

本文提出了一种轻量化高效能的盘腐病检测模型 YOLOv12n-RCL, 用于无人机遥感影像中不同危害程度向日葵盘腐病的实时精准识别。为支持模型训练与评估, 依据病斑占花盘面积的比例构建涵盖五种病害等级的数据集, 从而模拟田间复杂环境下盘腐病的真实场景。尽管现有研究在利用深度学习识别病害方面已取得一些进展, 但针对向日葵病害的系统研究相对匮乏, 且存在局限。例如, ZHOU 等^[31]提出了一种基于扩散模型与少样本学习的向日葵叶部病害检测网络 FSDDN, 该模型在 IoU 阈值为 0.75 时的平均精度均值达到 92%, 实现了对病害类别的精准识别, 但其多步迭代特征对硬件资源消耗较高, 难以满足边缘设备的实时部署需求。ZHANG^[32]等为了解决向日葵病害识别模型在移动端部署困难的问题, 构建了基于迁移学习的轻量级卷积神经网络性能对比方法。结果表明, EfficientNetV2-Small 模型在霜霉病、灰霉病等主要叶部病害识别任务中表现优异, 展现出较高分类准确率与部署效率。然而, 该研究所采用的训练数据集规模有限, 且样本均源自国外公开数据集, 导致模型对区域性特定病害的泛化能力不足。相比之下, 本研

究通过无人机平台构建了不同等级的盘腐病害样本, 所开发的 YOLOv12n-RCL 模型在面对特征差异细微、叶片干扰及病斑形态变化时表现出较强的泛化能力, 并能够适配计算资源受限的移动端, 可为向日葵盘腐病的实时监测与快速诊断提供技术支撑。

由于无人机数据均基于固定航高获取, 本研究尚缺乏不同飞行高度对模型检测精度影响的对比分析; 另外, 当前研究仅针对花盘下垂的成熟期向日葵, 尚未对花盘朝上的花期及灌浆前期展开有效采集, 模型在向日葵全生育期内的普适性还有待验证。针对上述问题, 后续研究将从以下几方面展开: 一是涵盖不同飞行高度的无人机影像采集, 以提升检测模型在多种高度场景下的鲁棒性; 二是获取向日葵花盘全生育期的多视觉影像, 针对花盘朝上的花期与灌浆初期, 引入多视角成像技术, 获取花盘正面及侧面的结构信息, 为模型提供更具时序完整性与形态多样性的训练数据, 三是结合模型压缩与知识蒸馏策略, 进一步提升模型在边缘计算设备上的实时检测性能。

5 结 论

本文提出了一种基于改进 YOLOv12n 的向日葵成熟期盘腐病危害程度检测方法, 主要研究结果如下:

1) YOLOv12n-RCL 模型在自制的向日葵盘腐病数据集上的训练结果表明, 与 YOLOv12n 模型相比, 改进后的算法在精确率 P 、召回率 R 、两种阈值下的平均精度均值 $mAP_{0.5}$ 和 $mAP_{0.5-0.95}$ 分别提升了 3.8、3.4、3.2 和 4.0 个百分点, 同时参数数量、计算量和模型大小分别减少了 17.9%、12.3% 和 19.6%。

2) 与 Faster R-CNN、CenterNet、SSD、RT-DETR、YOLO 系列的算法相比较, YOLOv12n-RCL 算法的精确率 P 、召回率 R 、 $mAP_{0.5}$ 和 $mAP_{0.5-0.95}$ 分别达到 83.4%、81.2、84.8% 和 50.2%, 均优于其他模型。

3) 归一化混淆矩阵病害等级误检结果表明, YOLOv12n-RCL 模型在 0 级、1 级、2 级、3 级和 4 级的召回率分别为 83.0%、81.2%、79.1%、80.7% 和 82.0%, 且易混淆类别间的错误预测比例最高不超过 10%, 表明 YOLOv12n-RCL 在区分不同等级盘腐病方面的良好性能。

4) 在 Jeston Orin Nano 边缘计算设备的部署试验表明, 通过 TensorRT 高性能算子加速后的 YOLOv12n-RCL 检测速度为 27.5 帧/s, 较基线模型提升了 47.1%, 且对不同等级盘腐病的检测结果更符合实际需求, 拥有更好的部署前景。

【参 考 文 献】

- [1] 李丹, 赵存鹏, 刘素恩, 等. 39 份油用向日葵杂交种主要农艺性状与产量的多元分析[J]. 华北农学报, 2023, 38(S1): 154-160.
- [2] 王彦尊, 王文浩, 何丽芬, 等. 不同向日葵品系对菌核病抗性的综合鉴定[J]. 中国种业, 2023(12): 130-135.
- [3] 史明. 向日葵病害综合防治技术[J]. 农业开发与装备, 2015(10): 146.
- [4] 魏伟业. 试论向日葵几种常见病及防治方法[J]. 农民致富之友, 2019(2): 13.
- [5] FERENTINOS K P. Deep learning models for plant disease detection and diagnosis[J]. *Computers and Electronics in Agriculture*, 2018, 145: 311-318.
- [6] UPADHYAY A, CHANDEL N S, SINGH K P, et al. Deep learning and computer vision in plant disease detection: a comprehensive review of techniques, models, and trends in precision agriculture[J]. *Artificial Intelligence Review*, 2025, 58(3): 92.
- [7] 朱锐, 张家瑜, 黄继超, 等. 基于卷积神经网络的农作物叶片病害检测研究进展[J]. 农业工程学报, 2025, 41(17): 15-28.
ZHU Rui, ZHANG Jiayu, HUANG Jichao, et al. Research progress of crop leaf disease detection based on convolutional neural network[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(17): 15-28. (in Chinese with English abstract)
- [8] GUAN B, WU Y, ZHU J, et al. GC-Faster RCNN: The object detection algorithm for agricultural pests based on improved hybrid attention mechanism[J]. *Plants*, 2025, 14(7): 1106.
- [9] 兰玉彬, 孙斌书, 张乐春, 等. 基于改进 YOLOv5s 的自然场景下生姜叶片病虫害识别[J]. 农业工程学报, 2024, 40(1): 210-216.
LAN Yubin, SUN Binshu, ZHANG Lechun, et al. Identifying diseases and pests in ginger leaf under natural scenes using improved YOLOv5s[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2024, 40(1): 210-216. (in Chinese with English abstract)
- [10] GONG X, ZHANG S. A high-precision detection method of apple leaf diseases using improved Faster R-CNN[J]. *Agriculture*, 2023, 13(2): 240.
- [11] 吴世琛, 毛玉明, 胡慧中, 等. 基于改进 YOLO11n 的葡萄果叶病害检测方法[J]. 农业工程学报, 2025, 41(14): 140-147.
WU Shichen, MAO Yuming, HU Huizhong, et al. Detecting grape leaf diseases using improved YOLO11n[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(14): 140-147. (in Chinese with English abstract)
- [12] CHEN S, LV F, HUO P. Improved detection of YOLOv4 sunflower leaf diseases[C]//2021 2nd International Symposium on Computer Engineering and Intelligent Communications (ISCEIC). Nanjing, China: IEEE, 2021: 56-59.
- [13] 于海琳, 兰玉彬, 李京谦, 等. 基于无人机遥感数据和机器学习的向日葵 LAI 反演[J]. 农业机械学报, 2025, 56(1): 356-365.
YU Hailin, LAN Yubin, LI Jingqian, et al. Sunflower LAI inversion based on unmanned aerial vehicle remote sensing

- data and machine learning[J]. Transactions of the Chinese Society for Agricultural Machinery, 2025, 56(1): 356-365. (in Chinese with English abstract)
- [14] 胡根生, 谢一帆, 鲍文霞, 等. 基于轻量型网络的无人机遥感图像中茶叶枯病检测方法[J]. 农业机械学报, 2024, 55(4): 165-175.
- HU Gensheng, XIE Yifan, BAO Wenxia, et al. Lightweight network for tea leaf blight detection in UAV remote sensing images[J]. Transactions of the Chinese Society for Agricultural Machinery, 2024, 55(4): 165-175. (in Chinese with English abstract)
- [15] PAN P, GUO W, ZHENG X, et al. Xoo-YOLO: A detection method for wild rice bacterial blight in the field from the perspective of unmanned aerial vehicles[J]. *Frontiers in Plant Science*, 2023, 14: 1256545.
- [16] 陈自立, 郭燕, 王明鑫, 等. 基于 RT-YOLOv10 和无人机遥感影像的烟草病害轻量化检测研究[J]. 山东农业科学, 2025, 57(9): 149-163.
- [17] YANG Z, KHAN Z, SHEN Y, et al. GTDR-YOLOv12: Optimizing YOLO for efficient and accurate weed detection in agriculture[J]. *Agronomy*, 2025, 15(8): 1824.
- [18] 李易初, 孟庆林, 石凤梅, 等. 田间防治向日葵菌核盘腐病的药剂筛选[J]. 宁夏农林科技, 2015, 56(7): 53-54.
- [19] 赵静, 李京谦, 杨蕾, 等. 基于 PConv-CGLU 与重参数检测头的轻量化膜下棉苗实时检测算法[J]. 农业工程学报, 2025, 41(18): 151-162.
- ZHAO Jing, LI Jingqian, YANG Lei, et al. Real-time detecting cotton seedlings under a lightweight film using PConv-CGLU with a heavy parameter detection head[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(18): 151-162. (in Chinese with English abstract)
- [20] 刘伟恒, 刘立波. 基于改进 YOLOv12 的遮挡环境下肉牛目标检测方法[J]. 智慧农业 (中英文), 2025, 7(5): 182-192.
- LIU Yiheng, LIU Libo. Beef cattle object detection method under occlusion environment based on improved YOLOv12[J]. *Smart Agriculture*, 2025, 7(5): 182-192. (in Chinese with English abstract)
- [21] NING M, MA H, WANG Y, et al. A raisin foreign object target detection method based on improved YOLOv8[J]. *Applied Sciences-Basel*, 2024, 14(16): 7295.
- [22] WEN G, LI S, LIU F, et al. YOLOv5s-CA: A modified YOLOv5s network with coordinate attention for underwater target detection[J]. *Sensors*, 2023, 23(7): 3367.
- [23] 邓阳君, 王旭, 龙陈锋, 等. 基于 VCDM-UNet 的水稻叶瘟病斑分割和病害程度分级[J]. 农业工程学报, 2024, 40(23): 190-198.
- DENG Yangjun, WANG Xu, LONG Chenfeng, et al. Segmenting and grading the blast disease of rice leaves using VCDM-UNet[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(23): 190-198. (in Chinese with English abstract)
- [24] 李兆东, 赵前华, 周硕, 等. 基于 YOLOv7-DH 模型的油菜苗期冻害分级检测[J]. 农业工程学报, 2025, 41(18): 185-192.
- LI Zhaodong, ZHAO Qianhua, ZHOU Shuo, et al. Classifying seedling freeze damage in oilseed rape using YOLOv7-DH model[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(18): 185-192. (in Chinese with English abstract)
- [25] JIN X, YU F, SUO Y, et al. SCL-YOLOv8n based rice disease lightweight detection method[J]. *Measurement Science and Technology*, 2025, 36(5): 056006.
- [26] 朱祥建, 任玲, 张玉泉, 等. 基于改进 RT-DETR 的番茄穴盘苗实时分级检测[J]. 农业工程学报, 2025, 41(22): 204-214.
- ZHU Xiangjian, REN Ling, ZHANG Yuquan, et al. Real-time detection and grading of tomato plug seedlings based on improved RT-DETR[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(22): 204-214. (in Chinese with English abstract)
- [27] 那日苏, 翟立浩, 邢海鹏, 等. 基于改进 YOLOv5 网络的牧区牛粪检测方法[J]. 农业工程学报, 2024, 40(22): 145-153.
- NA Risu, ZHAI Lihao, XING Haipeng, et al. Detecting cattle manure in pastoral areas using the YOLO network[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(22): 145-153. (in Chinese with English abstract)
- [28] 余永维, 陈天皓, 杜柳青, 等. 基于深度学习加速模型的杂乱目标实时视觉检测方法[J]. 农业机械学报, 2025, 56(5): 617-624.
- YU Yongwei, CHEN Tianhao, DU Liuqing, et al. Real time visual detection for cluttered targets based on deep learning acceleration model[J]. Transactions of the Chinese Society for Agricultural Machinery, 2025, 56(5): 617-624. (in Chinese with English abstract)
- [29] 胡继文, 张国梁, 李文浩, 等. 松木板材缺陷检测及纵锯加工排样系统设计与试验[J]. 农业工程学报, 2025, 41(20): 75-85.
- HU Jiwen, ZHANG Guoliang, LI Wenhao, et al. Design and experiment of defect detection and longitudinal sawing system for pine wood panels[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(20): 75-85. (in Chinese with English abstract)
- [30] SHI T, GONG J, HU J, et al. Feature-enhanced centernet for small object detection in remote sensing images[J]. *Remote Sensing*, 2022, 14(21): 548.
- [31] ZHOU H, LI W, LI P, et al. A novel few-shot learning framework based on diffusion models for high-accuracy sunflower disease detection and classification[J]. *Plants*, 2025,

14(3): 339.

sunflower disease identification: A comparative study[J].

[32] ZHANG L, WU X. The lightweight deep learning model in

Applied Sciences-Basel, 2025, 15(4): 2104.

Detection of sunflower disk rot severity at the mature stage based on UAV imagery and YOLOv12n-RCL

LI Jingqian^{1,2}, HAN Guotao^{1,2}, ZHAO Jing^{1,2,3*}, ZHANG Shuailing^{1,2}, XIE Xinyu⁴,
FU Shanshan⁴, LU Liquan⁴, LAN Yubin^{1,2}

(1. College of Agricultural Engineering and Food Science, Shandong University of Technology, Zibo 255000, China; 2. Shandong Province Engineering Technology Research Center for Agricultural Aviation Intelligent Equipment, Shandong University of Technology, Zibo 255000, China; 3. Institute of Modern Agricultural Equipment, Shandong University of Technology, Zibo 255000, China; 4. School of Transportation and Vehicle Engineering, Shandong University of Technology, Zibo 255000, China)

Abstract: Sunflower is one of the major oil crops, valued for its strong tolerance to nutrient-poor soils and drought, making it a preferred crop for the remediation of mildly to moderately saline-alkali soils. Sunflower disk rot, caused by *sclerotinia sclerotiorum* infection, leads to increased sterile seed rates, reduced yield, and a decline in nutritional components such as kernel protein and oil content, thereby compromising both the edible and commercial value of the seeds. Consequently, efficient and accurate assessment of disk rot severity is crucial for early disease control, precision pesticide application, and yield estimation. To address the inefficiency and subjectivity of traditional disease classification methods, this study proposes an improved YOLOv12n-based model for detecting the severity of sunflower disk rot at the mature stage. First, the C3K2 modules in the backbone and neck networks were replaced with C3K2-RC modules, which integrate receptive-field attention convolution (RFACnv) and coordinate attention (CA) mechanisms to enhance the model's feature extraction capability for different severity grades of disk rot in complex environments. Second, a lightweight upsampling operator, CARFAE, was integrated into the neck network to improve feature reconstruction. Finally, a lightweight shared convolutional detection head with separated batch normalization (LSCSBD) was introduced to improve the detection accuracy and speed for small-scale lesions. Experimental results show that the YOLOv12n-RCL model achieved precision, recall, mAP_{0.5}, and mAP_{0.5-0.95} of 83.4%, 81.2%, 84.8%, and 50.2%, respectively, representing improvements of 3.8, 3.2, 3.4, and 4.0 percentage points over the baseline model. The number of parameters, computational complexity, and model size were reduced to 2.11 M, 5.7 G, and 4.5 MB, corresponding to reductions of 17.9%, 12.3%, and 19.6% compared to the original model. Analysis based on the normalized confusion matrix indicated that the recall for disease severity grades 0, 1, 2, 3, and 4 were 83.0%, 81.2%, 79.1%, 80.7%, and 82.0%, respectively, demonstrating a balanced recognition capability across all five grades. Furthermore, 8.2% of samples with a true label of grade 2 were misclassified as grade 3, and 9.3% of samples with a true label of grade 3 were misclassified as grade 2. Therefore, confusion between severity grades occurred primarily between grades 2 and 3, while for the remaining grades, the model's misclassification rate remained below 10%, reflecting its strong discriminative ability for disk rot at different grades. In tests conducted on 70 images containing 1 298 samples of different grades of disk rot, YOLOv12n-RCL achieved only 10 missed detections and 8 false detections. Compared to the baseline YOLOv12n model, it demonstrates superior detection performance and a higher frame rate, reaching 27.5 frames per second (FPS). Visualization and analysis of sunflower disk rot areas based on UAV orthophoto imagery demonstrated that the improved model maintained stable detection performance even in complex scenarios with dense target distribution and leaf occlusion, without significant missed or false detections. In summary, the YOLOv12n-RCL model improves detection accuracy while effectively balancing lightweight design and deployment efficiency. It can serve as an algorithmic reference for the development of intelligent control equipment targeting sunflower disk rot at the mature stage.

Keywords: UAV; sunflower; remote sensing imagery; disk rot at the mature stage; YOLOv12n; classification of disease severity