

专业学位
硕士学位论文
论文

低空航拍可见光图像快速检测甘蔗 幼苗群体数量

朱能志

廣西大學

二〇二一年六月

分类号 TP391

密级

UDC 621.3

专业学位硕士学位论文

低空航拍可见光图像快速检测甘蔗 幼苗群体数量

朱 能 志

专业学位(领域)名称 控制工程

指导教师 李修华 副教授

论文答辩日期 20210608 学位授予日期 20210624

答辩委员会主席 周永华

低空航拍可见光图像快速检测甘蔗幼苗群体数量

摘 要

甘蔗的出苗数及出苗率一直是甘蔗农学家及种植户非常关注的参数。本文以大田甘蔗幼苗的航拍图像为技术手段，研究了深度学习方法检测甘蔗幼苗的方法。主要研究内容如下：

(1) 通过低空航拍获取了不同地块甘蔗幼苗的高精度 RGB 图像，使用自适应对比度增强、子图裁剪等预处理，制作了 600×600 像素大小的子图样本集三类，其中训练集 2392 张，训练集扩充后 14352 张，验证集 398 张，测试集 2340 张。训练集与验证集样本全部进行了检测对象的标注，用于检测模型的训练与验证；测试集样本未作标注，用于模型的测试及包含去重算法的甘蔗总苗数统计精度的评价。

(2) 研究了 Faster R-CNN 深度学习算法识别子图像中甘蔗幼苗的可行性，并根据大田蔗苗的特点对该网络进行了改进。将 ResNet50 替换原来的 VGG16 作为骨干网络；接着将基于通道注意力机制的 SN-Block 模块嵌入特征提取层；然后使用特征金字塔融合结构进行多尺度特征融合以兼顾低层网络的位置信息和高层网络的语义信息；最后通过统计数据集中目标框的宽高比修改 RPN 层中先验框的初始形状。将改进前后的检测模型进行了性能对比，发现本文提出的模型平均检测精度达到 93.67%，比 Faster R-CNN 提高了 8.69%。

(3) 研究了大尺度航拍图像识别结果的合并与去重方法。该方法应用于

带重叠度裁剪的子图目标识别结果。该方法基于非极大值抑制机制将合并到原图的检测结果进行重复边框的去重，从而实现对大田甘蔗幼苗群体的计数。该方法 IoU 阈值的不同对总体的计数精度有影响，实验结果表明，当阈值为 0.15 时检测和计数性能均表现最好。F1 分数达到 93.66%，计数准确率高达 96.83%，而平均绝对误差仅为 4.6 株。

(4) 最后针对前述识别与统计方法，开发了一套大田甘蔗幼苗检测与计数系统软件。可以实现用户自定义数据集制作、模型训练、检测与计数等功能。

综合可得，本文提出的方法能够提高大田甘蔗幼苗的识别和计数准确率，可以为后期甘蔗栽培管理和育种提供重要数据支持。

关键词：甘蔗 卷积神经网络 目标检测 幼苗计数 无人机

SUGARCANE SEEDLING POPULATION NUMBER DETECTION BASED ON LOW-ALTITUDE RGB IMAGES

ABSTRACT

The number and rate of emergence of sugarcane has always been a parameter of great interest to sugarcane agronomists and growers. Based on aerial images of sugarcane seedlings in field, this paper studies the method of deep learning to detect sugarcane seedlings. The main research contents are as follows:

(1) High resolution RGB images of sugarcane seedlings in different plots were obtained by low altitude aerial photography. Three kinds of 600×600 pixels subgraph sample sets were produced by using adaptive contrast enhancement and subgraph cropping. The training set contains 2392 subgraphs, and the training set is expanded with 14352 subgraphs. The validation set contains 398 subgraphs, and the test set contains 2340 subgraphs. The samples of training set and validation set are labeled with the detection object, which is used to train and validation the detection model; The test set samples are unlabeled and used for testing the model and evaluating the statistical accuracy of the total number of sugarcane seedlings including the de-duplication algorithm.

(2) The feasibility of the Faster R-CNN deep learning algorithm to identify sugarcane seedlings in sub-images is investigated, and the network is improved according to the characteristics of sugarcane seedlings in large fields. Firstly,

ResNet50 is replaced by VGG16 as the backbone network; Secondly, the SN-Block module based on channel attention mechanism is embedded into the feature extraction layer; Thirdly, the feature pyramid fusion structure is used for multi-scale feature fusion to take into account the location information of low-level network and the semantic information of high-level network; Finally, the initial shape of the anchor in the RPN layer is modified according to the aspect ratio of all labeled boxes in the dataset. Comparing the performance of the improved detection model with that of the original one, it is found that the average precision of the proposed model reaches 93.67%, which is 8.69% higher than that of Faster R-CNN.

(3) The method of merging and de-duplicating the recognition results of large scale aerial images is studied. The method is applied to the subgraph object recognition results with overlap cropping. The method is based on a non-maximal suppression mechanism to de-duplicate the detection results merged to the original map with bounding box, thus achieving the counting of the sugarcane seedling population in the field. The different IoU thresholds of the method have an impact on the overall counting accuracy, and the experimental results show that both detection and counting performance perform best when the threshold value is 0.15. The F1 score reached 93.66% and the counting accuracy was as high as 96.83%, while the average absolute error was only 4.6 plants.

(4) Finally, a field sugarcane seedling detection and counting system software was developed for the aforementioned recognition and statistical

methods. It can realize the functions of user-defined data set making, model training, detection and counting.

It can be concluded that the method proposed in this paper can improve the recognition and counting accuracy of sugarcane seedlings in the field, and provide important data support for sugarcane cultivation management and breeding in the later stage.

KEY WORDS: Sugarcane; Convolutional Neural Network; Object Detection; Seedling Count; UAV

目 录

第一章 绪论.....	1
1.1 课题研究的背景与意义.....	1
1.2 国内外研究与发展现状.....	2
1.2.1 作物表型评估中无人机技术的应用现状	2
1.2.2 深度学习目标检测方法的研究现状.....	3
1.3 存在的问题与挑战.....	6
1.4 主要研究内容和技术路线	7
1.4.1 主要的研究内容.....	7
1.4.2 研究技术路线.....	9
1.5 论文的层次结构安排.....	10
第二章 目标检测相关理论基础	12
2.1 神经网络的理论基础.....	12
2.1.1 感知机模型.....	12
2.1.2 BP 算法.....	13
2.2 卷积神经网络基础.....	16
2.3 目标检测算法介绍.....	18
2.3.1 传统目标检测方法.....	18
2.3.2 基于候选区域的深度学习目标检测.....	19
2.4 Faster R-CNN 目标检测算法	20
2.4.1 Faster R-CNN 算法的网络结构	20
2.4.2 Faster R-CNN 算法介绍	21
2.5 本章小结.....	23
第三章 图像预处理与数据集制作	24
3.1 数据采集.....	24
3.2 图像数据的预处理.....	26
3.2.1 图像自适应对比度增强.....	26
3.2.2 图像裁剪.....	28
3.2.3 图像的翻转与旋转	31
3.3 数据标注.....	32
3.4 本章小结.....	33
第四章 基于改进 Faster R-CNN 的甘蔗幼苗检测算法设计.....	34
4.1 概述.....	34
4.2 基于 Faster R-CNN 网络的甘蔗幼苗检测	34
4.3 基于改进 Faster R-CNN 网络的甘蔗幼苗检测算法设计	36

4.3.1 网络模型的整体结构.....	36
4.3.2 基于 Res Net50 的特征提取.....	37
4.3.3 SN-Block 注意力模块的引入.....	39
4.3.4 多尺度特征融合.....	40
4.3.5 改进 RPN 区域建议网络.....	43
4.4 实验设计与结论.....	44
4.4.1 实验方案的设计.....	44
4.4.2 模型检测性能的评估.....	46
4.4.3 实验结果对比与分析.....	47
4.5 本章小结.....	50
第五章 基于 SGN-D 模型的大田甘蔗幼苗计数方法.....	51
5.1 概述.....	51
5.2 大田甘蔗幼苗群体的检测与计数.....	51
5.2.1 检测结果合并.....	52
5.2.2 非极大值抑制的原理及实现方法.....	54
5.2.3 基于非极大值抑制的去重算法设计.....	55
5.2.4 结果与讨论.....	56
5.3 蔗苗自动检测与计数系统软件设计.....	61
5.3.1 自定义模型的训练.....	62
5.3.2 甘蔗幼苗的检测与统计.....	66
5.4 本章小结.....	68
第六章 总结与展望.....	69
6.1 全文总结.....	69
6.2 后续工作展望.....	70
6.3 本文创新点.....	70
参考文献.....	72

第一章 绪论

本章先主要介绍对甘蔗幼苗的航拍图像进行目标检测的研究背景和意义，然后分析了无人机技术及深度学习目标检测技术在植物表型领域应用及发展现状，接着总结论文的主要研究内容并分析研究中的难题，最后介绍全文的主要结构。

1.1 课题研究的背景与意义

甘蔗作为一种主要的糖料作物，其种植面积占我国糖料作物种植面积的 85%以上，产糖量占食糖总产量的 90%以上^[1]。另外，它的光能转换效率和光合速率均比较高且具有高净能比，因此被认为是最重要的生物能源作物之一^[2]。然而我国的甘蔗行业却因为病虫害问题、缺乏良种以及高种植成本等限制因素在国际市场上竞争性不强^[3]。

甘蔗品种是甘蔗生产的基础。甘蔗良种对大幅度提高甘蔗产量与蔗糖分具有十分显著的作用，可以大大降低吨蔗生产成本和吨糖生产成本^[4-6]。据甘蔗育种家们估测，从世界范围来说，蔗糖业的发展大约有 30%的功劳归功于甘蔗优良品种的推广应用^[7]。所以加快甘蔗优势品种的培育和筛选，对甘蔗产业至关重要。不同的品种其抗逆性、出苗率、分蘖率、株高、茎径、株数等表型参数会有所区别。农学家在甘蔗育种过程中会调查这些表型数据，并结合基因型数据对品种优劣进行综合评价与筛选。

甘蔗的常见栽培方式是采用上一年的蔗种（包含种芽的蔗茎）平植或斜植于土壤中实现种植。由于品种、病害、气候等的影响，甘蔗的出苗率会有所不同。甘蔗在生长早期易受病毒和虫害的威胁，如甘蔗黄叶病毒（ScYLV）^[8]；而且湿热的气候环境会引起甘蔗凤梨病、梢腐病、黑穗病等病菌更加活跃^[9]，从而会侵害蔗芽使其不能萌发，造成出苗率低，进而影响产量。因此，有效地评价甘蔗的出苗率，对甘蔗育种及大田生产均具有重要意义。

传统的出苗情况的调查统计主要依赖于人工，这在田间大规模实地测量时既耗时又繁琐，也限制了样本的采样规模，数据的稀疏和人工测量的偏差都会影响数据的准确度^[10]。近几年兴起的基于深度学习的目标检测技术为农作物目标检测提供了新的思路，在作物表型分析中取得了较好的成果。甘蔗幼苗数量检测方式的选取需要考虑田间作业的实时性、农业领域的低成本等特殊需求^[11]。为了快速、无损、准确地追踪田间甘蔗幼苗的出苗情况，需要对田间幼苗进行精准地识别定位，并能在较短时间内输出计数结果。

低空无人机航拍可以快速采集高分辨率的大田作物图像，并可以通过图像拼接得到大田高清全景图。Faster R-CNN 作为目标检测中的常用模型之一，具有定位准确率和检测效率高的特点^[12]，在农业中已有不少研究报道，如果实产量的估算^[13]、害虫^[14]和杂草的检测^[15]等。因此，本课题采用无人机航拍与深度学习方法相结合的方式对大田蔗苗进行识别并计数，以期替代人工统计，降低时间和人力成本，为后期甘蔗栽培管理和育种提供重要数据支持。因此，快速检测甘蔗幼苗的株数对确定出苗率，指导田间管理和育种都具有非常重要的意义。

本研究在国家自然科学基金项目“低空航拍图像融合田间环境及气象信息立体构建甘蔗长势、品质及产量预测模型（项目编号：31760342）”以及广西科技重大专项“广西甘蔗生物学重点实验室重大科技创新基地”（项目编号：桂科 2018-266-Z01）的资助下完成。

1.2 国内外研究与发展现状

1.2.1 作物表型评估中无人机技术的应用现状

无人机技术在获取大量信息方面具有优势，尤其在近几十年，无人机的广泛应用加速了农业表型分析技术的发展^[16, 17]。配备传感器的轻型无人机平台为高通量表型分析提供更加灵活和经济的解决方案，越来越多地应用于田间表型评估^[18-20]。Barrero 等^[21]提出将低分辨率多光谱图像和高分辨率 RGB 图像融合用来检测水稻出苗后的田间禾本科杂草。首先对 RGB 图像进行强度、色调、饱和度（HIS）变换分解；然后对强度层（I）和归一化绿红差异指数（NGRDI）图像进行二阶 Haar 小波变换；在这个变换中，NGRDI 图像的 low-low 系数（LL）被强度层（I）LL 系数代替，通过将新的小波系数变换到 RGB 空间得到融合后的图像；在验证阶段设计出神经网络比较融合图像用来检测杂草的性能。实验结果表明 RGB 图像和 NGRDI 图像融合后的图像用神经网络检测杂草的性能最好，该方法只能检测杂草区域的面积不能对每株杂草进行精准定位，并且在验证区域上会出现过度检测的问题。Enciso 等^[22]通过无人机搭载高清 RGB 相机和多光谱传感器系统用于不同品种番茄的表型性状鉴定，用无人机估算冠层覆盖度和冠层分析仪测得的叶面积指数进行相关性分析， R^2 达到 0.72，另外无人机数据计算的作物高度估计值与地面测量值的 R^2 均在 0.97 以上，该方法用作物网格提取每个番茄品种的冠层覆盖度和植株高度，仍然无法精确识别单株的作物和定位，而作物分布不均和光照条件差异也会引起系统误

差。Ampatzidis 等^[23]用小型无人机获取柑橘园的多光谱图像，首先使用 YOLO 深度神经网络对生成的 RNB 和 RGB 图像进行训练，返回神经网络的检测结果，通过算法分析一行树之间的距离并预测行中的树木间隙区域，再利用第二次卷积神经网络检测结合阈值分离出间隙区域来减少误检，之后根据平均 NDVI 值分割出单株树冠并计算冠层面积，但是没有对自然环境中树木种植间距不一致和存在遮挡的问题进行针对性处理。Xu 等^[24]为了获取棉花植株的株高、冠层覆盖度、植被指数及棉朵的数量，将无人机多光谱图像用到棉花的表型分析中。通过运动结构算法矫正数字高程模型计算株高时的地理误差，检测结果与人工测量的结果有较强的相关性（ R^2 大于 0.89），测量的均方根误差为 5.7~10.4 cm。然后使用数字高程模型和归一化植被指数（NDVI）分离冠层与土壤，计算的冠层覆盖度与平均冠层 NDVI 相关性较低（ R^2 最高为 0.57）。最后利用支持向量机算法对棉朵进行检测，但由于叶片遮挡和多光谱图像分辨率低等原因，导致检测的精度并不高，平均准确率不足 60%。这些方法在进行作物表型分析时都需要在无人机上搭载多光谱相机，不仅会增加采集图像的成本也会影响航行的时间。多光谱相机的成像效果受光线条件影响较大，且多光谱图像一般分辨率不高，如果采用这些方法很难对每株甘蔗幼苗进行准确识别和定位。

目前已经有研究人员开始用无人机航拍可见光图像对作物进行表型分析以辅助育种工作，因为筛选新品种需要在一个庞大且具有遗传多样性的群体中进行大规模实验^[25]，由于无人机能准确、快速地进行表型检测，因此能提高表型比较的效率从而加快育种工作的进度。Jung 等^[26]通过航拍的可见光图像计算棉花的冠层覆盖度及吐絮期的相关表型性状（如吐絮铃数等），利用这些性状实现对高产棉花基因型的筛选，实验结果显示利用该方法将种群的最小和平均棉产量分别提高了 7.4% 和 10%。

为了以更加经济和快速的方式通过航拍图像辅助育种专家提高甘蔗出苗率计算的效率。本研究采用旋翼无人机搭载 RGB 相机采集苗期的大田甘蔗俯拍图像。虽然无人机的应用可以提高作物表型评估的效率，但也要考虑自然环境中存在的不可控因素（如光照强度、风力大小和地表反射率等会影响作物遥感图像的纹理和颜色）加上相机参数的变化（如拍摄角度、光圈大小和镜头分辨率可能会使无人机航拍图像中的作物变得模糊甚至扭曲）均会增加从图像数据中提取准确信息的难度。

1.2.2 深度学习目标检测方法的研究现状

目标检测在计算机视觉技术中是一个重要的研究方向。目标检测任务包括对图像中

关注目标进行目标分类和目标定位两个分支操作，通过目标分类这个分支操作判断目标物体所属的类别名称，另外利用目标定位这部分操作获得目标物体在图像上的位置坐标。在深度学习兴起之前，目标检测主要采用传统的手工设计特征加浅层分类器的方法，由于滑窗效率低下、特征不够鲁棒等原因导致其发展缓慢。而基于深度学习算法的目标检测方法正致力于解决这些问题。在深度学习中，目标检测采用的是端到端（end-to-end）学习方案，也就是说，只需要输入图像就可以得到实际检测结果，不需要太关注算法内部利用神经网络对参数调整的过程。

2006 年基于人工智能提出的深度学习算法成为机器学习的一个新领域^[27]，深度学习凭借自动提取特征的优势，极大的促进了机器学习的发展。随后，深度学习算法通过增加神经网络的层数，以更高的精度与运算能力超越了传统的机器学习算法^[28,29]，为从海量、高维的数据中提取复杂的特征信息提供了巨大潜力。卷积神经网络（Convolutional Neural Networks, CNN）是目前应用最广泛的目标检测深度学习方法，基于 CNN 的目标检测方法可以通过迭代自动提取多层次特征，极大地增强图像表征能力^[30]，在一定程度上降低了提取特征时对图像质量的要求（如亮度的影响）。目前在行人检测和车辆检测等热门方向的目标检测研究中，CNN 的使用很频繁且取得了不错的效果，如 Liu 等^[31]通过改进 SSD 算法的骨干网络，利用去垂直可分离卷积降低模型复杂度并采用层级结构融合提高行人检测时分类与检测的精度，实验结果表明，改进算法在 INRIA 数据集中的漏检率低至 68%。在车辆检测方面，Zhang 等^[32]基于 Faster R-CNN 网络设计了精确车辆区域网络（AVRN）和车辆属性学习网络（VALN），并且在 AVRN 和 VALN 中引入相应的损失函数，实验结果表明，改进的 Faster R-CNN 算法比标准的 Faster R-CNN 算法在测试中平均精度提高 11%，检测时间缩短了三分之一。行人和车辆这类目标一般尺寸较大且特征较明显，在图像中容易用肉眼分辨。

CNN 除了广泛应用于行人、车辆等生活场景的目标检测研究外，它也逐渐在农业领域的各种目标检测任务中展现出较高的潜力和性能。研究表明，CNN 在众多农业论文中被采用，约占用于解决农业问题的深度学习方法的 42%^[33-35]。比如在植物组织识别方面，Miao 等^[36]在研究玉米和高粱叶片计数时，通过实验发现基于 Faster R-CNN 目标检测模型的检测计数方法准确率要高于基于卷积神经网络的回归计算方法，结果显示，目标检测模型的检测结果与人工统计结果的相关性更高（ R^2 为 0.9），均方根误差为 0.92 片。Song 等^[37]为了实现对植物叶片显微图像中气孔的自动计数，提出一种基于 Mask R-CNN 网络模型的显微图像气孔自动分割及空隙参数计算方法，通过该方法可以获得孔隙区域

的轮廓坐标，然后利用椭圆拟合得到孔隙的解剖参数，并对孔隙参数进行定量分析。实验结果表明，该方法对气孔的平均检测精度为 96.6%，气孔的分割结果也显示各项参数的检测精度均在 90% 以上。Zhou 等^[38]采用以参数压缩的 MobileNetV2 作为骨干网络的 SSD 网络模型设计了一个安卓系统的应用程序——KiwiDetector，用于猕猴桃果实的田间实时检测。通过手机采集的图像进行测试，实验结果显示，参数压缩的 MobileNetV2 的正确样本检出率（TDR）为 89.7%，在手机上处理每张图像用时 103 ms，检测速度比压缩前有显著提升。在农作物病虫害识别方面，Mohanty 等^[39]采用 AlexNet 和 GooLeNet 以迁移学习的方式在有 54306 张病叶和健康叶片的公共数据集上进行训练，训练后的模型在测试集上准确率最高能达到 99.35%，证明了该方法的可行性。Islam 等^[40]研究了基于卷积神经网络的稻叶病自动检测方法，研究人员共研究了褐斑病等 4 种患病水稻叶片，对 VGG19、Inception ResNet V2、ResNet101、exception 四种网络模型进行分析。结果表明，Inception ResNet V2 检测效果较好，准确率为 92.68%。基于 CNN 的目标检测也可以用于田间精准除草，如姜红花等^[41]提出基于 Mask R-CNN 的杂草检测方法，并且研发了针对杂草的变量喷洒装置，在田间测试时，对杂草准确喷雾的准确率为 85%，单张图像检测耗时 0.98 s，符合实际应用需求。农业领域检测的目标一般尺寸较小且数量多。植物组织识别多针对叶片、果实等形状较规则的部位，通过肉眼可将目标组织与其他组织区分；病虫害识别以植物病变部位为目标，特征较明显，但病虫害的种类通过肉眼较难区分；而田间杂草的特点在于形态不规则且存在交叉、遮挡的情况，因此识别难度相对较高。

大田的作物计数属于目标检测中较复杂的一类问题，因为大田环境下背景更复杂并且检测的群体规模更庞大，过程中的一些小误差可能会影响整体计数结果的真实性。目前在大田作物计数方面已有一些研究，如 Enrique 等^[42]提出一种无人机航拍图像与区域卷积神经网络算法结合的苹果产量快速估测方法，每棵树的估测产量与人工统计结果具有一定相关性（ R^2 为 0.80），平均绝对误差为 128.56 个。该方法需要将每棵树从拼接的正射影像中裁剪出来进行单独检测，再将单张图像的计数结果结合每棵树的轮廓坐标绘制到正射影像中得到整体计数结果。该研究只采集了一处果园的数据，模型的通用性有待验证，并且单独检测每棵果树的产量效率较低。Deng^[43]等开发了基于 CNN 的水稻有效分蘖自动检测 app，可实现对手机拍摄的人工切割后暴露的水稻分蘖茎横截面图像进行有效分蘖数的检测。分蘖茎横截面形状接近圆形或椭圆易于人工标注。该方法拍摄高度为距地表约 13 cm 处，对其他拍摄高度的适应性还有待验证，且没有对稻叶遮挡的分

蔗茎横截面做针对性处理。

上述研究现状表明基于 CNN 的目标检测技术用于大田作物计数有较好的可行性。近几年低成本无人机平台与基于 CNN 的目标检测算法结合提高了大田作物群体计数的效率。特别是当 Faster R-CNN 网络被开发出来以后^[44]，提高了目标识别和定位的精度，为计数提供了基础。当前 Faster R-CNN 已成为广泛应用于农业的目标检测框架。研究人员在刺梨^[45]和苹果^[46]的检测中运用 Faster R-CNN 都达到了较高的检测精度（平均识别精度最低为 92.01%）。即便如此，目前利用航拍图像进行基于 CNN 目标检测的大田幼苗群体计数的研究相对较少，一方面因为高分辨率的可见光航拍图像所占内存较大，受计算机运算能力的限制，在普通计算机上很难直接对高分辨率的航拍图像进行深度学习的运算。另一方面，由于作物幼苗在航拍图像中所占的尺寸很小，因此通过航拍图像的目标检测实现作物幼苗的计数难度更大。在 2019 年，Bipul 等^[47]为了实现香蕉农场中香蕉幼苗的自动计数，使用 Faster R-CNN 架构对不同高度采集的无人机航拍图像进行检测，对不同高度和图像处理方法得到的模型进行检测结果融合，最终将结合这些结果进行最终的检测和计数，实验结果表明此算法在 40 m 的数据集上总体检测精度高达 97.9%。在 2020 年，Feng 等^[48]采用以 ResNet18 作为特征提取器的 Faster R-CNN 模型进行田间棉花幼苗的检测与计数，并在预处理阶段结合地理信息纠正了航拍图像的畸变，结果显示，该方法检测的幼苗数与人工统计幼苗数的 R^2 达到 0.95。上述研究说明基于 Faster R-CNN 的目标检测在航拍图像中进行幼苗识别与计数有一定的可行性。与香蕉、棉花等形状相对规则且单株易于用肉眼分辨的作物幼苗不同，蔗苗的形态更复杂且不易于用肉眼分辨，因此需要根据蔗苗的特点对算法进行改进。

在总结了前人的研究以后，本文采用小型无人机搭载 RGB 相机以获取数据，结合甘蔗幼苗的特点对前人提出的深度学习算法进行改进，即采用改进的网络模型对航拍图像进行目标检测并在此基础上实现大田甘蔗幼苗的计数。

1.3 存在的问题与挑战

目前，一些基于深度学习的主流目标检测算法，如 SSD，YOLO v2，Faster R-CNN 等，主要利用已经公开的数据集开展实验。然而田间的环境更加复杂，作物的形态结构差异较大，在大田作物航拍图像数据集上使用传统目标检测算法难以取得较准确的效果。所以，利用深度学习目标检测算法对田间作物航拍图像进行检测值得进行专门的研究。

基于 Faster R-CNN 的航拍图像目标检测虽然在棉花、香蕉等作物幼苗的计数中取得一定效果，但运用到甘蔗幼苗检测中仍存在以下几方面挑战：

(1) 训练样本缺乏。无人机技术的发展有利于更加便捷的获取大量航拍图像数据，但由于目前没有针对甘蔗的公开数据集，所以需要人工对采集的图像标注。而且在深度学习训练中，数据集与最终的结果密切相关，加上大田的航拍图像一般具有目标物数量多、形态不规则、分布疏密不均等特点与常见的 ImageNet、CIFAR 或 COCO 等数据集相比有较大区别，因此数据标注人员手动标注时要确保准确性。这项工作很依赖人工，现在尚未有较好的方法解决数据集的标签问题。最终制作的数据集规模要远小于公开的数据集，为了保证样本的多样性采用旋转、翻转、镜像等变换来扩充样本。

(2) 因发芽速度存在差异，甘蔗幼苗的大小差异明显。无人机在高空中对地面甘蔗拍摄时，由于图像辐射范围很广，地面目标即使都是甘蔗幼苗也存在很明显的大小差异，如接近分蘖期的幼苗在 10 m 左右高度拍摄的图像上有的尺寸达到数百像素，而小的只占几十个像素。且由于航拍时镜头是俯视的，这会造成同一物体成像角度的差异。一些小尺寸的甘蔗幼苗在图像中占的像素较少，特征不明显，容易被漏检。杂乱的背景也会对检测结果造成误导。

(3) 由于风力影响，幼苗叶片的摆动造成成像后形状的不规则。

(4) 甘蔗幼苗之间存在交叉、遮挡的情况，即便是人工也较难分辨。

(5) 图像尺寸大而目标物体尺寸小。本文的航拍图像尺寸是 5472×3648 像素，直接输入会占用计算机大量运算资源影响检测的速度。甘蔗幼苗在原始图像上所占的像素数较小，约几十到数百像素，图像的尺寸远比目标物大。在深度学习目标检测任务中，用来做特征层的骨干神经网络通常会进行下采样，这样能获得更深层的抽象语义信息，但同时造成低层的部分特征丢失影响检测精度。而在缩放后的图像上检测又会造成小目标漏检。

1.4 主要研究内容和技术路线

1.4.1 主要的研究内容

甘蔗幼苗的数量是甘蔗育种中评价甘蔗出苗率、分蘖率的基础数据。本研究以广西两处甘蔗育种实验基地种植的糖料蔗苗为研究对象，利用无人机搭载可见光数码相机获取甘蔗幼苗的低空航拍 RGB 图像，采用深度学习方法检测甘蔗幼苗。本文针对甘蔗幼

苗的特点，在主流深度学习目标检测框架 Faster R-CNN 的基础上进行了改进，搭建了基于改进 Faster R-CNN 的田间幼苗检测与计数系统，实现了低空航拍图像中甘蔗幼苗的检测和计数。主要研究内容如下：

(1) 构建甘蔗幼苗航拍图像数据集。首先，在不同光照、遮挡情况和杂草的背景下进行田间蔗苗的可见光航拍图像的采集。然后对图像数据进行自适应对比度增强处理，并裁剪成适合深度学习算法快速识别的子图集合。接着使用目标检测标注软件 LabelImg 标注裁剪的图片数据，制作了一个 PASCAL VOC 2007 格式的甘蔗幼苗数据集。采用数据扩充技术，对数据集进行翻转和旋转的操作，提高模型的鲁棒性，使得定位任务的精度得到提升。最终将数据集按比例分为训练集、验证集和测试集，用来进行模型的训练以及性能评估。

(2) 基于改进 Faster R-CNN 的甘蔗幼苗检测模型设计。针对航拍图像中的甘蔗苗大小差异明显，小尺寸蔗苗较多，且部分蔗苗之间存在遮挡的情况，在 Faster R-CNN 目标检测网络基础上，对网络结构进行了改进。采用了更改特征提取网络、嵌入注意力机制模块——SN-Block、引入特征金字塔网络、调整先验框形状和数量等方法，得到了针对甘蔗幼苗的目标检测模型并命名为 SGN-D (SugarcaneDetector)。

(3) 不同卷积神经网络结构的改进对检测结果影响的对比。将不同结构的卷积神经网络在甘蔗苗数据集上进行训练，为进一步验证本文提出的改进目标检测模型的性能，将不同网络结构训练的模型在本文制作的验证集上进行对比试验及试验结果分析。

(4) 提出一种大尺寸航拍图像识别结果的合并与去重方法。航拍图像尺寸和容量较大，无法直接输入深度学习模型中进行检测，需要先将图像裁剪成统一的尺寸。为了减少图像边缘甘蔗幼苗的漏检，采用带重叠像素的裁剪方式。但在批量检测时重叠区域中一些蔗苗被重复检测，产生较多的冗余边界框。对此，本文提出基于非极大值抑制 (non maximum suppression, NMS) 算法的批量图像检测结果合并的方法，可以有效去除冗余边界框，实现对原始航拍图像全图蔗苗的检测与计数。进一步研发了大田甘蔗幼苗检测与计数系统软件，用户可以使用该软件进行训练前的数据集制作、模型训练与验证和检测与计数等功能，通过将检测结果可视化，让用户直观地感受该方法的检测效果。

论文的主要研究内容框架图如图 1-1 所示。




图 1-1 本文框架结构图

Fig.1-1 The framework structure of this paper

1.4.2 研究技术路线

通过低空航拍可见光图像检测大田甘蔗幼苗群体数量的研究主要分为两个部分，分别是训练能检测子图像中甘蔗幼苗的检测模型的过程和对高分辨率航拍图像中甘蔗幼苗群体直接检测及计数的过程。

训练能检测子图像中蔗苗的检测模型过程包含以下操作：大田甘蔗幼苗可见光图像采集；图像增强及不带重叠度的裁剪；训练集和验证集的制作；对 Faster R-CNN 进行四个部分的改进（更换特征提取网络、在骨干网络中嵌入注意力模块——SN-Block、在 RPN 层前引入特征金字塔融合结构及改进 RPN 中先验框的形状和数量）；训练改进的 Faster R-CNN 模型；利用验证集评估模型的性能并保留性能最优的模型。这部分操作流程如图 1-2 虚线左侧所示。

对高分辨率航拍图像中甘蔗幼苗群体直接检测及计数的过程包含以下操作：输入高分辨率航拍图像；图像增强及带重叠度的裁剪；检测结果拼接与去重算法中设置 IoU 阈值；验证检测与计数的精度；根据精度要求确定最佳 IoU 阈值作为后续检测的经验值；输出检测及计数结果。这部分操作流程如图 1-2 虚线右侧所示。




图 1-2 甘蔗幼苗检测与计数技术路线

Fig.1-2 Technical route for sugarcane seedling detection and counting

1.5 论文的层次结构安排

论文的主要层次结构安排如下：

第一章：绪论。主要介绍低空航拍可见光图像快速检测甘蔗幼苗群体数量的研究背景与意义，叙述了目前国内外在无人机作物表性评估和深度学习目标检测方法应用于农业领域的研究现状，总结田间甘蔗幼苗在进行检测与计数时出现的难题。最后总述本文的工作内容和技术路线。

第二章：目标检测相关理论基础。本章简要说明神经网络的基本结构和算法，解释了卷积神经网络的主要概念和算法原理。对传统目标检测算法与基于候选区域的深度学习目标检测方法的原理进行了介绍。接着详细描述了 Faster R-CNN 网络的处理机制和结构。

第三章：图像预处理与数据集制作。介绍数据采集，图像数据预处理部分以及数据的标注工作。对数据采集的环境进行说明，将采集的图像按步骤进行处理：自适应对比度增强、裁剪、翻转与旋转。最后介绍了数据标注的方法。

第四章：基于改进 Faster R-CNN 的甘蔗幼苗检测算法设计。先基于 Faster R-CNN 算法对甘蔗幼苗进行检测。然后在 Faster R-CNN 网络框架的基础上提出一个改进的目标检测模型 SGN-D，并详细介绍了网络的改进部分和相关参数调整。接着简要介绍了将 SGN-D 用于甘蔗苗目标检测的实验过程。简述实验方案的设计与模型性能的评估指标。最后基于训练得到的 SGN-D 模型，在验证集上开展不同卷积神经网络结构的改进对模型检测结果影响的对比试验，对试验结果进行分析。

第五章：基于 SGN-D 模型的大田甘蔗幼苗计数方法。首先介绍基于非极大值抑制的航拍图像批量检测结果合并与去重的算法。接着进行 IoU 阈值对检测与计数精度影响的实验，在测试图像上进行实验，根据实验结果选择最佳的 IoU 阈值。最后介绍了大田甘蔗幼苗检测与计数系统软件界面的设计，利用 PyQt5 框架将甘蔗苗航拍数据集制作、甘蔗苗目标检测模型的训练和验证、大尺寸航拍图像的目标检测结果拼接等功能设计成可视化的操作界面，简述各界面的操作流程。

第六章：总结与展望。本章总结主要的工作内容及取得的实验结果，客观评价已完成的研究内容，提出目前研究中出现的问题，同时结合田间蔗苗的实际种植情况对今后的研究安排进行展望。

第二章 目标检测相关理论基础

本章首先介绍神经网络的基础结构和原理；然后介绍在计算机视觉检测中得到广泛应用的卷积神经网络，对其结构和算法做进一步说明；最后简述经典的深度学习目标检测模型，针对本文运用的深度学习框架 Faster R-CNN 的结构和原理进行了阐述。

2.1 神经网络的理论基础

神经网络是机器学习领域的一种模型算法，刚开始它是为了模拟生物神经元的功能而设计的。计算机硬件水平的提高，为人工神经网络通过增加深度来解决复杂问题创造了条件，但在这个过程中存在过拟合等很多问题。因此，学者们专门为这种深度神经网络设计了相关算法，称为深度学习。深度学习方法中用到很多机器学习的算法。近几年，深度学习正处在高速发展阶段，甚至有成为独立研究领域的趋势。神经网络是一项非常重要的机器学习算法，也是深度学习的起源。其中，本研究所采用的卷积神经网络算法是其中一种具有代表性的深度学习算法。

2.1.1 感知机模型

20 世纪 50 年代感知机模型的概念被首次提出，输入层（接收输入信号）及输出层神经元组成该模型最初的结构，如图 2-1 所示，输出层神经元负责对信号进行运算。




图 2-1 感知机模型结构示意图

Fig.2-1 Perceptron model structure diagram

感知机模型可以实现对训练数据的线性分类，分类过程就是先通过运算得到输出值 z ，接着将输出值 z 与理论输出值作差得到偏差，将偏差用来调整输出层的权重值，重复该过程不断更新权重 $w_i(i = 1, 2, \dots, n)$ ，最终实现对输入数据分类。

单层感知机结构简单，无法解决异或这样的非线性可分问题。为了处理该问题，由单层感知机推广而来的多层感知机被提出。不同之处在于，在原有的 2 层结构之间增加了隐藏层。

图 2-2 所示的单隐层前馈网络与多层前馈网络是常见的多层网络结构。在多层前馈神经网络中，上下相邻两层的神经元均互相连接，这两层必须相邻。一般只要包含隐藏层就可以叫做多层网络，因而图 2-2(a)所示的网络模型也可以被称为“两层网络”。




图 2-2 多层感知机神经网络结构模型

Fig.2-2 Structural model of Multi-Layer Perceptron neural network

多层网络的关键问题在于如何训练得到各层之间的权重。训练情形可大概分成两种：一种是单独更新某两层间的权重，其他权重不变，已证明该方法对非线性可分的样本都收敛；而另一种则是使用误差逆传播（BackPropagation，简称 BP）算法对神经网络的权重进行更新，并且经常使用 sigmoid 和 tanh 等函数作为激活函数。

2.1.2 BP 算法

BP 算法是训练神经网络的主要算法之一，目前使用神经网络的大部分场合都会用到 BP 算法。BP 算法的主要步骤是：

- (1) 前向传播。样本数据进入输入层，经过隐藏层，隐藏层和输出层时会对数据处理，然后输出层输出结果。
- (2) 反向传播。将神经网络的输出值与真实值的误差从输出层反向传到输入层。各层间的权重更新参照传递的误差，保证损失函数的值减小。
- (3) 不断传入新的样本数据，按上述过程不断迭代，不断更新网络的权重，直到收敛，得到学习后的网络模型。




图 2-3 多层神经网络

Fig.2-3 Multi-layer neural networks

图 2-3 是多层神经网络的结构图，L-1、L-2、L-3 分别为输入层、隐藏层、输出层。

下面参考图 2-3 介绍 BP 算法公式推导过程：设 w_{ji}^l 为第 $(l-1)$ 层的第 i 个神经元与第 l 层的第 j 个神经元间的权值， a_j^l 为第 l 层第 j 个神经元的输入， z_j^l 为第 l 层第 j 个神经元的输出， b_j^l 为第 l 层第 j 个神经元的偏置， C 为代价函数，则前向传播计算过程如式(2-1)至式(2-2)所示：

$$a_j^l = \sum_i w_{ji}^l z_i^{l-1} + b_j^l \quad (2-1)$$

$$z_j^l = \sigma \left(\sum_i w_{ji}^l z_i^{l-1} + b_j^l \right) = \sigma(a_j^l) \quad (2-2)$$

其中， $\sigma(\bullet)$ 表示激活函数，比如 sigmoid 函数。

代价函数用来计算神经网络输出值和真实值的误差，通过训练使其最小化，对于一个输入样本 a ，该样本真实的值即标签为 Z ，以常用的二次代价函数为例，定义其代价函数为：

$$C = \frac{1}{2} \|Z - z^L\|^2 \quad (2-3)$$

其中 z^L 表示预测的输出值， L 表示神经网络的层数。

接下来介绍反向传播过程。定义误差 δ ，令 δ_j^l 表示第 l 层第 j 个神经元的误差，可定义为：

$$\delta_j^l = \frac{\partial C}{\partial a_j^l} \quad (2-4)$$

结合式(2-1)和式(2-2)，根据链式法则求偏导，可得输出层的误差方程为：

$$\delta_j^l = \frac{\partial C}{\partial z_j^l} \sigma'(a_j^l) \quad (2-5)$$

由链式法则计算当前层的误差：

$$\delta_j^l = \frac{\partial C}{\partial a_j^l} = \sum_i \frac{\partial C}{\partial a_i^{l+1}} \frac{\partial a_i^{l+1}}{\partial a_j^l} = \sum_i \frac{\partial a_i^{l+1}}{\partial a_j^l} \delta a_i^{l+1} \quad (2-6)$$

又因 a_i^{l+1} 是 a_j^l 的函数，可得：

$$a_i^{l+1} = \sum_j w_{ij}^{l+1} z_j^l + b_i^{l+1} = \sum_j w_{ij}^{l+1} \sigma(a_j^l) + b_i^{l+1} \quad (2-7)$$

对 a_j^l 求偏导，可得：

$$\frac{\partial a_i^{l+1}}{\partial a_j^l} = w_{ij}^{l+1} \sigma'(a_j^l) \quad (2-8)$$

因此有：

$$\delta_j^l = \sum_i w_{ij}^{l+1} \delta_i^{l+1} \sigma'(a_j^l) \quad (2-9)$$

权值的更新可以通过式(2-10)得到：

$$a_j^l = \sum_i w_{ji}^l z_i^{l-1} + b_j^l \quad (2-10)$$

则：

$$\frac{\partial C}{\partial w_{ji}^l} = \frac{\partial C}{\partial a_j^l} \frac{\partial a_j^l}{\partial w_{ji}^l} = \delta_j^l \frac{\partial (w_{ji}^l z_i^{l-1} + b_j^l)}{\partial w_{ji}^l} = z_i^{l-1} \delta_j^l \quad (2-11)$$

$$\frac{\partial C}{\partial b_j^l} = \frac{\partial C}{\partial a_j^l} \frac{\partial a_j^l}{\partial b_j^l} = \delta_j^l \frac{\partial (w_{ji}^l z_i^{l-1} + b_j^l)}{\partial b_j^l} = \delta_j^l \quad (2-12)$$

使用梯度下降法更新训练参数为：

$$w_{ji}^l = w_{ji}^l - \alpha \frac{\partial C}{\partial w_{ji}^l} = w_{ji}^l - \alpha \delta_j^l z_i^{l-1} \quad (2-13)$$

$$b_j^l = b_j^l - \alpha \frac{\partial C}{\partial b_j^l} = b_j^l - \alpha \delta_j^l \quad (2-14)$$

其中 α 为学习率。由此可以看出，反向传播的过程就是利用更新的误差值调整权值

和偏置值。

2.2 卷积神经网络基础

传统的前馈全连接网络可以直接从大量数据中学习复杂的高维特征，因而其可用于图像识别任务中。但随着隐藏层神经元数量的增多导致网络中的参数量增多，系统消耗和内存占用也会显著增加。20 世纪 60 年代，卷积神经网络（CNN）被提出，以降低传统前馈全连接网络的复杂性。目前，卷积神经网络已成为深度学习中非常重要的一个模型，在计算机视觉方面得到了广泛应用。和传统前馈全连接网络等模型不同，它因采用卷积运算可以利用很少的权重参数，实现很好的拟合效果。后来，Lecun 等^[49]提出了 LeNet5——一个经典 CNN 模型，其核心设计思想给卷积神经网络发展提供了借鉴，LeNet5 结构图如图 2-4 所示^[49]，它包含卷积（Convolutions）和全连接层（Full connection）等单元。




图 2-4 LeNet5 网络结构

Fig.2-4 LeNet5 network structure

LeNet5 早期用于 MNIST 灰度图像数据集，但随着卷积神经网络技术的进步，灰度图像数据集已无法满足现实任务的需求，研究人员开始整理彩色图像的数据集，于是 ImageNet 数据集在研究人员的多年整理后于 2009 年发布。随后，从 2010 年起，ImageNet 视觉识别大赛 ILSVRC 每年举办一次，这一阶段图像识别领域仍然以 SVM 和 Boost 方法为主导。直到 2012 年，Krizhevsky 等提出了 AlexNet 网络^[50]，它比 LeNet5 层数多了三层，参数量也大幅增加，并且在 2012 年的 ILSVRC 大赛中夺冠，标志着深度学习快速兴起。之后的 ILSVRC 图像分类大赛每年都陆续涌现出一些性能优异的经典网络模型，比如 2014 年的 GoogLeNet^[51]和 VGGNet^[52]，2015 年的 ResNet^[53]以及 2017 年诞生的 ResNeXt^[54]等，这些模型都是基于卷积神经网络的模型。

卷积神经网络是由输入层、卷积层、池化层及激励层等组成的模型^[55]。下面详细介绍

绍卷积神经网络的基础理论。

(1) 卷积

卷积是 CNN 的核心操作，在图像矩阵上用该操作可以提取相应的特征。以图 2-5 为例介绍卷积的具体操作，暂不考虑通道数。图中，5×5 大小的矩阵代表输入图像，通过中间 3×3 矩阵代表的卷积核（filter），得到右侧 3×3 矩阵代表的特征图（feature map）。卷积核先与图像左上角同尺寸区域的同位置元素相乘后累加，该结果表示右侧特征图第 1 行的第 1 个元素。步长（stride）是每次卷积核滑动的单位数，当步长为 1 时向右滑动 1 格，即上一轮输入图像中的 3×3 大小的矩形区域也相应右移一格。将该矩阵和卷积核中同位置的元素按之前的操作计算，得到的数值放到上一轮结果的后面，以此类推。卷积核以滑动窗口的形式对图像进行扫描，最终扫描的结果一起构成一张特征图。




图 2-5 卷积操作实例

Fig.2-5 Example of convolution operation

(2) 感受野与池化

感受野是 CNN 的重要概念之一，当前目标检测框架很多是围绕感受野设计的。在 CNN 中，感受野是特征图的某个元素映射到输入图的区域，具体示例如图 2-6 所示。

在图 2-6 中，Raw Image 代表输入图像矩阵，Conv2 中的元素 5 是由 Conv1 的左上角 2 行 2 列范围内的元素计算得来，而该黄色虚线区域又是由输入图像 5 行 5 列范围内的元素计算得到，则该元素的感受野是 5×5。

池化（Pooling）操作也可以用图 2-6 来解释，从左至右图像逐渐变小，因为每过一层就相当于一次降采样。池化层一方面可以减少计算量；另一方面可压缩特征，保留重要的特征，一定程度上可防止过拟合，便于网络的优化。




图 2-6 感受野示例图

Fig.2-6 Example chart of receptive field

2.3 目标检测算法介绍

目标检测是计算机视觉技术在现实生活广泛应用的一个热点方向。目标检测任务主要是完成对图像中所关注目标物体的类别判断和位置确定，在类别判断分支操作中输出分类的结果——目标物的名称，在确定目标位置的操作中输出目标物在图中的位置坐标，一般是能充分包含目标物的最小矩形框的位置坐标。

2.3.1 传统目标检测方法

目标检测的传统方法一般采用机器学习方法，通常需要分几个步骤完成：

(1) 选取检测窗口

采用穷举窗口扫描的策略，在图像的每个像素点处设置不同宽高比且不同大小的框，然后用滑动窗口遍历图像，该方法可以实现候选框对目标区域的覆盖，但是此方法在使用时会产生大量无效的窗口，造成运算资源的浪费。而且也无法准确获取目标的位置，会影响提取的特征和分类器的精度。

(2) 提取图像特征

主要采用有监督方法表达提取的特征，需要特征能很好的表达目标的纹理、边缘变化、局部明暗关系等信息，并且适应更多的环境。在传统的检测算法中，会用到 Haar、HOG、SIFT 和 SURF 等一些优秀的传统特征描述。这些特征虽然在较简单的任务中表现出较好的性能，但是缺点是需要研究人员通过一定时间来设计，成本较高。

(3) 构建分类器

一般最后一个环节是用分类器分类，常用的分类器主要包括 Adaboost、SVM 和决

策树等。Adaboost 通过弱分类器的组合实现了分类精度更高的强分类器。SVM 能以较高的精度完成线性可分数据的分类，而且 HOG 特征与 SVM 的组合算法是用于行人检测的经典算法。

目前利用深度学习目标检测方法的应用场合要远多于使用传统目标检测方法的情况，尤其是在复杂的任务中，深度学习目标检测方法在检测精度和效率上更高。传统方法发展被限制主要是因为滑窗效率低，人工设计的特征鲁棒性不高。

2.3.2 基于候选区域的深度学习目标检测

在目标检测任务中，先用 Selective search 方法结合图像信息生成目标大概会出现的区域，这就是生成候选区域（Region proposal），然后针对生成相对较少的候选框的情况再进行分类和候选框调整，可以提高检测的召回率和效率。基于候选区域目标检测算法主要以 R-CNN 系列方法为代表。

(1) R-CNN 算法简介

Selective search 方法于 2012 年诞生^[56]。该方法首先将图像分割成一些小区域，再根据纹理、大小和空间交叠等特征计算相似程度，把相似度高的相邻区域合并，重复上述过程，直到所有小区域被筛选和合并，输出目标可能出现的位置。Girshick 等利用候选区域和卷积神经网络提出 R-CNN 算法^[57]。R-CNN 利用 Selective search 策略有效减少了候选框的数量，并将候选框转化为同一尺寸，利用卷积神经网络提取特征，再使用 SVM 分类器对目标物体进行分类，最后通过回归器修正边界框坐标确定目标的位置。R-CNN 网络的主要框架如图 2-7 所示^[57]。

(2) Fast R-CNN 算法简介

R-CNN 算法虽然通过减少候选框的数量减少了一部分计算，但利用 Selective search 方法生成的候选区域仍有较多的重叠，这样会造成在相同区域做重复的特征提取运算，而且提取后的特征需要存储，因此导致 R-CNN 在训练时要消耗较多的时间和存储空间。而 Fast R-CNN^[58]是先将完整的图像输入神经网络；然后生成整张图像的特征图；接着采取 Selective search 方法在原始图像上得到候选框即感兴趣区域（ROI）；对感兴趣区域投影到特征图上的区域进行池化，得到特征向量；再经过全连接层，使用 softmax 分类器和回归算法进行分类与边框坐标调整。Fast R-CNN 要比 R-CNN 减少了对重叠的候选区域的冗余特征提取操作。Fast R-CNN 直接在最后一层特征图上生成候选区域，避免重复的特征提取，节约了运算资源。




图 2-7 R-CNN 网络结构

Fig.2-7 Network structure of R-CNN

2.4 Faster R-CNN 目标检测算法

R-CNN 和 Fast R-CNN 都没有解决 Selective search 方法中检测窗口扫描效率低的问题。于是任少卿等在 Fast R-CNN 框架的基础上提出 Faster R-CNN 算法^[44]，使用单独的 Region Proposal Networks（RPN）框架来预测候选区域以替代 Selective search 方法，使得目标检测可由神经网络端到端地完成。Faster R-CNN 也是运用候选区域机制的目标检测算法，在多目标检测任务中有不错的精度。

2.4.1 Faster R-CNN 算法的网络结构




图 2-8 Faster R-CNN 网络结构

Fig.2-8 Network structure of Faster R-CNN

图 2-8 展示了原始 Faster R-CNN 网络的结构，主要由特征提取层、RPN 网络层、ROI Pooling 层和分类回归层构成。其中 VGG16 网络是它的骨干网络，用于特征提取。提取后的特征图用于 RPN 层和 ROI 池化层。在 RPN 层中利用特征图生成一定数量的候选框；利用 ROI 池化层将特征层上的 ROI 调整为固定尺度，因为后面的全连接层只能处理同样大小的候选框。ROI 池化后经全连接层处理然后利用分类与回归两个分支操作进行类名与位置的确定。

2.4.2 Faster R-CNN 算法介绍

Faster R-CNN 可以通过学习以较快的速度生成候选区域，充分利用了特征图的价值。Faster R-CNN 算法与 Fast R-CNN 算法最大的区别就是提出了推荐候选区域的 RPN 网络；除 RPN 层外，其余结构类似。因为 Fast R-CNN 可以共享卷积计算，这样即使引入 RPN 网络，计算量也比较小。下面根据图 2-8 所示的结构详细介绍算法的各个步骤。

(1) 特征提取层

特征提取层采用 VGG16 结构，首先把大小为 $P \times Q$ 的输入图像缩放成 $M \times N$ 的尺寸，然后通过 13 个由卷积层和激励层组成两层结构，其中加入了 4 个最大池化层。使用 3×3 的卷积核进行步长为 1 的卷积，使用 2×2 的滤波器进行步长为 2 的池化。尺寸为 $M \times N$ 的图片，经过特征提取，生成大小为 $(M/16) \times (N/16)$ 的特征图。

(2) RPN 网络层

在 RPN 网络中，输入完整的图片，会在图片上生成一批候选区域。每个区域包含待检测目标属于某个类别的置信度和位置坐标，也就是在最终提取的 256 个特征图的每个像素点处利用滑窗生成 i 个不同的先验矩形框（anchor）， i 一般为 9。anchor 是预设的矩形框，具有不同尺寸和长宽比。假设卷积神经网络最终提取的特征图尺寸是 $w \times h$ ，那么总的矩形先验框数量为 $9 \times w \times h$ 。对于生成的先验框要用分类器判断 anchor 所在区域的图像属于前景还是背景。大部分的 anchor 属于背景，而待检测的目标物属于前景，因此在本环节去除冗余的 anchor 就能减少后面全连接层处的计算。上文提到的 256 个特征图经过 RPN 层的 3×3 卷积后还是得到 256 个特征图，然后利用 1×1 的卷积生成 18 个特征图。利用 softmax 分类器筛选出属于前景的 anchor。另外还要使用边框回归调整 anchor 的位置坐标。RPN 层的示意图如图 2-9 所示^[44]。




图 2-9 RPN 结构图

Fig.2-9 Network structure of RPN

(3) ROI Pooling 层

这一层与 Fast R-CNN 的类似，主要是针对生成候选区域后得到的候选框尺寸和形状不同这个问题，由于后面的全连接层只能对相同大小和形状的候选框运算，通过 ROI Pooling 层将映射到全连接层前的最后一层卷积输出的特征图上的不同大小的感兴趣区域（ROI）转换为相同大小的特征向量。




图 2-10 目标检测模型对不同大小目标检测的精度对比

Fig.2-10 Accuracy comparison of object detection models for different size objects

(4) 分类和回归层

ROI Pooling 层输出的特征图传给全连接层，然后进行两个分支操作，一个是进行目标分类，用 softmax 分类器判断属于的类别，得到分类的概率；另一个分支做目标定位，利用边界框回归算法调整特征子图的位置，得到目标框坐标。图 2-8 中分类概率用 cls_prob 表示，预测的目标框坐标用 bbox_pred 表示。

在检测速度方面，Faster R-CNN 使用 VGG16 作为特征提取网络时，可以在单个 GPU 上以每秒 5 帧的速度运行。在准确度方面，Faster R-CNN 在 VOC 2007 数据集上的检测精度为 73%。使用 ResNet101 网络作为骨干网络的 Faster R-CNN 在 VOC2012 数据集上的检测精度超过了 SSD 和 YOLOv2 模型^[59]。

虽然此后提出的一些目标检测模型确实提高了检测速度和准确度，但目前很少有模型能在 Faster R-CNN 基础上有很大程度的改进，Faster R-CNN 可能不是最简单或最快的目标检测方法，但它是性能最好的方法之一^[60, 61]。并且鉴于本研究的目的是针对大田进行甘蔗幼苗计数，计数结果的准确性将关系到后续播种、施肥和喷药的工作安排，直接影响经济效益，所以本研究更多关注的是计数结果的准确性。从图 2-10 可以看出，Faster R-CNN 结合 ResNet101 在小目标的检测上能获得不错的准确度，而田间的甘蔗幼苗在大尺寸的航拍图像中尺寸也比较小。因此根据在实际生产中的需求，Faster R-CNN 更适合对大田中的蔗苗进行单株的定位与识别。

2.5 本章小结

本章主要介绍目标检测的理论基础。先简单叙述神经网络的主要结构和算法，然后介绍卷积神经网络的结构特点以及相关概念。接着介绍了目标检测算法的发展，并且重点介绍 Faster R-CNN 网络的主要结构及算法各阶段处理的详细步骤。综合考虑检测模型的性能利弊和实际的应用需求，本研究选择 Faster R-CNN 网络为检测算法的基本框架。

第三章 图像预处理与数据集制作

本章主要介绍甘蔗幼苗航拍数据集的采集、图像的预处理操作以及数据标注。预处理操作涉及图像的自适应对比度增强、裁剪以及翻转与旋转变换。

3.1 数据采集

甘蔗幼苗的低空航拍图像采集地点为广西大学扶绥农科新城的两处甘蔗试验田，地块 1 与地块 2 的种植时间分别是 2020 年 7 月 6 日和 7 月 13 日，如图 3-1 中(a)、(c)所示。地块 1 与地块 2 的面积分别为 6.52 亩和 17.89 亩，田间除甘蔗幼苗外，还包含有杂草、滴灌管等。2020 年 8 月 2 日，研究采用了一架四旋翼无人机（大疆精灵 4 Pro）搭载一分辨率为 5472×3648 的 RGB 相机（如图 3-2 所示），对处于苗期（约出苗后 30 天）的甘蔗大田进行了低空航拍。航拍时间选在晴朗无风的上午 8-11 点、下午 3-5 点，避开了光线最强烈的中午时段。航拍时采用了 Altizure 软件自动规划并执行航线，飞行高度 10 m，飞行速度 2 m/s，拍摄角度垂直向下，最短拍照间隔 2 s，航线规划如图 3-1 中(b)、(d)所示。



(a) 地块 1



(b) 地块 1 航线规划



(c) 地块 2



(d) 地块 2 航线规划

图 3-1 实验地点及航线规划展示

Fig.3-1 Experimental site and route planning exhibition



(a) 无人机

(b) RGB 相机

图 3-2 实验设备

Fig.3-2 Experimental equipment

实验共采集甘蔗大田 RGB 图像 238 幅，其中地块 1 包含 120 幅图像，地块 2 包含 118 幅图像。地块 1 与地块 2 图像中的土壤颜色、光照强度及背景等存在差异，采集的图像样本分别如图 3-3 中(b)、(d)所示。由单张图像拼接成的地块 1 与地块 2 的全景图分别如图 3-3 中(a)、(c)所示。



(a) 地块 1 拼接全景



(b) 地块 1 单幅图像



(c) 地块 2 拼接全景



(d) 地块 2 单幅图像

图 3-3 实验地点全景及图像样本

Fig.3-3 Panoramic view of the experimental site and sample images

3.2 图像数据的预处理

图像采集后须经预处理才能进行后续的训练和检测，预处理的步骤为：先将所有的图像样本进行自适应对比度增强；然后将用于模型的测试及包含去重算法的甘蔗总苗数统计精度的评价的图像进行带重叠度的裁剪；而用于检测模型的训练与验证的图像进行不带重叠度的裁剪；人工筛选出至少包含一株完整甘蔗幼苗的子图；将筛选后的图像进行人工标注；标注的图像和标签文件会被划分为训练集和验证集，最后一步是扩充训练集数据。预处理的流程如图 3-4 所示。




图 3-4 预处理流程图

Fig.3-4 Preprocessing flow chart

3.2.1 图像自适应对比度增强

图像的频率能反映图中灰度变化的剧烈程度。图像前景的边缘灰度梯度大，从频域看，这部分是高频分量；而图像灰度平缓变化的部分为低频分量。图像中低频信息形成图像的基本灰度等级，对图像结构的决定作用较小，而高频信息反映了图像的边缘结构，是图像增强重点。在实际采集的数据中，由于光照等的变化可能会使得部分图像对比度较低。另外有些幼苗尺寸较小，如果出现在大量的低频信息中，在标注时视觉较难感受到幼苗的高频信号（边缘）。为了尽量减少人工标注时遗漏的样本数量并提高后期识别的准确性，本研究提出的解决方法是通过自适应对比度增强的方法增加绿色植株这一前景与土壤等背景的对比度。

由于本文的检测目标是甘蔗幼苗，因此需要增强图像中代表蔗苗的高频信息。对比度拉伸和直方图均衡可用于对全局图像增强，但利用对全局直方图均衡化可能会加强部分噪声信号并且导致细节的丢失。自适应对比度增强算法^[62]可以利用图像自身信息对图像特征进行处理，具有更好的鲁棒性。

本方法先通过低通滤波获得图像的低频分量，然后通过原图减去低频分量，得到表征图像边缘和细节的高频分量。最后将高频分量乘以一个增益值，接着重组低频分量和

高频分量就得到增强后的图像。该算法的核心部分为高频分量增益系数的计算。具体的方法为：

设图中某一像素点坐标为 (i, j) ，用 $f(i, j)$ 表示该点的灰度值，用 $M_f(i, j)$ 表示以点 (i, j) 为中心，大小为 $(2p+1) \times (2q+1)$ 的矩形区域的局部均值，其中 p 、 q 均为整数，该区域对应的局部方差用 $\sigma_f^2(i, j)$ 表示。对于图像中每个像素点，先分别计算该点的局部均值和方差。公式如式(3-1)和(3-2)所示。

$$M_f(i, j) = \frac{1}{(2p+1)(2q+1)} \sum_{s=i-p}^{i+p} \sum_{t=j-q}^{j+q} f(s, t) \quad (3-1)$$

$$\sigma_f^2(i, j) = \frac{1}{(2p+1)(2q+1)} \sum_{s=i-p}^{i+p} \sum_{t=j-q}^{j+q} (f(s, t) - M_f(i, j))^2 \quad (3-2)$$

式(3-1)中每个点的局部均值组成图像的低频部分，可以近似认为是背景部分。 $f(i, j) - M_f(i, j)$ 表示图像的高频分量，将高频部分乘上增益值 G ，就可对图像进行增强，具体公式如式(3-3)所示。

$$H(i, j) = M_f(i, j) + G(i, j)[f(i, j) - M_f(i, j)] \quad (3-3)$$

上式中， $H(i, j)$ 表示增强后的像素值。增益 G 是一个可以设置的系数，本方法将它设置为与局部标准差 $\delta(i, j)$ 成反比的变化值，即为：

$$G(i, j) = \alpha \frac{M}{\delta(i, j)} \quad 0 < \alpha < 1 \quad (3-4)$$

上式中， M 是一个常数，一般可取图像的全局平均值或全局标准差，本方法选取全局标准差。 α 是一个参数，一般取区间 $(0, 1)$ 内的小数，用来控制高频增益增强的程度。在图像的高频区域，由于本身局部标准差较大，对比度较强，增益却较小，这样就不会过度增强原本对比度就很强的区域。在图像的低频区域，局部标准差很小，对比度较弱，增益反而较大。这样就使得图像中原本对比度较弱的区域增强效果更显著。但也有可能增强部分噪声，因此需要限制增益的最大值，控制增益最大值的参数用 Max CG 表示。

通过本数据集进行测试实验，根据效果对其中的参数进行调整，最后确定 $\alpha=0.2$ ，将 Max CG 限制为10。在应用自适应对比度增强算法之后的效果如图3-5所示。本研究中，训练集、验证集和测试集中的图像都采用了自适应对比度增强方法进行预处理。




图 3-5 自适应对比度增强处理效果对比图

Fig.3-5 Effect comparison of adaptive contrast enhancement processing

3.2.2 图像裁剪

原始航拍图像的分辨率是 5472×3648 ，每张图像所占内存为 8 MB。如果直接在神经网络中训练会占用计算机大量内存和图形处理单元（GPU），使得深度学习的计算代价很高，为了节约在人工标注和训练时花的时间，本方法通过将大尺寸航拍图像裁剪为小尺寸的子图像块用于训练、验证和测试，从而提升各阶段的工作效率。

将 2 个地块采集的所有 238 幅航拍图像首先进行自适应对比度增强处理，然后随机分为训练集 168 幅、验证集 50 幅、测试集 20 幅。为了保证检测速度，本文采用了目标检测数据集较为常用的图像尺寸 600×600 来作为裁剪后的子图尺寸。各集合数据的裁剪方式如下：

(1) 无重叠度裁剪

无重叠度裁剪主要适用于训练集与验证集的图像。因为训练集与验证集主要用来对模型进行训练与验证，不涉及到识别结果的合并，因此可以直接采用网格的方式进行裁剪，也就是，相邻子图像间没有重叠。网格裁剪的效果如图 3-6 所示。由于原始尺寸与

目标裁剪尺寸没有整数倍的关系，因此，位于最后的裁剪行与列的子图不满足 600×600 的大小，直接弃用。最后裁剪出子图共 11772 张，部分裁剪后的子图如图 3-7 所示。可以看出，部分图像中没有蔗苗，或没有较为完整的蔗苗，因为无法正确标注，对模型的训练及验证无用，因此通过筛选直接弃用这部分子图。最终获得训练集子图 2392 幅，验证集子图 398 幅。




图 3-6 网格裁剪的效果

Fig.3-6 The effect of grid crop



(a) 有效子图

(b) 无效子图

图 3-7 部分裁剪后的子图

Fig.3-7 Part of the cropped tiles

在训练集子图中，地块 1 包含 1200 幅，地块 2 包含 1192 幅；在验证集子图中，地块 1 包含 198 幅，地块 2 包含 200 幅。

(2) 带重叠度裁剪

带重叠度裁剪主要应用于测试集中的图像。因为测试集图像不仅用来测试深度学习算法的蔗苗识别精度，还将用于测试原图像总体计数的有效性。因为裁剪的方式会引起部分蔗株被裁切为两部分甚至更多，在株数统计时带来较大误差。带重叠度的裁剪方式

可以帮助后期株数统计时设计更好的去重算法，提高株数统计的准确性。

为了验证大尺寸航拍图像批量检测结果合并与去重算法的准确度以及改进后的模型对大田甘蔗幼苗计数的性能，本文在测试阶段共使用 20 幅尺寸为 5472×3648 （原始航拍图像尺寸）的航拍图像作为待检测图像，在水平和垂直方向上分别使用 194 和 219 个像素数的重叠，刚好可以将大图分割成整数块，裁剪的子图尺寸均为 600×600 。裁剪成该尺寸是因为考虑到计算机运算能力的限制，另一方面可以在不拉伸大图的情况下将其切割成整数块，且重叠的像素占子图边长的 30% 至 40%，这样的重叠度可以减少边缘植株的漏检。裁剪方式如图 3-8 所示。




图 3-8 有重叠的裁剪示意图

Fig.3-8 Diagram of cropping with overlap method

图中最大的矩形 OABC 表示输入的原始图像，其中小正方形代表裁剪后的子图。这样，一张 5472×3648 大小的原始图像就会生成 13×9 个相互重叠的子图。将子图像块命名为 $\{0_0_600_600, 0_1_600_600, \dots, 8_0_600_600, 8_1_600_600, \dots, 8_12_600_600\}$ ，这样命名是为了便于在第五章中使用这些编号对批量的检测结果进行合并与去重。

为了满足其他尺寸的原始图像可以在某一给定水平重叠度 $OverLapPercentage_x$ 和某一给定垂直重叠度 $OverLapPercentage_y$ 下可实现整数倍于 600 像素的裁剪，需要对

原始图像进行轻微的拉伸。并且，水平和垂直重叠度都必须小于 50%，否则会造成边缘重复检测；但重叠度过小又容易引起幼苗漏检。为了减少边缘植株的漏检，需尽可能保证水平与垂直方向重叠像素数的乘积大于图像中单株蔗苗边框覆盖面积的最大值。通过经验得知，重叠度的取值范围一般为 30%~40%。重叠度设置好之后，可以通过式(3-5)、(3-6)分别计算水平重叠像素 $OverLapPixel_x$ 和垂直重叠像素 $OverLapPixel_y$ 这两个中间变量；然后通过式(3-7)、(3-8)分别计算尺寸为 $W \times H$ 的原始图像在水平及垂直方向可裁剪的子图数量 M 、 N ，“ROUND”表示四舍五入取整；最后通过式(3-9)和(3-10)可得拉伸后的、能被整数裁剪的新尺寸为 $W' \times H'$ ，图像在水平与垂直方向的拉伸倍数 $X_{stretch}$ 和 $Y_{stretch}$ 可由式(3-11)和(3-12)确定。拉伸倍数 $X_{stretch}$ 和 $Y_{stretch}$ 的大小约等于 1，因此拉伸造成的轻微形变将不影响蔗苗的识别精度。

$$OverLapPixel_x = 600 \times OverLapPercentage_x \quad (3-5)$$

$$OverLapPixel_y = 600 \times OverLapPercentage_y \quad (3-6)$$

$$M = \text{ROUND} \left(\frac{W - 600}{600 - OverLapPixel_x} \right) + 1 \quad (3-7)$$

$$N = \text{ROUND} \left(\frac{H - 600}{600 - OverLapPixel_y} \right) + 1 \quad (3-8)$$

$$W' = 600 + (600 - OverLapPixel_x)(M - 1) \quad (3-9)$$

$$H' = 600 + (600 - OverLapPixel_y)(N - 1) \quad (3-10)$$

$$X_{stretch} = \frac{W'}{W} \approx 1 \quad (3-11)$$

$$Y_{stretch} = \frac{H'}{H} \approx 1 \quad (3-12)$$

将原始图像裁剪为 $M \times N$ 块子图后，将子图依次命名为 $\{0_0_600_600, 0_1_600_600, \dots, 1_0_600_600, 1_1_600_600, \dots, y_i_x_i_600_600\}$ ，这里的 x_i 实际上就等于 $M-1$ ， y_i 等于 $N-1$ 。

3.2.3 图像的翻转与旋转

为了进一步扩充模型的训练集，对裁剪筛选得到的训练集中的所有子图进行了数据扩充，包括水平翻转、垂直翻转、90°旋转、180°旋转及 270°旋转。训练集和验证集不存在重叠的像素，在整个数据集中互斥。数据扩充的效果如图 3-9 所示。




图 3-9 数据集扩充效果示意图

Fig.3-9 Schematic diagram of the effect of data set augment

3.3 数据标注

利用图像编辑器 LabelImg 在每一幅训练和验证子图像块上使用边框标注单株甘蔗幼苗，不仅记录目标种类的数目，而且还有对目标空间分布的说明。每个边界框在其边界内只包含一株甘蔗幼苗。每张图片中目标框数量从 1 到 20 个不等，对于训练图像块和测试图像块总共有 9625 个甘蔗幼苗样本被人工标注。在训练集和验证集中分别有 8417 和 1208 个标注的蔗苗样本。




图 3-10 数据标记示意图

Fig.3-10 Schematic diagram of data labeling

训练集中的子图与标记后的示意图如图 3-10 所示。划分后的图片和记录边框位置

信息的标签文件构成本研究的专用数据集 SGE（Sugarcane）数据集。

3.4 本章小结

本章首先介绍了本文数据集采集地点、采集时间以及试验地块的环境，说明采集的图像考虑了田间各种复杂的环境。然后对图像预处理进行详细介绍，首先由于甘蔗幼苗尺寸小，直接用来标注会造成遗漏，于是介绍了对原始图像进行自适应对比度增强的操作。然后将大尺寸航拍图像裁剪，裁剪分两种模式，边缘无重叠的裁剪方式用于获得训练集和验证集图片，边缘有重叠的裁剪方式用于评估大尺寸航拍图像检测结果合并与去重算法的性能。接着为了确保样本多样性，采用旋转和翻转变换的方法来扩充数据集。最后是人工标注数据集，数据集含图像及对应的标签文件，为下文模型的训练与测试做准备。

第四章 基于改进 Faster R-CNN 的甘蔗幼苗检测算法设计

4.1 概述

目前深度卷积神经网络技术在目标检测领域中得到广泛的应用，尤其在近几年出现了很多性能优秀的深度学习目标检测模型。相较于传统的目标检测算法，深度学习算法通过搭建更深层次的网络，可以提升模型的特征提取能力，能在大规模数据集中学习到更加复杂的特征，因此深度学习目标检测算法凭借这些优势逐渐成为目标检测的主要研究方向。Faster R-CNN 是应用较多的深度目标检测算法之一，它具有较高的检测精度，已经在农业领域的目标检测任务中取得了一些不错的成果。然而直接用原始的 Faster R-CNN 网络训练甘蔗幼苗的检测模型并不能取得很好的检测效果，因为田间环境比较复杂，比如杂草和植株间叶片的遮挡都会影响识别的结果，因此改进 Faster R-CNN 网络以适应田间环境下对甘蔗幼苗的检测是很有必要的。

本研究以 Faster R-CNN 网络为基础，使用残差网络 ResNet50 和轻量化的通道注意力模块 SN-Block 对特征提取层进行改进，并且在 RPN 层前利用特征金字塔网络实现了多尺度的特征融合，最后根据数据集统计的结果对 RPN 网络也进行了调整。模型对比结果显示，本研究改进的 Faster R-CNN 算法在甘蔗幼苗检测中精度为 93.67%提高了 8.69%。该改进模型被命名为 SGN-D 模型，为下一章实现大尺寸航拍图像中甘蔗幼苗群体的计数奠定了基础。

4.2 基于 Faster R-CNN 网络的甘蔗幼苗检测

Faster R-CNN 是卷积神经网络方法中的一种，目前在农作物计数方面取得了较好效果。本节从该目标检测网络入手，研究 Faster R-CNN 深度学习算法识别子图像中甘蔗幼苗的可行性。

Faster R-CNN 算法的基本原理和网络结构在之前的 2.4 节中已经做了介绍，这里不再阐述。本节主要通过实验评估 Faster R-CNN 的检测精度。利用该网络对训练集中的数据进行训练以得到模型，模型是指利用计算机通过大量迭代运算得到的神经网络中学习的参数，为了防止训练中断造成模型丢失一般会以检查点文件的形式保存模型。

本研究提出的数据集的规模属于中等量级（几千到几万），适合采用迁移学习。这种方法是指将之前在不同任务上训练的预训练模型的参数迁移到新模型的训练中来初始化新的网络。本文采用了针对一个包含 **potted plant**（盆栽植物）类别的公开数据集——COCO 数据集训练得到的 **Faster R-CNN** 模型作为预训练模型，将该模型输出的包含了模型参数的检查点文件载入到新的模型中，再针对本文的数据集继续训练得出新的模型。这种方式通过共享其他任务学习过的模型权重，缩短了训练时间。大致过程如图 4-1 所示。




图 4-1 迁移学习原理图

Fig.4-1 Schematic diagram of transfer learning

模型训练过程中设置的部分参数如表 4-1 所示。检测的平均精度达到 84.98%，具体实验结果见表 4-2，相关评估指标将在 4.4.2 节中介绍。实际检测效果如图 4-2 所示，在图 4-2 中，黑色虚线框代表误检的结果，图 4-2(c)中的黑框处将一株杂草识别为甘蔗幼苗，图 4-2(d)中的黑框处出现了重复识别。误识别的情况很容易发生在尺寸较小、邻近杂草和相互邻近的蔗苗上。

表 4-1 Faster R-CNN 的训练参数

Table 4-1 Training parameters of Faster R-CNN

参数	设置
学习率	0.001
权重衰减	0.0005
动量项	0.9
训练批次(epoch)	150
正则化因子	0.0001
优化器	Momentum Optimizer

表 4-2 Faster R-CNN 检测性能

Table 4-2 Faster R-CNN detection performance

网络类型	基础先验框个数	AP/%	AR/%
Faster R-CNN	9	84.98	83.56




图 4-2 Faster R-CNN 检测时部分图片的效果

Fig.4-2 Effect of some images in Faster R-CNN detection

4.3 基于改进 Faster R-CNN 网络的甘蔗幼苗检测算法设计

由以上结果可知，基于 Faster R-CNN 的迁移学习结果容易出现误识别。针对田间甘蔗幼苗尺寸小、冠层叶片的形状不规则且幼苗之间存在交叉、遮挡的情况，本文对 Faster R-CNN 网络做了进一步改进，提出能识别子图中甘蔗幼苗的模型——SGN-D 模型。本节主要介绍识别算法设计思路、整体结构以及各部分结构。

4.3.1 网络模型的整体结构

本研究以 Faster R-CNN 为网络的基本框架，主要对特征提取层和 RPN 网络层进行了改进。改进的 Faster R-CNN 模型结构如图 4-3 所示。特征提取网络由 ResNet50 结合注意力模块 SN-Block 组成；在候选区域网络中引入特征金字塔网络对提取的特征进行多尺度融合；调整候选区域网络中先验框的初始宽高比与尺寸；Fast R-CNN 检测网络部分与原 Faster R-CNN 中相同。改进的主要部分为：针对光照等的变化和杂乱的背景，采用计算量更小但性能较高的 ResNet50 网络代替原骨干网络——VGG16 网络；针对蔗苗

间存在交叉、遮挡的情况，在残差网络中引入注意力机制模块 SN-Block，以减少蔗苗的漏检。




图 4-3 改进的 Faster R-CNN 网络结构图

Fig.4-3 Structure diagram of the improved Faster R-CNN network

4.3.2 基于 ResNet50 的特征提取

ResNet 网络^[53]是针对因网络层加深造成训练误差增大的问题而被提出的。其检测精度高，计算资源要求低。ResNet 网络在前馈神经网络上增加了短链接（shortcut connection）通道，可绕过权重层，通过这种连接方式产生残差块结构（图 4-4）。通过使用这些新产生的残差块的结构进行干涉，能有效防止因网络层加深造成的梯度消失问题。

残差块可定义为：

$$y = F(x, \{W_i\}) + x \quad (4-1)$$

其中， x ， y 分别为该结构的输入和输出， $F(x, \{W_i\})$ 表示残差部分的函数， W_i 表示权重。以 2 个权重层为例，则残差函数如式(4-2)所示。

$$F = W_{2\delta}(W_1x) \quad (4-2)$$

其中， δ 为非线性函数 ReLu，下标 1 和 2 表示两个权重层的序号。在图 4-4 中， x 为输入， $F(x)$ 为残差函数，ReLu 为激活函数， y 为输出。




图 4-4 ResNet 网络结构图

Fig.4-4 ResNet network structure diagram




图 4-5 ResNet50 特征图可视化

Fig.4-5 ResNet50 feature map visualization

ResNet 系列网络包括 ResNet50、ResNet101 和 ResNet152 网络等，由于数据集规模不大，本研究选择了结构相对简单、训练速度快以及运算时间较少的 ResNet50 网络作为特征提取器。ResNet50 网络的结构如图 4-5 所示，网络的输入尺寸设置为 640×640 ，因为图像在特征提取层共经历 6 次下采样，因此要求输入尺寸能被 64 整除。而实际输入的图片尺寸为 600×600 ，使用 0 对子图边缘进行填充以调整为输入尺寸，这样不会改变输入图像的原始像素信息。

将 600×600 像素的三通道（红、绿、蓝）图像输入，通过 0 填充将图像尺寸调整为 640×640 ，再输入 ResNet50 网络。该网络采用不同数量的卷积层组合、批量归一化层、激励层等组成的五个阶段进行特征提取，通过短链接实现的残差块结构对残差进行学习。

在目前的很多研究中，深度学习模型为农业方面的应用提供了具有前景的成果，但作为“黑盒”系统它的解释潜力有限^[33]。其他研究中已经开发了几种方法解释深度学习模型的机制，包括深度学习滤波器和特征图的可视化，反卷积神经网络^[63]，计算滤波器的感受野^[64]。在本研究中，为了直观地解释特征提取的效果，将 ResNet50 的五个阶段输出的特征图可视化。ResNet50 的网络结构及每个阶段中滤波器输出的特征图可视化效果如图 4-5 所示，其中 C1~C5 表示第 1 特征层至第 5 特征层，每个特征层都是通过对上层数据进行下采样而得，由于输入尺寸固定为 640×640 ，则 C1~C5 的尺寸依次为： $[320, 320]$ 、 $[160, 160]$ 、 $[80, 80]$ 、 $[40, 40]$ 、 $[20, 20]$ 。

4.3.3 SN-Block 注意力模块的引入

注意力模型最早被用于机器翻译^[65]，目前它已成为神经网络结构的重要组成部分，在人工智能的相关研究中频繁出现。注意力机制可以利用人类视觉系统进行直观解释，人类的视觉系统倾向于关注图像中辅助判断的部分信息，并忽略不相关的信息^[66]。通道注意力可以理解为让神经网络重点看哪些通道信息，典型的代表是 SENet^[67]。

针对甘蔗幼苗尺寸不一、叶片间存在遮挡的问题，设计出轻量化的基于通道注意力机制的网络结构——SN-Block，在骨干网络中对较低层特征进行加权，以增强目标特征。SN-Block 模块可以嵌入到 Faster R-CNN 中，增强特征提取层的感受野，提升卷积神经网络的性能。

输入的图像 X 经过特征提取层后，得到形状为 $H \times W \times C$ 的特征图，其中特征图的尺寸用 $H \times W$ 表示， C 为通道数。将其输入 SN-Block 结构，依次使用 3×3 卷积、 1×1 卷积、 3×3 卷积，在每一次卷积后使用 ReLU 函数激活。两个 3×3 卷积核的组合比一个较大尺

寸的卷积核的非线性表达能力更强同时能降低参数量，在 3×3 卷积核前加 1×1 卷积核是为了减少特征图的通道数从而降低总参数量。该模块通过以下操作对特征通道进行加权处理：首先对特征 F_{in} ($H \times W \times C$ 的特征图) 进行全局平均池化，生成具有全局特征信息的特征图 F_{global} ($1 \times 1 \times C$ 的特征图)，使其具有全局的感受野，通道数保持不变。接着通过 1×1 卷积恢复原来的通道数，并使用 sigmoid 函数进行归一化。最后得出各通道对应的权重，各通道与对应权重相乘，完成加权处理后便得到特征 F_{out} 。本方法使用的 SN-Block 结构如图 4-6 所示。 X 为输入图像， Y 为输出的特征图。




图 4-6 SN-Block 结构

Fig.4-6 SN-Block network structure

SN-Block 模块中的具体计算过程为：

$$F_{out} = H_c(F_{in}) \otimes F_{in} \quad (4-3)$$

式(4-3)中： F_{in} 为输入特征图； F_{out} 为加权处理后得到的输出特征图； $H_c(F_{in})$ 为通过 F_{in} 得到通道权重的操作， $\otimes$ 为对各个通道进行加权处理的操作。

$$H_c(F_{in}) = \sigma[M(F_{global})] \quad (4-4)$$

式(4-4)中： $H_c \in \mathbb{R}^{C \times C \times 1}$ ； σ 为 sigmoid 函数； M 为 1×1 的卷积操作， $M \in \mathbb{R}^{C \times C}$ ； F_{global} 是由特征图 F_{in} 经过全局平均池化后得到。

$$F_{global} = \rho\{\delta[O(F_{in})]\} \quad (4-5)$$

式(4-5)中， ρ 为全局平均池化操作； δ 为 ReLu 激活函数； O 为对输入特征图进行增加非线性的一系列卷积操作。

4.3.4 多尺度特征融合

R-CNN 系列算法是利用最后提取的特征进行目标识别的，因此容易忽略小目标。而特征金字塔网络 (Feature Pyramid Networks, FPN) 通过构建多尺度的高级语义特征图可

以提高多尺度检测的准确性^[68]。田间生长的甘蔗由于生长阶段不一致，导致很多尺寸小的幼苗很容易在检测中漏检，针对此问题，本研究将 FPN 结构融合到 Faster R-CNN 中，在很大程度上增强了目标检测网络对全图信息的认知。金字塔多尺度特征融合的原理示意图如下图 4-7 所示。在原始 Faster R-CNN 网络中使用 FPN 层进行多尺度特征融合的基本步骤如下：

第一步：先将图像送入底层网络中，通过特征提取网络得到三个特征图。

第二步：图中的 1、2、3 层即为预训练网络得到的特征，之后用 1×1 卷积对 2 层的特征图进行降维，把降维的结果与 3 层上采样之后的结果相加，得到第 5 层的特征图，这就是 FPN 的操作。同理，第 6 层的特征图是通过第 1 层的特征图降维后与第 5 层上采样的结果相加得到的，如图 4-7 虚线框所示。

第三步：然后将 4、5、6 层特征（top-down 网络，FPN 的核心）输入候选区域网络以生成先验框，如图 4-7 蓝色框所示。之后与原始 Faster R-CNN 的操作一样，通过 3×3 的卷积之后连接分类层和回归层。




图 4-7 金字塔多尺度特征融合原理示意图

Fig.4-7 Pyramid multi scale feature fusion principle schematic

低层的特征图适合确定目标位置，高层的特征图适合进行类别的判断。低层特征图较多的位置信息有助于检测小目标；而高层特征图由低层特征图经下采样得到，下采样次数增多会减少小目标在特征图的尺度，且步长大的下采样易造成特征信息缺失，从而降低小目标检测精度。图 4-7 中 1×1 卷积核用于使特征通道数匹配； $2 \times \text{up}$ 是图片 2 倍上采样，上层的特征层通过上采样生成的特征图尺寸与下层的特征图尺寸相匹配，相加后可生成融合后的特征层。因此可以利用图 4-7 的 4、5、6 层依次输出从大到小的目标。

本文为充分利用 ResNet50 网络提取到的各个阶段的特征，采用图 4-8 右边虚线框

中所示的 FPN 结构图进行特征融合。在图 4-8 中，Input 表示输入的图片，H、W 和 C 分别表示图像高、宽及通道数。




图 4-8 采用的 FPN 特征融合结构图

Fig.4-8 Feature fusion structure of FPN

本文所采用 FPN 层进行多尺度特征融合的主要步骤如下：

第一步：先将图像送入底层网络中，通过 ResNet50 和 SN-Block 结构组合的网络得到五个阶段的特征图。

第二步：图 4-8 中的 C1~C5 层即为特征提取网络得到的特征层，之后用 1×1 卷积对 C4 层进行降维，使得 C4 的特征通道数与 P5 的特征通道数匹配；P5 经过上采样后，使得 P5 与 C4 中特征图尺寸一致，最终二者相加，得到融合层 P4，其它层以此类推。

第三步：然后对于得到的 P2~P6 层（top-down 网络）进行 RPN 的训练得到候选区域，之后与原始 Faster R-CNN 的操作一样，通过 3×3 的卷积之后连接分类层和回归层。

P2~P5 是将来用于预测甘蔗苗边界框的，而 P6 只用于 RPN 网络中。

4.3.5 改进 RPN 区域建议网络

将经过 FPN 结构输出的特征图输入到 RPN 网络层中，以滑窗的形式根据特征图成一定数量的先验框。原 Faster R-CNN 设置宽高比为 (1:2, 1:1, 2:1) 的三种先验框，这三种比例的先验框能适应 COCO 数据集中各种不同形状和大小的物体，并且模型在 COCO 数据集上的实验已经取得不错的效果，但这种比例设置并不适用于识别自然环境下形状不规则的甘蔗幼苗。为了让模型适应研究对象的特点，本方法对甘蔗幼苗训练集中人工标注的目标框宽高比统计，统计结果如图 4-9 所示。横坐标表示标记框的宽高比，纵坐标表示相应宽高比对应的标记框数量。结果显示，出现频率最高的前 4 种标记框宽高比依次为 1:1, 2:1, 4:5, 1:2。

将统计得到的出现频率最高的 4 种宽高比替换原来的 3 种先验框宽高比，并将先验框的初始尺寸设置为 (16, 32, 64, 128, 256)。特征图上每个点生成 20 种先验框，在尺寸为 $W \times H$ 的图片上总共生成 $W \times H \times 20$ 个先验框。




图 4-9 标记框宽高比聚类结果

Fig.4-9 The clustering results of the aspect ratio of labeled box

然后对先验框进行二分类，分类的方法是基于 IoU 的阈值分类法。将与任一蔗苗的真实边框的 IoU 大于 0.7 的先验框分类为前景；将与所有真实边框的 IoU 值都小于 0.3 的先验框分类为背景。IoU 的计算公式如式(4-6)所示。

$$\text{IoU} = \frac{|P_{\text{area}} \cap G_{\text{area}}|}{|P_{\text{area}} \cup G_{\text{area}}|} \quad (4-6)$$

其中, P_{area} 和 G_{area} 分别表示预测的目标框和标注的边框所在的区域。

本研究为了与原始 Faster R-CNN 模型进行性能对比, 根据其原文^[44]设定 NMS 的阈值参数同样为 0.7, 只有当 $\text{IoU} > 0.7$ 时, 才认为甘蔗幼苗被检测到 (即是真阳性)。为了避免重复检测 (当在同一区域预测多个目标框或同一区域存在多株甘蔗幼苗时), 每个预测目标框和带标注的边框只考虑一次; 也就是说, 如果预测边框和标注的边框满足 $\text{IoU} > 0.7$, 则标注的边框不用于下一个预测边框的评估。对于预测的边框来说, 如果没有标注的边框与其满足 $\text{IoU} > 0.7$, 则认为预测边框是假阳性的。

4.4 实验设计与结论

4.4.1 实验方案的设计

为了验证改进的 Faster R-CNN 网络相较于原始 Faster R-CNN 对甘蔗幼苗检测性能的变化, 利用采集的数据完成模型训练和模型性能验证的工作, 整个实验流程如图 4-10 所示。

首先搭建基于 Faster R-CNN 的不同结构的改进网络, 将采集的数据经预处理后制作成数据集, 然后将训练集数据输入网络进行训练。利用 ResNet50 和 SN-Block 提取甘蔗的特征; 然后将生成的特征图输入 FPN, 对多尺度特征进行融合; 再将特征输入 RPN 网络, 特征图上的每个点对应输入图像上一个位置, 接着在每个位置生成一定数量不同形状的先验框; 最后通过 softmax 分类器判断先验框是否是前景, 通过边框回归调整前景先验框的坐标。将冗余候选框用 NMS 算法删除, 将得分高的候选框作为感兴趣区域 (ROI)。训练中, RPN 网络的损失、分类层损失与回归层损失分别如式(4-7)~(4-9)所示。

$$L(p_i, b_i) = \frac{1}{Q_c} \sum_i L_c(p_i, p'_i) + \mu \frac{1}{Q_r} \sum_i p'_i L_r(b_i, b'_i) \quad (4-7)$$

$$L_c(p_i, p'_i) = -\lg(p_i p'_i + (1 - p_i)(1 - p'_i)) \quad (4-8)$$

$$L_r(b_i, b'_i) = \sum_i \text{smooth}_{L_1}(b_i - b'_i) \quad (4-9)$$

$$\text{smooth}_{L_1}(b_i - b'_i) = \begin{cases} 0.5(b_i - b'_i)^2 & (|b_i - b'_i| < 1) \\ |b_i - b'_i| - 0.5 & (|b_i - b'_i| \geq 1) \end{cases} \quad (4-10)$$

$$p'_i = \begin{cases} 1 & (\text{先验框为正样本}) \\ 0 & (\text{先验框为负样本}) \end{cases} \quad (4-11)$$

式(4-7)~(4-11)中, i 表示先验框的序号; p_i 表示某先验框预测是甘蔗苗的概率; p'_i 为先验框判断结果; μ 负责平衡权重。 Q_c 为分类时一个小批次数据中的蔗苗数; Q_r 为回归时的蔗苗数; b_i 表示预测的甘蔗幼苗边框的坐标; b'_i 表示人工标注的甘蔗幼苗边框坐标; smooth_{L_1} 表示平滑后的 L_1 损失函数。




图 4-10 试验流程图

Fig.4-10 Experiment flow chart

经过 ROI 池化将所有区域特征图尺寸固定为 7×7 ，然后在 Fast R-CNN 中对候选区域进行检测。经过全连接层后通过 softmax 分类器判断候选边框所属类别，同时利用多任务损失边界框回归算法调整目标候选框的位置。

训练的基本学习率为 0.001，动量为 0.9（表示最后一次梯度更新的权重），权重衰减为 0.0001，以避免过拟合。在每次训练迭代中使用 Momentum 动量优化方法优化损失函数的计算以更新网络参数，达到训练次数后将训练模型保存。

训练之后，需要完成模型性能评估的对比试验，利用不同结构的改进网络和原始 Faster R-CNN 网络对验证集数据进行检测，使用 4.4.2 节中提到的性能评估指标对检测结果进行对比分析，保存检测精度最高的模型以用于后续检测。为了更直观地对比模型性能的变化，本文将实际检测结果以及在验证集生成的 Precision-Recall 曲线可视化，并对模型识别的情况进行分析。

4.4.2 模型检测性能的评估

将不同参数训练得到的检测模型保存下来后，需要进一步评估这些模型的检测精度，选择性能最优的模型用于最后大尺寸航拍图像中甘蔗幼苗的检测与计数。具体方法是：首先将制作的验证集输入保存的模型进行检测，利用性能评估指标评价不同模型的检测精度，在此阶段选择平均精度最高的模型作为最终用于实际检测的模型。

选择准确率 P 、召回率 R 、平均精度 AP 和平均召回率 AR 评价模型的性能。 AP 值为准确率对召回率的积分，平均召回率 AR 则定义为在一定数量的数据集上召回率的平均值。准确率 P 反映检测的真实蔗苗数占检测结果的百分比；而召回率 R 反映预测的实际蔗苗数占实际蔗苗总数的百分比。具体计算如式(4-12)~(4-15)所示。

$$P = \frac{TP}{TP + FP} \quad (4-12)$$

$$R = \frac{TP}{TP + FN} \quad (4-13)$$

$$AP = \int_0^1 PR dR \quad (4-14)$$

$$AR = \frac{1}{Q} \sum_{q=1}^Q R(q) \quad (4-15)$$

式(4-12)~(4-15)中， TP 代表检测的真实蔗苗（正样本）数； FN 表示真实蔗苗被误检

为非蔗苗（负样本）的样本数； FP 表示错误将非蔗苗部分识别为蔗苗的样本数； $R(q)$ 表示数据集中某一张图像 q 的召回率， Q 是待检测的图像总数。

4.4.3 实验结果对比与分析

(1) 不同特征提取器对 Faster R-CNN 检测结果的影响

使用残差网络能有效解决因骨干网络加深引起的性能退化问题。为了验证残差网络更适合作为甘蔗幼苗检测模型的骨干网络，在验证集上进行以 ResNet50、ResNet101 与 VGG16 网络作为 Faster R-CNN 的骨干网络时模型检测性能的对比试验，结果如表 4-3 所示。

表 4-3 不同特征提取网络的试验结果对比
Table 4-3 Comparison of experimental results of different feature extraction networks

测试指标	特征提取网络		
	VGG16	ResNet50	ResNet101
平均精度 AP/%	84.98	88.24	88.62

(2) RPN 候选框尺寸比例对检测结果的影响

采用 4.3.5 节提出的先验框形状和大小，利用以 ResNet50 为特征提取器的 Faster R-CNN 框架训练模型以进行先验框参数修改前后的对比实验，得到如表 4-4 所示的结果。将先验框改进为 20 种后，平均准确率提升了 1.64%，平均召回率提升了 1.52%。结果表明，该步骤通过调整先验框的初始参数能提高一定的蔗苗检测精度。

表 4-4 不同候选框宽高比的实验结果
Table 4-4 Experimental results of different aspect ratio of anchors

基础 anchor 个数	AP/%	AR/%
9	88.24	85.70
20	89.88	87.22

(3) SN-Block 结构对检测结果的影响

为验证本文提出的算法的有效性，对特征提取器改为 ResNet50 且使用改进的 RPN 网络的 Faster R-CNN 和在其基础上引入注意力模块后的 Faster R-CNN 在 398 张验证集图像上识别的结果进行对比。本文提出的方法在平均准确率上提升了 0.71%，召回率提升了 0.43%，结果如表 4-5 所示，说明引入 SN-Block 结构能提高蔗苗的检测精度。

表 4-5 引入注意力模块后的识别结果
Table 4-5 Recognition results after embedding network structure based on attention mechanism

网络类型	AP/%	AR/%
Faster R-CNN+ResNet50	89.88	87.22
Faster R-CNN+ResNet50+SN-Block	90.59	87.65

(4) 模型改进前后实验结果对比

为了对比不同的网络结构改进方式对检测性能的影响，在设置 20 种先验框的条件下进行实验。4.3.2~4.3.5 节中改进的网络结构的组合及整体改进后的检测结果如表 4-6 所示。由表 4-6 最后一行可知，基于 Faster R-CNN 的改进网络在验证集上表现的性能最好，平均精度达到 93.67%，平均召回率已经接近 90%，实验结果说明按照本文提出的方法改进 Faster R-CNN 网络结构能显著提升田间甘蔗幼苗的检测精度。

表 4-6 不同改进方式下检测结果的比较

Table 4-6 Comparison of detect results under different improvement methods			
网络结构	先验框数量	AP/%	AR/%
Faster R-CNN	20	86.58	84.91
Faster R-CNN+ResNet50	20	89.88	87.22
Faster R-CNN+ResNet50+SN-Block	20	90.59	87.65
Faster R-CNN+ResNet50+SN-Block+FPN	20	93.67	89.78

(5) 与其他常用算法的对比


与作物目标检测领域其他常用算法——YOLO v2、YOLO v3、SSD 在本文数据集上进行对比实验，结果如表 4-7 所示。将之前得到的实验数据与其他算法进行比较，本文提出的方法对子图检测的平均准确率和平均召回率均高于其他算法，说明本文的方法用于田间环境下子图中蔗苗的检测与计数可靠性更高。

表 4-7 与常见作物目标检测算法的对比


Table 4-7 Comparison with common crop object detection algorithms		
算法名称	AP/%	AR/%
YOLO v2	79.75	76.84
YOLO v3	82.46	80.33
SSD	77.50	74.21
Faster R-CNN	84.98	83.56
改进 Faster R-CNN	93.67	89.78



(a) 测试图 1



(b) 测试图 1 在 Faster R-CNN 中的检测结果



(c) 测试图 1 在改进的 Faster R-CNN 中的检测结果




图 4-11 图像瓦片检测结果可视化

Fig.4-11 Visualization of image tiles detection results

分别使用原始 Faster R-CNN 网络和最终改进后的 Faster R-CNN 网络训练的检测模型对验证集中田间的甘蔗幼苗进行识别，将实际的检测结果进行可视化展示，部分结果如图 4-11 所示，图中红色虚线框代表漏检的样本，黑色虚线框代表误检样本。

从图 4-11 中的(a)~(f)可以看出，针对小尺寸甘蔗幼苗和叶片存在遮挡的幼苗，改进的 Faster R-CNN 网络比原始的 Faster R-CNN 网络检测效果更好。另外对于尺寸较小的杂草，由于颜色跟甘蔗幼苗很接近，并且特征不是很明显，原始的 Faster R-CNN 会将这部分杂草误检为蔗苗，但是改进的 Faster R-CNN 已经改善了这个问题，从图 4-11 中的 (g)~(i)可以反映。为了直观地反映不同网络结构生成的模型检测精度的高低，遍历整个验证集，将检测的准确率 P 和召回率 R 进行可视化，通过 PR 曲线直观地反映出性能的变化，可以通过曲线与坐标轴围成的面积直观地比较模型的性能，生成的 Precision-Recall 曲线如图 4-12 所示。其中 PR1 为原始 Faster-RCNN 模型的 PR 曲线，PR2 为以 ResNet50 为特征提取器的 Faster-RCNN 模型的 PR 曲线，PR3 为最终改进后 Faster-RCNN 模型的 PR 曲线，从图中可以看出 PR3 与坐标轴围成的面积是最大的，反映出改进的 Faster R-CNN 网络的检测精度确实有显著提升。




图 4-12 Precision-Recall 曲线对比图

Fig.4-12 Comparison of Precision-Recall Curve

本研究将改进后的 Faster R-CNN 用于田间环境下甘蔗幼苗的检测,检测精度较高,在验证集上平均精度达到了 93.67%。并且能较好的适应不同的光照条件、不同遮挡程度和不同的杂草密度等环境条件,说明模型泛化能力较强。能够有效识别田间的甘蔗幼苗。最后将这一性能最优的模型保存下来,将其命名为 SGN-D 模型,为下文介绍大田甘蔗幼苗群体的检测与计数做了铺垫。

4.5 本章小结

本章先用标准的 Faster R-CNN 训练甘蔗幼苗的检测模型,模型在验证集上检测精度为 84.98%,检测时存在对杂草的误检和对小尺寸甘蔗幼苗的漏检等问题。基于上述不足,本研究对 Faster R-CNN 网络进行改进,提出了针对田间甘蔗幼苗检测的网络结构。本章对改进部分进行了详细阐述,训练不同结构的检测网络。然后在验证集上开展检测性能的对比实验,实验结果表明本文提出的网络模型检测的平均精度比 Faster R-CNN 更高,达到了 93.67%。将本文提出的网络训练得到的模型命名为 SGN-D 模型,最后对 SGN-D 模型的实际检测结果进行分析,发现对杂草的误检明显下降,并且对小尺寸幼苗的检测也进一步加强,足以证明本文提出的 SGN-D 模型,在田间环境下对甘蔗幼苗检测时比 Faster R-CNN 更有效。

第五章 基于 SGN-D 模型的大田甘蔗幼苗计数方法

5.1 概述

上一章设计了基于 Faster R-CNN 的改进模型——SGN-D 模型，并针对裁剪得到的 600×600 的子图进行了模型训练与测试，取得了较好的效果。但是由于输入图像尺寸受限，不能直接输入原始的大尺寸航拍图像。于是，本章提出对大尺寸航拍图像进行带重叠度的裁剪后送入模型批量检测，然后再将检测结果合并实现对大尺寸航拍图像中甘蔗幼苗的检测及群体数量的统计。

本章先介绍了大尺寸航拍图像的批量检测结果合并与去重算法，该算法采用非极大值抑制机制，可去除大尺寸航拍图像批量结果合并时边缘重叠区域的重复边框，在一定程度上解决了计算机性能对航拍图像目标检测的约束。本章还通过实验讨论了非极大值抑制步骤中 IoU 阈值的不同取值对大田甘蔗幼苗检测与计数性能造成的影响。

另外，本文为了提高用户对大田甘蔗幼苗的检测与计数的效率，满足用户定制化训练模型参数的需求，研发了大田甘蔗幼苗自动检测与计数系统软件，对人机互动流程做了进一步精简。整个软件涵盖了模型训练和检测两个过程。在训练阶段用户可以对自己采集的航拍图像进行预处理和标注，进行数据的扩充和数据集的格式转换，并可实现对模型参数的重新训练；训练的模型将更加适合用户实际的田间场景。在检测阶段，该软件可以实现批量读取原始大尺寸航拍图像，检测和统计蔗苗数量，同时显示原图和检测结果图等功能。

下面将对蔗苗计数算法及开发的软件平台进行详细的介绍。

5.2 大田甘蔗幼苗群体的检测与计数

本算法的主要目的是利用之前训练得到的模型实现对大尺寸航拍图像中所有甘蔗幼苗的检测与计数。前述提到，蔗苗的识别模型是针对裁剪后的子图设计的，为了提高原图统计精度，还特意选择了带一定重叠度的裁剪方式。为了准确统计原始图像或更大尺寸的拼接图像中的蔗苗数量，不能对所有子图的检测结果进行简单累加，需要将子图的检测结果进行合并，然后对重叠区域重复检测的结果进行去重。因此，去重算法非常

关键，直接决定了群体蔗苗的统计精度。

5.2.1 检测结果合并

在去重算法设计之前，需要先将各子图的识别结果进行合并，在原始大图中进行显示。子图检测结果中的识别框的位置和大小通常会使用两种方式表示，一种是使用中心点坐标 (x, y) 和边界框的宽高 (w, h) 一起表示，另一种则使用边框左上角顶点 (x_1, y_1) 和右下角顶点 (x_2, y_2) 一起表示。本方法采用第二种方式定义识别框的位置。对子图的识别结果进行合并需要按照子图像块的编号顺序及裁剪时的重叠度信息对检测框通过坐标转换的方式进行。子图编号形式为 $\{0_0_600_600, 0_1_600_600, \dots, 1_0_600_600, 1_1_600_600, \dots, y_i_x_i_600_600\}$ 。设子图中某识别框的左上角和右下角顶点坐标分别为 (x_1, y_1) 和 (x_2, y_2) ，根据其所在图像块的编号信息进行坐标转换，将它们统一转换到原始大尺寸航拍图像所代表的坐标系中。识别框新的左上角顶点 (x_1^*, y_1^*) 和右下角顶点 (x_2^*, y_2^*) ，分别使用等式(5-1)~(5-4)计算。

$$x_1^* = x_1 + x_{\text{shift}}x_i \quad (5-1)$$

$$y_1^* = y_1 + y_{\text{shift}}y_i \quad (5-2)$$

$$x_2^* = x_2 + x_{\text{shift}}x_i \quad (5-3)$$

$$y_2^* = y_2 + y_{\text{shift}}y_i \quad (5-4)$$

上面各式中 x_{shift} 和 y_{shift} 是需要调整的不同图像块中目标框的横向位移和纵向位移，而 x_i 和 y_i 是子图像块命名编号中对应位置的数值。裁剪后子图的尺寸为 600×600 ，假设给定的水平重叠度和垂直重叠度分别是 $OverLapPercentage_x$ 和 $OverLapPercentage_y$ 。则 $600OverLapPercentage_x$ 和 $600OverLapPercentage_y$ 分别表示水平和垂直方向重叠的像素数，那么 x_{shift} 和 y_{shift} 可以用式(5-5)和(5-6)计算：

$$x_{\text{shift}} = 600 - 600OverLapPercentage_x \quad (5-5)$$

$$y_{\text{shift}} = 600 - 600OverLapPercentage_y \quad (5-6)$$

坐标转换的示意图如图 5-1 所示，其中最大的矩形 OABC 表示输入的原始图像，其中裁剪后的子图块用宽高尺寸分别为 600 的小矩形表示， $over_x$ 和 $over_y$ 分别表示水平和垂直方向重叠的像素数。用于举例说明的蓝色小矩形的编号为 $0_1_600_600$ 。

最后将转换后的坐标绘制到大图中实现子图识别结果的合并，合并结果如图 5-2 所示。




图 5-1 坐标转换示意图

Fig.5-1 Diagram of coordinate transformation



图 5-2 未使用去重算法的合并结果

Fig.5-2 Detection results of unused redundant bounding box algorithm

从图中可以看出，在子图重叠区域存在大量重复的识别框，大致分两种情况：一种

是单株重复检测，完整的一株甘蔗在重叠的子图中被多次检测；另一种是部分重复检测，一株完整的幼苗可能在裁剪时被分成几部分，导致这些组成部分被重复检测。为了防止重叠区域的冗余边框降低检测精度，本研究设计了一种目标去重算法。该算法通过应用非极大值抑制（NMS）机制对重复边界框进行筛选，只保留最佳边界框，并进行了对比实验。图 5-3 所示为图 5-2 对应的使用了去重算法后的结果。



图 5-3 使用去重算法后的合并结果

Fig.5-3 Detection results after using redundant bounding box algorithm

5.2.2 非极大值抑制的原理及实现方法

下面介绍该算法的核心部分，即非极大值抑制的原理及实现方法。非极大值抑制是寻找局部最大值的过程，在进行目标检测时，图像上生成的候选框进行特征提取后会传入分类器，分类器一般会给出置信度。然后将有得分的候选框全部排序。选出得分最高的候选框，接着计算其他候选框与其重叠度(IoU)，达到重叠度的阈值就进行删除，否则就保留该候选框，重复以上过程。

假设输入的待检测图像包含 N 个候选边界框，使用分类网络计算每个边界框对应分类的类别概率即置信度 $scores$ ， $1 \leq i \leq N$ ，NMS 过程包括以下步骤：

第一步：构造一个集合 C 来存储所有 N 个边界框，这些边界框按置信度 $scores$ 的值排序；此外，构造一个集合 O 来存储保留的边界框，并将其初始化为空集。

第二步：从集合 C 中选择最高置信度的边界框（表示为 B ），并将其移动到集合 O 。

第三步：计算 C_i 的区域面积和 B 的区域面积之间的 IoU 重叠度，其中 C_i 是 C 中的候选边界框， $i=1, 2, \dots, |C|$ ；按照设置的 IoU 的阈值进行过滤，与 B 的区域面积存在 IoU 重叠且大于一定阈值 λ 的边界框 C_i 被视为 B 的冗余边界框。

第四步：从 C 中删除所有冗余的边界框。

第五步：重复第二步到第四步，直到集合 C 为空；集合 O 中的边界框就是我们需要的。

但是 NMS 算法应用到批量检测结果合并时的去重有一个问题，一般 NMS 在目标检测中使用较多的情况是对同一张图像上出现的重复检测目标框进行去重，因为计算 IoU 时要保证边框之间有重叠，但是不同图像上生成的检测边框都是以每张图像本身左上角的顶点为原点建立的参考系，所以不同图像上检测的边框坐标不能反映由这些图像拼接的大尺寸图像上边框之间的相对位置关系。

5.2.3 基于非极大值抑制的去重算法设计

为了将 NMS 算法用于批量检测结果的合并去重，本方法主要通过先将子图中目标框的坐标转换成大尺寸航拍图像中的坐标然后使用去重算法。这是一种后处理的方法，方法的具体步骤如下：

1) 将经过自适应对比度增强的大尺寸图像运用带边缘重叠像素的裁剪方式裁剪成均匀大小，并且将裁剪后的子图像块命名为 $\{0_0_600_600, 0_1_600_600, \dots, 1_0_600_600, 1_1_600_600, \dots, y_i_x_i_600_600\}$ 。

2) 设置 IoU 的阈值 λ ，将裁剪的子图输入检测模型中。

3) 将每个子图中检测到的边界框坐标、边界框的类名以及置信度分数按对应的顺序保存到集合 A 中。

4) 将集合 A 中边界框的左上角顶点 (x_1, y_1) 和右下角顶点坐标 (x_2, y_2) 根据其在图像块的命名信息进行坐标转换，将它们同一转换到原始大尺寸航拍图像所代表的坐标系中。边界框转换后的坐标使用等式(5-1)~(5-4)计算。

5) 将转换后的边界框坐标和对应的类别名称及置信度分数重新保存到一个新的集合 B 中，对集合 B 使用 NMS 算法，将去重后的边界框坐标与对应的置信度分数保存到另一个集合 C 中，此时 C 中任何一个边界框的坐标都已经成为基于原始大尺寸航拍图像坐标系下的坐标。

6) 最后读取完整的大尺寸航拍图像，将集合 C 中边界框的坐标及置信度分数在原

始大尺寸图像上绘制出来，就可以得到最终的检测结果。统计此时集合 C 中的目标框的数量，得到的就是应用去重算法后计算的甘蔗幼苗总数。

5.2.4 结果与讨论

上一小节步骤 2)中参数 λ 代表 IoU 的阈值，是一个预先设置的常数，用于确定边界框之间是否存在冗余的边框。为了证明阈值 λ 会影响大尺寸航拍图像中全体甘蔗幼苗检测的精确度，本方法选取不同的 IoU 阈值在 20 张用于测试的图像上进行检测性能的对比实验。在实验中， λ 取 6 个值：0.05、0.1、0.15、0.2、0.25 和 0.3，并以准确率 Precision、召回率 Recall 和 F1 分数（F1-score）作为评价指标来评价检测性能，准确率和召回率的计算公式见 4.4.2 节中式(4-12)和(4-13)，F1 分数的计算过程如下：

$$F1\text{-score}=\frac{2Precision \times Recall}{Precision + Recall}$$

(5-7)

为了计算本方法在大尺寸航拍图像中对图中全体甘蔗幼苗的检测精度，这里的准确率、召回率和 F1 分数都是用所有测试图像检测结果的真正（TP）、假正（FP）和假负（FN）样本的总数进行计算的，其中 Precision 为正确检测到的甘蔗幼苗总数除以检测到的所有甘蔗幼苗的总数，Recall 为正确检测到甘蔗幼苗总数除以地面实际的甘蔗幼苗总数，正确的检测是指检测结果中的边界框能准确包围单株的甘蔗幼苗。

表 5-1 展示了在保存的性能最优的模型上对测试集检测的数值结果。这些结果进一步证实了本方法训练的模型可以准确检测到大尺寸无人机图像中的甘蔗幼苗。

表 5-1 不同 IoU 阈值下大田蔗苗自动计数系统的检测性能
Table 5-1 Detection performance of automatic field sugarcane seedling counting system under different IoU thresholds

IoU 阈值	Precision (%)	Recall (%)	F1-score (%)
$\lambda=0.05$	95.32	86.93	90.93
$\lambda=0.10$	93.14	92.76	92.95
$\lambda=0.15$	92.70	94.65	93.66
$\lambda=0.20$	91.34	95.20	93.23
$\lambda=0.25$	89.93	96.24	92.98
$\lambda=0.30$	88.02	96.66	92.14

实验结果表明， λ 值过低或过高都会导致检测性能下降。在极端的情况下（ $\lambda = 0$ ），表示模型删除所有相交的检测结果，只保留不相交的检测结果。这种消除冗余的方法既苛刻又不合理，因为一些相邻的甘蔗幼苗本身就有重叠的部分。当 λ 接近 0 时，假负样本的数量增加，这反映在召回率和 F1 分数的减少上。如果使用较大的 λ 值，则保留相

交的一部分检测结果，从而减少假负样本的产生。以 $\lambda = 0.1$ 和 0.15 为例，甘蔗幼苗检测的 F1 得分超过 92%，召回率比 $\lambda = 0.05$ 时高出约 5~7%，这意味着增加 λ 可以获得更准确的检测结果。然而，增加 λ 并不总是可以提高检测性能。以 $\lambda = 0.2$ 和 0.3 为例，当 λ 继续增加时，假正样本的数量开始增加，造成甘蔗幼苗检测的 F1 得分和准确率都在下降，当 $\lambda = 0.3$ 时，召回率的增长并不明显，但准确率已经下降到 90% 以下。特别是当 $\lambda = 1$ 时，保留所有检测结果。在这种情况下，NMS 机制失去了减少冗余的能力，从而增加了误报的概率，导致出现更低的准确率和 F1 分数。基于以上实验的结果，说明合理设置 IoU 的阈值可以改善大尺寸航拍图像检测结果合并与去重算法的性能，可以有效提高大田甘蔗幼苗群体识别的精度。 $\lambda = 0.15$ 时对应的大田甘蔗幼苗群体实际的检测效果如图 5-4 所示。




图 5-4 $\lambda = 0.15$ 时实际检测效果

Fig.5-4 Actual detect results when $\lambda = 0.15$

在实际使用时，用户可以通过自己准备的测试图像确定最优的 IoU 阈值，一般 λ 在 $0.05 \sim 0.3$ 范围之间取值，然后用测试图像以不同的 λ 值进行检测，最后选择最高 F1 分数对应的 λ 值作为实际检测的经验值，在后续的检测任务里直接用该 λ 值作为去重算法中预设的 IoU 阈值。比如在上述实验中， $\lambda = 0.15$ 对应的 F1 分数最高，那么就将 0.15 确定为 NMS 机制中 λ 的经验值，在后续进行实际的检测任务时直接令检测结果合并和去重算法的 IoU 阈值等于 0.15 。

在评估此方法的计数性能时，使用平均绝对误差（MAE），计数准确率（ACC）和

R^2 值作为评价指标。计算公式如下：

$$MAE = \frac{1}{n} \sum_{i=1}^n |a_i - c_i| \quad (5-8)$$


$$ACC = \left(1 - \frac{1}{n} \sum_{i=1}^n \frac{|a_i - c_i|}{a_i} \right) \times 100\% \quad (5-9)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (a_i - c_i)^2}{\sum_{i=1}^n (a_i - a_i^*)^2} \quad (5-10)$$


上面各式中， a_i 、 a_i^* 和 c_i 分别是第 i 张无人机图像中甘蔗幼苗的地面真实值计数，平均地面真实值数量和第 i 张图像的预测计数（检测到的边界框总数）， n 是测试的无人机图像的数量，MAE 和 ACC 用于量化检测模型的计数精度， R^2 用于评估模型预测的计数结果与地面真实值之间的相关性，并且 MAE 的值越低，ACC 和 R^2 的值越高表示计数性能越好。

验证不同 λ 的取值对应的计数精度（如图 5-5 和表 5-2 所示）。图 5-5(a)显示了用于测试的图像中每一幅图像的 8 个计数结果，包括由训练得到的甘蔗幼苗检测模型以不同 λ ($\lambda = 0.05, 0.1, 0.15, 0.2, 0.25, 0.3$) 获得的 6 个预测计数、未使用基于 NMS 机制去重算法的计数和作为比较基线的人工调查计数（地面真实值）。从图 5-5(a)可以看出，对于几乎所有的图像，该检测模型未使用基于 NMS 机制去重算法得到的预测结果与地面真实值存在很明显的差距，并且都比真实的幼苗数量高出很多，这是因为输入模型的图像块边缘存在很多重叠区域，重叠区域里又存在大量密集的甘蔗幼苗，由于检测时图像块是批量输入模型检测的，那么过度检测产生的重复边框会对结果产生很大的影响。接着为了更明显且直观地表现不同 IoU 阈值的取值对于大田甘蔗幼苗实际计数结果的影响，图 5-5(b)只显示用于测试的 20 幅图像中每幅图像七次计数的结果，包括使用 6 个不同 λ 值在模型的检测结果中得到的预测计数以及地面真实值计数。另外对于测试的所有图像，将人工调查得到的甘蔗幼苗株数与由模型预测得出的计数结果进行相关性分析，总共包含未使用去重算法和 λ 取 6 个不同值这七种情况，图 5-6 和 5-7 展示了线性回归的结果，横坐标为地面真实值计数，纵坐标是其对应的模型预测的计数结果。图 5-6 中未去重的预测株数与人工计数相关性很低，趋势线与 $y = x$ 这条直线偏离的程度太大，说明预测结果不可靠。而图 5-7 中使用去重算法后，所有趋势线都比去重前要更接近直线 $y = x$ 。实验结果表明，人工计数和模型自动计数在所有图像上都显示出很强的正相关性， R^2 最低为 0.9687，最高可达 0.9905，证明本文提出的方法对甘蔗幼苗的田间计数是有效的。

表 5-2 给出了计数性能的更详细的量化评估结果, 结果表明, 在大多数情况下, 使用 $\lambda = 0.15$ 预测的计数结果比用 $\lambda \neq 0.15$ 预测的计数结果更接近地面真实值的计数, 显示出较高的精确度 (96.83%) 和更小的 MAE (4.60 株; 见表 5-2), 这表明该模型对大尺寸航拍图像中甘蔗幼苗的群体数量进行了合理地预测。当 $\lambda = 0.05$ 和 0.3 时, 计数结果分别出现过低和过高的情况, 这之前分析的相一致。这些结果进一步证实, 使用 $\lambda = 0.15$ 这个经验值得到的结果比 $\lambda \neq 0.15$ 时更好。



(a)



(b)

图 5-5 使用不同 IoU 阈值对 20 幅测试图像的预测计数及其中每幅图像的地面真值计数
Fig.5-5 Predicted count for different IoU thresholds obtained from SGN-D model versus ground truth count for each of the 20 images in the test set




图 5-6 未去重的预测株数与人工调查株数的相关性

Fig.5-6 The correlation between the number of predicted plants and the number of manually counted plants without removing the repeated identification box




图 5-7 去重的预测株数与人工调查株数的相关性

Fig.5-7 Correlation between the number of predicted plants and the number of manually counted plants

表 5-2 模型使用不同 IoU 阈值进行检测时的计数性能

Table 5-2 Counting performance of SGN-D model for different IoU thresholds

IoU 阈值	ACC (%)	MAE (株)	R ²
$\lambda = 0.05$	87.63	21.55	0.9687
$\lambda = 0.10$	94.08	10.15	0.9824
$\lambda = 0.15$	96.83	4.60	0.9905
$\lambda = 0.20$	92.73	10.30	0.9880
$\lambda = 0.25$	86.75	19.15	0.9784
$\lambda = 0.30$	81.06	28.05	0.9746

综上所述,当 IoU 阈值 λ 取 0.15 时,计数准确率 ACC 和 R^2 的值都是最高的,并且平均绝对误差 MAE 最低,证明 λ 为 0.15 时模型的性能可以达到最优,能显著提高大尺寸航拍图像中甘蔗幼苗群体的识别和计数精度。

5.3 蔗苗自动检测与计数系统软件设计

为了提高利用深度学习方法进行模型训练和实际检测的效率,基于本研究采用的方法,利用 PyQT5 框架设计了一套蔗苗自动检测与计数的软件系统。用户可以使用该软件完成自定义数据集的模型训练以及对大田航拍图像中甘蔗幼苗的自动计数。

本章主要从模型训练和实际检测两个方面介绍大田甘蔗幼苗自动检测与计数系统软件的相关操作界面。使用该软件的流程如图 5-8 所示。




图 5-8 软件的使用流程

Fig.5-8 Process of using the software

5.3.1 自定义模型的训练

打开软件后的初始界面如图 5-9 所示，用户可在此界面选择训练自有数据集或直接利用训练好的模型进行蔗苗的检测与计数。若用户选择训练自有数据集，可以根据自有数据集是否已标注选择相应的操作制作数据集或转化及统计现有数据集。




图 5-9 软件初始界面

Fig.5-9 Software initial interface

(1) 数据集制作

自有数据集制作的操作界面如图 5-10 所示。主要包含 8 个主要步骤，依次是自适应对比度增强、不带重叠度的裁剪、人工标注、数据扩充、批量重命名、格式转换、统计标注框宽高比、统计标注样本数。其中第 1 步至第 4 步是制作数据集的必选步骤，第 5-7 步是对数据集中人工标注框的宽高比进行统计，为模型训练提供 RPN 层先验框的初始宽高比的默认值，也是必选步骤。“Box count”用于统计数据集中包含的标注样本的总数，属于辅助功能。下面对各步骤进行简单的介绍。

第一步：执行自适应对比度增强操作。用户点击进入图 5-11 所示的界面，可以通过调节上方的三个游码分别修改“半径”、“数量”和“MAX CG”这三个参数对图像进行增强处理。“半径”是指取样半径，取样半径与模型的运算速度息息相关，值越大表示像素点关联的区域就越大，计算时间就越长。如果半径太小又会引起局部标准差减小，导致增益值过大。本研究采用的默认值为 30。“数量”这个参数是用来再次控制高频部分的增强程度，值取得太高可能导致在图像边缘或其他高频部分出现过度增强，本研究默认取值为 50。“MAX CG”控制增益的最大值。本文通过实验确定一般“半径”的范围为 20~40，“数量”的范围一般为 30~80，“MAX CG”在 10 以下，通常对同一批次的图

像采用同一组参数进行批处理。该界面将原始界面与增强后的图像同步显示，用户可以直观地判断自适应对比度增强的效果。




图 5-10 制作数据集的界面

Fig.5-10 software interface of making dataset




图 5-11 自适应对比度增强操作界面

Fig.5-11 Operation interface of adaptive contrast enhancement

第二步：将增强后的图像进行不带重叠度的均匀裁剪。用户可以实现在指定路径下将所有图片裁剪成 600×600 像素大小的子图。

第三步：对人工筛选的子图进行数据标注。用户可以进入 Labellmg 这个开源的标注工具界面，如图 5-12 所示。标注时，用户需用尽可能小的矩形框来充分包围一个完整的甘蔗幼苗，并给每个矩形框增加“Sugarcane”这个类名作为样本标签。



图 5-12 数据标注

Fig.5-12 Data annotations

第四步：采用翻转和旋转变换对训练及验证数据集进行扩充。用户在此界面中可一次性完成数据集水平翻转、垂直翻转、90°旋转、180°旋转及 270° 旋转共五种变换，数据集因此扩大五倍。至此，数据集制作完成。

(2) 格式转换及统计现有数据集

当用户已经有标注的数据集可以直接跳过数据集制作的界面，只需完成第五步至第七步即可进行模型的训练。

第五步：数据批量重命名。这一步是为了给第六步转换成 VOC 格式的数据集做铺垫。用户可以将指定路径下的所有文件从“00000”开始按递增的顺序重新命名。

第六步：数据集格式转换。在第五步的基础上将重命名的图像和 xml 格式的标签文件封装成 COCO 数据集的格式，用于在第七步中统计标注框的宽高比。

第七步：统计数据集中人工标注框的宽高比。第五步和第六步的操作是在为第七步做准备，在第六步得到的 COCO 格式的数据集基础上统计标注框的宽高比并将宽高比的分布图可视化显示，用户可以通过这一步得到的宽高比值作为模型训练时先验框 anchor 的初始宽高比，有利于提高目标检测精度与模型的训练速度。

第八步：统计标注的样本数量。这一步属于辅助性的功能，用户可根据自身需求决定是否执行该操作。本操作界面主要作用是让用户看到数据集中标注的样本数量，便于及时补充数据集中的样本。人工标注样本的统计结果如图 5-13 所示。



图 5-13 统计标记的样本数

Fig.5-13 Count the number of labeled samples

(3) 模型的训练与验证

用户制作完成数据集后，选择下一步进入训练和检测的主界面，如图 5-14 所示。该界面包含“Generate pkl document”和“Train and Validation”，按从上到下的顺序执行。

“Generate pkl document”操作的目的是将数据集中图像与对应的 xml 标签文件封装成 pkl 格式的数据集文件方便训练程序读取数据。训练集与验证集需各转换成一个 pkl 格式的数据集。



图 5-14 训练和检测功能界面

Fig.5-14 Train and detect function interface

当用户生成训练集和验证集的 pkl 文件以后，即可进入“Train and Validation”，进行模型的训练和验证，相应界面如图 5-15 所示，用户进入该界面后需要输入训练的 3 个

参数。“train”参数代表训练和验证两种处理模式，输入 0 执行验证模式，输入 1 则执行训练模式；“epoch_heads”后面输入用户设定的训练骨干网络的批次数；“epoch_all”后面输入用户设定的训练所有网络层的批次数。确定上面 3 个参数以后，用户可根据提示选择相应的路径。其中点击“ROOT_DIR_path”选择生成训练模型和训练日志的路径，接着点击“COCO_path”选择其他预训练的模型。“pkl_path_train”和“pkl_path_val”分别是训练集和验证集的路径。只有在验证模式下，“Curve_path”才需要选择生成的 Precision-Recall 曲线图的路径。




图 5-15 训练与验证操作界面

Fig.5-15 Training and validation operation interface

上文对该软件从训练前的准备工作到模型训练和验证的整个过程进行了详细的介绍。软件将各步骤分开执行，可以方便用户对任一个步骤多次尝试，避免从头开始的繁琐。

5.3.2 甘蔗幼苗的检测与统计

当用户已有符合要求的数据集及训练好的模型，即可进入蔗苗检测与计数界面，如图

5-16 所示。该界面显示的参数及其意义如下：“overlap_x”和“overlap_y”分别表示裁剪的子图之间在水平和垂直方向重叠像素数；“iou_thresh”表示需要在大尺寸航拍图像检测结果合并与去重算法中提前设定的 IoU 阈值。用户通过“RawImg_path”选择待检测的大尺寸的航拍图像所在的文件夹，“model_dir”选择模型文件的路径，“Results_path”则是选择检测结果的保存路径。




图 5-16 甘蔗幼苗检测与计数界面

Fig.5-16 Sugarcane seedling detection and counting interface

原始图像及检测完成的结果将会同时显示在结果显示界面，甘蔗幼苗的预测计数结果在下方的统计结果输出栏进行显示，如图 5-17 所示。最终的检测结果将按照“原始文件名_IoU 阈值_预测计数结果”的命名方式被保存在“Results_path”选择的文件夹下，方便用户进一步对检测结果进行统计和分析。



图 5-17 检测与计数结果可视化

Fig.5-17 Visualization of detect and count results

5.4 本章小结

本章首先介绍了基于 SGN-D 模型的大田甘蔗幼苗群体检测与计数的方法，该方法可以实现输入一张大尺寸航拍图像然后输出带边界框的大图和计数结果，重点介绍该方法的核心算法——基于非极大值抑制机制的大尺寸航拍图像检测结果合并与去重算法，其中在非极大值抑制的相关步骤中需要提前设定一个 IoU 阈值 λ 。为了探究 IoU 阈值对本方法的检测与计数性能的影响，接着本文利用 6 组不同的阈值 λ 在 20 幅用于测试的图像上进行检测与计数性能评估的实验。实验结果表明，当 IoU 阈值设定为 0.15 时，此方法在计数和检测方面性能均达到最佳。本章在后半部分介绍了大田甘蔗幼苗自动检测与计数系统软件的操作流程，用户可以根据操作提示完成模型的训练和实际检测，在操作界面有对输入量的提示，能帮助用户更好的理解该方法中训练和检测的过程。并且在检测阶段，软件可以将原始大尺寸图像、检测结果图和计数结果一起显示在窗口中，让用户能直观地看到检测效果，便于用户统计检测数据。

第六章 总结与展望

6.1 全文总结

为了辅助甘蔗育种中对出苗率及出苗数等表型信息的估算，本文利用无人机平台获取蔗苗的可见光图像，在 Faster R-CNN 目标检测框架的基础上对网络结构进行改进，提出一种基于改进 Faster R-CNN 的大田甘蔗幼苗检测与计数方法。本文完成的工作主要有以下几个方面：

(1) 改进了 Faster R-CNN 的网络结构，并提出针对甘蔗幼苗的目标检测模型——SGN-D 模型。SGN-D 模型将 ResNet50 作为特征提取器替换原来的 VGG16 网络，在 ResNet50 网络的基础上嵌入基于注意力机制的 SN-Block 模块，然后将提取的特征图用 FPN 结构进行多尺度特征融合，有效改善目标尺寸差异对检测精度的影响。并根据数据集的特点改变 RPN 网络中先验框的初始尺寸和宽高比。在验证集上进行了性能对比试验，结果表明，改进的 Faster R-CNN 模型平均检测精度达到 93.67%，比原始网络训练的模型平均检测精度提高了 8.69%。实际检测结果也表明 SGN-D 模型可以改善田间小尺寸蔗苗和存在遮挡的蔗苗的检测精度。

(2) 提出一种基于 SGN-D 检测模型且针对航拍图像中大田甘蔗幼苗计数的后处理方法，通过这种基于非极大值抑制机制的去重算法，可以提高大尺寸航拍图像中甘蔗幼苗群体计数的准确度。使用该方法在测试集图像上进行不同 IoU 阈值对检测和计数性能影响的实验，通过实验确定 IoU 阈值设为 0.15 时检测精度最高，并且在测试集上平均精度达到 93.66%，这个结果与验证集上得到的平均精度很接近，说明用此方法对大田甘蔗幼苗的识别与计数有较高的泛化性。另外在计数性能评估实验中 IoU 阈值取 0.15 时，模型的计数精度 ACC 能达到 96.83%，而平均绝对误差 MAE 只有 4.60 株，说明合理地设置 IoU 阈值可以在一定程度上提高模型在大田中对甘蔗幼苗群体的计数精度。还将人工调查得到的甘蔗幼苗数量与由模型预测得出的计数结果进行相关性分析，实验结果表明人工计数和模型自动计数在所有图像上都显示出很强的正相关性，当 IoU 阈值为 0.15 时，此时 R^2 达到 0.9905，结果证明，选择恰当的 IoU 阈值可以增加该方法计数的有效性。

(3) 开发了大田甘蔗幼苗自动检测与计数系统软件，软件包含了模型训练和检测两

个主要过程，用户可以通过软件训练自己的数据集并且可以通过软件对数据进行批量预处理。在检测阶段，可以窗口显示原始图像、带有检测结果的图像以及计数结果，便于用户分析和统计数据。

6.2 后续工作展望

虽然目前本文在大田甘蔗幼苗检测与计数方面取得一定的成果，但是工作依然存在一些不足，希望在今后的研究工作中能将下面提出的几个问题进一步完善：

(1) 采集的数据不够丰富，本研究所用的数据集主要基于两块试验地，地块内的杂草较少，拍摄时间点均在种植后 30 至 40 天这一范围，拍摄得到的蔗苗差异性及地块差异性不大，数据集通用性验证不足。后期可以多采集不同地块、不同时间段的苗期数据。

(2) 由于本次选择的地块杂草较少，在模型训练时只针对甘蔗进行了检测，导致部分杂草容易被误识别为甘蔗。后续可以增加杂草这一类别的识别，提高精度和鲁棒性。

(3) 无人机搭载的相机分辨率不高，为了拍清楚幼苗，选择的飞行高度比较低，导致难以实现大田全景的拼接。后续可以采用分辨率更高的相机，通过实验确定理想的高度范围，提高图像拼接的成功率。

(4) 虽然本文中采集的数据是幼苗期甘蔗的冠层图像，并且也考虑了不同光照和杂草等环境因素的影响，但是还缺乏早期甘蔗幼苗不同生长周期的冠层图像，可以在今后定期采集甘蔗幼苗的冠层图像，需要保证数据采集周期覆盖甘蔗的整个幼苗期。还要增加更多甘蔗品种的幼苗期图像，避免品种差异给检测精度造成影响。

(5) 大田甘蔗幼苗检测与计数系统软件有些功能还需要增加，比如自动计算并显示测试集图像在预设 IoU 阈值下的平均精度、平均召回率、计数准确率和平均绝对误差等性能评估指标。更进一步还可以编写程序自动计算测试集的最优 IoU 阈值。

6.3 本文创新点

(1) 提出了一种改进的 Faster R-CNN 模型（本文命名为 SGN-D 模型），实现了对大田甘蔗幼苗的高精度检测。该模型在原有的骨干网络上设计了一个新的网络结构：a) 将基于通道注意力机制的模块 SN-Block 嵌入 ResNet50 替换 Faster R-CNN 算法中的 VGG16 网络，可以增强目标特征并抑制背景特征，提高信息的融合效率，同时减少了计算量；b) 在 RPN 网络中调整了先验框初始的宽高比和尺寸，以适应甘蔗幼苗数据集的特点，

可以提高检测精度。

(2) 提出了基于 SGN-D 模型的大田甘蔗幼苗群体检测与计数方法。该方法使用坐标转换将检测框的位置坐标统一转换到原始大尺寸图像的坐标系下，利用非极大值抑制算法对边缘重复检测的目标框去重；通过设置恰当的 IoU 阈值可以提升对蔗苗的计数性能。

参考文献

- [1] 黄新文. 稳定广西甘蔗生产路径研究[J]. 世界热带农业信息, 2019(07): 50-54.
- [2] 李杨瑞, 谭裕模, 李松, 等. 甘蔗作为生物能源作物的潜力分析[J]. 科学中国人, 2007(05): 80-83.
- [3] 赵欢欢, 孙东磊, 卢颖林, 等. 我国甘蔗研究近况、热点分析与展望[J]. 甘蔗糖业, 2018(03): 65-70.
- [4] 彭绍光. 甘蔗育种学[M]. 北京: 中国农业出版社, 1990: 1-392.
- [5] 李杨瑞. 现代甘蔗学[M]. 北京: 中国农业出版社, 2010: 1-313.
- [6] 游建华. 广西甘蔗引种的回顾与展望[J]. 甘蔗, 1999(03): 41-46.
- [7] 李杨瑞. 关于广西的甘蔗育种[J]. 广西糖业, 2019(03): 3-9.
- [8] 郭枫, 邹承武, 姚姿婷, 等. 我国甘蔗主要育种材料的病原病毒检测[A]. 中国植物病理学会. 中国植物病理学会2019年学术年会论文集[C]. 中国植物病理学会: 中国植物病理学会, 2019: 1.
- [9] 李文凤, 单红丽, 黄应昆, 等. 多雨高湿季甘蔗重要病害发生流行动态与防控策略[J]. 中国糖料, 2017, 39(02): 75-77.
- [10] Stein M, Bargoti S, Underwood J. Image Based Mango Fruit Detection, Localisation and Yield Estimation Using Multiple View Geometry[J]. Sensors, 2016, 16(11): 1915.
- [11] 许文波, 张国平, 范锦龙, 等. 利用MODIS遥感数据监测冬小麦种植面积[J]. 农业工程学报, 2007, 23(012): 144-149.
- [12] Salvador A, Giro-i-Nieto X, Marques F, et al. Faster R-CNN Features for Instance Search[J]. I IEEE Computer Society, arXiv: 1604.08893v1, 2016.
- [13] Behera S K, Rath A K, Sethy P K. Fruits yield estimation using Faster R-CNN with MIoU[J]. Multimedia Tools and Applications, 2021(6S): 1-14.
- [14] 武英洁, 房世波, 冯旭宇, 等. 基于Faster R-CNN 的野外环境中蝗虫快速识别[J]. 气象与环境学报, 2020, 36(06): 137-143.
- [15] 李春明, 逯杉婷, 远松灵, 等. 基于Faster R-CNN的除草机器人杂草识别算法[J]. 中国农机化学报, 2019, 40(12): 171-176.
- [16] Mukherjee A, Misra S, Raghuwanshi N S. A survey of unmanned aerial sensing solutions in precision agriculture[J]. Journal of Network and Computer Applications, 2019, 148:102461.
- [17] Zhang W, Li X, Yu J, et al. Remote sensing image mosaic technology based on SURF algorithm in agriculture[J]. EURASIP Journal on Image and Video Processing, 2018, 2018(1): 1-9.
- [18] Perz R, Wronowski K. UAV application for precision agriculture[J]. Aircraft Engineering and Aerospace Technology, 2019, 92(2): 257-263.
- [19] Abdullahi H S, Mahieddine F, Sheriff R E. Technology Impact on Agricultural Productivity: A Review of Precision Agriculture Using Unmanned Aerial Vehicles[C]// International Conference

- on Wireless and Satellite Systems. Springer, Cham, 2015, 154: 388-400.
- [20] Pallottino F, Figorilli S, Cecchini C, et al. Light Drones for Basic In-Field Phenotyping and Precision Farming Applications: RGB Tools Based on Image Analysis[J]. *Methods in molecular biology* (Clifton, N.J.), 2021, 2264: 269-278.
- [21] Barrero O, Perdomo S A. RGB and multispectral UAV image fusion for Gramineae weed detection in rice fields[J]. *Precision Agriculture*, 2018, 19(5): 809-822.
- [22] Enciso J, Avila C A, Jung J, et al. Validation of agronomic UAV and field measurements for tomato varieties[J]. *Computers and Electronics in Agriculture*, 2019, 158: 278-283.
- [23] Ampatzidis Y, Partel V. UAV-Based High Throughput Phenotyping in Citrus Utilizing Multispectral Imaging and Artificial Intelligence[J]. *Remote Sensing*, 2019, 11(4): 410.
- [24] Xu R, Li C, Paterson A H, et al. Multispectral imaging and unmanned aerial systems for cotton plant phenotyping[J]. *PLoS ONE*, 2019, 14(2): e0205083.
- [25] Mulla D J. Twenty five years of remote sensing in precision agriculture: Key advances and remaining knowledge gaps[J]. *Biosystems Engineering*, 2013, 114(4): 358-371.
- [26] Jung J, Maeda M, Chang A, et al. Unmanned aerial system assisted framework for the selection of high yielding cotton genotypes[J]. *Computers and Electronics in Agriculture*, 2018, 152: 74-81.
- [27] Hinton G E, Salakhutdinov R R. Reducing the Dimensionality of Data with Neural Networks[J]. *Science*, 2006, 313(5786): 504-507.
- [28] Minar M R, Naher J. Recent Advances in Deep Learning: An Overview[J]. *arXiv: 1807.08169*, 2018.
- [29] Hao X, Zhang G, Ma S. Deep Learning[J]. *International Journal of Semantic Computing*, 2016, 10(03): 417-439.
- [30] Pan S J, Yang Q. A Survey on Transfer Learning[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2010, 22(10): 1345-1359.
- [31] Liu D, Gao S, Chi W, et al. Pedestrian detection algorithm based on improved SSD[J]. *International Journal of Computer Applications in Technology*, 2021, 65(1):25.
- [32] Zhang Q, Wan C, Han W, et al. A modified faster region-based convolutional neural network approach for improved vehicle detection performance[J]. *Multimedia tools and applications*, 2019, 78(20): 29431-29446.
- [33] Kamilaris A, Prenafeta-Boldu F X. Deep learning in agriculture: A survey[J]. *Computers and Electronics in Agriculture*, 2018, 147: 70-90.
- [34] Yang X, Sun M. A Survey on Deep Learning in Crop Planting[J]. *IOP Conference Series: Materials Science and Engineering*, 2019, 490(6): 062053.
- [35] Bayer P E, Edwards D. Machine learning in agriculture: from silos to marketplaces[J]. *Plant biotechnology journal*, 2020, 19(4): 648-650.

- [36] Miao C, Guo A, Yang J, et al. Automation of Leaf Counting in Maize and Sorghum Using Deep Learning. bioRxiv preprint doi: <https://doi.org/10.1101/2020.12.19.423626>.
- [37] Song W, Li J, Li K, et al. An Automatic Method for Stomatal Pore Detection and Measurement in Microscope Images of Plant Leaf Based on a Convolutional Neural Network Model[J]. Forests, 2020, 11(9): 954.
- [38] Zhou Z, Song Z, Fu L, et al. Real-time kiwifruit detection in orchard using deep learning on Android™ smartphones for yield estimation[J]. Computers and Electronics in Agriculture, 2020, 2020(179): 105856.
- [39] Mohanty S P, Hughes D P, Salathe M. Using Deep Learning for Image-Based Plant Disease Detection[J]. Frontiers in Plant Science, 2016, 7: 1419.
- [40] Islam M A, Shuvo M N, Muhammad S, et al. An Automated Convolutional Neural Network Based Approach for Paddy Leaf Disease Detection[J]. International Journal of Advanced Computer Science and Applications, 2021, 12(1): 280-288.
- [41] 姜红花, 张传银, 张昭, 等. 基于Mask R-CNN的玉米田间杂草检测方法[J]. 农业机械学报, 2020, v.51(06): 227-235+254.
- [42] Enrique A A, Manuel P R, Jorge M G, et al. A Cloud-Based Environment for Generating Yield Estimation Maps From Apple Orchards Using UAV Imagery and a Deep Learning Technique [J]. Frontiers in Plant Science, 2020, 11: 1086.
- [43] Deng R, Jiang Y, Tao M, et al. Deep learning-based automatic detection of productive tillers in rice[J]. Computers and Electronics in Agriculture, 2020, 177: 105703.
- [44] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks.[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 39(6): 1137-1149.
- [45] 闫建伟, 赵源, 张乐伟, 等. 改进Faster-RCNN自然环境下识别刺梨果实[J]. 农业工程学报, 2019, 35(18): 143-150.
- [46] Häni N, Roy P, Isler V. A comparative study of fruit detection and counting methods for yield mapping in apple orchards[J]. Journal of Field Robotics, 2020, 37(2): 263-282.
- [47] Bipul N, Teerayut H, Duy H N. Deep learning based banana plant detection and counting using high-resolution red-green-blue (RGB) images collected from unmanned aerial vehicle (UAV)[J]. PLoS ONE, 2019, 14(10): e0223906.
- [48] Feng A, Zhou J, Vories E, et al. Evaluation of cotton emergence using UAV-based imagery and deep learning[J]. Computers and Electronics in Agriculture, 2020, 177: 105711.
- [49] Lecun Y, Bottou L. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [50] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.

- [51] Szegedy C, Liu W, Jia Y Q, et al. Going Deeper with Convolutions[C]// Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2015: 1-9.
- [52] Simonyan K, Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. Computer Science, arXiv: 1409.1556, 2014.
- [53] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]// Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2016: 770-778.
- [54] Xie S, Girshick R, P Dollár, et al. Aggregated Residual Transformations for Deep Neural Networks[C]// Proc of IEEE Conference on Computer Vision and Pattern Recognition, Washington DC: IEEE Computer Society, 2017: 5987-5995.
- [55] Georgevici A I, Terblanche M. Neural networks and deep learning: a brief introduction[J]. Intensive Care Medicine, 2019, 45(5): 712-714.
- [56] Uijlings J R, Sande K E, Gevers T, et al. Selective Search for Object Recognition[J]. International Journal of Computer Vision, 2013, 104(2): 154-171.
- [57] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]// IEEE Conference on Computer Vision and Pattern Recognition, 2014: 580-587.
- [58] Girshick R. Fast R-CNN[C]// IEEE International Conference on Computer Vision, 2015: 1440-1448.
- [59] Redmon J, Farhadi A. YOLO9000: Better, Faster, Stronger[C]// IEEE Conference on Computer Vision and Pattern Recognition, 2017: 6517-6525.
- [60] Wang H, Zheng X. Survey of Deep Learning Based Object Detection[C]// In: In Proceedings of the 2nd International Conference on Big Data Technologies, 2019: 149-153.
- [61] Xu J. 斯坦福目标检测深度学习指南[J]. 机器人产业, 2017(06): 18-24.
- [62] Narendra P M, Fitch R C. Real-time adaptive contrast enhancement[J]. IEEE transactions on pattern analysis and machine intelligence, 1981, 3(6): 655-661.
- [63] Zeiler MD, Fergus R. Visualizing and Understanding Convolutional Neural Networks[C]// Proceedings of 2014 European Conference on Computer Vision. Springer, Cham, 2014, 818-833.
- [64] Dumoulin V, Visin F. A guide to convolution arithmetic for deep learning[J]. arXiv preprint arXiv: 1603.07285, 2016.
- [65] Bahdanau D, Cho K, Bengio Y. Neural Machine Translation by Jointly Learning to Align and Translate[J]. arXiv preprint arXiv: 1409.0473, 2014.
- [66] Xu K, Ba J, Kiros R, et al. Show, Attend and Tell: Neural Image Caption Generation with Visual Attention[J]. Computer Science, 2015: 2048-2057.
- [67] Jie H, Li S, Samuel A, et al. Squeeze-and-Excitation Networks[J]. IEEE transactions on pattern

analysis and machine intelligence, 2020, 42(8): 2011-2023.

- [68] Lin T Y, Dollar P, Girshick R, et al. Feature Pyramid Networks for Object Detection[C]// Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition, 2017: 936-944.