

DOI: 10.13733/j.jcam.issn.2095-5553.2025.10.027

张志鹏, 张铁异, 陆静平, 等. YOLO—Sugarcane: 用于快速检测复杂背景下甘蔗植株的轻量级神经网络[J]. 中国农机化学报, 2025, 46(10): 210—217
Zhang Zhipeng, Zhang Tieyi, Lu Jingping, et al. YOLO—Sugarcane: Lightweight neural networks for rapid detection of sugarcane plants against complex backgrounds [J]. Journal of Chinese Agricultural Mechanization, 2025, 46(10): 210—217

YOLO—Sugarcane: 用于快速检测复杂背景下甘蔗植株的轻量级神经网络^{*}

张志鹏¹, 张铁异¹, 陆静平¹, 熊灵聪¹, 袁安路¹, 韦俊²

(1. 广西大学机械工程学院, 南宁市, 530004; 2. 广西交通职业技术学院汽车工程学院, 南宁市, 530023)

摘要:为解决现有轻量级网络模型易受到甘蔗遮挡影响而导致漏检和误检问题,提出一种改进的 YOLO—Sugarcane 轻量级神经网络模型。首先,用 MobileNetV3 的 Bneck 模块替换 YOLOv7—tiny 主干网络内的 MP 和 ELAN 模块,有效提高模型的召回率;其次,用深度可分离卷积替代标准 3×3 卷积,降低模型的运算成本,保证其在甘蔗收割机上的稳定部署;最后,引入轻量级通道注意力模块 ECA(Efficient Channel Attention),使模型能够有效捕捉不同通道间的特征关联,专注于有效特征并丢弃冗余特征。试验结果表明,与 YOLOv7—tiny 模型相比,YOLO—Sugarcane 模型的浮点运算量减少 29.18%,平均精度均值 *mAP* 从 97.10% 提升到 98.18%,召回率从 85.21% 提升到 93.71%,检测速度达到 91 帧/s。

关键词:甘蔗;神经网络;注意力机制;深度学习;轻量化模型

中图分类号:S566.1 文献标识码:A 文章编号:2095-5553 (2025) 10-0210-08

YOLO—Sugarcane: Lightweight neural networks for rapid detection of sugarcane plants against complex backgrounds

Zhang Zhipeng¹, Zhang Tieyi¹, Lu Jingping¹, Xiong Lingcong¹, Yuan Anlu¹, Wei Jun²

(1. School of Mechanical Engineering, Guangxi University, Nanning, 530004, China;

2. School of Automotive Engineering, Guangxi Transport Vocational and Technical College, Nanning, 530023, China)

Abstract: In order to solve the problem that the existing lightweight network model is susceptible to omission and misdetection due to sugarcane occlusion, an improved YOLO—Sugarcane lightweight neural network model is proposed. First, the Bneck module of MobileNetV3 is used to replace the MP and ELAN modules within the YOLOv7—tiny backbone network, which effectively improves the recall of the model. Secondly, the depth-separable convolution is used to replace the standard 3×3 convolution, which reduces the computational cost of the model and ensures its stable deployment on the sugarcane harvester. Finally, the lightweight channel attention module ECA (Efficient Channel Attention) is introduced, which enables the model to effectively capture the feature associations between different channels, focus on effective features and discard redundant features. The experimental results show that compared with the YOLOv7—tiny model, the floating-point operation amount of the YOLO—Sugarcane model is reduced by 29.18%, the *mAP* is increased from 97.10% to 98.18%, the recall rate is increased from 85.21% to 93.71%, and the detection speed reaches 91 frames/s.

Keywords: sugarcane; neural networks; attention mechanism; deep learning; lightweight model

0 引言

甘蔗生长于热带和亚热带地区,是全球制糖的重

要原材料。我国是全球第三大甘蔗生产国,仅次于巴西和印度。我国有 80% 的甘蔗种植于丘陵和山坡地区^[1],这使得 95% 的甘蔗需要人工采摘^[2]。相比于巴

收稿日期:2024 年 5 月 20 日 修回日期:2024 年 7 月 9 日

^{*} 基金项目:国家自然科学基金(51965003)

第一作者:张志鹏,男,1996 年生,河南驻马店人,硕士研究生;研究方向为深度学习在农业机械中的应用。E-mail: 1435990152@qq.com

通讯作者:张铁异,男,1963 年生,福建龙岩人,硕士,教授;研究方向为深度学习和目标检测。E-mail: 393666019@qq.com

西 90% 以上^[3]的甘蔗采用机械化收割,我国的甘蔗种植成本远高于巴西。目前国内的甘蔗收割机主要分为切段式和整杆式^[4],整杆式甘蔗收割机的收获过程包括切梢、扶倒、根切、喂入、输送、剥叶和集堆;切段式甘蔗收割机的收获过程为切梢、扶倒、根切、喂入、输送、切段、风力排杂、蔗段提升和装载,但这些甘蔗收割机难以在丘陵山地地区充分发挥其效能。为降低我国的甘蔗生产成本,设计一款针对中国丘陵地貌的智能甘蔗收割机显得尤其重要。

智能甘蔗收割机控制系统通常由图像采集、视觉识别、甘蔗定位^[5]、路径规划^[6]和执行机构等多个单元组成^[7]。在这些单元中,对甘蔗植株进行实时识别检测是整个控制系统的关键步骤,其识别准确度直接影响后续操作的效率和效果。随着人工智能的不断发展,越来越多的视觉处理技术被应用于农业机械上^[8]。传统的机器视觉方法通常依赖于手工设计的特征来检测目标物体。Kumar 等^[9]利用 KNN 聚类和支持向量机分类器定期识别检测甘蔗图像是否存在疾病感染。Rahmad 等^[10]先使用 RGB 颜色特征和 Gabor 纹理特征对收集到的甘蔗图片进行特征提取,再使用支持向量机将甘蔗区分为成熟、未成熟和半成熟 3 类。虽然这种传统的视觉检测方法为目标检测任务提供了一些解决方案,但其检测精度容易受到背景颜色以及光照条件等影响^[11]。

近年来,深度学习技术已广泛应用于农业生产的各个场景。深度学习目标检测算法按照其检测流程可分为单阶段和双阶段。Faster R—CNN^[12]和 Mask R—CNN^[13]为了追求更高的检测精度使用双阶段检测算法。相较于双阶段检测算法,单阶段目标检测只需一次特征提取即可完成目标检测,因此速度更快,使用计算资源更低。单阶段目标检测算法的思想最早应用于 YOLOv1^[14]算法,YOLOv1 将输入的原始图像划分为 7×7 个网络,经过特征提取后根据各网格单独预测其中可能包含的目标,预测每个网格时会生成 2 个预测框,随后取与实际目标框最接近的预测框作为输出。随着 YOLO 的不断发展,以及越来越多的学者不断创新深化,为本研究提供了良好的参考和启示。Yu 等^[15]以 YOLOv5s 为基础,使用 MobileNetV2 网络替换原主干网络,用于复杂环境下甘蔗茎节点的实时检测。陈文等^[16]为了降低算法部署对智能甘蔗收割机高算力需求,采用轻量化网络模型 MobileNet 替换 YOLOv4—tiny 主干网络和网络瘦身两种方法对 YOLOv4—tiny 模型进行改进。赵文博等^[17]对 YOLOv5 模型进行优化改进,首先基于 BiFPN 的跨层级加权连接优化颈部结构,然后用 EIou 和 Focal loss 替代原损失函数,最后引入 Ghost 模块,提高甘蔗智能

切种机的茎节识别精度。李威等^[18]使用 YOLOv4 网络模型和支持向量机 2 种方法对中耕期甘蔗进行识别定位和坐标分类。Chen 等^[19]针对复杂环境下甘蔗茎节点快速识别问题,利用数据集增强方法模拟了不同光照条件,然后将 5 种不同的深度学习算法(Faster R—CNN、SSD300、RetinaNet、YOLOv3 和 YOLOv4)进行比较,得出 YOLOv4 表现最佳。

传统采用轻量级网络模型的甘蔗目标识别技术主要侧重于甘蔗茎节的目标检测,忽略了对甘蔗整体的识别检测。如果不能准确识别收割机前方的甘蔗,可能导致收割机卡死甚至损坏刀盘,还会影响甘蔗定位和路径规划,致使收割效率降低。为解决传统轻量级网络模型容易出现漏检和误检问题,本文对 YOLOv7—tiny 模型的 Backbone 和 Neck 部分进行改进,并引入不同的注意力机制,建立 10 个网络模型进行消融实验,以优化检测效果。通过与主流网络模型的测试对比,验证改进后模型的有效性。

1 材料与方法

1.1 数据采集

数据来自广西壮族自治区崇左市某甘蔗种植基地,获取时间为 2023 年 1 月 28—29 日的 9:00—11:00 和 15:00—17:00,用 iPhone 14 Pro 手机拍摄,分辨率为 $4\,032$ 像素 $\times$ $3\,024$ 像素,保存格式为 JPEG。为保证采集的图像与甘蔗收割机的实际工况相匹配,在采集图像时使用固定三脚架,使手机与甘蔗之间距离约为 0.5 m,摄像头高度约为 1 m。共收集 3 779 张原始甘蔗图片,数据采集过程如图 1 所示。



图 1 数据采集过程示意图

Fig. 1 Schematic diagram of the data acquisition process

1.2 图像增强与标注

为获得性能更好的神经网络模型,需要大量的数据集支撑。Liu 等^[20]通过消融实验得出神经网络模型的泛化能力和鲁棒性随着数据集的增加而提高。因此,从收集的原始甘蔗图片中挑选 1 460 张高清图片,并使用 Python 软件对这些图片采用不同的数据增强方案,以扩充甘蔗数据集。

数据增强方式如图 2 所示。最终获得 5 239 张甘蔗图片数据集用于后续甘蔗目标识别研究。先对数据集进行预处理,将 $4\,032$ 像素 $\times$ $3\,024$ 像素的图像等比例缩放

至 1 209 像素 $\times$ 907 像素,以减小数据集所占内存,加快 YOLO 模型加载数据集的速度,缩短模型训练时间。预处理之后,还需对图像进行标注才能使用,所用的标注软件为 LabelImg。图中的甘蔗标注准则为对人眼能够识别的进行正常标注,标注名称为 sugarcane,以 VOC 格式导出,再将 VOC 格式转换为 YOLO 格式。最后将数据集按 8:1:1 的比例随机划分为训练集、验证集和测试集。




图 2 甘蔗数据集

Fig. 2 Sugarcane data set

1.3 YOLO—Sugarcane 构建

随着人工智能不断进步,YOLO 也在不断更新迭代。基于 YOLOv7^[21]作为甘蔗目标检测模型。YOLOv7 模型

有 3 个主要版本,分别为 YOLOv7—tiny、YOLOv7l 和 YOLOv7x。由于甘蔗收割机上的硬件平台配置不高,所以选取参数量较少的 YOLOv7—tiny 模型作为基础。

YOLOv7—tiny 模型由 Input、Backbone、Neck 和 Prediction 组成。Input 部分将数据集加载到模型并进行必要的预处理。Backbone 部分由 CBL 模块、MP 模块和 ELAN 模块组成,通过多层卷积来获取高级语义特征,扩大感受野,获取上下文信息。为增强模型的感知能力,Neck 部分由 SPPCSPC 模块与 FPN 和 PAN 结构组成,有助于多尺度信息捕捉和更好地获取物体的边缘及轮廓信息。Prediction 部分将传入进来的不同尺度特征层,用 CBL 模块进行通道调整,最后再用一个 1×1 的卷积层将网络学到的特征图映射为目标检测的输出,其中包括边界框位置、置信度及类别概率。

为提高 YOLOv7—tiny 模型的召回率和鲁棒性,降低甘蔗漏检概率,将 YOLOv7—tiny 模型改进为 YOLO—Sugarcane 模型,整体结构如图 3 所示。首先,使用 MobileNetV3 网络中的 Bneck 模块替换 YOLOv7—tiny 主干网络中的 MP 模块和 ELAN 模块。然后,为减少 Neck 部分的参数量,使用深度可分离卷积 DPconv 模块替换原有的标准 3×3 卷积,从而达到缩减参数量的目的。最后,在 Backbone 网络有效特征层传出通道添加 ECA 注意力机制。




图 3 YOLO—Sugarcane 模型

Fig. 3 YOLO—Sugarcane model

1.3.1 Backbone

MobileNetV3^[22]结合网络架构搜索和 NetAdapt 算法,并在 MobileNetV2 的基础上引入 SE 注意力机制和

H—Swish 激活函数,Bneck 模块是 MobileNetV3 网络的核心模块。在 YOLO—Sugarcane 模型中,使用经过优化的 Bneck 模块,其工作流程如图 4 所示。




图 4 Bneck 模块工作流程

Fig. 4 Workflow of Bneck module

Bneck 是一个具有反向残差结构的线性瓶颈模块。首先, Bneck 模块会判断是否执行残差连接程序, 接着, 它会检查输入通道数是否与中间层通道数相同, 如果相同, 则执行图 4 左侧虚线框流程; 如果不同, 则执行图 4 右侧虚线框流程。在 MobileNetV3 网络的运行过程中, 绝大多数情况下会执行图 4 右侧虚线框流程。图 4 右侧虚线框流程: 第 1 步是经过一个 1×1 卷积操作, 以扩展特征图的通道数。进行批归一化, 以提高模型的稳定性。根据判断选择使用预先定义的 H—Swish 激活函数, 还是默认的 ReLU 激活函数, 用来缓解梯度消失问题。ReLU 激活函数和 H—Swish 激活函数计算如式(1)和式(2)所示。第 2 步是先使用深度卷积调整特征图的尺寸, 再进行批归一化, 以提高模型的泛化能力。第 3 步是先判断是否使用 SE 注意力模块, 若不使用则直接调用 PyTorch 中的 nn.Identity 模块进行恒等映射, 然后使用与第一步相同的激活函数增强网络的表达能力。第 4 步是再次使用 1×1 卷积操作, 以降低特征图的通道数, 并经过批归一化后传出。

$$\text{ReLU}(x) = \max(0, x) \quad (1)$$

$$\text{ReLU6}(x) = \min(\max(0, x), 6)$$

$$\text{H—Swish}[x] = x \frac{\text{ReLU6}(x+3)}{6} \quad (2)$$

式中: x ——输入, 任意实数。

1.3.2 改进 Neck 结构减少计算量

对于 YOLOv7—tiny 模型的加强特征提取网络, 其

参数量大多集中于 Neck 结构内的标准 3×3 卷积上。因此, 使用深度可分离卷积模块代替原有的标准 3×3 卷积来降低模型的计算成本。深度可分离卷积^[23]由深度卷积和逐点卷积组合而成, 如图 5 所示。DPCnv 模块先经过深度卷积操作, 使每个输入通道都与一个独立的 3×3 卷积核进行卷积, 从而生成与输入通道数相同数量的特征图。随后, 经过逐点卷积操作, 使用 1×1 的卷积核对深度卷积生成的特征图进行卷积。逐点卷积的目的是引入通道之间的混合信息, 将深度卷积产生的独立通道进行组合, 从而生成最终的输出。




图 5 DPCnv 模块

Fig. 5 DPCnv module

如图 5 所示, 当输入图片为 RGB 三通道, 大小为 3×3 , 步长为 1, 输出通道数为 64, 输出特征图尺寸为 3×3 , 卷积核尺寸为 3×3 。标准卷积的参数量为 $3 \times 3 \times 3 \times 64 = 1\,728$, 计算成本为 $3 \times 3 \times 3 \times 3 \times 3 \times 64 = 15\,552$ 。深度可分离卷积的参数量为 $3 \times 3 \times 3 + 3 \times 64 = 219$, 计算成本为 $3 \times 3 \times 3 \times 3 \times 3 + 3 \times 3 \times 3 \times 64 = 1\,971$ 。标准卷积的参数量和计算量约为深度可分离卷积的 8 倍, 这使 YOLO—Sugarcane 模型能够部署在性能较低的甘蔗收割机上。

1.3.3 引入注意力机制

添加注意力机制的效果不仅受到注意力机制类型的影响, 还受其添加位置的影响。将 YOLO—Sugarcane 模型按照有效特征图维度分为 $80 \times 80 \times C$ 、 $40 \times 40 \times C$ 和 $20 \times 20 \times C$ 的高、中、低 3 个维度, 其中 C 为通道数。分别在位置 1 和位置 2 应用空间注意力机制 CA、通道注意力机制 ECA^[24]和混合注意力机制 CBAM, 如图 6 所示。首先对输入特征图进行自适应平均池化操作。随后通过一维卷积层进行通道注意力加权操作, 卷积核大小的选择对不同通道之间信息交互和覆盖程度具有重要影响, 因此选择合适的卷积核尤为关键。最后使用 Sigmoid 激活函数生成通道权重, 再将原始输入特征图与得到的通道注意力权重进行按元素相乘, 目的是加权调整输入特征图中每个通道的特征表示, 使模型更加集中地关注图中重要特征信息。




图 6 注意力机制插入位置图

Fig. 6 Attention mechanism insertion location map

2 试验结果及分析

2.1 试验环境

试验平台是一台运行 Windows 11 (22H2) 操作系统的台式电脑, 配备 32 GB 的 RAM 和 NVIDIA GeForce RTX 3060Ti 8 G 显卡, 处理器为 13th Gen Intel(R) Core(TM) i5-13400F 2.50 GHz。运行软件主要包括 python 3.9.16、torchvision 0.13.0、PyTorch 1.12.0、OpenCV—python 4.7.0.72、CUDA 11.3 和 cuDNN 8.3.2。网络模型训练参数设置: YOLOv3 模型和 YOLOv4 模型的输入图像大小为 416 像素×416 像素, 其他网络模型的输入图像大小为 640 像素×640 像素, 训练过程使用 SGD 优化器, 批量大小 (batch size) 为 8, 总迭代次数 (epoch) 为 300, 初始学习率设置为 0.001, 应用余弦退火算法对学习率进行动态调整, 权重衰减系数为 5×10^{-4} , 动量为 0.937。

2.2 评价指标

为评估模型的整体性能以及未来在甘蔗收割机上部署的可行性, 采用精确率 P 、召回率 R 、平均精度 AP 、平均精度均值 mAP 、F1 分数、检测速度 FPS 、参数量和浮点运算量 $FLOPs$ 进行评估。精确率表示被模型识别为甘蔗的目标中真实为甘蔗所占比例, 召回率表示所有甘蔗真例中被模型正确识别为甘蔗的目标所占比例, 计算如式(3)和式(4)所示。F1 分数能够综合评估分类器性能, F1 分数越高, 模型预测性能越好, 计算如式(5)所示。

$$P = \frac{TP}{TP + FP} \times 100\% \quad (3)$$

$$R = \frac{TP}{TP + FN} \times 100\% \quad (4)$$

$$F1 = \frac{2 \times P \times R}{P + R} \times 100\% \quad (5)$$

式中: TP ——标注为甘蔗的目标被正确检测为甘蔗;

FP ——未标注的背景被错误检测为甘蔗;

FN ——标注为甘蔗的目标被错误检测为背景。

AP 表示目标检测中每个类别的平均精度, mAP 表示模型对多类目标识别的平均精度 AP 的平均值, 计算方法如式(6)和式(7)所示。本文只检测甘蔗, 所以 $n=1$, 模型对甘蔗的平均精度等于模型的平均精度均值, mAP 值越高, 模型性能越好。FLOPs 表示浮点运算量, FLOPs 越高意味着模型越复杂。参数量是神经网络模型中的权重和偏差。检测速度 FPS 代表模型每秒处理的图像数量, 其值越大代表模型实时性越好。

$$AP = \int_0^1 P(R) dR \times 100\% \quad (6)$$

$$mAP = \frac{1}{n} \sum_{i=1}^n AP(i) \times 100\% \quad (7)$$

式中: n ——目标检测中目标类别数量;

$AP(i)$ ——第 i 类的 AP 值。

2.3 消融实验

1) 为测试不同轻量化网络在 YOLOv7—tiny 模型中的性能, 分别建立 MobileNetV1、MobileNetV2、MobileNetV3 和 GhostNet 的 YOLO 网络, 不同主干特征提取网络的性能如表 1 所示。

表 1 轻量级网络性能比较

Tab. 1 Lightweight network performance comparison

网络模型	$mAP@0.5/\%$	$R/\%$	$P/\%$	参数量 /M	$FLOPs$ /G
YOLOv7—tiny	97.10	85.21	97.79	6.227	13.860
YOLOv7—tiny—MobileNetV1	97.72	91.52	96.57	7.536	16.879
YOLOv7—tiny—MobileNetV2	97.59	91.50	96.25	5.713	11.632
YOLOv7—tiny—MobileNetV3	97.99	91.74	96.62	6.638	10.231
YOLOv7—tiny—GhostNet	97.06	88.60	96.36	6.337	8.941

由表 1 可知,将 YOLOv7—tiny 模型的 Backbone 网络替换为 MobileNetV3 后,仅以牺牲 1.17% 的精确率为代价,使模型的 mAP 和召回率分别提高 0.89%、6.53%。与此同时,模型的浮点运算量下降 26.18%。这意味着改进后的模型在实际应用能力上要优于 YOLOv7—tiny 模型。此外,与其他轻量级网络相比,MobileNetV3 具有最高的 mAP 、召回率和精确率,是替换原 Backbone 的最佳选择。

2) 为检验不同注意力机制在 YOLOv7—tiny—MobileNetV3 模型中的性能。在图 6 位置 1,主干特征提取网络的有效特征层前传到 Neck 结构时,分别应用 3 种不同注意力机制,目的是使模型更有效地捕捉到小目标特征,从而提高对小目标的检测能力。由表 2 可知,模型 1~模型 3 中,模型 1 的 mAP 是三者中最高的,召回率相比于模型 2 和模型 3 分别提高 0.41%、1.21%,精确率相比于最高的模型 3 下降 0.6%,而模型 1 实时检测速度却比模型 3 提升 10.98%,是 3 个模型中实时性能最好的。因此,模型 1 被认为是综合性能最佳的模型。

表 2 不同注意力机制模型
Tab. 2 Models of different attention mechanisms

网络模型	ECA	ECA	CA	CBAM	$mAP@0.5/\%$	$R/\%$	$P/\%$	$FPS/(帧 \cdot s^{-1})$
模型 1	✓				98.18	93.71	96.34	91
模型 2			✓		98.15	93.30	96.73	83
模型 3				✓	98.16	92.50	96.94	82
模型 4	✓	✓			98.16	93.11	96.77	85
模型 5	✓		✓		98.18	92.80	96.97	80
模型 6	✓			✓	98.17	92.76	96.90	79

为了进一步提高模型 1 的精确率,在 Neck 结构前传

表 3 不同网络模型性能参数
Tab. 3 Performance parameters of different network models

网络模型	$mAP@0.5/\%$	$R/\%$	$P/\%$	$F1$ 分数/ $\%$	$FPS/(帧 \cdot s^{-1})$	$FLOPs/G$	参数量/ M
YOLOv3	94.10	83.09	94.67	88.50	72	66.171	61.949
YOLOv4	94.86	85.37	94.88	89.88	57	60.527	64.363
YOLOv5s	96.53	85.25	96.95	90.73	97	16.625	7.235
YOLOv5l	97.89	90.07	96.46	93.16	48	109.587	46.564
YOLOv7l	97.90	91.47	96.13	93.75	47	106.472	37.620
YOLOv7x	97.78	91.64	96.33	93.93	32	190.580	71.344
YOLOv7—tiny	97.10	85.21	97.79	91.07	125	13.860	6.227
YOLO—Sugarcane	98.18	93.71	96.34	95.00	91	9.816	6.312

如表 3 所示,与其他主流网络模型相比,YOLO—Sugarcane 模型具有最少的 $FLOPs$ 和参数量。这表明该网络模型的复杂度最低,更适于在硬件性能较低的甘蔗收割机上进行部署。同时,YOLO—Sugarcane 模型也具备最高的召回率、 $F1$ 分数和 mAP 。虽然精确率相比于最高的 YOLOv5s 模型低 0.61%,但是 YOLO—

到预测部分位置 2,再次引入 3 种不同的注意力机制,如表 2 中的模型 4、模型 5 和模型 6 所示。然而,在位置 2 再次使用注意力机制,性能并没有进一步提高,反而模型实时检测速度在不断下降。因此,最终选用 YOLOv7—tiny—MobileNetV3—ECA 作为最终的模型输出,本文称为 YOLO—Sugarcane 模型。相比于 YOLOv7—tiny—MobileNetV3 模型, YOLOv7—tiny—MobileNetV3—ECA 模型的 mAP 和召回率分别提升 0.19%、1.97%。

2.4 YOLO—Sugarcane 模型与其他深度学习模型对比

图 7 为 YOLOv7—tiny 模型和 YOLO—Sugarcane 模型的 PR 曲线,这些 PR 曲线代表了模型在 IoU 阈值为 0.5 时的甘蔗检测性能。 PR 曲线内的封闭区域表示模型的平均精度,其计算如式(6)所示。由图 7 可知, YOLO—Sugarcane 模型的 PR 曲线完全包裹住 YOLOv7—tiny 模型的曲线,这表明 YOLO—Sugarcane 模型具有更高的 mAP 。由表 3 可知, YOLO—Sugarcane 模型的 mAP 较 YOLOv7—tiny 模型提高 1.08%。不仅如此,与 YOLOv7—tiny 模型相比, YOLO—Sugarcane 模型在召回率和 $F1$ 分数上分别提高 8.5%、3.93%,而模型的浮点运算量下降 29.18%。




图 7 YOLOv7—tiny 和 YOLO—Sugarcane 的 $P-R$ 曲线
Fig. 7 $P-R$ curves for YOLOv7—tiny and YOLO—Sugarcane

Sugarcane 模型的 mAP 和召回率分别比 YOLOv5s 模型高 1.65%、8.46%。YOLO—Sugarcane 模型在各项性能参数上均保持最高水准,并且具有 91 帧/s 的实时检测速度。通过全面对比分析,YOLO—Sugarcane 模型在综合检测性能上优于目前主流的检测模型,更适合在复杂环境中检测甘蔗物体。

2.5 复杂检测场景下模型计数效果对比

为检验模型在实际应用中的检测性能,从甘蔗数据集集中随机挑选 40 张具有不同遮挡程度的甘蔗图片进行验证。这些图片共标记 145 根甘蔗物体。如图 8 所示,绿色比例越多,表示模型的检测性能越好。其中,YOLO—Sugarcane 模型的检测效果最佳,共检测出 133 根甘蔗物体。YOLOv5 和 YOLOv7 版本中,随着模型规模的增大,检测性能也逐渐提升。YOLOv7x 模型和 YOLOv5l 模型分别检测出 132 根和 114 根甘蔗物体。但是更大的模型也意味着需要更多的计算资源。相比于 YOLOv7x 模型,YOLO—Sugarcane 模型的 FLOPs 和参数量分别下降 94.85%、91.15%,轻量级的 YOLO—Sugarcane 模型不仅具备与大模型相媲美的检测性能,还不需要太多的计算资源。此外,YOLO—Sugarcane 模型摆脱了轻量级模型在复杂环境中检测性能不稳定、容易误检的情况。




图 8 不同网络模型计数对比

Fig. 8 Comparison of different network model counts

如图 9(a)所示,当甘蔗被前方甘蔗严重遮挡时,YOLOv5s 模型错误地将前方甘蔗的叶片误认为是后方甘蔗;图 9(b)中,一根甘蔗被甘蔗叶严重包裹遮挡时,YOLOv7—tiny 模型将甘蔗的叶片误认为甘蔗本体。YOLO—Sugarcane 模型相比于原 YOLOv7—tiny 模型多检测出 34 根甘蔗,其性能提升主要有两方面:一方面,改进后的 YOLO—Sugarcane 模型具有最高的 *mAP*,因此轻量级的 YOLO—Sugarcane 模型拥有与大模型相似的鲁棒性。图 9(c)中,在逆光和未聚焦的拍摄环境下,YOLOv7—tiny 模型只能检测出近处的甘蔗,而远处受到光照影响导致拍摄虚化的甘蔗全部漏检,但 YOLO—Sugarcane 模型并不会受到光照强度干扰。另一方面,YOLO—Sugarcane 模型相比于 YOLOv7—tiny 模型在召回率上提升 8.5%,并具备 ECA 注意力机制的加持,使模型面对复杂的环境时依然表现出色。图 9(d)中,当甘蔗被甘蔗叶包裹遮挡时,YOLOv7—tiny 模型会出现大量漏检情况,而 YOLO—Sugarcane 模型则不受影响。综上所述,YOLO—Sugarcane 模型能够有效应对各种复杂场景下的甘蔗物体目标检测任务。




图 9 不同网络模型的实际检测结果

Fig. 9 Actual detection results for different network models

3 结论

为实现甘蔗收获过程的机械化,必须准确且高效地识别甘蔗收割机前方的甘蔗物体,基于此,设计一种基于 YOLOv7—tiny 和注意力机制的卷积神经网络模型 YOLO—Sugarcane。

1) 为提高模型的鲁棒性,采取 5 种不同的数据增强方式对甘蔗数据集进行扩充。

2) 为提高 YOLOv7—tiny 模型的召回率,共建立 10 个网络模型,旨在筛选最合适的轻量级网络主干和注意力机制类型,并确定插入位置。通过消融实验分析研究,最终选择将 MobileNetV3 网络替换原有的主干网络,并引入轻量级通道注意力模块 ECA。相比于 YOLOv7—tiny 模型,YOLO—Sugarcane 模型的召回率和 F1 分数分别提升 8.5%、3.93%。改进后的模型能够更加聚焦于小物体和被遮挡物体所在的区域,从而提高对这些物体的识别准确度。

3) 为降低模型的复杂度,通过引入轻量级 MobileNetV3 网络和深度可分离卷积,使模型的浮点

运算量相比于改进前降低 29.18%,为其部署在无人甘蔗收割机上创造可能性。

参 考 文 献

- [1] 张跃彬,邓军,胡朝晖. “十三五”我国蔗糖产业现状及“十四五”发展趋势[J]. 中国糖料, 2022, 44(1): 71—76.
- [2] Huang J, Khan M T, Perecin D, et al. Sugarcane for bioethanol production: Potential of bagasse in Chinese perspective [J]. Renewable and Sustainable Energy Reviews, 2020, 133: 110296.
- [3] Da Silva M J, O Neves L, Correa M H F, et al. Quality indexes and performance in mechanized harvesting of sugarcane at a burnt cane and green cane [J]. Sugar Tech, 2021, 23(3): 499—507.
- [4] 武涛,任甲辉,刘庆庭,等. 4GDZ—132型切段式甘蔗联合收割机研制[J]. 农业工程学报, 2022, 38(10): 30—38. Wu Tao, Ren Jiahui, Liu Qingting, et al. Development of the 4GDZ—132 sugarcane chopper combine harvester [J]. Transactions of the Chinese Society of Agricultural Engineering, 2022, 38(10): 30—38.
- [5] Tang Y, Chen M, Wang C, et al. Recognition and localization methods for vision-based fruit picking robots: A review [J]. Frontiers in Plant Science, 2020, 11: 510.
- [6] Liu L, Wang X, Yang X, et al. Path planning techniques for mobile robots: Review and prospect [J]. Expert Systems with Applications, 2023, 227: 120254.
- [7] Zhou H, Wang X, Au W, et al. Intelligent robots for fruit harvesting: Recent developments and future challenges [J]. Precision Agriculture, 2022, 23(5): 1856—1907.
- [8] Tian H, Wang T, Liu Y, et al. Computer vision technology in agricultural automation: A review [J]. Information Processing in Agriculture, 2020, 7(1): 1—19.
- [9] Kumar S, Mishra S, Khanna P, et al. Precision sugarcane monitoring using SVM classifier [J]. Procedia Computer Science, 2017, 122: 881—887.
- [10] Rahmad C, Rahutomo F, Gustalika M A, et al. Identification of sugarcane maturity scale based on RGB, gabor feature extraction and support vector machine [J]. IOP Conference Series: Materials Science and Engineering. IOP Publishing, 2018, 434(1): 012065.
- [11] Yu L, Xiong J, Fang X, et al. A litchi fruit recognition method in a natural environment using RGB—D images [J]. Biosystems Engineering, 2021, 204: 50—63.
- [12] Zhang Y, Xiao D, Liu Y, et al. An algorithm for automatic identification of multiple developmental stages of rice spikes based on improved Faster R—CNN [J]. The Crop Journal, 2022, 10(5): 1323—1333.
- [13] López-Barrios J D, Escobedo Cabello J A, Gómez-Espinosa A, et al. Green sweet pepper fruit and peduncle detection using Mask R—CNN in greenhouses [J]. Applied Sciences, 2023, 13(10): 6296.
- [14] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 779—788.
- [15] Yu K, Tang G, Chen W, et al. MobileNet—YOLOv5s: An improved lightweight method for real-time detection of sugarcane stem nodes in complex natural environments [J]. IEEE Access, 2023, 11: 104070—104083.
- [16] 陈文,余康,李岩舟,等. 基于网络瘦身算法的YOLOv4—tiny的甘蔗茎节识别[J]. 中国农机化学报, 2023, 44(2): 172—181. Chen Wen, Yu Kang, Li Yanzhou, et al. Recognition of sugarcane stem node based on network slimming algorithm and YOLOv4—tiny algorithm [J]. Journal of Chinese Agricultural Mechanization, 2023, 44(2): 172—181.
- [17] 赵文博,周德强,邓干然,等. 基于改进YOLOv5的甘蔗茎节识别方法[J]. 华中农业大学学报, 2023, 42(1): 268—276.
- [18] 李威,李尚平,潘家枫,等. 基于机器学习的中耕期甘蔗幼苗识别定位[J]. 中国农机化学报, 2021, 42(11): 130—137. Li Wei, Li Shangping, Pan Jiafeng, et al. Recognition and location of sugarcane seedlings in intertillage period based on machine learning [J]. Journal of Chinese Agricultural Mechanization, 2021, 42(11): 130—137.
- [19] Chen W, Ju C, Li Y, et al. Sugarcane stem node recognition in field by deep learning combining data expansion [J]. Applied Sciences, 2021, 11(18): 8663.
- [20] Liu G, Nouaze J C, Touko Mbouembe P L, et al. YOLO—Tomato: A robust algorithm for tomato detection based on YOLOv3 [J]. Sensors, 2020, 20(7): 2145.
- [21] Wang C, Bochkovskiy A, Liao H. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors [C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 7464—7475.
- [22] Howard A, Sandler M, Chu G, et al. Searching for MobileNetV3 [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 1314—1324.
- [23] Howard A G, Zhu M, Chen B, et al. MobileNets: Efficient convolutional neural networks for mobile vision applications [J]. arXiv preprint arXiv: 1704.04861, 2017.
- [24] Wang Q, Wu B, Zhu P, et al. ECA—Net: Efficient channel attention for deep convolutional neural networks [C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 11534—11542.