

无人机图像中耕期甘蔗植株检测计数方法

——基于改进 YOLOv5s

李尚平^{1,2}, 唐 丹^{1,2}, 文春明^{1,2}, 李凯华^{1,2}

(1. 广西民族大学 电子信息学院, 南宁 530006; 2. 广西高校智慧无人系统与智能装备重点实验室, 南宁 530006)

摘 要: 以中耕期甘蔗作物的无人机图像为研究对象, 针对植株叶片互相遮挡、目标粘连和背景信息复杂等问题, 设计了一种基于改进 YOLOv5s 的甘蔗检测计数模型。首先, 通过在网络中使用基于归一化的注意力模块, 加强对图像中中耕期甘蔗植株的特征学习和特征提取, 并且减弱与甘蔗植株相似的蔗地杂草背景对检测效果的干扰。其次, 原始 YOLOv5s 网络中的耦合头替换为改进过的高效解耦头, 用以进行分类和回归分支的解耦计算, 提升甘蔗植株检测模型的性能。最后, 更改边界框损失函数为动态非单调聚焦机制 WIoU, 提高模型收敛速度。同时, 采用多尺度训练在一定程度上提高改进模型对物体大小的鲁棒性, 最终使模型可以输入任意大小的图片。试验结果表明: 改进的 YOLOv5s 模型准确率、召回率和平均精度均值分别为 97.72%、91.7% 和 96.2%, 较原始 YOLOv5s 模型分别提高 3.82、4.5、2.5 个百分点。统计表明: 测试集的 30 幅甘蔗图像中, 甘蔗植株真实值为 1 104, 改进 YOLOv5s 模型生成的甘蔗植株数为 1 086, 漏检个数为 18, 漏检率为 1.6%, 改进模型对无人机图像中的甘蔗植株计数误差较小, 可为甘蔗的检测计数、长势评估提供技术支撑。

关键词: 甘蔗计数; 无人机; 图像处理; YOLOv5s; 解耦头; 归一化

中图分类号: S24; TP391.4

文献标识码: A

文章编号: 1003-188X(2025)10-0138-08

DOI: 10.13427/j.issn.1003-188X.2025.10.018

0 引 言

甘蔗作为可再生的能源作物, 在我国国民经济中占有重要地位。其培育和栽培旨在提高产量, 以实现高产高糖的目标。单位面积蔗茎产量由单位面积有效茎数和单茎重构成, 而甘蔗的茎长、茎径和有效茎数是估算蔗茎产量的关键因素^[1]。吴建涛等^[2]认为: 相对于茎长和茎径, 有效茎数与蔗茎产量关系最密切。可见有效茎数是甘蔗产量的关键构成因素, 所以设计一种检测甘蔗植株有效茎数的方法对监测甘蔗产量至关重要。传统的甘蔗植株监测方法主要依赖于人工观察和定期抽样, 但效率低、耗时长且容易受人为因素的干扰。这在大规模蔗地测量时既费时又繁琐, 增加了成本, 同时也限制了样本采样规模。因此, 结合无人机图像与深度学习模型, 开发一种高效、准确的甘蔗生长监测方法对于提高甘蔗产量和优化农业资源配置具有重要意义。

在与甘蔗幼苗具有相似性的玉米幼苗研究中, 张宏鸣等^[3]提出了一种基于特征增强机制的幼苗获取检测模型(FE-YOLO), 实现对玉米幼苗的快速获取。孙

俊等^[4]通过构建普适麦穗计数模型(Wheat Ear Counting Network, WECnet)对灌浆期小麦进行精准的计数与密度预估。在甘蔗植株的研究中, 杨丹彤等^[5]基于改进后的 YOLOv5 神经网络模型, 对甘蔗茎节和分叉点进行识别, 然后计算出甘蔗单个植株的质量, 从而实现甘蔗产量测量。李修华等^[6]搭建了基于改进 Faster R-CNN 的田间幼苗期检测与计数系统, 实现航拍图像中甘蔗幼苗的识别和计数。值得重视的是, 介于甘蔗幼苗期与甘蔗成熟期之间的甘蔗中耕期。甘蔗中耕期较幼苗期而言生长密度更高, 分蘖增多, 叶片出现重叠, 监测好中耕期植株情况以便有针对性地加强生长后期管理。以上方法虽然在田间甘蔗的产量预测和幼苗计数领域取得了一定的效果, 但对于甘蔗的中耕期识别监测仍存在空白。近年来, 随着深度学习等视觉技术的迅猛发展和无人机技术的逐渐成熟, 将这两者有效结合的理念为农业生产开辟了全新的研究方向^[7]。与自然场景图像不同, 由于无人机飞行高度高, 航拍图像中存在大量小目标, 这些小目标的可提取特征有限, 加之无人机飞行高度变化大, 导致物体比例剧烈变化, 从而影响检测精度。除此之外, 在实际飞行拍摄中场景复杂, 密集小目标之间会存在大量遮挡, 甚至被其他目标或背景遮挡^[8]。为此, 设计了基于改进 YOLOv5s 的无人机图像中耕期甘蔗植株检测计数方法, 以满足实际应用场景需求。

收稿日期: 2024-04-08

基金项目: 国家自然科学基金项目(52165009)

作者简介: 李尚平(1956-), 男, 广西博白人, 教授, 博士生导师, (E-mail)spli501@vip.sina.com。

1 数据采集与预处理

1.1 数据采集

本试验的研究区域是广西壮族自治区崇左市扶绥县(东经 $107^{\circ}3' \sim 108^{\circ}6'$, 北纬 $22^{\circ}11' \sim 22^{\circ}57'$)。数据采集时间为 2023 年 6 月 7 日 06:00—16:00, 能见度 26 km, 光照良好, 减少了弱光照对数据采集的干扰。本试验使用图像采集设备为大疆精灵 4proV2.0 无人机, 配备 1 英寸 2 000 万像素影像传感器。拍摄光圈值为 $f/5.0$, ISO 速度为 ISO-400, 最大续航时间为 30 min, 飞行速度为 1.0 m/s, 所拍摄图像的分辨率大小是 $5\,472 \times 3\,648$ 像素, 摄像机与地面垂直 90° , 航向重叠率与旁向重叠率均设为 80%, 拍摄时无人机的飞行高度为 10 m, 共获取 1 178 幅无人机甘蔗图像。采集后采用人工筛选的方法对采集图像进行数据清洗, 即包括删除由于无人机悬停引起的图像重复和去除无人机姿态调整过程中未包含甘蔗植株或未包含密集甘蔗植株的图像。且为了便于模型处理, 将得到的无人机图像按照 $2\,736 \times 3\,648$ 像素的大小进行裁剪, 每张照片平均有 43 株甘蔗植株。

1.2 数据处理

1.2.1 图像数据增强

对已清洗的数据进行增强预处理, 以提高所选模型的泛化能力和鲁棒性, 同时增加训练样本数量和引入噪声数据。采用镜像、对比度、亮度和高斯噪声等图像增强技术扩展数据集, 经过清理后的数据集原始数量为 100 张图片, 增强扩充后数据集图像为 1 100 张图片, 共包含 47 314 个目标, 完全可以满足训练所需。

1.2.2 目标标注及划分

生长高度不同, 甘蔗叶片遮挡的干扰程度存在差异, 这是影响甘蔗植株目标识别效果的关键因素。图 1 为原始图像, 图 2 为局部放大图。在实际的蔗田场景中, 由于甘蔗植株的生长情况和植被的变化存在差异, 甘蔗之间或者甘蔗与其他植物之间的相互遮挡情况千差万别。这种差异性使得目标检测模型需要具备强大的适应性, 能够处理不同遮挡情况下的图像数据。植株之间的遮挡或许仅涉及到部分叶片或茎部, 然而也可能会出现完全遮挡的情况, 使得目标的关键特征无法完整呈现。因此, 对于甘蔗目标检测算法的设计, 考虑遮挡程度的变化是至关重要的。通过优化算法, 使其能够有效处理不同程度的遮挡, 将有助于提高甘蔗植株目标在图像中的准确识别率, 从而更好

地满足实际农业生产中的监测和管理需求。所以, 本研究根据图像中大部分甘蔗植株被遮挡程度的不同, 将甘蔗图像中植株分为轻微遮挡(遮挡面积 $0 \sim 40\%$)、中度遮挡(遮挡面积 $40\% \sim 60\%$)、重度遮挡(遮挡面积 $60\% \sim 90\%$), 基本涵盖无人机视角下所有遮挡程度的甘蔗图像。






图 1 甘蔗原图

Fig. 1 Original image of sugarcane



(a) 轻微遮挡



(b) 中度遮挡



(c) 重度遮挡

图 2 不同遮挡情况下的甘蔗局部放大图

Fig. 2 Partial enlargement of sugarcane with different shade levels

为了更精确地量化遮挡的程度, 采用了等面积网格线方法^[9], 以近似计算甘蔗植株的遮挡面积。如图 2(a) 所示, 甘蔗植株目标呈现出轮廓完整, 遮挡比例相对较小, 可归类为轻微遮挡情况。如图 2(b) 所示, 甘蔗植株目标轮廓较为完整, 且场景较近, 特征较为明显, 属于中度遮挡。如图 2(c) 所示, 甘蔗轮廓只剩

余一部分蔗叶,遮挡比例很大,特征有限,可被归类为重度遮挡情况。本次研究使用的数据图像目标标注软件为 LabelImg,采用 PASCAL VOC 格式,目标类别标签标注如下:重度遮挡目标标注为“l-sugarcane”;中度遮挡目标标注为“m-sugarcane”;轻度遮挡目标标注为“s-sugarcane”。将裁剪、扩充、标注后的图像按照比例 8:2 分为训练集、验证集进行模型训练。

2 基于改进 YOLOv5s 的甘蔗识别计数方法

2.1 YOLOv5s 模型

由于在蔗田环境下,无人机图像中甘蔗植株分布密集且存在重叠现象,因此会出现错检和漏检的问题。此外,甘蔗蔗心尺度小、背景复杂也使得检测工作更为困难。这些问题会干扰模型在无人机图像中对甘蔗植株的准确识别与计数。因此,选择一种有效的检测模型对甘蔗植株的识别工作至关重要。YOLO (You Only Look Once) 是一种流行的目标检测模型,与

传统的目标检测方法不同,YOLO 使用单一的神经网络模型同时完成目标检测和定位,因此它的速度相对较快^[10]。本文中 YOLOv5s 采用了改进的网络架构,通常包括输入端(Input)、骨干网络(Backbone)、颈部网络(Neck)和预测端(Prediction Head)^[11-13]。本文选择基于改进的 YOLOv5s 进行甘蔗植株检测,具有检测精确、速度快等优点,在开源数据集上具有良好效果,但是在蔗田环境下对无人机图像中甘蔗植株的检测和计数任务方面仍需要改进。

本文首先针对甘蔗植株与田间杂草相似的问题,在检测头前端引入 NAM 注意力机制,以此抑制背景的干扰,突出甘蔗蔗心的特征;其次将原始耦合头替换为改进的高效解耦头来区分回归和分类,加快模型收敛速度,进一步提升甘蔗植株检测性能;最后,更改边界框损失函数为动态非单调聚焦机制 WIoU,提高模型收敛速度。改进后的 YOLOv5s 甘蔗检测整体网络架构如图 3 所示。




图 3 改进后的 YOLOv5s 网络结构图

Fig. 3 Structure diagram of the improved YOLOv5s network

2.2 NAM 注意力机制

在网络中使用基于归一化的轻量级注意力模块^[14],能够增强网络对特征点的感知,并在不引入额

外参数的情况下增强网络模型在嘈杂环境中的检测能力,使其非常适合网络的轻量级任务。在实际蔗田任务中,无人机捕捉的甘蔗植株图像通常受到大量噪

声的影响。这种噪声有时表现出与目标甘蔗植株相似的特征,导致错误的检测。NAM 通过全局性的关联,可以绕过一些局部遮挡,提高对被遮挡对象的识别和理解能力。其采用 CBAM (Convolutional Block Attention Module) 的模块集成^[15-16],重新设计了独立的通道注意力模块和空间注意力模块。NAM 注意力机制结构如图 4 所示。由图 4(a)可知:与 CBAM 的模块设计不同,NAM 没有引入额外的卷积层;相反,它直接使用批归一化^[17] (Batch Normalization, BN) 操作,运用缩放因子来调整权重的标准差,以强调其重要性,并以此为准重新调整网络,如式(1)所示。其中, γ 和 β 是可训练的仿射变换参数 (scale 和 shift)^[18]。

$$B_{out} = BN(B_{in}) = \gamma \frac{B_{in} - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}} + \beta \quad (1)$$

式中: B_{in} 为输入的特征矩阵, $BN()$ 为计算批归一化缩放因子函数, μ_B 为最小批次 B 的均值, σ_B 为最

小批次 B 的标准差, ε 为常数。

通道注意力模块如图 4(b) 所示。输出特征 M_c 计算公式为

$$M_c = \text{sigmoid}(W_\gamma(BN(F_1))) \quad (2)$$

式中: γ 为各通道的缩放因子。

权重 W_γ 计算公式为

$$W_\gamma = \gamma_i / \sum_{j=0} \gamma_j \quad (3)$$

另外,应用像素归一化方法使得图像的像素值具有特定的统计特性,以便更好地适应深度学习模型的训练和优化过程^[19],对应的空间注意力模块如图 4(c) 和式(4)所示。输出特征 M_s 计算公式为

$$M_s = \text{sigmoid}(W_\lambda(BN_s(F_2))) \quad (4)$$

式中: λ 为各通道缩放因子。

权重 W_λ 计算公式为

$$W_\lambda = \lambda_i / \sum_{j=0} \lambda_j \quad (5)$$




图 4 NAM 注意力机制结构图

Fig. 4 Structural diagram of Nam's attention mechanism

2.3 Decoupled Head

YOLOv5 的初始设计采用了耦合头作为检测头,其中分类和回归任务通常共享一些计算分支,这可能导致模型在学习过程中关注某些任务而忽略其他任务^[20]。当网络模型过度关注分类的信息时,较明显特征的响应值会被提高,然后只识别到特征更明显的甘蔗植株,这样的结果会影响到目标的准确定位,进而导致甘蔗植株的检测位置不准确,同时也会降低训练

过程中的模型收敛速度。为了减少甘蔗植株分类问题和回归任务的冲突,加快模型的收敛速度,提高模型的整体性能,本文将 YOLOv5 中耦合头替换为解耦头 (Decoupled Head) 结构。YOLOX^[21] 引入了 Anchor-free 的解耦头用于检测,Decoupled Head 对分类和回归分支解耦计算。分类任务更专注于目标的纹理信息,而回归任务则更注重目标的边缘信息,于是 Decoupled Head 将这两个任务进行解耦,改善模型中分

类和回归任务之间的相互影响,以更好地实现不同任务的优化,结构如图 5 所示。此外,模型还增加了 2 个额外的 3×3 CBS 卷积模块,有助于网络更好地适应分类和回归任务的需求。




图 5 Decoupled Head 结构图

Fig. 5 Structure diagram of Decoupled Head

2.4 W-IoU 位置损失函数

损失函数被用于衡量模型的预测输出与实际目标之间的差异或误差。已有的损失函数 GIoU (Generalized Intersection over Union) 能在更广义的层面上计算 IoU (Intersection over Union), 但是当两个预测框呈包含关系时不能反映出实际情况, 导致 GIoU 退化为 IoU 指标。此外, GIoU 对每个预测框与真实框均要计算最小外接框, 故损失函数计算和收敛速度受到限制。为了避免这个情况, 改进的网络中使用了 WIoU (Wise-IoU)^[22] 作为损失函数。通过在锚框与目标框重合时降低位置信息的权重, 减少对预训练的干扰, 以此提高模型的泛化能力。作为边界框回归损失, WIoUv3 引入了一种动态非单调机制, 并设计了一种合理的梯度增益分配策略, 以减少在极端样本中出现的大梯度或有害梯度。边界框回归的 WIoU 如图 6 所示。计算公式为

$$WIoU = L_{WIoUv3} = rL_{WIoUv1} \quad (6)$$

$$r = \frac{\beta}{\delta \alpha^{\beta-\delta}} \quad (7)$$

$$L_{WIoUv1} = R_{WIoU} L_{IoU} \quad (8)$$

$$R_{WIoU} = \exp\left(\frac{(x - x_{gt})^2 + (y - y_{gt})^2}{(W_g^2 + H_g^2)^*}\right) \quad (9)$$

式中: r 为梯度增益; β 为非单调聚焦系数; α, δ 为超参数; (x, y) 为预测框中心点坐标; (x_{gt}, y_{gt}) 为目标框中心点坐标; W_g 为预测框与目标框并集的宽; H_g 为预测框与目标框并集的高。

R_{WIoU} 用于放大普通质量锚框的权重, 使模型关注预测框与目标框重叠度较低的锚框; L_{IoU} 用于降低高质量锚框的权重, 进而减少对预测框与目标框重叠度较高时中心点间距离的关注; “*”表示将 W^c 和 H^c 从计算图中分离出来, 防止 R_{WIoU} 产生阻碍收敛的梯度。由于 L_{IoU} 是动态的, 锚框的质量划分标准也是动态的, 使得 WIoUv3 能够根据每个时刻的情况制定最符合当前情况的梯度增益分配策略, 从而提高目标检测的整体性能。




图 6 边界框回归示意图

Fig. 6 Illustration of bounding box regression

3 模型训练

3.1 试验环境与参数设置

本文所有试验所使用的训练及测试平台为 AutoDL 深度学习云计算平台, 具体配置参数: 中央处理器 CPU 为 15 核 AMD EPYC 7543, 80G 云存储空间; 图形处理器 GPU 为 1 块显存, 24GB 的 NVIDIA GeForce RTX 3090。训练环境为 Anaconda 搭建的隔离虚拟环境, 具体参数: 编程语言使用 Python3.8.10, 深度学习框架为 Pytorch1.9.0, CUDA 运算平台版本为 11.0。训练采用的批量大小 (batch size) 为 8, 初始学习率设置为 0.01, 动量设置为 0.937, 训练总轮数设置为 300, 后续不同算法对比试验中也将保持统一变量。

3.1.1 多尺度训练

由于在实际蔗田环境下无人机数据采集会出现甘蔗植株有多种复杂遮挡的情况, 加之无人机飞行高

度变化大,物体比例变化剧烈,因此无人机图像裁剪尺寸会出现差异。检测模型的性能受到输入图片尺寸的影响,基础网络通常生成比原图小数十倍的特征图,导致小物体的特征描述不容易被检测网络捕捉。通过输入更大、更多尺寸的图片进行训练,能够在一定程度上提高检测模型对物体大小的鲁棒性。因此,本试验采用多尺度训练策略,它是一种训练深度学习模型时使用不同输入图像尺寸的方法。这种训练策略旨在提高模型对不同目标尺寸和比例的适应性,使其更具有泛化能力。模型可以接受任意大小的图片作为输入,多尺度训练一个明显的好处是不增加推理时间。将多尺度训练应用到模型中,且以此作为网络优化的基础,后续试验均以此为 Baseline。

3.1.2 图像加权策略

本实试验数据集中, s - sugarcane 的数据量为 36 545, m - sugarcane 的数据量为 6 068, l - sugarcane 的数据量为 4 701。其中,轻度遮挡类别明显高于另外两种程度遮挡图片数量。在目标检测问题中,目标类别的个数区别较大属于类别不平衡问题,会导致模型在训练过程中对样本较多的类别更容易学到,而对样本较少的类别学习不足的情况。这可能使得模型在测试时对少数类别的目标识别能力较弱,影响整体的检测性能。在训练过程中为了减小类别不平衡问题的影响, YOLOv5 中引入了图像权重 (Image - Weight) 的设置,开启后会对于上一轮训练效果不好的图片在下一轮中增加一些权重。本试验训练时开启图像权重设置。

4 试验结果与分析

4.1 评价指标

本文试验使用准确率 (Precision, P)、召回率 (Recall, R) 和平均精度均值 (Average Precision, mAP) 对模型在测试集上检测性能进行评价。

4.2 试验对比分析

为了验证所提出模型的有效性,将本文改进后的 YOLOv5s 模型与 YOLOv7^[23]、YOLOv8^[24]、DETR^[25] 和 Faster-RCNN^[26] 等主流检测模型进行对比试验,所有模型均在同一数据集和同一训练设备下采用控制变量原则进行试验,结果如表 1 所示。

由表 1 可知:与 YOLO 其他系列原始模型相比, YOLOv5s 原始模型准确率、召回率、平均精度均值都更胜一筹。除此之外,与非 YOLO 系列模型的 DETR 与 Faster-RCNN 模型对比分析,本文改进 YOLOv5s 的

准确率、召回率、平均精度均值也高于前两者。

表 1 改进模型与其他检测模型对比

Table 1 Comparison between the improved model and other detection models

模型	准确率/%	召回率/%	平均精度均值/%
YOLOv5s	93.90	87.20	93.70
YOLOv7	88.20	69.10	80.20
YOLOv8	97.71	68.95	80.70
DETR		38.30	69.00
Faster-RCNN		23.40	60.40
改进 YOLOv5s	97.72	91.70	96.20

4.3 改进 YOLOv5 模型检测实例

图 7 为模型改进前后检测图像对比。从左到右依次为原图、改进前 YOLOv5s、改进后 YOLOv5 模型识别效果图。




图 7 部分图像甘蔗植株检测结果对比

Fig. 7 Comparison of detection results of sugarcane plants

由图 7 可知:YOLOv5s 原始模型存在不同程度的漏检现象,即使中度遮挡植株也未被检测出来,其原因是甘蔗植株在田间背景下蔗心特征不明显,在通过主干网络下采样和 FPN 结构上采样后会造成特征信息的丢失,导致在检测头处因特征信息不足引起漏检。而本文改进后的 YOLOv5s 模型,能识别出被遮挡的甘蔗植株,提升了漏检率。这说明,位于检测头前端的 NAM 注意力机制弱化了与植株相似的甘蔗地杂草背景对检测效果的影响,能够从复杂背景中检测出蔗心;Decoupled Head 加速了模型的收敛速度,提升了模型的整体性能。由于在计数问题中计数目标是否存在漏检是至关重要的,因此本研究针对复杂田间环境中甘蔗植株遮挡识别问题提出了有效的解决

方法。

4.4 计数试验结果与分析

本计数试验所有植株图像均按五点取样法进行取样。先随机选取确定对角线的中点作为中心取样点,再在对角线上选取与中心取样点距离相等的 4 个点进行取样。使用红绳作为标记框选出每个取样点的范围,标记出 5 个 5 m×5 m 的矩形框。如此 5 个矩形框为 1 组,取 6 组,共 30 个 5 m×5 m 矩形框。使用无人机拍摄取样矩形框的俯视图,将 30 块取样矩形框中甘蔗植株数量进行人工计数,每一幅图像上都进行 10 次人工统计,取平均值作为甘蔗植株数量的真实值。

本研究统计出测试集的 30 幅甘蔗图像中,轻度遮挡植株 959 株、中度遮挡 75 株、重度遮挡 52 株,共计 1 104 株;改进后 YOLOv5s 模型生成的甘蔗植株轻度遮挡植株 964 株、中度遮挡 79 株、重度遮挡 61 株,共计 1 086 株,漏检个数为 18,漏检率为 1.6%。本文模型对图像中的甘蔗植株计数误差较小。

5 结 论

本研究以无人机甘蔗作物图像为研究对象,针对图像中甘蔗植株叶片互相遮挡、目标粘连、背景信息复杂等问题,设计了一种基于改进 YOLOv5s 的甘蔗植株检测模型,提高了无人机图像甘蔗植株计数的精度。首先,通过在网络中使用基于归一化的注意力模块,增强了网络对特征点的感知,加强对中耕期甘蔗植株图像的特征学习和特征提取,同时弱化与甘蔗植株相似的甘蔗地杂草背景对检测结果的影响。其次,原始网络中的耦合头替换为改进的高效解耦头用以区分回归和分类,加快模型收敛速度,进一步提升甘蔗植株检测性能。同时,更改边界框损失函数为动态非单调聚焦机制 WIoU,提高模型收敛速度。最后,采用多尺度训练在一定程度上提高检测模型对物体大小的鲁棒性,可以接受任意大小的图片作为输入。

试验表明:改进的 YOLOv5s 模型准确率、召回率和平均精度均值分别为 97.72%、91.7% 和 96.2%,较原始 YOLOv5s 模型分别提高 3.82、4.5 和 2.5 个百分点。本研究统计出测试集的 30 幅甘蔗图像中甘蔗植株真实值为 1 104,改进 YOLOv5s 模型生成的甘蔗植株数为 1 086,漏检个数为 18,漏检率为 1.6%。本文改进模型对无人机图像中的甘蔗植株计数误差较小,可为甘蔗的检测计数、长势评估提供技术支撑。

参考文献:

- [1] 李佳慧,程琴,欧克纬,等.不同蔗区甘蔗品种(系)分蘖性状比较及其对产量和产量构成因子的影响[J].作物杂志,2021(5):79-86.
- [2] 吴建涛,刘福业,杨俊贤,等.粤糖系列甘蔗品种产量因子间相关和通径分析[J].中国农学通报,2012,28(12):66-71.
- [3] 张宏鸣,付振宇,韩文霆,等.基于改进 YOLO 的玉米幼苗株数获取方法[J].农业机械学报,2021,52(4):221-229.
- [4] 孙俊,杨锴锋,罗元秋,等.基于无人机图像的多尺度感知麦穗计数方法[J].农业工程学报,2021,37(23):136-144.
- [5] 杨丹彤,戴久翔,岳学军,等.一种便携式甘蔗田间测产系统:202210393815.5[P].2022-07-12.
- [6] 李修华,朱能志,潘雨蕴,等.一种基于深度神经网络的甘蔗幼苗自动识别与计数方法:202110671163.2[P].2021-09-14.
- [7] 孟颖晨.遥感技术在作物生长监测与估产中的应用分析[J].粮食科技与经济,2019,44(5):112-113,129.
- [8] 赵鑫,陈里里,杨维川,等.DY-YOLOv5:基于多重注意力机制的航拍图像目标检测[J].计算机工程与应用,2024,60(7):183-191.
- [9] 宋怀波,李嵘,王云飞,等.基于 ECA-YOLOv5s 网络的重度遮挡肉牛目标识别方法[J].农业机械学报,2023,54(3):274-281.
- [10] 鲍文霞,谢文杰,胡根生,等.基于 TPH-YOLO 的无人机图像麦穗计数方法[J].农业工程学报,2023,39(1):155-161.
- [11] 罗志聪,李鹏博,宋飞宇,等.嵌入式设备的轻量化百香果检测模型[J].农业机械学报,2022,53(11):262-269,322.
- [12] 马宁,曹云峰,王指辉,等.基于 YOLOv5 网络架构的着陆跑道检测算法研究[J].激光与光电子学进展,2022,59(14):199-205.
- [13] 邱天衡,王玲,王鹏,等.基于改进 YOLOv5 的目标检测算法研究[J].计算机工程与应用,2022,58(13):63-73.
- [14] LIU Y C, SHAO Z R, TENG Y Y, et al. NAM: normalization-based attention module. arXiv preprint [EB/OL]. [2021-11-24]. <https://arxiv.org/abs/2111.12419>.
- [15] ZHU X K, LYU S C, WANG X, et al. TPH-YOLOv5: Improved YOLOv5 based on transformer prediction head for object detection on drone-captured scenarios [EB/OL]. (2021-08-25) [2021-08-26]. <https://doi.org/10.48550/arXiv.2108.11539>.
- [16] GONG H, MU T K, LI Q X, et al. Swin-transformer-enabled YOLOv5 with Attention mechanism for small object de-

- tection on satellite images [J]. Remote sensing, 2022, 14 (12):2861.
- [17] IOFFE S, SZEGEDY C. Batch Normalization: accelerating deep network training by reducing internal covariate shift [EB/OL]. (2015-05-02) [2023-08-12]. <https://arxiv.org/abs/1502.03167>.
- [18] GAO A, FAN Z X, LI A N, et al. YOLO-Weld: a modified YOLOv5-based weld feature detection network for extreme weld noise [J]. Sensors, 2023, 23 (12):5640.
- [19] SONG G L, LIU Y, WANG X G. Revisiting the sibling head in object detector [C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. IEEE, 2020:11560-11569.
- [20] AHMAD H M, RAHIMI A. Deep learning methods for object detection in smart manufacturing: A survey [J]. Journal of manufacturing systems, 2022, 64:181-196.
- [21] GE Z, LIU S, WANG F, et al. YOLOX: Exceeding YOLO Series in 2021 [EB/OL]. (2021-07-18) [2024-01-11]. <https://arxiv.dosf.top/abs/2107.08430v2>.
- [22] TONG Z J, CHEN Y H, XU Z W, et al. Wise-IoU: bounding box regression loss with dynamic focusing mechanism [EB/OL]. (2023-08-08) [2023-08-12]. <https://arxiv.org/abs/2301.10051>.
- [23] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors [C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2023: 7464-7475.
- [24] 付锦燚, 张自嘉, 孙伟, 等. 改进 YOLOv8 的航拍图像小目标检测算法 [J]. 计算机工程与应用, 2024, 60 (6): 100-109.
- [25] ZHU Y, XIA Q Y, JIN W. Srdd: a lightweight end-to-end object detection with transformer [J]. Connection science, 2022, 34 (1):2448-2465.
- [26] REN S Q, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks [J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 39 (6):1137-1149.

Detection and Counting Method of Sugarcane Plants in Tillage Based on Improved YOLOv5s in UAV Images

Li Shangping^{1,2}, Tang Dan^{1,2}, Wen Chunming^{1,2}, Li Kaihua^{1,2}

(1. College of Electronic Information, Guangxi Minzu University, Nanning 530006, China; 2. Key Laboratory of Intelligent Unmanned System and Intelligent Equipment, Nanning 530006, China)

Abstract: In this study, the UAV images of sugarcane crops in the middle tillage period were taken as the research object, and a sugarcane detection and counting model based on improved YOLOv5s was designed to solve the problems of mutual occlusion of plant leaves, target adhesion and complex background information in the images. Firstly, by using the normalized attention module in the network, the feature learning and feature extraction of sugarcane plants in the middle tillage period in the image are strengthened, and the interference of weed background in sugarcane fields similar to sugarcane plants on the detection effect is weakened. Secondly, the coupling head in the original YOLOv5 network is replaced by an improved efficient decoupling head, which is used for decoupling calculation of classification and regression branches and improving the performance of sugarcane plant detection model. Finally, the loss function of bounding box is changed to dynamic nonmonotonic focusing mechanism WIoU to improve the convergence speed of the model. At the same time, multi-scale training is used to improve the robustness of the improved model to the size of the object to a certain extent, and finally the model can input pictures of any size. The experimental results show that the accuracy, recall and average precision of the improved YOLOv5s model are 97.72%, 91.7% and 96.2%, respectively, which are 3.82, 4.5 and 2.5 percentage points higher than the original YOLOv5s model. In this study, the actual value of sugarcane plants in the 30 sugarcane images in the test set is 1 104, and the number of sugarcane plants generated by the improved YOLOv5s model is 1 086, and the number of errors is 18, with an error rate of 1.6%, indicating that the improved model in this paper has a small error in counting sugarcane plants in UAV images. It can provide technical support for sugarcane detection, counting and growth evaluation.

Key words: sugarcane counting; UAV; image processing; YOLOv5s; decoupled head; normalize